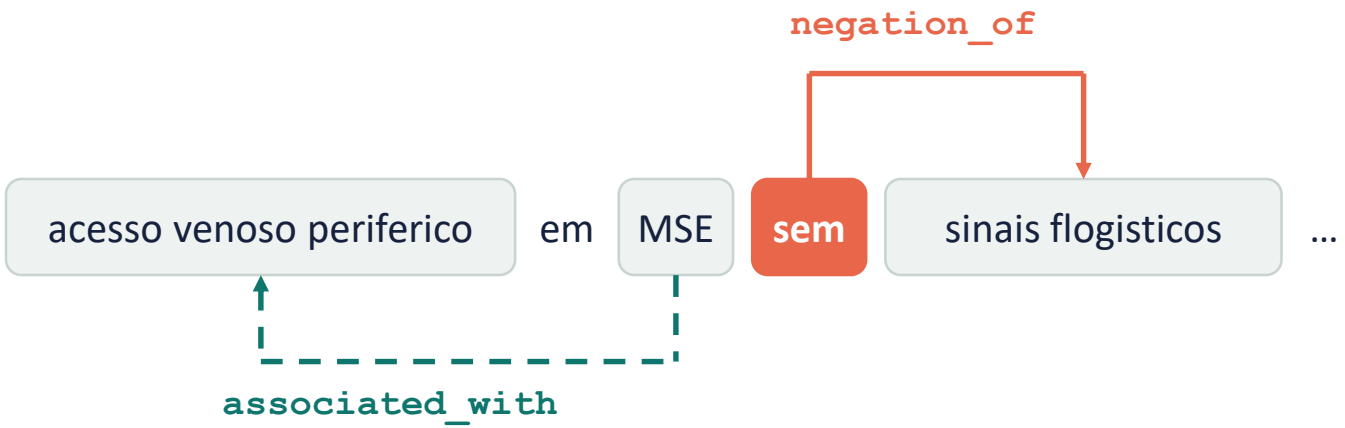
RECLin-PT: extração de relações em notas clínicas em português sobre o corpus SemClinBr, com ênfase na relação de negação

Angelo Antonio Lima Silveira Filho · Sistemas de Informação · Instituto Federal do Espírito Santo
Orientador: Prof. Dr. Cristiano da Silveira Colombo

Na nota clínica, negar não é o mesmo que afirmar

Trecho real anotado no SemClinBr



Documento 9091 (partição de treino), trecho parcial; grafia original, sem acentos. Outras relações associated_with do trecho foram omitidas.

1. **Texto livre**

   abreviações, telegrafismo e pouca pontuação padronizada

2. **Alto impacto**

   tratar um achado negado como presente inverte o sentido do prontuário

3. **SemClinBr**

   1.000 documentos anotados: o primeiro corpus clínico semântico em português

Fonte: elaborado pelo autor a partir de dados do SemClinBr (Oliveira et al., 2022).

PROBLEMA DE PESQUISA E OBJETIVO

Desenvolvimento do RECLin-PT para extração de relações clínicas

Pergunta de pesquisa

Como desenvolver um modelo para a extração de relações clínicas em português no corpus SemClinBr, com ênfase na identificação de relações de negação?

Contexto da literatura

Extração de relações clínicas

Uma tarefa específica no processamento de linguagem natural aplicado à saúde não aproveitada.

Shimaoka et al., 2026

Objetivo geral

Desenvolver o RECLin-PT para a extração de relações clínicas em português no corpus SemClinBr, com ênfase na identificação de relações de negação.

Escopo pares de entidades já anotadas (sem NER automático).

PROPOSTA: O RECLIN-PT

Do corpus ao modelo: ajustar, comparar e congelar

1 DADOS — *feito*

SemClinBr

Notas clínicas com entidades e relações anotadas.

800 / 100 / 100 documentos (treino, DEV, TEST)

2 PARES CANDIDATOS — *feito*

Um exemplo por par

Par marcado com `[E1]` e `[E2]` no texto.

… **`[E1] sem [/E1] [E2] sinais flogisticos [/E2]`** …

3 ENCODER — *três comparados*

Pré-treinado em português

- **BioBERTpt-all · clínico e biomédico**
- **BioBERTpt-clin · narrativas clínicas**
- **BERTimbau-base · domínio geral**

4 BASELINE — *ponto de partida*

Fine-tuning supervisionado

Ponto de partida: o par é classificado pelo `[CLS]`.

5 ESTUDOS DE ESTRATÉGIAS

resultados no DEV

Novas estratégias sobre o baseline

Cada uma comparada ao baseline no DEV.

↻ *ajustar a estratégia, treinar de novo e voltar ao passo 5*

6 MODELO — *pendente*

RECLin-PT

Encoder e estratégia congelados; avaliado no TEST uma vez.

`negation_of` · **`associated_with`** · `no_relation`

Fonte: elaborado pelo autor; exemplo: trecho do SemClinBr (Oliveira et al., 2022).

METODOLOGIA: DADOS E CONSTRUÇÃO DOS PARES

Do XML aos pares candidatos que o modelo recebe

XML do SemClinBr

1.000 documentos, com entidades já anotadas

→

Partição por documento

TRAIN / DEV / TEST: 800 / 100 / 100

→

Pares candidatos

190.960 pares, janela de 25 caracteres

Entrada do modelo: um exemplo por par ordenado

```
… SEGUE EM OBSERVAÇÃO. [E1] OSTEOMIELITE
[/E1] [E2] NÃO ESPECIFICADA [/E2].
INTUBADO, SOB …
```

Marcadores posicionais, sem o tipo semântico das entidades.

Classe minoritária

14%

das relações são negation_of

Fonte: elaborado pelo autor a partir de dados do SemClinBr (Oliveira et al., 2022).

PONTO DE PARTIDA: O BASELINE

Baseline: o par classificado pela representação global [CLS]



Ponto de partida

O Baseline utiliza apenas a representação global do [CLS] para classificar o par de entidades.

O que as entidades fazem?

As entidades [E1] e [E2] já estão na entrada, e influenciam a representação do [CLS] pela atenção do encoder.

E se a cabeça também recebesse representações específicas das duas entidades?

É essa a ideia da Pair-Aware Linear, que será apresentada no próximo slide.

Fonte: elaborado pelo autor, a partir do código do projeto (reclin); a Pair-Aware Linear é detalhada no slide seguinte.

ARQUITETURA PROPOSTA: PAIR-AWARE LINEAR

Pair-Aware Linear: a cabeça passa a ler as entidades



Mesma entrada e encoder

Mudam a cabeça classificadora e a origem do [CLS].

Fonte: elaborado pelo autor.

EXPERIMENTOS: ENCODERS E CONFIGURAÇÃO DE TREINO

Três encoders, mesma configuração de treino

BioBERTpt-all

domínio clínico e biomédico

177,9 M

parâmetros

BioBERTpt-clin

somente narrativas clínicas

177,9 M

parâmetros

BERTimbau-base

domínio geral (brWaC)

≈108 M

parâmetros (~61% do BioBERTpt)

Configuração de treino comum (não varia entre as execuções)

- até 128 tokens
- AdamW · lr 2×10^{-5}
- lote 64
- aquecimento 10%
- perda ponderada por classe
- 3 épocas (estágio 2: 10)
- seed 42
- Colab · GPU T4

A diferença de parâmetros vem do vocabulário; a arquitetura é a mesma (porte base).

PROTOCOLO DE AVALIAÇÃO E CLASSIFICAÇÃO DA PESQUISA

Escolhas só no DEV; o TEST, uma única vez

Protocolo registrado — *feito*

antes de qualquer treino; partições e configurações identificadas por hash

Escolhas no DEV — *feito*

época de cada execução

Congelamento — *pendente*

encoder e estratégia

TEST, uma vez — *pendente*

avaliação da configuração congelada

Métrica primária: F1 de negation_of

Também: precisão, recall e macro-F1 (média das 3 classes)

Comparações pareadas

Bootstrap pareado, 10.000 reamostras: há diferença se o IC95% exclui o zero.

Pesquisa **aplicada**, **quantitativa** e **experimental**

Fonte: elaborado pelo autor.

RESULTADOS PRELIMINARES (DEV, SEED 42)

F1 de negation_of entre 0,80 e 0,83 em todas as execuções

Encoder	Baseline	Pair-Aware	Two-Stage*
BioBERTpt-all	0,802	0,829	0,831
BioBERTpt-clin	0,814	0,826	0,832
BERTimbau-base	0,800	0,818	0,825

F1 da classe negation_of. DEV, uma seed (42); sem TEST.

Por que a Pair-Aware

- Um só modelo, sem limiar τ
- Recall 0,940, contra 0,867 do Two-Stage (BioBERTpt-all)

F1 do Two-Stage é ligeiramente maior; a diferença não é detectável.

Fonte: elaborado pelo autor.

RESULTADOS PRELIMINARES (DEV, SEED 42) · BIOBERTPT-ALL

O ganho da Pair-Aware veio de menos falsos positivos

Falsos positivos de negation_of

62 → 49

142 → 141 negações acertadas, de 150

Precisão	Recall	F1
0,742	0,940	0,829
antes 0,696 · +0,046	antes 0,947 · −0,007	antes 0,802 · +0,027

Baseline → Pair-Aware · BioBERTpt-all · DEV, seed 42

Onde ainda dá para ganhar

O recall já é alto (0,940): o espaço está na precisão (0,742)

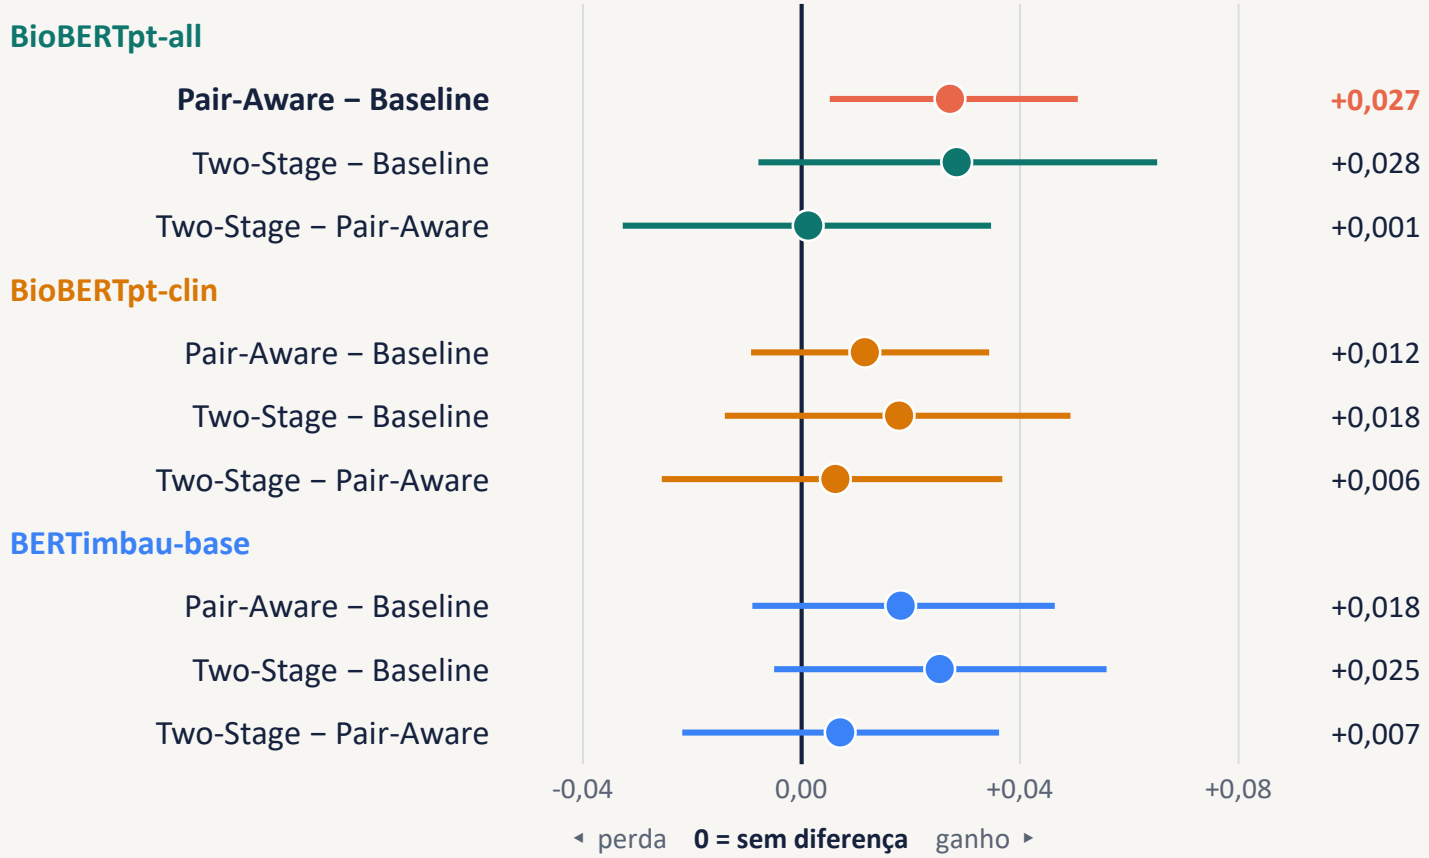
1. Auditar os 49 falsos positivos restantes e agrupar por tipo
2. Ajustar o limiar de decisão ou o peso de negation_of na perda
3. Incluir o tipo semântico das entidades nos marcadores

Hipóteses ainda não testadas: qualquer escolha seria feita só no DEV e avaliada no TEST uma única vez.

Fonte: elaborado pelo autor.

Pair-Aware: o único ganho detectável sobre o baseline

Ganho no F1 de negation_of do 1º sobre o 2º sistema, IC95% do bootstrap pareado



Precisão × recall de negation_of

Estratégia	Precisão	Recall
Baseline	0,70 a 0,72	0,92 a 0,95
Pair-Aware	0,71 a 0,74	0,94 a 0,96
Two-Stage	0,75 a 0,80	0,87 a 0,91

Faixas entre encoders. No Two-Stage com BioBERTpt, o F1 de associated_with cai (0,37 a 0,38, contra 0,41 a 0,43 no baseline); com BERTimbau, sobe (0,46 contra 0,42).

Fonte: elaborado pelo autor.

EXEMPLOS DO DEV (BIOBERTPT-ALL, SEED 42)

Onde as duas estratégias divergem, em casos reais

Baseline: falso positivo

… EM VM PCV COM 20 PI, **[E1] 14 [/E1] [E2] FR [/E2]**, 5 PEEP, 50% FIO2 …

Gold	associated_with	
Baseline	negation_of	✗
Pair-Aware	no_relation	✗

Pair-Aware erra

… abdome plano, flácido, **[E1] indolor [/E1]** à **[E2] palpação [/E2]**, RHA +.

Gold	negation_of	
Baseline	negation_of	✓
Pair-Aware	no_relation	✗

15 contra 2

falsos positivos que só o Baseline (15) ou só a Pair-Aware (2) comete

Nas 150 negações a diferença é mínima: 142 contra 141 acertos

Pair-Aware evita a negação, mas erra a classe.

Fonte: elaborado pelo autor; trechos do SemClinBr (Oliveira et al., 2022), grafia original.

CONTRIBUIÇÕES DO RECLIN-PT

O RECLin-PT como contribuição central

1

Desenvolvimento do RECLin-PT

Abordagem de extração de relações clínicas em português no SemClinBr, com ênfase em negation_of e a Pair-Aware como arquitetura proposta.

2

Avaliação experimental

Encoders e estratégias sob os mesmos dados e pares. No DEV, a Pair-Aware com BioBERTpt-all é a direção proposta: mais simples e com o único ganho detectável. O Two-Stage segue como alternativa experimental.

3

Reprodutibilidade

Dados reconstruídos dos XML, partições por hash, gerador único de pares, protocolo registrado e números ligados aos artefatos.

Síntese a Pair-Aware é a arquitetura proposta para o RECLin-PT; a configuração final e a avaliação no TEST continuam pendentes.

LIMITAÇÕES E PRÓXIMOS PASSOS

O que limita as conclusões e o que vem a seguir

Limitações

- Nenhuma avaliação no TEST: todos os números são de DEV
- Uma única seed: o DEV escolheu a direção; a variação do treino não foi medida
- Entidades gold: sem etapa automática de NER

Feito (DEV)

- ✓ Dados reconstruídos e partições congeladas por hash
- ✓ Baseline e Two-Stage com 3 encoders; Pair-Aware com 3
- ✓ Protocolo registrado e comparações pareadas no DEV

Pendente, em ordem

1. Refinar a precisão da Pair-Aware no DEV (filtros, fine-tuning)
2. Congelar a configuração final (encoder e estratégia)
3. Avaliar a configuração congelada no TEST, uma única vez

A Pair-Aware é a arquitetura proposta; as três execuções da Pair-Aware já estão no DEV, mas o encoder e a configuração final ainda não foram definidos.

Obrigado!

Perguntas?

RECLin-PT · github.com/angeloalsf/RECLin-PT

APÊNDICE · RESULTADOS COMPLETOS (DEV, SEED 42)

F1 de negation_of entre 0,80 e 0,83 em todas as execuções

Encoder	Estratégia	P neg	R neg	F1 neg	macro-F1
BioBERTpt-all	Baseline	0,696	0,947	**0,802**	0,719
BioBERTpt-clin	Baseline	0,722	0,933	**0,814**	0,731
BERTimbau-base	Baseline	0,708	0,920	**0,800**	0,723
BioBERTpt-all	Pair-Aware	0,742	0,940	**0,829**	0,741
BioBERTpt-clin	Pair-Aware	0,732	0,947	**0,826**	0,746
BERTimbau-base	Pair-Aware	0,713	0,960	**0,818**	0,736
BioBERTpt-all	Two-Stage (τ = 0,95)	0,798	0,867	**0,831**	0,725
BioBERTpt-clin	Two-Stage (τ = 0,95)	0,768	0,907	**0,832**	0,730
BERTimbau-base	Two-Stage (τ = 0,85)	0,753	0,913	**0,825**	0,751
BioBERTpt-all	*Pair-Aware MLP (exploratória)*	*0,715*	*0,953*	***0,817***	*0,737*

P, R e F1 da classe negation_of; macro-F1 das três classes. Cinza: exploratória.

Por que a Pair-Aware

- Recall 0,940, contra 0,867 do Two-Stage; um só modelo, sem τ
- Macro-F1 0,741, o maior com BioBERTpt-all (Two-Stage 0,725; Baseline 0,719)
- F1 acima do baseline nos 3 encoders (+0,012 a +0,027); IC fora do zero só com BioBERTpt-all

O F1 de negação do Two-Stage é ligeiramente maior (0,831 contra 0,829); a diferença não é detectável.

Ressalvas

- DEV, uma seed (42); sem TEST
- τ do Two-Stage escolhido no próprio DEV: valores otimistas
- Com BERTimbau, o maior macro-F1 é do Two-Stage (0,751)

Fonte: elaborado pelo autor a partir de metricas.json e predicoes_dev.json das execuções (branch resultados-colab, ad7c2a2); limiar.json para τ.

APÊNDICE · SITUAÇÃO DAS EXECUÇÕES

O que foi executado, o que falta e o que é exploratório

Estratégia	BioBERTpt-all	BioBERTpt-clin	BERTimbau-base
Baseline	executado	executado	executado
Pair-Aware	executado	executado	executado
Two-Stage estágios 1 e 2 treinados; composição e τ	**composto** τ = 0,95	**composto** τ = 0,95	**composto** τ = 0,85
Pair-Aware MLP exploratória	executado	—	—
Fine-tuning restrito (previsto)	*não executado*		

“Executado”: treinado, com época selecionada e avaliado no DEV. “—”: não prevista. Nenhuma execução foi avaliada no TEST. Baseline calibrado e filtro léxico existem apenas como execuções derivadas, fora do repositório; não entram nas comparações.

APÊNDICE · PROVENIÊNCIA DAS EXECUÇÕES

Pasta, checkpoint, épocas e parâmetros de cada execução

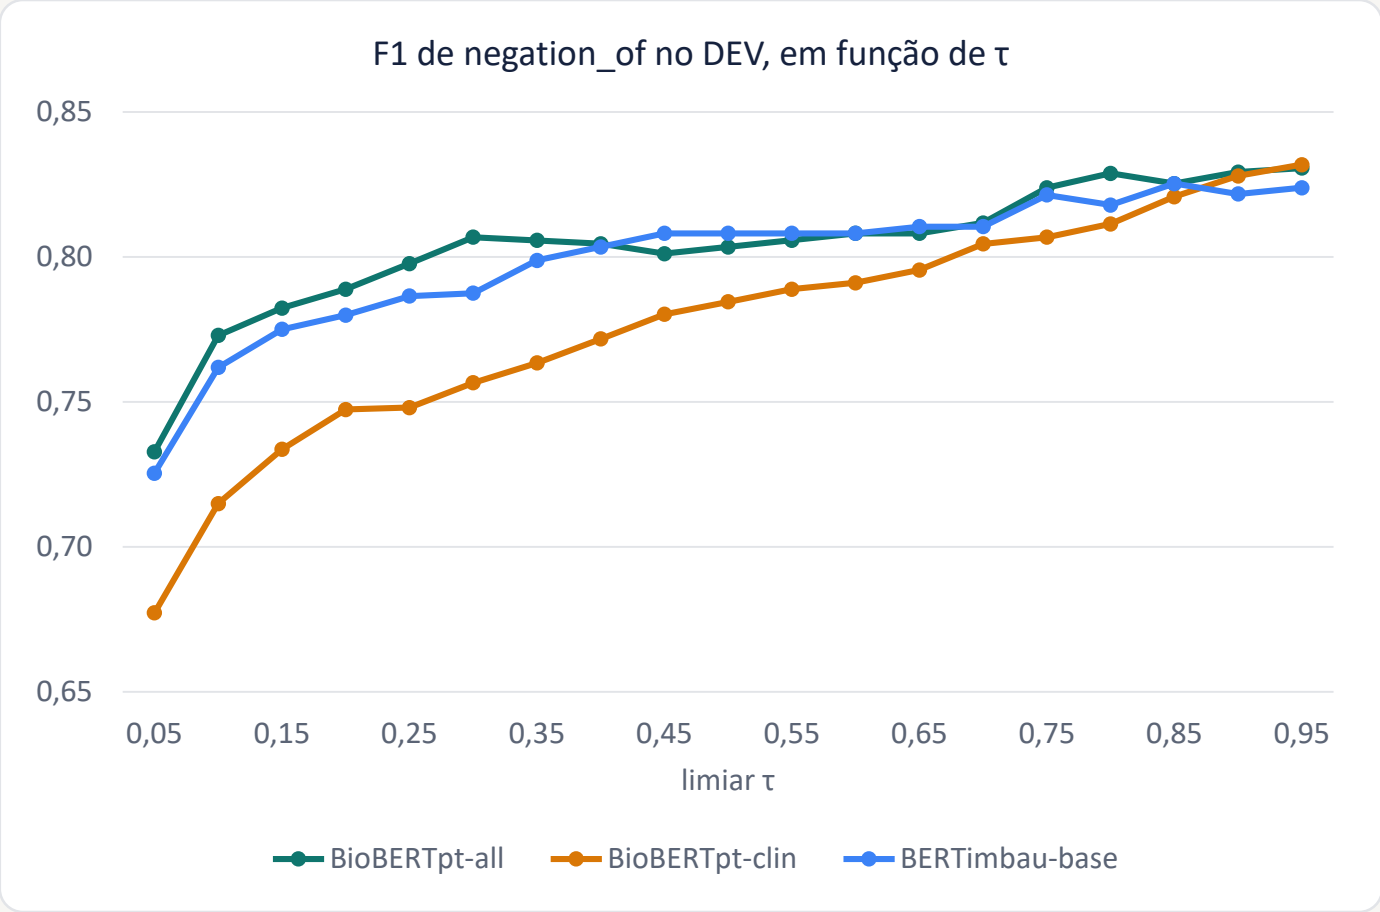
Pasta (resultados/execucoes/)	Checkpoint	Estratégia	Melhor época	Parâmetros	Seed
baseline_biobertpt_seed42	BioBERTpt-all@36b11cf	Baseline	3 de 3	177,9 M	42
baseline_BioBERTpt-clin	BioBERTpt-clin@b59beec	Baseline	3 de 3	177,9 M	42
baseline_BERTimbau	BERTimbau@94d69c9	Baseline	3 de 3	108,9 M	42
pairaware_biobertpt_seed42	BioBERTpt-all@36b11cf	Pair-Aware	3 de 3	177,3 M	42
pair_aware__6d11685f9cdb__t1	BioBERTpt-clin@b59beec	Pair-Aware	3 de 3	177,3 M	42
pair_aware__f7a5acb7f500__t1	BERTimbau@94d69c9	Pair-Aware	3 de 3	108,3 M	42
pair_aware_mlp_BioBERTpt-all	BioBERTpt-all@36b11cf	Pair-Aware MLP (explor.)	3 de 3	179,0 M	42
two_stage_limiar_BioBERTpt-all	BioBERTpt-all@36b11cf	Two-Stage ($\tau = 0{,}95$)	E1: 2 de 3 · E2: 8 de 10	177,9 M	42
two_stage_limiar_BioBERTpt-clin	BioBERTpt-clin@b59beec	Two-Stage ($\tau = 0{,}95$)	E1: 2 de 3 · E2: 6 de 10	177,9 M	42
twostage_bertimbau_seed42	BERTimbau@94d69c9	Two-Stage ($\tau = 0{,}85$)	E1: 3 de 3 · E2: 5 de 10	108,9 M	42

Dados v2-texto-fonte; AdamW, lr 2×10^{-5}, lote 64, 128 tokens, janela de 25 caracteres. Two-Stage: as pastas dos estágios (E1, E2) guardam o treino; limiar.json guarda τ e a data de congelamento (13/10, 16/10 e 19/10/2026). Parâmetros: com o mesmo encoder, a Pair-Aware tem 585.984 a menos que o Baseline, pois não usa o pooler (590.592) e a cabeça passa de 2.307 para 6.915.

Fonte: elaborado pelo autor a partir de treino.json, config.json, limiar.json (branch resultados-colab, ad7c2a2). Execuções de estágio do Two-Stage não têm campo test_avaliado.

APÊNDICE · LIMIAR DO TWO-STAGE (DEV)

O τ ficou no extremo da grade nos dois BioBERTpt



Encoder	τ	roteados	F1 neg	macro	assoc. → no_rel.	τ do macro máx.
BioBERTpt-all	0,95	592	0,831	0,725	541 de 763	0,90
BioBERTpt-clin	0,95	676	0,832	0,730	517 de 763	0,90
BERTimbau-base	0,85	1.494	0,825	0,751	278 de 763	0,85

Como ler

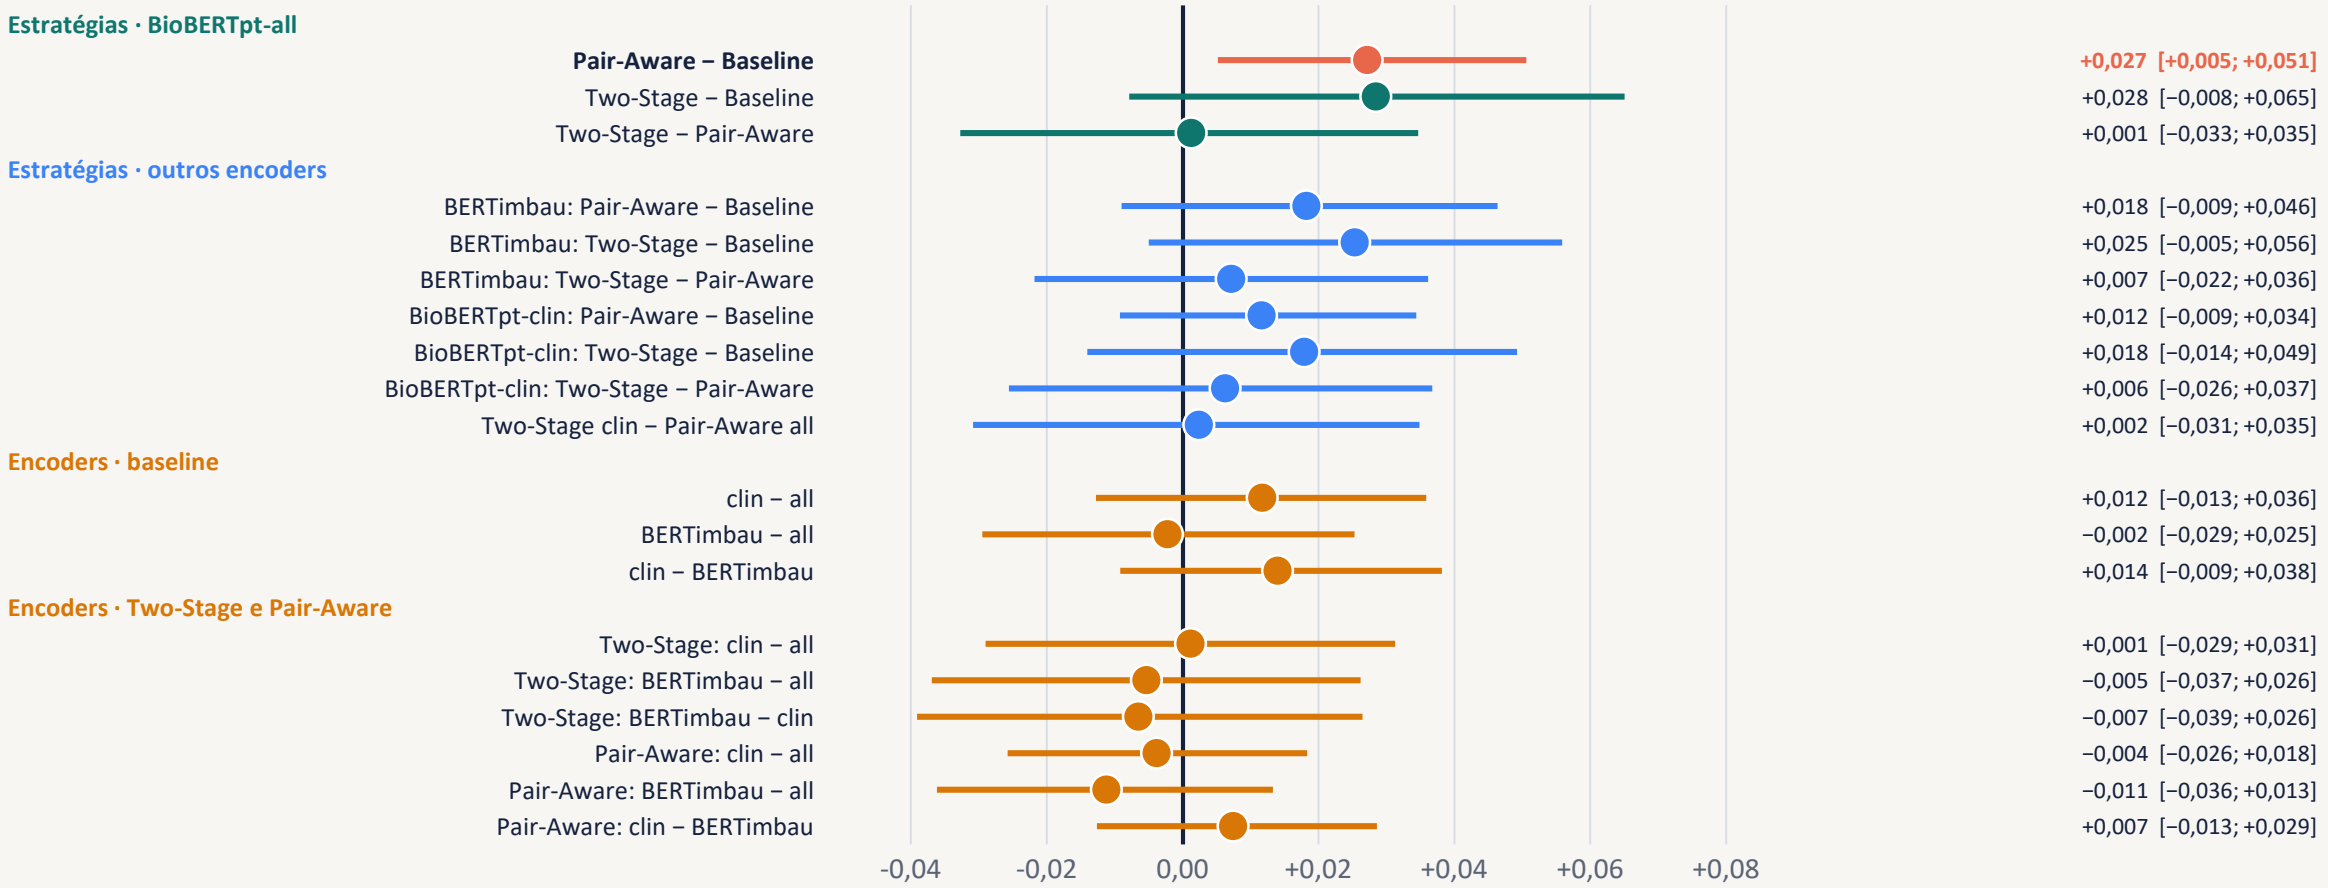
Nos dois BioBERTpt o máximo cai em τ = 0,95, o último ponto da grade: o máximo verdadeiro pode estar além. O critério, fixado antes dos resultados, olha só negation_of; o macro-F1 seria máximo em 0,90. Em associated_with, o custo é alto: 541 de 763 pares viram no_relation no BioBERTpt-all.

Fonte: elaborado pelo autor a partir de limiar.json (tabela da grade) e metricas.json das execuções (DEV). τ escolhido no próprio DEV: valores otimistas.

APÊNDICE · COMPARAÇÕES PAREADAS NO DEV

Só uma das 19 comparações exclui o zero

Ganho no F1 de negation_of do 1º sobre o 2º sistema e IC95% do bootstrap pareado (10.000 reamostras). A linha em 0 marca “sem diferença”.



Fonte: elaborado pelo autor a partir de analise_dev_clin.py (predicoes_dev.json). Uma seed: o IC mede só a incerteza entre exemplos. Sem correção para múltiplas comparações.

APÊNDICE · MÉTRICAS POR CLASSE (DEV)

associated_with é a classe mais difícil

Encoder	Estratégia	P neg	R neg	F1 neg	F1 assoc.	F1 no_rel.	macro-F1	MCC
BioBERTpt-all	Baseline	0,696	0,947	0,802	0,408	0,946	0,719	0,480
BioBERTpt-clin	Baseline	0,722	0,933	0,814	0,426	0,952	0,731	0,489
BERTimbau-base	Baseline	0,708	0,920	0,800	0,417	0,951	0,723	0,480
BioBERTpt-all	Pair-Aware	0,742	0,940	0,829	0,436	0,956	0,741	0,497
BioBERTpt-clin	Pair-Aware	0,732	0,947	0,826	0,454	0,958	0,746	0,514
BERTimbau-base	Pair-Aware	0,713	0,960	0,818	0,435	0,955	0,736	0,497
BioBERTpt-all	Two-Stage (τ = 0,95)	0,798	0,867	0,831	0,366	0,978	0,725	0,462
BioBERTpt-clin	Two-Stage (τ = 0,95)	0,768	0,907	0,832	0,380	0,977	0,730	0,464
BERTimbau-base	Two-Stage (τ = 0,85)	0,753	0,913	0,825	0,461	0,968	0,751	0,505
BioBERTpt-all	*Pair-Aware MLP (exploratória)*	*0,715*	*0,953*	*0,817*	*0,438*	*0,956*	*0,737*	*0,498*

Fonte: elaborado pelo autor; metricas.json recalculadas a partir de predicoes_dev.json (DEV, seed 42).

Ambiente e bibliotecas dos experimentos

1. **Google Colab**
   treino e avaliação no DEV
2. **GPU Tesla T4**
   15 GB; CUDA 13.0
3. **Python**
   3.13 (treino); 3.10 (dados)
4. **PyTorch 2.11.0**
   treino dos modelos
5. **Transformers 5.16.1**
   encoders e tokenizadores
6. **Tokenizers 0.23.2**
   Hugging Face Hub 1.29.0
7. **NumPy 2.1.3 · SciPy 1.16.3**
   análises numéricas
8. **Determinismo**
   sementes fixas, algoritmos determinísticos do PyTorch
9. **Código próprio**
   pacote Python; repositório RECLin-PT (branch resultados-colab)

Fonte: elaborado pelo autor a partir do capítulo de metodologia do TCC (Preparação do ambiente) e experimento.json das execuções (DEV, seed 42).