

RECLin-PT: Extração de Relações em Notas Clínicas em Português sobre o Corpus SemClinBr

Angelo A. L. Silveira Filho¹, Cristiano da Silveira Colombo¹

¹Bacharelado em Sistemas de Informação
Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo (IFES)
Cachoeiro de Itapemirim – ES – Brasil

angeloalsf@gmail.com cristiano.colombo@gmail.com

Abstract. *Clinical free text concentrates information whose interpretation depends on the relation between concepts, particularly the negation of findings. As the initial stage of developing **RECLin-PT** — an improved clinical relation extraction (RE) model for Portuguese — this work reports the baseline results that ground that development. We fine-tune two Portuguese encoders under an identical experimental pipeline (the supporting infrastructure, not a named model): a clinical-domain one (BioBERTpt) and a general-domain one (BERTimbau), over the SemClinBr corpus in a three-class space (negation, association and no-relation), changing only the pre-trained checkpoint. On the frozen test set, the two baselines are statistically tied on the `negation_of` F1 under the reference seed (0.724 vs. 0.734; McNemar $p = 0.18$; paired bootstrap 95% CI $[-0.047, +0.026]$), but this verdict does not hold across the two seeds we tested: seed-to-seed variation exceeds the gap between the models, and the clinical encoder leads under neither seed. These initial results indicate that RECLin-PT can be built upon the best-performing baseline, with no significant penalty from adopting the more efficient general encoder.*

Resumo. *O texto clínico livre concentra informação cuja interpretação depende da relação entre conceitos, em especial a negação de achados. Como etapa inicial do desenvolvimento do **RECLin-PT** — um modelo aprimorado de extração de relações (Relation Extraction, RE) clínicas em português —, este trabalho apresenta os resultados dos baselines que fundamentam esse desenvolvimento. Ajustamos dois encoders para o português sob uma mesma infraestrutura experimental, um de domínio clínico (BioBERTpt) e um de domínio geral (BERTimbau), sobre o corpus SemClinBr, em um espaço de três classes (negação, associação e ausência de relação), variando apenas o checkpoint de pré-treino. No conjunto de teste congelado, os dois baselines empatam estatisticamente no F1 de `negation_of` na semente de referência (0,724 vs. 0,734; McNemar $p = 0,18$; bootstrap pareado IC95% $[-0,047; +0,026]$), mas esse veredito não se sustenta nas duas sementes testadas: a variação entre sementes supera a diferença entre os modelos, e o encoder clínico não lidera em nenhuma delas. Esses resultados iniciais indicam que o RECLin-PT pode ser construído a partir do melhor baseline, sem penalidade significativa ao adotar o encoder geral, mais eficiente.*

1. Introdução

O registro eletrônico em saúde concentra grande parte da informação clínica sob a forma de texto livre. Notas de evolução, sumários de alta e laudos são redigidos em linguagem natural, com abreviações idiossincráticas, ausência frequente de pontuação padronizada e construções negativas características do discurso médico. Essa riqueza textual, embora valiosa para pesquisa e apoio à decisão, permanece majoritariamente inacessível a consultas estruturadas, o que motiva o desenvolvimento de técnicas de Processamento de Linguagem Natural (PLN) capazes de transformar texto clínico em conhecimento estruturado.

O reconhecimento de entidades nomeadas identifica menções a conceitos clínicos (sintomas, doenças, achados, procedimentos), mas isoladamente não captura como esses conceitos se articulam no enunciado. Saber que um documento menciona “febre” não é suficiente: é preciso distinguir se a febre está associada ao quadro do paciente ou se está sendo negada (“paciente afebril”). Esse vínculo é o objeto da extração de relações (*Relation Extraction*, RE), modelada aqui como a classificação de um par ordenado de entidades (e_1, e_2) dentro do espaço de rótulos `negation_of`, `associated_with` e `no_relation`.

A negação clínica é um fenômeno linguístico de alto impacto: tratar um achado negado como presente pode inverter completamente a interpretação de um prontuário. Em português, a negação é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”), e há a expectativa difundida de que modelos pré-treinados sobre texto do próprio domínio clínico capturem melhor essas construções do que modelos de domínio geral. Essa expectativa, contudo, é raramente testada de forma controlada para o português: trabalhos costumam adotar um modelo clínico por hipótese, sem isolar o efeito do pré-treinamento de domínio sob protocolo estatístico rigoroso.

Este trabalho integra o desenvolvimento do **RECLin-PT**, um modelo aprimorado de extração de relações em texto clínico em português sobre o corpus SemClinBr. Como etapa inicial dessa construção, conduz-se um experimento controlado de *baselines* para responder a uma questão fundamental que fundamenta as decisões de projeto seguintes: **o pré-treinamento clínico importa para a extração de relações em textos médicos em português?** Para respondê-la, comparam-se dois *encoders* para o português na *mesma* tarefa de RE sobre o SemClinBr [Oliveira et al. 2022], mudando *somente* o *checkpoint* de pré-treino: o BioBERTpt [Schneider et al. 2020], adaptado a narrativas clínicas e biomédicas em português, e o BERTimbau [Souza et al. 2020], pré-treinado em texto de domínio geral (brWaC). Ambos são ajustados sob uma única cadeia determinística, compartilhando a representação de entrada, a função de perda, o escalonador, a seleção de modelo, as métricas e a semente, de modo que qualquer diferença observada possa ser atribuída ao pré-treinamento, e não a artefatos de implementação. O RECLin-PT será, então, desenvolvido a partir do *encoder* que se mostrar a melhor base nesses *baselines*.

As contribuições iniciais deste trabalho são: (i) uma infraestrutura experimental reproduzível e controlada — do texto bruto às métricas finais — que viabiliza a comparação justa de *baselines* para o desenvolvimento do RECLin-PT; (ii) uma comparação empírica, com teste de significância pareado, entre um *encoder* clínico e um geral sobre o SemClinBr; e (iii) a identificação da melhor base sobre a qual construir o RECLin-PT, observando que o *encoder* de domínio geral alcança o clínico — e, nas

sementes testadas, nunca fica atrás dele — inclusive na classe de negação, com cerca de 60% dos parâmetros. O restante do trabalho está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica; a Seção 3 detalha a metodologia; a Seção 4 reporta os resultados iniciais dos *baselines*; e a Seção 5 traz as considerações parciais.

1.1. Trabalhos relacionados

A extração de relações clínicas consolidou-se em língua inglesa em torno de campanhas de avaliação como as séries i2b2 e n2c2 [Uzuner et al. 2011], que disponibilizaram corpora anotados e tarefas compartilhadas para problemas como relações entre medicamentos, dosagens e efeitos adversos. Esses esforços estabeleceram protocolos de avaliação e evidenciaram a importância de tratar adequadamente o desbalanceamento de classes e o vazamento de dados entre partições — preocupações transpostas para este trabalho. No plano dos modelos, o BioBERT [Lee et al. 2020] demonstrou ganhos da adaptação de domínio biomédico em inglês, e técnicas de representação de pares por marcadores de entidade [Baldini Soares et al. 2019] tornaram-se padrão para RE com modelos baseados em BERT.

O desenvolvimento de PLN clínico em português foi por muito tempo limitado pela ausência de corpora anotados de acesso controlado. O Sem-ClinBr [Oliveira et al. 2022] preencheu parte dessa lacuna ao disponibilizar mil documentos clínicos anotados semanticamente, acompanhados de dicionários de abreviações e de pistas de negação. No plano dos modelos, o BioBERTpt [Schneider et al. 2020] adaptou o paradigma de modelos contextuais ao domínio clínico em português, demonstrando ganhos em reconhecimento de entidades nomeadas em relação a modelos de domínio geral; o BERTimbau [Souza et al. 2020], por sua vez, é a referência de domínio geral para o português. Enquanto boa parte da literatura em português concentra-se em NER e adota um modelo clínico por hipótese, o RECLin-PT aborda a etapa subsequente de RE e, como ponto de partida, *testa* de forma controlada se o ganho do pré-treinamento clínico observado em NER se transfere para a extração de relações, com atenção particular à negação clínica.

2. Fundamentação Teórica

2.1. Processamento de linguagem natural clínico

O PLN clínico ocupa-se da análise automática de textos produzidos no cuidado em saúde. Esses textos apresentam características que os distinguem da linguagem geral: vocabulário técnico, abreviações não padronizadas, telegrafismo (omissão de elementos gramaticais) e prevalência de construções negativas e de incerteza. Tais propriedades tornam a transferência direta de ferramentas treinadas em domínio aberto pouco eficaz, motivando recursos e modelos específicos do domínio — hipótese cuja validade, para a tarefa de RE em português, é justamente a questão que orienta esta etapa inicial do trabalho.

2.2. Extração de relações

A extração de informação em texto clínico costuma ser decomposta em duas tarefas encadeadas. A primeira, o reconhecimento de entidades nomeadas, delimita trechos do texto que mencionam conceitos de interesse e lhes atribui um tipo semântico. A segunda, a RE,

determina se um par de entidades mantém uma relação e de que tipo. Formalmente, dado um par ordenado (e_1, e_2) em um documento, a RE é modelada como um problema de classificação que associa ao par um rótulo dentro de um conjunto pré-definido. Neste trabalho o espaço de rótulos é *negation_of*, *associated_with* e *no_relation*. O rótulo *no_relation* é fundamental: como a anotação de corpora registra apenas relações positivas, todo par de entidades não anotado deve ser tratado como ausência de relação, o que introduz um forte desbalanceamento de classes.

2.3. A negação clínica

Em detecção de negação clínica, o algoritmo NegEx [Chapman et al. 2001] tornou-se referência: a partir de um léxico de gatilhos de negação e de janelas de contexto, classifica achados como negados ou afirmados. Sua eficácia deriva do fato de a negação clínica ser altamente lexicalizada. Em português, gatilhos como “não”, “sem”, “nega” e “ausência de”, além de adjetivos que embutem negação morfológicamente (“afebril”, “anictérico”), sustentam estratégias análogas. A alta lexicalização sugere que o sinal de negação possa estar acessível mesmo a modelos não especializados no domínio, o que torna a comparação entre *encoders* clínico e geral particularmente informativa.

2.4. Modelos baseados em *Transformers*

A arquitetura *Transformer* [Vaswani et al. 2017], baseada em mecanismos de atenção, viabilizou modelos de linguagem pré-treinados que produzem representações contextuais das palavras. O BERT [Devlin et al. 2019] popularizou o paradigma de pré-treinamento seguido de ajuste fino (*fine-tuning*) para tarefas específicas. Para o português, há tanto modelos de domínio geral, como o BERTimbau [Souza et al. 2020], pré-treinado no corpus brWaC, quanto modelos de domínio clínico, como o BioBERTpt [Schneider et al. 2020], adaptado a narrativas clínicas e biomédicas em português brasileiro. Esses dois modelos compartilham a mesma arquitetura base (BERT) e diferem essencialmente no corpus de pré-treinamento, o que os torna candidatos naturais a um experimento controlado sobre a importância do domínio de pré-treino.

3. Metodologia

Os dois *encoders* avaliados — BioBERTpt e BERTimbau — são tratados como *baselines*, comparados para identificar a melhor base sobre a qual o RECLin-PT será desenvolvido. A infraestrutura experimental descrita a seguir não constitui um modelo com nome próprio: é apenas a cadeia que viabiliza essa comparação de forma justa e reproduzível. A premissa metodológica central é a *paridade*: os dois *baselines* compartilham um único núcleo de implementação e diferem apenas no *checkpoint* de pré-treino. Todas as etapas foram projetadas sob reprodutibilidade: ordenação determinística das saídas, serialização fixa e semente aleatória registrada (42).

3.1. Corpus SemClinBr e representação canônica

Utiliza-se o corpus SemClinBr [Oliveira et al. 2022], composto por mil documentos clínicos em português anotados com entidades e relações, distribuído sob licença restrita. Um *parser* determinístico converte cada arquivo XML em um registro canônico no formato JSONL, com identificador do documento, texto, lista de entidades (tipo e *offsets*)

e lista de relações. O *parser* é fiel ao XML e executa verificações de sanidade (correspondência entre o texto extraído por *offset* e o atributo anotado, validade dos intervalos e integridade referencial das relações), corrigindo automaticamente pequenos deslocamentos de *offset* (± 1 e ± 2 caracteres) e acumulando as inconsistências em um log de avisos.

A análise da representação canônica totaliza 1.000 documentos, 45.508 entidades (média de 45,5 por documento) e 11.458 relações (média de 11,5; mediana de 10; máximo de 65 por documento); 46 documentos (4,60%) não possuem relação anotada. As relações distribuem-se de forma fortemente desbalanceada entre os dois tipos anotados: *associated_with* responde por 9.852 ocorrências (86,0%) e *negation_of* por 1.606 (14,0%). Esse desequilíbrio motiva tanto a escolha do macro-F1 como métrica principal quanto o tratamento explícito de classes no ajuste dos *baselines*.

3.2. Particionamento dos dados

A partição segue a razão 80/10/10 em nível de *documento*, e não de relação. Essa escolha previne o vazamento de dados: relações de um mesmo documento compartilham vocabulário e trechos repetidos, e dividi-las entre partições diferentes inflaria artificialmente as métricas de teste. A partição é estratificada pela presença das classes *negation_of* e *associated_with* em cada documento, por meio do algoritmo de estratificação multirrótulo de [Sechidis et al. 2011], de modo a garantir representação estável da classe minoritária. A partição é gerada com semente fixa (42) e congelada. O resultado são 800 documentos de treino, 100 de desenvolvimento e 100 de teste; a proporção de *negation_of* permanece estável (entre 13,7% e 15,0%) em todas as partições, condição necessária para que a estimativa de F1 dessa classe no teste seja confiável.

3.3. Geração de pares candidatos

O SemClinBr anota apenas relações positivas. Avaliar um classificador no espaço $\{\text{negation_of}, \text{associated_with}, \text{no_relation}\}$ exige, portanto, construir os exemplos negativos. A geração é feita por uma função compartilhada por ambos os *baselines* — condição necessária para que os resultados fiquem na mesma régua estatística. Para cada documento, percorrem-se todos os pares ordenados de entidades (e_1, e_2) , $e_1 \neq e_2$ (a ordem importa, porque a direção é relevante para a negação); descartam-se os pares cuja distância exceda a janela máxima ($\text{max_gap} = 20$) e os pares entre documentos distintos; e atribui-se o rótulo: se o par ordenado coincide com uma relação anotada, recebe o tipo *gold*; caso contrário, recebe *no_relation*. A emissão segue ordenação determinística, de modo que o conjunto de candidatos e o *hash* das predições sejam estáveis entre execuções.

O procedimento gera 128.380 candidatos de treino, 15.994 de desenvolvimento e 16.074 de teste. A consequência é um conjunto de teste fortemente desbalanceado: a classe *no_relation* concentra 14.959 instâncias (93,1%), enquanto *associated_with* e *negation_of* somam, respectivamente, 964 e 151. A janela impõe um teto de *recall*: relações cujo par fique além de *max_gap* jamais são geradas como candidato. No teste, esse limite é desprezível para a negação (151 de 152 relações *gold* preservadas), mas mais sensível para *associated_with*, fixando um teto de *recall* documentado para essa classe. Como ambos os *baselines* recebem exatamente os mesmos candidatos, o teto é idêntico para os dois e não afeta a comparação.

3.4. Representação de entrada: marcadores tipados e grupos UMLS

Cada par candidato é transformado na *string* de entrada do *encoder* com marcadores de entidade tipados, no esquema [E1] <grupo> : superfície [/E1] ... [E2] <grupo> : superfície [/E2]. Os quatro marcadores são registrados como *tokens* especiais no *tokenizer*, a ordem (e_1, e_2) preserva a direção da relação, e a representação do par alimentada ao cabeçote de classificação é a concatenação dos estados ocultos dos marcadores de início, na linha de [Baldini Soares et al. 2019].

O campo <grupo> não é o tipo bruto da entidade. O SemClinBr anota cada entidade com tipos semânticos da UMLS, frequentemente em rótulos múltiplos separados por “|” (por exemplo, Medical Device|Finding|Abbreviation). Usar a *string* de tipo diretamente faria o número de símbolos distintos explodir (centenas de combinações mal povoadas no treino), prejudicando a generalização. A solução agrega os tipos atômicos nos 15 grupos semânticos da UMLS [McCray et al. 2001] — por exemplo, DISO (transtornos), CHEM (químicos e fármacos), PROC (procedimentos) —, acrescidos de duas camadas próprias do corpus que carregam sinal relevante para a tarefa: Abbreviation e Negation (esta diretamente associada à classe negation_of). Como a mesma representação de entrada é aplicada aos dois *baselines*, qualquer efeito dessa escolha é compartilhado e não confunde a comparação.

3.5. Baselines comparados e paridade

Comparam-se dois *encoders* para o português, tratados como *baselines* sob a mesma tarefa, variando apenas o *checkpoint* de pré-treino:

- **BioBERTpt** (pucpr/biobertpt-all) — *encoder* de domínio *clínico*, com 177,9 milhões de parâmetros [Schneider et al. 2020].
- **BERTimbau** (neuralmind/bert-base-portuguese-cased) — *encoder* de domínio *geral*, pré-treinado no brWaC, com 108,9 milhões de parâmetros [Souza et al. 2020].

Os dois compartilham um único núcleo de implementação e, portanto, são idênticos por construção em tudo, exceto o modelo: a representação de entrada por marcadores tipados; a perda de entropia cruzada com `class_weight="balanced"`, que reescala o erro de forma inversamente proporcional à frequência de cada classe (sem o que o otimizador minimizaria o erro prevendo `no_relation` para quase tudo); o escalonador linear com *warmup*; a seleção da melhor época pelo macro-F1 no conjunto de desenvolvimento; e a semente de reprodutibilidade (42). Trocar um *baseline* pelo outro consiste apenas em mudar o *checkpoint* carregado. O melhor *baseline* identificado por esse protocolo será a base do RECLin-PT.

3.6. Protocolo de avaliação

A métrica principal é o macro-F1, que atribui peso igual às três classes e, portanto, penaliza modelos que ignoram as classes minoritárias — comportamento desejável dado o desbalanceamento. Classes ausentes nas predições recebem F1 nulo, conforme [Forman and Scholz 2010]. Reportam-se também o F1 por classe, o micro-F1 (acurácia), o *weighted*-F1 e o coeficiente de correlação de Matthews (MCC), robusto a desbalanceamento. A métrica que responde diretamente à pergunta “o modelo detecta bem a negação?” é o F1 de `negation_of` no teste.

A comparação entre os dois *baselines* emprega dois testes complementares, calculados sobre o mesmo conjunto de teste a partir das predições salvas. O teste de McNemar [Dietterich 1998] olha apenas os casos em que os modelos discordam no acerto (b = o primeiro acerta e o segundo erra; c = o inverso) e, sob a hipótese nula de mesma taxa de acerto, avalia $b \sim \text{Binomial}(b + c, 0,5)$ pelo teste binomial exato; mede se os padrões de erro globais diferem. O *bootstrap* pareado no F1 de `negation_of` reamostra os exemplos do teste com reposição 10.000 vezes e recalcula a diferença $F1_A - F1_B$, reportando a diferença média, o intervalo de confiança de 95% (percentis 2,5/97,5) e um valor- p bilateral; mede diretamente se a vantagem na negação é robusta. Como análise de robustez à variação de inicialização, ambos os *baselines* são treinados também com uma segunda semente (43).

3.7. Ambiente experimental

O ajuste fino é executado em GPU (Google Colab, Tesla T4); o parsing, o particionamento, a geração de candidatos e os testes de significância executam em CPU. Os principais hiperparâmetros são: `max_length` de 128 *tokens*, janela de contexto de 128 caracteres em torno do par, tamanho de lote 64, taxa de aprendizado 2×10^{-5} (AdamW), 3 épocas e seleção de modelo por macro-F1 no desenvolvimento. Esses valores são idênticos para os dois *baselines*.

4. Resultados Iniciais

Esta seção reporta os resultados iniciais dos *baselines*, que orientarão o desenvolvimento do RECLin-PT. Todos os modelos foram avaliados sobre o mesmo conjunto de teste, composto por 16.074 pares candidatos (14.959 `no_relation`, 964 `associated_with` e 151 `negation_of`). A Tabela 1 consolida os resultados dos dois *baselines* na semente 42. Os melhores valores por coluna estão em negrito.

Tabela 1. Resultados dos *baselines* no conjunto de teste (semente 42). Negrito indica o melhor valor por coluna.

Baseline	Macro-F1	F1 neg.	F1 assoc.	F1 no_rel.	MCC	Acur.
BioBERTpt (clínico)	0,707	0,724	0,460	0,935	0,487	0,885
BERTimbau (geral)	0,704	0,734	0,445	0,934	0,471	0,882

4.1. Desempenho dos dois *baselines*

Os dois *baselines* apresentam desempenho praticamente indistinguível. O BioBERTpt clínico atinge macro-F1 de 0,707 e o BERTimbau geral, 0,704 — uma diferença de 0,003. Na métrica-alvo, o F1 de `negation_of`, a ordem inclusive se inverte: o BERTimbau geral (0,734) supera marginalmente o BioBERTpt clínico (0,724). As demais métricas seguem o mesmo padrão de quase empate: ambos alcançam *recall* alto na negação (BioBERTpt 0,894; BERTimbau 0,887) com precisão moderada ($\approx 0,61$ – $0,63$), e ambos têm na classe `associated_with` a maior dificuldade (F1 $\approx 0,45$ – $0,46$), com alta cobertura mas baixa precisão, refletindo a dificuldade de distinguir associação genuína de mera proximidade textual. A Figura 1 resume o F1 por classe dos dois *baselines*.




Figura 1. F1 por classe no conjunto de teste: BioBERTpt (clínico) vs. BERTimbau (geral). As barras são praticamente coincidentes em todas as classes.

4.2. Matrizes de confusão

As Figuras 2 e 3 apresentam as matrizes de confusão dos dois *baselines*, normalizadas por linha (cada célula é a fração das instâncias de uma classe verdadeira atribuída a cada classe predita; a diagonal corresponde ao *recall* por classe). Os dois padrões de erro são notavelmente semelhantes: diagonal forte na negação e na classe majoritária, e o erro dominante remanescente na confusão entre *associated_with* e *no_relation* — coerente com a baixa precisão daquela classe nos dois modelos. A semelhança qualitativa entre as matrizes reforça a leitura de que os dois *encoders* aprendem essencialmente a mesma função para esta tarefa.




Figura 2. Matriz de confusão do BioBERTpt (clínico), normalizada por linha.




Figura 3. Matriz de confusão do BERTimbau (geral), normalizada por linha.

4.3. Significância estatística

A proximidade dos valores pontuais sugere empate, mas a conclusão exige um teste pareado. A Tabela 2 reporta a comparação direta entre os dois *baselines* no conjunto de teste. No F1 de `negation_of`, a diferença observada é de apenas $-0,010$ (a favor do BioBERTpt geral). O teste de McNemar não rejeita a hipótese nula de igualdade ($p = 0,18$): das 946 instâncias em que os modelos discordam, 494 favorecem o BioBERTpt e 452 o BERTimbau, uma assimetria compatível com o acaso. O *bootstrap* pareado confirma o resultado: o intervalo de confiança de 95% para a diferença no F1 de `negation_of` é $[-0,047; +0,026]$, que *inclui o zero*, com valor- p de 0,57. Em ambos os testes, portanto, **não há diferença estatisticamente significativa** entre o *encoder* clínico e o geral *nesta semente* — ressalva relevante, pois a análise de robustez à semente, a seguir, mostra que esse veredito não se repete na semente 43.

Tabela 2. Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no teste ($n = 16.074$, semente 42).

Medida	Valor
F1 <code>negation_of</code> — BioBERTpt (A)	0,724
F1 <code>negation_of</code> — BERTimbau (B)	0,734
Diferença observada (A – B)	$-0,010$
McNemar: b (só A acerta) / c (só B acerta)	494 / 452
McNemar: valor- p (binomial exato)	0,18
<i>Bootstrap</i> pareado: IC95% da diferença	$[-0,047; +0,026]$
<i>Bootstrap</i> pareado: valor- p	0,57
Diferença significativa ($\alpha = 0,05$)?	Não

4.4. Robustez à semente

Para situar a magnitude da diferença entre os *baselines*, treinamos ambos com uma segunda semente (43). No BioBERTpt, o macro-F1 cai de 0,707 (semente 42) para 0,665 (semente 43), e o F1 de `negation_of`, de 0,724 para 0,653 — uma variação de 0,071 atribuível *apenas* à inicialização aleatória do treino. Essa variação entre sementes de um *mesmo* modelo é cerca de sete vezes maior que a diferença de 0,010 observada entre o BioBERTpt e o BERTimbau na semente 42. Em outras palavras, o ruído de treino do *encoder* clínico, isoladamente, é maior que a vantagem que se poderia atribuir ao domínio de pré-treino, o que reforça a leitura de empate.

O BERTimbau, sob a mesma troca de semente, mostra-se sensivelmente mais estável: o macro-F1 passa de 0,704 para 0,706 e o F1 de `negation_of`, de 0,734 para 0,726 — uma amplitude de 0,008, cerca de nove vezes menor que a do BioBERTpt na mesma métrica. Na semente 43 a ordenação entre os dois *baselines* no F1 de negação se mantém, com margem de 0,073, e o mesmo protocolo de significância aplicado à semente 42 acusa agora uma diferença significativa em favor do BERTimbau (McNemar $p < 10^{-30}$; *bootstrap* pareado IC95% $[-0,115; -0,031]$, $p = 0,0002$) — ao contrário do que se observa na semente 42, em que o mesmo teste não rejeita a hipótese nula. Esse contraste não estabelece a superioridade do *encoder* geral: o que ele mostra é que o próprio *veredito* do teste pareado, sob protocolo e conjunto de teste idênticos, alterna entre “sem

diferença” e “diferença significativa” em função apenas da inicialização do treino. O que atravessa as duas sementes é o sinal — em nenhuma delas o pré-treinamento clínico aparece à frente — e a menor previsibilidade do *encoder* clínico entre reinicializações, o que, em um cenário de implantação, pesa a favor do geral.

4.5. Análise dos resultados

O resultado central é a *ausência de vantagem do pré-treinamento clínico*: para a extração de relações no SemClinBr, no espaço de três classes, o BioBERTpt não produz ganho mensurável sobre o BERTimbau, nem mesmo na classe de negação, onde a especialização de domínio seria mais plausível. Convém precisar o que os testes sustentam: o veredito de empate vale para a semente 42 e não se repete na semente 43, em que a comparação pareada favorece o BERTimbau. O que se mantém entre as duas sementes não é o empate, e sim a direção — em nenhuma delas o *encoder* clínico fica à frente. Esse achado contrasta com a expectativa difundida — e com os ganhos relatados para NER clínico em português [Schneider et al. 2020] — de que modelos de domínio sempre se transfiram melhor.

Duas explicações são plausíveis e compatíveis com os dados. Primeiro, a negação clínica em português é fortemente lexicalizada (“não”, “sem”, “nega”, “afebril”); esse sinal é frequente e regular o bastante para que um *encoder* de domínio geral, com vocabulário amplo do português, o capture tão bem quanto um clínico, sobretudo quando reforçado pelos marcadores tipados de entrada e pela camada *Negation* dos grupos UMLS. Segundo, a tarefa, tal como formulada, depende mais da estrutura local do par (direção, proximidade, tipos semânticos das entidades) do que de conhecimento lexical especializado de domínio, e essa estrutura é fornecida igualmente aos dois *baselines* pela representação de entrada compartilhada.

Um corolário prático — e diretamente relevante para o desenvolvimento do RECLin-PT — é a eficiência: o BERTimbau iguala o BioBERTpt com aproximadamente 60% dos parâmetros (108,9 vs. 177,9 milhões). Quando o desempenho é equivalente, o modelo menor é preferível por custo de inferência e de memória — uma consideração concreta para implantação em ambientes clínicos com recursos limitados, e um argumento a favor de construir o RECLin-PT sobre o *encoder* geral.

4.6. Limitações e ameaças à validade

Quanto à validade interna, o congelamento das partições com semente fixa e o particionamento em nível de documento mitigam o vazamento de dados, a principal causa de resultados não reproduzíveis em PLN biomédico; e a paridade total de implementação entre os dois *baselines* garante que a diferença medida reflita o *checkpoint*, e não artefatos. Persiste, porém, uma decisão de projeto: a janela *max_gap* na geração de pares descarta relações verdadeiras mais distantes, impondo um teto de *recall* à classe *associated_with*; como esse teto é idêntico para os dois *baselines*, ele não afeta a comparação, mas limita o desempenho absoluto reportado. Uma ressalva mais séria recai sobre a própria caracterização de empate: ela vale para a semente 42, e a comparação pareada refeita na semente 43 acusa diferença significativa em favor do BERTimbau. Nenhuma das duas sementes coloca o *encoder* clínico à frente, de modo que a conclusão prática — ausência de ganho atribuível ao pré-treinamento clínico — não depende da semente; a leitura estatística, porém, depende, e não deve ser tomada como definitiva a

partir de uma única execução por modelo. Duas sementes por modelo tampouco bastam para estimar um intervalo de confiança sobre essa variação; fechar a questão exige um número maior de repetições com agregação formal.

Quanto à validade externa, a tarefa pressupõe entidades já anotadas (*gold*): a avaliação não considera o erro propagado de uma etapa de NER automática, de modo que os resultados refletem a RE isoladamente. Além disso, o SemClinBr, apesar de multi-institucional e multiespecialidade, representa um conjunto específico de instituições e estilos de redação; a generalização para outros contextos clínicos e para outros espaços de relação deve ser feita com cautela. Por fim, o achado de empate é específico desta formulação de três classes e desta escala de modelo (*base*); não se pode excluir que o pré-treinamento clínico volte a importar em espaços de relação mais ricos, em modelos maiores ou em cenários com menos dados de ajuste — hipóteses a serem exploradas na construção do RECLin-PT.

5. Considerações Parciais

Este trabalho apresentou os resultados iniciais de um experimento controlado de *baselines*, etapa inicial do desenvolvimento do **RECLin-PT**, um modelo aprimorado de extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, no espaço de rótulos `negation_of`, `associated_with` e `no_relation`. Comparando um *encoder* clínico (BioBERTpt) e um geral (BERTimbau) sob uma infraestrutura experimental idêntica que varia apenas o *checkpoint* de pré-treino, não se observou vantagem do pré-treinamento clínico. Na semente 42, a diferença no F1 de `negation_of` é de 0,010 e não é significativa (McNemar $p = 0,18$; *bootstrap* pareado IC95% $[-0,047; +0,026]$); na semente 43, a mesma comparação pareada passa a favorecer o BERTimbau. O veredicto estatístico, portanto, não é estável entre sementes — a variação de inicialização de um mesmo modelo supera com folga a diferença entre eles —, mas a direção é: em nenhuma das sementes testadas o *encoder* clínico fica à frente. O geral alcança o clínico com cerca de 60% dos parâmetros.

Esses resultados iniciais orientam diretamente a próxima etapa: o RECLin-PT será desenvolvido a partir do *encoder* de melhor desempenho identificado nos *baselines*. Como o BERTimbau geral não fica atrás em nenhuma das sementes testadas na métrica-alvo `negation_of` e exige cerca de 60% dos parâmetros, ele se apresenta como a base mais atraente por sua eficiência. O desenvolvimento do RECLin-PT terá como foco o aprimoramento da classe `negation_of`, a mais crítica para a correta interpretação clínica. O trabalho encontra-se, portanto, em andamento: os *baselines* aqui reportados estabelecem o ponto de partida, e não um encerramento.

Como próximos passos, além do desenvolvimento do RECLin-PT propriamente dito, prevê-se: estimar o desempenho dos *baselines* sob múltiplas sementes de treino, para um intervalo de confiança da diferença mais estreito; estender o espaço de relações para além das três classes atuais; avaliar modelos maiores e *encoders* multilíngues [Conneau et al. 2020]; e integrar uma etapa de NER automática, medindo a extração de relações em um cenário fim a fim.

Referências

- Baldini Soares, L., FitzGerald, N., Ling, J., and Kwiatkowski, T. (2019). Matching the blanks: Distributional similarity for relation learning. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 2895–2905. Association for Computational Linguistics.
- Chapman, W. W., Bridewell, W., Hanbury, P., Cooper, G. F., and Buchanan, B. G. (2001). A simple algorithm for identifying negated findings and diseases in discharge summaries. *Journal of Biomedical Informatics*, 34(5):301–310.
- Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., and Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 8440–8451. Association for Computational Linguistics.
- Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*, pages 4171–4186. Association for Computational Linguistics.
- Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7):1895–1923.
- Forman, G. and Scholz, M. (2010). Apples-to-apples in cross-validation studies: pitfalls in classifier performance measurement. *ACM SIGKDD Explorations Newsletter*, 12(1):49–57.
- Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., and Kang, J. (2020). BioBERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240.
- McCray, A. T., Burgun, A., and Bodenreider, O. (2001). Aggregating UMLS semantic types for reducing conceptual complexity. *Studies in Health Technology and Informatics*, 84:216–220.
- Oliveira, L. E. S., Peters, A. C., da Silva, A. M. P., Gebelucá, C. P., Gumiel, Y. B., Cintho, L. M. M., Carvalho, D. R., Al Hasan, S., and Moro, C. M. C. (2022). SemClinBr – a multi-institutional and multi-specialty semantically annotated corpus for Portuguese clinical NLP tasks. *Journal of Biomedical Semantics*, 13(1):13.
- Schneider, E. T. R., de Souza, J. V. A., Knafo, J., Oliveira, L. E. S., Copara, J., Gumiel, Y. B., Oliveira, L. F. A., Paraiso, E. C., Teodoro, D., and Barbosa, C. M. C. M. (2020). BioBERTpt – a Portuguese neural language model for clinical named entity recognition. In *Proceedings of the 3rd Clinical Natural Language Processing Workshop*, pages 65–72. Association for Computational Linguistics.
- Sechidis, K., Tsoumakas, G., and Vlahavas, I. (2011). On the stratification of multi-label data. In *Machine Learning and Knowledge Discovery in Databases (ECML PKDD 2011)*, volume 6913 of *Lecture Notes in Computer Science*, pages 145–158. Springer.
- Souza, F., Nogueira, R., and Lotufo, R. (2020). BERTimbau: Pretrained BERT models for Brazilian Portuguese. In *Intelligent Systems (BRACIS 2020)*, volume 12319 of *Lecture Notes in Computer Science*, pages 403–417. Springer.

- Uzuner, Ö., South, B. R., Shen, S., and DuVall, S. L. (2011). 2010 i2b2/VA challenge on concepts, assertions, and relations in clinical text. *Journal of the American Medical Informatics Association*, 18(5):552–556.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30.