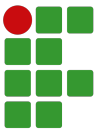
Diferenças entre a revisão da cronologia e a revisão da E3 (decisões de 02/11/2026)

~~Texto removido em vermelho, riscado.~~

Texto adicionado em verde.

A figura do ciclo de desenvolvimento foi alterada (etapas 6 a 8 e nota); a versão nova aparece no lugar da anterior.



INSTITUTO FEDERAL
Espírito Santo
Campus Cachoeiro de Itapemirim

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

TRABALHO DE GRADUAÇÃO

ANGELO ANTONIO LIMA SILVEIRA FILHO

RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS SOBRE O CORPUS SEMCLINBR

Cachoeiro de itapemirim

2026

ANGELO ANTONIO LIMA SILVEIRA FILHO

RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS SOBRE O CORPUS SEMCLINBR

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Cristiano da Silveira Colombo

Coorientadora: Profa. Dra. Beltrana de Tal

Cachoeiro de itapemirim

2026

(Biblioteca do Campus Cachoeiro de Itapemirim)

X999y

RECLin-PT: extração de relações em notas clínicas em português sobre o corpus SemClinBr/ Angelo Antonio Lima Silveira Filho. – 2026.

89 f: il; 30 cm.

Orientador: Cristiano da Silveira Colombo

Trabalho de Graduação – Instituto Federal do Espírito Santo, Bacharelado em Sistemas de Informação, 2026.

1. Processamento de linguagem natural. 2. Extração de relações. 3. Informática em saúde. 4. Aprendizado de máquina. 5. Língua portuguesa. I. Colombo, Cristiano da Silveira. II. Título. III. Instituto Federal do Espírito Santo.

CDD 000.00

Elaborada por XXXXXXXXXXXXXXXXXXXXX – CRB-X/ES - XXX

ANGELO ANTONIO LIMA SILVEIRA FILHO

RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS SOBRE O CORPUS SEMCLINBR

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Aprovado em 01 de Agosto de 2026

COMISSÃO EXAMINADORA

Prof. Dr. Cristiano da Silveira Colombo
Instituto Federal do Espírito Santo
Orientador

Profa. Dra. Beltrana de Tal
Instituto Federal do Espírito Santo
Coorientadora

Profa. Dra. Fulana de Tal
Instituto Federal do Espírito Santo
Examinadora

Prof. Dr. Cicrano de Tal
Instituto Federal do Espírito Santo
Examinador

À minha mãe, meu alicerce de força e superação, que esteve ao meu lado mesmo nos dias em que eu já não tinha vontade de continuar. Que jamais me desamparou diante das dificuldades e, com amor, coragem e fé, tornou-se o meu maior exemplo de vida. Tudo o que sou carrega um pouco da sua força. Aos meus amigos de jornada, que foram âncora e apoio durante todo o processo.

“Citação a ser escolhida.”

(Autor, ano)

RESUMO

O registro eletrônico em saúde concentra grande parte da informação clínica em texto livre, no qual a relação entre conceitos, em especial a negação de achados, é determinante para a correta interpretação. Este trabalho desenvolve o RECLin-PT, um modelo de extração de relações em notas clínicas em português sobre o corpus SemClinBr, com ênfase na relação `negation_of`, no espaço de rótulos `negation_of`, `associated_with` e `no_relation`. A definição de sua configuração é orientada por experimentos controlados, que investigam como a escolha do *encoder* pré-treinado e da estratégia de modelagem influencia o desempenho, com todas as alternativas avaliadas sobre os mesmos dados e pares candidatos e sob um protocolo pré-registrado que fixa os critérios de seleção no conjunto de desenvolvimento (DEV) e reserva o conjunto de teste para uma avaliação única, posterior ao congelamento da configuração. A arquitetura oficial do RECLin-PT é a Pair-Aware linear, que classifica o par a partir das representações do `[CLS]` e dos marcadores das duas entidades. Os resultados apresentados são preliminares, todos no DEV, com semente 42, e cruzam três *encoders* (BioBERTpt-all, BioBERTpt-clin e BERTimbau-base) com três estratégias (baseline, Pair-Aware linear e Two-Stage). Com os três *encoders*, a Pair-Aware linear alcança F1 de `negation_of` de 0,829, 0,826 e 0,818, acima do baseline, e tem macro-F1 maior que o do baseline com diferença detectada pelo *bootstrap* pareado nos três, inclusive por documento; no F1 de `negation_of`, a diferença só é detectada com o BioBERTpt-all. O Two-Stage, que detecta a existência de relação antes de decidir o tipo, alcança F1 de `negation_of` equivalente (0,825 a 0,832), sem diferença detectada para a Pair-Aware linear, mas depende de um limiar escolhido no DEV que, com os dois BioBERTpt, sacrificou a classe `associated_with`. Nenhuma comparação entre *encoders* detectou diferença no F1 de `negation_of`~~; o BERTimbau-base, de domínio geral, usa cerca de 61% dos parâmetros dos BioBERTpt~~. A configuração ~~final do RECLin-PT, inclusive o *encoder*, ainda não foi selecionada: dependem dela uma emenda ao protocoloque defina as comparações principais da~~ de referência atual é a Pair-Aware ~~linear e a avaliação no teste~~linear com o BioBERTpt-all, *encoder* do protocolo, e a semente 42, mas não é definitiva: novos experimentos seguem permitidos no DEV, e o teste será usado uma única vez, só para o modelo final, após o congelamento.

Palavras-chave: Extração de relações. Processamento de linguagem natural clínico. Língua portuguesa. SemClinBr. Aprendizado de máquina.

ABSTRACT

Electronic health records store much clinical information as free text, in which the relationship between concepts, particularly the negation of findings, is decisive for correct interpretation. This work develops RECLin-PT, a relation extraction model for Portuguese clinical notes on the SemClinBr corpus, with emphasis on the `negation_of` relation, in the label space `negation_of`, `associated_with` and `no_relation`. The definition of its configuration is informed by controlled experiments that investigate how the choice of pre-trained encoder and of modelling strategy influences performance, with all alternatives evaluated on the same data and candidate pairs and under a pre-registered protocol that fixes selection criteria on the development set (DEV) and reserves the test set for a single evaluation after the configuration is frozen. The official RECLin-PT architecture is the linear Pair-Aware model, which classifies the pair from the representations of `[CLS]` and of the two entity markers. The results reported here are preliminary, all on DEV, with seed 42, and cross three encoders (BioBERTpt-all, BioBERTpt-clin and BERTimbau-base) with three strategies (baseline, linear Pair-Aware and Two-Stage). With the three encoders, linear Pair-Aware reaches `negation_of` F1 of 0.829, 0.826 and 0.818, above the baseline, and has a higher macro-F1 than the baseline, with a difference detected by the paired bootstrap for all three, including at document level; in `negation_of` F1, the difference is detected only with BioBERTpt-all. Two-Stage, which detects whether a relation exists before deciding its type, reaches an equivalent `negation_of` F1 (0.825 to 0.832), with no difference detected from linear Pair-Aware, but it depends on a threshold chosen on DEV that, with both BioBERTpt models, sacrificed the `associated_with` class. No encoder comparison detected a difference in `negation_of` F1~~; the general-domain BERTimbau-base uses about 61% of the parameters of the BioBERTpt models. The final RECLin-PT configuration , including the encoder, has not yet been selected: it depends on a protocol amendment defining the main comparisons of linear Pair-Aware and on the test-set evaluation~~. The current reference configuration is linear Pair-Aware with BioBERTpt-all, the protocol encoder, and seed 42, but it is not final: further experiments remain allowed on DEV, and the test set will be used only once, for the final model only, after freezing.

Keywords: Relation extraction. Clinical natural language processing. Portuguese language. SemClinBr. Machine learning.

LISTA DE FIGURAS

Figura 1 – Exemplo real de anotação de um documento do SemClinBr (documento 9091, trecho): entidades anotadas, com seus identificadores, e relações entre elas. 30
Figura 2 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200), com a janela `max_gap` assinalada. 35
Figura 3 – Ciclo de desenvolvimento do RECLin-PT e estado atual de cada etapa. 54
Figura 4 – Matrizes de confusão no DEV (normalizadas por linha, contagens entre parênteses): baseline, Pair-Aware linear e Two-Stage, BioBERTpt-all, seed 42. 59
Figura 5 – Two-Stage no DEV: F1 de `negation_of` e macro-F1 do *pipeline* completo em função do limiar τ, para os três *encoders*. 63

LISTA DE TABELAS

Tabela 1 – Distância em caracteres entre as entidades de cada relação anotada (corpus completo). 35

Tabela 2 – Partições congeladas: documentos, entidades, relações anotadas e pares candidatos (max_gap$=25$). 36

Tabela 3 – Relações anotadas por partição com outras sementes do particionamento e posição da semente 42. 37

Tabela 4 – Documentos quase duplicados identificados no corpus (as partições não foram alteradas). 37

Tabela 5 – Relações anotadas que se tornam pares candidatos com max_gap$=25$ (teto de *recall*), por partição. 40

Tabela 6 – Sensibilidade ao max_gap (treino e desenvolvimento): pares candidatos, cobertura das relações e pares no_relation por relação coberta. * valor adotado. 40

Tabela 7 – Controles diagnósticos com o tipo semântico Negation anotado, no treino e no DEV. 42

Tabela 8 – Resultados no DEV das três estratégias com os três *encoders*, da variante MLP e dos controles: precisão (P), *recall* (R) e F1 de negation_of, VP/FP/FN, F1 das outras classes, macro-F1 e MCC. . 56

Tabela 9 – associated_with e no_relation no DEV: precisão, *recall*, F1, VP/FP/FN e AP de associated_with. 57

Tabela 10 – Comparações pareadas descritivas da Pair-Aware linear, no DEV: diferenças de F1 de negation_of, de F1 de associated_with e de macro-F1. 58

Tabela 11 – Comparação entre *encoders* dentro de cada estratégia, no DEV (mesma configuração; só o *checkpoint* de pré-treino muda). 61

Tabela 12 – Falsos positivos de associated_with no DEV: origem e precisão por faixa de distância entre os argumentos. 62

Tabela 13 – Two-Stage no DEV, por *encoder*: o que o estágio 1 encaminha com o τ congelado e quanto o estágio 2 acerta do tipo. 63

Tabela 14 – Comparações pareadas descritivas do Two-Stage e do baseline calibrado, no DEV (as comparações que o protocolo prevê para o teste, aqui aplicadas ao DEV e estendidas aos três *encoders*). . . . 64
Tabela 15 – Busca de τ do Two-Stage no DEV para os três *encoders* (*pipeline* completo, fluxo real). * valor congelado (maior F1 de `negation_of`). 83
Tabela 16 – Evolução por época no DEV das execuções de três rótulos. $*$ marca a época selecionada (maior macro-F1 no DEV). 85
Tabela 17 – Two-Stage: valor do critério de seleção de cada estágio por época, no DEV, para os três *encoders*. Em negrito, a época selecionada. . 86
Tabela 18 – Resultado exploratório no DEV (fora do protocolo pré-registrado): Pair-Aware MLP ao lado da Pair-Aware do protocolo, BioBERTpt-all, seed 42. 87
Tabela 19 – Inventário das execuções da branch `resultados-colab` e das execuções derivadas só do DEV. 89

LISTA DE QUADROS

Quadro 1 – Hiperparâmetros e configuração do *fine-tuning*, comuns às estratégias treinadas. 29
Quadro 2 – Ambientes de execução e versões das principais bibliotecas. . . . 31
Quadro 3 – Exemplo de geração de candidatos para um trecho do SemClinBr. 39
Quadro 4 – Entrada efetivamente construída para o par *gold* do Quadro 3. . . 49
Quadro 5 – SHA-256 das partições congeladas e do manifesto. 80
Quadro 6 – Léxico de pistas congelado (D4): `min_freq`$= 10$, 8 formas, `lexico_sha1` `8af0716633e9`. 81

LISTA DE ABREVIATURAS

ABNT	Associação Brasileira de Normas Técnicas
AP	*Average Precision* (Precisão Média)
BERT	*Bidirectional Encoder Representations from Transformers*
CRLF	*Carriage Return + Line Feed*
DEV	Conjunto de desenvolvimento (*development set*)
EDA	*Exploratory Data Analysis* (Análise Exploratória de Dados)
i2b2	*Informatics for Integrating Biology and the Bedside*
IC	Intervalo de Confiança
IFES	Instituto Federal do Espírito Santo
MCC	*Matthews Correlation Coefficient* (Coeficiente de Correlação de Matthews)
n2c2	*National NLP Clinical Challenges*
NER	*Named Entity Recognition* (Reconhecimento de Entidades Nomeadas)
NLP	*Natural Language Processing* (Processamento de Linguagem Natural)
PLN	Processamento de Linguagem Natural
RE	*Relation Extraction* (Extração de Relações)
SemClinBr	*Semantically Annotated Corpus for Portuguese Clinical NLP*
XML	*Extensible Markup Language*

SUMÁRIO

1 INTRODUÇÃO 17
1.1 Problema de pesquisa 17
1.2 Motivação 18
1.3 Objetivos 19
1.3.1 Objetivo geral 19
1.3.2 Objetivos específicos 20
2 REFERENCIAL TEÓRICO 21
2.1 Processamento de linguagem natural clínico 21
2.2 Extração de entidades e de relações 21
2.3 Abordagens baseadas em regras e a negação clínica 22
2.4 Modelos baseados em *transformers* 22
2.5 Representação do par e decomposição da decisão 23
3 TRABALHOS RELACIONADOS 24
3.1 Recursos e desafios em inglês 24
3.2 Recursos para o português e posicionamento deste trabalho 24
4 METODOLOGIA 27
4.1 *Fine-tuning* de *encoders* pré-treinados 27
4.2 O *dataset* SemClinBr 29
4.3 Preparação do ambiente 31
4.4 Métricas utilizadas para avaliar os modelos 32
4.5 Preparação dos dados 34
4.5.1 Reconstrução dos dados e alinhamento dos offsets 34
4.5.2 Caracterização do corpus 34
4.5.3 Particionamento dos dados 35
4.5.4 Geração de pares candidatos 38
4.5.5 Teto de recall imposto pela janela 39
4.5.6 Tipos semânticos e controles diagnósticos 41
4.6 Protocolo pré-registrado e comparações estatísticas 42
5 PROPOSTA DO RECLIN-PT 46
5.1 Paridade entre os sistemas comparados 46
5.2 Os *encoders* 47

5.3 Representação de entrada: marcadores de posição 48
5.4 Estratégias de modelagem 49
5.4.1 Baseline 49
5.4.2 Baseline calibrado 49
5.4.3 Filtro léxico 50
5.4.4 Pair-Aware linear: a arquitetura oficial 50
5.4.5 Two-Stage 51
6 EXPERIMENTOS E RESULTADOS 53
6.1 Execuções e conferência dos registros 54
6.2 Treino e seleção de época 55
6.3 Visão geral 55
6.4 A Pair-Aware linear frente às demais estratégias 57
6.5 O efeito do *encoder* 60
6.6 A classe `associated_with` 60
6.7 O Two-Stage em detalhe 62
6.8 Resultado exploratório 65
7 DISCUSSÃO 66
7.1 A arquitetura oficial: a Pair-Aware linear 66
7.2 O Two-Stage e o papel do limiar 67
7.3 A escolha do *encoder* 67
7.4 A classe `associated_with` 69
7.5 Limitações 69
7.6 Ameaças à validade 70
8 CONCLUSÃO 73
8.1 Principais resultados 73
8.2 Limitações 74
8.3 Contribuições 74
8.4 Trabalhos futuros 75
REFERÊNCIAS 77
APÊNDICES 79
APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS 80
APÊNDICE B – LÉXICO DE PISTAS DE NEGAÇÃO 81

APÊNDICE C – BUSCA DO LIMIAR DO TWO-STAGE 82
APÊNDICE D – HISTÓRICO DE TREINO POR ÉPOCA 84
APÊNDICE E – RESULTADO EXPLORATÓRIO DA PAIR-AWARE MLP 87
APÊNDICE F – INVENTÁRIO DAS EXECUÇÕES 88

1 INTRODUÇÃO

O registro eletrônico em saúde concentra grande parte da informação clínica sob a forma de texto livre. Notas de evolução, sumários de alta e laudos são redigidos em linguagem natural, com abreviações idiossincráticas, ausência frequente de pontuação padronizada e construções negativas características do discurso médico. Essa riqueza textual, embora valiosa para pesquisa e apoio à decisão, permanece majoritariamente inacessível a consultas estruturadas, o que motiva o desenvolvimento de técnicas de Processamento de Linguagem Natural (PLN) capazes de transformar texto clínico em conhecimento estruturado.

No contexto da língua portuguesa, o avanço dessas técnicas foi historicamente limitado pela escassez de recursos anotados. A disponibilização do corpus **SemClinBr** (OLIVEIRA *et al.*, 2022), primeiro corpus clínico anotado semanticamente para o português, com mil documentos provenientes de múltiplas instituições e especialidades, criou condições para investigar tarefas antes restritas ao inglês, entre elas a extração de relações entre entidades clínicas.

1.1 PROBLEMA DE PESQUISA

A extração de entidades nomeadas identifica menções a conceitos clínicos (sintomas, doenças, achados, procedimentos), mas isoladamente não captura como esses conceitos se articulam no enunciado. Saber que um documento menciona “febre” não é suficiente. É preciso distinguir se a febre está *associada* ao quadro do paciente ou se está sendo *negada* (“paciente afebril”). Esse vínculo é o objeto da extração de relações (Relation Extraction, RE).

Os sistemas atuais de extração de relações partem de um *encoder*[1] pré-treinado, ajustado à tarefa a partir de um *checkpoint*[2] público. Para o português, contudo, a extração de relações clínicas é pouco representada na literatura, que se concentra na classificação de textos e no reconhecimento de entidades (SHIMAOKA *et al.*, 2026).

[1] *Encoder* é a metade codificadora da arquitetura Transformer, que recebe a sequência de entrada e devolve uma representação vetorial contextual de cada *token*, sem gerar texto novo. É o tipo de modelo do BERT e de suas variantes.

[2] *Checkpoint* é o arquivo com os pesos de um modelo já pré-treinado, distribuído publicamente e usado como ponto de partida do ajuste fino.

O problema abordado neste trabalho é, assim, o desenvolvimento de um modelo de extração de relações em notas clínicas em português, com ênfase na identificação de relações de negação: o RECLin-PT, desenvolvido sobre o SemClinBr. Esse desenvolvimento envolve decisões para as quais a literatura não oferece resposta pronta: qual *encoder* usar, entre os de domínio geral e os adaptados ao domínio clínico, escolha com consequências de custo e de desempenho, e qual estratégia de modelagem define como as saídas desse *encoder* produzem os rótulos de relação. Daí a pergunta de pesquisa:

> *Como desenvolver o RECLin-PT para a extração de relações clínicas em português no corpus SemClinBr, com ênfase na identificação de relações de negação, e de que modo a escolha do encoder pré-treinado e da estratégia de modelagem influencia seu desempenho?*

A primeira parte da pergunta corresponde à finalidade do trabalho, o desenvolvimento do modelo; a segunda, às decisões que esse desenvolvimento exige, investigadas experimentalmente para subsidiar a definição de sua configuração. Para isso, os componentes do modelo são avaliados em duas dimensões, sob um protocolo pré-registrado e sobre os mesmos dados e pares candidatos: os *encoders*, comparados sob configuração idêntica, e as estratégias de modelagem, comparadas com o mesmo *encoder*. O desafio é agravado por dois fatores inerentes ao corpus: o forte desbalanceamento entre as classes de relação e o fato de o SemClinBr anotar apenas relações positivas, o que exige a geração controlada de exemplos negativos.

1.2 MOTIVAÇÃO

A negação clínica é um fenômeno linguístico de alto impacto, uma vez que tratar um achado negado como presente pode inverter completamente a interpretação de um prontuário, o que justifica um modelo dedicado a essa relação. No desenvolvimento do RECLin-PT, a primeira decisão é o *encoder*. Em português, a negação é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”), e há a expectativa difundida de que modelos pré-treinados sobre texto do próprio domínio clínico capturem melhor essas construções do que modelos de domínio geral. Esse ganho, contudo, não é automático.

Em inglês, Lin *et al.* (2020) reportam que, na detecção de negação clínica, o BERT sem as extensões de adaptação de domínio avaliadas obteve, em média, o melhor desempenho. Para o português, não localizamos avaliação controlada que isole o efeito do pré-treinamento de domínio na extração de relações clínicas. A comparação direta entre *encoders* clínicos e de domínio geral sobre o SemClinBr foi conduzida para o reconhecimento de entidades (ALMEIDA *et al.*, 2026), e não para a etapa de relações (Capítulo 3).

A escolha do *encoder* também não é independente da estratégia de modelagem. Um classificador direto de três classes, uma cabeça que lê explicitamente o par de entidades e uma arquitetura em dois estágios, que primeiro detecta a existência de relação e depois decide seu tipo, distribuem o problema de formas diferentes, e o efeito do pré-treinamento pode variar com essa distribuição. Comparar estratégias e *encoders* de forma justa exige que todos passem pelos mesmos dados, pelos mesmos pares candidatos e pelo mesmo protocolo de seleção e de avaliação. Por isso, o desenvolvimento do RECLin-PT apoia-se em uma cadeia experimental reprodutível, que também responde a críticas recorrentes à literatura de PLN biomédico, como o compartilhamento restrito de modelos e o detalhamento insuficiente do ajuste fino[3] (FRAILE NAVARRO *et al.*, 2023; SHIMAOKA *et al.*, 2026).

1.3 OBJETIVOS

1.3.1 Objetivo geral

Desenvolver o RECLin-PT, um modelo de extração de relações clínicas em português aplicado ao corpus SemClinBr, com ênfase na identificação de relações de negação (`negation_of`), investigando alternativas de *encoder* pré-treinado e de estratégia de modelagem para subsidiar a definição de sua configuração.

[3] Ajuste fino (fine-tuning) é o retreinamento de um modelo pré-treinado sobre os dados de uma tarefa específica, partindo dos pesos já aprendidos em vez de uma inicialização aleatória (DEVLIN *et al.*, 2019).

1.3.2 Objetivos específicos

- Reconstruir os dados do SemClinBr a partir dos XML originais, com o texto alinhado aos offsets de anotação, e congelar partições em nível de documento, estratificadas e verificáveis por *hashes*.
- Caracterizar o corpus, quantificando a distribuição das relações e a distância entre entidades relacionadas, e justificar a janela de geração de pares candidatos.
- Implementar um gerador determinístico de pares candidatos compartilhado por todas as estratégias, garantindo a comparabilidade dos resultados.
- Implementar a arquitetura oficial do RECLin-PT, a Pair-Aware linear, e as estratégias e controles com que ela é comparada: baseline, Two-Stage, baseline calibrado e filtro léxico, além de uma variante exploratória da Pair-Aware com cabeça MLP.
- Comparar, para orientar a escolha do *encoder*, *encoders* para o português sob configuração idêntica, mudando apenas o *checkpoint* de pré-treino: BioBERTpt-all, BioBERTpt-clin e BERTimbau-base, em cada estratégia treinada.
- Comparar a Pair-Aware linear com as demais estratégias, com o mesmo *encoder* e sob o mesmo protocolo.
- Avaliar as configurações do RECLin-PT por precisão, *recall* e F1 por classe, macro-F1 e MCC, com comparações pareadas por *bootstrap*[4] e McNemar, e auditar as execuções, recalculando as métricas a partir das predições gravadas.
- ~~Registrar~~ Definir a configuração de referência do RECLin-PT e registrar o que falta para selecionar e congelar a configuração ~~do RECLin-PT, inclusive o *encoder*, e avaliá-la~~ final, a única a ser avaliada no conjunto de teste.

[4] O *bootstrap* pareado estima a incerteza de uma diferença de desempenho reamostrando com reposição o mesmo conjunto para os dois modelos, sem supor uma distribuição para a métrica (Seção 4.6).

2 REFERENCIAL TEÓRICO

Este capítulo reúne os fundamentos em que se apoia o desenvolvimento do RECLin-PT: o processamento de linguagem natural aplicado a textos clínicos, a tarefa de extração de relações, a abordagem baseada em regras para a negação clínica, os modelos de linguagem baseados em transformers e as formas de representar o par de entidades e de decompor a decisão.

2.1 PROCESSAMENTO DE LINGUAGEM NATURAL CLÍNICO

O PLN clínico ocupa-se da análise automática de textos produzidos no cuidado em saúde, como notas de evolução, sumários de alta e laudos. Esses textos apresentam características que os distinguem da linguagem geral: vocabulário técnico, abreviações não padronizadas, telegrafismo (omissão de elementos gramaticais) e prevalência de construções negativas e de incerteza. Tais propriedades tornam a transferência direta de ferramentas treinadas em domínio aberto pouco eficaz, motivando recursos e modelos específicos do domínio.

2.2 EXTRAÇÃO DE ENTIDADES E DE RELAÇÕES

A extração de informação em texto clínico costuma ser decomposta em duas tarefas encadeadas. A primeira, reconhecimento de entidades nomeadas (Named Entity Recognition, NER), delimita trechos do texto que mencionam conceitos de interesse e lhes atribui um tipo semântico. A segunda, extração de relações (RE), determina se um par de entidades mantém uma relação e de que tipo. Formalmente, dado um par ordenado de entidades (e_1, e_2) em um documento, a RE pode ser modelada como um problema de classificação que associa ao par um rótulo dentro de um conjunto pré-definido.

Neste trabalho o espaço de rótulos é `negation_of`, `associated_with` e `no_relation`. O rótulo `no_relation` é fundamental. Como a anotação de corpora registra apenas relações positivas, todo par de entidades não anotado deve ser tratado como ausência de relação, o que introduz um forte desbalanceamento de classes.

2.3 ABORDAGENS BASEADAS EM REGRAS E A NEGAÇÃO CLÍNICA

Abordagens baseadas em regras codificam conhecimento linguístico explícito. Em detecção de negação clínica, o algoritmo NegEx (CHAPMAN *et al.*, 2001) tornou-se referência. A partir de um léxico de gatilhos de negação e de janelas de contexto, ele classifica achados como negados ou afirmados. Sua simplicidade e eficácia derivam do fato de a negação clínica ser altamente lexicalizada. Em português, gatilhos como "não", "sem", "nega" e "ausência de", além de adjetivos que embutem negação morfologicamente ("afebril", "anictérico"), sustentam estratégias análogas. A alta lexicalização sugere que o sinal de negação possa estar acessível mesmo a modelos não especializados no domínio clínico, hipótese relevante para a escolha do *encoder* do RECLin-PT e que a comparação entre *encoders* examina.

2.4 MODELOS BASEADOS EM *TRANSFORMERS*

Métodos aprendidos clássicos, que representam as palavras como unidades independentes, não capturam dependências de longo alcance nem contexto, limitação que motivou a transição da área para modelos contextuais. A arquitetura Transformer (VASWANI *et al.*, 2017), baseada em mecanismos de atenção, viabilizou modelos de linguagem pré-treinados que produzem representações contextuais das palavras. O BERT (DEVLIN *et al.*, 2019) popularizou o paradigma de pré-treinamento seguido de ajuste fino (fine-tuning) para tarefas específicas. Para o português, os candidatos naturais à extração de relações clínicas dividem-se entre modelos de domínio geral e modelos adaptados ao domínio clínico. No primeiro grupo está o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020), pré-treinado no corpus brWaC[1] e hoje a referência de domínio geral para a língua; nele também se enquadram modelos multilíngues como o XLM-R (CONNEAU *et al.*, 2020), que trocam especialização por cobertura ampla de idiomas. No segundo grupo está o BioBERTpt (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e textos biomédicos em português brasileiro e distribuído em variantes conforme o corpus de adaptação, entre elas a *clin* (narrativas clínicas) e a *all* (clínico e biomédico). É o contraste entre esses dois grupos que estrutura a escolha

[1] O brWaC (Brazilian Portuguese Web as Corpus) é um corpus de larga escala construído a partir de páginas web em português brasileiro, sem restrição de domínio.

do *encoder* do RECLin-PT e, com ela, a pergunta de pesquisa; o XLM-R permanece como alternativa de base ampla, fora do escopo experimental aqui delimitado.

2.5 REPRESENTAÇÃO DO PAR E DECOMPOSIÇÃO DA DECISÃO

Em extração de relações com modelos do tipo BERT, o par de entidades costuma ser indicado por marcadores inseridos no próprio texto, como `[E1]...[/E1]` e `[E2]...[/E2]`, de modo que a atenção condicione a codificação de toda a sequência ao par sob análise (SOARES *et al.*, 2019). A partir da sequência marcada, a classificação pode usar apenas a representação agregada da sequência (o *token* `[CLS]`) ou ler explicitamente os estados ocultos nas posições dos marcadores de início das entidades, variante que Soares *et al.* (2019) denominam *entity start* e que concentra a decisão no par em vez de no contexto inteiro.

Quando a grande maioria dos pares não mantém relação, como ocorre ao considerar todos os pares próximos de um documento, um único classificador precisa resolver ao mesmo tempo duas perguntas de natureza diferente: *se* há relação e *qual* relação. Uma alternativa é decompor a decisão em estágios encadeados, em que um primeiro classificador binário filtra os pares com relação e um segundo decide o tipo apenas entre eles. Em decomposições desse tipo, a passagem de um estágio ao outro depende de um limiar sobre a probabilidade estimada pelo primeiro: limiares altos favorecem a precisão e sacrificam o *recall* das relações que não chegam ao segundo estágio. Do mesmo modo, num classificador direto, um limiar sobre a probabilidade de uma classe permite deslocar o compromisso entre precisão e *recall* dessa classe sem novo treino. Essas alternativas fundamentam as estratégias de modelagem do RECLin-PT (Seção 5.4). A forma de escolher esses limiares e suas consequências para a avaliação são tratadas no protocolo experimental (Seção 4.6).

3 TRABALHOS RELACIONADOS

Este capítulo situa o desenvolvimento do RECLin-PT em relação a recursos e estudos de extração de informação clínica, com ênfase na língua portuguesa, e identifica o que esses trabalhos oferecem ao modelo e o que deixam em aberto.

3.1 RECURSOS E DESAFIOS EM INGLÊS

A extração de relações clínicas consolidou-se em língua inglesa em torno de campanhas de avaliação como as séries Informatics for Integrating Biology and the Bedside (i2b2) e National NLP Clinical Challenges (n2c2) (UZUNER *et al.*, 2011), que disponibilizaram corpora anotados e tarefas compartilhadas para problemas como relações entre medicamentos, dosagens e efeitos adversos. Esses esforços estabeleceram protocolos de avaliação e evidenciaram a importância de tratar adequadamente o desbalanceamento de classes e o vazamento de dados entre partições, preocupações transpostas para este trabalho, respectivamente, pela geração controlada de pares candidatos (Seção 4.5.4) e pelo particionamento em nível de documento (Seção 4.5.3).

Quanto aos modelos, o BioBERT (LEE *et al.*, 2020) demonstrou os ganhos da adaptação de domínio biomédico em inglês, estabelecendo o precedente que torna a escolha entre *encoders* de domínio e gerais uma decisão a examinar no desenvolvimento do RECLin-PT. Quanto à representação de entrada, a delimitação do par por marcadores de entidade inseridos no próprio texto (SOARES *et al.*, 2019) tornou-se a técnica padrão para extração de relações com modelos baseados em BERT, e é a adotada aqui (Seção 5.3).

3.2 RECURSOS PARA O PORTUGUÊS E POSICIONAMENTO DESTE TRABALHO

O desenvolvimento de PLN clínico em português foi por muito tempo limitado pela ausência de corpora anotados de acesso controlado. O **SemClinBr** (OLIVEIRA *et al.*, 2022) preencheu parte dessa lacuna ao disponibilizar mil documentos clínicos de múltiplas instituições e especialidades, anotados semanticamente e acompanhados de dicionários de abreviações e de pistas de negação. Para este trabalho, sua contribuição central é a anotação de relações, inclusive de negação, entre entidades; como o

corpus anota apenas relações positivas, usá-lo para classificar todos os pares de um documento exige construir os exemplos negativos (Seção 4.5.4). É o corpus sobre o qual o RECLin-PT é desenvolvido.

Os *encoders* disponíveis para o português foram avaliados, até aqui, sobretudo em reconhecimento de entidades. O BioBERTpt (SCHNEIDER *et al.*, 2020) adaptou modelos BERT a narrativas clínicas e textos biomédicos em português brasileiro e relatou ganhos em NER em dois corpora de narrativas clínicas; o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020), referência de domínio geral, foi avaliado em similaridade textual, inferência textual e reconhecimento de entidades, todas tarefas de domínio geral. Nenhum dos dois trabalhos mede o efeito do pré-treinamento sobre a extração de relações. O estudo mais próximo, de Almeida *et al.* (2026), compara sobre o SemClinBr, com hiperparâmetros comuns sempre que possível, variantes do BioBERTpt, o BERTimbau, modelos BERT recentes e modelos de linguagem de grande porte, também em reconhecimento de entidades; nesse estudo, o melhor desempenho coube a um modelo multilíngue de domínio geral (mmBERT-base), à frente das variantes do BioBERTpt, o que indica que o domínio do pré-treino não é o único fator relevante mesmo em NER. Esses resultados motivam comparar *encoders* antes de fixar o do RECLin-PT, mas não substituem essa comparação: se a vantagem observada em entidades se transfere para relações é a questão que permanece aberta.

A extração de relações clínicas em português é pouco representada na literatura revisada. Uma revisão sistemática de 28 estudos de modelos de linguagem em português voltados à saúde, publicados entre janeiro de 2020 e novembro de 2024, inventaria classificação (16 modelos), reconhecimento de entidades nomeadas (8), modelagem de tópicos, resposta a perguntas, geração de texto e agentes conversacionais, sem registrar extração de relações (SHIMAOKA *et al.*, 2026). O desequilíbrio não é exclusivo do português: uma revisão de 94 estudos de extração de informação em texto clínico registra 63 dedicados a reconhecimento de entidades contra 13 dedicados a extração de relações (FRAILE NAVARRO *et al.*, 2023). O trabalho de extração de relações em texto clínico em português aqui localizado (SILVA *et al.*, 2023) contribui com um corpus próprio de oncologia em português brasileiro e menciona três *encoders* candidatos (BERT multilíngue, BioBERTpt e BERTimbau), mas não reporta comparação entre eles

e resolve a etapa de relações com uma rede BiLSTM, sem teste de significância. O efeito do pré-treinamento de domínio sobre a extração de relações, portanto, não é isolado ali.

Em síntese, os trabalhos revisados oferecem o corpus, os *encoders* e as técnicas de representação do par em que o RECLin-PT se apoia, mas não localizamos estudo que verifique, para o português, se a vantagem do pré-treinamento clínico relatada em NER se transfere para a extração de relações, nem que compare, sobre um mesmo corpus clínico em português, estratégias de modelagem distintas sob protocolo único. O RECLin-PT se posiciona nessa lacuna: é desenvolvido sobre o SemClinBr com foco na negação clínica, e suas estratégias, que vão do classificador direto a uma arquitetura em dois estágios, combinam técnicas já descritas na literatura, como os marcadores de entidade e a decomposição da decisão. Sua contribuição central é o próprio modelo; as comparações de *encoders* e de estratégias, conduzidas sob as mesmas condições e com uma cadeia reprodutível, servem para orientar sua configuração e, ao mesmo tempo, produzem evidência sobre a lacuna descrita, que pode servir de referência para trabalhos futuros sobre o mesmo corpus.

4 METODOLOGIA

Neste capítulo são descritos os métodos empregados no desenvolvimento do RECLin-PT: o ajuste fino de *encoders* pré-treinados para a extração de relações, o *dataset* utilizado, a preparação do ambiente experimental, as métricas de avaliação, a preparação dos dados e o protocolo que rege a seleção e a comparação dos modelos. Os experimentos descritos são o instrumento pelo qual as decisões de modelagem do RECLin-PT, isto é, a escolha do *encoder* e da estratégia, passam a se apoiar em evidência medida, e não em preferência prévia. Todas as etapas foram projetadas sob a premissa de reprodutibilidade: cada artefato é identificado por *hash*, e cada decisão tomada sobre os dados fica registrada antes de ser usada.

4.1 *FINE-TUNING* DE *ENCODERS* PRÉ-TREINADOS

Os modelos deste trabalho partem de *encoders* pré-treinados: redes da família BERT (DEVLIN *et al.*, 2019) que já aprenderam, sobre grandes volumes de texto não anotado, a produzir uma representação vetorial contextual para cada *token*. Esse conhecimento prévio é a razão de usá-los. Em vez de aprender a língua a partir dos poucos exemplos anotados da tarefa, o modelo parte de pesos que já codificam vocabulário, morfologia e relações sintáticas, e o treino só precisa especializá-los. O *encoder* é escolhido pelo seu *checkpoint* de pré-treino; neste trabalho, o BioBERTpt-all e o BioBERTpt-clin, de domínio clínico, e o BERTimbau-base, de domínio geral (Seção 5.2).

O *fine-tuning* (ajuste fino) adapta esses pesos à extração de relações. Cada exemplo é um par de entidades, apresentado ao modelo como uma janela de texto em torno do par, com as duas entidades delimitadas por marcadores (Seção 5.3). O *encoder* transforma a janela em representações contextuais, e uma cabeça de classificação, uma camada nova acrescentada sobre ele, converte essas representações em uma pontuação para cada rótulo. Durante o treino, as predições são comparadas aos rótulos anotados por uma função de perda de entropia cruzada; o gradiente dessa perda é propagado de volta por toda a rede (retropropagação), e um otimizador atualiza tanto a cabeça quanto os pesos do *encoder*. Como as classes são muito desbalanceadas, a perda de cada exemplo é ponderada pelo inverso da frequência de sua classe no

treino, com peso $n/(K \cdot n_c)$, em que n é o número de exemplos, K o número de classes e n_c o número de exemplos da classe c; sem essa ponderação, o modelo minimizaria o erro prevendo `no_relation` para quase tudo.

O procedimento de treino é o mesmo para todas as estratégias treinadas e segue a configuração do Quadro 1. Os exemplos de treino são apresentados em lotes de 64, embaralhados por um gerador com semente fixa. O otimizador é o AdamW, com taxa de aprendizado de 2×10^{-5} e *weight decay* de $0{,}01$; a taxa cresce linearmente durante os primeiros 10% dos passos (aquecimento) e decresce linearmente até zero, e a norma do gradiente é limitada a 1. O treino percorre um número fixo de épocas, sem parada antecipada. Ao fim de cada época, o modelo é avaliado no conjunto de desenvolvimento (DEV) pelo critério da estratégia, e os pesos da melhor época são restaurados ao final. Essa é a única escolha feita durante o treino, e ela usa apenas o DEV (Seção 4.6). Para que a mesma configuração produza os mesmos números no mesmo ambiente, as sementes de Python, NumPy e PyTorch são fixadas, as operações determinísticas da GPU são exigidas sempre que disponíveis, e o estado completo dos geradores aleatórios é salvo nos *checkpoints*, o que permite retomar um treino interrompido exatamente do ponto em que parou.

O *fine-tuning* é a base comum de todas as estratégias treinadas, que diferem na forma de ler a representação do *encoder* e de organizar a decisão; duas estratégias apenas pós-processam as predições do baseline, sem treino próprio (Capítulo 5).

Três conceitos são distinguidos ao longo do texto. O *encoder* é o modelo de linguagem pré-treinado, fixado pelo seu *checkpoint*. A estratégia é a forma como esse *encoder* é ajustado e como suas saídas são combinadas para produzir os três rótulos. O RECLin-PT é o modelo em desenvolvimento, formado por um *encoder* e uma estratégia e apoiado pela cadeia de dados e pelo protocolo descritos neste capítulo. Sua configuração final será a combinação de *encoder* e estratégia selecionada pelos critérios do protocolo, depois do congelamento das escolhas e da avaliação no conjunto de teste, e ainda não foi definida; o Capítulo 6 indica qual estratégia serve de referência nas análises preliminares.

Quadro 1 – Hiperparâmetros e configuração do *fine-tuning*, comuns às estratégias treinadas.

Item	Valor
Entrada	janela de ± 128 caracteres em torno do par (`ctx_chars`), com marcadores `[E1]`/`[E2]`, sem tipo semântico; até 128 *tokens* (`max_length`)
Pares candidatos	distância máxima de 25 caracteres entre as entidades (`max_gap`)
Lote (*batch*)	64
Otimizador	AdamW; taxa de aprendizado 2×10^{-5}; *weight decay* $0{,}01$
Escalonador	linear, com aquecimento nos primeiros 10% dos passos
Norma máxima do gradiente	1,0
Perda	entropia cruzada ponderada (`class_weight="balanced"`), com pesos calculados no treino de cada estratégia ou estágio
Épocas	3 (estratégias de três rótulos e estágio 1 do Two-Stage); 10 (estágio 2)
Seleção da época	maior macro-F1 no DEV (estratégias de três rótulos); critérios próprios nos estágios do Two-Stage
Semente	42

Fonte: elaborado pelo autor.

4.2 O *DATASET* SEMCLINBR

Os documentos clínicos utilizados neste trabalho foram retirados do **SemClinBr** (OLIVEIRA *et al.*, 2022)[1], primeiro corpus clínico em português do Brasil anotado semanticamente. Ele reúne mil documentos provenientes de múltiplas instituições e especialidades, redigidos por profissionais de saúde no registro do cuidado, e é distribuído mediante solicitação formal, para uso não comercial. Neste trabalho, o SemClinBr é a única fonte de dados: dele saem os exemplos de treino, a escolha de modelos no DEV e o conjunto de teste reservado para a avaliação final.

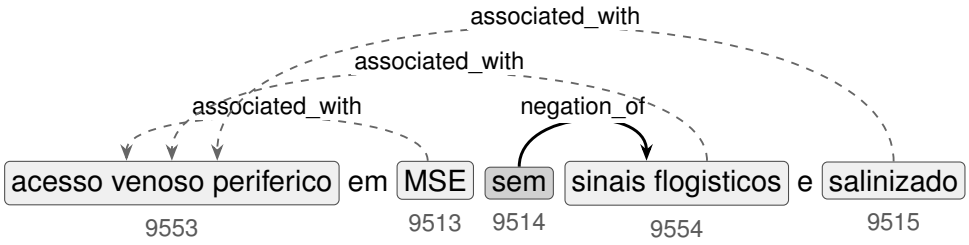
O texto do corpus é típico do prontuário. As frases são curtas e telegráficas, com omissão de verbos e artigos, abreviações frequentes e não padronizadas (como MSE,

[1] Repositório do corpus e formulário de requisição de acesso em github.com/HAILab-PUCPR/SemClinBr.

para membro superior esquerdo), mistura de letras maiúsculas e minúsculas e ausência ocasional de acentos, e construções negativas recorrentes, como “sem sinais flogísticos” ou “nega queixas”. Essas características afastam o texto da linguagem dos corpora usados no pré-treino de domínio geral e motivam a comparação entre *encoders*.

Cada documento traz anotações de entidades, trechos do texto delimitados por posições de caractere (*offsets*) e associados a tipos semânticos da UMLS, além de categorias próprias como `Abbreviation` e `Negation`; uma mesma entidade pode receber vários tipos, separados por “|”. Entre as entidades, são anotadas relações dirigidas, de um primeiro argumento (e_1) para um segundo (e_2), de dois tipos: `associated_with`, que liga conceitos relacionados, como um dispositivo e a região do corpo em que está, e `negation_of`, que liga uma expressão de negação ao conceito negado. A Figura 1 mostra um trecho real de um documento do corpus, com as entidades e as relações anotadas.

Figura 1 – Exemplo real de anotação de um documento do SemClinBr (documento 9091, trecho): entidades anotadas, com seus identificadores, e relações entre elas.



Id	Entidade	Tipo anotado
9553	acesso venoso periferico	*Therapeutic or Preventive Procedure*|*Medical Device*
9513	MSE	*Body Location or Region*|*Abbreviation*
9514	sem	*Negation*
9554	sinais flogisticos	*Sign or Symptom*
9515	salinizado	*Therapeutic or Preventive Procedure*|*Finding*

Fonte: elaborado pelo autor a partir de dados do SemClinBr (OLIVEIRA *et al.*, 2022).

No trecho, a entidade “sem” (tipo `Negation`) é o primeiro argumento de uma relação `negation_of` cujo segundo argumento é “sinais flogisticos”: o registro afirma a *ausência* de sinais inflamatórios no acesso venoso, e um sistema que perdesse essa relação leria o achado como presente. As outras três relações, do tipo `associated_with`, ligam a

localização (“MSE”), o achado negado e o estado (“salinizado”) ao dispositivo descrito.

Três características da anotação afetam diretamente o treino e a avaliação. A primeira é o desbalanceamento: das $11\,458$ relações anotadas no corpus, $9\,852$ são `associated_with` e apenas $1\,606$ ($14{,}02\%$) são `negation_of`. A segunda é que o corpus anota apenas relações positivas. Um par de entidades sem anotação não é, por si, um exemplo explícito de ausência de relação, e por isso os exemplos negativos (`no_relation`) precisam ser construídos a partir dos pares não anotados (Seção 4.5.4), o que agrava ainda mais o desbalanceamento. A terceira é que as relações são dirigidas: o par (e_1, e_2) e o par inverso são exemplos diferentes, e só um deles pode carregar a relação anotada.

4.3 PREPARAÇÃO DO AMBIENTE

Os experimentos foram organizados em um pacote Python próprio, versionado em um repositório Git[2], que reúne a leitura do corpus, as partições, a geração de candidatos, as estratégias, o treino, a avaliação e os relatórios. O Quadro 2 resume os ambientes utilizados e as versões registradas pelo próprio código em cada execução.

Quadro 2 – Ambientes de execução e versões das principais bibliotecas.

Item	Valor
Treino e avaliação no DEV	Google Colab, GPU NVIDIA Tesla T4 (15 GB), CUDA 13.0
Python	3.13 (treino); 3.10 (reconstrução dos dados, no computador do autor)
Bibliotecas	PyTorch 2.11.0, Transformers 5.16.1, Tokenizers 0.23.2, Hugging Face Hub 1.29.0, Safetensors 0.8.0, NumPy 2.1.3, SciPy 1.16.3
Pesos pré-treinados	`pucpr/biobertpt-all` (revisão `36b11cf`) e `neuralmind/bert-base-portuguese-cased` (revisão `94d69c9`), baixados por revisão exata e conferidos por *hash*
Determinismo	`PYTHONHASHSEED=0`, `CUBLAS_WORKSPACE_CONFIG=:4096:8`, sementes fixas e algoritmos determinísticos do PyTorch

Fonte: elaborado pelo autor.

[2] Código e resultados em github.com/angeloalsf/RECLin-PT (branch `resultados-colab`); o corpus SemClinBr não é redistribuído, por ter acesso restrito.

A reconstrução dos dados a partir dos XML do corpus foi executada no computador do autor, porque os arquivos originais não podem ser redistribuídos; o resultado são partições derivadas, identificadas por *hashes* (Seção 4.5). O treino foi executado no Google Colab, com um *notebook* por estratégia, que obtém o código do repositório, confere o ambiente e a GPU e chama os *scripts* de treino. Os pesos pré-treinados são baixados uma única vez, na revisão exata registrada no protocolo, e carregados sem acesso à rede, com os *hashes* de todos os arquivos conferidos antes de cada carga. As versões das bibliotecas são fixadas por um arquivo de restrições, com o qual o pacote é instalado.

Cada execução grava uma pasta própria com a configuração completa (`config.json`), o histórico de treino por época e as sessões (`treino.json`), as métricas (`metricas.json`), as predições do DEV (`predicoes_dev.json`) e o registro do ambiente e da proveniência (`experimento.json`). Os *checkpoints*, que permitem retomar um treino interrompido, são espelhados no Google Drive durante o treino. Para reproduzir os experimentos, basta instalar o pacote com as versões fixadas, conferir as partições contra o manifesto e executar os *scripts* de treino com a mesma configuração e semente; as tabelas e figuras deste trabalho são regeneradas a partir das pastas das execuções por *scripts*, sem transcrição manual de números.

4.4 MÉTRICAS UTILIZADAS PARA AVALIAR OS MODELOS

Nesta seção são apresentadas as métricas utilizadas para avaliar o desempenho dos modelos de extração de relações. As métricas centrais são a precisão (*precision*), o *recall* e o F1-*Score*, calculadas para cada uma das três classes da tarefa, `negation_of`, `associated_with` e `no_relation`. Para uma classe, um par conta como verdadeiro positivo (TP) quando é dessa classe e o modelo o atribui a ela; como falso positivo (FP) quando o modelo o atribui à classe sem que ele pertença a ela; e como falso negativo (FN) quando pertence à classe e o modelo o atribui a outra.

A precisão (*precision*) é calculada pela razão entre o número de verdadeiros positivos e o total de previsões positivas realizadas pelo modelo. Essa métrica indica a proporção de previsões positivas que foram classificadas corretamente, conforme apresentado na

Fórmula 1.

Fórmula 1 – Precisão

$$\text{Precisão} = \frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{Falsos positivos}}$$

O *recall*, também conhecido como sensibilidade ou taxa de detecção, corresponde à proporção de exemplos positivos reais que foram identificados corretamente pelo modelo. Dessa forma, a métrica permite avaliar a capacidade do modelo de recuperar os exemplos pertencentes à classe analisada, conforme apresentado na Fórmula 2.

Fórmula 2 – *Recall*

$$\textit{Recall} = \frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{Falsos negativos}}$$

Por fim, o F1-*Score* combina as medidas de precisão e *recall* por meio da média harmônica entre elas. Essa métrica permite avaliar conjuntamente a capacidade do modelo de realizar previsões positivas corretas e identificar os exemplos positivos reais. Seu cálculo é apresentado na Fórmula 3.

Fórmula 3 – F1-*Score*

$$\text{F1-}\textit{Score} = 2 \cdot \frac{\text{Precisão} \cdot \textit{Recall}}{\text{Precisão} + \textit{Recall}}$$

No código do projeto, as três métricas são calculadas a partir da matriz de confusão, com o F1 na forma equivalente $2TP/(2TP+FP+FN)$, e valem zero quando o denominador é nulo, por exemplo quando o modelo nunca prediz a classe. O F1 de `negation_of` é a métrica primária do trabalho. Para resumir o desempenho nas três classes, usa-se o macro-F1, média simples dos três F1, que dá o mesmo peso a cada classe e, por isso, penaliza modelos que negligenciam as minoritárias (FORMAN; SCHOLZ, 2010); ele é também o critério de seleção de época das estratégias de três rótulos. São reportados ainda a acurácia, pouco informativa isoladamente porque `no_relation`

domina os pares, e o coeficiente de correlação de Matthews (MCC) multiclasse, que considera a matriz de confusão inteira e é robusto ao desbalanceamento.

4.5 PREPARAÇÃO DOS DADOS

4.5.1 Reconstrução dos dados e alinhamento dos offsets

Os dados empregados foram reconstruídos diretamente dos XML do SemClinBr. Um *parser* lê cada arquivo e produz um registro com identificador do documento, texto, entidades (tipo e offsets) e relações, sem normalizar tipos e sem alterar ou descartar nenhuma anotação. O ponto crítico da reconstrução é o alinhamento entre o texto e os offsets. Em parte dos documentos, os offsets foram calculados sobre o texto com quebras de linha de dois caracteres, e substituir cada quebra por um único espaço desloca todas as entidades seguintes. A regra adotada identifica, por documento e com todas as anotações, qual convenção os offsets seguem e, quando é a de dois caracteres, substitui cada quebra por dois espaços, de modo que o texto passe a ter o comprimento pressuposto pelos offsets. A regra transformou 421 dos 1.000 documentos; nos demais, o texto foi mantido sem alteração.

O resultado foi verificado por auditoria: nenhuma entidade das três partições apresenta divergência entre o trecho recortado pelo offset e o texto anotado, e a reconstrução preserva os documentos de cada partição, as entidades, as relações, os pares candidatos e os rótulos de referência. As 26 anomalias de anotação encontradas (por exemplo, um offset inválido) foram mantidas como estão e registradas em arquivo próprio. Um manifesto (`MANIFEST.json`) registra o SHA-256 de cada partição, as contagens e a proveniência da fonte (Apêndice A).

4.5.2 Caracterização do corpus

A análise exploratória (Exploratory Data Analysis, EDA) foi conduzida com as próprias funções do código do projeto, totalizando $1\,000$ documentos, $45\,508$ entidades e $11\,458$ relações. A mediana é de 10 relações por documento, o percentil 90 é de 24 e o máximo é de 65; 46 documentos não possuem relação anotada. Entre as categorias de entidade, contadas como ocorrências do rótulo depois de decompor as anotações multirrótulo,

predominam `Abbreviation` (12 592), `Finding` (6 827) e `Therapeutic or Preventive Procedure` (4 759), e a categoria `Negation` soma 2 646 ocorrências. Como a anotação de uma mesma entidade pode repetir um rótulo, essas contagens superam o número de entidades com cada tipo: são 12 290, 6 747, 4 716 e 2 299 entidades, respectivamente. Os controles da Seção 4.5.6 contam entidades, e não ocorrências do rótulo.

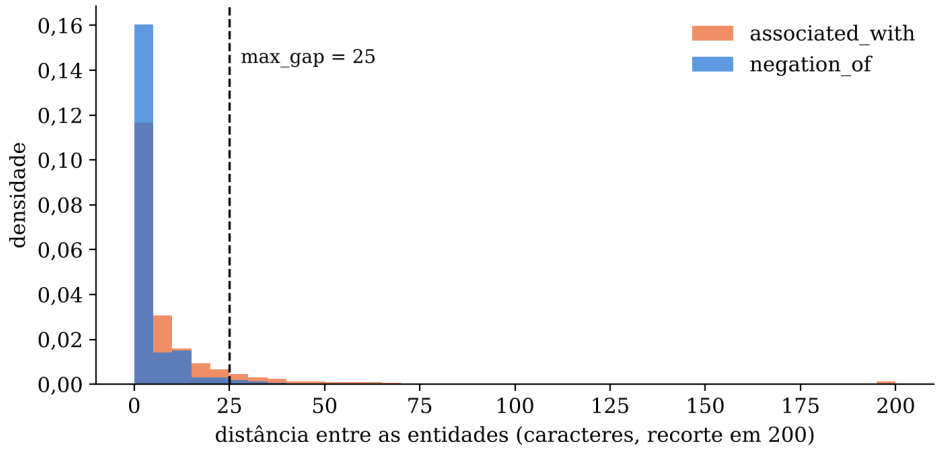
A Tabela 1 e a Figura 2 mostram que as relações ocorrem entre entidades próximas, com um contraste nítido entre os tipos. A negação é praticamente adjacente, com mediana e percentil 75 de um único caractere, enquanto a associação se distribui por uma cauda bem mais longa. Essa assimetria fundamenta a janela máxima (`max_gap` $= 25$) da geração de pares candidatos (Seção 4.5.5).

Tabela 1 – Distância em caracteres entre as entidades de cada relação anotada (corpus completo).

Tipo	n	Média	Mediana	p75	p95	Máx.	> 25
`negation_of`	1 606	3,5	1	1	15	54	1,87%
`associated_with`	9 852	11,8	4	10	43	541	9,89%

Fonte: elaborado pelo autor.

Figura 2 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200), com a janela `max_gap` assinalada.



Fonte: elaborado pelo autor.

4.5.3 Particionamento dos dados

A partição segue a razão 80/10/10 em nível de documento, e não de relação. Essa escolha previne o vazamento de dados, pois relações de um mesmo documento

compartilham vocabulário e trechos repetidos, e dividi-las entre partições inflaria artificialmente as métricas. A partição é estratificada pela presença de `negation_of`: os documentos com ao menos uma relação de negação e os demais são embaralhados separadamente, com semente 42, e divididos 80/10/10 dentro de cada grupo, o que garante exemplos da classe rara nas três partições. O resultado são 800 documentos de treino, 100 de DEV e 100 de teste, congelados e verificados por SHA-256 (Apêndice A). A Tabela 2 apresenta as contagens por partição.

Tabela 2 – Partições congeladas: documentos, entidades, relações anotadas e pares candidatos (`max_gap`$= 25$).

Partição	Documentos	Entidades	`negation_of`	`associated_with`	Candidatos	`no_relation`
Treino	800	36 455	1 299	7 922	152 686	144 335
Desenvolvimento	100	4 513	155	832	19 064	18 151
Teste	100	4 540	152	1 098	19 210	18 062
Total	1 000	45 508	1 606	9 852	190 960	180 548

Fonte: elaborado pelo autor.

Trata-se de uma partição única, usada por todas as execuções. A proporção 80/10/10 é uma convenção adotada no projeto, sem justificativa específica além do equilíbrio usual entre o tamanho do treino e o das partições de avaliação. A estratificação binária fixa o número de documentos com negação em cada partição (533, 67 e 67), mas não o número de relações. Para dimensionar esse efeito, o mesmo algoritmo de partição foi executado com 200 sementes, sem alterar a partição congelada (Tabela 3). Para `negation_of`, a semente 42 é típica: o DEV tem 155 relações (percentil 47) e o teste, 152 (percentil 28), enquanto entre as sementes o teste teria de 138 a 191 negações (percentis 5 e 95). Para `associated_with`, a semente 42 produziu um DEV com poucas associações (832, percentil 4,5) e um teste com muitas (1 098, percentil 94). Por isso, as métricas de `associated_with` e o macro-F1 medidos no DEV antecipam com menos segurança os do teste do que as de `negation_of`.

A divisão por documento não impede que textos quase idênticos fiquem em partições diferentes. Um detector de documentos quase duplicados compara o texto de todos os pares de documentos, sem espaços em branco, pela similaridade de Jaccard entre sequências de oito caracteres (limiar 0,8). Ele apenas registra as ocorrências, sem alterar as partições. Foram identificados sete pares, todos idênticos a menos de

Tabela 3 – Relações anotadas por partição com outras sementes do particionamento e posição da semente 42.

Relação	Partição	mín.	p5	mediana	p95	máx.	semente 42	percentil
`negation_of`	DEV	127	137	157	186	201	155	47,0%
`negation_of`	Teste	118	138	159	191	202	152	28,0%
`associated_with`	DEV	765	841	979	1 117	1 211	832	4,5%
`associated_with`	Teste	812	875	984	1 103	1 153	1 098	94,0%

Mesmo algoritmo de partição, sementes 0 a 199 (200 sementes); a partição congelada não foi alterada.

Fonte: elaborado pelo autor.

espaços (Tabela 4). Um deles é trivial (dois documentos de uma única entidade, sem relações); os outros seis correspondem a notas que aparecem duas vezes no corpus, com anotações diferentes. Em três deles, uma cópia está no treino e a outra no teste (documentos de teste 9534, 9535 e 9536); essas três notas somam 5 das 152 relações `negation_of` do teste e 1 118 dos 19 210 pares candidatos. A partição congelada foi mantida, e o protocolo registra, antes de qualquer avaliação no teste, uma análise de sensibilidade secundária: as métricas do teste são recalculadas a partir das mesmas predições, sem os pares desses três documentos, e relatadas ao lado da análise principal, feita sobre o teste completo (Seção 4.6).

Tabela 4 – Documentos quase duplicados identificados no corpus (as partições não foram alteradas).

Documentos	Partições	Espaços diferentes	Entidades (a/b/comum)	Relações (a/b/comum)	`negation_of` (a/b/comum)
9280 / 9271	treino / DEV	4	1 / 1 / 1	0 / 0 / 0	–
9531 / 9632	treino / treino	13	40 / 43 / 21	13 / 17 / 8	1 / 1 / 1
9532 / 9633	treino / treino	4	34 / 33 / 20	8 / 7 / 6	–
9533 / 9634	treino / treino	4	49 / 55 / 23	18 / 26 / 10	1 / 1 / 1
9635 / 9534	treino / teste	3	59 / 58 / 34	20 / 19 / 11	2 / 2 / 2
9636 / 9535	treino / teste	8	58 / 60 / 39	24 / 27 / 16	2 / 2 / 2
9637 / 9536	treino / teste	4	46 / 47 / 30	22 / 22 / 16	1 / 1 / 1

Jaccard de *shingles* de 8 caracteres do texto sem espaços em branco, limiar 0,8. Todos os pares ficam idênticos sem os espaços. “Em comum”: texto e tipo das entidades e dos argumentos das relações, sem *offsets*.

Fonte: elaborado pelo autor.

4.5.4 Geração de pares candidatos

Como o corpus anota apenas relações positivas, avaliar um classificador no espaço {negation_of, associated_with, no_relation} exige construir os exemplos negativos. Treinar ou avaliar apenas com os pares anotados produziria um classificador incapaz de operar em um cenário real, em que o sistema recebe *todos* os pares de entidades de um documento.

A geração é feita por uma única função do código, compartilhada por todas as estratégias, condição necessária para que os resultados fiquem na mesma régua. Para cada documento, ela percorre os pares ordenados de entidades (e_1, e_2), já que a direção é relevante para a negação, e respeita cinco propriedades: (i) os pares são emitidos sempre na mesma ordem, pela posição de e_1 e de e_2; (ii) não há pares entre documentos diferentes; (iii) apenas pares cuja distância em caracteres seja $\leq \texttt{max_gap} = 25$ são gerados, sendo a distância simétrica: conta os caracteres entre o fim da entidade que aparece primeiro no texto e o início da outra, qualquer que seja e_1, e vale zero quando os *spans* se tocam ou se sobrepõem, de modo que (e_1, e_2) e (e_2, e_1) têm a mesma distância; (iv) nunca se forma o par de uma entidade consigo mesma, nem entre entidades com *span* idêntico; e (v) um par presente nas relações anotadas (*gold*) recebe o tipo anotado, e um par ausente recebe no_relation.

O Quadro 3 ilustra o processo no trecho da Figura 1. Entre as três entidades consecutivas “MSE” (9513), “sem” (9514) e “sinais flogisticos” (9554), separadas por 1 a 5 caracteres, a única relação anotada é $9514 \rightarrow 9554 = \texttt{negation_of}$. As seis combinações ordenadas são candidatas, mas apenas o par $(9514, 9554)$ casa com o *gold*; os outros cinco, inclusive o par na direção inversa, tornam-se no_relation.

O procedimento produz 152 686 candidatos de treino, 19 064 de DEV e 19 210 de teste (Tabela 2). No DEV, sobre o qual os resultados deste trabalho são medidos, 18 151 pares (95,21%) pertencem a no_relation, contra 763 associated_with e 150 negation_of. Esse desbalanceamento é intrínseco à tarefa, pois decorre da combinatória de pares de entidades, e é tratado pela ponderação da perda (Seção 4.1) e pelo uso do macro-F1 na seleção de modelos (Seção 4.4).

Quadro 3 – Exemplo de geração de candidatos para um trecho do SemClinBr.

Entidades (documento 9091): 9513="MSE" (*Body Location or Region*|*Abbreviation*), 9514="sem" (*Negation*), 9554="sinais flogisticos" (*Sign or Symptom*).
Relação *gold*: $9514 \rightarrow 9554 =$ `negation_of`.

Par ordenado	Rótulo gerado	
$9514 \rightarrow 9554$	`negation_of`	(casa com o *gold*)
$9554 \rightarrow 9514$	`no_relation`	(direção inversa do *gold*)
$9513 \rightarrow 9514$	`no_relation`	
$9514 \rightarrow 9513$	`no_relation`	
$9513 \rightarrow 9554$	`no_relation`	
$9554 \rightarrow 9513$	`no_relation`	

Fonte: elaborado pelo autor a partir de dados do SemClinBr (OLIVEIRA *et al.*, 2022).

4.5.5 Teto de recall imposto pela janela

A janela `max_gap`$= 25$ impõe um teto de recall: toda relação *gold* cujo par fique a mais de 25 caracteres jamais é gerada como candidato e é irrecuperável por qualquer classificador. A Tabela 5 quantifica a cobertura das relações anotadas por partição (além da janela, pares com *span* idêntico e relações repetidas sobre o mesmo par contam como não cobertos). O limite não se distribui igualmente entre as classes: a cobertura é maior na classe-alvo `negation_of` do que em `associated_with`, coerente com a distância menor entre os argumentos da negação. A Tabela 6 mostra o custo de ampliar a janela, que é de outra natureza: a partir de 25, os ganhos de cobertura de `negation_of` são pequenos, enquanto o número de pares candidatos e de exemplos `no_relation` por relação coberta continua a crescer quase linearmente (com 50, cerca de 76% mais candidatos). Como o teto é idêntico para todas as estratégias, que recebem exatamente os mesmos candidatos, ele limita o desempenho absoluto, mas não afeta a comparação entre elas.

Cobertura e *recall* são, portanto, medidas distintas. A cobertura é a fração das relações anotadas que se tornam candidatas; o *recall* reportado neste trabalho é calculado sobre os candidatos, e o *recall* sobre as relações anotadas é o produto dos dois. No

Tabela 5 – Relações anotadas que se tornam pares candidatos com `max_gap`$= 25$ (teto de *recall*), por partição.

Partição	`negation_of`	`associated_with`
Treino	1 255/1 299 (0,9661)	7 096/7 922 (0,8957)
Desenvolvimento	150/155 (0,9677)	763/832 (0,9171)
Teste	152/152 (1,0000)	996/1 098 (0,9071)

Fonte: elaborado pelo autor.

Tabela 6 – Sensibilidade ao `max_gap` (treino e desenvolvimento): pares candidatos, cobertura das relações e pares `no_relation` por relação coberta. * valor adotado.

`max_gap`	Candidatos	Cob. `negation_of`	Cob. `associated_with`	`no_relation`/relação
5	61 982	0,7999	0,6525	8,0
10	87 418	0,8700	0,7506	10,2
15	116 772	0,9402	0,8239	12,6
20	144 374	0,9525	0,8674	15,1
25*	171 750	0,9663	0,8978	17,5
30	198 956	0,9746	0,9184	20,0
50	302 844	0,9862	0,9550	29,9
100	541 912	0,9869	0,9801	53,1
200	954 044	0,9869	0,9909	93,4

Fonte: elaborado pelo autor.

DEV, das 155 relações `negation_of` anotadas, 153 formam pares distintos (duas se repetem sobre o mesmo par) e 150 estão dentro da janela; um sistema que acerte 141 das 150 candidatas tem *recall* de $0{,}940$ sobre os candidatos e de $0{,}910$ sobre as relações anotadas. No teste, todas as 152 relações `negation_of` anotadas estão dentro da janela (Tabela 5), e os dois valores coincidem para essa classe, o que precisa ser considerado ao comparar o DEV com o teste.

O valor 25 foi fixado antes do registro do protocolo. A contagem de cobertura que acompanhou essa escolha, citada no código do projeto, foi feita sobre as relações anotadas do corpus inteiro, incluindo o conjunto de teste: com 20 caracteres, $1\,324$ das $11\,458$ relações ($11{,}6\%$), quase todas `associated_with` ($1\,272$), ficariam fora dos

candidatos; com 25, ficam fora $1\,004$ ($8{,}8\%$). Trata-se de uma contagem sobre as anotações, e não de uma medida de desempenho de modelo, mas a escolha da janela teve contato com as anotações do conjunto completo, e isso fica registrado.

4.5.6 Tipos semânticos e controles diagnósticos

Os tipos semânticos anotados pelo SemClinBr são preservados nas partições, no campo de tipo de cada entidade, mas não são usados como entrada por nenhuma das configurações experimentais: os marcadores de entidade são apenas posicionais (Seção 5.3). Para medir o quanto essa informação antecipa a tarefa, e, portanto, o atalho que um modelo teria se a recebesse, foram definidos controles diagnósticos informados pelas anotações. Eles não são configurações do RECLin-PT, não envolvem treino, não entram nas comparações do protocolo e foram calculados apenas no treino e no DEV, sobre os mesmos pares candidatos dos modelos:

- tipo $\rightarrow$ pista: no nível da entidade, toda entidade com o tipo `Negation` é prevista como pista, e a referência são as entidades que são e_1 de ao menos uma `negation_of` anotada; no nível do par, todo candidato cujo e_1 tem o tipo `Negation` e cujo e_2 não tem é previsto como `negation_of`;
- tipo e posição: para cada entidade `Negation`, a primeira entidade seguinte no texto que não tenha esse tipo é tomada como alvo, e o par é previsto como `negation_of` se for candidato.

Os resultados estão na Tabela 7. O tipo `Negation` identifica 96% das pistas anotadas. As que ele não identifica correspondem às relações cujo e_1 não tem esse tipo: no treino, 38 relações com a direção invertida, em que a expressão de negação é o segundo argumento, e 4 sem nenhuma entidade `Negation`; no DEV, 5 invertidas. A precisão em torno de $0{,}6$ decorre de cerca de 37% das entidades `Negation` não participarem de nenhuma `negation_of` anotada. No nível do par, o tipo sozinho mantém *recall* de $0{,}967$ com precisão de $0{,}16$, e a regra de tipo e posição alcança F1 de $0{,}719$ no treino e de $0{,}699$ no DEV, sem aprendizado.

Tabela 7 – Controles diagnósticos com o tipo semântico `Negation` anotado, no treino e no DEV.

Controle	Partição	TP	FP	FN	P	R	F1
Tipo `Negation` → pista (entidades)	Treino	1 125	716	42	0,611	0,964	0,748
	DEV	136	94	5	0,591	0,965	0,733
Tipo `Negation` → `negation_of` (pares)	Treino	1 213	6 191	42	0,164	0,967	0,280
	DEV	145	751	5	0,162	0,967	0,277
Tipo `Negation` + posição (pares)	Treino	1 089	684	166	0,614	0,868	0,719
	DEV	130	92	20	0,586	0,867	0,699

Controles diagnósticos informados pelas anotações, sem treino; não são configurações do RECLin-PT. Pares: os candidatos da tarefa (`max_gap`$= 25$). Teste não avaliado.

Fonte: elaborado pelo autor.

Esses números indicam que fornecer o tipo `Negation` ao modelo entregaria quase toda a identificação da pista por meio da própria anotação, um recurso que não existe quando as entidades são reconhecidas automaticamente, e que a dificuldade restante da tarefa está na escolha do alvo. Por isso, os tipos semânticos ficam fora da entrada das configurações. Os controles servem apenas como diagnóstico do atalho e não são tratados como sistemas concorrentes.

4.6 PROTOCOLO PRÉ-REGISTRADO E COMPARAÇÕES ESTATÍSTICAS

As decisões experimentais desta fase foram fixadas em um protocolo registrado antes de qualquer treino, rotulado “validação inicial, seed 42”. Ele define o escopo (*encoder* BioBERTpt-all, semente 42 e as partições congeladas), a revisão exata dos pesos pré-treinados, os critérios de seleção e de parada de cada estratégia, os limiares escolhidos no DEV, a sequência de execução e a forma de interpretar os resultados. Alterações posteriores ao registro dependem de aprovação explícita do autor e ficam documentadas; a mais relevante para este texto é a decisão que fixou a configuração atual da Pair-Aware (Seção 5.4.4), aprovada antes de seu treino. As execuções com o BioBERTpt-clin e o BERTimbau-base, nas três estratégias, estendem a comparação de *encoders* e estão fora do escopo pré-registrado, que fixa o BioBERTpt-all; usam, porém, a mesma configuração, os mesmos critérios de seleção e o mesmo limiar de busca, trocando apenas o *checkpoint*. A variante Pair-Aware MLP também está fora do

escopo e é exploratória.

A Pair-Aware linear (Seção 5.4.4) é a arquitetura oficial do RECLin-PT, por decisão do autor. Essa designação não faz parte do protocolo pré-registrado, que toma o Two-Stage como objeto das duas comparações principais previstas para o teste (contra o baseline e contra o baseline calibrado) e trata a comparação com a Pair-Aware como exploratória. A designação também não consta dos registros do projeto até 22/10/2026, quando terminou o último treino no DEV: até então, os registros e o próprio texto tratavam o Two-Stage como referência preliminar, e os primeiros registros da designação são de 01/11/2026. Ela foi, portanto, registrada com os resultados do DEV já conhecidos e não constitui evidência confirmatória. ~~Antes de qualquer avaliação no teste, as comparações principais precisam ser redefinidas em~~

Uma emenda ao protocolo ~~; a emenda correspondente~~ (E3)~~foi~~ , redigida como proposta e ainda não ~~foi aprovada. Até lá,~~ aprovada, registra as decisões do autor para a etapa seguinte. Pela proposta:

- a Pair-Aware linear é a arquitetura principal;
- o BioBERTpt-all continua sendo o *encoder* de referência, como no protocolo, e os demais *encoders* seguem como variantes experimentais;
- a configuração de referência atual (Pair-Aware linear, BioBERTpt-all, semente 42) não é definitiva, e novos experimentos de aprimoramento, só com treino e DEV, continuam permitidos;
- o modelo final é definido depois desses experimentos e do congelamento da configuração;
- o conjunto de teste é avaliado uma única vez, só para o modelo final, sem comparar sistemas.

Os critérios estatísticos e o critério de seleção da configuração final continuam em aberto. Enquanto a emenda não for aprovada, vale o protocolo registrado, e as comparações deste texto entre a Pair-Aware linear e as demais estratégias são descritivas. O

protocolo prevê ainda uma estratégia de *fine-tuning* restrito, treinada apenas sobre os pares cujo primeiro argumento é pista do léxico de negação, que não foi executada até o momento e, por isso, não é descrita no Capítulo 5 (Seção 7.5).

Todas as escolhas usam somente o DEV:

- Época: cada estratégia de três rótulos treina um número fixo de épocas, sem parada antecipada, e mantém a de maior macro-F1 no DEV (empate: a primeira). Os estágios do Two-Stage usam métricas próprias (Seção 5.4.5).
- Limiares: o limiar τ do Two-Stage e o limiar t do baseline calibrado são escolhidos numa grade de $0{,}05$ a $0{,}95$, com passo de $0{,}05$, pelo maior F1 de `negation_of` da saída final no DEV (desempates: maior macro-F1, menor distância de $0{,}5$, maior limiar) e congelados em arquivo vinculado aos *hashes* dos modelos e do DEV.
- Léxico de pistas: o léxico usado pelo filtro foi congelado antes da fase, por validação cruzada só no treino (Seção 5.4.3).

O ~~teste de cada sistema deve ser avaliado~~ protocolo registrado prevê que cada sistema seja avaliado no teste uma única vez, depois que todas as escolhas do DEV estiverem congeladas~~, e~~; pela emenda proposta (E3), só o modelo final será avaliado nele. Em ambos os casos, nenhum resultado de teste influencia qualquer escolha. Até o momento deste texto, nenhuma das configurações deste trabalho, entre elas a Pair-Aware linear, foi avaliada no teste, porque a configuração ~~definitiva, inclusive a escolha do *encoder*, ainda~~ final não foi congelada. O conjunto de teste, contudo, não é inédito: seus documentos e rótulos foram usados em avaliações anteriores do projeto, cujos números não são utilizados neste trabalho. Quando o teste for avaliado, a análise principal será feita sobre o teste completo, e a análise sem os três documentos com cópia no treino (Seção 4.5.3) será relatada como secundária. Por isso, todos os resultados do Capítulo 6 são de DEV. Os do Two-Stage e do baseline calibrado são, além disso, otimistas por construção, porque seus limiares foram escolhidos no mesmo DEV em que são medidos.

Para as comparações estatísticas entre sistemas, empregam-se dois testes pareados, calculados sobre o *mesmo* conjunto a partir das predições salvas. O teste de McNemar (DIETTERICH, 1998) considera as instâncias em que os dois sistemas discordam quanto ao acerto (b: só o primeiro acerta; c: só o segundo) e avalia, sob a hipótese nula de mesma taxa de acerto, $b \sim \mathrm{Binomial}(b+c,\, 0{,}5)$ pelo teste binomial exato. Por incidir sobre o acerto global, ele é dominado pela classe `no_relation` e não é específico da classe-alvo. O *bootstrap* pareado responde à pergunta da classe-alvo: reamostram-se as instâncias com reposição $10\,000$ vezes (semente 42), recalcula-se a diferença no F1 de `negation_of` e reportam-se a diferença, o intervalo de confiança de 95% (percentis $2{,}5/97{,}5$) e um valor-p bilateral. Uma diferença é tratada como detectada quando o IC95% exclui o zero.

O *bootstrap* do protocolo reamostra pares candidatos, como se fossem independentes, embora os pares de um mesmo documento compartilhem texto e anotador. Por isso, as comparações no DEV são acompanhadas, como análise complementar, de um *bootstrap* pareado por documento, que reamostra com reposição os documentos inteiros ($10\,000$ reamostras, semente 42) e recalcula as métricas sobre todos os pares dos documentos sorteados. Os dois níveis são aplicados ao F1 de `negation_of`, ao F1 de `associated_with` e ao macro-F1, a partir das mesmas predições.

O protocolo registrado prevê esses testes no conjunto de teste. Neste trabalho eles são aplicados ao DEV apenas de forma descritiva, para dimensionar a incerteza das diferenças observadas~~; não substituem a comparação pré-registrada no teste~~ , e não corrigem o otimismo dos sistemas com limiar escolhido no DEV. Se a emenda proposta for aprovada, o teste não terá comparações entre sistemas, e as diferenças entre estratégias e *encoders* ficarão apoiadas só no DEV. Com uma única semente, eles medem a incerteza sobre os exemplos, dados os modelos treinados, e não a variação do treino.

5 PROPOSTA DO RECLIN-PT

Este capítulo apresenta a proposta do RECLin-PT, modelo de extração de relações clínicas em português com ênfase em `negation_of`. Um modelo RECLin-PT é formado por um *encoder* pré-treinado, ajustado sobre os pares candidatos do Capítulo 4, e por uma estratégia de modelagem, que define como as saídas desse *encoder* produzem os três rótulos. O desenvolvimento consiste em escolher esses dois componentes, e por isso eles são examinados em duas dimensões: os *encoders*, comparados sob configuração idêntica, e as estratégias, comparadas com o mesmo *encoder*. A arquitetura oficial do RECLin-PT é a Pair-Aware linear (Seção 5.4.4); o baseline é a referência experimental, o Two-Stage é uma estratégia experimental, a Pair-Aware MLP é uma variante exploratória, e o baseline calibrado e o filtro léxico são controles. As alternativas são descritas aqui sem antecipar resultados~~, e a~~. A configuração de referência atual é a Pair-Aware linear com o BioBERTpt-all e a semente 42; a configuração final, inclusive o *encoder*, só será ~~selecionada depois do congelamento das escolhas e da avaliação~~ definida depois dos experimentos de aprimoramento e do congelamento, e só ela será avaliada no teste (Seção 4.6).

5.1 PARIDADE ENTRE OS SISTEMAS COMPARADOS

A premissa metodológica central é a paridade. Todas as estratégias usam a mesma partição congelada, os mesmos pares candidatos (e, portanto, o mesmo teto de *recall*), a mesma representação de entrada (Seção 5.3), a mesma configuração base de otimização (Quadro 1), a mesma semente e critérios de seleção fixados no protocolo. Todas gravam predições no conjunto completo de candidatos, na mesma ordem e com os mesmos rótulos de referência, o que permite compará-las por todas as métricas e pelos mesmos testes pareados. Entre *encoders*, a paridade é ainda mais estrita: em cada estratégia, os três modelos passam exatamente pelo mesmo código, e trocar um pelo outro consiste em mudar o *checkpoint* carregado.

5.2 OS *ENCODERS*

O *encoder* de domínio clínico é o BioBERTpt-all (`pucpr/biobertpt-all`)[1] (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e textos biomédicos em português brasileiro, com $177{,}9$ milhões de parâmetros com a cabeça de classificação do baseline. É o *encoder* fixado pelo protocolo desta fase, o *encoder* de referência da configuração atual e o único com o qual a variante Pair-Aware MLP foi treinada e os controles foram calculados.

O *encoder* de domínio geral é o BERTimbau-base [2] (SOUZA; NOGUEIRA; LOTUFO, 2020), referência de domínio geral para o português, com $108{,}9$ milhões de parâmetros (cerca de 61% do BioBERTpt-all). Ele entra como o controle que isola o efeito do domínio de pré-treino. Se o desempenho for equivalente, o modelo menor é preferível por custo de inferência e de memória, consideração concreta para ambientes clínicos com recursos limitados.

A variante BioBERTpt-clin (`pucpr/biobertpt-clin`)[3] (SCHNEIDER *et al.*, 2020), adaptada só a narrativas clínicas, tem o mesmo número de parâmetros do BioBERTpt-all e permite distinguir, dentro do domínio clínico, o efeito do material de adaptação. O BERTimbau-base e o BioBERTpt-clin foram treinados nas três estratégias (baseline, Pair-Aware linear e Two-Stage), com a mesma configuração e os mesmos critérios do BioBERTpt-all, como variantes de *encoder* fora do escopo pré-registrado desta fase.

A delimitação a esses *encoders* é deliberada. Para orientar a configuração do RECLin-PT, a influência do domínio de pré-treinamento e da estratégia de extração de relações é avaliada sob condições experimentais controladas, e por isso cada comparação muda um único fator: o *checkpoint*, com a estratégia fixa, ou a estratégia, com o *encoder* fixo. Os três *encoders* têm a mesma arquitetura de porte *base*, e a diferença no número de parâmetros entre os BioBERTpt e o BERTimbau-base decorre inteiramente do tamanho do vocabulário, cerca de quatro vezes maior nos BioBERTpt ($119\,551$ contra $29\,798$ *tokens*, incluídos os marcadores), que amplia a matriz de *embeddings*. Variantes

[1] *Checkpoint* público em huggingface.co/pucpr/biobertpt-all.
[2] *Checkpoint* público `neuralmind/bert-base-portuguese-cased`, em huggingface.co/neuralmind/bert-base-portuguese-cased.
[3] *Checkpoint* público em huggingface.co/pucpr/biobertpt-clin.

de maior porte, como os modelos *large*, ficaram fora do escopo experimental: cada uma acrescentaria custos de treinamento e de avaliação a todas as estratégias e introduziria a escala como um fator adicional, o que tornaria a comparação menos viável e menos controlada nas condições deste trabalho. Modelos maiores podem apresentar vantagens, mas o porte, por si só, não garante ganhos na tarefa investigada, e a questão permanece aberta para trabalhos futuros. A delimitação, portanto, não implica que os *encoders* escolhidos sejam superiores a outros.

5.3 REPRESENTAÇÃO DE ENTRADA: MARCADORES DE POSIÇÃO

Os modelos não recebem o par de entidades de forma abstrata, e sim um recorte do *texto* do documento com o par delimitado por marcadores de entidade (SOARES *et al.*, 2019). A função `janela_marcada` (`reclin/entrada.py`) recorta uma janela de ± 128 caracteres em torno do par (`ctx_chars`) e insere quatro delimitadores, no esquema

$$\texttt{[E1]}\ \texttt{superfície}_{e_1}\ \texttt{[/E1]}\quad \ldots\quad \texttt{[E2]}\ \texttt{superfície}_{e_2}\ \texttt{[/E2]}$$

Os quatro marcadores são registrados como *tokens*[4] especiais, e a matriz de *embeddings* é redimensionada para lhes dar um vetor dedicado, aprendido durante o ajuste fino. Duas propriedades delimitam *que informação* o modelo recebe:

1. Os marcadores são posicionais, não semânticos. Eles indicam quais trechos da janela formam o par e qual deles é o primeiro argumento. O tipo semântico anotado pelo SemClinBr (`Disease or Syndrome`, `Negation`, `Finding`...) não é passado ao modelo, que precisa inferir a natureza de cada entidade a partir da superfície textual e do contexto. A escolha é deliberada: o tipo `Negation` marca a própria pista de negação, e os controles diagnósticos da Seção 4.5.6 mostram que ele, sozinho, recupera $96{,}7\%$ dos pares `negation_of` candidatos, um atalho indisponível quando as entidades vêm de um reconhecimento automático.

[4] *Tokens* são as unidades em que o *tokenizer* divide o texto antes de entregá-lo ao modelo, e podem ser palavras inteiras ou fragmentos de palavra. Os especiais não vêm do texto e recebem um vetor próprio.

2. A direção vem da etiqueta, não da ordem. Quando e_2 precede e_1 no texto, a *string* resultante começa por `[E2]`; a direção da relação, que importa para `negation_of`, é preservada por *qual* marcador envolve *qual* entidade.

Aplicado ao trecho do Quadro 3, o par *gold* $9514 \rightarrow 9554$ produz a entrada reproduzida, em parte, no Quadro 4, na qual nenhum tipo semântico aparece.

Quadro 4 – Entrada efetivamente construída para o par *gold* do Quadro 3.

```
... acesso venoso periferico em MSE [E1] sem [/E1] [E2] sinais
flogisticos [/E2] e salinizado ...
```

Fonte: elaborado pelo autor a partir de dados do SemClinBr (OLIVEIRA *et al.*, 2022).

A anotação de tipo, além de não chegar ao modelo, não seria aproveitável na forma em que vem. No treino ocorrem apenas 89 tipos *atômicos* distintos, mas a combinação multirrótulo faz o número de *strings* de tipo distintas subir para 828, das quais 752 contêm "`|`"; cada combinação viraria um símbolo praticamente único e mal povoado. Para a comparação de *encoders*, a ausência do tipo é inclusive conveniente, pois mede a capacidade de cada um de *inferi-lo* do texto, exatamente onde o pré-treinamento de domínio deveria fazer diferença.

5.4 ESTRATÉGIAS DE MODELAGEM

5.4.1 Baseline

O baseline é o classificador direto da tarefa: todos os pares candidatos, a janela marcada e o *encoder* com a cabeça de classificação de sequência, que projeta a representação agregada (`[CLS]`) nas três classes. Usa a configuração comum de treino e de seleção de época (Seção 4.1 e Quadro 1) e nenhum conhecimento específico de negação. É a referência experimental contra a qual as demais estratégias são descritas, pelas suas diferenças.

5.4.2 Baseline calibrado

O baseline calibrado não treina nada: aplica às probabilidades já produzidas pelo baseline um limiar t sobre a probabilidade de `negation_of`. Se $P(\texttt{negation_of}) \geq t$, o

par recebe `negation_of`; caso contrário, recebe a mais provável entre `associated_with` e `no_relation`. O limiar é escolhido no DEV pela busca do protocolo (Seção 4.6). Seu papel é de controle: como o Two-Stage também depende de um limiar escolhido no DEV, só a comparação com o baseline calibrado permite separar o efeito da arquitetura do efeito de simplesmente recalibrar a decisão.

5.4.3 Filtro léxico

O filtro pós-processa as predições do baseline com um léxico de pistas de negação: toda predição `negation_of` cujo primeiro argumento (e_1) não seja uma pista do léxico é rebaixada a `no_relation`. Nenhuma predição é promovida, nenhuma outra classe é tocada e, por isso, o filtro só pode elevar a precisão da classe-alvo, nunca o seu *recall*. As formas são comparadas após remoção de acentos, colapso de espaços e conversão para caixa baixa.

O léxico é induzido exclusivamente do treino: são contadas as formas de e_1 nos pares candidatos `negation_of`, e retêm-se as que atingem uma frequência mínima (`min_freq`). O valor foi escolhido antes da fase, por validação cruzada em 5 partes só no treino, sem modelos, predições, DEV ou teste, pelo maior F1 do léxico como detector; a escolha recaiu sobre `min_freq`$= 10$, que retém 8 formas (Apêndice B). Duas limitações registradas acompanham essa escolha: o valor escolhido é o maior da grade avaliada, e o critério favorece a precisão, porque os falsos positivos dominam o F1 de um léxico usado como detector.

5.4.4 Pair-Aware linear: a arquitetura oficial

A Pair-Aware substitui a cabeça do baseline por uma que lê explicitamente o par: os estados ocultos da última camada nas posições do `[CLS]`, de `[E1]` e de `[E2]` são concatenados e projetados nas três classes,

$$[\,h_{\texttt{[CLS]}}; h_{\texttt{[E1]}}; h_{\texttt{[E2]}}\,] \rightarrow \text{Dropout} \rightarrow \text{Linear}(3d, 3),$$

a variante *entity start* de Soares *et al.* (2019), com o `[CLS]` mantido. A configuração em vigor foi fixada antes de seu treino, por decisão registrada no protocolo: todos os

pares candidatos, sem filtro e sem uso do léxico, cabeça linear (sem camada oculta), 3 épocas e seleção pelo macro-F1 do DEV, como o baseline. Assim, todas as suas métricas são comparáveis às do baseline, e a única diferença entre os dois é a forma de ler a representação. É a arquitetura oficial do RECLin-PT, designação feita pelo autor fora do protocolo pré-registrado (Seção 4.6); com o BioBERTpt-all e a semente 42, forma a configuração de referência atual, que não é necessariamente a definitiva.

A variante exploratória Pair-Aware MLP é idêntica, exceto pela cabeça, que tem uma camada oculta, $\mathrm{Linear}(3d, d) \to \mathrm{GELU} \to \mathrm{Dropout} \to \mathrm{Linear}(d, 3)$. Ela foi criada depois do protocolo, está fora dele e é apresentada apenas como resultado exploratório.

5.4.5 Two-Stage

O Two-Stage decompõe a decisão em dois classificadores binários independentes, cada um com seu próprio ajuste fino a partir dos pesos originais do *encoder*; nenhum estágio parte de um modelo já ajustado.

- Estágio 1, existe relação? Classifica `relacao` contra `no_relation` e é treinado com todos os pares candidatos do treino ($8\,351$ com relação e $144\,335$ sem relação). Treina por 3 épocas, e a época escolhida é a de maior precisão média (AP) da classe `relacao` no DEV completo.
- Estágio 2, qual o tipo? Classifica `negation_of` contra `associated_with` e é treinado só com os pares do treino que têm relação anotada ($1\,255$ e $7\,096$). Treina por 10 épocas, e a escolhida é a de maior F1 de `negation_of` nos 913 pares do DEV com relação anotada.
- Composição (inferência). Um par segue para o estágio 2 quando a probabilidade de relação estimada pelo estágio 1, arredondada a quatro casas, é $\geq \tau$; os demais ficam `no_relation`, e o estágio 2 decide o tipo dos pares roteados pelo argmax. A saída tem os três rótulos da tarefa sobre o conjunto completo.

O limiar τ é o único parâmetro do *pipeline* escolhido no DEV, pela busca do protocolo, executando para cada valor da grade o fluxo real (o estágio 2 só sobre os pares

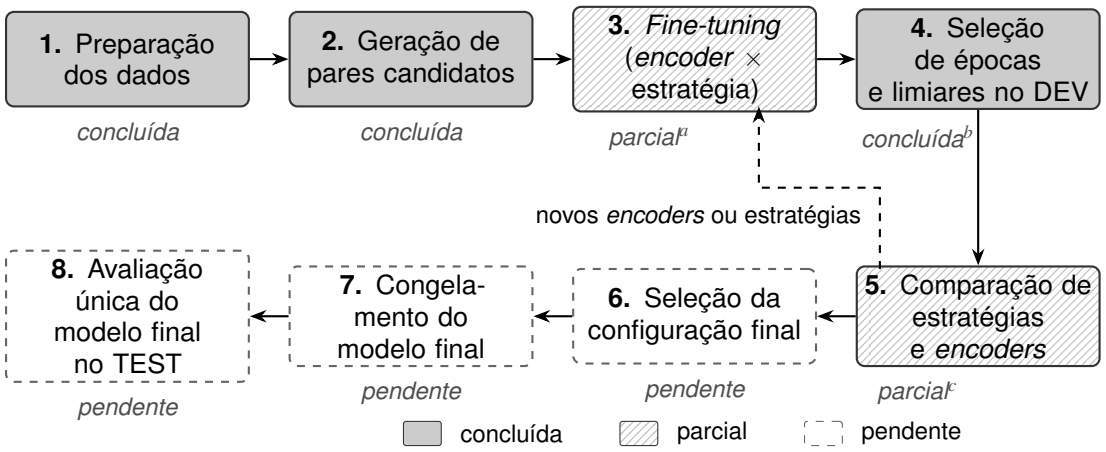
roteados). Como cada estágio é escolhido pela sua própria métrica, nada garante que a combinação de épocas seja a melhor para o *pipeline* completo, e não há otimização conjunta. O estágio 2 é treinado com os rótulos anotados, nunca com predições do estágio 1: os dois só se encontram na composição. A motivação da decomposição é a do Capítulo 2: separar a pergunta “há relação?”, dominada pelo desbalanceamento, da pergunta “qual relação?”, em que `negation_of` deixa de competir com a massa de pares `no_relation`.

6 EXPERIMENTOS E RESULTADOS

Neste capítulo são descritos os experimentos conduzidos no desenvolvimento do RECLin-PT, com foco na classe `negation_of`, bem como os resultados obtidos até o momento, todos no conjunto de desenvolvimento. Os experimentos cruzam as duas dimensões do desenvolvimento: três *encoders* (BioBERTpt-all, BioBERTpt-clin e BERTimbau-base) e três estratégias de modelagem (baseline, Pair-Aware linear e Two-Stage), além da variante exploratória Pair-Aware MLP e dos controles do protocolo. A Pair-Aware linear é a arquitetura oficial do RECLin-PT (Seção 4.6), e por isso os resultados são organizados em torno dela: como se compara às demais estratégias e como varia com o *encoder*. Este capítulo reporta o que foi observado; o que esses resultados implicam para o RECLin-PT é discutido no Capítulo 7. A Figura 3 apresenta o ciclo de desenvolvimento e o estado atual de cada etapa. A preparação dos dados, a geração de pares candidatos, o *fine-tuning* das nove combinações de *encoder* e estratégia e a seleção de épocas e de limiares no DEV estão concluídos. ~~O~~ A configuração de referência atual é a Pair-Aware linear com o BioBERTpt-all e a semente 42. Permanecem pendentes os experimentos de aprimoramento, a seleção e o congelamento da configuração ~~,~~ final e a avaliação única desse modelo final no conjunto de teste~~e a seleção da configuração final do RECLin-PT permanecem pendentes~~. A seta de retorno indica que novos *encoders*, hiperparâmetros ou estratégias voltam à etapa de *fine-tuning* antes de entrar na comparação, sempre no DEV.

Todos os números são do conjunto de desenvolvimento (DEV), com semente 42, sobre os 19 064 pares candidatos das partições congeladas (Seção 4.5.4). O DEV é o mesmo conjunto usado nas escolhas de época e de limiar, e nenhuma das configurações deste trabalho foi avaliada no teste (Seção 4.6). Os resultados são, portanto, evidências preliminares, e não estimativas finais de desempenho; os do Two-Stage e do baseline calibrado, cujo limiar foi escolhido neste mesmo DEV, são otimistas por construção (Seção 4.6).

Figura 3 – Ciclo de desenvolvimento do RECLin-PT e estado atual de cada etapa.



[a] Baseline, Pair-Aware linear e Two-Stage foram ajustados com os três *encoders* (BioBERTpt-all, BioBERTpt-clin e BERTimbau-base); a Pair-Aware MLP, só com o BioBERTpt-all; o *fine-tuning* restrito não tem execução. [b] Para as execuções existentes e verificadas. [c] Comparações descritivas no DEV; os controles do protocolo existem só com o BioBERTpt-all~~, e as comparações principais da~~. Configuração de referência atual: Pair-Aware linear~~ainda não foram pré-registradas~~, BioBERTpt-all, semente 42. Pela emenda proposta (E3), novos experimentos voltam à etapa 3 só com treino e DEV, e o TEST avalia apenas o modelo final.

Fonte: elaborado pelo autor.

6.1 EXECUÇÕES E CONFERÊNCIA DOS REGISTROS

Antes da análise, todas as execuções disponíveis foram inventariadas e conferidas a partir dos próprios arquivos gravados (Apêndice F): 7 execuções treinadas de três rótulos (baseline e Pair-Aware linear com os três *encoders* e a Pair-Aware MLP com o BioBERTpt-all), 6 estágios do Two-Stage (dois por *encoder*), 3 composições do Two-Stage, cada uma com o seu limiar τ congelado, e as 2 execuções derivadas do baseline BioBERTpt-all (baseline calibrado e filtro léxico). Todas as execuções treinadas estão concluídas, usam a semente 42, as mesmas partições (os mesmos *hashes* de treino e de DEV) e a mesma revisão de pesos por *encoder*. As execuções de três rótulos registram que o teste não foi avaliado; os estágios do Two-Stage não têm esse campo, e nenhuma execução ou composição tem métrica de teste gravada.

As métricas foram recalculadas a partir das predições gravadas e coincidem, valor a valor, com as registradas por cada execução; os rótulos de referência das predições coincidem com os do DEV reconstruído da partição congelada. Cada composição do Two-Stage foi ligada aos seus dois estágios pelos *hashes* da configuração e do melhor

modelo. Na composição com o BERTimbau-base, os nomes dos estágios registrados no arquivo do limiar diferem dos nomes das pastas, mas os dois *hashes* coincidem, o que identifica os mesmos estágios. Os *checkpoints* e os registros de console das sessões ficam fora do repositório e não foram verificados. Sete execuções foram interrompidas e retomadas a partir de um *checkpoint* e registram apenas a sessão final (Apêndice D).

6.2 TREINO E SELEÇÃO DE ÉPOCA

Nas sete execuções de três rótulos, a época selecionada foi sempre a terceira, a última permitida pelo protocolo, e o macro-F1 do DEV ainda subia entre a segunda e a terceira época em todas elas (na Pair-Aware linear com o BioBERTpt-all, de $0{,}727$ para $0{,}741$); a evolução completa por época, com perdas e duração, está no Apêndice D. Em todas, a perda do DEV foi menor na segunda época do que na terceira, de modo que perda e macro-F1 não apontaram a mesma época. A coincidência entre a melhor época e o teto é compatível com a possibilidade de que um orçamento maior de treino altere os números absolutos; essa possibilidade é comum a todas as estratégias e não foi explorada. As épocas executadas em uma única sessão levaram cerca de uma hora na GPU T4; as interrompidas e retomadas registram apenas a parte final, o que impede usar as durações para comparar o custo das estratégias.

O Two-Stage não segue esse padrão porque seus dois estágios são classificadores binários treinados separadamente, com critérios de seleção próprios, e o macro-F1 do *pipeline* completo só é definido após a escolha do limiar τ (Seção 6.7).

6.3 VISÃO GERAL

A Tabela 8 reúne os doze sistemas com resultado no DEV. Na classe-alvo, os F1 ficam entre $0{,}800$ e $0{,}832$, faixa que corresponde a poucas predições: com 150 pares `negation_of` no DEV, os sistemas diferem em no máximo 14 verdadeiros positivos e 29 falsos positivos. Em todos os *encoders*, a Pair-Aware linear tem F1 de `negation_of` maior que o do baseline (de $0{,}829$, $0{,}826$ e $0{,}818$, contra $0{,}802$, $0{,}814$ e $0{,}800$, para o BioBERTpt-all, o BioBERTpt-clin e o BERTimbau-base), com *recall* entre $0{,}940$ e $0{,}960$. O Two-Stage tem os dois maiores F1 de `negation_of`, com os dois BioBERTpt

($0{,}831$ e $0{,}832$), e as três maiores precisões, mas com *recall* menor. No macro-F1, a Pair-Aware linear com o BioBERTpt-clin ($0{,}746$) só fica abaixo do Two-Stage com o BERTimbau-base ($0{,}751$), e tem o maior MCC ($0{,}514$). Entre os controles, o filtro léxico e o baseline calibrado elevam a precisão do baseline ao custo de parte do *recall*: o filtro rebaixou 24 das 204 predições `negation_of` do baseline, e o limiar escolhido para o calibrado foi $t = 0{,}90$.

Tabela 8 – Resultados no DEV das três estratégias com os três *encoders*, da variante MLP e dos controles: precisão (P), *recall* (R) e F1 de `negation_of`, VP/FP/FN, F1 das outras classes, macro-F1 e MCC.

Estratégia	*Encoder*	P neg	R neg	F1 neg	VP/FP/FN	F1 assoc	F1 no_rel	Macro-F1	MCC
Pair-Aware linear	BioBERTpt-all	0,742	0,940	0,829	141/49/9	0,436	0,956	0,741	0,497
	BioBERTpt-clin	0,732	0,947	0,826	142/52/8	0,454	0,958	0,746	0,514
	BERTimbau-base	0,713	0,960	0,818	144/58/6	0,435	0,955	0,736	0,497
Baseline	BioBERTpt-all	0,696	0,947	0,802	142/62/8	0,408	0,946	0,719	0,480
	BioBERTpt-clin	0,722	0,933	0,814	140/54/10	0,426	0,952	0,731	0,489
	BERTimbau-base	0,708	0,920	0,800	138/57/12	0,417	0,951	0,723	0,480
Two-Stage	BioBERTpt-all ($\tau = 0{,}95$)	0,798	0,867	0,831	130/33/20	0,366	0,978	0,725	0,462
	BioBERTpt-clin ($\tau = 0{,}95$)	0,768	0,907	0,832	136/41/14	0,380	0,977	0,730	0,464
	BERTimbau-base ($\tau = 0{,}85$)	0,753	0,913	0,825	137/45/13	0,461	0,968	0,751	0,505
Pair-Aware MLP	BioBERTpt-all	0,715	0,953	0,817	143/57/7	0,438	0,956	0,737	0,498
Baseline calibrado	BioBERTpt-all ($t = 0{,}90$)	0,723	0,920	0,809	138/53/12	0,407	0,946	0,721	0,479
Filtro léxico	BioBERTpt-all	0,750	0,900	0,818	135/45/15	0,408	0,946	0,724	0,477

DEV, $n = 19\,064$ pares candidatos (150 `negation_of`, 763 `associated_with`), semente 42. Não são resultados de teste. A época de cada modelo, τ (Two-Stage) e t (baseline calibrado) foram escolhidos neste mesmo DEV. O protocolo pré-registrado fixa o BioBERTpt-all; as execuções com o BioBERTpt-clin e o BERTimbau-base são variantes de *encoder* fora do pré-registro, e a Pair-Aware MLP é exploratória.

Fonte: elaborado pelo autor.

As outras duas classes completam o quadro (Tabela 9). Em `associated_with`, todas as estratégias treinadas de três rótulos têm *recall* entre $0{,}760$ e $0{,}826$ e precisão entre $0{,}271$ e $0{,}319$; a Pair-Aware linear tem precisão maior que a do baseline nos três *encoders*. O Two-Stage com os dois BioBERTpt inverte esse perfil: precisão de cerca de $0{,}5$ e *recall* de cerca de $0{,}3$. Com o BERTimbau-base, cujo limiar é menor, o Two-Stage fica entre os dois perfis e tem o maior F1 da classe ($0{,}461$). A AP de `associated_with`, que não depende de limiar, vai de $0{,}396$ a $0{,}446$ nas estratégias de três rótulos e é maior na Pair-Aware linear do que no baseline nos três *encoders*.

A Figura 4 mostra para onde vão os erros, com o BioBERTpt-all. No baseline e na

Tabela 9 – `associated_with` e `no_relation` no DEV: precisão, *recall*, F1, VP/FP/FN e AP de `associated_with`.

		`associated_with`					`no_relation`		
Estratégia	*Encoder*	P	R	F1	VP/FP/FN	AP	P	R	F1
Pair-Aware linear	BioBERTpt-all	0,305	0,764	0,436	583/1326/180	0,445	0,989	0,925	0,956
	BioBERTpt-clin	0,319	0,785	0,454	599/1276/164	0,446	0,990	0,927	0,958
	BERTimbau-base	0,304	0,765	0,435	584/1340/179	0,413	0,990	0,923	0,955
Baseline	BioBERTpt-all	0,271	0,826	0,408	630/1696/133	0,425	0,992	0,904	0,946
	BioBERTpt-clin	0,292	0,785	0,426	599/1453/164	0,416	0,990	0,917	0,952
	BERTimbau-base	0,285	0,782	0,417	597/1501/166	0,396	0,990	0,915	0,951
Two-Stage	BioBERTpt-all ($\tau = 0{,}95$)	0,508	0,286	0,366	218/211/545	–	0,970	0,987	0,978
	BioBERTpt-clin ($\tau = 0{,}95$)	0,481	0,315	0,380	240/259/523	–	0,971	0,984	0,977
	BERTimbau-base ($\tau = 0{,}85$)	0,364	0,626	0,461	478/834/285	–	0,984	0,952	0,968
Pair-Aware MLP	BioBERTpt-all	0,308	0,760	0,438	580/1305/183	0,436	0,989	0,925	0,956
Baseline calibrado	BioBERTpt-all ($t = 0{,}90$)	0,270	0,826	0,407	630/1700/133	0,425	0,992	0,904	0,946
Filtro léxico	BioBERTpt-all	0,271	0,826	0,408	630/1696/133	–	0,992	0,905	0,946

AP: precisão média de `associated_with` calculada das probabilidades gravadas, sem limiar; não se aplica ao Two-Stage (as probabilidades do estágio 2 não são gravadas) nem ao filtro léxico (pós-processamento sem probabilidades próprias). O baseline calibrado usa as probabilidades do baseline, por isso a mesma AP.

Fonte: elaborado pelo autor.

Pair-Aware linear, a classe `negation_of` é quase toda recuperada, e o erro dominante é a confusão de `no_relation` com `associated_with` ($1\,693$ e $1\,323$ pares). No Two-Stage, essa confusão quase desaparece (208 pares), mas o erro se desloca para o sentido inverso: 541 das 763 relações `associated_with` são classificadas como `no_relation`, e 17 das 150 `negation_of` também.

6.4 A PAIR-AWARE LINEAR FRENTE ÀS DEMAIS ESTRATÉGIAS

A Tabela 10 aplica ao DEV, de forma descritiva, os testes pareados da Seção 4.6, com dois níveis de reamostragem: por candidato, como prevê o protocolo, e por documento, que reamostra os 100 documentos do DEV inteiros e leva em conta que pares de um mesmo documento não são independentes. Os intervalos por documento são, em geral, mais largos.

Contra o baseline do mesmo *encoder*, a Pair-Aware linear tem diferença detectada no macro-F1 e no F1 de `associated_with` nos três *encoders*, nos dois níveis de reamostra-

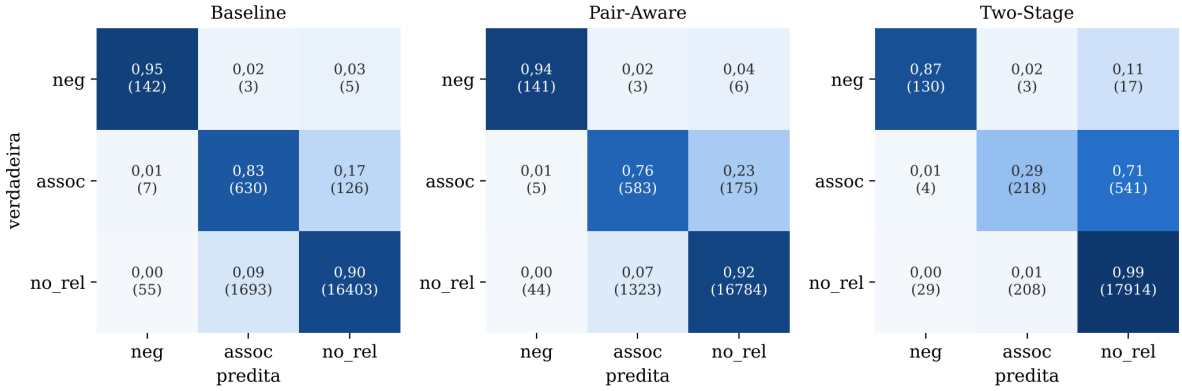
Tabela 10 – Comparações pareadas descritivas da Pair-Aware linear, no DEV: diferenças de F1 de `negation_of`, de F1 de `associated_with` e de macro-F1.

		F1 `negation_of`			F1 `associated_with`		Macro-F1			
Comparação (A − B)	*Encoder*	Δ	IC cand.	IC doc.	Δ	IC doc.	Δ	IC cand.	IC doc.	b/c
Pair-Aware linear − Baseline	BioBERTpt-all	+0,0272	[+0,005; +0,051]*	[+0,001; +0,056]*	+0,0285	[+0,009; +0,046]*	+0,0219	[+0,013; +0,031]*	[+0,010; +0,034]*	588/255
Pair-Aware linear − Baseline	BioBERTpt-clin	+0,0116	[−0,009; +0,034]	[−0,008; +0,032]	+0,0286	[+0,014; +0,042]*	+0,0151	[+0,006; +0,024]*	[+0,007; +0,023]*	432/254
Pair-Aware linear − Baseline	BERTimbau-base	+0,0182	[−0,009; +0,046]	[−0,011; +0,045]	+0,0173	[+0,005; +0,030]*	+0,0134	[+0,003; +0,024]*	[+0,004; +0,023]*	423/270
Pair-Aware linear − Two-Stage	BioBERTpt-all	−0,0013	[−0,035; +0,033]	[−0,033; +0,030]	+0,0706	[+0,013; +0,126]*	+0,0157	[−0,001; +0,032]	[−0,008; +0,038]	383/1137
Pair-Aware linear − Two-Stage	BioBERTpt-clin	−0,0062	[−0,037; +0,026]	[−0,039; +0,026]	+0,0738	[+0,014; +0,135]*	+0,0159	[+0,000; +0,032]*	[−0,008; +0,040]	376/1039
Pair-Aware linear − Two-Stage	BERTimbau-base	−0,0071	[−0,036; +0,022]	[−0,048; +0,029]	−0,0260	[−0,051; +0,001]	−0,0151	[−0,027; −0,003]*	[−0,033; +0,001]	183/589
Pair-Aware linear − Pair-Aware MLP	BioBERTpt-all	+0,0123	[−0,011; +0,036]	[−0,011; +0,037]	−0,0017	[−0,015; +0,011]	+0,0034	[−0,005; +0,012]	[−0,005; +0,013]	249/261
Pair-Aware linear − Baseline calibrado	BioBERTpt-all	+0,0200	[+0,000; +0,042]	[−0,002; +0,043]	+0,0290	[+0,009; +0,047]*	+0,0196	[+0,011; +0,029]*	[+0,009; +0,030]*	587/258
Pair-Aware linear − Filtro léxico	BioBERTpt-all	+0,0112	[−0,013; +0,036]	[−0,017; +0,039]	+0,0285	[+0,009; +0,046]*	+0,0165	[+0,007; +0,026]*	[+0,006; +0,027]*	589/264

Descritivas, no DEV: as épocas, τ e t foram escolhidos neste mesmo conjunto; não substituem as comparações pré-registradas no teste. A e B usam o mesmo *encoder*. IC cand.: IC95% do *bootstrap* pareado por candidato, o do protocolo (10.000 reamostras, semente 42). IC doc.: IC95% do *bootstrap* pareado por documento (os 100 documentos do DEV reamostrados inteiros, 10.000 reamostras, semente 42). *: intervalo que exclui o zero. b/c: pares em que só A acerta / só B acerta (McNemar exato sobre o acerto global).

Fonte: elaborado pelo autor.

Figura 4 – Matrizes de confusão no DEV (normalizadas por linha, contagens entre parênteses): baseline, Pair-Aware linear e Two-Stage, BioBERTpt-all, seed 42.



Fonte: elaborado pelo autor.

gem. No F1 de `negation_of`, a diferença só é detectada com o BioBERTpt-all ($+0{,}027$, com IC95% de $[+0{,}005; +0{,}051]$ por candidato e de $[+0{,}001; +0{,}056]$ por documento); com o BioBERTpt-clin ($+0{,}012$) e o BERTimbau-base ($+0{,}018$), os intervalos contêm o zero.

Contra o Two-Stage do mesmo *encoder*, nenhuma diferença no F1 de `negation_of` é detectada (de $-0{,}001$ a $-0{,}007$). As diferenças nas outras classes dependem do *encoder*, porque dependem do limiar do Two-Stage: com os dois BioBERTpt ($\tau = 0{,}95$), a Pair-Aware linear tem F1 de `associated_with` maior ($+0{,}071$ e $+0{,}074$, detectado nos dois níveis), e a diferença no macro-F1 ($+0{,}016$) só é detectada por candidato com o BioBERTpt-clin; com o BERTimbau-base ($\tau = 0{,}85$), o Two-Stage tem F1 de `associated_with` e macro-F1 maiores, com diferença detectada por candidato, mas não por documento.

Com o BioBERTpt-all, a Pair-Aware linear também foi comparada à variante MLP e aos controles. Com a MLP, nenhuma diferença é detectada. Contra o baseline calibrado, a diferença no F1 de `negation_of` é de $+0{,}020$, com limite inferior do IC95% igual a zero por candidato e abaixo de zero por documento, e contra o filtro léxico, de $+0{,}011$, também não detectada; no macro-F1 e em `associated_with`, a diferença é detectada contra os dois controles, que praticamente não alteram essas classes. O McNemar rejeita a igualdade em quase todas as comparações, mas responde a outra pergunta:

ele incide sobre o acerto global, dominado pela classe `no_relation`, e não é específico de nenhuma classe. Na Tabela 10, a exceção é a comparação com a variante MLP (b/c de $249/261$).

6.5 O EFEITO DO *ENCODER*

A Tabela 11 compara os três *encoders* dentro de cada estratégia, com a mesma configuração e apenas o *checkpoint* de pré-treino trocado. No F1 de `negation_of`, nenhuma das nove comparações tem diferença detectada; as diferenças vão de $-0{,}011$ a $+0{,}014$. Na Pair-Aware linear, o BioBERTpt-all tem o maior F1 da classe-alvo ($0{,}829$), o BioBERTpt-clin, o maior macro-F1 ($0{,}746$), e o BERTimbau-base, o maior *recall* ($0{,}960$) e a menor precisão ($0{,}713$).

As diferenças detectadas aparecem nas outras classes. O BioBERTpt-clin tem F1 de `associated_with` maior que o do BioBERTpt-all na Pair-Aware linear e no baseline, e maior que o do BERTimbau-base na Pair-Aware linear, nos dois níveis de reamostragem; no baseline, ele também tem macro-F1 maior que o do BioBERTpt-all. No Two-Stage, o BERTimbau-base tem F1 de `associated_with` e macro-F1 maiores que os dos dois BioBERTpt, mas essas diferenças acompanham a diferença de limiar ($\tau = 0{,}85$ contra $0{,}95$) e não isolam o *encoder*. O BERTimbau-base tem cerca de 61% dos parâmetros dos dois BioBERTpt.

6.6 A CLASSE `ASSOCIATED_WITH`

A precisão de `associated_with` é a mais baixa das três classes em todos os sistemas. A Tabela 12 decompõe os falsos positivos dessa classe. Em todas as estratégias e *encoders*, entre 25% e 31% deles são pares cuja direção inversa está anotada como `associated_with`: o modelo reconhece a associação entre as duas entidades, mas não a direção anotada. Os demais são, quase todos, pares sem relação anotada em nenhuma direção; no máximo $1{,}4\%$ são pares `negation_of`. No DEV, só 4 das 763 relações `associated_with` candidatas têm o par inverso também anotado, de modo que a direção é, na prática, sempre uma escolha exclusiva. A precisão também cai com a distância entre os argumentos: nas estratégias de três rótulos, fica entre $0{,}35$ e $0{,}39$ quando os argumentos estão a até um caractere e entre $0{,}14$ e $0{,}17$ na faixa de 11

Tabela 11 – Comparação entre *encoders* dentro de cada estratégia, no DEV (mesma configuração; só o *checkpoint* de pré-treino muda).

		F1 `negation_of`			F1 `associated_with`		Macro-F1		
Estratégia	Comparação (A − B)	Δ	IC cand.	IC doc.	Δ	IC doc.	Δ	IC cand.	IC doc.
Pair-Aware linear	BioBERTpt-clin − BioBERTpt-all	−0,0038	[−0,026; +0,018]	[−0,023; +0,016]	+0,0178	[+0,003; +0,034]*	+0,0052	[−0,003; +0,014]	[−0,004; +0,014]
Pair-Aware linear	BERTimbau-base − BioBERTpt-all	−0,0112	[−0,036; +0,013]	[−0,038; +0,014]	−0,0017	[−0,013; +0,011]	−0,0045	[−0,014; +0,005]	[−0,015; +0,006]
Pair-Aware linear	BioBERTpt-clin − BERTimbau-base	+0,0074	[−0,013; +0,029]	[−0,014; +0,029]	+0,0194	[+0,002; +0,038]*	+0,0097	[+0,001; +0,019]*	[−0,001; +0,020]
Baseline	BioBERTpt-clin − BioBERTpt-all	+0,0117	[−0,013; +0,036]	[−0,009; +0,035]	+0,0177	[+0,004; +0,032]*	+0,0120	[+0,003; +0,021]*	[+0,003; +0,022]*
Baseline	BERTimbau-base − BioBERTpt-all	−0,0023	[−0,029; +0,025]	[−0,029; +0,028]	+0,0094	[−0,008; +0,025]	+0,0041	[−0,006; +0,014]	[−0,006; +0,015]
Baseline	BioBERTpt-clin − BERTimbau-base	+0,0140	[−0,009; +0,038]	[−0,010; +0,036]	+0,0082	[−0,009; +0,025]	+0,0079	[−0,001; +0,017]	[−0,001; +0,017]
Two-Stage	BioBERTpt-clin − BioBERTpt-all	+0,0011	[−0,029; +0,031]	[−0,027; +0,031]	+0,0146	[−0,015; +0,047]	+0,0049	[−0,009; +0,019]	[−0,008; +0,020]
Two-Stage	BERTimbau-base − BioBERTpt-all	−0,0054	[−0,037; +0,026]	[−0,036; +0,026]	+0,0950	[+0,052; +0,138]*	+0,0263	[+0,011; +0,042]*	[+0,007; +0,046]*
Two-Stage	BioBERTpt-clin − BERTimbau-base	+0,0065	[−0,026; +0,039]	[−0,027; +0,040]	−0,0804	[−0,123; −0,037]*	−0,0213	[−0,037; −0,006]*	[−0,040; −0,003]*

Descritivas, no DEV: as épocas, τ e t foram escolhidos neste mesmo conjunto; não substituem as comparações pré-registradas no teste. IC cand.: IC95% do *bootstrap* pareado por candidato, o do protocolo (10.000 reamostras, semente 42). IC doc.: IC95% do *bootstrap* pareado por documento (os 100 documentos do DEV reamostrados inteiros, 10.000 reamostras, semente 42). *: intervalo que exclui o zero.

Fonte: elaborado pelo autor.

a 25 caracteres.

Tabela 12 – Falsos positivos de `associated_with` no DEV: origem e precisão por faixa de distância entre os argumentos.

			Origem dos FP			Precisão por distância			
Estratégia	*Encoder*	FP	direção invertida	sem relação	é `negation_of`	0–1	2–5	6–10	11–25
Pair-Aware linear	BioBERTpt-all	1 326	25,7%	74,1%	0,2%	0,38	0,32	0,25	0,15
	BioBERTpt-clin	1 276	26,2%	73,7%	0,1%	0,39	0,32	0,30	0,17
	BERTimbau-base	1 340	25,4%	74,6%	0,1%	0,37	0,31	0,25	0,17
Baseline	BioBERTpt-all	1 696	25,3%	74,5%	0,2%	0,35	0,28	0,22	0,15
	BioBERTpt-clin	1 453	25,8%	74,0%	0,2%	0,37	0,29	0,26	0,16
	BERTimbau-base	1 501	25,5%	74,2%	0,3%	0,38	0,29	0,24	0,14
Two-Stage	BioBERTpt-all ($\tau = 0{,}95$)	211	25,1%	73,5%	1,4%	0,52	0,52	0,46	0,41
	BioBERTpt-clin ($\tau = 0{,}95$)	259	30,9%	69,1%	0,0%	0,49	0,46	0,61	0,34
	BERTimbau-base ($\tau = 0{,}85$)	834	28,1%	71,7%	0,2%	0,41	0,37	0,35	0,21
Pair-Aware MLP	BioBERTpt-all	1 305	26,7%	73,2%	0,2%	0,38	0,32	0,25	0,17

Direção invertida: o par (e_2, e_1) tem `associated_with` anotada, e o par (e_1, e_2), não. Das 763 relações `associated_with` candidatas do DEV, só 4 têm o par inverso também anotado. Distância: caracteres entre os dois *spans* (a mesma do `max_gap`).

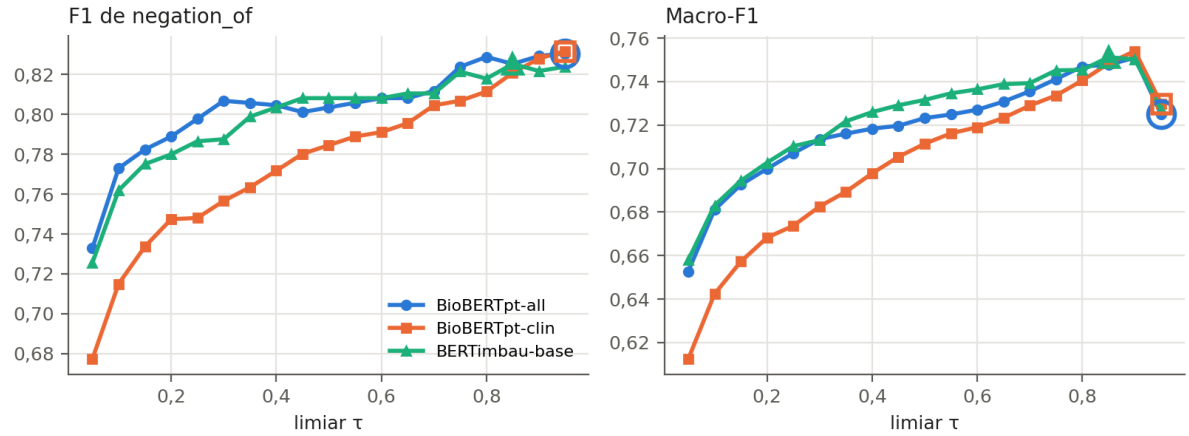
Fonte: elaborado pelo autor.

6.7 O TWO-STAGE EM DETALHE

Nos estágios do Two-Stage (Apêndice D), a época selecionada no estágio 1 foi a segunda com os dois BioBERTpt e a terceira com o BERTimbau-base, e, no estágio 2, a oitava, a sexta e a quinta das dez, para o BioBERTpt-all, o BioBERTpt-clin e o BERTimbau-base. Medido só sobre os 913 pares do DEV com relação anotada, o F1 de `negation_of` do estágio 2 ficou acima de $0{,}9$ em todas as épocas. Esses números descrevem cada estágio isoladamente e não são resultados da arquitetura, porque o estágio 2 nunca vê, na inferência, os pares que o estágio 1 não roteia.

A Figura 5 mostra o efeito de τ sobre o *pipeline* completo nos três *encoders* (a tabela completa está no Apêndice C). O F1 de `negation_of` tende a crescer com τ, enquanto o macro-F1 cresce até $\tau = 0{,}85$ ou $0{,}90$ e cai em $\tau = 0{,}95$. Com os dois BioBERTpt, o valor congelado foi $0{,}95$, o extremo superior da grade, que venceu $\tau = 0{,}90$ por margens de $0{,}0014$ (BioBERTpt-all) e $0{,}0038$ (BioBERTpt-clin) no F1 de `negation_of`, mas reduziu os pares roteados ao estágio 2 a menos da metade e o macro-F1 em cerca de $0{,}025$. Com o BERTimbau-base, o valor congelado foi $0{,}85$. Como os pares não roteados recebem `no_relation`, o limiar se reflete diretamente no *recall* de `associated_with`.

Figura 5 – Two-Stage no DEV: F1 de `negation_of` e macro-F1 do *pipeline* completo em função do limiar τ, para os três *encoders*.



Marcador vazado: τ congelado (maior F1 de negation_of). DEV, semente 42.

Fonte: elaborado pelo autor.

A Tabela 13 mostra o que o estágio 1 encaminha com o limiar congelado. Ele recupera de $88{,}7\%$ a $92{,}7\%$ dos pares `negation_of`, mas só de $38{,}9\%$ a $68{,}3\%$ do conjunto de pares com relação, e, entre os pares roteados que têm relação, o estágio 2 acerta o tipo em mais de 98% dos casos nos três *encoders*. Nestas execuções, portanto, as perdas do Two-Stage concentram-se no estágio 1 e no limiar, e não na distinção entre os tipos.

Tabela 13 – Two-Stage no DEV, por *encoder*: o que o estágio 1 encaminha com o τ congelado e quanto o estágio 2 acerta do tipo.

Encoder	τ	Roteados	Sem relação anotada	*Recall* est. 1 (neg)	*Recall* est. 1 (relação)	Acerto do tipo
BioBERTpt-all	0,95	592	237	88,7%	38,9%	98,0%
BioBERTpt-clin	0,95	676	294	90,7%	41,8%	98,4%
BERTimbau-base	0,85	1 494	870	92,7%	68,3%	98,6%

Diagnóstico do fluxo real, gravado na composição (`metricas.json`); não é resultado da arquitetura. Acerto do tipo: entre os pares roteados que têm relação anotada.

Fonte: elaborado pelo autor.

A Tabela 14 aplica ao DEV as comparações que o protocolo prevê para o teste, estendidas aos três *encoders*. No F1 de `negation_of`, o Two-Stage fica à frente do baseline do mesmo *encoder* ($+0{,}018$ a $+0{,}028$) e do baseline calibrado ($+0{,}021$), mas nenhuma dessas diferenças é distinguível de zero. O baseline calibrado e o baseline diferem em apenas 12 pares.

Tabela 14 – Comparações pareadas descritivas do Two-Stage e do baseline calibrado, no DEV (as comparações que o protocolo prevê para o teste, aqui aplicadas ao DEV e estendidas aos três *encoders*).

		F1 `negation_of`			F1 `associated_with`		Macro-F1			
Comparação (A − B)	*Encoder*	Δ	IC cand.	IC doc.	Δ	IC doc.	Δ	IC cand.	IC doc.	b/c
Two-Stage − Baseline	BioBERTpt-all	$+0{,}0284$	$[-0{,}008; +0{,}065]$	$[-0{,}013; +0{,}074]$	$-0{,}0421$	$[-0{,}107; +0{,}021]$	$+0{,}0062$	$[-0{,}012; +0{,}024]$	$[-0{,}021; +0{,}034]$	1517/430
Two-Stage − Baseline	BioBERTpt-clin	$+0{,}0179$	$[-0{,}014; +0{,}049]$	$[-0{,}018; +0{,}057]$	$-0{,}0452$	$[-0{,}102; +0{,}009]$	$-0{,}0008$	$[-0{,}017; +0{,}015]$	$[-0{,}025; +0{,}023]$	1212/371
Two-Stage − Baseline	BERTimbau-base	$+0{,}0253$	$[-0{,}005; +0{,}056]$	$[-0{,}010; +0{,}065]$	$+0{,}0434$	$[+0{,}013; +0{,}071]^*$	$+0{,}0285$	$[+0{,}016; +0{,}041]^*$	$[+0{,}012; +0{,}046]^*$	738/179
Two-Stage − Baseline calibrado	BioBERTpt-all	$+0{,}0213$	$[-0{,}011; +0{,}054]$	$[-0{,}011; +0{,}056]$	$-0{,}0416$	$[-0{,}107; +0{,}021]$	$+0{,}0040$	$[-0{,}013; +0{,}021]$	$[-0{,}021; +0{,}029]$	1512/429
Baseline calibrado − Baseline	BioBERTpt-all	$+0{,}0071$	$[-0{,}012; +0{,}026]$	$[-0{,}014; +0{,}030]$	$-0{,}0005$	$[-0{,}001; -0{,}000]^*$	$+0{,}0023$	$[-0{,}004; +0{,}009]$	$[-0{,}005; +0{,}010]$	8/4

Descritivas, no DEV: as épocas, τ e t foram escolhidos neste mesmo conjunto; não substituem as comparações pré-registradas no teste. A e B usam o mesmo *encoder*. IC cand.: IC95% do *bootstrap* pareado por candidato, o do protocolo (10.000 reamostras, semente 42). IC doc.: IC95% do *bootstrap* pareado por documento (os 100 documentos do DEV reamostrados inteiros, 10.000 reamostras, semente 42). *: intervalo que exclui o zero. b/c: pares em que só A acerta / só B acerta (McNemar exato sobre o acerto global).

Fonte: elaborado pelo autor.

6.8 RESULTADO EXPLORATÓRIO

A variante Pair-Aware MLP, fora do protocolo, foi treinada com a mesma entrada, os mesmos dados e a mesma seleção da Pair-Aware linear, mudando apenas a cabeça, e só com o BioBERTpt-all. Ela teve *recall* de `negation_of` um pouco maior ($0{,}953$) e precisão menor ($0{,}715$), e terminou com F1 de $0{,}817$ e macro-F1 de $0{,}737$, ambos abaixo da Pair-Aware linear, sem diferença detectada em nenhuma métrica (Tabela 10). Por ser exploratório, esse resultado não é evidência confirmatória.

7 DISCUSSÃO

Este capítulo interpreta os resultados de desenvolvimento do RECLin-PT à luz da pergunta de pesquisa e do que implicam para as decisões de configuração do modelo, discute as estratégias e registra as limitações e ameaças à validade. Todas as leituras abaixo são preliminares, porque se apoiam no DEV, com uma única semente, e aguardam a avaliação no teste; quando uma explicação é plausível, mas não foi testada, ela é apresentada como hipótese.

7.1 A ARQUITETURA OFICIAL: A PAIR-AWARE LINEAR

A Pair-Aware linear é a arquitetura oficial do RECLin-PT por decisão do autor (Seção 4.6). Essa decisão não decorre de um teste confirmatório: foi registrada depois de conhecidos os resultados do DEV, e o protocolo pré-registrado tomava o Two-Stage como objeto das comparações principais~~, que a~~. A emenda proposta (E3) ~~redefine em torno da~~ adota a Pair-Aware linear como arquitetura principal e reserva o teste ao modelo final, de modo que as comparações entre estratégias ficam no DEV. Os resultados do DEV não ~~a contradizem~~ contradizem a decisão, e o que eles permitem afirmar sobre ela é o seguinte.

Contra o baseline, que difere dela apenas na forma de ler a representação, o padrão se repete nos três *encoders*: a Pair-Aware linear tem macro-F1 e F1 de `associated_with` maiores, com diferença detectada mesmo quando se reamostram documentos inteiros, e F1 de `negation_of` maior, mas com diferença detectada só com o BioBERTpt-all. Esse padrão é compatível com um benefício da leitura explícita do par, que reduz os falsos positivos de `associated_with` sem sacrificar o *recall* de `negation_of`. Com uma única semente, porém, ele não pode ser separado da variação do treino, e a repetição nos três *encoders* reduz, mas não elimina, essa dúvida, porque cada combinação foi treinada uma única vez.

Na classe-alvo, a Pair-Aware linear não se distingue do Two-Stage em nenhum *encoder*, e a diferença para o baseline calibrado, controle que o protocolo exige para atribuir um efeito à arquitetura e não à simples recalibração da decisão, tem limite inferior igual a zero. Os resultados, portanto, não sustentam afirmar que a Pair-Aware linear é superior

na identificação de `negation_of`; sustentam que ela alcança, sem limiar escolhido no DEV, F1 da classe-alvo equivalente ao das demais estratégias e, em cada *encoder*, o maior macro-F1 entre as estratégias sem limiar escolhido no DEV. A variante MLP não acrescentou ganho observado sobre a cabeça linear, o que é compatível com a escolha da cabeça mais simples.

7.2 O TWO-STAGE E O PAPEL DO LIMIAR

O Two-Stage deixa de ser a referência do RECLin-PT e permanece como estratégia experimental. Pela avaliação do autor, ele não apresentou no DEV ganho suficientemente relevante para justificar a sua maior complexidade: dois classificadores treinados separadamente e um limiar escolhido no próprio DEV. Seus resultados ilustram um compromisso que não depende do *encoder*: o estágio 2 quase não erra o tipo dos pares que recebe, e as perdas se concentram no estágio 1 e no limiar. Os pares que o estágio 1 não encaminha viram `no_relation`, o que custa algumas negações e, sobretudo, relações `associated_with`.

O limiar amplifica esse compromisso. Com os dois BioBERTpt, o critério do protocolo, o F1 de `negation_of`, escolheu o extremo da grade, $\tau = 0{,}95$, à frente de $\tau = 0{,}90$ por margens de $0{,}0014$ e $0{,}0038$ no F1, com perda de cerca de $0{,}025$ no macro-F1; com o BERTimbau-base, escolheu $0{,}85$. A diferença entre os *encoders* no Two-Stage, nas classes que não são a alvo, decorre em grande parte dessa escolha, e não pode ser atribuída ao *encoder*. Um critério baseado no macro-F1 teria escolhido $\tau = 0{,}90$ com os dois BioBERTpt e $0{,}85$ com o BERTimbau-base (Apêndice C). Como o critério foi fixado antes de qualquer resultado, ele não foi alterado, e a consequência é registrada aqui. Do mesmo modo, a vantagem do Two-Stage sobre o baseline na classe-alvo, de até $0{,}028$, não é distinguível de zero nem contra o baseline nem contra o baseline calibrado, mesmo com o viés favorável de um limiar escolhido no DEV.

7.3 A ESCOLHA DO *ENCODER*

Com os três *encoders* treinados nas três estratégias, o pré-treinamento clínico não produziu vantagem detectável na classe-alvo em nenhuma estratégia: as nove comparações de F1 de `negation_of` têm intervalos que contêm o zero, e o *encoder* com o

maior F1 muda de uma estratégia para outra. Esse quadro contrasta com a expectativa difundida, bem como com os ganhos relatados para o reconhecimento de entidades clínicas em português (SCHNEIDER *et al.*, 2020), de que modelos de domínio se transfiram melhor.

Duas hipóteses são compatíveis com esse resultado, sem que os experimentos atuais permitam distingui-las ou demonstrá-las. A primeira é linguística: a negação clínica em português é fortemente lexicalizada, e o gatilho está quase sempre colado ao achado negado, com distância mediana de um único caractere (Seção 4.5.2); um sinal tão local e regular pode depender pouco de vocabulário clínico especializado. A segunda é estrutural: a tarefa, tal como formulada, depende da delimitação e da direção do par, fornecidas igualmente aos três *encoders* pela mesma representação de entrada. Testar essas hipóteses exigiria, por exemplo, analisar os erros por tipo de gatilho e por distância entre os argumentos.

Fora do Two-Stage, cujas diferenças entre *encoders* acompanham o limiar, as diferenças detectadas favorecem o BioBERTpt-clin, e não na classe-alvo: na Pair-Aware linear e no baseline, ele tem F1 de `associated_with` maior que o do BioBERTpt-all, e, na Pair-Aware linear, também maior que o do BERTimbau-base. Uma hipótese compatível, não testada, é que o pré-treinamento só em narrativas clínicas ajude a relação menos lexicalizada, mais dependente do contexto clínico. Há, por fim, o argumento de eficiência: com F1 de `negation_of` equivalente, o BERTimbau-base usa cerca de 61% dos parâmetros, o que tende a reduzir o custo de memória e de inferência, embora esse custo não tenha sido medido neste trabalho.

Para o RECLin-PT, a evidência disponível não basta para ~~fixar~~ trocar o *encoder* da Pair-Aware linear. Pela métrica primária, os três são equivalentes no DEV; pelo macro-F1 e pelo MCC, o BioBERTpt-clin fica à frente, mas, no macro-F1, sem diferença detectada nos dois níveis de reamostragem, e a vantagem detectada é a de `associated_with`, a classe mais ruidosa da anotação; pelo custo, o BERTimbau-base é o menor. ~~A escolha depende de qual desses critérios o protocolo fixar antes da avaliação no teste~~Por isso, o BioBERTpt-all, fixado no protocolo, continua sendo o *encoder* de referência, e os demais seguem como variantes experimentais, que só substituem a referência se assim

indicar a seleção da configuração final, feita no DEV antes do congelamento.

7.4 A CLASSE `ASSOCIATED_WITH`

A classe `associated_with` é a mais difícil para todas as estratégias, e a análise dos falsos positivos (Seção 6.6) indica de onde vem parte da dificuldade. Cerca de um quarto dos falsos positivos são pares cuja direção inversa está anotada como associação: o modelo reconhece o vínculo entre as duas entidades, mas não a direção escolhida pela anotação. Como quase nenhuma associação do DEV é anotada nas duas direções, e como a associação, ao contrário da negação, não tem uma direção linguística evidente, uma hipótese plausível é que a direção anotada seja, em parte, arbitrária para o modelo. A precisão também cai com a distância entre os argumentos, o que é compatível com a hipótese de que distinguir associação genuína de mera proximidade seja ambíguo em texto clínico telegráfico, em que entidades vizinhas frequentemente não mantêm relação anotada, como no exemplo do Quadro 3.

Dois fatores medidos limitam, além disso, o que se pode esperar da classe. O F1 é calculado sob o teto de *recall* imposto pela janela, que deixa de fora cerca de 8% das relações `associated_with` do DEV, contra cerca de 3% das de `negation_of` (Seção 4.5.5). E, nas seis notas anotadas duas vezes no corpus, a concordância entre as duas anotações de `associated_with` é de cerca de $0{,}57$ (Seção 4.5.3), um indício de que a própria referência é instável nessa classe. Como o foco deste trabalho é a negação, nenhuma decisão foi otimizada para `associated_with`.

7.5 LIMITAÇÕES

A limitação mais séria é a ausência de avaliação no teste. Todos os números são de DEV, o mesmo conjunto usado para escolher épocas e limiares; os do Two-Stage e do baseline calibrado são otimistas por construção, e mesmo as escolhas de época introduzem algum otimismo nas demais estratégias. A avaliação definitiva será feita no teste, uma única vez, depois de congelada a configuração. Pela emenda proposta, essa avaliação se restringe ao modelo final. Assim, o teste estimará o desempenho do RECLin-PT, mas não a sua vantagem sobre o baseline ou sobre as demais estratégias, que continuará apoiada só no DEV. Os experimentos de aprimoramento previstos até o

congelamento, avaliados no mesmo DEV, tendem a aumentar esse otimismo.

Além disso: (i) há uma única semente, de modo que não é possível separar o efeito de uma estratégia ou de um *encoder* da variação do treino; os intervalos de confiança medem só a incerteza sobre os exemplos; (ii) a designação da Pair-Aware linear como arquitetura oficial foi registrada depois de conhecidos os resultados do DEV e não é confirmatória, e ~~as~~ o protocolo registrado ainda prevê as comparações principais ~~pré-registradas para o teste ainda são as~~ do Two-Stage no teste, enquanto a emenda ~~que as redefine~~ proposta (E3) não for aprovada (Seção 4.6); (iii) o protocolo fixa o BioBERTpt-all, de modo que as execuções com o BioBERTpt-clin e o BERTimbau-base são variantes de *encoder* fora do pré-registro, e a Pair-Aware MLP é exploratória; (iv) em todas as execuções de três rótulos, a época escolhida foi a última permitida, o que sugere que mais treino poderia mudar os valores absolutos; (v) o limiar τ com os dois BioBERTpt e o `min_freq` do léxico ficaram no extremo das respectivas grades; (vi) os controles do protocolo (baseline calibrado e filtro léxico) só existem com o BioBERTpt-all; (vii) o *fine-tuning* restrito, previsto no protocolo, não foi executado; (viii) a tarefa pressupõe entidades já anotadas, e o erro de uma etapa automática de reconhecimento de entidades não é considerado; (ix) o achado se limita a esta formulação de três classes e à escala *base* dos modelos (Seção 5.2); (x) a anotação apresenta inconsistências que afetam o treino e a avaliação: 38 relações `negation_of` do treino e 5 do DEV têm a direção invertida, com a expressão de negação como segundo argumento; cerca de 37% das entidades `Negation` não participam de nenhuma `negation_of` anotada, de modo que parte dos pares `no_relation` pode corresponder a relações omitidas, e não a ausências reais; e, nas seis notas anotadas duas vezes no corpus, a concordância entre as duas anotações (F1) é de cerca de $0{,}57$ nas entidades e nas relações `associated_with`, contra $1{,}0$ nas 7 relações `negation_of` (Seção 4.5.3); e (xi) há uma única partição, na qual a semente 42 deixou o DEV com poucas relações `associated_with` e o teste com muitas (Tabela 3).

7.6 AMEAÇAS À VALIDADE

Quanto à validade interna, as partições congeladas e verificadas por *hash*, a reconstrução dos dados com offsets alinhados ao texto e o particionamento em nível de

documento mitigam o vazamento de dados e os erros de alinhamento. A divisão por documento, porém, não impediu que três notas do teste fossem cópias, diferentes só em espaços, de notas do treino; a partição foi mantida, e o protocolo prevê relatar o teste também sem esses documentos (Seção 4.5.3). Além disso, o valor da janela de candidatos foi fixado com uma contagem de cobertura que incluiu as anotações do teste (Seção 4.5.5).

Persistem, ainda, pontos de procedência que precisam ser resolvidos antes da avaliação no teste (Apêndice F). As execuções foram produzidas com quatro versões distintas do código, registradas em sete revisões, enquanto o protocolo prevê uma identidade única na conferência final; as diferenças entre as versões, conferidas nos manifestos de código registrados por cada execução, correspondem às mudanças documentadas da Pair-Aware, à criação da variante MLP e à inclusão dos novos *encoders* na configuração; o código da estratégia baseline é o mesmo em todas elas. Sete execuções foram retomadas a partir de um *checkpoint* e registram apenas a sessão final de treino; os estágios do Two-Stage não registram a revisão do código nem o campo de avaliação do teste; na composição do Two-Stage com o BERTimbau-base, os nomes dos estágios registrados no limiar diferem dos nomes das pastas, embora os *hashes* da configuração e do modelo confiram; os *checkpoints* e os registros de console ficam fora do repositório e não foram verificados; e todas as sessões registradas trazem um aviso de não determinismo de uma rotina de atenção da GPU, emitido apesar de os algoritmos determinísticos terem sido solicitados. Nenhum desses pontos altera as métricas recalculadas a partir das predições, mas todos limitam a reprodutibilidade estrita.

Uma segunda ameaça diz respeito à independência das instâncias. O *bootstrap* previsto no protocolo trata os pares candidatos como independentes, embora pares de um mesmo documento compartilhem texto. Para dimensionar esse efeito, as comparações do DEV foram repetidas com o *bootstrap* por documento, que produziu intervalos em geral mais largos e, em algumas comparações, deixou de detectar diferenças detectadas por candidato (Seção 6.4); as conclusões deste capítulo se apoiam nas diferenças detectadas nos dois níveis. Quanto à validade externa, o SemClinBr representa um conjunto específico de instituições e de estilos de redação, e

as 26 anomalias de anotação mantidas no corpus impõem um limite ao desempenho alcançável, igual para todos os sistemas.

8 CONCLUSÃO

Este trabalho teve como objetivo desenvolver o RECLin-PT, modelo de extração de relações em notas clínicas em português sobre o corpus SemClinBr, com ênfase na relação `negation_of`. Quanto à primeira parte da pergunta de pesquisa, como desenvolver o modelo, o trabalho construiu sua cadeia de dados, com a reconstrução do corpus a partir dos XML, as partições congeladas e o gerador de pares candidatos, e, sobre ela, a representação do par por marcadores e o ajuste fino de *encoders*. A arquitetura oficial do RECLin-PT é a Pair-Aware linear, que lê explicitamente as representações do par; ela foi avaliada no DEV com três *encoders*, ao lado do baseline, do Two-Stage, de uma variante exploratória e dos controles do protocolo. A configuração de referência atual é a Pair-Aware linear com o BioBERTpt-all e a semente 42, mas a configuração final do modelo, inclusive o *encoder*, ainda não foi selecionada, congelada nem validada no teste, de modo que essa parte da resposta permanece incompleta. Quanto à segunda parte, a influência do *encoder* e da estratégia sobre o desempenho, a resposta disponível é provisória e delimitada ao DEV e a uma semente: na classe-alvo, nem a troca de *encoder* nem a troca entre a Pair-Aware linear e o Two-Stage produziram diferença detectável; a estratégia influenciou sobretudo as outras classes, e o *encoder*, sobretudo `associated_with`.

8.1 PRINCIPAIS RESULTADOS

Nos três *encoders*, a Pair-Aware linear tem F1 de `negation_of` maior que o do baseline ($0{,}829$, $0{,}826$ e $0{,}818$ com o BioBERTpt-all, o BioBERTpt-clin e o BERTimbau-base, contra $0{,}802$, $0{,}814$ e $0{,}800$), com diferença detectada só com o BioBERTpt-all, e macro-F1 e F1 de `associated_with` maiores, com diferença detectada nos três, inclusive quando se reamostram documentos inteiros. O Two-Stage alcança F1 de `negation_of` equivalente ($0{,}825$ a $0{,}832$), sem diferença detectada para a Pair-Aware linear, mas depende de um limiar escolhido no DEV, que, com os dois BioBERTpt, ficou no extremo da grade e sacrificou a classe `associated_with`. Entre *encoders*, nenhuma das nove comparações no F1 de `negation_of` detectou diferença; o BioBERTpt-clin teve F1 de `associated_with` maior na Pair-Aware linear e no baseline, e o BERTimbau-base, com cerca de 61% dos parâmetros, ficou equivalente na classe-alvo. A análise dos

falsos positivos de `associated_with` mostrou que cerca de um quarto deles são pares cuja direção inversa está anotada. Para o desenvolvimento do RECLin-PT, esses resultados são compatíveis com a Pair-Aware linear como arquitetura, sem a demonstrar superior na classe-alvo, e ~~deixam a escolha do~~ não justificam trocar o BioBERTpt-all, o *encoder* ~~dependente do critério a ser fixado antes do teste~~do protocolo, que segue como referência.

8.2 LIMITAÇÕES

Essas conclusões não podem ser tomadas como definitivas. Todos os números são de DEV, o mesmo conjunto usado nas escolhas de época e de limiar; há uma única semente; a designação da Pair-Aware linear como arquitetura oficial não é confirmatória~~, e as comparações principais pré-registradas para o teste ainda são as do Two-Stage~~; as variantes de *encoder* estão fora do pré-registro; ~~e~~ a configuração final do RECLin-PT não foi congelada nem avaliada no teste; e, se a emenda proposta for aprovada, o teste avaliará só o modelo final, de modo que as diferenças entre estratégias e *encoders* continuarão apoiadas apenas no DEV. As limitações e as ameaças à validade são detalhadas no Capítulo 7 (Seção 7.5 em diante).

8.3 CONTRIBUIÇÕES

As principais contribuições são: (i) o desenvolvimento do RECLin-PT, com a Pair-Aware linear como arquitetura oficial e a comparação, sob o mesmo protocolo e com três *encoders*, de estratégias de modelagem para a extração de relações clínicas em português, do classificador direto a uma arquitetura em dois estágios; (ii) a comparação, sob configuração idêntica e em três estratégias, entre *encoders* clínicos e um geral na extração de relações sobre o SemClinBr, que subsidia a escolha do *encoder* do modelo e oferece evidência inicial sobre a lacuna descrita no Capítulo 3; (iii) a cadeia de dados que sustenta essas comparações, com os dados reconstruídos dos XML e o texto alinhado aos offsets de anotação, partições em nível de documento congeladas por *hashes* e um gerador determinístico de pares candidatos compartilhado por todas as estratégias, com o teto de *recall* quantificado; (iv) uma caracterização do corpus que evidencia o desbalanceamento das relações e a quase adjacência dos pares de

negação; e (v) um protocolo pré-registrado e uma matriz de rastreabilidade que ligam cada escolha e cada número do texto ao artefato de origem, complementados por diagnósticos reproduzíveis dos dados e das execuções: a sensibilidade da partição à semente, a detecção de documentos quase duplicados, controles informados pelas anotações, que medem o atalho oferecido pelo tipo semântico `Negation`, e a auditoria das execuções, que recalcula as métricas a partir das predições gravadas e confere os vínculos entre elas.

8.4 TRABALHOS FUTUROS

Os próximos passos decorrem diretamente das limitações registradas e são necessários para completar a avaliação do RECLin-PT:

- aprovar e registrar, antes de qualquer avaliação no teste, a emenda ao protocolo ~~já~~ redigida como proposta (E3), ~~que trata a Pair-Aware linear como arquitetura principal, define as suas~~ depois de definidos os critérios estatísticos das comparações ~~principais (contra o baseline e contra o baseline calibrado)~~ e o critério de ~~escolha do *encoder*, e formaliza as variantes de~~ seleção da configuração final, ambos ainda em aberto;
- conduzir os experimentos de aprimoramento só com treino e DEV, registrando todas as tentativas, e comparar cada uma com a configuração de referência e com os baselines do mesmo *encoder*;
- selecionar e congelar a configuração ~~definitiva, unificar a identidade do código das execuções e~~ final, conferir a proveniência ~~de todas elas, inclusive os *checkpoints*, como prevê o protocolo~~do modelo final, inclusive o *checkpoint*, e registrar a identidade do código;
- avaliar no teste, uma única vez, ~~cada sistema congelado, e aplicar as comparações pré-registradas~~apenas o modelo final congelado;
- repetir os experimentos com mais sementes, para separar o efeito das estratégias e dos *encoders* da variação do treino;

- calcular os controles do protocolo (baseline calibrado e filtro léxico) também para o BioBERTpt-clin e o BERTimbau-base, e executar o *fine-tuning* restrito previsto no protocolo;
- investigar, em novo protocolo, critérios de limiar que considerem as três classes, grades que não terminem no valor escolhido e orçamentos de treino maiores, já que a melhor época coincidiu com o teto;
- relatar a avaliação no teste também sem as três notas do teste que têm cópia no treino, como análise secundária pré-registrada, e realizar a adjudicação cega dos falsos positivos cuja pista não tem relação anotada, para separar erros do modelo de possíveis omissões da anotação;
- examinar, para `associated_with`, o efeito da direção anotada, por exemplo avaliando a classe sem direção, em protocolo próprio;
- investigar, em uma variante experimental separada e com protocolo próprio, tipos semânticos agregados na entrada, com o tipo `Negation` mascarado, já que esse tipo, sozinho, recupera quase todas as pistas (Seção 4.5.6); e integrar uma etapa automática de reconhecimento de entidades, medindo a extração de relações em um cenário fim a fim.

REFERÊNCIAS

ALMEIDA, V. A. de *et al.* **Clinical named entity recognition in the Portuguese language: a benchmark of modern BERT models and LLMs**. 2026. ArXiv:2603.26510 [cs.CL]. Pré-publicação.

CHAPMAN, W. W. *et al.* A simple algorithm for identifying negated findings and diseases in discharge summaries. **Journal of Biomedical Informatics**, v. 34, n. 5, p. 301–310, 2001.

CONNEAU, A. *et al.* Unsupervised cross-lingual representation learning at scale. In: **Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2020. p. 8440–8451.

DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. In: **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)**. [S.l.]: Association for Computational Linguistics, 2019. p. 4171–4186.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895–1923, 1998.

FORMAN, G.; SCHOLZ, M. Apples-to-apples in cross-validation studies: Pitfalls in classifier performance measurement. **ACM SIGKDD Explorations Newsletter**, v. 12, n. 1, p. 49–57, 2010.

FRAILE NAVARRO, D. *et al.* Clinical named entity recognition and relation extraction using natural language processing of medical free text: A systematic review. **International Journal of Medical Informatics**, v. 177, p. 105122, 2023.

LEE, J. *et al.* BioBERT: A pre-trained biomedical language representation model for biomedical text mining. **Bioinformatics**, v. 36, n. 4, p. 1234–1240, 2020.

LIN, C. *et al.* Does BERT need domain adaptation for clinical negation detection? **Journal of the American Medical Informatics Association**, v. 27, n. 4, p. 584–591, 2020.

OLIVEIRA, L. E. S. e. *et al.* SemClinBr – a multi-institutional and multi-specialty semantically annotated corpus for Portuguese clinical NLP tasks. **Journal of Biomedical Semantics**, v. 13, n. 1, p. 13, 2022.

SCHNEIDER, E. T. R. *et al.* BioBERTpt – a Portuguese neural language model for clinical named entity recognition. In: **Proceedings of the 3rd Clinical Natural Language Processing Workshop**. [S.l.]: Association for Computational Linguistics, 2020. p. 65–72.

SHIMAOKA, A. M. *et al.* Large language models in Portuguese for healthcare: a systematic review. **Research on Biomedical Engineering**, v. 42, n. 1, p. 13, 2026.

SILVA, D. Pinheiro da *et al.* Exploring named entity recognition and relation extraction for ontology and medical records integration. **Informatics in Medicine Unlocked**, v. 43, p. 101381, 2023.

SOARES, L. B. *et al.* Matching the blanks: Distributional similarity for relation learning. In: **Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2019. p. 2895–2905.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for Brazilian Portuguese. In: **Intelligent Systems (BRACIS 2020)**. [S.l.]: Springer, 2020. (Lecture Notes in Computer Science, v. 12319), p. 403–417.

UZUNER, Ö. *et al.* 2010 i2b2/VA challenge on concepts, assertions, and relations in clinical text. **Journal of the American Medical Informatics Association**, v. 18, n. 5, p. 552–556, 2011.

VASWANI, A. *et al.* Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

Apêndices

APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS

As partições de treino, desenvolvimento e teste reconstruídas dos XML do SemClinBr foram congeladas após sua geração (semente 42, estratificação pela presença de `negation_of`, nível de documento). O Quadro 5 apresenta os *hashes* SHA-256 dos arquivos de partição versionados no repositório do projeto e do manifesto que os registra, junto com as contagens, a proveniência dos XML e as anomalias mantidas. Qualquer alteração nos arquivos altera o *hash*, o que permite a verificação independente da integridade das partições. O código recusa combinar versões de dados numa mesma execução ou tabela, e cada execução registra os *hashes* das partições que usou.

Quadro 5 – SHA-256 das partições congeladas e do manifesto.

Partição	Arquivo	SHA-256
Treino	`train.jsonl`	`b8aaafce423afb9cda49fa5d116c14b1 4d6b9c2d09a0521bff4ef8733305d034`
Desenvolvimento	`dev.jsonl`	`19feb024ca9d60f0016491b2e9bc35ab 7de9b5cc384e0d22ba34b21a85a9f99c`
Teste	`test.jsonl`	`47d40d0b06f23714a8f332e3f8455bff 0471bb68fad7b4a835b2aa72812e9666`
Manifesto	`MANIFEST.json`	`18264860a3d8fff7bcc335b8f5703a55 d60e08893a09be2afa20b1ea446d3b70`

Fonte: elaborado pelo autor.

As partições contêm, respectivamente, 800, 100 e 100 documentos, com as contagens de relações e de pares candidatos da Tabela 2.

APÊNDICE B – LÉXICO DE PISTAS DE NEGAÇÃO

O Quadro 6 registra o léxico de pistas congelado usado pelo filtro léxico (Seção 5.4.3). As formas foram induzidas exclusivamente do treino, a partir do primeiro argumento (e_1) dos pares candidatos `negation_of`, e são comparadas após remoção de acentos, colapso de espaços e conversão para caixa baixa. O limiar `min_freq`$= 10$ foi escolhido antes da fase experimental, por validação cruzada em 5 partes só no treino, na grade $\{1,2,3,5,10\}$, pelo maior F1 do léxico como detector de `negation_of`. Nenhuma estratégia de três rótulos, nem o Two-Stage, recebe esse léxico: ele é usado apenas pelo filtro.

Quadro 6 – Léxico de pistas congelado (D4): `min_freq`$= 10$, 8 formas, `lexico_sha1` `8af0716633e9`.

Forma normalizada	Ocorrências como e_1 (treino)
`sem`	662
`nega`	353
`nao`	128
`ausente`	12
`ausencia`	11
`s`	11
`evacuacao`	10
`s/`	10

Fonte: elaborado pelo autor.

APÊNDICE C – BUSCA DO LIMIAR DO TWO-STAGE

A Tabela 15 reproduz a busca completa do limiar τ do Two-Stage no DEV para os três *encoders*, registrada no arquivo de congelamento do limiar de cada composição. Para cada valor da grade, o *pipeline* completo foi executado pelo fluxo real, com o estágio 2 aplicado só aos pares roteados. O critério do protocolo é o maior F1 de `negation_of`, com desempate pelo macro-F1, e foi o mesmo para os três *encoders*. Esses valores foram usados para a escolha de τ e são, por isso, otimistas como estimativa de desempenho.

Tabela 15 – Busca de τ do Two-Stage no DEV para os três *encoders* (*pipeline* completo, fluxo real). * valor congelado (maior F1 de `negation_of`).

	BioBERTpt-all				BioBERTpt-clin				BERTimbau-base			
τ	roteados	F1 neg	Macro-F1	R assoc	roteados	F1 neg	Macro-F1	R assoc	roteados	F1 neg	Macro-F1	R assoc
0,05	3 901	0,7328	0,6527	0,923	4 693	0,6773	0,6124	0,942	3 602	0,7254	0,6579	0,898
0,10	3 407	0,7730	0,6811	0,902	4 058	0,7150	0,6423	0,925	3 175	0,7619	0,6830	0,873
0,15	3 131	0,7824	0,6926	0,882	3 744	0,7337	0,6572	0,911	2 923	0,7751	0,6944	0,848
0,20	2 968	0,7889	0,6999	0,869	3 502	0,7474	0,6682	0,894	2 724	0,7799	0,7027	0,834
0,25	2 825	0,7978	0,7071	0,855	3 334	0,7481	0,6737	0,885	2 590	0,7865	0,7103	0,826
0,30	2 686	0,8068	0,7135	0,835	3 162	0,7566	0,6825	0,878	2 470	0,7875	0,7131	0,805
0,35	2 605	0,8057	0,7160	0,828	3 000	0,7634	0,6893	0,862	2 341	0,7989	0,7217	0,793
0,40	2 518	0,8046	0,7183	0,818	2 852	0,7717	0,6978	0,856	2 255	0,8035	0,7260	0,781
0,45	2 432	0,8012	0,7197	0,806	2 730	0,7802	0,7054	0,849	2 189	0,8081	0,7291	0,769
0,50	2 331	0,8035	0,7232	0,790	2 591	0,7845	0,7114	0,835	2 103	0,8081	0,7316	0,755
0,55	2 246	0,8058	0,7249	0,769	2 468	0,7889	0,7162	0,817	2 027	0,8081	0,7346	0,746
0,60	2 179	0,8081	0,7270	0,756	2 361	0,7911	0,7190	0,796	1 971	0,8081	0,7364	0,737
0,65	2 089	0,8081	0,7308	0,747	2 235	0,7955	0,7233	0,772	1 893	0,8105	0,7388	0,720
0,70	1 985	0,8118	0,7355	0,733	2 078	0,8045	0,7289	0,738	1 812	0,8105	0,7393	0,696
0,75	1 857	0,8239	0,7411	0,701	1 925	0,8068	0,7336	0,709	1 709	0,8214	0,7451	0,675
0,80	1 711	0,8288	0,7469	0,674	1 760	0,8114	0,7405	0,682	1 612	0,8179	0,7453	0,650
0,85	1 560	0,8253	0,7478	0,634	1 577	0,8208	0,7483	0,644	1 494*	0,8253	0,7512	0,626
0,90	1 303	0,8293	0,7509	0,561	1 356	0,8280	0,7541	0,586	1 307	0,8218	0,7502	0,567
0,95	592*	0,8307	0,7249	0,286	676*	0,8318	0,7299	0,315	788	0,8239	0,7270	0,346

R assoc: *recall* de `associated_with`. Grade e critério do protocolo, iguais para os três *encoders*.

Fonte: elaborado pelo autor.

APÊNDICE D – HISTÓRICO DE TREINO POR ÉPOCA

Este apêndice reúne a evolução por época das execuções no DEV, resumida na Seção 6.2 e na Seção 6.7. A Tabela 16 apresenta as sete execuções de três rótulos, com a época selecionada pelo maior macro-F1 no DEV. A Tabela 17 apresenta, para os três *encoders*, o valor do critério de seleção de cada estágio do Two-Stage por época. Os valores vêm dos arquivos `treino.json` de cada execução.

As durações registram o tempo de cada época na sessão em que ela foi concluída. Sete execuções foram interrompidas e retomadas a partir de um *checkpoint*: o baseline com o BioBERTpt-clin e com o BERTimbau-base, a Pair-Aware linear com o BioBERTpt-clin, a Pair-Aware MLP e o estágio 1 do Two-Stage com os três *encoders* (Apêndice F). Em cada uma delas, o registro preserva apenas a sessão final; a época retomada mostra a duração da parte executada nessa sessão, e as épocas anteriores, concluídas em sessões sem registro, não podem ser conferidas. Por isso, as durações não servem para comparar o custo de treino entre estratégias.

Tabela 16 – Evolução por época no DEV das execuções de três rótulos. $*$ marca a época selecionada (maior macro-F1 no DEV).

Execução	Época	Perda (treino)	Perda (DEV)	Macro-F1	F1 neg	Duração (min)
Pair-Aware linear (BioBERTpt-all)	1	0,4165	0,3964	0,702	0,788	58,4
	2	0,2543	0,3330	0,727	0,802	59,3
	3$*$	0,1896	0,3803	0,741	0,829	59,7
Pair-Aware linear (BioBERTpt-clin)	1	0,4026	0,4003	0,711	0,785	64,3‡
	2	0,2459	0,3167	0,733	0,814	36,2†
	3$*$	0,1799	0,3568	0,746	0,826	66,7
Pair-Aware linear (BERTimbau-base)	1	0,4379	0,3639	0,690	0,768	61,0
	2	0,2529	0,3425	0,724	0,798	61,9
	3$*$	0,1917	0,3905	0,736	0,818	62,2
Baseline (BioBERTpt-all)	1	0,5642	0,3622	0,580	0,507	62,2
	2	0,3226	0,3544	0,712	0,798	61,4
	3$*$	0,2550	0,3609	0,719	0,802	60,6
Baseline (BioBERTpt-clin)	1	0,5276	0,4072	0,703	0,787	59,2‡
	2	0,2995	0,3742	0,717	0,805	42,3†
	3$*$	0,2335	0,3745	0,731	0,814	58,1
Baseline (BERTimbau-base)	1	0,5411	0,4312	0,688	0,778	66,4‡
	2	0,2882	0,3774	0,713	0,799	67,3‡
	3$*$	0,2265	0,3930	0,723	0,800	20,3†
Pair-Aware MLP (BioBERTpt-all)	1	0,4219	0,3623	0,709	0,795	24,1‡
	2	0,2558	0,3322	0,718	0,795	10,3†
	3$*$	0,1915	0,3683	0,737	0,817	68,1

† Época interrompida e retomada a partir de um *checkpoint*; a duração cobre apenas a sessão final (Pair-Aware linear (BioBERTpt-clin), época 2: 1 272 dos 2 386 passos; Baseline (BioBERTpt-clin), época 2: 1 772 dos 2 386 passos; Baseline (BERTimbau-base), época 3: 658 dos 2 386 passos; Pair-Aware MLP (BioBERTpt-all), época 2: 272 dos 2 386 passos). ‡ Época concluída em sessão anterior, sem registro de sessão preservado. As durações não são comparáveis entre execuções como medida de custo.

Fonte: elaborado pelo autor.

Tabela 17 – Two-Stage: valor do critério de seleção de cada estágio por época, no DEV, para os três *encoders*. Em negrito, a época selecionada.

Estágio	*Encoder*	1	2	3	4	5	6	7	8	9	10
Estágio 1 (AP de relação)	BioBERTpt-all	0,506	**0,544**	0,533	–	–	–	–	–	–	–
	BioBERTpt-clin	0,498	**0,553**	0,546	–	–	–	–	–	–	–
	BERTimbau-base	0,488	0,516	**0,518**	–	–	–	–	–	–	–
Estágio 2 (F1 neg)	BioBERTpt-all	0,943	0,946	0,957	0,967	0,963	0,967	0,963	**0,970**	0,963	0,967
	BioBERTpt-clin	0,935	0,960	0,946	0,960	0,960	**0,971**	0,961	0,964	0,957	0,953
	BERTimbau-base	0,915	0,940	0,944	0,935	**0,964**	0,940	0,954	0,947	0,943	0,943

Estágio 1: AP da classe `relacao` no DEV completo (3 épocas). Estágio 2: F1 de `negation_of` nos 913 pares do DEV com relação anotada (10 épocas). Valores de cada estágio isolado, não da arquitetura.

Fonte: elaborado pelo autor.

APÊNDICE E – RESULTADO EXPLORATÓRIO DA PAIR-AWARE MLP

A Tabela 18 apresenta a variante Pair-Aware MLP, criada depois do protocolo e mantida fora dele (Seção 5.4.4), ao lado da Pair-Aware linear, ambas com o BioBERTpt-all. O resultado é exploratório: não integra a comparação pré-registrada, não é evidência confirmatória e não entra na escolha da configuração do RECLin-PT.

Tabela 18 – Resultado exploratório no DEV (fora do protocolo pré-registrado): Pair-Aware MLP ao lado da Pair-Aware do protocolo, BioBERTpt-all, seed 42.

Sistema	P	R	F1	VP/FP/FN	Macro-F1	MCC
Pair-Aware (protocolo, D10)	0,742	0,940	0,829	141/49/9	0,741	0,497
Pair-Aware MLP (exploratória)	0,715	0,953	0,817	143/57/7	0,737	0,498

Fonte: elaborado pelo autor.

APÊNDICE F – INVENTÁRIO DAS EXECUÇÕES

A Tabela 19 lista as execuções usadas no Capítulo 6: as pastas de resultados da branch `resultados-colab` do repositório do projeto e as duas execuções derivadas só do DEV (baseline calibrado e filtro léxico). O inventário e todas as métricas do Capítulo 6 foram produzidos pelo mesmo procedimento reprodutível, que lê apenas os arquivos gravados pelas execuções, recalcula as métricas a partir das predições, confere os *hashes* do conjunto de desenvolvimento e liga cada composição do Two-Stage aos seus estágios pelos *hashes* da configuração e do melhor modelo. Ele não treina, não executa modelos e não lê o conjunto de teste.

Três observações complementam a tabela. Primeiro, as execuções usam quatro identidades de código; entre a identidade da Pair-Aware MLP e a das execuções com os novos *encoders*, o único arquivo diferente é o da configuração, em que esses *encoders* foram incluídos. Segundo, na composição do Two-Stage com o BERTimbau-base, o arquivo do limiar registra os estágios com nomes diferentes dos nomes das pastas, mas os *hashes* da configuração e do melhor modelo de cada estágio coincidem com os registrados nas pastas. Terceiro, os *checkpoints* e os registros de console ficam no armazenamento das sessões de treino, fora do repositório, e não foram verificados.

Tabela 19 – Inventário das execuções da branch `resultados-colab` e das execuções derivadas só do DEV.

Pasta	Tipo	Estratégia	*Encoder*	Commit	Identidade	Sessão registrada	Melhor	TEST
`baseline_biobertpt_seed42`	treinada	Baseline	BioBERTpt-all	`cc3d8b3`	`8a6c19`	nova	3/3	não
`baseline_BioBERTpt-clin`	treinada	Baseline	BioBERTpt-clin	`3e3cb39`	`0526d9`	retomada (3 000)	3/3	não
`baseline_BERTimbau`	treinada	Baseline	BERTimbau-base	`c2cc230`	`0526d9`	retomada (6 500)	3/3	não
`pairaware_biobertpt_seed42`	treinada	Pair-Aware linear	BioBERTpt-all	`cb88c52`	`ecbb98`	nova	3/3	não
`pair_aware__6d11685f9cdb__t1`	treinada	Pair-Aware linear	BioBERTpt-clin	`54faa5e`	`0526d9`	retomada (3 500)	3/3	não
`pair_aware__f7a5acb7f500__t1`	treinada	Pair-Aware linear	BERTimbau-base	`5a42f28`	`0526d9`	nova	3/3	não
`pair_aware_mlp_BioBERTpt-all`	treinada	Pair-Aware MLP	BioBERTpt-all	`e16836d`	`22339f`	retomada (4 500)	3/3	não
`twostage_e1_biobertpt_seed42`	estágio	Two-Stage, estágio 1	BioBERTpt-all	–	`8a6c19`	retomada (6 000)	2/3	não registrado
`two_stage_e1__82490c70baed__t1`	estágio	Two-Stage, estágio 1	BioBERTpt-clin	–	`0526d9`	retomada (6 000)	2/3	não registrado
`two_stage_e1_BERTimbau`	estágio	Two-Stage, estágio 1	BERTimbau-base	–	`0526d9`	retomada (6 000)	3/3	não registrado
`twostage_e2_biobertpt_seed42`	estágio	Two-Stage, estágio 2	BioBERTpt-all	–	`8a6c19`	nova	8/10	não registrado
`two_stage_e2__65e72d6c30e8__t1`	estágio	Two-Stage, estágio 2	BioBERTpt-clin	–	`0526d9`	nova	6/10	não registrado
`two_stage_e2_BERTimbau`	estágio	Two-Stage, estágio 2	BERTimbau-base	–	`0526d9`	nova	5/10	não registrado
`two_stage_limiar_BioBERTpt-all`	composição	Two-Stage	BioBERTpt-all	–	–	–	$\tau = 0{,}95$	–
`two_stage_limiar_BioBERTpt-clin`	composição	Two-Stage	BioBERTpt-clin	–	–	–	$\tau = 0{,}95$	–
`twostage_bertimbau_seed42`	composição	Two-Stage	BERTimbau-base	–	–	–	$\tau = 0{,}85$	–
`baseline_calibrado_biobertpt_seed42`	derivada	Baseline calibrado	BioBERTpt-all	–	`8a6c19`	–	–	–
`filtro_biobertpt_seed42`	derivada	Filtro léxico	BioBERTpt-all	–	`8a6c19`	–	–	–

Commit: revisão do código registrada em `experimento.json` (os estágios do Two-Stage e as composições não têm esse arquivo). Identidade: os seis primeiros dígitos do SHA-256 do manifesto do código (`config.json`). Sessões: só a sessão final de cada treino fica registrada; "retomada (passo)"indica que o treino começou em sessão anterior, sem registro preservado. Melhor época: selecionada/registradas. TEST: o campo `test_avaliado` do `treino.json`; os estágios do Two-Stage não têm o campo. Checkpoints e *logs* de console ficam fora do repositório (Google Drive) e não foram verificados.

Fonte: elaborado pelo autor.