

INSTITUTO FEDERAL DO ESPÍRITO SANTO  
CAMPUS CACHOEIRO DE ITAPEMIRIM  
CURSO SUPERIOR DE SISTEMAS DE INFORMAÇÃO

**ALDA MARIA NORBIATO TORRES**

**DESENVOLVIMENTO DE MODELO NER PARA A EXTRAÇÃO DE INFORMAÇÕES  
EM RELATOS DE CASOS CLÍNICOS**

Cachoeiro de Itapemirim

2024

**ALDA MARIA NORBIATO TORRES**

**DESENVOLVIMENTO DE MODELO NER PARA A EXTRAÇÃO DE INFORMAÇÕES  
EM RELATOS DE CASOS CLÍNICOS**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Sistemas de Informação do Instituto Federal do Espírito Santo, Campus Cachoeiro de Itapemirim, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. M.e. Cristiano da Silveira  
Colombo

Cachoeiro de Itapemirim

2024

(Biblioteca do Campus Cachoeiro de Itapemirim)

T693d

Torres, Alda Maria Norbiato.

Desenvolvimento de modelo NER para a extração de informações em relatos de casos clínicos / Alda Maria Norbiato Torres. - 2024.  
45 f. : il. ; 30 cm.

Orientador: Cristiano da Silveira Colombo

TCC (Graduação) Instituto Federal do Espírito Santo, Campus Cachoeiro de Itapemirim, Sistemas de Informação, 2024.

1. Processamento de linguagem natural (Computação). 2. Inteligência artificial. 3. Aprendizado do computador. 4. Padrões de prática médica. 5. Medicina - Serviços de informação. I. Colombo, Cristiano da Silveira. II. Título III. Instituto Federal do Espírito Santo.

CDD: 006.3

Bibliotecário/a: Renata Lorencini Rizzi CRB6-ES nº 085



**MINISTÉRIO DA EDUCAÇÃO  
INSTITUTO FEDERAL DO ESPÍRITO SANTO  
CAI - COORDENADORIA DO CURSO DE  
BACHARELADO EM SISTEMAS DE INFORMACAO**



**FOLHA DE APROVAÇÃO-TCC Nº 10 / 2024 - CAI-CCSI  
(11.02.18.01.08.02.13)**

**Nº do Protocolo: 23151.003545/2024-25  
Cachoeiro De Itapemirim-ES, 11 de dezembro de 2024.**

ALDA MARIA NORBIATO TORRES

**DESENVOLVIMENTO DE MODELO NER PARA A EXTRAÇÃO DE INFORMAÇÕES  
EM RELATOS DE CASOS CLÍNICOS**

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal do Espírito Santo, Campus Cachoeiro de Itapemirim, como requisito parcial para obtenção do título de Bacharel em Sistemas de Informação.

Aprovado em 10 de dezembro de 2024.

**COMISSÃO EXAMINADORA**

Prof. M.Sc. Cristiano da Silveira Colombo  
Instituto Federal do Espírito Santo  
Orientador

Prof. (a) D.Sc. Susana Brunoro Costa de Oliveira  
Instituto Federal do Espírito Santo

Prof. D.Sc. Rafael Silva Guimarães  
Instituto Federal do Espírito Santo

Prof. D.Sc. Lucas Poubel Timm do Carmo  
Instituto Federal do Espírito Santo

**(Assinado digitalmente em 11/12/2024 10:01 ) (Assinado digitalmente em 12/12/2024 08:20 )**

**CRISTIANO DA SILVEIRA COLOMBO**  
PROFESSOR DO ENSINO BASICO TECNICO E  
TECNOLOGICO  
CAI-CCSI (11.02.18.01.08.02.13)  
Matrícula: 1673901

**LUCAS POUBEL TIMM DO CARMO**  
PROFESSOR DO ENSINO BASICO TECNICO E  
TECNOLOGICO  
CAI-CCSI (11.02.18.01.08.02.13)  
Matrícula: 2417426

(Assinado digitalmente em 12/12/2024 08:23 )

RAFAEL SILVA GUIMARAES  
PROFESSOR DO ENSINO BASICO TECNICO E  
TECNOLOGICO  
CAI-CCSI (11.02.18.01.08.02.13)  
Matrícula: 1919203

(Assinado digitalmente em 11/12/2024 15:58 )

SUSANA BRUNORO COSTA DE  
OLIVEIRA  
PROFESSOR DO ENSINO BASICO TECNICO E  
TECNOLOGICO  
CAI-CCTI (11.02.18.01.08.02.07)  
Matrícula: 1505999

(Não Assinado)

ALDA MARIA NORBIATO TORRES  
DISCENTE  
Matrícula: 9999361116

Visualize o documento original em <https://sipac.ifes.edu.br/public/documentos/index.jsp>  
informando seu número: **10**, ano: **2024**, tipo: **FOLHA DE APROVAÇÃO-TCC**, data de emissão:  
**11/12/2024** e o código de verificação: **a8f29d6cfe**

## **DECLARAÇÃO DO AUTOR**

Declaro, para fins de pesquisa acadêmica, didática e técnico-científica, que este Trabalho de Conclusão de Curso pode ser parcialmente utilizado, desde que se faça referência à fonte e ao autor.

Cachoeiro de Itapemirim, 05 de Dezembro de 2024.

**ALDA MARIA NORBIATO TORRES**

À minha mãe e meu pai, que foram meu pilar de força e superação nos dias em que não quis ser alguém, que nunca me desampararam em meio às dificuldades, sendo meus exemplos de vida.

À minha namorada, que segurou minha mão e me apoiou para chegar até aqui, me motivando a lutar todos os dias com um sorriso no rosto.

Ao meu professor e orientador, que abriu portas para que o conhecimento fosse transmitido, guiou meu caminho e cumpriu seu papel de forma excepcional.

Aos meus amigos de jornada, que foram âncora durante todo o processo.

Por fim, à todo o corpo docente, que de alguma forma contribuiu para a conclusão deste trabalho e que agregou à minha vida pessoal e profissional.

"Irmão, você não percebeu que você é o único representante do seu sonho na face da terra? Se isso não fizer você correr, chapa, eu não sei o que vai."  
Emicida



## RESUMO

Se faz evidente que os relatos de casos clínicos desempenham um papel crucial na prática médica e que podem ser bem aproveitados para gerar estudos e hipóteses para pesquisas sistematizadas. Entretanto, a análise de tais relatos se torna difícil pela limitação de tempo dos profissionais da saúde e pela ausência de estrutura nos textos, dificultando a identificação de padrões ou adversidades. O presente trabalho visa o desenvolvimento de um modelo de Reconhecimento de Entidades Nomeadas (Named Entity Recognition - NER) para a extração de informações em Língua Portuguesa a partir de relatos de casos clínicos. Com isso, a pesquisa envolveu a criação de uma base de dados com tais documentos disponíveis na web e a aplicação de técnicas de Processamento de Linguagem Natural (Natural Language Processing - NLP) utilizando a biblioteca spaCy. O modelo criado visa, por fim, aperfeiçoar e contribuir para a análise de dados da saúde e auxiliar no suporte em tomadas de decisões médicas. Os resultados obtidos demonstraram a viabilidade e eficácia do modelo em identificar entidades relevantes nos relatos, mostrando grande potencial para melhorias futuras e aplicações práticas na área clínica.

Palavras-chave: extração de informações, NLP, reconhecimento de entidade nomeada, relato de caso, spaCy.

## **ABSTRACT**

It is well-known that clinical case reports play a crucial role in medical practice and can be effectively utilized to generate studies and hypotheses for systematic research. However, analyzing such reports becomes difficult due to the time constraints of healthcare professionals and the lack of structure in the texts, which hinders the identification of patterns or adversities. This work aims to develop a Named Entity Recognition (NER) model for extracting information in Portuguese from clinical case reports. To this end, the research involved creating a database with such documents available on the web and applying Natural Language Processing (NLP) techniques using the spaCy library. Ultimately, the developed model aims to enhance and contribute to the analysis of health data and assist in supporting medical decision-making. The results obtained demonstrated the feasibility and effectiveness of the model in identifying relevant entities in the reports, showing great potential for future improvements and practical applications in the clinical field.

**Keywords:** case report, entity recognition, information extraction, NLP, spaCy.

## LISTA DE FIGURAS

|                                                                           |    |
|---------------------------------------------------------------------------|----|
| Figura 1 – Ciclo de treinamento spaCy. . . . .                            | 26 |
| Figura 2 – Exemplo de documento extraído da base de dados do SemClinBr. . | 27 |
| Figura 3 – Relato de caso pós processamento com modelo nativo spaCy . . . | 30 |
| Figura 4 – Trecho de padrão de anotação em um relato de caso . . . . .    | 32 |
| Figura 5 – Ciclo de desenvolvimento . . . . .                             | 32 |
| Figura 6 – Resultado de relato de caso pós treinamento . . . . .          | 37 |

## LISTA DE TABELAS

|                                                                              |    |
|------------------------------------------------------------------------------|----|
| Tabela 1 – Resultados das métricas retiradas do artigo comparativo . . . . . | 33 |
| Tabela 2 – Resultados do primeiro experimento . . . . .                      | 36 |
| Tabela 3 – Resultados do segundo experimento . . . . .                       | 38 |

## LISTA DE ABREVIATURAS

NLP *Natural Language Processing*

IA Inteligência Artificial

EI Extração de Informação

NER *Named Entity Recognition*

POS *Part-of-speech tagging*

CRF *Conditional Random Fields*

LG *Local Grammar*

RNN *Recurrent Neural Network*

MISC Miscellaneous

PER *Person*

ORG *Organization*

XML *Extensible Markup Language*

TXT *Text*

LLM *Large Language Models*

## SUMÁRIO

|              |                                                                       |           |
|--------------|-----------------------------------------------------------------------|-----------|
| <b>1</b>     | <b>INTRODUÇÃO . . . . .</b>                                           | <b>14</b> |
| 1.1          | Objetivos gerais . . . . .                                            | 15        |
| 1.2          | Objetivos específicos . . . . .                                       | 15        |
| <b>2</b>     | <b>REFERENCIAL TEÓRICO . . . . .</b>                                  | <b>17</b> |
| 2.1          | Inteligência Artificial . . . . .                                     | 17        |
| 2.2          | Aprendizado de Máquina . . . . .                                      | 18        |
| 2.3          | Processamento de Linguagem Natural . . . . .                          | 19        |
| 2.4          | Reconhecimento de Entidades Nomeadas . . . . .                        | 20        |
| 2.5          | Relatos de Caso . . . . .                                             | 21        |
| <b>3</b>     | <b>TRABALHOS CORRELATOS . . . . .</b>                                 | <b>22</b> |
| <b>4</b>     | <b>MATERIAIS E MÉTODOS . . . . .</b>                                  | <b>25</b> |
| 4.1          | SpaCy e MedspaCy . . . . .                                            | 25        |
| 4.2          | O Dataset SemClinBR . . . . .                                         | 27        |
| 4.3          | Preparação do ambiente . . . . .                                      | 27        |
| 4.4          | Métricas Utilizadas para Avaliar os Modelos . . . . .                 | 28        |
| <b>5</b>     | <b>EXPERIMENTOS E RESULTADOS . . . . .</b>                            | <b>30</b> |
| 5.1          | Experimento realizado com SpaCy . . . . .                             | 30        |
| 5.2          | Experimento realizado com MedspaCy . . . . .                          | 31        |
| 5.3          | O Modelo spaCy Treinado com Relatos Clínicos . . . . .                | 31        |
| 5.4          | O Modelo spaCy Treinado com Amostras do Dataset SemClinBr . . . . .   | 34        |
| <b>5.4.1</b> | <b>Resultados dos Testes com Relatos Usados na Fase de Treino . .</b> | <b>35</b> |
| <b>5.4.2</b> | <b>Resultados dos Testes com Relatos não Usados na Fase de Treino</b> | <b>37</b> |
| <b>6</b>     | <b>CONCLUSÃO . . . . .</b>                                            | <b>39</b> |
| 6.1          | Trabalhos futuros . . . . .                                           | 40        |
|              | <b>REFERÊNCIAS . . . . .</b>                                          | <b>42</b> |

## 1 INTRODUÇÃO

A quantidade de informações contidas em textos e documentos, disponibilizados por inúmeras áreas em todo o mundo, é extensa e, muitas vezes, complexa. Com isso, torna-se ainda mais difícil para um ser humano compreender toda essa informação. A Extração de Informação (EI) é, então, aplicada como solução automatizada com o objetivo de facilitar o processamento de dados textuais. Segundo Castro (2013), a EI objetiva localizar, estruturar e armazenar informações relevantes de um documento ou conjunto de documentos. Dessa forma, pode auxiliar na compreensão de relações entre os textos, na formulação de hipóteses para pesquisas e em resoluções para problemas.

Ao revisar o contexto da área da saúde, onde a carga de trabalho é grande e muitas vezes as soluções precisam ser praticamente imediatas, é perceptível a dificuldade em interpretação e correlação de relatos de casos clínicos por parte do corpo profissional. Sobre isso, Riedo (2019) diz que, embora os dados estejam disponíveis em redes pelo mundo, a maior parte das informações contidas nos relatos de caso são obtidas de locais heterogêneos, semiestruturados ou sem estrutura, ou seja, não possuem padrão definido, tornando difícil sua análise e comparação.

Nos dias atuais, o problema é processar um volume de informações massivo, sendo por meio de prontuários eletrônicos, resultados de exames, diagnóstico proposto, prescrição e resultados de medicações, ou por digitação, considerando que tais dados podem não estar disponíveis ou estar incompletos. Deve-se imaginar, também, que algumas informações ainda precisem ser digitadas em decorrência de erros ou incompatibilidade de sistemas onde essas estejam armazenadas. Com isso, deve-se considerar que essa inserção manual pode eventualmente introduzir um componente de erro humano, como citado por Lobo (2017).

Os relatos de caso contribuem com grande relevância na história da literatura médica, servindo como forma de aprendizado e engrandecimento do conhecimento. De acordo com Graber (2005, tradução nossa)<sup>1</sup>, durante a prática médica, a maioria dos erros

<sup>1</sup> Most errors of clinical reasoning are not linked to gross incompetence or the lack of knowledge but

de raciocínio clínico não estão ligados à incompetência ou falta de conhecimento dos profissionais de saúde, mas sim, à vulnerabilidade do pensamento dos clínicos no mundo real, que é acompanhado pela complexidade, por pressões de tempo e várias outras restrições contextuais. Audétat (2013, tradução nossa)<sup>2</sup> coloca que: a vasta grandeza da literatura sobre o raciocínio clínico e a diversidade das abordagens utilizadas tornam-no um tema difícil de compreender e assimilar completamente. A partir de tais entendimentos, este trabalho utilizou uma biblioteca gratuita e *open source* em Python para a aplicação do Processamento de Linguagem Natural (do inglês *Natural Language Processing* - NLP) em textos clínicos, com o objetivo de extrair informações ricas e auxiliar a prática clínica.

## 1.1 OBJETIVOS GERAIS

O objetivo deste trabalho é pesquisar e encontrar uma base de dados com relatos de casos clínicos publicados na *web* e treinar um modelo de Inteligência Artificial, utilizando o Reconhecimento de Entidades Nomeadas (do inglês *Named Entity Recognition* - NER) para a extração de informações em Português do Brasil. E a partir disso, fazer correlações e encontrar possíveis adversidades entre os relatos, com o propósito de auxiliar profissionais de saúde na tomada de decisões.

## 1.2 OBJETIVOS ESPECÍFICOS

- A. Pesquisar sobre *datasets* com textos de relatos de casos clínicos;
- B. Organizar e dividir os documentos para treino e teste;
- C. Anotar os relatos de caso obtidos, se for necessário, de acordo com seu contexto;
- D. Treinar o modelo para a compreensão e extração de entidades em Português;
- E. Realizar experimentos para testar o modelo;

---

rather to the vulnerability of clinicians' thinking in the real-world of clinical practice characterized by complexity, time pressures, and various other contextual constraints.

<sup>2</sup> The abundance of the literature on clinical reasoning and the diversity of approaches used make it a difficult topic to comprehend and fully grasp.



F. Compreender e aplicar as métricas adequadas.

## 2 REFERENCIAL TEÓRICO

O presente trabalho utilizou os conceitos de Inteligência Artificial (IA), Aprendizado de Máquina (do inglês *Machine Learning*), Processamento de Linguagem Natural, Reconhecimento de Entidades Nomeadas e contextualização sobre Relatos de Caso, como embasamento teórico para os treinamentos e testes. Nas próximas seções, tais conceitos estão brevemente descritos.

### 2.1 INTELIGÊNCIA ARTIFICIAL

A inteligência artificial, comumente conhecida como IA, é descrita por Garcia (2020) como a área da Ciência da Computação voltada para o desenvolvimento de sistemas realizadores de tarefas que demandam habilidades e inteligência humana. A partir de tal conhecimento, a IA baseia-se em dados previamente fornecidos de determinado domínio, usados em um conjunto de algoritmos inteligentes, para fazer com que a máquina possa ainda planejar sequências de atividades para alcançar metas (Garcia, 2020).

Martins et al. (2023) assinala que, o volume de dados criados até os dias atuais foi tão grande que ficou praticamente inviável que o ser humano gerencie a tomada de decisões a partir dos algoritmos. Por esta razão, as máquinas são treinadas e ajustadas para tomar decisões simples e massificadas. Ao seguir essa linha de raciocínio, infere-se que um modelo de IA não é realmente capaz de compreender um contexto nunca antes introduzido, por isso, sabe-se que a inteligência artificial não possui inteligência verdadeira e apenas realiza processos repetitivos que foram exercitadas muitas vezes no passado a fim de obter um desempenho extremamente rápido.

Em linhas gerais, a busca pela inteligência artificial geral significa tentar emular capacidades da mente humana nas diversas esferas da experiência, produzir comportamento autônomo, independente e proativo e aprender sobre este comportamento de forma criativa. (Silva, 2019)

Algumas das áreas de aplicação da IA incluem: assistência virtual, reconhecimento de imagens e vídeos, análise de dados, automação e robótica. Segundo Mendonça et al.

(2023), a IA será cada vez mais utilizada para automatizar tarefas rotineiras e repetitivas em diversos setores, como saúde, finanças e varejo. Na colocação de Russel (2010), a Inteligência Artificial é a área da ciência da computação que desenvolve sistemas e algoritmos capazes de simular aspectos da inteligência humana, como aprendizado, raciocínio, percepção e interação. Dentre vários conceitos e definições, o que melhor caracteriza o cerne deste trabalho é de que o domínio da IA é caracterizado por uma coleção de modelos, técnicas e tecnologias (dentre elas a busca, representação de conhecimento, decisão, planejamento, processamento de linguagem natural) que resolvem problemas de tal natureza (Simão, 2021).

No âmbito da saúde, a Inteligência Artificial é vista, corriqueiramente, através de assistentes virtuais para telemedicina, verificação de pressão arterial e queda através de relógios inteligentes, simulação de casos reais para estudantes de área e identificação de processos anormais em exames de imagem (Lanzagorta-Ortega et al., 2022). Além disso, a IA tem sido fundamental no combate a epidemias e pandemias, como demonstrado na COVID-19, utilizando-a para modelar a disseminação do vírus, prever picos de casos e auxiliar na aceleração do desenvolvimento de vacinas (Rossi et al., 2023).

A necessidade da área por avanços significativos em diagnóstico, tratamento e gestão de recursos foi ampliada pela necessidade de processamento de dados massivo, tal problema pode ser assentado com a utilização da IA. Através disso, sua capacidade de processar grandes volumes de dados e identificar padrões complexos permite que profissionais da saúde tomem decisões mais rápidas e precisas (Oliveira, 2024). Entretanto, a avaliação visual e a experiência do profissional são essenciais para sintomas e diagnósticos não pautados, necessariamente, em exames, ou seja, “uma inteligência artificial que toma decisões baseada apenas em alterações de padrões de dados será limitada a doenças que já não necessitam tanto de ‘inteligência humana’” (Junior et al., 2024).

## 2.2 APRENDIZADO DE MÁQUINA

Comumente conhecido como *Machine Learning*, área que deriva da IA, o aprendizado de máquina consiste no estudo que se preocupa em como construir soluções computacionais que automaticamente se aperfeiçoam com suas experiências (Mitchell, 1997).

A IBM (2024) descreve que, por meio do uso de métodos estatísticos, os algoritmos são treinados para fazer classificações ou previsões, revelando os principais *insights* em projetos de mineração de dados.

Neste contexto, descreve-se dois tipos mais comuns de aprendizado: o supervisionado e o não supervisionado, que possuem características distintas e, por isso, diferentes aplicações (Paixão et al., 2022). No treinamento supervisionado, o algoritmo é alimentado pelo usuário e treinado com um conjunto de dados rotulados, onde cada exemplo inclui a entrada e a saída esperada, por meio de repetições checadas até que atinja o mínimo de erros possíveis (Fontana, 2020). De acordo com Paixão et al. (2022), o objetivo é que o modelo aprenda a mapear as entradas para as saídas com base nesses exemplos e depois use esse conhecimento para fazer previsões em novos dados. No presente trabalho, o aprendizado supervisionado envolve, em suma, a divisão dos textos em treino e teste, o pré-processamento a fim de mitigar erros de escrita, espaços em branco e afins, a anotação dos textos a serem usados no treino e supervisão dos resultados, de forma iterativa, visando a melhoria do aprendizado.

Sendo assim, pode-se inferir que:

Tudo isso significa que é possível produzir, rápida e automaticamente, modelos capazes de analisar dados maiores e mais complexos, e entregar resultados mais rápidos e precisos – mesmo em grande escala. E ao construir modelos precisos, uma organização tem mais chances de identificar oportunidades lucrativas – ou de evitar riscos desconhecidos. (Sas, 2023)

Tendo isso em vista, o *Machine Learning* está em potencial crescimento e, no contexto da área médica, Sas (2023) ainda diz que essa tecnologia também pode ajudar especialistas médicos a analisar dados para identificar tendências ou alertas, levando ao aperfeiçoamento de diagnósticos e tratamentos.

## 2.3 PROCESSAMENTO DE LINGUAGEM NATURAL

O Processamento de Linguagem Natural ou NLP, do inglês, "*Natural Language Processing*", é uma ramificação da IA que consegue unir a Linguística Computacional

(modelagem baseada nas regras linguísticas humanas), bem como os modelos estatísticos de *Machine Learning* e *Deep Learning* (Cronapp, 2023). Lauriola et al. (2022) propõe que o processamento de linguagem natural é tido como ramo da inteligência artificial que lida com a linguagem humana. E complementa, ainda, que (tradução nossa)<sup>1</sup> a NLP envolve o design e implementação de modelos, sistemas e algoritmos para resolver problemas práticos no entendimento da linguagem humana. Falcão (2022) pontua que as tecnologias de NLP capacitam os sistemas computacionais a realizar de forma automatizada a extração de informações e conhecimentos a partir de dados não estruturados da linguagem humana.

## 2.4 RECONHECIMENTO DE ENTIDADES NOMEADAS

De acordo com Milidiú et al. (2007), o Reconhecimento de Entidades Nomeadas (do inglês, NER) é a tarefa de encontrar nomes próprios em um dado texto e classificá-los entre várias categorias de interesse ou em uma categoria padrão chamada Outros. O conceito de entidades, descrito por Elint (2021), consiste em qualquer palavra ou série de palavras que se referem ao mesmo tema. Cada entidade detectada é classificada em uma categoria predeterminada.

O reconhecimento de entidades nomeadas é uma técnica amplamente utilizada em Processamento da Linguagem Natural e consiste na identificação de nomes de entidades chave, presentes na forma livre de dados textuais. Nesse sentido, a entrada para um sistema de extração de entidades nomeadas é um texto em sua forma livre, e sua saída é um conjunto de textos anotados. (Fonseca et al., 2015)

O NER funciona de forma relativamente simples, iniciando pela *tokenization*, que é o ato de quebrar o texto em pequenas partes (BotPenguin, 2023). Após isso, é feito o *part-of-speech tagging* (POS) (UniversalDependencies, 2024), onde para cada um dos *tokens* separados são atribuídas etiquetas chamadas de tag POS, o que provê maior contexto para o algoritmo de NER (BotPenguin, 2023). E então, baseado nas tags POS, o algoritmo classifica e atribui as etiquetas de entidade no texto, como Pessoa, Localização, Organização e etc.

<sup>1</sup> NLP involves the design and implementation of models, systems, and algorithms to solve practical problems in understanding human languages.

A partir disso, pode-se levar em consideração a sentença a seguir:

*Maria tem 22 anos e estuda no Instituto Federal do Espírito Santo.*

Ao efetuar a extração de entidades nomeadas neste trecho, temos **Maria**, **22 anos** e **Instituto Federal do Espírito Santo** como entidades classificadas em categorias como "Pessoa", "Idade" e "Organização", respectivamente.

## 2.5 RELATOS DE CASO

Os relatos de casos são uma forma de compartilhar informações cruciais para a prática médica. Além disso, eles desempenham um papel significativo como recursos educacionais valiosos tanto para os autores quanto para os leitores (Carleton *et al.*, 2012). Há uma rica fonte de informações contidas nesses relatos, que fornecem esclarecimentos fundamentais sobre o estado de saúde de indivíduos e sobre como foram realizados os procedimentos. De acordo com Guimarães (2015), os relatos de caso podem originar outros estudos, ou seja, eles podem servir para criar uma hipótese que é posta à prova usando pesquisas sistematizadas.

Segundo Patino *et al.* (2019), este tipo de texto contribui para o aumento do conhecimento existente sobre importantes tópicos clínicos e para fornecer percepções sobre doenças novas ou raras e tratamentos não convencionais, podendo posteriormente ser avaliadas de modo mais formal utilizando desenhos de estudo mais sofisticados, como ensaios controlados randomizados. Um trecho de um relato de caso clínico é apresentado a seguir, retirado do trabalho de Rente *et al.* (2020):

*"Em 14 de março de 2020, o paciente retornou ao pronto atendimento referindo tosse seca, sensação de dispneia e febre (39 graus – aferido em madrugada prévia). Negou congestão ou rinorreia. Foi realizada radiografia de tórax e a prescrição médica foi amoxicilina + clavulanato 875/125mg, de 12 em 12 horas. O paciente foi liberado posteriormente."*

### 3 TRABALHOS CORRELATOS

Esta seção, apresenta os trabalhos correlatos ao cerne desta pesquisa.

O trabalho de Colombo e Oliveira (2022) apresentou um artefato de software capaz de extrair informações sobre medicamentos e doenças das bulas farmacêuticas com um modelo de IA construído à partir de uma abordagem híbrida baseada em *Conditional Random Fields* (CRF) e *Local Grammar* (LG), denominada CRF+LG. Os resultados mostraram a medida F1 de 82.08% para a categoria ABS (doenças), 94.26% para a categoria PER (pessoas) e 59.14% para a categoria TNG (medicamentos). Os autores ressaltam ainda que os resultados obtidos derivam de um modelo gerado à partir da anotação humana de 5 bulas farmacêuticas e 10 relatos de casos clínicos. Isso demonstra o potencial do modelo híbrido CRF+LG de classificar entidades das bulas, mesmo com conjuntos menores de documentos na fase de treino.

Em outro trabalho, Colombo et al. (2023), apresenta melhores resultados da extração de informações em bulas farmacêuticas, utilizando também o modelo híbrido CRF+LG. Neste novo cenário, foram realizados 5 experimentos. O treinamento dos experimentos 1 e 2 foi realizado com 5 bulas, e os experimentos 3 e 4 utilizaram 10 bulas. Já o experimento 5 incluiu 15 documentos que serviram para verificar o impacto no desempenho do modelo durante a fase de testes. Nos experimentos 2, 4 e 5 foram utilizados 10 casos clínicos obtidos da SciELO, visando enriquecer o treinamento. Conforme o artigo, os resultados do experimento 2 demonstraram que a inclusão de 10 casos clínicos na fase de treinamento contribuiu para a melhoria da medida F1 das entidades classificadas nas categorias ABS (doenças e seus sintomas) e TNG (medicamentos), em comparação com os resultados do experimento 1. Esse cenário indica que a diversificação dos dados de treinamento, incluindo casos clínicos reais, teve impacto positivo no desempenho do modelo. Na categoria ABS, o resultado inicial foi de 68,4%, alcançando 82,08%. Já na categoria TNG, o resultado foi de 58,99%, chegando a 59,14%. De acordo com os experimentos 3 e 4, que foram treinados com 5 documentos a mais do que os experimentos 1 e 2, foi observado uma melhora considerável nos resultados em relação aos anteriores. O melhor resultado

para a categoria ABS foi 94,85% (conforme experimento 4), sendo superior ao 82,08% (experimento 2). O mesmo cenário aconteceu com a categoria TNG, onde o melhor resultado foi 66,16% (experimento 4), em comparação com 59,14% (experimento 2).

O estudo de Schneider et al. (2023), apresentou etiquetadores desenvolvidos para textos brasileiros, refinados a partir de modelos BioBERTpt (clínico/biomédico) e BER-Timbau (genérico) em um corpus com anotações morfossintáticas. De acordo com os autores, obtiveram 98% de acurácia, estado-da-arte para o corpus utilizado. Também foi realizada uma avaliação, por profissionais da área da saúde, dos modelos treinados e outros da literatura, utilizando narrativas clínicas autênticas. O modelo clínico atingiu 81% de acurácia comparado com 76% do modelo genérico. O experimento do estudo mostrou que, mesmo usando um corpus jornalístico para treinamento, o conhecimento específico da área codificado no BioBERTpt pode beneficiar tarefas clínicas, apresentando resultados promissores.

Um estudo de destaque na área de NLP aplicada ao domínio biomédico foi o de Oliveira et al. (2022), que apresentou o SemClinBr, o primeiro corpus anotado e desenvolvido para auxiliar tarefas de NLP em Língua Portuguesa clínica. Este corpus reúne 1000 documentos clínicos extraídos de múltiplas especialidades médicas e instituições, abrangendo mais de 65 mil entidades e 11 mil relações anotadas. Além disso, o estudo gerou dicionários de negações e abreviações médicas alcançando altos níveis de acordo interanotadores, variando de 71% (considerando uma correspondência estrita) a 92% (com correspondência mais relaxada). Assim sendo, sua eficácia foi demonstrada em avaliações intrínsecas e extrínsecas, especialmente em tarefas como reconhecimento de entidades nomeadas e detecção de negações. O trabalho não menciona explicitamente o tipo de algoritmo NLP utilizado, porém, destaca que o corpus SemClinBr foi projetado para suportar o desenvolvimento e a avaliação de algoritmos de NLP voltados para tarefas específicas. Tais tarefas geralmente envolvem o uso de algoritmos baseados em aprendizado supervisionado, como modelos de classificação ou sequenciamento de texto, incluindo abordagens mais modernas, como redes neurais recorrentes (RNNs) ou modelos baseados em *Transformers* (como, por exemplo, o BERT), sendo adaptados para o Português do Brasil. Ademais, o corpus também suporta tarefas de busca semântica e sumarização. Em suma, este trabalho se destaca



como um marco essencial para o avanço de algoritmos de NLP para a área da saúde, promovendo a extração de informações de prontuários eletrônicos e contribuindo para a prática clínica e a pesquisa biomédica.

## 4 MATERIAIS E MÉTODOS

Nesta seção são descritos os métodos para o desenvolvimento de um novo modelo de extração de informações em relatos clínicos usando Python.

### 4.1 SPACY E MEDSPACY

De acordo com a documentação oficial, a spaCy é uma biblioteca de processamento de linguagem natural avançada e de código aberto desenvolvida em Python (Explosion, 2024). Seu principal propósito é fornecer uma ferramenta robusta para o processamento eficiente de grandes volumes de texto, podendo ser utilizado para construir sistemas de extração de informações ou de compreensão de linguagem natural.

A spaCy oferece modelos pré-treinados para diferentes idiomas, permitindo aos usuários realizar tarefas de NLP com facilidade em várias línguas (Explosion, 2024). Sua capacidade de processar texto de forma rápida e precisa, a torna uma ferramenta essencial para aplicações como análise de sentimentos, extração de informações e construção de sistemas de conversação inteligentes. Sua flexibilidade também permite que seja utilizado para o pré-processamento de texto, sendo uma etapa crucial na preparação de dados para treinamento de modelos de aprendizado profundo.

Vários dos componentes de treinamento da biblioteca são alimentados por modelos estatísticos, ou seja, spaCy usa modelos baseados em algoritmos de aprendizado de máquina supervisionado para tomar decisões com base em padrões extraídos de grandes quantidades de dados anotados. Cada uma das decisões que os componentes tomam — como por exemplo, qual *tag* de classe gramatical atribuir ou se uma palavra é uma entidade nomeada — são uma previsão que tomam por base os valores de peso atuais do modelo. Esses valores de peso são calculados levando em conta os exemplos que o modelo viu durante o treinamento, sendo assim, para treinar um modelo, precisa-se de dados de treinamentos robustos que se deseja que a IA reconheça no futuro, podendo ser uma etiqueta de classe gramatical, entidade nomeada ou outra informação.

O treinamento em si é um processo iterativo, onde as previsões do modelo são geralmente comparadas às anotações de referência (feitas manualmente), para estimar o gradiente da perda. Neste caso, o gradiente da perda é usado para o cálculo do gradiente dos pesos por meio de *backpropagation* (ou retropropagação) — algoritmo usado para treinar redes neurais artificiais, ajustando os pesos das conexões entre os neurônios de uma rede com base no erro cometido ao realizar previsões. Os gradientes são utilizados para indicar como os valores de peso devem ser alterados para que as previsões se tornem o mais semelhante possível às das etiquetas de referência (Explosion, 2024). A Figura 1 mostra o ciclo de treinamento do modelo pela spaCy, onde entram os dados de treino, divide-se em dados de texto e as etiquetas (*labels*), os gradientes são definidos e então, o modelo é salvo e atualizado.




Figura 1 – Ciclo de treinamento spaCy.

Fonte: Explosion, 2024

Como extensão da biblioteca spaCy, uma das principais ferramentas de NLP, surge a medSpaCy, tendo sido desenvolvida especialmente para tarefas e aplicações na área da saúde. O objetivo fundamental é conseguir moldar o poder da spaCy para a análise e compreensão de textos clínicos, englobando termos médicos específicos, frases ambíguas e abreviações. Diante de suas muitas funcionalidades, destacam-se o reconhecimento de entidades clínicas — como diagnósticos, medicamentos e procedimentos — e capacidade de realizar compreensão contextual de sentenças, como incerteza ou negação. Com isso, a spaCy utilizada em conjunto com a medSpaCy promete possibilitar a automatização de processos na área da saúde e oferecer suporte à tomada de decisões clínicas com base em dados.

## 4.2 O DATASET SEMCLINBR

Os relatos de casos clínicos utilizados foram retirados de um dataset denominado **SemClinBr** (Oliveira *et al.*, 2022)<sup>1</sup>, que possui um conteúdo adequado para a realização do treinamento e testes. No que tange a criação do corpus de Oliveira *et al.* (2022), os dados foram obtidos de duas fontes diferentes, sendo: um corpus de 2.094.929 entradas de um grupo de hospitais no Brasil gerado entre 2013 e 2018, e um corpus originado de um hospital universitário com entradas no período entre 2002 e 2007, totalizando 5.617 entradas. No primeiro conjunto de dados, cada entrada era associada a dados estruturados (como gênero, especialidade médica, data de entrada) e dados não estruturados em formato de texto livre, representando uma narrativa clínica (como histórico da doença, histórico familiar e queixa principal). Tais dados foram obtidos de registros de aproximadamente 553.952 pacientes. Já o segundo conjunto de dados consistiu em um único tipo de documento (resumos de alta), proveniente exclusivamente do Centro de Serviço de Cardiologia. Um exemplo de um dos documentos provenientes do *dataset* é mostrado na Figura 2.

```
<?xml version='1.0' encoding='UTF-8'?>
<ANNOTATIONS>
<TEXT>Em 05/10/2006, 14 HORAS: PERMANECE SEDADO, COM PUPILAS ISOMIÓTICAS E FOTORREAGENTES, COM DISCRETO EDEMA
PERIPALPEBRAL BILATERAL. VM VIA TRAQUEO COM F02 50%, PCV, PI 23 cmH20, PEEP 10cm H20, F 14 mrpm, SPO2 99%.
AUSCULTA PULMONAR COM RONCOS DIFUSOS E DISCRETAMEN. TRAUMATISMO DO BACO. Em 26/07/2007, 08:36h: Acordada,
alerta, responsiva, mucosas coradas e hidratadas. Apresenta abdome plano, flácido, RHA +, indolor à palpação.
Mantém SNE para alimentação por bomba infusora, em jejum no momento para procedimento cirúrgico
(gastrostomia). Diureses.</TEXT>
<TAGS>
<annotation id="9368" tag="Finding|Therapeutic or Preventive Procedure" start="35" end="41" text="SEDADO"
abbr="" />
<annotation id="9369" tag="Body Part, Organ, or Organ Component" start="47" end="54" text="PUPILAS" abbr="" />
<annotation id="9370" tag="Finding" start="55" end="66" text="ISOMIÓTICAS" abbr="" />
<annotation id="9371" tag="Finding" start="69" end="83" text="FOTORREAGENTES" abbr="" />
<annotation id="9372" tag="Abbreviation|Therapeutic or Preventive Procedure" start="148" end="151" text="F02"
abbr="" />
<annotation id="9373" tag="Quantitative Concept" start="152" end="155" text="50%" abbr="" />
```

Figura 2 – Exemplo de documento extraído da base de dados do SemClinBr.

Fonte: Elaborado pela autora

## 4.3 PREPARAÇÃO DO AMBIENTE

No que tange a montagem e configuração do ambiente de desenvolvimento, primeiro foi criado um ambiente virtual (venv) para a instalação das dependências das bibliotecas e suas extensões auxiliares. Inicialmente, criou-se um ambiente virtual para isolar as

<sup>1</sup> Repositório do Github: Github SemClinBr

dependências do projeto, utilizando o comando "python -m venv venv" e ativando-o com "venv\Scripts\activate". Em seguida, as dependências essenciais foram instaladas, incluindo spaCy e os modelos de linguagem "en-core-web-sm"<sup>2</sup> e "pt-core-news-sm"<sup>3</sup>, necessário para o processamento de textos em inglês e português, por meio do comando "pip install -U spacy" seguido de "python -m spacy download en-core-web-sm pt-core-news-sm", respectivamente. Em seguida, para verificar a instalação, utilizou-se o comando "python -m spacy info". Um teste básico foi realizado criando um script simples que carregava o modelo de linguagem e processava uma frase de exemplo, identificando as entidades nomeadas. Por fim, foram executados procedimentos para resolver potenciais erros relacionados ao ambiente, como a execução explícita do interpretador do ambiente virtual para garantir compatibilidade com dependências instaladas localmente.

O editor de código utilizado foi o *Visual Studio Code*<sup>4</sup>, no sistema operacional *Windows* 11 x64, (configurações de máquina: processador AMD Ryzen 7 4800H Radeon Graphics 2.90 GHz, 8GB de RAM, placa de vídeo NVIDIA GeForce GTX 1650) executando comandos a partir do *prompt* de comando e *PowerShell*. Para armazenamento remoto e controle de versão dos códigos e dados utilizados, foi usado o Git e um repositório na plataforma Github.

No que tange a proporção utilizada para treinamento do novo modelo e testes de precisão, este trabalho utilizou um corpus contendo 481 relatos de casos clínicos, no qual a divisão foi de aproximadamente 70% e 30% para treino e testes, respectivamente, totalizando 337 casos para treinamento e 134 para testes.

#### 4.4 MÉTRICAS UTILIZADAS PARA AVALIAR OS MODELOS

Nesta seção são apresentadas as métricas utilizadas para avaliar o desempenho dos modelos treinados. Estas métricas são *Precision*, *Recall* e *F1 Score*, sendo as mesmas usadas no trabalho de Torres *et al.* (2024), apresentado na seção 5.3 deste trabalho.

<sup>2</sup> O modelo "en-core-web-sm" corresponde ao modelo nativo em Inglês e de tamanho pequeno, onde "sm" corresponde a *small*, "md" corresponde a *medium* e "lg" a *large*.

<sup>3</sup> O modelo "pt-core-news-sm" corresponde ao modelo nativo em Português e de tamanho pequeno.

<sup>4</sup> Link para *download*: Visual Studio Code

*Precision* é calculada dividindo o número de previsões corretas pelo número total de previsões que o modelo foi capaz de fazer, ou seja, a razão entre o número de verdadeiros positivos e o número total de previsões positivas, a Fórmula 1 mostra o cálculo.

$$\text{Precisão} = \frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{Falsos positivos}} \quad (1)$$

Já o *recall*, também conhecido como taxa de detecção, consiste em calcular quantos dos exemplos o modelo conseguiu identificar de todos os exemplos possíveis que ele poderia ter identificado. O cálculo da métrica se dá pela fórmula mostrada na Fórmula 2.

$$\text{Recall} = \frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{Falsos negativos}} \quad (2)$$

E ainda, é importante pontuar que o cálculo do *F1 Score* é medido por meio da relevância das medidas *precision* e *recall*, portanto, baseia-se em saber se essas medidas foram igualmente importantes para o problema apresentado. O F1 Score é a média harmônica entre *precision* e *recall* e pode ser calculado a partir da Fórmula 3.

$$F1 - \text{Score} = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (3)$$

## 5 EXPERIMENTOS E RESULTADOS

Nesta seção são descritos os experimentos utilizados ao longo dessa pesquisa, bem como os resultados obtidos com o desenvolvimento de um novo modelo de extração de informações.

### 5.1 EXPERIMENTO REALIZADO COM SPACY

Nessa pesquisa, ao efetuar testes inserindo a base de dados dos relatos de caso nos modelos pré-treinados nativamente pela spaCy, não foram obtidos resultados relevantes. Ou seja, o modelo não conseguiu reconhecer entidades voltadas para a área da saúde, como mostra a Figura 3, onde as caixas coloridas representam as entidades reconhecidas, seguidas pela tag POS, ou sigla da categoria a qual foram classificadas. Para a visualização gráfica dos resultados de classificação de cada etiqueta, foi utilizada outra biblioteca, a displaCy, que permitiu diferenciar as etiquetas com um padrão de cores. Ao executar o código, displaCy cria um arquivo HTML com as entidades reconhecidas.

A Sra. Joana Paciente tem problemas cardíacos e se encontra sob terapia com digitoxina. Na prescrição médica constavam ainda comprimidos antiácidos de hidróxidos metálicos. Sofrendo de vez em quando de desconforto intestinal (diarréia), solicitou ao farmacêutico se poderia tomar carvão ativado.

INTERAÇÃO DIGITOXINA **MISC** COM HIDRÓXIDOS **MISC** METÁLICOS?

Hidróxidos de magnésio e alumínio ligam-se , in vitro , com a digitoxina. Deste fato poder-se-ia concluir que a velocidade de cedência e a intensidade de ação do glicosídeo cardiotônico devam estar reduzidas. A substituição deste fármaco por digoxina não representa uma alternativa válida por dois motivos: Já foi descrita a mesma interação para digoxina. Foi especialmente indicada para Sra. Paciente **PER** a digitoxina, já que ela apresenta deficiência renal. Este fármaco, por possuir uma eliminação diária mais reduzida, não necessita de uma adaptação de dose, o que seria o caso na administração da digoxina. Ensaio clínico demonstrou que o hidróxido de alumínio não produziu redução da velocidade de absorção de digitoxina. Este resultado encontra-se em contradição com os testes in vitro. A relevância clínica conclusiva não pode ser ainda determinada, pois o número de pesquisas sobre o tema é ainda muito reduzido. Já para a digoxina esta interação está seguramente comprovada.

RECOMENDAÇÃO **ORG**

Figura 3 – Relato de caso pós processamento com modelo nativo spaCy

Fonte: Elaborado pela autora

Esse comportamento se dá devido ao fato de que os modelos pré-treinados não contêm textos específicos da área de saúde. O modelo nativo foi capaz de reconhecer apenas

as siglas de categoria MISC, PER e ORG, que significam *Miscellaneous* (categorizando tudo que não se encaixa em outras categorias), *Person* (categorizando pessoas e nomes) e *Organization* (categorizando organizações e instituições), respectivamente.

## 5.2 EXPERIMENTO REALIZADO COM MEDSPACY

A partir dessas observações e resultados, a biblioteca em Python antes mencionada, MedspaCy, baseada na biblioteca spaCy, foi utilizada para testes com a mesma base de dados. MedspaCy foi desenvolvida com a finalidade de conseguir reconhecer textos médicos e biomédicos, porém, ao executar os testes com os relatos de caso em Português, não apresentou resultados, mostrando-se apenas eficiente para textos da área da saúde redigidos em Inglês.

Com essas inferências, fez-se necessário o treinamento de um novo modelo, neste trabalho chamado de *pipeline*, para a compreensão dos relatos de caso clínicos em Língua Portuguesa, tomando como base a spaCy.

## 5.3 O MODELO SPACY TREINADO COM RELATOS CLÍNICOS

Diante deste cenário, efetuou-se o desenvolvimento de um modelo que fosse capaz de reconhecer as entidades da área da saúde. Para isso, foram definidas 7 categorias para a classificação das entidades, sendo elas: "Procedimento", "Doença", "Medicamento", "Sintoma", "Especialidade", "Reação" e "Diagnóstico", escritas em maiúsculo e sem nenhum acento ou caractere especial. Tais etiquetas foram pensadas levando em consideração o conteúdo dos casos clínicos utilizados nos experimentos anteriores, sendo suficientes para catalogar as informações que eram coerentes para o cenário.

A anotação dos relatos de casos foi realizada por uma equipe de 3 pessoas, sendo uma delas com conhecimentos na área da saúde. As anotações utilizaram os conceitos descritos no Código Internacional de Doenças (CID-10) e também no Dicionário de Especialidades Farmacêuticas (DEF).

Foram utilizados 10 arquivos no formato .txt, onde 6 deles eram devidamente anotados na formatação suportada pela spaCy, para a realização do treinamento, e 4 arquivos não anotados para os testes posteriores. O padrão de anotação suportado pela



biblioteca seguiu uma estrutura semelhante ao de um dicionário em Python, onde eram descritas as etiquetas dentro de um objeto “*entities*” e, para cada etiqueta identificada no texto, foi atribuída o número do caractere inicial onde ela se encontrava e o número do caractere final. Este trabalho de anotação foi todo feito manualmente pelos autores, arquivo por arquivo. A Figura 4 mostra o exemplo de um trecho anotado.

```
("O exame físico evidenciava paciente pálida, em bom estado nutricional. Estava lúcida e orientada; pressão arterial (PA) - 180 X110mmHg; frequência respiratória - 24inc/min e frequência cardíaca -107bpm.", {"entities": [(2, 13, "PROCEDIMENTO"), (27, 42, "SINTOMA"), (78, 84, "SINTOMA"), (87, 96, "SINTOMA"), (98, 134, "SINTOMA"), (136, 171, "SINTOMA"), (174, 201, "SINTOMA")]})
```

Figura 4 – Trecho de padrão de anotação em um relato de caso

Fonte: Elaborado pela autora

Os testes foram executados utilizando os 10 relatos de casos clínicos, incluindo os que foram anotados anteriormente e usados para o treinamento do *pipeline*, o que contribuiu para a realização da comparação de desempenho entre os dados anotados e não anotados. Para verificar a qualidade do modelo criado, foram realizados 2 experimentos: o primeiro testou o modelo criado no conjunto de documentos utilizado em seu treinamento; e o segundo experimento testou o modelo num conjunto de relatos de casos não utilizado em seu treinamento. A Figura 5 apresenta o ciclo de desenvolvimento necessário para a realização deste trabalho.




Figura 5 – Ciclo de desenvolvimento

Fonte: Elaborado pela autora

Os resultados do primeiro experimento demonstraram que o modelo foi capaz de reconhecer com exatidão todas as entidades presentes nos textos do treino. Demonstrando que o processo de anotação dos documentos para criar uma base de treino e o treinamento do modelo a partir desta base gerou um modelo capaz de reconhecer entidades da área de saúde nos relatos de casos clínicos. Caso o modelo não reconhecesse as entidades presentes nestes documentos, o processo seria revisado e refeito.

Os resultados do segundo experimento apontam que o modelo foi capaz de reconhecer um padrão entre algumas entidades. Ele identificou mais de 60% das entidades de maneira correta em todos os documentos de teste. Para o cálculo dos resultados, foram considerados o número de entidades reconhecidas pelo modelo em cada arquivo HTML processado e, dentre essas entidades reconhecidas, quais delas estavam realmente corretas, de acordo com os critérios de anotação.

| <b>Entidades</b> | <b>Precisão</b> | <b>Recall</b> | <b>F1-Score</b> |
|------------------|-----------------|---------------|-----------------|
| Doença           | 0.00            | 0.00          | 0.00            |
| Diagnóstico      | 0.00            | 0.00          | 0.00            |
| Especialidade    | 0.00            | 0.00          | 0.00            |
| Medicamento      | <b>0.80</b>     | <b>1.00</b>   | <b>0.89</b>     |
| Procedimento     | 0.00            | 0.00          | 0.00            |
| Reação           | <b>0.43</b>     | <b>1.00</b>   | <b>0.60</b>     |
| Sintoma          | <b>0.40</b>     | <b>1.00</b>   | <b>0.57</b>     |

Tabela 1 – Resultados das métricas retiradas do artigo comparativo

Fonte: Torres et al., 2024

A Tabela 1 mostra os resultados das métricas de Precisão, *Recall* e *F1-Score* do segundo experimento, que evidencia a melhoria do modelo atual em relação ao modelo nativo da spaCy. Além das evoluções no que tange o conteúdo e quantidade da base de dados, as categorias também foram expandidas, como será descrito mais adiante, para contribuir da melhor forma possível ao conteúdo e enriquecimento do modelo.

É possível perceber que o modelo não reconheceu nenhuma entidade das categorias "Doença", "Diagnostico", "Especialidade" e "Procedimento". Isto demonstra que há necessidade de melhorar a qualidade do treino para que o modelo seja capaz de reconhecer entidades destas categorias. Por outro lado, percebe-se que o modelo reconheceu entidades das categorias "Medicamento", "Reacao" e "Sintoma". Ou seja,

mesmo com uma quantidade pequena de documentos no treino o modelo obteve taxa de assertividade razoável para entidades das categorias Reacao (60%) e Sintoma (57%) em medida F1. Isso pode ser justificado pela característica dos textos utilizados no treinamento. A taxa de acerto para as entidades da categoria Medicamento (89%) em medida F1 foi superior, indicando o potencial do modelo.

Uma das contribuições deste Trabalho de Conclusão de Curso (TCC) para a comunidade científica foi a publicação de um artigo (Torres *et al.*, 2024), que relata todo o processo descrito nesta subseção. Este artigo foi aceito e apresentado no **XX Congresso Brasileiro de Informática em Saúde (CBIS'24)**, evento realizado em Belo Horizonte (MG), entre os dias 8 e 11 de outubro de 2024. Posteriormente, o mesmo artigo (Torres *et al.*, 2024) foi publicado numa edição suplementar do ***Journal of Health Informatics*** (JHI), cujo Qualis é A4, em 21 de novembro de 2024. Esta conquista veio coroar a qualidade do trabalho realizado visando a construção deste TCC, bem como demonstrar o potencial das alunas e alunos do Bacharelado em Sistemas de Informação do IFES Campus Cachoeiro de Itapemirim.

#### 5.4 O MODELO SPACY TREINADO COM AMOSTRAS DO DATASET SEMCLINBR

Após a compreensão da necessidade da criação de um novo modelo, foi analisada a possibilidade de repetir o processo de criação de um modelo spaCy a partir de um *dataset* com um número maior de amostras. O primeiro desafio envolveu a obtenção dos dados para serem usados na fase de treino e de teste. Para isso, os relatos foram extraídos do dataset **SemClinBr** (Oliveira et al., 2022), apresentado na seção 4.2. Mediante sua obtenção, também foi preciso o tratamento de alguns dos arquivos, que incluiu a remoção de espaços em branco, caracteres especiais e excesso de parágrafos que poderiam gerar conflito com o padrão aceito pela spaCy. O tratamento dos dados foi feito manualmente e também com auxílio de funções em Python para a varredura automática e detecção de inconsistências ao longo dos arquivos. Após essa varredura, algumas classificações feitas manualmente nos arquivos precisaram ser ignoradas durante o treinamento pois saíam do padrão esperado para o modelo.

Alguns dos dados obtidos para treinamento foram retirados de arquivos do tipo XML, sendo necessário fazer um processo de extração para retirar o texto puro e converter

para arquivos do tipo TXT, aceitos pela biblioteca utilizada para treino. A biblioteca de NLP, spaCy, requer um padrão de anotação muito específico, também feito como parte do pré-processamento dos dados, para a compreensão e treinamento. Sendo assim, para cada relato de caso clínico usado, deve ser seguido o padrão de anotação, onde indicam-se quais termos dentro do texto se encaixam em alguma categoria definida previamente. O padrão de anotação suportado pela biblioteca segue uma estrutura semelhante ao de um dicionário em Python, apresentado no formato JSON, onde são descritas as entidades (categorias) dentro de um objeto “*entities*” e, para cada entidade identificada no texto, é atribuído o número do caractere inicial e o número do caractere final, que correspondem à sua posição dentro do texto.

Foram definidas 18 etiquetas (categorias) para a classificação das entidades para serem usadas de base para as anotações, sendo elas: "Sintoma|Sinal", "Doença|Síndrome", "Parte do Corpo|Órgão", "Procedimento", "Dispositivo Médico", "Célula|Disfunção Molecular", "Procedimento Diagnóstico", "Função Fisiológica", "Conclusão", "Antibiótico", "Localização no Corpo ou Região", "Resultado de Laboratório ou Teste", "Membro Familiar", "Ação de Cuidado", "Fármaco|Hormônio|Proteína", "Lesão", "Envenenamento", e "Bactéria". Todas as etiquetas foram escritas em maiúsculo e sem nenhum acento ou caractere especial para o treinamento do modelo. Tais etiquetas foram pensadas levando em consideração o conteúdo dos casos clínicos utilizados nos experimentos, sendo suficientes para catalogar as informações que eram coerentes para o cenário.

Foram realizados dois experimentos, que incluíram: testes com os arquivos do grupo usado para treinamento, para testar a eficácia em termos esperados pelo modelo; e testes com os arquivos não usados no treinamento, a fim de conferir a capacidade do modelo de reconhecer novas palavras e termos semelhantes. Com esta estratégia foi possível obter os resultados, que serão apresentados a seguir.

#### **5.4.1 Resultados dos Testes com Relatos Usados na Fase de Treino**

Os resultados obtidos com os dados treinados no modelo, conforme mostrado na Tabela 2, levando em consideração que foram usados mais arquivos para esse experimento, mostram evolução nas métricas do modelo. Nesse caso, as entidades apresentaram desempenho mais uniforme em comparação com os resultados dos testes não usados

em treinamento, com a maioria das entidades alcançando F1-Scores acima de 0.90. Isso indica que o modelo foi bem ajustado ao domínio clínico com entidades que ele já esperava reconhecer.

| Entidades                      | Precisão | Recall | F1-Score |
|--------------------------------|----------|--------|----------|
| PARTE DO CORPO ORGÃO           | 0.96     | 0.92   | 0.94     |
| CONCLUSÃO                      | 0.99     | 0.93   | 0.96     |
| SINTOMA SINAL                  | 0.98     | 0.97   | 0.97     |
| PROCEDIMENTO DIAGNÓSTICO       | 0.95     | 0.91   | 0.93     |
| LESÃO                          | 0.96     | 0.89   | 0.92     |
| LOCALIZAÇÃO NO CORPO OU REGIÃO | 0.97     | 0.96   | 0.96     |
| PROCEDIMENTO                   | 0.97     | 0.95   | 0.96     |
| DOENÇA SÍNDROME                | 0.94     | 0.99   | 0.96     |
| FUNÇÃO FISIOLÓGICA             | 1.00     | 0.50   | 0.67     |
| ACAO DE CUIDADO                | 0.96     | 0.94   | 0.95     |
| DISPOSITIVO MÉDICO             | 1.00     | 0.92   | 0.93     |
| ENVENENAMENTO                  | 1.00     | 0.87   | 0.93     |
| ANTIBIÓTICO                    | 1.00     | 0.50   | 0.67     |
| MEMBRO FAMILIAR                | 1.00     | 0.94   | 0.97     |
| RESULTADO LABORATÓRIO OU TESTE | 0.95     | 0.96   | 0.96     |
| FARMACO HORMÔNIO PROTEÍNA      | 1.00     | 1.00   | 1.00     |

Tabela 2 – Resultados do primeiro experimento

O maior destaque ficou com classes como "SINTOMA|SINAL" e "DISPOSITIVO MÉDICO", que obtiveram F1-Scores elevados (0.97 e 0.96, respectivamente), o que reflete a capacidade do modelo de identificar entidades altamente relevantes em textos clínicos. Observa-se, ainda, que mesmo em entidades menos frequentes nos conteúdos dos relatos, como "ENVENENAMENTO" e "MEMBRO FAMILIAR", os resultados foram robustos (F1-Scores de 0.93 e 0.97, respectivamente), o que demonstra que o modelo foi capaz de generalizar bem após o treinamento.

Por outro lado, é importante destacar um desempenho mais baixo nas categorias como "FUNÇÃO FISIOLÓGICA" e "ANTIBIÓTICO", que apresentaram a métrica F1-Score de 0.67. Esse resultado, mesmo maior do que no cenário com dados não treinados, pode indicar que essas entidades ainda carecem de maior representatividade nos dados de treinamento ou que essas apresentam maior variância nos relatos de caso clínicos.

Em conclusão, os resultados dos dados treinados evidenciaram a eficácia do trei-

namento supervisionado no ajuste do modelo ao domínio clínico, que resultou em melhorias significativas nas métricas. Esse avanço destaca o impacto positivo de dados de qualidade e do ajuste fino em contextos específicos para aplicações de NER.

A Figura 6 mostra, utilizando recursos gráficos para melhor compreensão, o exemplo de relato de caso clínico pós treinamento do novo modelo.

POI DE LAVAGEM + CURETA DE TECIDO NECRÓTICO. 18:00: PACIENTE RETORNOU DO CC LÚCIDO, **ORIENTADO CONCLUSÃO**, **COMUNICATIVO** **CONCLUSÃO**; MANTEM AVP COM STP. REFERE TER APRESENTADO 01 EPISÓDIO DE EMESE NO CC. CURATIVO COM ASPECTO LIMPO E **SECO** **CONCLUSÃO**. SEGUE EM **OBSERVAÇÃO AÇÃO DE CUIDADO**. OSTEOMIELITE NÃO ESPECIFICADA. INTUBADO, SOB **VENTILAÇÃO MECÂNICA** **PROCEDIMENTO**, **MONITORIZAÇÃO CARDÍACA** **PROCEDIMENTO DIAGNOSTICO** E **OXIMETRIA DE PULSO** **PROCEDIMENTO DIAGNOSTICO**, JUGULAR COM SOROTERAPIA EM CURSO, SNG ABERTA COM ESTASE BORRA DE CAFÉ. REALIZADO **MUDANÇA DE DECÚBITO** **PROCEDIMENTO**, ASPIRADO TOT COM GRANDE QUANTIDADE DE SECREÇÃO ESPESSA E PURULENTE, SVD L. **INFARTO CEREBRAL** **DOENÇA|SINDROME** DEVIDO A **TROMBOSE DE ARTÉRIAS PRÉ-CEREBRAIS** **DOENÇA|SINDROME**. 18:30: DESACORDADO, FAZ **ABERTURA OCULAR ESPONTÂNEA** **CONCLUSÃO**, **AGITADO** **SINTOMA|SINAL**. REALIZADO BANHO DE LEITO E **HIGIENE ORAL** **PROCEDIMENTO**, APÓS CONTIDO NO LEITO NOVAMENTE DEVIDO A AGITAÇÃO. COM HEMATOMA E **EDEMA DISCRETO** **SINTOMA|SINAL** EM REGIÃO OCULAR À D. MEIA TALA GESSADA EM MIE E REALIZADA NOVA PUNÇÃO V. **TRAUMATISMOS MÚLTIPLOS** **LESAO** NÃO ESPECIFICADOS. 13/10/2006, 15:40 HORAS: PERMANECE EM **COMA** **SINTOMA|SINAL**, COM PUPILAS MÉDIO-FIXAS, MANTENDO CATETER DE DVE. VM VIA **TOT** **DISPOSITIVO MEDICO** COM FIO2-50%, PCV, PP 25cmH20, PEEP 2cmH20, F15mrpm, SPO2 99%. **AUSCULTA PULMONAR** **PROCEDIMENTO DIAGNOSTICO** COM MV LIVRES. **HEMODINAMICAMENTE ESTÁVEL** **CONCLUSÃO**. CVP EM MSD COM **PLANO BÁSICO** **PROCEDIMENTO** D. OUTRAS **HEMORRAGIAS INTRACEREBRAIS** **DOENÇA|SINDROME**

Figura 6 – Resultado de relato de caso pós treinamento

Fonte: Elaborado pela autora

#### 5.4.2 Resultados dos Testes com Relatos não Usados na Fase de Treino

Os resultados apresentados na Tabela 3, utilizando os dados não usados em treinamento, refletem o desempenho inicial do modelo de NER aplicado à relatos de casos clínicos. A partir disso, observa-se que as métricas de Precisão, *Recall* e *F1-Score* tem variância significativa entre as entidades, tal comportamento é esperado, visto que o modelo não foi treinado especificamente para esse conjunto de dados e, portanto, depende exclusivamente de características similares ou genéricas.

Pode-se inferir que entidades como "CONCLUSÃO" e "PROCEDIMENTO DIAGNÓSTICO", apresentaram valores de F1-score relativamente altos (0.71 e 0.65, respectivamente), o que indica que o modelo conseguiu identificar essas categorias de maneira moderadamente eficaz, resultado obtido, provavelmente, devido à clareza e

uniformidade com que esses termos aparecem no conteúdo dos relatos clínicos. Em contrapartida, categorias como "ANTIBIÓTICO", "FUNÇÃO FISIOLÓGICA", e "RESULTADO LABORATÓRIO OU TESTE" apresentaram métricas zeradas, indicando que o modelo não foi capaz de reconhecer nenhuma instância dessas entidades, o que pode ser explicado pela falta de exemplos suficientes dessas classes no conjunto de dados ou pela ambiguidade nos textos. O que leva à conclusão de que a divisão entre dados de teste e treino pode ter impactado nos resultados.

| <b>Entidades</b>               | <b>Precisão</b> | <b>Recall</b> | <b>F1-Score</b> |
|--------------------------------|-----------------|---------------|-----------------|
| CONCLUSAO                      | <b>0.82</b>     | <b>0.63</b>   | <b>0.71</b>     |
| ACAO DE CUIDADO                | <b>0.53</b>     | <b>0.47</b>   | <b>0.50</b>     |
| PROCEDIMENTO                   | <b>0.54</b>     | <b>0.34</b>   | <b>0.42</b>     |
| PROCEDIMENTO DIAGNOSTICO       | <b>0.80</b>     | <b>0.55</b>   | <b>0.65</b>     |
| DOENÇA SINDROME                | <b>0.46</b>     | <b>0.50</b>   | <b>0.49</b>     |
| SINTOMA SINAL                  | <b>0.57</b>     | <b>0.53</b>   | <b>0.55</b>     |
| LESAO                          | <b>0.57</b>     | <b>0.35</b>   | <b>0.44</b>     |
| DISPOSITIVO MEDICO             | <b>0.47</b>     | <b>0.15</b>   | <b>0.22</b>     |
| CELULA DISFUNCAO MOLECULAR     | 0.00            | 0.00          | 0.00            |
| LOCALIZACAO NO CORPO OU REGIAO | <b>0.67</b>     | <b>0.49</b>   | <b>0.57</b>     |
| PARTE DO CORPO ORGAO           | <b>0.31</b>     | <b>0.27</b>   | <b>0.29</b>     |
| RESULTADO LABORATORIO OU TESTE | 0.00            | 0.00          | 0.00            |
| ANTIBIOTICO                    | 0.00            | 0.00          | 0.00            |
| MEMBRO FAMILIAR                | <b>0.83</b>     | <b>0.25</b>   | <b>0.38</b>     |
| FUNCAO FISIOLOGICA             | 0.00            | 0.00          | 0.00            |
| ENVENENAMENTO                  | 0.00            | 0.00          | 0.00            |
| FARMACO HORMONIO PROTEINA      | 0.00            | 0.00          | 0.00            |

Tabela 3 – Resultados do segundo experimento

No geral, os resultados sugerem que o modelo apresenta um desempenho limitado com dados não treinados, com dificuldades evidentes em reconhecer entidades menos frequentes ou mais complexas. Esse cenário reforça a necessidade de um treinamento específico para melhorar a capacidade de generalização do modelo em contextos clínicos.

## 6 CONCLUSÃO

O presente estudo apresentou um método para treinamento de um novo modelo de IA capaz de extrair entidades em relatos de casos clínicos, utilizando técnicas de NLP e NER, com o auxílio da biblioteca spaCy em Língua Portuguesa brasileira. Com um ambiente criado para fins de pesquisa, o modelo treinado superou de forma significativa o desempenho dos modelos pré treinados da spaCy, reconhecendo entidades específicas do domínio clínico. Com isso, a assertividade do modelo pode ser aprimorada se os dados utilizados para anotação fossem ainda mais robustos e ricos em conteúdos distintos e, ainda, dedicar uma equipe da área da saúde exclusivamente para anotação desses dados, de forma que fosse feita a revisão e melhoria da base. Para além, a utilização de um método semi-automático na etapa de anotação, traria mais agilidade ao processo, onde evitaria o esforço de passar as anotações para o formato esperado pela spaCy, pois os dados já viriam de forma correta, deixando-o mais rápido e menos suscetível a erros. É de grande importância destacar o esforço do presente trabalho para demonstrar que a adaptação de ferramentas de NLP para domínios específicos é possível e viável conforme demonstraram os resultados.

É importante destacar a contribuição da primeira fase deste trabalho, que resultou em uma aprovação e apresentação no **Congresso Brasileiro de Informática em Saúde** (CBIS'24) e na publicação do artigo citado para comparação neste trabalho na revista ***Journal of Health Informatics*** (JHI), cujo Qualis é A4. Isso demonstra a relevância da pesquisa científica no âmbito da saúde e ressalta a necessidade de trabalhos específicos que auxiliem que a prática médica tenha maior qualidade e, ainda, evidencia que o uso de tecnologia e inteligência artificial podem aprimorar significativamente avanços e o cotidiano na área da saúde.

A extração de informações de relatos de casos clínicos demonstrou que essa iniciativa pode ser direcionada em trabalhos futuros de forma a prover *insights* que sejam úteis como suporte à profissionais da área da saúde em tomadas de decisões ou para melhorar a análise de dados clínicos. Essa afirmativa se baseia, então, nos resultados obtidos a partir do treinamento, os quais indicaram que a extração relacionada à



categoria CONCLUSÃO (0.71) e PROCEDIMENTO DIAGNÓSTICO (0.65) pode auxiliar profissionais do domínio clínico na aquisição de conhecimento para tomada de decisão, e também na investigação sobre interações medicamentosas e possíveis reações adversas. Nesta mesma linha de aplicação, é possível apontar que a extração das entidades nomeadas de textos da área de saúde, pode ser usada por um Sistema de Informação Inteligente para sanar dúvidas de pacientes e auxiliar profissionais de saúde na tomada de decisão sobre terapias e prescrição de medicamentos (Colombo, 2022). O exemplo descrito e citado demonstra como o modelo criado e seus resultados podem ser utilizados para auxiliar de forma positiva o dia a dia dos profissionais de saúde.

## 6.1 TRABALHOS FUTUROS

Neste âmbito, como propostas de trabalhos futuros, pretende-se inserir outros tipos de textos da área de saúde, tais como bulas de medicamentos, prontuários médicos e entre outros, nas fases de treino e teste, a fim de melhorar o modelo de forma quantitativa e qualitativa, aumentando as métricas de precisão das entidades.

Para mais, ampliar o escopo do estudo com o objetivo de extrair as relações entre as entidades reconhecidas nestes tipos de documentos e, com isso, conseguir fazer inferências e auxiliar a prática clínica e o dia a dia de profissionais e pacientes. E ainda, conseguir aplicar tais inferências em prontuários eletrônicos para análise automatizada e sugestões de medicamentos, diagnósticos e programas de prevenção.

O modelo desenvolvido neste estudo apresenta, ainda, potencial para ser empregado em ferramentas baseadas em *Large Language Models* (LLMs), que são modelos amplamente utilizados em sistemas de NLP. As LLMs podem incorporar capacidades específicas de extração de informações desenvolvidas aqui como uma camada especializada para compreensão de textos clínicos. Essa aplicação pode facilitar o treinamento contínuo de LLMs voltadas para o domínio da saúde, utilizando dados ricos e anotados, podendo oferecer percepções robustas para suporte à decisão médica. Bem como, ser empregado em LLMs para realizar perguntas e respostas para profissionais de saúde, a fim de auxiliar em estudos e pesquisas. Assim, o uso deste modelo em tais ferramentas pode expandir significativamente seu impacto, alinhando inteligência artificial com a

prática clínica de maneira inovadora.

Por conseguinte, é de suma importância promover a colaboração entre profissionais da área da saúde e especialistas em NLP, para garantir a precisão e relevância dos resultados de pesquisas como essa. Em conclusão, este trabalho representou um passo na direção de sistemas NER robustos e precisos para a área da saúde em Português do Brasil.

## REFERÊNCIAS

AUDETAT SUZANNE LAURIN, G. S. C. B. N. C. F. J.-G. B. M.-C.; CHARLIN, B. Clinical reasoning difficulties: A taxonomy for clinical teachers. *Medical Teacher*, Taylor and Francis, v. 35, n. 3, p. e984–e989, 2013. Disponível em: <<https://doi.org/10.3109/0142159X.2012.733041>>.

BOTPENGUIN. Named entity recognition: Types challenges. *Botpenguin.com*, BotPenguin, Jul 2023. Disponível em: <<https://botpenguin.com/glossary/named-entity-recognition>>.

CARLETON, H. A.; WEBB, M. L. The case report in context. *The Yale journal of biology and medicine*, v. 85, n. 1, p. 93–6, 2012. Disponível em: <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3313543/>>.

CASTRO, R. S. Extração de informação: conceitos, plataformas e sistemas. In: . [S.l.]: Universidade Federal do Maranhão, Centro de Ciências exatas e tecnológicas, 2013.

COLOMBO, C.; OLIVEIRA, E. Intelligent information system for extracting knowledge from pharmaceutical package inserts. In: *Anais do XVIII Simpósio Brasileiro de Sistemas de Informação*. SBC, 2022. Disponível em: <<https://sol.sbc.org.br/index.php/sbsi/article/view/21388>>.

COLOMBO, C. da S.; BADUE, C.; OLIVEIRA, E. Extracting knowledge from pharmaceutical package inserts. In: ABRAHAM, A. et al. (Ed.). *Intelligent Systems Design and Applications*. [S.l.]: Springer Nature Switzerland, 2023.

CRONAPP. O que é natural language processing (nlp) e como usar no desenvolvimento de sistemas. *Blog Cronapp*, 2023. Disponível em: <<https://blog.cronapp.io/natural-language-processing>>.

ELINT. Uma visão geral sobre named entity recognition (ner). In: . [s.n.], 2021. Disponível em: <<https://medium.com/elinttech/uma-vis%C3%A3o-geral-sobre-named-entity-recognition-ner-4dc4e3b5e37a>>.

EXPLOSION. spacy 101: Everything you need to know. In: . [s.n.], 2024. Disponível em: <<https://spacy.io/usage/spacy-101>>.

FALCAO BRENNER LOPES, R. R. S. Luander Cipriano de J. Absorção das tarefas de processamento de linguagem natural (nlp) pela ciência da informação. *Ufrgs.br*, 2022. Disponível em: <<https://seer.ufrgs.br/index.php/EmQuestao/article/view/111323/64623>>.

FONSECA, E. et al. *Reconhecimento de Entidades Nomeadas para o Português Usando o OpenNLP*. [s.n.], 2015. Disponível em: <[https://repositorio.pucrs.br/dspace/bitstream/10923/14040/2/Reconhecimento\\_de\\_Entidades\\_Nomeadas\\_para\\_o\\_Portugues\\_Usando\\_o\\_OpenNLP.pdf](https://repositorio.pucrs.br/dspace/bitstream/10923/14040/2/Reconhecimento_de_Entidades_Nomeadas_para_o_Portugues_Usando_o_OpenNLP.pdf)>.

FONTANA, R. C. *Apostila de Machine Learning - Parte 2*. [S.l.], 2018. Disponível em: <[https://fontana.paginas.ufsc.br/files/2018/03/apostila\\_ML\\_pt2.pdf](https://fontana.paginas.ufsc.br/files/2018/03/apostila_ML_pt2.pdf)>.

GARCIA, A. C. B. Ética e inteligência artificial. *Computação Brasil*, 2020.

GONTIJO, B.; ROCHA, D. M.; FLOR, E. M. Relatos de caso: seu papel em um periódico médico. *Anais Brasileiros de Dermatologia*, Sociedade Brasileira de Dermatologia, v. 83, n. 6, p. 561–565, Nov 2008. ISSN 0365-0596. Disponível em: <<https://doi.org/10.1590/S0365-05962008000600011>>.

GRABER, M. Diagnostic errors in medicine: A case of neglect. *The Joint Commission Journal on Quality and Patient Safety*, v. 31, n. 2, p. 106–113, 2005. ISSN 1553-7250. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1553725005310154>>.

GUIMARÃES, C. A. Evidence based case report. *Revista do Colégio Brasileiro de Cirurgias*, Colégio Brasileiro de Cirurgias, v. 42, n. 5, p. 280–280, Sep 2015. ISSN 0100-6991. Disponível em: <<https://doi.org/10.1590/0100-69912015005001>>.

IBM. o que é machine learning? *IBM.com*, 2024. Disponível em: <<https://www.ibm.com/br-pt/topics/machine-learning>>.

JUNIOR, E. A.; NAKAYA, H.; RIZZO, L. V. Inteligência artificial em saúde. *Revista USP*, n. 141, p. 41–50, 2024. Disponível em: <<https://www.revistas.usp.br/revusp/article/view/225206/204612>>.

LANZAGORTA-ORTEGA, D.; CARRILLO-PÉREZ, D. L.; CARRILLO-ESPER, R. Inteligencia artificial en medicina: presente y futuro. *Gaceta médica de México*, v. 158, n. Supl. 1, p. 17–21, 2022. Disponível em: <[https://www.scielo.org.mx/scielo.php?script=sci\\_arttext&pid=S0016-38132022001100017&lng=es&nrm=iso&tlng=es](https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0016-38132022001100017&lng=es&nrm=iso&tlng=es)>.

LAURIOLA ALBERTO LAVELLI, F. A. I. An introduction to deep learning in natural language processing: models, techniques, and tools. *ScienceDirect*, 2022. Disponível em: <<https://sci-hub.se/https://doi.org/10.1016/j.neucom.2021.05.103>>.

LOBO, L. C. Inteligência artificial e medicina. *Revista Brasileira de Educação Médica*, v. 41, n. 2, p. 185–193, 2017. Disponível em: <<https://www.scielo.br/j/rbem/a/f3kqKjVQJxB4985fDMVb8b>>.

MARTINS, M. d. F. R. J. D. D. Algoritmos e inteligência artificial: Democracia não rima com obscurantismo. In: . [S.l.]: Revista da Faculdade Mineira de Direito, V.25N.50, 2023.

MENDONCA, M. et al. *INTELIGÊNCIA ARTIFICIAL, FUNDAMENTOS, CONCEITOS, APLICAÇÕES E TENDÊNCIAS*. [S.l.: s.n.], 2023.

MILIDIU RUY LUIZ DUARTE, J. C. C. R. Machine learning algorithms for portuguese named entity recognition. *Inteligencia Artificial. Revista Iberoamericana de Inteligencia Artificial*, 2007. ISSN 1137-3601. Disponível em: <<https://www.redalyc.org/articulo.oa?id=92503610>>.

MITCHELL, T. Machine learning. McGraw-Hill Science/Engineering/Math, 1997. Disponível em: <<https://www.cin.ufpe.br/~cavmj/Machine%20-%20Learning%20-%20Tom%20Mitchell.pdf>>.

NETO, J. F. D. S. Reconhecimento de entidades nomeadas para o português usando redes neurais. In: . [S.l.]: ESCOLA POLITÉCNICA, PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO, 2019.

OLIVEIRA, A. N. de. O impacto da inteligência artificial na melhoria do diagnóstico e tratamento de doenças na área da saúde. *Revista Tópicos*, v. 2, n. 7, 2024. Disponível em: <<https://zenodo.org/record/10780988>>.

OLIVEIRA, L. E. S. et al. Semclinbr - a multi-institutional and multi-specialty semantically annotated corpus for portuguese clinical nlp tasks. *Journal of Biomedical Semantics*, v. 13, p. 13, 2022. Disponível em: <<https://doi.org/10.1186/s13326-022-00269-1>>.

PAIXÃO, G. M. de M. et al. Machine learning na medicina: Revisão e aplicabilidade. *Arquivos Brasileiros de Cardiologia*, v. 118, n. 1, p. 95–102, 2022. Disponível em: <<https://abccardiol.org/article/machine-learning-na-medicina-revisao-e-aplicabilidade/>>.

PATINO, C.; FERREIRA, J. *Relatos de caso: narrativas destacando experiências clínicas que contribuem para a prática e para futuros estudos*. [s.n.]. Disponível em: <<https://www.scielo.br/j/jbpneu/a/TbKJZrsBFG7FwpzyHCxzHkj/?format=pdf&lang=pt>>.

PRADO, F. A. Evidence based case report. Raciocínio Clínico, a ciência e arte do diagnóstico, 2020.

RENTE, A.; JUNIOR, D. U.; UEZATO, K. M. K. Coronavírus e o coração | um relato de caso sobre a evolução da covid-19 associado à evolução cardiológica. *SciELO*, 2020.

RIEDO, S. A. C. Vitor dos S. Um modelo para extração, estruturação, indexação e recuperação de casos clínicos publicados na web. ISSN 2178-8332.

ROSSI, R. C.; LOURENÇO, M. dos S.; FILHO, A. L. V. R. O papel da inteligência artificial no combate à pandemia do covid-19. *Revista Interface Tecnológica*, v. 20, n. 1, p. 202–213, 2023. Disponível em: <<https://revista.fatectq.edu.br/interfacetecnologica/article/view/1688>>.

RUSSELL, S. J.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. Third. [S.l.]: Prentice Hall, 2010. Disponível em: <[https://people.engr.tamu.edu/guni/csce421/files/AI\\_Russell\\_Norvig.pdf](https://people.engr.tamu.edu/guni/csce421/files/AI_Russell_Norvig.pdf)>.

SAS. Machine learning: o que é e qual sua importância? *Sas.com*, 2023. Disponível em: <[https://www.sas.com/pt\\_br/insights/analytics/machine-learning.html](https://www.sas.com/pt_br/insights/analytics/machine-learning.html)>.

SCHNEIDER, E. T. R. et al. Developing a transformer-based clinical part-of-speech tagger for brazilian portuguese. *Journal of Health Informatics*, v. 15, 2023. Disponível em: <<https://jhi.sbis.org.br/index.php/jhi-sbis/article/view/1086>>.

SICHMAN, J. S. Inteligência artificial e sociedade: avanços e riscos. *Estudos Avançados*, University of São Paulo, v. 35, n. 101, p. 37–50, Apr 2021. Disponível em: <<https://www.scielo.br/j/ea/a/c4sqqrthGMS3ngdBhGWtKhh/>>.

SILVA, T. 2. O que as máquinas aprendem? *Racismo Algorítmico: inteligência artificial e discriminação nas redes digitais*, Sesc Edições, jun 19 2022. <https://racismo-algoritmico.pubpub.org/pub/o-que-maquinas-aprendem>.

TORRES, A. M. N.; BERSOT, R. P. M.; COLOMBO, C. d. S. A extração de entidades nomeadas em relatos de casos clínicos. *Journal of Health Informatics*, v. 16, nov. 2024.

UNIVERSALDEPENDENCIES. *Universal POS tags*. 2014. Disponível em: <<https://universaldependencies.org/u/pos/>>.