

INSTITUTO FEDERAL DO ESPÍRITO SANTO
CAMPUS CACHOEIRO DE ITAPEMIRIM
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

FERNANDA DE OLIVEIRA RAMOS

**CLINPTHYB: UMA ABORDAGEM HÍBRIDA PARA O RECONHECIMENTO DE
ENTIDADES NOMEADAS EM RELATOS DE CASOS CLÍNICOS**

Cachoeiro de Itapemirim

2025

FERNANDA DE OLIVEIRA RAMOS

**CLINPTHYB: UMA ABORDAGEM HÍBRIDA PARA O RECONHECIMENTO DE
ENTIDADES NOMEADAS EM RELATOS DE CASOS CLÍNICOS**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Sistemas de Informação do Instituto Federal do Espírito Santo, Campus Cachoeiro de Itapemirim, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. M.e. Cristiano da Silveira
Colombo

Cachoeiro de Itapemirim

2025

(Biblioteca do Campus Cachoeiro de Itapemirim)

R175c

Ramos, Fernanda de Oliveira.

Clinphyb: uma abordagem híbrida para o reconhecimento de entidades nomeadas em relatos de casos clínicos / Fernanda de Oliveira Ramos. - 2025.

48 f. : il. ; 30 cm.

Orientador: Cristiano da Silveira Colombo

TCC (Graduação) Instituto Federal do Espírito Santo, Campus Cachoeiro de Itapemirim, Sistemas de Informação, 2025.

1. Programação (computadores). 2. Aprendizado do computador. 3. Sistemas especialistas (computação). 4. Sistemas de reconhecimento de padrões. 5. Saúde. I. Colombo, Cristiano da Silveira. II. Título III. Instituto Federal do Espírito Santo.

CDD: 005.133

Bibliotecário/a: Jacqueline Machado Silva CRB-ES nº 640



**MINISTÉRIO DA EDUCAÇÃO
INSTITUTO FEDERAL DO ESPÍRITO SANTO
CAI - COORDENADORIA DO CURSO DE BACHARELADO EM
SISTEMAS DE INFORMACAO**



FOLHA DE APROVAÇÃO-TCC N° 10 / 2025 - CAI-CCSI (11.02.18.01.08.02.13)

N° do Protocolo: 23151.003513/2025-19

Cachoeiro De Itapemirim-ES, 02 de dezembro de 2025.

FERNANDA DE OLIVEIRA RAMOS

**CLINPTHYB: UMA ABORDAGEM HÍBRIDA PARA O RECONHECIMENTO DE
ENTIDADES
NOMEADAS EM RELATOS DE CASOS CLÍNICOS**

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal do Espírito Santo, Campus Cachoeiro de Itapemirim, como requisito parcial para obtenção de título de Bacharela em Sistemas de Informação.

Aprovado em 28 de novembro de 2025.

COMISSÃO EXAMINADORA

Prof. M.Sc. Cristiano da Silveira Colombo
Instituto Federal Do Espírito Santo
Orientador

Prof. M.Sc. Jaimel de Oliveira Lima
Instituto Federal Do Espírito Santo

Prof. D.Sc. Rafael Silva Guimarães
Instituto Federal Do Espírito Santo

Prof. D.Sc. Flávio Izo
Instituto Federal Do Espírito Santo

(Assinado digitalmente em 02/12/2025 22:52)
CRISTIANO DA SILVEIRA COLOMBO
PROFESSOR DO ENSINO BASICO TECNICO E TECNOLÓGICO
CAI-CCSI (11.02.18.01.08.02.13)
Matrícula: 1673901

(Assinado digitalmente em 04/12/2025 10:14)
FLAVIO IZO
PROFESSOR DO ENSINO BASICO TECNICO E TECNOLÓGICO
CAI-CCSI (11.02.18.01.08.02.13)
Matrícula: 2764270

(Assinado digitalmente em 02/12/2025 23:37)
JAIMEL DE OLIVEIRA LIMA
COORDENADOR DE CURSO
COL-CCTI (11.02.21.01.08.02.08)
Matrícula: 1248711

(Assinado digitalmente em 03/12/2025 07:42)
RAFAEL SILVA GUIMARAES
PROFESSOR DO ENSINO BASICO TECNICO E TECNOLÓGICO
CAI-CCSI (11.02.18.01.08.02.13)
Matrícula: 1919203

Visualize o documento original em <https://sipac.ifes.edu.br/public/documentos/index.jsp> informando seu número: **10**, ano: **2025**, tipo: **FOLHA DE APROVAÇÃO-TCC**, data de emissão: **02/12/2025** e o código de verificação: **6471e19bf1**

DECLARAÇÃO DO AUTOR

Declaro, para fins de pesquisa acadêmica, didática e técnico-científica, que este Trabalho de Conclusão de Curso pode ser parcialmente utilizado, desde que se faça referência à fonte e ao autor.

Cachoeiro de Itapemirim, 28 de Novembro de 2025.

FERNANDA DE OLIVEIRA RAMOS

Dedico esse trabalho a todos que fizeram parte da minha jornada acadêmica, seja no aspecto docente ou pessoal. Em especial, aos meus pais, que sempre fizeram o possível e o impossível pra me garantir boas condições de estudo. Também ao meu irmão, meu melhor amigo, que traz alegria aos meus dias desde que nasceu.

AGRADECIMENTOS

Primeiramente agradeço profundamente aos meus pais, que sempre me apoiaram e estiverem presentes em cada etapa da minha trajetória acadêmica, oferecendo todo o suporte necessário para que eu chegasse até aqui. Agradeço também ao meu irmão - ou manolito, como gosto de chamar - cuja companhia e bom humor tornaram essa caminhada muito mais leve.

Sou também muito grata à minha namorada, que esteve ao meu lado nos dias difíceis e sempre me motivou a continuar.

Além disso, agradeço imensamente ao corpo docente do IFES Cachoeiro, que contribuiu de forma essencial para a minha formação profissional e para o meu crescimento pessoal. Por fim, agradeço aos meus amigos e colegas de curso, que compartilharam comigo tantos aprendizados ao longo desses anos.

"I'm beautiful in my way 'cause God makes no mistakes
I'm on the right track, baby, I was born this way."

Lady Gaga

RESUMO

O Processamento de Linguagem Natural (*Natural Language Processing* - NLP) tem desempenhado um papel de destaque na área da saúde por possibilitar a extração de conhecimento a partir de dados médicos não estruturados. No português do Brasil, porém, ainda há poucos modelos capazes de lidar com esses dados, sobretudo nos relatos de casos clínicos, que reúnem informações sobre sintomas, diagnósticos e tratamentos. Este trabalho apresenta o ClinptHyb, um modelo híbrido de Reconhecimento de Entidades Nomeadas (*Named Entity Recognition* - NER) desenvolvido para identificar e categorizar automaticamente entidades clínicas em português. A metodologia envolveu o pré-processamento do corpus, a divisão estratificada do *dataset*, o treinamento do componente NER do spaCy e a integração com o Llama-3.3-70b, utilizado como LLM revisor. Os resultados mostraram que o ClinptHyb superou o spaCy em todas as categorias, alcançando *F1-score* de 97% em *Negation*, e superou as variantes do BERT em 8 das 10 categorias avaliadas, estabelecendo novos padrões de referência no SemClinBr. Além do desempenho superior, o modelo identificou inconsistências nas anotações originais, demonstrando potencial para apoiar a tarefa de anotação manual e o aprimoramento de *datasets* clínicos em português.

Palavras-chave: NLP; NER; Modelo Híbrido; SemClinBr; spaCy; LLMs; Relatos de Casos Clínicos.

ABSTRACT

Natural Language Processing (NLP) has gained prominence in the healthcare field by enabling the extraction of knowledge from unstructured medical data. In Brazilian Portuguese, however, there are still few models capable of handling such data, especially in clinical case reports, which contain essential information about symptoms, diagnoses, and treatments. This study presents ClinptHyb, a hybrid model for Named Entity Recognition (NER) developed to automatically identify and categorize clinical entities in Portuguese. The methodology involved corpus preprocessing, stratified dataset splitting, training of the spaCy NER component, and integration with Llama-3.3-70b, used as an LLM reviewer. The results showed that ClinptHyb outperformed the standalone spaCy model across all categories, achieving an F1-score of 97% in Negation, and surpassed the BERT variants in 8 out of 10 categories, establishing new benchmark standards for the SemClinBr corpus. In addition to its superior performance, the model identified inconsistencies in the original annotations, demonstrating potential to assist manual annotation and enhance Portuguese clinical datasets.

Keywords: NLP; NER; Hybrid Model; SemClinBr; spaCy; LLMs; Clinical Case Reports.

LISTA DE FIGURAS

Figura 1 – Representação das subáreas de estudo da linguagem. Fonte: Caseli, Nunes e Pagano (2024).	19
Figura 2 – Diagrama demonstrando o fluxo de funcionamento do spaCy. Fonte: spaCy (2025).	22
Figura 3 – Distribuição de entidades no dataset. Fonte: a autora.	30
Figura 4 – Distribuição de entidades distintas por documento. Fonte: a autora.	31
Figura 5 – Exemplo de erros com a posição das anotações após conversão para JSON. Fonte: a autora.	33
Figura 6 – Exemplo de sobreposição encontrada no arquivo "9808.xml" do <i>dataset</i> . Fonte: a autora.	33
Figura 7 – Exemplo de anotação de um Relato de Caso Clínico no formato JSON. Fonte: a autora.	34
Figura 8 – Diagrama demonstrando o processo de treinamento do spaCy. Fonte: spaCy (2025).	34
Figura 9 – Diagrama demonstrando os componentes da <i>pipeline</i> do novo modelo spaCy. Fonte: a autora.	35
Figura 10 – Estrutura principal do prompt utilizado nos experimentos. Fonte: a autora.	36
Figura 11 – Diagrama demonstrando o funcionamento do novo algoritmo híbrido. Fonte: a autora.	38

LISTA DE TABELAS

Tabela 1 – Descrição dos atributos que compõem uma anotação no <i>dataset</i> SemclinBr. Fonte: a autora.	32
Tabela 2 – Descrição dos componentes do novo modelo spaCy. Fonte: a autora.	35
Tabela 3 – Janela de contexto e número máximo de tokens de saída dos modelos Llama e GPT-OSS. Fonte: a autora.	38
Tabela 4 – Valores de <i>F1-score</i> por entidade para os modelos Llama e GPT-OSS. Fonte: a autora.	39
Tabela 5 – Métricas globais de <i>Precision</i> (P), <i>Recall</i> (R) e <i>F1-Score</i> (F1) para os modelos Llama e GPT-OSS. Fonte: a autora.	39
Tabela 6 – Valores de <i>F1-score</i> por entidade para os modelos ClinptCy e ClinptHyb. Fonte: a autora.	41
Tabela 7 – Métricas globais de <i>Precision</i> (P), <i>Recall</i> (R) e <i>F1-Score</i> (F1) para os modelos ClinptCy e ClinptHyb. Fonte: a autora.	41
Tabela 8 – Valores de <i>F1-score</i> por entidade dos modelos deste estudo (ClinptCy e ClinptHyb) em comparação com modelos da literatura (BERT e BioBERTpt). Fonte: a autora.	42

LISTA DE ABREVIATURAS

F1 - *F1-Score*

FN - Falsos Negativos

FP - Falsos Positivos

IE - *Information Extraction* - Extração de Informação

LLM - *Large Language Model* - Grande Modelo de Linguagem

ML - *Machine Learning* - Aprendizado de Máquina

NE - *Named Entities* - Entidades Nomeadas

NER - *Named Entity Recognition* - Reconhecimento de Entidades Nomeadas

NLG - *Natural Language Generation* - Geração de Linguagem Natural

NLP - *Natural Language Processing* - Processamento de Linguagem Natural

NLU - *Natural Language Understanding* - Compreensão de Linguagem Natural

P - *Precision* - Precisão

R - *Recall* - Revocação

RAG - *Retrieval-Augmented Generation* - Geração Aumentada via Recuperação

VP - Verdadeiros Positivos

SUMÁRIO

1	INTRODUÇÃO	15
1.1	Objetivos gerais	16
1.2	Objetivos específicos	16
2	REFERENCIAL TEÓRICO	18
2.1	Processamento de Linguagem Natural	18
2.2	Extração de Informação	19
2.2.1	Reconhecimento de Entidades Nomeadas	20
2.3	Relatos de Casos Clínicos como fonte de dados	20
2.4	SemClinBr	21
2.5	spaCy	21
2.6	LLMs	22
2.7	<i>Prompting</i>	23
2.8	Métricas de Avaliação	24
3	TRABALHOS CORRELATOS	26
4	MATERIAIS E MÉTODOS	28
4.1	Análise do Dataset	28
4.1.1	Divisão Estratificada Do Dataset	30
4.1.2	Conversão dos Arquivos	31
4.2	Treinamento do modelo spaCy	34
4.3	Criação Do Algoritmo Híbrido (spaCy + Llama)	35
4.3.1	Construção do <i>prompt</i>	36
4.3.2	Modelos	37
5	EXPERIMENTOS E RESULTADOS	40
5.1	ClinptCy e ClinptHyb	40
5.2	Análise de Resultados frente ao Estado da Arte	41
5.3	Achados relacionados à consistência do <i>dataset</i>	42
6	CONCLUSÃO	44
6.1	Análise Geral	44
6.2	Trabalhos Futuros	45
	REFERÊNCIAS	47

1 INTRODUÇÃO

O Processamento de Linguagem Natural (*Natural Language Processing* - NLP) tem desempenhado um papel crescente na área da saúde, especialmente em países de língua inglesa, onde as técnicas e modelos de NLP têm avançado consideravelmente. No entanto, quando se trata de outros idiomas, como o Português do Brasil, ainda há uma lacuna significativa no desenvolvimento e aplicação dessas tecnologias, principalmente no contexto clínico (NéVéOL et al., 2018). Isso se torna um desafio particular ao lidar com dados médicos não estruturados, como os relatos de casos clínicos, que contêm informações cruciais para a prática médica, incluindo sintomas, diagnósticos e tratamentos, registrados em linguagem natural pelos profissionais de saúde (PAGANO et al., 2024).

Apesar da riqueza de dados presentes nesses documentos, a falta de um padrão de escrita resulta em registros com formatos distintos, que variam de acordo com o profissional responsável. Estudos recentes destacam que a extração manual desse tipo de dado é lenta, demorada, sujeita a erro humano e pouco eficiente diante do volume crescente de registros clínicos (PAGANO et al., 2024). Dessa forma, o desafio que o presente estudo busca atacar é a interpretação automática informações clínicas presentes nesses relatos.

Neste cenário, diante da dificuldade de interpretação e correlação entre os inúmeros relatos, este trabalho propõe o desenvolvimento de um modelo para o Reconhecimento de Entidades Nomeadas (*Named Entity Recognition* - NER) em Relatos de Casos Clínicos. O NER tem como finalidade identificar e classificar entidades textuais, permitindo organizar e estruturar dados relevantes para a prática médica. Essa abordagem possibilita a detecção de padrões e a organização do conhecimento para os profissionais de saúde, favorecendo decisões fundamentadas em informações extraídas dos relatos de casos clínicos (PAGANO et al., 2024).

Nos últimos anos, avanços em modelos de linguagem de grande porte (*Large Language Models* - LLMs) têm ampliado as possibilidades para a análise automática de

textos médicos, especialmente por sua capacidade de interpretar contexto e lidar com ambiguidades. Entretanto, o uso direto desses modelos ainda enfrenta limitações conhecidas, como a dependência de dados generalistas, a ocorrência de alucinações e a baixa especialização em domínios clínicos específicos (WULFF; KUBSCH; KRIST, 2025), como o clínico. Essas restrições reforçam a necessidade de abordagens que combinem modelos especializados em língua portuguesa com técnicas mais recentes baseadas em LLMs.

Diante desse contexto, define-se o problema central deste trabalho: os relatos clínicos em português reúnem informações essenciais, porém apresentadas de forma despadronizada, o que evidencia a escassez de modelos especialistas em português. Por outro lado, abordagens baseadas apenas em LLMs ainda não oferecem precisão suficiente para lidar com domínios altamente especializados, como o clínico. Assim, torna-se fundamental integrar a especialização linguística de modelos treinados em corpus clínicos com a capacidade de generalização dos LLMs.

Para lidar com esse desafio, propõe-se o desenvolvimento do *ClinptHyb*, um modelo híbrido que combina um modelo NER spaCy treinado do zero com o corpus SemClinBr (ClinptCy) e um LLM revisor (Llama 3.3-70B). Essa abordagem busca melhorar a precisão e a consistência das anotações clínicas, contribuindo para o avanço da extração de informação em textos médicos em língua portuguesa.

1.1 OBJETIVOS GERAIS

O objetivo geral deste trabalho é desenvolver e avaliar um modelo híbrido de Reconhecimento de Entidades Nomeadas (NER) aplicado a relatos de casos clínicos em português.

1.2 OBJETIVOS ESPECÍFICOS

- Treinar um modelo novo com spaCy utilizando o corpus SemClinBr para reconhecimento inicial de entidades clínicas.
- Implementar a abordagem híbrida integrando o modelo spaCy e um LLM que atua

como revisor das anotações em relatos de casos clínicos.

- Comparar o desempenho do modelo híbrido (spaCy + LLM) com o modelo spaCy e com resultados já publicados na literatura, utilizando métricas padrão (*Precision*, *Recall* e *F1-score*).
- Demonstrar as contribuições deste estudo para o avanço do NLP aplicado à saúde na língua portuguesa.

2 REFERENCIAL TEÓRICO

Esta seção estabelece a base teórica para o presente trabalho, apresentando os principais conceitos que fundamentam a metodologia e os experimentos realizados. Inicialmente, são introduzidos o Processamento de Linguagem Natural, a Extração de Informação e o Reconhecimento de Entidades Nomeadas, que constituem a base para o desenvolvimento do algoritmo proposto. Em seguida, são detalhados os relatos de casos clínicos, o *dataset* SemClinBr e as funcionalidades da biblioteca spaCy. Por fim, são apresentados os *Large Language Models*, o conceito de *prompting* e as métricas de avaliação utilizadas.

2.1 PROCESSAMENTO DE LINGUAGEM NATURAL

O Processamento de Linguagem Natural, do inglês *Natural Language Processing*, é uma área de estudo voltada à investigação e resolução de problemas que envolvem a linguagem humana através de ferramentas computacionais. No trabalho de Caseli, Nunes e Pagano (2024), os autores destacam que por meio de abordagens estatísticas e neurais, os sistemas de NLP podem aprender com exemplos, utilizando técnicas de Aprendizado de Máquina (*Machine Learning* - ML) para extrair informações relevantes de dados não estruturados.

De modo geral, em PLN buscam-se soluções para problemas computacionais, ou seja, tarefas, sistemas, aplicações ou programas, que requerem o tratamento computacional de uma língua (português, inglês etc.), seja escrita (texto) ou falada (fala). Línguas como as de sinais também têm sido alvo de estudos da área (CASELI; NUNES; PAGANO, 2024).

Entre as subáreas que compõem o NLP, destacam-se: a Geração de Linguagem Natural (*Natural Language Generation* - NLG) e a Compreensão de Linguagem Natural (*Natural Language Understanding* - NLU) (CASELI; NUNES; PAGANO, 2024). Nesse contexto, a NLG é responsável pela criação de textos compreensíveis e coesos a partir de informações estruturadas, como, por exemplo, na geração de respostas por *chatbots*.

Já a NLU, que contempla o tema central deste trabalho, pode ser entendida como um conjunto de processos voltados à análise e interpretação da linguagem.

A etapa de análise está diretamente relacionada às diversas dimensões da linguagem humana, como ilustra a Figura 1. Essa fase envolve a separação e classificação dos elementos linguísticos, como palavras e suas respectivas categorias morfológicas (dimensão morfológica) e funções gramaticais (dimensão sintática) (CASELI; NUNES; PAGANO, 2024). Além disso, a análise considera o significado das palavras (dimensão semântica), a fim de compreender como as palavras e frases se estruturam e se relacionam dentro de um texto.




Figura 1 – Representação das subáreas de estudo da linguagem. Fonte: Caseli, Nunes e Pagano (2024).

Por outro lado, a etapa de interpretação foca em compreender os significados atribuídos pelo ser humano, levando em conta o contexto em que palavras e frases são usadas. Nessa fase, são analisadas as intenções e nuances, como figuras de linguagem e expressões idiomáticas, o que está ligado à dimensão pragmática da linguagem.

2.2 EXTRAÇÃO DE INFORMAÇÃO

A Extração de Informação, ou *Information Extraction* (IE), é uma subárea do Processamento de Linguagem Natural cujo objetivo é obter o conteúdo semântico de um texto, convertendo dados não estruturados em informação estruturada (CLARO et al., 2024). A IE pode ser subdividida com base no tipo de informação a ser extraída do texto, abrangendo diferentes tarefas, dentre as quais o Reconhecimento de Entidades Nomeadas destaca-se como foco principal do presente estudo.

2.2.1 Reconhecimento de Entidades Nomeadas

O Reconhecimento de Entidades Nomeadas (*Named Entity Recognition* - NER) é a tarefa de identificar e classificar expressões linguísticas chamadas Entidades Nomeadas (*Named Entities* - NE). Estas por sua vez fazem referência a entidades específicas em um determinado domínio, como nomes próprios, expressões temporais e espécies biológicas (NADEAU, 2007). Em geral, o processo do NER é dividido em duas etapas: primeiro, a identificação (ou delimitação), onde são selecionadas as palavras que compõem as NEs. Em seguida, a classificação atribui uma categoria semântica à Entidade Nomeada (CLARO et al., 2024).

No contexto do NER, considere a frase:

"Estar acima do peso pode fazer com que apareça o diabetes tipo 2." (PAVANELLI et al., 2023).

Neste exemplo, a etapa de identificação consiste em reconhecer "**Estar acima do peso**" e "**diabetes tipo 2**" como entidades relevantes. Em seguida, o processo de classificação define "**Estar acima do peso**" como uma Complicação (*Complication*) e "**diabetes tipo 2**" como Tipo de Diabete (*DiabetesType*).

2.3 RELATOS DE CASOS CLÍNICOS COMO FONTE DE DADOS

Relatos de Casos Clínicos são descrições detalhadas de casos clínicos observados por profissionais de saúde, contendo informações essenciais sobre o paciente, como sintomas, histórico médico e estilo de vida (PAGANO et al., 2024). Essas narrativas podem incluir questionários preenchidos pelo paciente, registros de exames, e anotações feitas por profissionais de saúde, como notas de evolução de enfermagem, sumários de alta, boletins médicos e observações em texto livre nos prontuários eletrônicos.

Partindo de um modelo treinado para a extração de NER em textos clínicos, é possível identificar e classificar automaticamente entidades relevantes como medicamentos, doenças, sintomas, entre outros. A análise desses dados pode ser empregada para detectar padrões e organizar o conhecimento presente nos relatos, favorecendo uma

compreensão mais aprofundada da condição do paciente (PAGANO et al., 2024). Como resultado, fornece informações relevantes aos profissionais de saúde, possibilitando tomadas de decisões clínicas mais assertivas.

2.4 SEMCLINBR

O SemClinBr é um dataset anotado e desenvolvido para apoiar tarefas de NLP no contexto clínico em português (OLIVEIRA et al., 2022). Construído a partir de textos clínicos obtidos de diversas instituições e especialidades médicas, o corpus é composto por 1.000 notas clínicas que foram rotuladas com 65.117 entidades e 11.263 relações. O SemClinBr destaca-se por oferecer anotações detalhadas que seguem padrões semânticos específicos para a área da saúde, abrangendo categorias como problemas de saúde, exames, tratamentos e sinais clínicos. As anotações foram validadas por especialistas médicos e linguistas, garantindo a sua qualidade e a sua consistência, sendo um recurso valioso para treinar e avaliar modelos voltados à compreensão de linguagem em cenários clínicos.

2.5 SPACY

A documentação oficial define o spaCy como uma biblioteca gratuita de código aberto voltada para o NLP em Python. Essa biblioteca fornece ferramentas robustas que realizam análise e compreensão de grandes volumes de dados, permitindo sua utilização para diferentes tarefas de NLP (spaCy, 2025).

Uma das vantagens do spaCy é a modularização, que permite a criação de uma sequência customizada de componentes na *pipeline*. Além disso, a biblioteca possibilita o treinamento individual de cada componente, facilitando a adaptação com base nas tarefas de NLP desejadas. O presente estudo apresenta o treinamento do componente NER a partir do zero, utilizado para a identificação de entidades relevantes em relatos de casos clínicos. A Figura 2 demonstra o fluxo de funcionamento de um modelo spaCy:

1. O modelo recebe um texto como entrada.

2. O componente *tokenizer* é acionado, dividindo o texto em *tokens*¹ e criando o objeto Doc.
3. Os demais componentes da *pipeline* (*tagger*, *parser*, *ner*, entre outros) são chamados em sequência, processando a saída do *tokenizer*.
4. O modelo retorna um objeto do tipo Doc, que armazena os *tokens* e os resultados de todos os componentes da *pipeline*.




Figura 2 – Diagrama demonstrando o fluxo de funcionamento do spaCy. Fonte: spaCy (2025).

Dentre os modelos pré-treinados disponíveis na língua portuguesa, o *pt_core_news_lg*² foi selecionado e sua utilização será descrita posteriormente na metodologia.

2.6 LLMS

Wulff, Kubsch e Krist (2025) define os *Large Language Models* (LLMs) como modelos baseados na arquitetura *Transformer*³ que, através do treinamento auto-supervisionado em grandes volumes de textos, desenvolvem a capacidade de compreender diferentes dimensões da linguagem humana (sintaxe, semântica e pragmática), além de incorporar conhecimento de mundo. Essas habilidades permitem sua aplicação em diferentes tarefas de NLP, como tradução, sumarização e NER. Entretanto, o desempenho dos LLMs depende diretamente da representatividade dos dados de treinamento, o que limita sua aplicação em domínios especializados (WULFF; KUBSCH; KRIST, 2025). Os termos técnicos e contextos específicos dos domínios biomédico e o clínico, por

¹ *Tokens* correspondem às unidades básicas de texto, como palavras, números ou pontuações, utilizadas pelos componentes da pipeline (spaCy, 2025).

² O sufixo *lg* (*large*) indica uma maior quantidade de dados e vetores de palavras, o que o torna mais robusto e preciso para tarefas que exigem maior detalhamento semântico (spaCy, 2025).

³ A arquitetura *Transformer*, proposta por Vaswani et al. (2017), introduziu mecanismos de atenção que permitem ao modelo relacionar diferentes partes de uma sequência de texto, tornando-se a base de modelos amplamente utilizados, como BERT e GPT.

exemplo, são pouco frequentes nos corpora generalistas, o que tende a impactar negativamente o desempenho desses modelos.

Uma estratégia para adaptar os LLMs a contextos específicos é o uso do *fine-tuning*⁴. No entanto, conforme descrito por Wulff, Kubsch e Krist (2025), essa abordagem exige elevado custo computacional e grandes volumes de dados anotados, o que a torna inviável no contexto deste estudo. Como alternativa, esta pesquisa propõe uma abordagem híbrida, combinando a especialização de um modelo spaCy treinado no corpus SemClinBr com a versatilidade de um LLM revisor. O objetivo é equilibrar precisão em domínios específicos e capacidade de generalização na tarefa de NER.

2.7 PROMPTING

Segundo Jurafsky e Martin (2024), o *prompting* consiste em fornecer instruções ou exemplos diretamente no texto de entrada de um LLM, orientando a forma como o modelo produz sua saída. Ou seja, um *prompt* é uma sequência textual que guia o LLM na execução de uma tarefa específica, como responder perguntas, realizar traduções ou classificar sentimentos. O processo de elaborar instruções claras e eficazes para otimizar o desempenho do modelo é conhecido como *prompt engineering* (engenharia de *prompt*).

Jurafsky e Martin (2024) destaca que existem diferentes estratégias de *prompting*, entre elas:

- *Zero-shot prompting*: o modelo recebe apenas a instrução, sem exemplos adicionais.
- *Few-shot prompting*: o modelo recebe alguns exemplos de entrada e saída no *prompt* para orientar a tarefa.

A elaboração do *prompt* tem grande influência na qualidade da resposta, sendo possível estruturar instruções mais restritivas (como oferecer opções fixas de resposta) para

⁴ Processo de ajuste de um modelo pré-treinado em um conjunto de dados específico, com o objetivo de adaptá-lo a uma nova tarefa ou domínio (JURAFSKY; MARTIN, 2024).

aumentar a consistência e reduzir ambiguidades (JURAFSKY; MARTIN, 2024).

2.8 MÉTRICAS DE AVALIAÇÃO

Cortes, Vieira e Barone (2024) destaca que a utilização de métricas de avaliação permite mensurar de forma objetiva a qualidade das predições em relação a um conjunto de referência (*gold standard*). No contexto do NER, essas métricas são essenciais para analisar tanto a confiabilidade dos resultados obtidos quanto à cobertura das entidades relevantes, fornecendo uma visão mais abrangente do desempenho do modelo. As métricas adotadas nesta pesquisa foram *Precision*, *Recall* e *F1-score*, cujas fórmulas e descrições são apresentadas a seguir:

- *Precision* (P): mede a proporção de entidades anotadas corretamente entre todas as entidades preditas pelo modelo.

$$P = \frac{VP}{VP + FP}$$

- *Recall* (R): mede a proporção de entidades corretas recuperadas pelo modelo entre todas as entidades que deveriam ter sido identificadas.

$$R = \frac{VP}{VP + FN}$$

- *F1-score* (F1): média harmônica entre *precision* e *recall*, condensando as duas medidas.

$$F1 = 2 \times \frac{P \cdot R}{P + R}$$

Onde:

- VP (Verdadeiros Positivos): entidades identificadas corretamente pelo modelo.
- FP (Falsos Positivos): entidades anotadas pelo modelo que não existem no conjunto de referência.

- FN (Falsos Negativos): entidades presentes no conjunto de referência, mas que o modelo não anotou.

A *Precision* está diretamente relacionada à ocorrência de falsos positivos, pois indica a proporção de entidades anotadas pelo modelo que de fato correspondem ao conjunto de referência. Dessa forma, valores reduzidos dessa métrica indicam que o modelo está incluindo entidades que não deveriam ser reconhecidas. O *Recall*, por outro lado, reflete o impacto dos falsos negativos, uma vez que mede a capacidade do modelo de recuperar todas as entidades presentes no texto. Um valor baixo de *recall* indica que o modelo deixou de identificar parte das entidades relevantes. Já o *F1-score* integra *Precision* e *Recall* em uma medida única, oferecendo uma avaliação equilibrada entre acertos e omissões.

No contexto clínico, em que tanto a anotação indevida quanto a ausência de informações podem comprometer a avaliação do estado de saúde do paciente, a utilização dessas métricas é fundamental para uma análise rigorosa do desempenho dos modelos desenvolvidos.

3 TRABALHOS CORRELATOS

O trabalho de Lee et al. (2020) introduziu o BioBERT, um modelo de linguagem baseado no BERT, pré-treinado com grandes corpora biomédicos, como os resumos do PubMed e os artigos completos do PubMed (*PubMed Central full-text articles - PMC*). O modelo foi avaliado em tarefas como NER, Extração de Relações e Resposta a Perguntas, demonstrando um desempenho superior a modelos genéricos. Em contraste com o BioBERT, voltado ao inglês e a textos biomédicos gerais, o presente estudo busca adaptar a tarefa de NER ao contexto específico dos relatos clínicos na língua portuguesa.

O trabalho de Schneider et al. (2020), por sua vez, apresenta o BioBERTpt, um modelo de linguagem adaptado para o português, focado em tarefas NER em textos clínicos e biomédicos. Foram desenvolvidas três versões do modelo: o BioBERTpt(clin), treinado com notas clínicas; o BioBERTpt(bio), utilizando textos biomédicos; e o BioBERTpt(all), que combina ambos os conjuntos de dados. Os resultados da avaliação indicaram que o BioBERTpt(clin) superou os modelos de base ¹ em 11 das 13 categorias de entidades no corpus SemClinBr e alcançou um *F1-score* de 92,6% no CLINpt, estabelecendo um novo padrão de excelência para esse corpus. Em contrapartida, esta pesquisa adota uma abordagem híbrida de menor custo, que combina um modelo spaCy treinado do zero com um LLM revisor, dispensando o re-treinamento completo de grandes modelos *Transformer*.

Torres (2024) aborda a utilização do spaCy para o reconhecimento de entidades nomeadas em textos clínicos. Um dos modelos desenvolvidos por Torres (2024) utilizou uma amostra do dataset SemClinBr, com destaque para a categoria *Finding* (retratada como Conclusão) que obteve *F1-score* de 71%. Os resultados obtidos indicam um potencial promissor do spaCy para a classificação de entidades clínicas em português. Enquanto o trabalho de Torres (2024) avaliou apenas o desempenho de

¹ Modelos de base, treinados em grandes conjuntos de dados gerais, servem como referência para avaliar o desempenho de novos modelos em tarefas específicas. Eles permitem uma comparação eficaz com modelos especializados, como o BioBERTpt, adaptado para textos clínicos e biomédicos, facilitando a avaliação na tarefa de NER.

um modelo spaCy, o presente estudo amplia essa abordagem ao integrá-lo com um LLM, melhorando o desempenho alcançado.

Mello et al. (2024), por fim, avaliou a eficácia de diferentes LLMs na tarefa de NER clínico em português, utilizando 30 relatos do corpus SemClinBr. Foram avaliados os modelos GPT-3.5, Gemini, Llama-3 e Sabiá-2, considerando três categorias de entidades: Sinais ou Sintomas, Doenças ou Síndromes e Dados Negados. Os resultados mostraram que o Llama-3 apresentou o melhor desempenho, com *F1-score* de 0,538 e destaque para o *Recall*. O GPT-3.5, por sua vez, obteve desempenho equilibrado, enquanto o Gemini obteve maior *Precision*, mas com *Recall* reduzido. O estudo demonstra o potencial dos LLMs para a extração de informações clínicas em português, ressaltando que a escolha do modelo deve considerar os requisitos específicos de cada aplicação. Diferentemente dos experimentos comparativos entre LLMs realizados por Mello et al. (2024), o presente trabalho amplia a análise ao apresentar métricas detalhadas por categoria de entidade e comparações diretas com o estado da arte do corpus SemClinBr.

Os trabalhos correlatos apresentados nesta seção reforçam a relevância desta pesquisa ao buscar soluções alternativas para desenvolver um modelo adaptado às especificidades dos relatos clínicos em português. Nesse contexto, pretende-se explorar o dataset SemClinBr e avaliar potenciais melhorias na classificação de suas entidades por meio uma abordagem híbrida, que combina um modelo spaCy com um LLM revisor na tarefa de NER.

4 MATERIAIS E MÉTODOS

Este capítulo descreve a metodologia utilizada no presente estudo, que foi estruturada em etapas bem definidas, visando a transparência e a reprodutibilidade. O processo iniciou-se com a análise do *dataset*, no qual foi aplicado um algoritmo de estratificação para a divisão em conjuntos de treino, teste e validação. Ainda nessa fase, os arquivos originais em formato XML foram convertidos para JSON, de modo a torná-los compatíveis com a biblioteca spaCy. Em seguida, realizou-se o treinamento do modelo spaCy, com a criação do componente NER a partir do zero. Por fim, foi desenvolvido o algoritmo híbrido, que integra o novo modelo spaCy a um LLM revisor.

4.1 ANÁLISE DO DATASET

Nessa etapa, foi realizada a análise do *dataset* e a definição das categorias de interesse, a fim de facilitar sua utilização no treinamento do modelo. Inicialmente, desenvolveu-se um *script* que percorreu todos os arquivos e retornou uma lista com todas as entidades nomeadas encontradas. No total foram identificadas 923 classes distintas, número elevado em razão da presença de múltiplas *tags* (etiquetas) atribuídas a uma mesma sequência de caracteres. Por exemplo, o trecho “**COMORBIDADES**” aparecia anotado como “*Disease or Syndrome/Disease or Syndrome*”, o que seria interpretado pelo spaCy como uma categoria diferente de “*Disease or Syndrome*”.

Por limitação do escopo do trabalho, optou-se por não trabalhar com múltiplas anotações para a mesma entidade. Para isso, a primeira fase consistiu em mapear todas as anotações duplicadas de uma mesma entidade - como o exemplo acima - e substituí-las por uma única classificação. Assim, “**COMORBIDADES**” passou a ser anotado apenas como “*Disease or Syndrome*”. Na segunda etapa realizou-se o mapeamento das abreviações, mantendo apenas a entidade clínica associada. Por exemplo, o termo “**AVC**”, anteriormente anotado como “*Disease or Syndrome/Abbreviation*” passou a ser classificado exclusivamente como “*Disease or Syndrome*”.

Por fim, foram selecionadas 12 categorias de interesse, descritas a seguir:

1. *Chemicals and Drugs (Chem)*: substância farmacológica ou preparação usada no diagnóstico, tratamento ou prevenção de doenças.
2. *Diagnostic Procedure (DProced)*: procedimento, método ou técnica utilizada para determinar a natureza ou identidade de uma doença ou distúrbio. Excluem-se aqui procedimentos realizados exclusivamente em espécimes de laboratório.
3. *Disease or Syndrome (DisSynd)*: condição que altera ou interfere no funcionamento normal de um organismo, geralmente caracterizada por alterações patológicas em sistemas, órgãos ou partes do corpo.
4. *Disorders (Disor)*: alteração estrutural ou lesão de uma parte do corpo resultante de causa externa ou trauma. Inclui fraturas, luxações ou lesões traumáticas.
5. *Finding (Find)*: constatação clínica obtida por meio de observação direta ou pela mensuração de um atributo ou condição de um organismo, incluindo o histórico clínico do paciente.
6. *Health Care Activity (Health)*: atividade relacionada à prática médica ou ao cuidado de pacientes.
7. *Laboratory or Test Result (LResult)*: resultado ou interpretação derivada de exame laboratorial ou teste diagnóstico.
8. *Laboratory Procedure (LProced)*: procedimento ou técnica usada para determinar composição, quantidade ou concentração de uma amostra, realizado em laboratório clínico.
9. *Medical Device (MDev)*: objeto fabricado utilizado principalmente no diagnóstico, tratamento ou prevenção de distúrbios fisiológicos ou anatômicos.
10. *Negation (Neg)*: expressão linguística que indica ausência ou negação de conceito clínico em texto narrativo.

11. *Sign or Symptom (Sign)*: manifestação clínica de doença ou condição: sinal observável pelo profissional ou sintoma subjetivo relatado pelo paciente, indicando desvio do normal.
12. *Therapeutic or Preventive Procedure (TProced)*: procedimento, método ou técnica destinado a prevenir doença/distúrbio, melhorar função física ou tratar doença/lesão.

4.1.1 Divisão Estratificada Do Dataset

Após a definição das categorias de interesse, realizou-se a divisão estratificada do *dataset*, com o objetivo de garantir que as entidades nomeadas estivessem proporcionalmente representadas nos conjuntos treino, teste e validação.

Inicialmente, foi gerado um arquivo binário contendo a distribuição das entidades por documento. A Figura 3 apresenta, por meio de um gráfico de barras, a frequência de cada categoria no corpus, evidenciando maior ocorrência das categorias *Sign or Symptom*, *Finding*, *Therapeutic or Preventive Procedure*, *Health Care Activity* e *Negation*. Por outro lado, categorias como *Laboratory Procedure* e *Disorders* aparecem com menor frequência.




Figura 3 – Distribuição de entidades no dataset. Fonte: a autora.

A Figura 4, por sua vez, ilustra através de um histograma a distribuição de entidades distintas por documento. Observa-se que a maioria dos relatos clínicos contém entre 7 e 9 categorias diferentes, embora existam casos com menos de duas. Essa variação reforça a necessidade da estratificação para manter o equilíbrio entre os conjuntos, minimizando vieses durante o processo de treinamento.




Figura 4 – Distribuição de entidades distintas por documento. Fonte: a autora.

Para a divisão, utilizou-se a biblioteca *iterative-stratification*, implementada em Python como extensão do scikit-learn, a qual disponibiliza métodos específicos para problemas de classificação multirrótulo (SECHIDIS et al., 2024). O processo resultou em três subconjuntos na proporção de 8:1:1, correspondentes a treino (80%), teste (10%) e validação (10%). Considerando o total de 1000 relatos clínicos, a divisão produziu 800 arquivos para treino, 100 para validação e 100 para teste. Essa estratégia busca evitar desequilíbrios entre as classes, preservando a distribuição original dos dados e contribuindo para a confiabilidade das avaliações posteriores.

4.1.2 Conversão dos Arquivos

Nessa etapa, os relatos de casos clínicos do SemclinBr, originalmente disponibilizados em formato XML, foram convertidos para JSON, tornando-os compatíveis com a biblioteca spaCy. Cada arquivo do *dataset* possui uma *tag* <TEXT>, que contém o relato em

linguagem natural, e um conjunto de *tags* <annotation> com as entidades anotadas. Os atributos de cada anotação estão descritos na Tabela 1.

Tabela 1 – Descrição dos atributos que compõem uma anotação no *dataset* SemclinBr. Fonte: a autora.

Atributo	Descrição
<i>id</i>	Identificador único e incremental iniciado em 1.
<i>tag</i>	Classificação da Entidade Nomeada.
<i>start</i>	Posição do primeiro caractere da palavra no texto.
<i>end</i>	Posição do último caractere da palavra no texto.
<i>text</i>	Texto correspondente a Entidade Nomeada.
<i>abbr</i> (opcional)	Abreviação do texto presente em <i>text</i> .

Uma característica dos relatos de casos clínicos é a ausência de um padrão de escrita, o que resulta em textos com diferentes formatos. Durante a conversão dos arquivos para JSON, os documentos que possuíam algum tipo de formatação no elemento <TEXT>, como quebras de linha (\n) ou tabulações (\t), ocasionaram em divergências na posição das anotações, tornando-as incorretas e comprometendo assim a confiabilidade da fonte de dados a ser utilizada no modelo.

A Figura 5 ilustra alguns exemplos das inconsistências observadas no processo. Nota-se, por exemplo, que o trecho original "**PISANDO COM 1 MULETA**", correspondente a uma entidade do tipo *Finding*, teve parte de seus caracteres suprimidos, resultando na forma corrompida "**SANDO COM 1 MULETA**". Para contornar esse problema, foi desenvolvido um *script* que, a partir da lista original de anotações (*tags* <annotation>), utiliza o atributo *text* de cada anotação para criar uma nova lista com as posições corrigidas.

Ainda nessa etapa, foi tratada uma situação recorrente: anotações sobrepostas, ou seja, casos em que os valores de *start* ou *end* de uma anotação entravam em conflito com outra já existente no mesmo relato. A Figura 6 apresenta um exemplo retirado do *dataset* em que os trechos "**QUEIXAS**" e "**QUEIXAS DE DOR**" foram anotados como entidades distintas, embora a palavra "**QUEIXAS**" representasse a mesma sequência de caracteres em ambos os casos.

A estratégia adotada para solucionar esse problema consistiu em aplicar uma regra

File: 8926.xml

Sentence: PCTE PISANDO COM 1 MULETA.

Start: 62

End: 66

Tag: Abbreviation|Patient or Disabled Group

Text (Before): PCTE

Text (After): TE P

Start: 67

End: 81

Tag: Finding

Text (Before): PISANDO COM 1 MULETA

Text (After): SANDO COM 1 MULETA

Figura 5 – Exemplo de erros com a posição das anotações após conversão para JSON. Fonte: a autora.

de priorização baseada nos índices de início (*start*) e de fim (*end*) das anotações. Sempre que duas ou mais entidades apresentavam sobreposição, mantinha-se aquela cujo valor de *start* fosse menor e o valor de *end* maior, eliminando-se as demais. Dessa forma, no exemplo citado, como ambos possuíam o mesmo índice inicial, o trecho "**QUEIXAS DE DOR**" apresentava o maior índice final e, portanto, foi preservado, enquanto a anotação duplicada referente a "**QUEIXAS**" foi descartada.

```

X SOBREPOSIÇÃO DETECTADA no arquivo: 9808.xml
Anotação 1: {'id': '39420', 'tag': 'Sign or Symptom', 'start': 329, 'end': 336, 'text': 'QUEIXAS', 'abbr': ''}
Anotação 2: {'id': '39468', 'tag': 'Sign or Symptom', 'start': 329, 'end': 343, 'text': 'QUEIXAS DE DOR'}

Execução interrompida devido à sobreposição.

```

Figura 6 – Exemplo de sobreposição encontrada no arquivo "9808.xml" do *dataset*. Fonte: a autora.

Após a resolução dessas inconsistências, foi possível converter o *dataset* para o formato JSON, no qual cada relato foi representado como um dicionário contendo as chaves *text* e *entities*: a primeira armazena o relato em linguagem natural, enquanto a segunda corresponde a uma lista de anotações estruturada no formato [*start*, *end*, *entity*, *text*]. Nesse caso, *start* e *end* indicam as posições da entidade no texto, *entity* refere-se ao rótulo atribuído e *text* armazena a sequência de caracteres correspondente. A Figura 7 apresenta um exemplo de relato de caso clínico anotado após a conversão.

```

"text": "POI DE LAVAGEM + CURETA DE TECIDO NECRÓTICO. 18:00: PACIENTE RETORNOU DO CC LÚCIDO,"
"entities": [
  [ 7, 14, "Procedure", "LAVAGEM" ],
  [ 17, 23, "Procedure", "CURETA"],
  [ 52, 60, "Patient or Disabled Group", "PACIENTE" ],
  [ 76, 82, "Finding", "LÚCIDO"],

```

Figura 7 – Exemplo de anotação de um Relato de Caso Clínico no formato JSON. Fonte: a autora.

4.2 TREINAMENTO DO MODELO SPACY

O treinamento de um modelo com spaCy é um processo cíclico que utiliza exemplos anotados como base. Esses exemplos são compostos por um texto e pelos rótulos (*labels*) a serem previstos, como categorias gramaticais ou entidades nomeadas. Durante o treinamento, o modelo recebe o texto, gera uma predição e compara essa saída com o rótulo original. A diferença entre as previsões do modelo e as *labels* de referência permite o cálculo do gradiente ¹, que indica como os parâmetros internos do modelo devem ser ajustados para reduzir o erro. A Figura 8 ilustra esse ciclo, cujo resultado final é um modelo atualizado que pode ser salvo e utilizado em diferentes tarefas de NLP (spaCy, 2025).




Figura 8 – Diagrama demonstrando o processo de treinamento do spaCy. Fonte: spaCy (2025).

O componente selecionado para treinamento nesta pesquisa foi o NER, e a metodologia segue a documentação oficial da biblioteca spaCy (spaCy, 2025). Inicialmente, foi criado um arquivo de configuração **config.cfg** ², no qual foram definidos os componentes da *pipeline* e os hiperparâmetros de treino.

¹ Em aprendizado de máquina, o gradiente corresponde à variação da função de erro em relação aos parâmetros do modelo e orienta o ajuste dos pesos durante a retropropagação, permitindo que o modelo reduza progressivamente o erro a cada iteração (ALBAWI; MOHAMMED; AL-ZAWI, 2017).

² Esse arquivo centraliza todas as definições da *pipeline* e dos hiperparâmetros, o que favorece a reprodutibilidade e o versionamento do modelo. Assim, diferentes usuários podem treinar *pipelines* equivalentes com as mesmas configurações (spaCy, 2025).

A Figura 9 apresenta os componentes do novo modelo, cuja descrição encontra-se na Tabela 2.

Tabela 2 – Descrição dos componentes do novo modelo spaCy. Fonte: a autora.

Componente	Descrição
Tokenizer	Divide o texto em <i>tokens</i> e cria o objeto Doc. Cada língua possui um <i>tokenizer</i> padrão definido pelo spaCy e neste estudo o português foi utilizado.
Tok2Vec	Converte cada <i>token</i> em uma representação vetorial, que será utilizada pelos demais componentes. Foi inicializado a partir do modelo pré-treinado <i>pt_core_news_lg</i> , garantindo representações mais adequadas à língua portuguesa.
NER	Realiza o reconhecimento de entidades nomeadas, identificando <i>spans</i> de texto e classificando-os em categorias específicas. Esse componente foi treinado do zero a partir do corpus SemClinBr, visando a aprendizagem de entidades específicas do domínio clínico.

Ainda no **config.cfg**, são definidos os caminhos para os arquivos binários de treino e teste no formato .spacy que, conforme descrito anteriormente, contém 800 e 100 relatos de casos clínicos, respectivamente. Para fins didáticos, a partir desse ponto o novo modelo spaCy será tratado como ClinptCy (*Clinical Portuguese spaCy Model*).




Figura 9 – Diagrama demonstrando os componentes da *pipeline* do novo modelo spaCy. Fonte: a autora.

O treinamento é executado a partir de uma instrução na linha de comando e esse processo utiliza os arquivos treino.spacy e teste.spacy. O primeiro serve como base para o aprendizado, fornecendo os relatos de casos clínicos já anotados. Já o segundo é utilizado para ajustar os hiperparâmetros do modelo e monitorar seu desempenho durante o treinamento, evitando o *overfitting* ³.

4.3 CRIAÇÃO DO ALGORITMO HÍBRIDO (SPACY + LLAMA)

Após experimentos iniciais realizados com o ClinptCy (descritos posteriormente no Capítulo 5), observou-se que, apesar de os resultados serem satisfatórios quando

³ *Overfitting* é um problema em aprendizado de máquina que ocorre quando um modelo se ajusta excessivamente aos dados de treinamento, perdendo a capacidade de generalizar para novos dados.

comparados a outros modelos disponíveis na literatura, ainda existia uma margem significativa para melhorias. A partir dessa constatação surge a proposta central do presente estudo: o desenvolvimento de um algoritmo híbrido que integra o spaCy e um LLM revisor, buscando aprimorar o desempenho inicial obtido.

4.3.1 Construção do *prompt*

A próxima etapa consistiu na construção do *prompt*, elemento fundamental para o uso adequado de LLMs. Os testes iniciais utilizando a estratégia *few-shot prompting* não trouxeram ganhos de consistência, além de aumentar o tamanho e a complexidade do *prompt*. Essa conclusão foi obtida por meio de experimentos nos quais diferentes exemplos anotados foram inseridos no início do *prompt*, com variações na quantidade e na ordem desses exemplos.

Observou-se que o LLM reproduzia inconsistências presentes nos exemplos fornecidos, além de aumentar a ocorrência de alucinações e de saídas que não seguiam o formato especificado. Diante desses resultados, optou-se por adotar a abordagem de *zero-shot prompting*, cuja estrutura principal foi apresentada na Figura 10 e consiste em:

```
messages = [
    SystemMessage(content="""Você é um revisor de anotações médicas.
    Sua função é revisar e corrigir entidades extraídas de prontuários médicos, garantindo consistência e precisão."""),
    HumanMessage(content=f"""
    ### Entrada
    Prontuário médico (texto e anotações atuais):
    {json.dumps(clinical_report, ensure_ascii=False, indent=2)}

    ### Definições de entidades (labels em inglês, descrições em português):
    {json.dumps(ENTITIES_LIST, ensure_ascii=False, indent=2)}
    {json.dumps(ENTITIES_DEFINITION, ensure_ascii=False, indent=2)}

    ---

    ### Tarefa
    1. Revisar entidades anotadas no prontuário.
    2. Corrigir labels incorretos conforme as definições.
    3. Adicionar entidades faltantes.
    4. Remover entidades não suportadas.
    5. Mesclar duplicatas (ignorar maiúsculas/minúsculas, acentuação, espaços).
    6. Evitar anotações artificiais ou redundantes.
    7. **Verificar sistematicamente negação**: identificar e anotar gatilhos de negação (label "Negation") quando presentes.

    ---

    ### Regras do output
    - Retornar **apenas JSON**, sem explicações adicionais.
    - Formato JSON esperado (schema):
    {json_output_str}
    """)
]
```

Figura 10 – Estrutura principal do *prompt* utilizado nos experimentos. Fonte: a autora.

1. Descrição geral da tarefa, indicando ao LLM para atuar como um revisor de anotações médicas.

2. Objeto JSON contendo o texto clínico e as anotações realizadas pelo ClinptCy.
3. Lista de entidades e suas respectivas definições, extraídas diretamente da *UMLS Semantic Network*⁴.
4. Descrição mais detalhada da tarefa, especificando as instruções através de uma lista numerada.
5. Especificação do formato de saída, exigindo que as respostas sejam fornecidas estritamente em JSON.

Além disso, foram adicionadas regras complementares a fim de reduzir ambiguidades e comportamentos inesperados observados durante os testes.

4.3.2 Modelos

A etapa seguinte consistiu na escolha do LLM e os primeiros testes foram realizados com modelos locais através do Ollama⁵. No entanto, a limitação computacional foi um fator decisivo, uma vez que as configurações do computador utilizado não eram compatíveis com os modelos que possuíam um maior número de parâmetros. Entre os modelos testados nessa fase (llama3.1:8b, gemma3:4b, mistral:7b, qwen3:4b), nenhum apresentou desempenho satisfatório na tarefa de revisão, cometendo muitas alucinações e fugindo do contexto restrito dos casos clínicos apresentados.

Buscando a utilização de LLMs mais robustos, a ferramenta Groq foi a escolhida, pois disponibiliza gratuitamente modelos de produção acessíveis via API (Groq, 2025). Os modelos testados foram o llama-3.3-70b-versatile (Meta) e o openai/gpt-oss-120b (OpenAI). Para simplificação, eles serão referidos neste estudo como Llama e GPT-OSS, respectivamente. A Tabela 3 apresenta informações mais detalhadas a respeito

⁴ A *UMLS Semantic Network* fornece uma estrutura consistente de categorias semânticas (como *Disease or Syndrome*, *Sign or Symptom*, entre outros) e os relacionamentos entre elas, servindo como base para a organização e interpretação de conceitos biomédicos (U.S. National Library of Medicine, 2025).

⁵ Ollama é uma ferramenta que permite executar modelos de linguagem localmente em diferentes sistemas operacionais, oferecendo suporte a diversos modelos e facilitando sua integração e aplicações (Ollama, 2025).

dos modelos, trazendo a janela de contexto (*Context Window*) e o número máximo de tokens de saída (*Max Output Tokens*).

Tabela 3 – Janela de contexto e número máximo de tokens de saída dos modelos Llama e GPT-OSS.
Fonte: a autora.

Modelo	Groq ID	Janela de Contexto	Max. Tokens de Saída
Llama	llama-3.3-70b-versatile	131.072	65.536
GPT-OSS	openai/gpt-oss-120b	131.072	32.768

Nesta etapa, aplicou-se o mesmo algoritmo de estratificação descrito no Subtópico 4.1.1 para segmentar o conjunto de validação, reduzindo a quantidade de arquivos necessários para a validação manual, mas preservando a proporção original das entidades. Inicialmente, dos 100 arquivos disponíveis, 12 foram selecionados para compor o conjunto de validação. Além disso, optou-se por remover três entidades da lista original, mantendo assim as seguintes categorias: *Diagnostic Procedure*, *Disease or Syndrome*, *Finding*, *Health Care Activity*, *Laboratory Procedure*, *Medical Device*, *Negation*, *Sign or Symptom* e *Therapeutic or Preventive Procedure*.

Em seguida, o novo conjunto de validação foi submetido ao modelo híbrido, cuja arquitetura está representada na Figura 11. Inicialmente, o texto é processado pelo ClinptCy, responsável por anotar as entidades clínicas e retornar um objeto Doc. A seguir, esse objeto Doc é convertido para o formato JSON, armazenando o texto original e suas respectivas anotações. Por fim, esses dados servem de entrada para o LLM, que atua como revisor e gera a versão final das entidades anotadas, também em formato JSON.




Figura 11 – Diagrama demonstrando o funcionamento do novo algoritmo híbrido. Fonte: a autora.

A fim de selecionar o LLM com melhor desempenho para a tarefa de revisão das anotações, o mesmo experimento foi aplicado tanto ao Llama quanto ao GPT-OSS. Os conjuntos de anotações gerados foram comparados com o *dataset* original do

SemClinBr, considerado o *gold standard* (padrão-ouro) de referência para a avaliação no presente estudo.

A partir dessa comparação, foram calculadas as métricas de *Precision* (P), *Recall* (R) e *F1-Score* (F1), cujos resultados são apresentados nas Tabelas 4 e 5. A Tabela 4 apresenta os valores de F1 por entidade, evidenciando que o Llama obteve melhor desempenho em todas as 9 categorias analisadas. Já a Tabela 5 reúne as métricas globais de P, R e F1, demonstrando que o Llama superou o GPT-OSS em 22,8 pontos percentuais em precisão, 8,5 em revocação e 15,6 em *F1-score*.

Tabela 4 – Valores de *F1-score* por entidade para os modelos Llama e GPT-OSS. Fonte: a autora.

Modelo	DProced	DisSynd	Find	Health	LProced	MDev	Neg	Sign	TProced
GPT-OSS	0,545	0,683	0,576	0,511	0,1540	0,538	0,824	0,610	0,563
Llama	0,737	0,889	0,688	0,632	0,571	0,667	0,848	0,747	0,634

Em razão do desempenho superior do Llama em relação ao GPT-OSS, ele foi o LLM selecionado para compor o algoritmo híbrido. Durante o processo de validação, foram identificados dois padrões de classificação incorreta: medicamentos com posologia eram classificados como *Therapeutic or Preventive Procedure*, enquanto traumatismos e lesões eram anotados como *Sign or Sympton*. Buscando aprimorar os resultados, o prompt foi ajustado para reinserir as três entidades anteriormente removidas, resultando em uma lista final composta pelas 12 categorias originais apresentadas no Subtópico 4.1.1.

Tabela 5 – Métricas globais de *Precision* (P), *Recall* (R) e *F1-Score* (F1) para os modelos Llama e GPT-OSS. Fonte: a autora.

Modelo	P	R	F1
GPT-OSS	0,557	0,621	0,587
Llama	0,785	0,706	0,743

Por fim, o escopo de validação foi ampliado com a aplicação do mesmo algoritmo de estratificação, desta vez considerando 33 dos 100 arquivos disponíveis. O cálculo das métricas seguiu o mesmo procedimento já estabelecido, e os resultados foram apresentados no Capítulo 5. Para fins didáticos, a partir desse ponto o novo algoritmo híbrido será referido como ClinptHyb (*Hybrid Clinical Portuguese Model*).

5 EXPERIMENTOS E RESULTADOS

Este capítulo apresenta os resultados dos experimentos realizados com os modelos desenvolvidos no presente estudo. Inicialmente, foram comparados o ClinptCy e o ClinptHyb, com destaque para os ganhos de desempenho proporcionados pela abordagem híbrida. Em seguida, os valores de *F1-score* de ambos os modelos foram confrontados com resultados da literatura, indicando avanços relevantes e o estabelecimento de novos padrões de desempenho para algumas categorias do SemclinBr. Por fim, foram apresentados achados pontuais sobre a consistência do *dataset*, destacando casos de falta de padronização em algumas anotações e omissão de entidades relevantes.

5.1 CLINPTCY E CLINPTHYB

O primeiro experimento teve como objetivo comparar os dois modelos desenvolvidos neste estudo, avaliando o ganho de desempenho ao substituir o modelo spaCy pelo algoritmo híbrido proposto. Para o cálculo das métricas do ClinptCy, foram utilizados todos os 100 arquivos disponíveis para validação, em um processo automatizado por meio de uma instrução de linha de comando fornecida pela própria biblioteca spaCy.

Já o ClinptHyb contou com o cálculo manual das métricas. Como o LLM revisor retorna as anotações em formato JSON, sem a estrutura de objetos Doc necessária para uso direto das ferramentas de avaliação do spaCy, foi adotado um procedimento alternativo. Tanto o *gold standard* quanto as saídas do LLM foram convertidos para CSV por meio de um *script*, permitindo o cálculo das métricas em planilha.

Essa abordagem possibilitou comparar individualmente cada anotação revisada com sua correspondente no *dataset* original, o que foi fundamental para analisar o comportamento do LLM e identificar os padrões de divergência discutidos posteriormente. Conforme descrito no capítulo anterior, essa análise foi conduzida sobre uma amostra de 33 relatos clínicos do conjunto de validação, selecionados por meio de estratificação a fim de preservar a proporção original de entidades.

Tabela 6 – Valores de *F1-score* por entidade para os modelos ClinptCy e ClinptHyb. Fonte: a autora.

Modelo	Chem	DProced	DisSynd	Disor	Find	Health	LResult	LProced	MDev	Neg	Sign	TProced
ClinptCy	0,822	0,682	0,738	0,530	0,716	0,604	0,562	0,388	0,700	0,872	0,611	0,616
ClinptHyb	0,905	0,867	0,866	0,696	0,783	0,726	0,713	0,545	0,873	0,972	0,767	0,773

Os resultados apresentados na Tabela 6 destacam a superioridade do ClinptHyb em todas as categorias quando comparado com o ClinptCy. O principal destaque foi a categoria *Negation*, que alcançou um F1-score de 97%. Além disso, as categorias *Chemicals and Drugs*, *Diagnostic Procedure*, *Disease or Syndrome* e *Medical Device* também obtiveram desempenho expressivo, com valores F1 acima de 85%. Já a Tabela 7 reforça o ganho de desempenho do ClinptHyb, mostrando melhorias consistentes em todas as métricas avaliadas: *Precision*, *Recall* e *F1-score*.

Tabela 7 – Métricas globais de *Precision* (P), *Recall* (R) e *F1-Score* (F1) para os modelos ClinptCy e ClinptHyb. Fonte: a autora.

Modelo	P	R	F1
ClinptCy	0,703	0,680	0,691
ClinptHyb	0,875	0,752	0,809

5.2 ANÁLISE DE RESULTADOS FRENTE AO ESTADO DA ARTE

O segundo experimento avaliou o desempenho dos modelos desenvolvidos neste estudo frente às variações do BERT apresentadas por Schneider et al. (2020), que até então representavam o melhor resultado para o corpus SemClinBr. Conforme demonstrado na Tabela 8, o ClinptHyb superou todos os modelos em 8 das 10 categorias avaliadas, estabelecendo uma nova referência de desempenho para as entidades *Diagnostic Procedure*, *Disease or Syndrome*, *Finding*, *Health Care Activity*, *Laboratory or Test Result*, *Medical Device*, *Sign or Syptom* e *Therapeutic or Preventive Procedure*.

Além disso, destaca-se que o modelo spaCy apresentou resultados robustos, superando as variações do BERT em diversas categorias. Esse resultado reforça sua relevância como base consistente para o desenvolvimento do algoritmo híbrido proposto.

Tabela 8 – Valores de *F1-score* por entidade dos modelos deste estudo (ClinptCy e ClinptHyb) em comparação com modelos da literatura (BERT e BioBERTpt). Fonte: a autora.

Modelo	Chem	DProced	DisSynd	Disor	Find	Health	LResult	MDev	Sign	TProced
<i>ClinptCy</i>	0,822	0,682	0,738	0,530	0,716	0,604	0,562	0,700	0,611	0,616
<i>ClinptHyb</i>	0,905	0,867	0,866	0,696	0,783	0,726	0,713	0,873	0,767	0,773
BERT multilin- gual uncased	0,903	0,546	0,562	0,787	0,503	0,374	0,378	0,559	0,519	0,487
BERT multilin- gual cased	0,901	0,519	0,538	0,782	0,505	0,412	0,417	0,593	0,537	0,486
Portuguese BERT large	0,782	0,504	0,575	0,625	0,526	0,336	0,404	0,514	0,552	0,489
Portuguese BERT base	0,904	0,556	0,540	0,784	0,500	0,346	0,422	0,537	0,538	0,471
BioBERTpt (bio)	0,894	0,551	0,575	0,785	0,526	0,459	0,398	0,604	0,534	0,501
BioBERTpt (clin)	0,911	0,560	0,583	0,781	0,521	0,406	0,453	0,562	0,544	0,459
BioBERTpt (all)	0,904	0,548	0,564	0,791	0,517	0,404	0,440	0,555	0,566	0,513

5.3 ACHADOS RELACIONADOS À CONSISTÊNCIA DO *DATASET*

Durante o processo de cálculo manual das métricas do ClinptHyb, foram identificadas duas inconsistências nas anotações originais do SemclinBr, cujas implicações serão discutidas a seguir.

A primeira diz respeito a falta de padronização em algumas anotações, com casos em que uma mesma entidade nomeada apresenta limites diferentes dentro do próprio dataset. Considere o seguinte trecho extraído de um dos relatos:

“Às 01:38: Lucido, nao verbalizando, traqueostomizado, **eupneico** em aa, afebril, apresenta fixador externo em MMSS . . .” (OLIVEIRA et al., 2022)

Nessa sentença, a palavra “**eupneico**” foi anotada como *Finding*. Já em outro arquivo, em contexto muito semelhante, a entidade anotada como *Finding* foi “**eupneico em aa**”:

“Às 14:20 hrs: paciente consciente, comunicativo, **eupneico em aa**, em repouso no leito, sem queixas algicas.” (OLIVEIRA et al., 2022)

Entre os 33 arquivos avaliados, foram observadas cerca de 24 ocorrências semelhantes. Esse padrão não invalida o *dataset*, mas pode introduzir incertezas para o modelo, que passa a lidar com exemplos contraditórios. Em tarefas de NER, essas variações nos limites da entidade podem gerar confusão no aprendizado, impactando a consistência das previsões.

Já a segunda inconsistência refere-se a omissão de algumas entidades relevantes. Em um dos relatos, por exemplo, a negação “sem” aparecia três vezes, mas as anotações originais registraram apenas duas. O ClinptHyb, por sua vez, foi capaz de reconhecer de forma consistente todas as três ocorrências. No total, entre os 33 arquivos de validação, foram identificadas cerca de 60 anotações ausentes.

A confirmação desses achados foi feita por meio de uma comparação cruzada dentro do próprio SemclinBr: em trechos equivalentes de outros arquivos, a anotação omitida estava presente, o que sugere falhas pontuais no processo de anotação. Essas omissões não comprometem a validade geral do corpus, mas podem levar a pequenas distorções na avaliação dos modelos, já que o conjunto original de anotações não contempla todas as entidades mencionadas nos relatos.

Dessa forma, os resultados apontam que a abordagem híbrida proposta neste estudo possui potencial para atuar como ferramenta de apoio à anotação manual, atuando como um revisor automático capaz de sinalizar inconsistências e recuperar entidades que passaram despercebidas.

6 CONCLUSÃO

Neste capítulo é apresentada a análise geral do trabalho, são apontados os trabalhos futuros, bem como a conclusão e as considerações finais.

6.1 ANÁLISE GERAL

Este estudo apresentou o desenvolvimento e avaliação do ClinptHyb, um algoritmo híbrido para o reconhecimento de entidades nomeadas em relatos de casos clínicos em português.

Os experimentos realizados demonstraram que o ClinptHyb superou os modelos de referência introduzidos por Schneider et al. (2020) em 8 das 10 categorias analisadas, estabelecendo novos padrões de desempenho para essas entidades no corpus SemClinBr. Observou-se ainda que o modelo spaCy obteve melhor desempenho em algumas categorias quando comparados às variações do BERT, o que reforça sua relevância como uma base consistente para o desenvolvimento do modelo híbrido.

Outro ponto que merece destaque é o desempenho obtido na categoria de negação (*Negation*), que alcançou 97% de *F1-score*. Esse resultado é especialmente relevante para o domínio clínico, uma vez que a identificação correta de negações é essencial para evitar interpretações equivocadas sobre o estado de saúde do paciente. Estudos em extração de informação médica ressaltam que erros nesse processo podem comprometer diagnósticos, gerar custos indevidos e até implicações legais, o que reforça a relevância prática do modelo desenvolvido (FABREGAT et al., 2023).

Além das métricas apresentadas, o ClinptHyb revelou potencial adicional ao identificar inconsistências no corpus SemClinBr, como variações de limites de entidades e omissões pontuais de anotações. Esse achado indica a capacidade do modelo de atuar como recurso de apoio a anotação manual e contribuir com o aprimoramento de *datasets* clínicos em português.

Embora os resultados sejam promissores, ainda há espaço para melhorias, especi-

almente em categorias com desempenho inferior, como *Disorders* e *Laboratory or Test Result*. Esses casos evidenciam a necessidade de refinar o modelo e explorar estratégias complementares de treinamento. Assim, as propostas de trabalhos futuros tornam-se fundamentais para ampliar o alcance e a aplicação prática do ClinptHyb.

6.2 TRABALHOS FUTUROS

Como trabalho futuro, propõe-se a aplicação do ClinptHyb a todo o corpus SemClinBr, com o objetivo de identificar inconsistências e omissões de forma sistemática, possibilitando a criação de uma versão revisada do *dataset*. Esse processo também permite a ampliação do conjunto de entidades contempladas pelo modelo, abrangendo todas as categorias disponíveis no corpus e, conseqüentemente, tornando as anotações mais completas.

Outra linha de investigação consiste na integração de técnicas de Recuperação de Conhecimento (*Retrieval-Augmented Generation - RAG*¹), permitindo a utilização de fontes complementares, como bulas de medicamentos e prontuários eletrônicos. Esse avanço potencializaria a capacidade do modelo de produzir anotações mais assertivas e contextualizadas.

Além disso, considera-se ampliar o escopo do ClinptHyb para além do reconhecimento de entidades nomeadas, incorporando a extração de relações. Esse recurso possibilitaria a identificação de interações medicamentosas, correlações entre sintomas e diagnósticos e outras conexões relevantes, enriquecendo a análise clínica.

Por fim, considera-se relevante o desenvolvimento de uma ferramenta de anotação com interface web, na qual o modelo poderia ser utilizado tanto para a pré-anotação automática quanto para a revisão das anotações humanas. Dessa forma, seria possível otimizar fluxos de trabalho e contribuir para uma maior consistência nos dados anotados.

Conclui-se que este trabalho representa uma contribuição relevante para o avanço do reconhecimento de entidades nomeadas em textos clínicos em português. A abor-

¹ Técnica que combina modelos de linguagem com sistemas de recuperação de informações para acessar bases externas e enriquecer a análise de textos.

dagem híbrida proposta, além de proporcionar ganhos expressivos em desempenho, abriu possibilidades para novas pesquisas e aplicações, consolidando um caminho promissor para o desenvolvimento de soluções em NLP voltadas ao domínio da saúde.

REFERÊNCIAS

ALBAWI, S.; MOHAMMED, T. A.; AL-ZAWI, S. Understanding of a convolutional neural network. In: *2017 International Conference on Engineering and Technology (ICET)*. [S.l.: s.n.], 2017. p. 1–6.

CASELI, H. d. M.; NUNES, M. d. G. V.; PAGANO, A. O que é pln? In: CASELI, H. M.; NUNES, M. G. V. (Ed.). *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*. 2. ed. BPLN, 2024. book chapter 1. ISBN 978-65-00-95750-1. Disponível em: <<https://brasileiraspln.com/livro-pln/2a-edicao/parte-introducao/cap-introducao/cap-introducao.html>>.

CLARO, D. B. et al. Extração de informação. In: CASELI, H. M.; NUNES, M. G. V. (Ed.). *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*. 2. ed. BPLN, 2024. book chapter 20. ISBN 978-65-00-95750-1. Disponível em: <<https://brasileiraspln.com/livro-pln/2a-edicao/parte-aplicacoes/cap-ie/cap-ie.html>>.

CORTES, E. G.; VIEIRA, R.; BARONE, D. A. C. Perguntas e respostas. In: CASELI, H. M.; NUNES, M. G. V. (Ed.). *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*. 2. ed. BPLN, 2024. book chapter 16. ISBN 978-65-00-95750-1. Disponível em: <<https://brasileiraspln.com/livro-pln/2a-edicao/parte-interacao/cap-qa/cap-qa.html>>.

FABREGAT, H. et al. Negation-based transfer learning for improving biomedical named entity recognition and relation extraction. *Journal of Biomedical Informatics*, v. 138, 2023. Disponível em: <<https://doi.org/10.1016/j.jbi.2022.104279>>.

Groq. *Groq Documentation: Overview*. 2025. <<https://console.groq.com/docs/overview>>. Acesso em: 2025-07-16.

JURAFSKY, D.; MARTIN, J. H. Large language models. In: *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. 3rd. ed. USA: Prentice Hall PTR, 2024. cap. 7. Draft, August 24, 2025. Disponível em: <<https://web.stanford.edu/~jurafsky/slp3/>>.

LEE, J. et al. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, Oxford University Press, v. 36, n. 4, p. 1234–1240, 2020. Disponível em: <<https://academic.oup.com/bioinformatics/article/36/4/1234/5566506>>.

MELLO, C. E. R. et al. Avaliação de grandes modelos de linguagem na extração de informações clínica. *Journal of Health Informatics*, v. 16, n. Especial, p. 1–14, 2024. Apresentado no XX Congresso Brasileiro de Informática em Saúde (CBIS'24), Belo Horizonte, MG, Brasil, 8-11 out. 2024. Disponível em: <<https://jhi.sbis.org.br/index.php/jhi-sbis/article/view/1306>>.

NADEAU, D. *Semi-supervised named entity recognition: learning to recognize 100 entity types with little supervision*. Tese (Doutorado) — University of Ottawa, [s.l.], 2007.

NéVéOL, A. et al. Clinical natural language processing in languages other than english: opportunities and challenges. *Journal of Biomedical Semantics*, BioMed Central, v. 9, n. 1, p. 1–13, 2018.

OLIVEIRA, L. E. S. et al. Semclinbr - a multi-institutional and multi-specialty semantically annotated corpus for portuguese clinical nlp tasks. *Journal of Biomedical Semantics*, v. 13, n. 13, 2022. Disponível em: <<https://doi.org/10.1186/s13326-022-00269-1>>.

Ollama. *Ollama Documentation*. 2025. <<https://docs.ollama.com/>>. Acesso em: 2025-07-16.

PAGANO, A. et al. Pln na saúde. In: CASELI, H. M.; NUNES, M. G. V. (Ed.). *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*. 2. ed. BPLN, 2024. book chapter 25. ISBN 978-65-00-95750-1. Disponível em: <<https://brasileiraspln.com/livro-pln/2a-edicao/parte-dominios/cap-saude/cap-saude.html>>.

PAVANELLI, L. et al. Bete: A brazilian portuguese dataset for named entity recognition and relation extraction in the diabetes healthcare domain. In: NALDI, M. C.; BIANCHI, R. A. C. (Ed.). *Intelligent Systems. BRACIS 2023. Lecture Notes in Computer Science*. Cham: Springer, 2023, (Lecture Notes in Computer Science, v. 14197). p. 256—267. Disponível em: <https://doi.org/10.1007/978-3-031-45392-2_17>.

SCHNEIDER, E. T. R. et al. BioBERTpt - a Portuguese neural language model for clinical named entity recognition. In: *Proceedings of the 3rd Clinical Natural Language Processing Workshop*. Online: Association for Computational Linguistics, 2020. p. 65–72. Disponível em: <<https://www.aclweb.org/anthology/2020.clinicalnlp-1.7>>.

SECHIDIS, K. et al. *iterative-stratification: Iterative stratification algorithms for multi-label data*. 2024. <<https://github.com/trent-b/iterative-stratification>>. Acesso em: 22 set. 2025.

spaCy. *spaCy 101: Everything you need to know · spaCy Usage Documentation*. 2025. <<https://spacy.io/usage/spacy-101>>. Acesso em: 2025-07-16.

TORRES, A. M. N. *Desenvolvimento de modelo NER para a extração de informações em relatos de casos clínicos*. Monografia (Trabalho de Conclusão de Curso (Bacharelado em Sistemas de Informação)) — Instituto Federal do Espírito Santo, Campus Cachoeiro de Itapemirim, Cachoeiro de Itapemirim, 2024. Orientador: Cristiano da Silveira Colombo. Disponível em: <<https://repositorio.ifes.edu.br/handle/123456789/5522>>.

U.S. National Library of Medicine. *UMLS Semantic Network*. 2025. <<https://uts.nlm.nih.gov/uts/umls/semantic-network/root>>. Acesso em: 2025-09-18.

VASWANI, A. et al. Attention is all you need. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems (NeurIPS 2017)*. Long Beach, CA, USA: Curran Associates Inc., 2017. p. 6000–6010. Disponível em: <<https://arxiv.org/abs/1706.03762>>.

WULFF, P.; KUBSCH, M.; KRIST, C. Natural language processing and large language models. In: WULFF, P.; KUBSCH, M.; KRIST, C. (Ed.). *Applying Machine Learning in Science Education Research: When, How, and Why?* Springer, 2025, (Springer Texts in Education). p. 117–142. ISBN 978-3-031-74226-2. Disponível em: <https://doi.org/10.1007/978-3-031-74227-9_7>.