



INSTITUTO FEDERAL

Espírito Santo

Campus Cachoeiro de Itapemirim

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

TRABALHO DE GRADUAÇÃO

ANGELO ANTONIO LIMA SILVEIRA FILHO

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS
SOBRE O CORPUS SEMCLINBR**

Cachoeiro de itapemirim

2026

ANGELO ANTONIO LIMA SILVEIRA FILHO

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS
SOBRE O CORPUS SEMCLINBR**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Cristiano da Silveira Colombo

Coorientadora: Profa. Dra. Beltrana de Tal

Cachoeiro de itapemirim

2026

(Biblioteca do Campus Cachoeiro de Itapemirim)

X999y

RECLin-PT: extração de relações em notas clínicas em português sobre o corpus SemClinBr/ Angelo Antonio Lima Silveira Filho. – 2026.

82 f: il; 30 cm.

Orientador: Cristiano da Silveira Colombo

Trabalho de Graduação – Instituto Federal do Espírito Santo, Bacharelado em Sistemas de Informação, 2026.

1. Processamento de linguagem natural. 2. Extração de relações. 3. Informática em saúde. 4. Aprendizado de máquina. 5. Língua portuguesa. I. Colombo, Cristiano da Silveira. II. Título. III. Instituto Federal do Espírito Santo.

CDD 000.00

ANGELO ANTONIO LIMA SILVEIRA FILHO

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS
SOBRE O CORPUS SEMCLINBR**

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Aprovado em 01 de Agosto de 2026

COMISSÃO EXAMINADORA

Prof. Dr. Cristiano da Silveira Colombo

Instituto Federal do Espírito Santo
Orientador

Profa. Dra. Beltrana de Tal

Instituto Federal do Espírito Santo
Coorientadora

Profa. Dra. Fulana de Tal

Instituto Federal do Espírito Santo
Examinadora

Prof. Dr. Cicrano de Tal

Instituto Federal do Espírito Santo
Examinador

À minha mãe, meu alicerce de força e superação, que esteve ao meu lado mesmo nos dias em que eu já não tinha vontade de continuar. Que jamais me desamparou diante das dificuldades e, com amor, coragem e fé, tornou-se o meu maior exemplo de vida. Tudo o que sou carrega um pouco da sua força. Aos meus amigos de jornada, que foram âncora e apoio durante todo o processo.

“Citação a ser escolhida.”
(Autor, ano)

RESUMO

O registro eletrônico em saúde concentra grande parte da informação clínica em texto livre, no qual a relação entre conceitos, em especial a negação de achados, é determinante para a correta interpretação. Este trabalho investiga a extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, considerando o espaço de rótulos *negation_of*, *associated_with* e *no_relation*. Como etapa inicial do desenvolvimento do RECLin-PT, um modelo aprimorado de extração de relações clínicas em português, conduz-se um experimento controlado para responder a uma questão de projeto: o pré-treinamento clínico importa para essa tarefa? Propõe-se uma cadeia experimental reproduzível que vai do texto bruto às métricas finais, composta por um *parser* determinístico do formato XML do corpus, análise exploratória das relações, particionamento 80/10/10 em nível de documento, estratificado e congelado para evitar vazamento de dados, e geração controlada de pares candidatos. Sobre essa infraestrutura, dois *encoders* para o português são ajustados variando apenas o *checkpoint* de pré-treino: um de domínio clínico (BioBERTpt) e um de domínio geral (BERTimbau). No conjunto de teste congelado, os dois empatam estatisticamente no F1 de *negation_of* na semente de referência (0,696 contra 0,711; *bootstrap* pareado IC95% $[-0,051; +0,021]$, $p = 0,420$), e esse empate se repete na semente 43, em que o intervalo também inclui o zero (IC95% $[-0,018; +0,057]$, $p = 0,288$). O que não se repete é a *direção* da diferença, que *inverte de sinal* e passa a favorecer o *encoder* clínico. A variação entre sementes de um mesmo modelo supera a diferença entre os modelos, de modo que essa direção não é estável *nessa classe*, ao passo que, no padrão global de acertos, o teste de McNemar tampouco rejeita a hipótese nula em qualquer das sementes. Esses resultados indicam que o RECLin-PT pode ser construído sobre o *encoder* geral, que acompanha o clínico em macro-F1 médio (0,701 contra 0,703) com cerca de 60% dos parâmetros e é cerca de seis vezes mais estável entre reinicializações na métrica-alvo. Sobre esse *encoder* de melhor relação custo-benefício, o RECLin-PT é construído por meio de um filtro de pista lexical calibrado no conjunto de desenvolvimento, que restringe a predição de *negation_of* aos pares cujo primeiro argumento é um gatilho de negação induzido do conjunto de treino. O ganho é estatisticamente significativo sobre os dois *baselines* nas duas sementes, uma vez que as dezesseis comparações pareadas entre execução filtrada e *baseline* apresentam

intervalo de confiança de 95% inteiramente acima de zero, com F1 de `negation_of` entre 0,817 e 0,851 contra a faixa de 0,696 a 0,739 dos *baselines*.

Palavras-chave: Extração de relações. Processamento de linguagem natural clínico. Língua portuguesa. SemClinBr. Aprendizado de máquina.

ABSTRACT

Electronic health records store much clinical information as free text, in which the relationship between concepts, particularly the negation of findings, is decisive for correct interpretation. This work investigates relation extraction between clinical entities in Portuguese over the SemClinBr corpus, considering the label space `negation_of`, `associated_with` and `no_relation`. As the initial stage of developing RECLin-PT, an improved clinical relation extraction model for Portuguese, we run a controlled experiment to answer a design question: does clinical pre-training matter for this task? We propose a reproducible experimental pipeline that goes from raw text to final metrics, comprising a deterministic parser for the corpus XML format, exploratory analysis of relations, a document-level, stratified and frozen 80/10/10 split to prevent data leakage, and controlled candidate-pair generation. On this infrastructure, two Portuguese encoders are fine-tuned changing only the pre-trained checkpoint: a clinical-domain one (BioBERTpt) and a general-domain one (BERTimbau). On the frozen test set, the two are statistically tied on the `negation_of` F1 under the reference seed (0.696 vs. 0.711; paired bootstrap 95% CI $[-0.051, +0.021]$, $p = 0.420$), and this tie also holds under seed 43, where the interval likewise includes zero (95% CI $[-0.018, +0.057]$, $p = 0.288$). What does not hold is the *direction* of the difference, which *flips sign* and comes to favour the clinical encoder. Seed-to-seed variation of a single model exceeds the gap between the models, so that direction is not stable *on that class*, whereas on the overall pattern of correct predictions McNemar’s test likewise fails to reject the null hypothesis under either seed. These results indicate that RECLin-PT can be built on the general encoder, which matches the clinical one in mean macro-F1 (0.701 vs. 0.703) with about 60% of the parameters and is roughly six times more stable across restarts on the target metric. On that best cost-benefit encoder, RECLin-PT is then built by means of a lexical cue filter calibrated on the development set, which restricts `negation_of` predictions to pairs whose first argument is a negation trigger induced from the training set. The gain is statistically significant over both baselines under both seeds, since all sixteen paired comparisons between a filtered run and a baseline yield a 95% confidence interval entirely above zero, with `negation_of` F1 between 0.817 and 0.851 against the 0.696 to 0.739 range of the baselines.

Keywords: Relation extraction. Clinical natural language processing. Portuguese language. SemClinBr. Machine learning.

LISTA DE FIGURAS

Figura 1 – Processo de criação e anotação do corpus SemClinBr	29
Figura 2 – Distribuição dos tipos de relação no SemClinBr.	31
Figura 3 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200), com a janela <code>max_gap</code> assinalada.	31
Figura 4 – Distribuição do número de relações por documento.	32
Figura 5 – Categorias atômicas de entidade mais frequentes (15 primeiras). . .	32
Figura 6 – Distribuição das relações por partição (escala logarítmica), com o percentual de <code>negation_of</code> anotado.	34
Figura 7 – Evolução por época dos dois <i>encoders</i> nas sementes 42 e 43: perda (à esquerda) e F1 no conjunto de validação (à direita). Marcador preenchido indica a época selecionada.	52
Figura 8 – F1 por classe no conjunto de teste: BioBERTpt (clínico) vs. BERTim- bau (geral), semente 42.	53
Figura 9 – Matriz de confusão do BioBERTpt (clínico), normalizada por linha. .	54
Figura 10 – Matriz de confusão do BERTimbau (geral), normalizada por linha. .	55

LISTA DE TABELAS

Tabela 1 – Distribuição dos tipos de relação no corpus parseado.	30
Tabela 2 – Distância em caracteres entre as entidades de cada relação, por tipo.	31
Tabela 3 – Distribuição real das relações por partição (<i>splits</i> congelados, semente 42).	34
Tabela 4 – Pares candidatos gerados por partição ($\text{max_gap}=25$) e distribuição dos rótulos.	36
Tabela 5 – Teto de <i>recall</i> imposto pela janela $\text{max_gap}=25$ por partição.	37
Tabela 6 – Evolução por época no conjunto de validação. * marca a época selecionada (maior macro-F1 na validação), cujo <i>checkpoint</i> produziu as métricas de teste.	51
Tabela 7 – Resultados dos <i>baselines</i> no conjunto de teste ($n=19.210$, semente 42). Negrito indica o melhor valor por coluna.	52
Tabela 8 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ($n=19.210$, semente 42).	55
Tabela 9 – Robustez à semente de treino: métricas de teste por semente, média e amplitude observada.	57
Tabela 10 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ($n=19.210$, semente 43).	57
Tabela 11 – Desempenho na classe <i>negation_of</i> e macro-F1 no conjunto de teste ($n=19.210$) dos quatro <i>baselines</i> , das quatro execuções do RECLin-PT e da regra pura R3. Negrito indica o melhor valor por coluna.	60
Tabela 12 – As dezesseis comparações pareadas entre cada execução do RECLin-PT e cada <i>baseline</i> oficial, no F1 de <i>negation_of</i> sobre o conjunto de teste (<i>bootstrap</i> pareado, 10.000 reamostragens, IC95% por percentis 2,5/97,5).	61

LISTA DE QUADROS

Quadro 1 – Exemplo de geração de candidatos para um trecho do SemClinBr.	36
Quadro 2 – Ambiente experimental e hiperparâmetros compartilhados pelos dois <i>baselines</i> .	39
Quadro 3 – Entrada efetivamente construída para o par <i>gold</i> do Quadro 1.	45
Quadro 4 – SHA-256 das partições congeladas do SemClinBr.	78
Quadro 5 – Marcadores de negação recorrentes no português clínico.	79
Quadro 6 – Parâmetros gerais da preparação dos dados e da avaliação.	81
Quadro 7 – Hiperparâmetros do ajuste fino, idênticos para os dois <i>encoders</i> .	82

LISTA DE ABREVIATURAS

ABNT	Associação Brasileira de Normas Técnicas
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
i2b2	<i>Informatics for Integrating Biology and the Bedside</i>
IC	Intervalo de Confiança
IFES	Instituto Federal do Espírito Santo
MCC	<i>Matthews Correlation Coefficient</i> (Coeficiente de Correlação de Matthews)
n2c2	<i>National NLP Clinical Challenges</i>
NER	<i>Named Entity Recognition</i> (Reconhecimento de Entidades Nomeadas)
NLP	<i>Natural Language Processing</i> (Processamento de Linguagem Natural)
PLN	Processamento de Linguagem Natural
RE	<i>Relation Extraction</i> (Extração de Relações)
SemClinBr	<i>Semantically Annotated Corpus for Portuguese Clinical NLP</i>
TF-IDF	<i>Term Frequency–Inverse Document Frequency</i>
XML	<i>Extensible Markup Language</i>

SUMÁRIO

1	INTRODUÇÃO	16
1.1	Problema de pesquisa	16
1.2	Motivação	17
1.3	Objetivos	18
1.3.1	Objetivo geral	18
1.3.2	Objetivos específicos	19
1.4	Organização do trabalho	20
2	REFERENCIAL TEÓRICO	21
2.1	Processamento de linguagem natural clínico	21
2.2	Extração de entidades e de relações	21
2.3	Abordagens baseadas em regras e a negação clínica	22
2.4	Abordagens baseadas em aprendizado de máquina	22
2.5	Modelos baseados em <i>transformers</i>	22
3	TRABALHOS RELACIONADOS	24
3.1	Recursos e desafios em inglês	24
3.2	Recursos para o português	24
3.3	Posicionamento deste trabalho	26
4	METODOLOGIA	27
4.1	Visão geral do pipeline	27
4.2	Corpus SemClinBr	28
4.3	Parsing e representação canônica	29
4.4	Caracterização do corpus	30
4.4.1	Distribuição dos tipos de relação	30
4.4.2	Distância entre entidades relacionadas	30
4.4.3	Relações por documento e categorias de entidade	32
4.5	Particionamento dos dados	33
4.6	Geração de pares candidatos	34
4.6.1	Teto de recall imposto pela janela	36
4.7	Protocolo de avaliação	37
4.8	Ajuste fino, ambiente experimental e rastreabilidade	38
5	PROPOSTA DO PROTÓTIPO	41

5.1	Visão geral e papel dos <i>baselines</i>	41
5.2	Os dois <i>encoders</i> comparados	42
5.2.1	BioBERTpt — <i>encoder</i> de domínio clínico	42
5.2.2	BERTimbau — <i>encoder</i> de domínio geral	42
5.3	Tratamento do desbalanceamento	43
5.4	Representação de entrada: marcadores de posição	43
5.4.1	O esquema adotado	43
5.4.2	Exemplo	44
5.4.3	O que essa escolha deixa de fora	45
5.5	Construção do RECLin-PT	45
5.5.1	O diagnóstico que motiva o filtro	46
5.5.2	Indução do léxico de gatilhos	46
5.5.3	A regra de rebaixamento	47
5.5.4	Calibração de <code>min_freq</code> no conjunto de desenvolvimento	48
5.5.5	A regra pura como terceiro sistema de referência	49
6	EXPERIMENTOS E RESULTADOS	50
6.1	Configuração experimental	50
6.2	Curvas de treino e seleção de modelo	50
6.3	Resultados no conjunto de teste	52
6.4	Matrizes de confusão	53
6.5	Significância estatística	54
6.6	Robustez à semente de treino	56
6.7	O RECLin-PT no conjunto de teste	59
6.7.1	Desempenho na classe-alvo	59
6.7.2	Significância das dezesseis comparações	60
6.7.3	O que a restrição lexical alcança sozinha	62
7	DISCUSSÃO	63
7.1	Análise dos resultados	63
7.2	O ganho do filtro de pista lexical	65
7.3	A classe <code>associated_with</code>	66
7.4	Limitações	66
7.5	Ameaças à validade	67

7.5.1	Deriva dos <i>offsets</i> de entidade	68
8	CONCLUSÃO	70
8.1	Contribuições	70
8.2	Trabalhos futuros	72
	REFERÊNCIAS	75
	APÊNDICES	77
	APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS	78
	APÊNDICE B – MARCADORES DE NEGAÇÃO DO PORTUGUÊS	
	CLÍNICO	79
	APÊNDICE C – HIPERPARÂMETROS	81

1 INTRODUÇÃO

O registro eletrônico em saúde concentra grande parte da informação clínica sob a forma de texto livre. Notas de evolução, sumários de alta e laudos são redigidos em linguagem natural, com abreviações idiossincráticas, ausência frequente de pontuação padronizada e construções negativas características do discurso médico. Essa riqueza textual, embora valiosa para pesquisa e apoio à decisão, permanece majoritariamente inacessível a consultas estruturadas, o que motiva o desenvolvimento de técnicas de Processamento de Linguagem Natural (PLN) capazes de transformar texto clínico em conhecimento estruturado.

No contexto da língua portuguesa, o avanço dessas técnicas foi historicamente limitado pela escassez de recursos anotados. A disponibilização do corpus **SemClinBr** (OLIVEIRA *et al.*, 2022), primeiro corpus clínico anotado semanticamente para o português, com mil documentos provenientes de múltiplas instituições e especialidades, criou condições para investigar tarefas antes restritas ao inglês, entre elas a extração de relações entre entidades clínicas.

1.1 PROBLEMA DE PESQUISA

A extração de entidades nomeadas identifica menções a conceitos clínicos (sintomas, doenças, achados, procedimentos), mas isoladamente não captura como esses conceitos se articulam no enunciado. Saber que um documento menciona “febre” não é suficiente. É preciso distinguir se a febre está *associada* ao quadro do paciente ou se está sendo *negada* (“paciente afebril”). Esse vínculo é o objeto da **extração de relações** (Relation Extraction, RE).

Este trabalho desenvolve o **RECLin-PT**, um modelo aprimorado de extração de relações em texto clínico em português sobre o corpus SemClinBr. Essa construção se dá em dois momentos, ambos conduzidos aqui. O primeiro responde a uma questão de projeto: *o pré-treinamento clínico importa para a extração de relações em textos médicos em português?* Responder a ela determina sobre qual *encoder*¹ o RECLin-

¹ *Encoder* é a metade codificadora da arquitetura Transformer, que recebe a sequência de entrada e devolve uma representação vetorial contextual de cada *token*, sem gerar texto novo. É o tipo de modelo do BERT e de suas variantes.

PT deve ser construído, e exige comparar dois modelos na *mesma* tarefa variando *somente* o *checkpoint*² de pré-treino. A segunda parte da base assim escolhida é a especializada na relação de negação, produzindo o modelo propriamente dito. O desafio é agravado por dois fatores inerentes ao corpus: o forte desbalanceamento entre as classes de relação e o fato de o SemClinBr anotar apenas relações positivas, exigindo a geração controlada de exemplos negativos.

Convém explicitar desde já o posicionamento assumido. A contribuição deste trabalho não está em propor uma arquitetura inédita, mas em estabelecer a cadeia experimental completa, que vai do texto bruto às métricas com teste de significância pareado. Essa cadeia é usada duplamente, para responder a essa questão e para construir o RECLinPT sobre a base que ela indica, medindo-o sob o mesmo crivo a que os *baselines* foram submetidos. A mesma cadeia permite que trabalhos futuros sobre o corpus sejam comparados em pé de igualdade. Trata-se de uma escolha deliberada de escopo, retomada e desenvolvida na Seção 3.3 e na Seção 5.1.

1.2 MOTIVAÇÃO

A negação clínica é um fenômeno linguístico de alto impacto, uma vez que tratar um achado negado como presente pode inverter completamente a interpretação de um prontuário. Em português, a negação é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”), e há a expectativa difundida de que modelos pré-treinados sobre texto do próprio domínio clínico capturem melhor essas construções do que modelos de domínio geral. Esse ganho, contudo, não é automático. Em inglês, Lin *et al.* (2020) reportam, na detecção de negação clínica, desempenho superior do BERT de domínio geral em relação a variantes submetidas a adaptação de domínio. Para o português, não localizamos avaliação controlada que isole o efeito do pré-treinamento de domínio na extração de relações clínicas. A comparação direta entre *encoders* clínicos e de domínio geral sobre o SemClinBr foi conduzida para o reconhecimento de entidades (ALMEIDA *et al.*, 2026), e não para a etapa de relações (Capítulo 3). Construir esse teste de forma reproduzível, desde o texto bruto até as métricas finais, é em si uma contribuição metodológica, dado que o compartilhamento restrito de modelos

² *Checkpoint* é o arquivo com os pesos de um modelo já pré-treinado, distribuído publicamente e usado como ponto de partida do ajuste fino.

e o detalhamento insuficiente do ajuste fino³ são críticas recorrentes à literatura de PLN biomédico (FRAILE NAVARRO *et al.*, 2023; SHIMAOKA *et al.*, 2026). O teste não se esgota, contudo, em si mesmo. Dele sai a base sobre a qual o RECLin-PT é construído, e é o mesmo protocolo que depois mede o modelo especializado. Isolar esse efeito exige, porém, enunciar a tarefa por inteiro, e não apenas como um detector de negação. Como o SemClinBr anota somente relações positivas, o rótulo `no_relation` precisa ser construído para representar os pares sem vínculo, sem o que a avaliação ficaria restrita ao conjunto já anotado; e `associated_with`, a outra relação positiva do corpus, é mantida como classe própria para que `negation_of` seja decidida contra uma alternativa concreta, e não apenas contra a ausência de relação. Daí a formulação em três classes que os objetivos a seguir enunciam, detalhada na Seção 2.2 e na Seção 4.6. É também o impacto clínico da negação que justifica dirigir a ela, e não ao conjunto das três classes, a especialização que dá origem ao RECLin-PT.

1.3 OBJETIVOS

1.3.1 Objetivo geral

Desenvolver, de forma reprodutível, um *pipeline* determinístico de extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, considerando o espaço de rótulos `negation_of`, `associated_with` e `no_relation`, e, sobre essa infraestrutura, avaliar sob protocolo estatístico rigoroso (macro-F1 e F1 por classe, com teste de significância pareado) se o pré-treinamento de domínio clínico traz ganho para a tarefa, comparando um *encoder* clínico (BioBERTpt) e um de domínio geral (BERTimbau) sob paridade total de implementação; e, a partir da base assim identificada, construir nesta mesma fase o **RECLin-PT**, modelo especializado de extração de relações clínicas em português com foco na classe `negation_of`, avaliado sob o mesmo protocolo e entregue como parte deste trabalho.

³ Ajuste fino (fine-tuning) é o retreinamento de um modelo pré-treinado sobre os dados de uma tarefa específica, partindo dos pesos já aprendidos em vez de uma inicialização aleatória (DEVLIN *et al.*, 2019).

1.3.2 Objetivos específicos

- Construir um *parser* fiel ao formato XML do SemClinBr que produza uma representação canônica determinística do corpus.
- Caracterizar o corpus por meio de análise exploratória, quantificando a distribuição das relações e a distância entre entidades relacionadas.
- Definir uma partição treino/desenvolvimento/teste em nível de documento, estratificada e congelada, de modo a evitar vazamento de dados.
- Implementar um gerador determinístico de pares candidatos compartilhado por todos os modelos, garantindo a comparabilidade dos resultados.
- Ajustar (*fine-tuning*) dois *encoders* para o português na tarefa de extração de relações: um de domínio clínico (BioBERTpt) e um de domínio geral (BERTimbau).
- Garantir paridade total de implementação entre os dois ajustes, mantendo-os sob um único núcleo de código, de modo que difiram apenas no *checkpoint* de pré-treino.
- Comparar os dois *baselines* sob teste de significância pareado (McNemar e *bootstrap* pareado⁴ no F1 de `negation_of`), reportando macro-F1, F1 por classe, MCC e acurácia.
- Avaliar a robustez do resultado à semente de treino, treinando ambos os modelos com uma segunda inicialização e repetindo todo o protocolo estatístico.
- Identificar, a partir dessa comparação, a melhor base sobre a qual desenvolver o RECLin-PT.
- Construir o RECLin-PT a partir do *encoder* identificado como base mais adequada, com adaptação direcionada à classe `negation_of`, e avaliá-lo sob o mesmo protocolo estatístico aplicado aos *baselines*.

⁴ O *bootstrap* pareado estima a incerteza de uma diferença de desempenho reamostrando com reposição o mesmo conjunto de teste para os dois modelos, sem supor uma distribuição para a métrica. O procedimento adotado está descrito na Seção 4.7.

1.4 ORGANIZAÇÃO DO TRABALHO

O Capítulo 2 apresenta os fundamentos de PLN clínico, extração de relações e modelos baseados em transformers. O Capítulo 3 discute trabalhos relacionados, com ênfase em recursos para o português. O Capítulo 4 descreve o corpus, o *pipeline* de processamento, a geração de pares candidatos, o ajuste fino dos *encoders* e o protocolo de avaliação. O Capítulo 5 detalha a proposta de modelo. O Capítulo 6 reporta os experimentos e resultados. O Capítulo 7 analisa limitações e ameaças à validade, e o Capítulo 8 sintetiza as contribuições e aponta trabalhos futuros.

2 REFERENCIAL TEÓRICO

Este capítulo reúne os fundamentos necessários à compreensão do trabalho: o processamento de linguagem natural aplicado a textos clínicos, a tarefa de extração de relações, as abordagens baseadas em regras e em aprendizado, e os modelos de linguagem baseados em transformers.

2.1 PROCESSAMENTO DE LINGUAGEM NATURAL CLÍNICO

O PLN clínico ocupa-se da análise automática de textos produzidos no cuidado em saúde, como notas de evolução, sumários de alta e laudos. Esses textos apresentam características que os distinguem da linguagem geral: vocabulário técnico, abreviações não padronizadas, telegrafismo (omissão de elementos gramaticais) e prevalência de construções negativas e de incerteza. Tais propriedades tornam a transferência direta de ferramentas treinadas em domínio aberto pouco eficaz, motivando recursos e modelos específicos do domínio.

2.2 EXTRAÇÃO DE ENTIDADES E DE RELAÇÕES

A extração de informação em texto clínico costuma ser decomposta em duas tarefas encadeadas. A primeira, **reconhecimento de entidades nomeadas** (Named Entity Recognition, NER), delimita trechos do texto que mencionam conceitos de interesse e lhes atribui um tipo semântico. A segunda, **extração de relações** (RE), determina se um par de entidades mantém uma relação e de que tipo. Formalmente, dado um par ordenado de entidades (e_1, e_2) em um documento, a RE pode ser modelada como um problema de classificação que associa ao par um rótulo dentro de um conjunto pré-definido.

Neste trabalho o espaço de rótulos é `negation_of`, `associated_with` e `no_relation`. O rótulo `no_relation` é fundamental. Como a anotação de corpora registra apenas relações positivas, todo par de entidades não anotado deve ser tratado como ausência de relação, o que introduz um forte desbalanceamento de classes.

2.3 ABORDAGENS BASEADAS EM REGRAS E A NEGAÇÃO CLÍNICA

Abordagens baseadas em regras codificam conhecimento linguístico explícito. Em detecção de negação clínica, o algoritmo **NegEx** (CHAPMAN *et al.*, 2001) tornou-se referência. A partir de um léxico de gatilhos de negação e de janelas de contexto, ele classifica achados como negados ou afirmados. Sua simplicidade e eficácia derivam do fato de a negação clínica ser altamente lexicalizada. Em português, gatilhos como “não”, “sem”, “nega” e “ausência de”, além de adjetivos que embutem negação morfológicamente (“afebril”, “anictérico”), sustentam estratégias análogas (Apêndice B). A alta lexicalização sugere que o sinal de negação possa estar acessível mesmo a modelos não especializados no domínio clínico, hipótese que este trabalho testa diretamente.

2.4 ABORDAGENS BASEADAS EM APRENDIZADO DE MÁQUINA

Métodos aprendidos estimam, a partir de exemplos rotulados, a associação entre características do par de entidades e o rótulo da relação. Modelos lineares como a regressão logística, alimentados por características léxicas (por exemplo, representações TF-IDF do texto entre as entidades) e estruturais (tipos das entidades, distância, direção), oferecem um compromisso entre interpretabilidade e desempenho e são frequentemente empregados como *sanity check* antes de modelos mais custosos. Sua principal limitação é a representação de palavras como unidades independentes, incapaz de capturar dependências de longo alcance e contexto, limitação que motivou a transição da área para modelos contextuais.

2.5 MODELOS BASEADOS EM TRANSFORMERS

A arquitetura Transformer (VASWANI *et al.*, 2017), baseada em mecanismos de atenção, viabilizou modelos de linguagem pré-treinados que produzem representações contextuais das palavras. O **BERT** (DEVLIN *et al.*, 2019) popularizou o paradigma de pré-treinamento seguido de ajuste fino (fine-tuning) para tarefas específicas. Para o português, os candidatos naturais à extração de relações clínicas dividem-se entre modelos de **domínio geral** e modelos **adaptados ao domínio clínico**. No primeiro grupo está o **BERTimbau** (SOUZA; NOGUEIRA; LOTUFO, 2020), pré-treinado no

corpus brWaC¹ e hoje a referência de domínio geral para a língua; nele também se enquadram modelos multilíngues como o **XLM-R** (CONNEAU *et al.*, 2020), que trocam especialização por cobertura ampla de idiomas. No segundo grupo está o **BioBERTpt** (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e textos biomédicos em português brasileiro. É o contraste entre esses dois grupos que estrutura a proposta deste trabalho, que compara o BioBERTpt ao BERTimbau sob paridade total de implementação; o XLM-R permanece como alternativa de base ampla, relevante ao panorama, mas fora do escopo experimental aqui delimitado.

¹ O brWaC (Brazilian Portuguese Web as Corpus) é um corpus de larga escala construído a partir de páginas web em português brasileiro, sem restrição de domínio.

3 TRABALHOS RELACIONADOS

Este capítulo situa o trabalho em relação a recursos e estudos de extração de informação clínica, com ênfase na língua portuguesa.

3.1 RECURSOS E DESAFIOS EM INGLÊS

A extração de relações clínicas consolidou-se em língua inglesa em torno de campanhas de avaliação como as séries Informatics for Integrating Biology and the Bedside (i2b2) e National NLP Clinical Challenges (n2c2) (UZUNER *et al.*, 2011), que disponibilizaram corpora anotados e tarefas compartilhadas para problemas como relações entre medicamentos, dosagens e efeitos adversos. Esses esforços estabeleceram protocolos de avaliação e evidenciaram a importância de tratar adequadamente o desbalanceamento de classes e o vazamento de dados entre partições, preocupações transpostas para este trabalho. O vazamento é endereçado pelo particionamento em nível de documento (Seção 4.5), e o desbalanceamento, pela geração controlada de pares candidatos e pelo tratamento explícito da assimetria de classes que dela resulta (Seção 4.6).

Quanto aos modelos, o **BioBERT** (LEE *et al.*, 2020) demonstrou os ganhos da adaptação de domínio biomédico em inglês, estabelecendo o precedente que motiva a questão investigada nesta monografia. Quanto à representação de entrada, a delimitação do par por marcadores de entidade inseridos no próprio texto (SOARES *et al.*, 2019) tornou-se a técnica padrão para extração de relações com modelos baseados em BERT, e é a adotada aqui (Seção 5.4).

3.2 RECURSOS PARA O PORTUGUÊS

O desenvolvimento de PLN clínico em português foi por muito tempo limitado pela ausência de corpora anotados de acesso controlado. O **SemClinBr** (OLIVEIRA *et al.*, 2022) preencheu parte dessa lacuna ao disponibilizar mil documentos clínicos anotados semanticamente, acompanhados de dicionários de abreviações e de pistas de negação. É o corpus central deste trabalho.

No plano dos modelos, o **BioBERTpt** (SCHNEIDER *et al.*, 2020) adaptou o paradigma de modelos de linguagem contextuais ao domínio clínico e biomédico em português brasileiro, demonstrando ganhos em reconhecimento de entidades nomeadas clínicas em relação a modelos de domínio geral. O **BERTimbau** (SOUZA; NOGUEIRA; LOTUFO, 2020), por sua vez, é a referência de domínio geral para o português, pré-treinado no corpus brWaC. Modelos multilíngues como o XLM-R (CONNEAU *et al.*, 2020) oferecem uma alternativa de base ampla, útil como ponto de comparação futuro.

Quanto às tarefas efetivamente atacadas em português, o levantamento aqui conduzido aponta concentração fora da extração de relações. Uma revisão sistemática de 28 estudos de modelos de linguagem em português voltados à saúde, publicados entre janeiro de 2020 e novembro de 2024, inventaria as tarefas tratadas, a saber, classificação (16 modelos), reconhecimento de entidades nomeadas (8), modelagem de tópicos, resposta a perguntas, geração de texto e agentes conversacionais. A extração de relações não figura nesse inventário (SHIMAOKA *et al.*, 2026). O desequilíbrio não é exclusivo do português. Uma revisão de 94 estudos de extração de informação em texto clínico registra 63 dedicados a reconhecimento de entidades contra 13 dedicados a extração de relações (FRAILE NAVARRO *et al.*, 2023). O trabalho de extração de relações em texto clínico em português aqui localizado (SILVA *et al.*, 2023) anota um corpus próprio de oncologia em português brasileiro e menciona três *encoders* candidatos (BERT multilíngue, BioBERTpt e BERTimbau), mas não reporta comparação entre eles e resolve a etapa de relações com uma rede BiLSTM, sem teste de significância; o efeito do pré-treinamento de domínio sobre a extração de relações, portanto, não é isolado ali.

É digno de nota que os ganhos relatados para o BioBERTpt foram medidos em NER, e não em extração de relações. O modelo é avaliado em dois corpora de narrativas clínicas na tarefa de reconhecimento de entidades (SCHNEIDER *et al.*, 2020). O BERTimbau, por sua vez, é avaliado em similaridade textual, inferência textual e reconhecimento de entidades, todas tarefas de domínio geral (SOUZA; NOGUEIRA; LOTUFO, 2020). A comparação direta entre os dois sobre o SemClinBr, sob protocolo de treinamento unificado, foi conduzida para o reconhecimento de entidades (ALMEIDA *et al.*, 2026), e não para a extração de relações. Não localizamos, para o português,

trabalho que verifique se a vantagem do pré-treinamento clínico se transfere para a extração de relações, lacuna que este trabalho endereça.

3.3 POSICIONAMENTO DESTE TRABALHO

Enquanto os trabalhos em português localizados na Seção 3.2 concentram-se em classificação e NER, e o de extração de relações não isola o efeito do *checkpoint* de pré-treino, este trabalho aborda a etapa subsequente de extração de relações sobre o SemClinBr e, como ponto de partida do RECLin-PT, *testa* de forma controlada se o ganho do pré-treinamento clínico observado em NER se transfere para a extração de relações, com atenção particular à negação clínica. A contribuição não está em propor uma arquitetura inédita, mas em estabelecer, de maneira reproduzível e estatisticamente fundamentada, uma cadeia completa, do texto bruto às métricas com teste de significância pareado, que sirva de referência comparável para trabalhos futuros sobre o mesmo corpus, e em responder a uma questão de projeto que não localizamos endereçada, para o português, sob comparação controlada.

4 METODOLOGIA

Este capítulo descreve o corpus, o *pipeline* de processamento, a estratégia de particionamento, a geração de pares candidatos, o ajuste fino dos *encoders* e o protocolo de avaliação. Todas as etapas foram projetadas sob a premissa de **reprodutibilidade**: ordenação determinística das saídas, serialização fixa, semente aleatória registrada e verificação por hashes SHA-256.

4.1 VISÃO GERAL DO PIPELINE

Entende-se por *pipeline* de PLN uma sequência encadeada de etapas em que a saída de cada estágio é a entrada do seguinte, de modo que o dado bruto é progressivamente transformado até a métrica final. Estruturar o trabalho como um *pipeline* explícito tem duas vantagens: isola a responsabilidade de cada etapa (facilitando o teste e a auditoria isolados) e torna o caminho completo **reproduzível**, pois cada estágio é determinístico e seus artefatos podem ser verificados de forma independente. As etapas deste trabalho, na ordem em que são executadas, são:

1. **Parsing (XML bruto → dataset.jsonl)**. O *parser* converte cada documento XML do SemClinBr em um registro canônico JSONL (texto, entidades e relações). É necessário porque o formato XML original, fiel à anotação, não é prático para as etapas seguintes; a representação canônica unifica o acesso ao corpus.
2. **Particionamento (dataset.jsonl → *splits*)**. O conjunto é dividido em treino, desenvolvimento e teste em nível de documento. É necessário para separar dados de ajuste dos de avaliação sem vazamento (Seção 4.5).
3. **Geração de pares candidatos (*splits* → candidatos rotulados)**. Como o corpus só anota relações positivas, esta etapa constrói os exemplos negativos (*no_relation*), produzindo o espaço de classificação completo (Seção 4.6).
4. **Marcação de entidades (candidatos → texto marcado)**. Cada par candidato é transformado na *string* de entrada do *encoder*, que consiste em uma janela de texto em torno do par, com as duas entidades delimitadas por marcadores

(Seção 5.4 do Capítulo 5). É necessária para informar ao modelo *quais* trechos da janela formam o par sob análise e qual deles é o primeiro argumento da relação.

5. **Ajuste fino (texto marcado → modelo treinado).** Cada *encoder* é ajustado sobre os candidatos marcados da partição de treino, com seleção de modelo pelo desempenho na partição de desenvolvimento. É a etapa que produz o classificador empregado no estágio seguinte; o ambiente e os hiperparâmetros estão na Seção 4.8, e a representação de entrada e a paridade entre os dois *encoders*, no Capítulo 5.
6. **Classificação (texto marcado → predições).** Cada *baseline* ou modelo atribui um rótulo do conjunto {negation_of, associated_with, no_relation} a cada candidato (Capítulo 5).
7. **Avaliação (predições → métricas).** As predições são comparadas ao *gold* para produzir macro-F1, F1 por classe, MCC e acurácia, com testes pareados entre os modelos (Seção 4.7).

O **determinismo** é garantido em *todas* as etapas, condição para que os *hashes* SHA-256 dos artefatos sejam estáveis entre execuções: a serialização JSONL é fixada byte a byte (`ensure_ascii=False`, `sort_keys=True`, quebras de linha LF); a ordenação das saídas é explícita (documentos por `doc_id`, candidatos por `(start, end, id)`); a semente do particionamento é fixada em 42, e a semente de treino é registrada em cada artefato de resultado. As seções seguintes detalham cada etapa. A Figura 1 (Seção 4.2) situa a origem do dado de entrada, ilustrando o processo de criação e anotação do SemClinBr que antecede o *pipeline* aqui descrito.

4.2 CORPUS SEMCLINBR

O trabalho utiliza o corpus SemClinBr (OLIVEIRA *et al.*, 2022)¹, composto por mil documentos clínicos em português anotados com entidades e relações. O corpus é distribuído sob licença restrita, mediante solicitação formal, e seus arquivos XML originais são tratados como **imutáveis** ao longo do *pipeline*. As relações anotadas

¹ Repositório do corpus e formulário de requisição de acesso em github.com/HAILab-PUCPR/SemClinBr.

no corpus público utilizado pertencem a dois tipos, *associated_with* e *negation_of*, sobre os quais se constrói o espaço de rótulos da tarefa. A Figura 1 ilustra o processo de criação e anotação do corpus.




Figura 1 – Processo de criação e anotação do corpus SemClinBr

Fonte: Oliveira et al. (2022).

4.3 PARSING E REPRESENTAÇÃO CANÔNICA

Um *parser* converte cada arquivo XML em um registro canônico no formato JSONL², com identificador do documento, texto, lista de entidades (tipo e *offsets*) e lista de relações. O *parser* é *fiel ao XML*, ou seja, não normaliza tipos de entidade ou de relação, e deixa tais decisões para etapas posteriores. A única transformação aplicada ao texto é o colapso de quebras de linha ($\backslash r \backslash n$, $\backslash r$, $\backslash n$) em espaço único, necessário para manter o alinhamento dos *offsets* de anotação.

Por se tratar de um corpus com inconsistências de anotação conhecidas, o *parser* executa verificações de sanidade (correspondência entre o texto extraído por *offset* e o atributo anotado, validade dos intervalos e integridade referencial das relações) e, quando possível, corrige automaticamente pequenos deslocamentos de *offset* (± 1 e ± 2 caracteres). As inconsistências são acumuladas em um log de avisos em vez de interromperem o processamento.

² JSONL (JSON Lines) é um formato textual em que cada linha do arquivo é um objeto JSON independente, o que permite ler e gravar grandes conjuntos registro a registro.

4.4 CARACTERIZAÇÃO DO CORPUS

A análise exploratória (Exploratory Data Analysis, EDA) foi conduzida sobre a representação canônica do corpus, totalizando 1 000 documentos, 45 508 entidades (média de 45,5 por documento) e 11 458 relações (média de 11,5 por documento). A mediana é de 10 relações por documento, o percentil 90 é de 24 e o máximo observado é de 65; 46 documentos (4,60%) não possuem nenhuma relação anotada. Essa caracterização quantifica a distribuição das relações, a distância entre entidades relacionadas e as categorias de entidade, fornecendo subsídio empírico para as decisões de projeto das etapas seguintes.

4.4.1 Distribuição dos tipos de relação

A Tabela 1 e a Figura 2 mostram o forte desbalanceamento entre os dois tipos de relação anotados, com predominância de `associated_with` (85,98%) sobre `negation_of` (14,02%). Esse desequilíbrio motiva tanto a escolha do macro-F1 como métrica principal quanto o tratamento explícito de classes nos modelos aprendidos.

Tabela 1 – Distribuição dos tipos de relação no corpus parseado.


Tipo de relação	N	%
<code>negation_of</code>	1.606	14,02
<code>associated_with</code>	9.852	85,98
Total	11.458	100,00

Fonte: elaborado pelo autor a partir do SemClinBr (`data/processed/dataset.jsonl`).

4.4.2 Distância entre entidades relacionadas

A Tabela 2 e a Figura 3 indicam que as relações ocorrem entre entidades próximas, com mediana da distância de poucos caracteres e percentil 95 que não ultrapassa algumas dezenas (`associated_with`: média 11,8, mediana 4, p95 43; `negation_of`: média 3,5, mediana 1, p95 15). O contraste entre os dois tipos é o achado relevante. A negação é praticamente adjacente, pois em 75% dos casos a distância é de um único caractere, enquanto a associação se distribui por uma cauda bem mais longa. Essa assimetria fundamenta a escolha da janela máxima (`max_gap=25`) na geração de

Figura 2 – Distribuição dos tipos de relação no SemClinBr.




Fonte: elaborado pelo autor (scripts/make_tcc_eda.py).

pares candidatos, discutida na Seção 4.6.1. Uma janela estreita preserva quase toda a classe-alvo e limita a explosão combinatória de negativos, ao custo de um teto de *recall* concentrado em *associated_with*.

Tabela 2 – Distância em caracteres entre as entidades de cada relação, por tipo.

Tipo	N	média	p25	p50	p75	p90	p95
negation_of	1.606	3,5	1	1	1	11	15
associated_with	9.852	11,8	1	4	10	25	43

Fonte: elaborado pelo autor a partir do SemClinBr (data/processed/dataset.jsonl).


Figura 3 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200), com a janela *max_gap* assinalada.

Fonte: elaborado pelo autor (scripts/make_tcc_eda.py).

4.4.3 Relações por documento e categorias de entidade


A Figura 4 apresenta a distribuição do número de relações por documento, e a Figura 5, as categorias de entidade mais frequentes (após decomposição das anotações multirótulo separadas por "|"). As categorias predominantes refletem a natureza telegráfica e abreviada do texto clínico: Abbreviation (12592), Finding (6827), Therapeutic or Preventive Procedure (4759) e Sign or Symptom (4616). Vale notar a presença expressiva da categoria Negation (2646), coerente com a importância do fenômeno de negação tratado neste trabalho.

Figura 4 – Distribuição do número de relações por documento.



Fonte: elaborado pelo autor (scripts/make_tcc_eda.py).

Figura 5 – Categorias atômicas de entidade mais frequentes (15 primeiras).



Fonte: elaborado pelo autor (scripts/make_tcc_eda.py).

4.5 PARTICIONAMENTO DOS DADOS

A partição segue a razão 80/10/10 em **nível de documento**, e não de relação. Essa escolha previne o vazamento de dados, pois relações de um mesmo documento compartilham vocabulário e trechos repetidos, e dividi-las entre partições diferentes inflaria artificialmente as métricas de teste. A partição é **estratificada** pela presença das classes `negation_of` e `associated_with` em cada documento, por meio do algoritmo de estratificação multirrótulo de Sechidis, Tsoumakas e Vlahavas (2011), de modo a garantir representação estável da classe minoritária em todas as partições.

A partição é gerada com semente fixa (42) e **congelada**. Os arquivos de treino, desenvolvimento e teste e seus respectivos *hashes* SHA-256 são versionados (Apêndice A), evitando que comparações entre execuções sejam confundidas com variação de amostragem. O resultado são 800 documentos de treino, 100 de desenvolvimento e 100 de teste.

A Tabela 3 apresenta a distribuição real das relações entre as partições. O ponto crítico é que a classe minoritária `negation_of`, que representa 14,02% das relações do corpus, permanece bem representada em todas as partições, com proporções de 14,09% no treino, 15,70% na validação e 12,16% no teste. A estratificação atua sobre a *presença* das classes em cada documento, e não sobre a contagem de relações. Com isso, ela garante que nenhuma partição fique sem exemplos da classe rara, mas não iguala percentuais; daí a variação de cerca de três pontos percentuais observada. Essa garantia é o que importa para o protocolo, uma vez que um particionamento puramente aleatório poderia, por azar de amostragem, sub-representar `negation_of` no conjunto de teste, comprometendo a estabilidade da estimativa de F1 dessa classe. Com 152 relações `negation_of` no teste, a estimativa permanece interpretável, ainda que com incerteza amostral relevante, razão pela qual todas as comparações do Capítulo 6 são acompanhadas de teste pareado e intervalo de confiança, e não apenas do valor pontual.

A Figura 6 apresenta a mesma informação em barras agrupadas (escala logarítmica), com o percentual de `negation_of` de cada partição anotado na legenda. A leitura visual reforça o ponto anterior. A classe rara está presente em volume comparável nas três


Tabela 3 – Distribuição real das relações por partição (*splits* congelados, semente 42).

Partição	Documentos	associated_with	negation_of	Total relações	% negation_of
Treino	800	7.922	1.299	9.221	14,09
Validação	100	832	155	987	15,70
Teste	100	1.098	152	1.250	12,16
Total	1.000	9.852	1.606	11.458	14,02

Fonte: elaborado pelo autor (data/splits/MANIFEST.json).

partições, mas sua fração não é constante, e a partição de teste é justamente a de menor proporção.

Figura 6 – Distribuição das relações por partição (escala logarítmica), com o percentual de *negation_of* anotado.



Fonte: elaborado pelo autor (scripts/make_tcc_eda.py).

4.6 GERAÇÃO DE PARES CANDIDATOS

O SemClinBr anota apenas relações *positivas*. Cada relação registrada indica que existe vínculo entre duas entidades, mas a ausência de anotação não é, por si, um exemplo negativo explícito. Avaliar um classificador no espaço {*negation_of*, *associated_with*, *no_relation*} exige, portanto, **construir** os exemplos negativos. Treinar ou avaliar apenas com os pares anotados produziria um classificador binário sobre as duas classes positivas, incapaz de operar em um cenário real, em que o sistema recebe *todos* os pares de entidades de um documento e precisa decidir, para cada um, se há

relação e de que tipo. A classe `no_relation` é o que torna a tarefa aplicável fora do conjunto anotado.

A geração é feita pela função `iter_candidate_pairs` (`src/candidates.py`), compartilhada por todos os modelos e *baselines*, condição necessária para que os resultados fiquem na mesma régua estatística. Para cada documento, ela percorre todos os **pares ordenados** de entidades (e_1, e_2) , com $e_1 \neq e_2$. A ordem importa, uma vez que a direção é relevante para a negação. Em seguida, descarta os pares cuja distância em caracteres exceda a janela máxima (`max_gap=25`) e os pares entre documentos distintos, e atribui o rótulo. Se o par ordenado (e_1, e_2) coincide com uma relação anotada, ele recebe o tipo *gold*; caso contrário, recebe `no_relation`. A emissão segue ordenação determinística por $(start, end, id)$, de modo que o conjunto de candidatos e o *hash* das predições sejam estáveis entre execuções.

Em resumo, o gerador respeita cinco propriedades. **(i) Ordenação determinística:** os pares são emitidos sempre na mesma ordem por $(start, end, id)$ de e_1 e depois de e_2 , requisito do qual depende a estabilidade das predições entre execuções. **(ii) Sem cruzamento entre documentos:** nunca se forma um par com entidades de documentos distintos, pois o documento é a unidade de processamento. **(iii) Janela respeitada:** apenas pares cuja distância em caracteres (entre o fim de e_1 e o início de e_2) seja $\leq \text{max_gap} = 25$ são gerados. **(iv) Sem autopares:** nunca se forma o par (e, e) de uma entidade consigo mesma ($e_1 \neq e_2$), nem entre entidades com *span* idêntico. **(v) Conferência com o *gold*:** um par presente nas relações anotadas do documento recebe o tipo real (`associated_with` ou `negation_of`), e um par ausente recebe `no_relation` (amostragem negativa).

A Quadro 1 ilustra o processo em um trecho real do corpus. A relação anotada é $16 \rightarrow 52 = \text{negation_of}$ (a entidade “NÃO ESPECIFICADA” nega “OSTEOMIELITE”). Das seis combinações ordenadas possíveis entre as três entidades próximas, apenas o par $(16, 52)$ casa com o *gold*; os outros cinco tornam-se `no_relation`. A representação de entrada para os modelos contextuais delimita o par com marcadores de posição, por exemplo `[E1] OSTEOMIELITE [/E1] [E2] NÃO ESPECIFICADA [/E2]` (Seção 5.4).

A Tabela 4 reporta o resultado do procedimento nas três partições: 152686 candi-

Quadro 1 – Exemplo de geração de candidatos para um trecho do SemClinBr.

Entidades: 16=“OSTEOMIELEITE” (*Disease or Syndrome*), 52=“NÃO ESPECIFICADA” (*Negation*), 17=“INTUBADO” (*Finding*). Relação *gold*: 16 → 52 = *negation_of*.

Par ordenado	Rótulo gerado
16 → 52	<i>negation_of</i> (casa com o <i>gold</i>)
16 → 17	<i>no_relation</i>
52 → 16	<i>no_relation</i> (direção inversa do <i>gold</i>)
52 → 17	<i>no_relation</i>
17 → 16	<i>no_relation</i>
17 → 52	<i>no_relation</i>

Fonte: elaborado pelo autor (`src/candidates.py`).

dados de treino, 19064 de validação e 19210 de teste. A consequência direta é um conjunto de teste fortemente desbalanceado. Dos 19210 pares candidatos, 18062 (94,02%) pertencem à classe *no_relation*, enquanto *associated_with* e *negation_of* somam, respectivamente, 996 e 152 instâncias. Esse desbalanceamento de $\approx 16:1$ é intrínseco à tarefa, e não um artefato evitável, pois decorre da combinatória de pares de entidades. Ele é tratado, nos modelos aprendidos, pela reescala de perda `class_weight="balanced"` (Capítulo 5), e, na avaliação, pela escolha do macro-F1 como métrica principal, que dá peso igual às três classes.

Tabela 4 – Pares candidatos gerados por partição (`max_gap= 25`) e distribuição dos rótulos.

Partição	Candidatos	<i>negation_of</i>	<i>associated_with</i>	<i>no_relation</i>	% <i>no_relation</i>
Treino	152.686	1.255	7.096	144.335	94,53
Validação	19.064	150	763	18.151	95,21
Teste	19.210	152	996	18.062	94,02

Fonte: elaborado pelo autor (`src/candidates.py`); confere com o campo `n_candidates` de `results/baseline_*.json`.

4.6.1 Teto de recall imposto pela janela

A janela `max_gap= 25` impõe um **teto de recall**. Toda relação *gold* cujo par fique a mais de 25 caracteres jamais é gerada como candidato e, portanto, é irrecuperável por qualquer classificador, independentemente da arquitetura. A Tabela 5 quantifica esse

limite por partição, e o ponto essencial é que ele **não se distribui igualmente entre as classes**. Na classe-alvo *negation_of*, a perda é nula ou marginal, pois **nenhuma** das 152 relações do conjunto de teste é descartada, contra 3 de 155 na validação e 27 de 1299 no treino (2,08%), valor coerente com a mediana de distância de 1 caractere observada na EDA. Em *associated_with*, ao contrário, a perda é substantiva, com 100 de 1098 no teste (9,11%), o que puxa o teto agregado do conjunto de teste para 92,00%.

Trata-se de uma **decisão de projeto documentada**, um compromisso entre o *recall* de *associated_with* e a explosão combinatória de candidatos negativos, tomado em favor da classe que este trabalho investiga. A consequência deve ser lida junto com os resultados. O F1 de *associated_with* reportado no Capítulo 6 é medido *sob* esse teto, e não sobre o conjunto completo de relações anotadas. Como o teto é idêntico para todos os modelos, que recebem exatamente os mesmos candidatos, ele limita o desempenho absoluto, mas não afeta a comparação entre eles.

A tabela também reporta, em coluna separada, as *duplicatas de anotação* colapsadas, isto é, relações *gold* repetidas com o mesmo par ordenado e tipo, que o gerador representa uma única vez. Estas **não** reduzem o teto, pois a relação permanece recuperável, sendo apenas redundância de anotação do corpus.

Tabela 5 – Teto de *recall* imposto pela janela *max_gap*= 25 por partição.

Partição	Total ouro	Perdas <i>negation_of</i>	Perdas <i>associated_with</i>	Duplicatas colapsadas	Teto recall (%)
Treino	9.221	27 (2,08%)	806 (10,17%)	37	90,97
Validação	987	3 (1,94%)	68 (8,17%)	3	92,81
Teste	1.250	0 (0,00%)	100 (9,11%)	2	92,00
Total	11.458	30 (1,87%)	974 (9,89%)	42	91,24

Fonte: elaborado pelo autor (*scripts/make_tcc_eda.py*).

4.7 PROTOCOLO DE AVALIAÇÃO

A métrica principal é o **macro-F1**, que atribui peso igual às três classes e, portanto, penaliza modelos que ignoram as classes minoritárias, comportamento desejável dado o desbalanceamento. Classes ausentes nas predições recebem F1 nulo em vez de serem descartadas, conforme recomendado por Forman e Scholz (2010). Reporta-se também o F1 por classe, o micro-F1 (equivalente à acurácia neste cenário de rótulo

único) e o *coeficiente de correlação de Matthews* (MCC), robusto a desbalanceamento. A métrica que responde diretamente à pergunta “o modelo detecta bem a negação?” é o F1 de `negation_of` no conjunto de teste, tratada aqui como **métrica-alvo**.

A comparação entre modelos emprega dois testes pareados complementares, ambos calculados sobre o *mesmo* conjunto de teste a partir das predições salvas, o que elimina a variância entre amostras da comparação e mede exatamente a diferença entre os modelos.

O **teste de McNemar** (DIETTERICH, 1998) olha apenas as instâncias em que os dois modelos discordam quanto ao acerto. Monta-se a tabela de discordâncias (b = o primeiro acerta e o segundo erra; c = o inverso) e, sob a hipótese nula de mesma taxa de acerto, avalia-se $b \sim \text{Binomial}(b+c, 0,5)$ pelo **teste binomial exato**. Ele mede se os padrões de erro *globais* diferem, mas não é específico de uma classe.

O **bootstrap pareado** responde à pergunta específica da classe-alvo. Reamostram-se, com reposição, as instâncias do conjunto de teste 10000 vezes; a cada reamostragem recalcula-se a diferença $F1_A - F1_B$ no F1 de `negation_of`, e reportam-se a diferença média, o intervalo de confiança de 95% (percentis 2,5/97,5) e um valor- p bilateral. Adota-se como critério de decisão a **exclusão do zero pelo IC95%**. Se o intervalo contém zero, a diferença não é considerada estatisticamente significativa ao nível $\alpha = 0,05$.

Por fim, como **análise de robustez à inicialização**, ambos os modelos são treinados também com uma segunda semente (43), e todo o protocolo acima é repetido sobre esses resultados. Essa análise é parte do protocolo, e não um complemento opcional, pois, como o Capítulo 6 mostra, o veredito do teste pareado depende da semente, e reportar uma única execução por modelo daria uma impressão de definitividade que os dados não sustentam.

4.8 AJUSTE FINO, AMBIENTE EXPERIMENTAL E RASTREABILIDADE

As etapas de *parsing*, particionamento, geração de candidatos, análise exploratória e testes de significância executam em CPU; o ajuste fino dos *encoders* é executado em

ambiente com GPU (Google Colab³, Tesla T4), com o mesmo núcleo de código para os dois modelos. O Quadro 2 consolida o ambiente e os hiperparâmetros comuns às duas execuções.

Quadro 2 – Ambiente experimental e hiperparâmetros compartilhados pelos dois *baselines*.

Item	Valor
Ajuste fino (GPU)	Google Colab, Tesla T4
Demais etapas	CPU
Núcleo de implementação	src/relation_extraction.py (idêntico para os dois <i>encoders</i>)
max_gap	25 caracteres
ctx_chars	128 caracteres em torno do par
max_length	128 <i>tokens</i>
<i>Batch</i>	64
Taxa de aprendizado	2×10^{-5} (AdamW), escalonador linear com <i>warmup</i>
Épocas	3
Perda	<i>cross-entropy</i> com <code>class_weight="balanced"</code>
Seleção de modelo	maior macro-F1 no conjunto de validação
Sementes de treino	42 (referência) e 43 (robustez)
<i>Bootstrap</i> pareado	10.000 reamostragens, percentis 2,5/97,5
Comparação pareada	McNemar (binomial exato) + <i>bootstrap</i> pareado

Fonte: elaborado pelo autor (campo `config` de `results/baseline_*.json`).

A rastreabilidade é reforçada por três mecanismos: a semente de treino é registrada em cada arquivo de resultado, junto com a configuração completa; os *splits* congelados são verificados por *hashes* SHA-256 (Apêndice A); e cada métrica reportada tem um arquivo JSON correspondente em `results/`, do qual as tabelas e figuras deste trabalho são geradas por *script*, nunca transcritas à mão.⁴

³ Ambiente hospedado pelo Google para execução de *notebooks* Python com acesso a GPU, disponível em colab.research.google.com.

⁴ O código, os *scripts* de geração das tabelas e figuras e os arquivos de resultado estão em github.com/angeloalsf/RECLin-PT. O corpus SemClinBr não é redistribuído ali, por ter licença própria

5 PROPOSTA DO PROTÓTIPO

Este capítulo descreve a proposta de solução para a extração de relações clínicas. O trabalho integra o desenvolvimento do **RECLin-PT**, um modelo aprimorado de extração de relações em texto clínico em português. Como etapa inicial dessa construção, conduz-se um **experimento controlado de *baselines*** que responde a uma pergunta de projeto anterior a qualquer aprimoramento: *o pré-treinamento clínico importa para a extração de relações em textos médicos em português?* A resposta determina sobre qual *encoder* o RECLin-PT deve ser construído. Respondida essa pergunta, a Seção 5.5 descreve a segunda etapa, em que o RECLin-PT é construído sobre a base assim escolhida por meio de um filtro de pista lexical¹ calibrado no conjunto de desenvolvimento.

5.1 VISÃO GERAL E PAPEL DOS *BASELINES*

Comparam-se dois *encoders* para o português, tratados como *baselines* sob a mesma tarefa: o **BioBERTpt** (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e biomédicas em português, e o **BERTimbau** (SOUZA; NOGUEIRA; LOTUFO, 2020), pré-treinado em texto de domínio geral (brWaC). Os dois compartilham a mesma arquitetura base (BERT) e diferem essencialmente no corpus de pré-treinamento, o que os torna candidatos naturais a um experimento controlado sobre a importância do domínio de pré-treino.

A premissa metodológica central é a **paridade**. A infraestrutura descrita aqui não constitui um modelo com nome próprio, e sim a cadeia que viabiliza a comparação de forma justa. Os dois *baselines* compartilham um único núcleo de implementação (`src/relation_extraction.py`) e são, por construção, idênticos em tudo exceto no *checkpoint* carregado:

- a mesma partição congelada e os mesmos pares candidatos (Capítulo 4), o que coloca os dois sob o mesmo teto de *recall* e na mesma régua estatística;

¹ Pista lexical é uma palavra ou expressão cuja simples presença no texto sinaliza um fenômeno linguístico, aqui a negação. O filtro verifica apenas se o primeiro argumento de cada par predito como `negation_of` é uma dessas pistas, sem analisar o restante da sentença.

- a mesma representação de entrada por marcadores de entidade (Seção 5.4);
- a mesma função de perda, *cross-entropy* com `class_weight="balanced"`;
- o mesmo escalonador linear com *warmup* e os mesmos hiperparâmetros de otimização (Quadro 2);
- a mesma semente de treino e o mesmo critério de seleção de modelo, o maior macro-F1 no conjunto de validação.

Trocar um *baseline* pelo outro consiste, literalmente, em mudar a *string* do *checkpoint*. Qualquer diferença observada pode, portanto, ser atribuída ao pré-treinamento, e não a artefatos de implementação. Essa é exatamente a condição para que a pergunta de pesquisa tenha resposta.

5.2 OS DOIS *ENCODERS* COMPARADOS

5.2.1 BioBERTpt — *encoder* de domínio clínico

O **BioBERTpt** (`pucpr/biobertpt-all`)² (SCHNEIDER *et al.*, 2020) é um modelo contextual adaptado ao domínio clínico e biomédico em português brasileiro, com 177,9 milhões de parâmetros. Sua adoção corresponde à expectativa, difundida na literatura e sustentada pelos ganhos relatados em reconhecimento de entidades nomeadas clínicas, de que o pré-treinamento sobre texto do próprio domínio produza representações mais adequadas a tarefas clínicas. É essa expectativa que o experimento coloca à prova.

5.2.2 BERTimbau — *encoder* de domínio geral

O **BERTimbau** (`neuralmind/bert-base-portuguese-cased`)³ (SOUZA; NOGUEIRA; LOTUFO, 2020) é a referência de domínio geral para o português, pré-treinado no corpus brWaC, com 108,9 milhões de parâmetros, cerca de 60% do tamanho do BioBERTpt. Ele entra no experimento como o controle que isola o efeito do domínio de pré-treino, e não como modelo secundário. Se o desempenho for equivalente, o modelo

² *Checkpoint* público em huggingface.co/pucpr/biobertpt-all.

³ *Checkpoint* público em huggingface.co/neuralmind/bert-base-portuguese-cased.

menor é preferível por custo de inferência e de memória, consideração concreta para implantação em ambientes clínicos com recursos limitados.

5.3 TRATAMENTO DO DESBALANCEAMENTO

Uma decisão central, comum aos dois *baselines*, é o uso de `class_weight="balanced"` na função de perda, que reescala o erro de forma inversamente proporcional à frequência de cada classe. Sem esse ajuste, o otimizador minimizaria o erro simplesmente prevendo `no_relation` para quase tudo, dado que essa classe concentra 94,02% dos candidatos de teste. A reescala força o modelo a “pagar” caro por erros nas classes raras, sem descartar dados nem introduzir o não-determinismo de uma subamostragem. Como a mesma estratégia é aplicada aos dois *encoders*, seu efeito é compartilhado e não confunde a comparação.

A seleção de modelo usa o conjunto de validação (macro-F1), com o conjunto de teste reservado a uma única avaliação final. Os hiperparâmetros efetivamente utilizados constam do Apêndice C.

5.4 REPRESENTAÇÃO DE ENTRADA: MARCADORES DE POSIÇÃO

O modelo contextual não recebe o par de entidades de forma abstrata, e sim um recorte do *texto* do documento com o par delimitado por **marcadores de entidade**. A técnica é padrão em extração de relações com modelos baseados em BERT (SOARES *et al.*, 2019). Inserir no próprio texto marcadores que delimitam e_1 e e_2 é mais eficaz do que concatenar representações de *span* isoladas, pois permite que o mecanismo de atenção condicione a codificação de toda a janela ao par sob análise.

5.4.1 O esquema adotado

A função `build_marked_window` (`src/relation_extraction.py`) recorta uma janela de ± 128 caracteres em torno do par (`ctx_chars`) e insere quatro delimitadores, no esquema

[E1] superfície $_{e_1}$ [/E1] ... [E2] superfície $_{e_2}$ [/E2]

Os quatro marcadores são registrados como *tokens*⁴ especiais no *tokenizer* (`add_special_tokens`), e a matriz de *embeddings* do modelo é redimensionada (`resize_token_embeddings`) para lhes dar um vetor dedicado, aprendido durante o ajuste fino.

Três propriedades desse esquema merecem registro explícito, por delimitarem exatamente *que informação* o modelo recebe:

1. **Os marcadores são posicionais, não semânticos.** Eles indicam quais trechos da janela formam o par e qual deles é o primeiro argumento, e nada mais. O **tipo semântico** anotado pelo SemClinBr (`Disease or Syndrome`, `Negation`, `Finding...`) **não é passado ao modelo**, e cabe a ele inferir a natureza de cada entidade a partir da superfície textual e do contexto.
2. **A direção vem da etiqueta, não da ordem.** A inserção é feita por deslocamento de caractere; quando e_2 precede e_1 no texto, a *string* resultante começa por [E2]. A direção da relação, que importa para `negation_of`, é preservada por *qual* marcador envolve *qual* entidade, e não pela ordem em que os marcadores aparecem.
3. **A classificação usa a representação agregada da sequência.** O cabeçote é o de `AutoModelForSequenceClassification`, que projeta a representação agregada da sequência (o *token* [CLS]) nas três classes. Não há extração explícita dos estados ocultos dos marcadores. Eles influenciam a predição por meio da atenção, ao condicionar a codificação da janela inteira ao par delimitado.

Como a mesma representação é aplicada aos dois *encoders*, qualquer efeito dessas escolhas é compartilhado e não confunde a comparação (Capítulo 6).

5.4.2 Exemplo

Aplicado ao trecho do Quadro 1, o par *gold* 16 → 52 produz a entrada reproduzida no Quadro 3. Note que nem `Disease or Syndrome` (tipo de “OSTEOMIELITE”) nem

⁴ *Tokens* são as unidades em que o *tokenizer* divide o texto antes de entregá-lo ao modelo, e podem ser palavras inteiras ou fragmentos de palavra. Os especiais não vêm do texto e recebem um vetor próprio.

Negation (tipo de “NÃO ESPECIFICADA”) aparecem na entrada, pois o modelo vê apenas o texto e os delimitadores.

Quadro 3 – Entrada efetivamente construída para o par *gold* do Quadro 1.

```
... CURATIVO COM ASPECTO LIMPO E SECO. SEGUE EM OBSERVAÇÃO. [E1]
OSTEOMIELOITE [/E1] [E2] NÃO ESPECIFICADA [/E2]. INTUBADO, SOB
VENTILAÇÃO MECÂNICA, MONITORIZAÇÃO CARDÍACA ...
```

Fonte: elaborado pelo autor (saída de `build_marked_window` para o documento 8906 do SemClinBr, `ctx_chars=128`).

5.4.3 O que essa escolha deixa de fora

Registrar o que *não* entra na representação é tão importante quanto descrever o que entra. O SemClinBr anota cada entidade com tipos semânticos da UMLS, frequentemente em **rótulos múltiplos** separados por “|” (por exemplo, `Medical Device|Finding|Abbreviation`). Essa anotação **não chega ao modelo**. Os resultados do Capítulo 6 foram obtidos com marcadores puramente posicionais, e a natureza de cada entidade tem de ser inferida da superfície textual e do contexto.

A anotação de tipo, aliás, não é diretamente aproveitável na forma em que vem. No conjunto de treino ocorrem apenas 89 tipos *atômicos* distintos, mas a combinação multirrótulo faz o número de *strings* de tipo distintas subir para 828, das quais 752 contêm “|”. Injetar essa *string* diretamente no marcador seria contraproducente, pois cada uma das 828 combinações viraria um símbolo praticamente único e mal povoado no treino, prejudicando a generalização. Aproveitá-la exigiria, antes, um esquema de normalização que colapsasse as combinações em um vocabulário pequeno e estável.

Para a pergunta desta etapa, porém, a ausência do tipo é inclusive conveniente. Como nenhum dos dois *encoders* recebe a informação semântica pronta, a comparação mede a capacidade de cada um de *inferi-la* do texto, e é exatamente aí que o pré-treinamento de domínio deveria fazer diferença.

5.5 CONSTRUÇÃO DO RECLIN-PT

Respondida a pergunta de projeto, esta seção descreve a segunda etapa da construção. A especialização é dirigida à classe `negation_of`, pelo critério de criticidade clínica

enunciado na Seção 1.2, e toma a forma de um **filtro de pista lexical** aplicado às predições do *encoder* já ajustado.

5.5.1 O diagnóstico que motiva o filtro

O ponto de partida está nas colunas de precisão e *recall* da classe-alvo. Nas quatro execuções dos *baselines*, o *recall* de *negation_of* varia entre 0,9145 e 0,9342, ao passo que a precisão fica entre 0,5547 e 0,6167 (Tabela 11). O gargalo da classe é, portanto, de **precisão**, e não de cobertura. O modelo localiza o contexto de negação e o atribui ao par errado, produzindo falsos positivos em candidatos que sequer começam por uma expressão de negação. Um ganho nessa classe depende, por esse motivo, de restringir *onde* ela pode ser predita, e não de deslocar a fronteira entre *negation_of* e *associated_with*.

5.5.2 Indução do léxico de gatilhos

Toda relação *negation_of* anotada no SemClinBr tem, como primeiro argumento, uma expressão que marca a negação (“sem”, “nega”, “não”, “ausência”, além das negações morfológicas registradas no Apêndice B). O léxico de gatilhos⁵ empregado pelo filtro (`src/negation_lexicon.py`) é induzido **exclusivamente do conjunto de treino**. Induzi-lo do corpus completo configuraria vazamento de dados, pela mesma razão que motiva o particionamento em nível de documento (Seção 4.5), e comprometeria a leitura de qualquer ganho medido no conjunto de teste.

A indução percorre o *espaço de candidatos* do treino, gerado por `iter_candidate_pairs` sob a mesma janela `max_gap=25` (Seção 4.6), e não o conjunto de relações anotadas. Os dois diferem, uma vez que parte das relações *gold* fica fora da janela e nunca chega a ser candidata (Seção 4.6.1). Como o filtro opera sobre predições feitas no espaço de candidatos, o léxico é induzido desse mesmo espaço, de modo que ambos falem do mesmo objeto. São contadas as formas de superfície de e_1 nos

⁵ Neste método, gatilho é cada forma retida no léxico induzido do treino, e um par começa por um gatilho quando o texto de e_1 , após a normalização descrita adiante, coincide com uma dessas formas. O conceito é operacional e distinto dos marcadores do Apêndice B, que caracterizam o fenômeno linguisticamente e não participam do filtro.

pares candidatos rotulados `negation_of`, e retêm-se aquelas cuja frequência atinge o limiar `min_freq`⁶.

As formas são comparadas sob normalização por decomposição NFKD⁷, remoção de diacríticos, colapso de espaço em branco e *casefold*⁸. A remoção de diacríticos não é cosmética. No corpus, a mesma forma ocorre acentuada e não acentuada (“NÃO” e “NAO”, “AUSÊNCIA” e “AUSENCIA”), e sem essa normalização um único gatilho se partiria em duas formas, cada uma delas abaixo do limiar de frequência por artefato de digitação.

5.5.3 A regra de rebaixamento

A regra de decisão atua sobre predições já produzidas e é de **rebaixamento**. Toda predição `negation_of` cujo primeiro argumento não pertença ao léxico é reescrita como `no_relation`. Nenhuma predição é promovida a `negation_of`, e nenhuma outra classe é tocada.

Dessa assimetria decorrem duas consequências que importam para a leitura dos resultados. A primeira é que o F1 de `associated_with` permanece inalterado em todos os dígitos nas quatro execuções, de modo que o ganho de macro-F1 provém exclusivamente das outras duas classes. A segunda é que o filtro não pode elevar o *recall*, apenas a precisão, e a cobertura do léxico⁹ passa a ser um teto de *recall* da classe-alvo, somado ao teto já imposto pela janela (Seção 4.6.1).

Convém precisar o que esta etapa é e o que ela não é. **Nenhum modelo é retreinado aqui**. Os pesos empregados são os das execuções reportadas no Capítulo 6, e o RECLin-PT resultante **não possui pesos próprios**. Trata-se de um sistema híbrido, em que um componente determinístico restringe o espaço de decisão e o *encoder* já

⁶ `min_freq` é o número mínimo de pares candidatos `negation_of` do treino em que uma forma precisa figurar como e_1 para ser retida no léxico, e o seu valor é calibrado na Seção 5.5.4.

⁷ NFKD (Normalization Form Compatibility Decomposition) é uma das formas de normalização do padrão Unicode, que decompõe cada letra acentuada em letra-base seguida de um diacrítico combinante, o que permite remover o acento descartando este último.

⁸ *Casefold* é a conversão para caixa baixa definida pelo padrão Unicode para comparar textos sem distinguir maiúsculas de minúsculas, de modo que “NEGA” e “nega” passam a ter a mesma forma.

⁹ Cobertura do léxico é a proporção, entre os pares candidatos de uma partição cujo rótulo de referência é `negation_of`, daqueles cujo e_1 normalizado pertence ao léxico.

ajustado escolhe, dentro desse espaço, qual entidade é negada. O filtro tampouco representa um retorno a abordagens puramente léxicas como o NegEx (CHAPMAN *et al.*, 2001), pois ele não decide a relação. Quem decide o alvo da negação continua sendo o classificador contextual, e a Seção 5.5.5 introduz o sistema de referência que mede quanto a restrição léxica alcança sozinha.

5.5.4 Calibração de `min_freq` no conjunto de desenvolvimento

O único parâmetro livre do filtro é o limiar `min_freq`, e a sua escolha é feita **no conjunto de desenvolvimento**, nunca no de teste. O critério foi fixado antes da varredura. Seleciona-se o `min_freq` que maximiza a *média* do F1 de `negation_of` no desenvolvimento sobre as quatro execuções, com empate resolvido pelo menor limiar, que corresponde ao léxico de maior cobertura e, portanto, ao maior teto de *recall*. A varredura sobre $\{1, 2, 3, 5, 10\}$ seleciona `min_freq=3`, com léxico de 11 formas e cobertura de 0,9467 dos pares `negation_of` do desenvolvimento.

Essa escolha de partição é o ponto metodologicamente decisivo da etapa, e o seu custo é mensurável. Uma análise exploratória anterior, conduzida diretamente sobre o conjunto de teste, encontrava ganho monotônico com léxicos cada vez mais restritivos, e o seu melhor valor estava em `min_freq=10`. No conjunto de desenvolvimento, por sua vez, o máximo é *interior* e recai sobre `min_freq=3`, porque a cobertura começa a diminuir antes que o ganho de precisão a compense. A configuração metodologicamente defensável não é, portanto, a que o conjunto de teste premiaria, e a distância entre as duas é exatamente o que a disciplina de calibração custa. Registrar esse custo é parte do argumento, e não um detalhe de implementação, uma vez que é ele que sustenta que o ganho reportado no Capítulo 6 não decorre de ajuste ao conjunto de avaliação. O conjunto de teste foi lido uma única vez por sistema, com a configuração já fechada, conforme o protocolo da Seção 4.7.

A mesma calibração avaliou ainda um sistema combinado, em que a condição de distância da regra descrita a seguir seria aplicada também sobre as predições já filtradas. O limiar vencedor no conjunto de desenvolvimento desliga essa condição, de modo que o sistema combinado colapsa no filtro isolado. Ele não foi, por esse motivo,

levado ao conjunto de teste como sistema separado.

5.5.5 A regra pura como terceiro sistema de referência

A comparação entre dois *encoders* não responde à pergunta que se formula em seguida. O que o modelo contextual acrescenta sobre uma regra fixa? Para respondê-la, define-se um terceiro sistema de referência que dispensa qualquer rede neural e opera somente sobre o mesmo léxico induzido do treino (`scripts/make_rule_baseline.py`). Quatro variantes foram consideradas, todas partindo da condição de que e_1 seja um gatilho do léxico, e sendo *gap* a distância em caracteres entre os *spans*, a mesma grandeza empregada na geração de candidatos:

1. **R1**: todo par cujo e_1 é gatilho recebe `negation_of`.
2. **R2**: R1 restrita ao alvo mais próximo de cada gatilho, um alvo por gatilho.
3. **R3**: R1 restrita aos pares cujo *gap* não excede um limiar.
4. **R4**: R1 sob as duas restrições anteriores simultaneamente.

A variante e o limiar também são escolhidos no conjunto de desenvolvimento, pelo F1 de `negation_of`, com empates resolvidos pela regra de menor índice e depois pelo menor limiar. A escolha recai sobre **R3 com** $\text{gap} \leq 1$, que alcança F1 de 0,6935 no desenvolvimento. A regra nunca prediz `associated_with` e não constitui, por isso, um sistema completo de extração de relações. Ela entra como piso da classe-alvo, e o seu papel é delimitar quanto do ganho do RECLin-PT seria atribuível à restrição lexical isolada.

As predições dos cinco sistemas introduzidos nesta seção são gravadas no **espaço completo** de candidatos da partição, na mesma ordem e com o mesmo *gold* dos arquivos de predição das execuções dos *baselines*. Essa condição é o que permite compará-los sob o mesmo teste pareado aplicado no Capítulo 6, que aborta quando os rótulos de referência de dois sistemas divergem.

6 EXPERIMENTOS E RESULTADOS

Este capítulo reporta os experimentos conduzidos e seus resultados. Os dois *encoders* descritos no Capítulo 5 foram ajustados sobre a mesma partição congelada e avaliados sobre o mesmo conjunto de teste, composto por 19210 pares candidatos (18062 *no_relation*, 996 *associated_with* e 152 *negation_of*), gerados conforme o Capítulo 4. As métricas seguem o protocolo ali descrito.

6.1 CONFIGURAÇÃO EXPERIMENTAL

Cada *encoder* foi ajustado por 3 épocas, com *batch* de 64, taxa de aprendizado 2×10^{-5} (AdamW) e *max_length* de 128 *tokens*, sob *cross-entropy* ponderada por *class_weight="balanced"*. A época reportada é a de maior macro-F1 no conjunto de validação; o conjunto de teste foi avaliado uma única vez, ao final. Os dois modelos foram treinados com a semente de referência 42 e, como análise de robustez, novamente com a semente 43, mantendo, em ambos os casos, todos os demais elementos idênticos (Quadro 2).

O conjunto de teste é fortemente desbalanceado, e a classe *no_relation* concentra 94,02% dos pares. Esse cenário torna o macro-F1 a métrica mais informativa, por penalizar modelos que negligenciam as classes minoritárias, e faz da acurácia uma métrica enganosa isoladamente, dado que um classificador que respondesse sempre *no_relation* acertaria mais de 94% dos candidatos sem qualquer utilidade clínica.

6.2 CURVAS DE TREINO E SELEÇÃO DE MODELO

A Figura 7 apresenta a evolução por época dos dois *encoders* nas duas sementes, e a Tabela 6 traz os mesmos valores em número. Três observações são relevantes.

Primeiro, a **perda de treino cai monotonicamente** nas quatro execuções, enquanto a perda de validação estabiliza ou volta a subir a partir da segunda época, comportamento típico de ajuste fino de *encoders* sobre conjuntos pequenos. Segundo, e mais importante para o protocolo, o **macro-F1 de validação continua subindo** mesmo quando a perda de validação piora. É o caso do BioBERTpt na semente 42, cuja

perda de validação sobe de 0,380 (época 2) para 0,426 (época 3) enquanto o macro-F1 avança de 0,654 para 0,673. Sob forte desbalanceamento, perda e macro-F1 não são intercambiáveis como critério de parada, e selecionar pela perda teria descartado a melhor época em termos da métrica de interesse, razão pela qual a seleção de modelo usa explicitamente o macro-F1 de validação.


Terceiro, as curvas tornam visível a **sensibilidade à semente** dos dois *encoders*, que se manifesta em fases distintas do treino. Na perda de treino, o BERTimbau percorre trajetórias mais próximas entre as duas sementes que o BioBERTpt. Na primeira época do conjunto de validação, contudo, a ordem se inverte. O BERTimbau parte de um F1 de *negation_of* de 0,674 na semente 42 contra 0,525 na semente 43, uma distância de 0,149, ao passo que o BioBERTpt parte de 0,643 e 0,628, distância de apenas 0,015. Ao final das três épocas, porém, é o *encoder* clínico que apresenta a maior amplitude entre sementes (Seção 6.6). A dispersão observada na primeira época não antecipa, portanto, a dispersão das métricas finais, e cada *encoder* manifesta sua instabilidade em um momento diferente do ajuste.

Tabela 6 – Evolução por época no conjunto de validação. * marca a época selecionada (maior macro-F1 na validação), cujo *checkpoint* produziu as métricas de teste.

Modelo	Semente	Época	Perda (treino)	Perda (val.)	Macro-F1 (val.)	F1 <i>negation_of</i> (val.)	Duração (min)
BioBERTpt (clínico)	42	1	0,7265	0,4375	0,631	0,643	67,0
		2	0,4146	0,3800	0,654	0,680	67,1
		3*	0,3064	0,4256	0,673	0,711	67,2
	43	1	0,6609	0,4175	0,598	0,628	62,1
		2	0,3862	0,4108	0,679	0,706	62,1
		3*	0,2835	0,4456	0,683	0,722	62,2
BERTimbau (geral)	42	1	0,6969	0,4830	0,640	0,674	61,1
		2	0,3961	0,4256	0,661	0,688	61,4
		3*	0,2974	0,4505	0,671	0,703	61,3
	43	1	0,7278	0,4323	0,564	0,525	57,4
		2	0,4153	0,4728	0,651	0,656	54,0
		3*	0,3197	0,4686	0,664	0,690	54,1

Fonte: elaborado pelo autor (campo *dev_history* de *results/baseline_*.json*).

Figura 7 – Evolução por época dos dois *encoders* nas sementes 42 e 43: perda (à esquerda) e F1 no conjunto de validação (à direita). Marcador preenchido indica a época selecionada.



Fonte: elaborado pelo autor (scripts/make_tcc_curves.py).

6.3 RESULTADOS NO CONJUNTO DE TESTE

A Tabela 7 consolida os resultados dos dois *baselines* na semente de referência. Os melhores valores por coluna estão em negrito.

Tabela 7 – Resultados dos *baselines* no conjunto de teste ($n = 19.210$, semente 42). Negrito indica o melhor valor por coluna.


Modelo	Macro-F1	F1 _{neg}	F1 _{assoc}	F1 _{no_rel}	MCC	Acurácia
BioBERTpt (clínico)	0,693	0,696	0,442	0,942	0,478	0,894
BERTimbau (geral)	0,698	0,711	0,441	0,941	0,476	0,893

Fonte: elaborado pelo autor (results/baseline*_seed42.json).

Os dois *baselines* apresentam desempenho praticamente indistinguível. O BERTimbau geral atinge macro-F1 de 0,698 e o BioBERTpt clínico, 0,693, uma diferença de 0,004

em favor do *encoder* geral. Na métrica-alvo, o F1 de *negation_of*, a ordenação se mantém, e o BERTimbau geral (0,711) supera marginalmente o BioBERTpt clínico (0,696). As demais colunas, porém, distribuem-se em sentido contrário, uma vez que o *encoder* clínico registra os melhores valores em *associated_with* (0,442 contra 0,441), em *no_relation* (0,942 contra 0,941), no MCC (0,478 contra 0,476) e na acurácia (0,894 contra 0,893). Nenhuma dessas margens excede 0,002, de modo que a tabela não ordena os dois modelos de forma consistente. Ambos alcançam *recall* alto na negação, 0,934 no clínico e 0,914 no geral, com precisão moderada ($\approx 0,55$ – $0,58$), e ambos têm na classe *associated_with* a maior dificuldade (F1 $\approx 0,44$), com alta cobertura mas baixa precisão. A Figura 8 resume o F1 por classe dos dois *baselines*, cujas barras são praticamente coincidentes em todas as classes.

Figura 8 – F1 por classe no conjunto de teste: BioBERTpt (clínico) vs. BERTimbau (geral), semente 42.




Fonte: elaborado pelo autor (`scripts/make_tcc_artifacts.py`).

6.4 MATRIZES DE CONFUSÃO

As Figuras 9 e 10 apresentam as matrizes de confusão dos dois *baselines*, **normalizadas por linha**, de modo que cada célula indica a fração das instâncias de uma classe verdadeira atribuída a cada classe predita. Os valores da diagonal correspondem, assim, ao *recall* por classe. Essa visão complementa o F1 por classe ao revelar *para onde* vão os erros de cada modelo.

Os dois padrões de erro são notavelmente semelhantes, com diagonal forte na negação e na classe majoritária, e o erro dominante remanescente na confusão entre *associated_with* e *no_relation*, coerente com a baixa precisão daquela classe nos dois modelos. A semelhança qualitativa entre as matrizes reforça a leitura de que os dois *encoders* aprendem essencialmente a mesma função para esta tarefa, pois não apenas chegam a números próximos, mas erram nos mesmos lugares.

Figura 9 – Matriz de confusão do BioBERTpt (clínico), normalizada por linha.



Fonte: elaborado pelo autor (`scripts/make_tcc_artifacts.py`).


6.5 SIGNIFICÂNCIA ESTATÍSTICA

A proximidade dos valores pontuais sugere empate, mas a conclusão exige um teste pareado. A Tabela 8 reporta a comparação direta entre os dois *baselines* no conjunto de teste, na semente de referência.

No F1 de *negation_of*, a diferença observada é de apenas $-0,015$ (a favor do BERTimbau geral). Os dois testes, contudo, **não respondem à mesma pergunta**, e a distinção entre eles é necessária para interpretar tanto esta semente quanto a seguinte.

O teste de McNemar incide sobre o *padrão global de acertos*, em todas as três classes. Ele **não rejeita** a hipótese nula de igualdade ($p = 0,479$). Das 1056 instâncias em que

Figura 10 – Matriz de confusão do BERTimbau (geral), normalizada por linha.



Fonte: elaborado pelo autor (scripts/make_tcc_artifacts.py).

Tabela 8 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ($n = 19.210$, semente 42).

Medida	Valor
F1 negation_of — BioBERTpt (A)	0,696
F1 negation_of — BERTimbau (B)	0,711
Diferença observada (A – B)	–0,015
McNemar: b (só A acerta) / c (só B acerta)	540 / 516
McNemar: valor- p (binomial exato)	0,48
<i>Bootstrap</i> pareado: IC95% da diferença	[–0,051; +0,021]
<i>Bootstrap</i> pareado: valor- p	0,4204
Diferença significativa ($\alpha = 0,05$)?	Não

Fonte: elaborado pelo autor (results/significance_biobertpt_vs_bertimbau_seed42.json).

os modelos discordam, 540 favorecem o BioBERTpt e 516 o BERTimbau, assimetria compatível com o acaso. Não há, portanto, diferença mensurável entre os dois *encoders no conjunto dos candidatos*, e a leve vantagem de contagem que se observa aponta para o *encoder* clínico, em sentido oposto ao da métrica-alvo nesta semente e coerente com a distribuição das demais colunas da Tabela 7, vista na Seção 6.3.

O *bootstrap* pareado, por sua vez, incide diretamente sobre a métrica-alvo, o F1 de *negation_of*, e chega ao mesmo veredito. O intervalo de confiança de 95% para a diferença é $[-0,051; +0,021]$, que **inclui o zero**, com valor-*p* de 0,420. **Na classe que este trabalho investiga não há diferença estatisticamente significativa** entre o *encoder* clínico e o geral *nesta semente*. A leitura conjunta é, então, direta. Nenhum dos dois testes detecta diferença entre os *encoders*, nem no agregado dos candidatos nem na classe em que a hipótese do pré-treinamento clínico seria testada. A ressalva de semente permanece relevante, pois a análise a seguir mostra que, embora o veredito de ausência de diferença se repita na semente 43, a *direção* da diferença pontual *nessa classe* não se repete.

6.6 ROBUSTEZ À SEMENTE DE TREINO

Para situar a magnitude da diferença entre os *baselines*, ambos foram treinados com uma segunda semente (43), mantendo todo o restante idêntico. A Tabela 9 consolida as métricas por semente e a amplitude observada.

O contraste entre os dois *encoders* é acentuado. No BioBERTpt, o macro-F1 sobe de 0,693 (semente 42) para 0,713 (semente 43), e o F1 de *negation_of*, de 0,696 para 0,739, uma amplitude de 0,043 atribuível *apenas* à inicialização aleatória do treino. Essa variação entre sementes de um *mesmo* modelo é quase **três vezes maior** que a diferença de 0,015 observada entre o BioBERTpt e o BERTimbau na semente 42. Em outras palavras, o ruído de treino do *encoder* clínico, isoladamente, supera qualquer vantagem que se pudesse atribuir ao domínio de pré-treino.

O BERTimbau, sob a mesma troca de semente, mostra-se sensivelmente mais estável. O macro-F1 passa de 0,698 para 0,704 e o F1 de *negation_of*, de 0,711 para 0,718, uma amplitude de 0,007, cerca de seis vezes menor que a do BioBERTpt na mesma

Tabela 9 – Robustez à semente de treino: métricas de teste por semente, média e amplitude observada.

Modelo	Métrica	Semente 42	Semente 43	Média	Amplitude
BioBERTpt (clínico)	Macro-F1	0,693	0,713	0,703	0,020
	F1 negation_of	0,696	0,739	0,717	0,043
	F1 associated_with	0,442	0,453	0,448	0,012
	F1 no_relation	0,942	0,946	0,944	0,004
BERTimbau (geral)	Macro-F1	0,698	0,704	0,701	0,006
	F1 negation_of	0,711	0,718	0,715	0,007
	F1 associated_with	0,441	0,447	0,444	0,006
	F1 no_relation	0,941	0,945	0,943	0,004

Fonte: elaborado pelo autor (scripts/aggregate_seeds.py → results/summary_by_seed.json).

métrica.

O ponto metodologicamente mais delicado é que a *direção* da diferença também muda. A Tabela 10 aplica à semente 43 exatamente o mesmo protocolo da Seção 6.5.

Tabela 10 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ($n = 19.210$, semente 43).

Medida	Valor
F1 negation_of — BioBERTpt (A)	0,739
F1 negation_of — BERTimbau (B)	0,718
Diferença observada (A – B)	0,020
McNemar: b (só A acerta) / c (só B acerta)	559 / 510
McNemar: valor- p (binomial exato)	0,14
<i>Bootstrap</i> pareado: IC95% da diferença	$[-0,018; +0,057]$
<i>Bootstrap</i> pareado: valor- p	0,2878
Diferença significativa ($\alpha = 0,05$)?	Não

Fonte: elaborado pelo autor (results/significance_biobertpt_vs_bertimbau_seed43.json).

Na semente 43, a ordenação entre os dois *baselines* no F1 de negação **se inverte**. O BioBERTpt clínico passa à frente, com margem de 0,020, e o *bootstrap* pareado sobre essa métrica, que na semente 42 não rejeitava a hipótese nula, tampouco a rejeita

agora (IC95% $[-0,018; +0,057]$, $p = 0,288$). O intervalo continua a incluir o zero, de modo que o que se inverte é o **signal** da diferença pontual, e não o veredito do teste.

Essa inversão é da **métrica-alvo**, e não do padrão global de erro; a distinção entre os dois testes, estabelecida na Seção 6.5, é o que permite enunciá-la sem ambiguidade. O teste de McNemar incide sobre o conjunto dos candidatos, e não sobre a classe investigada. Ele **não rejeita a hipótese nula em nenhuma das duas sementes**. Na semente 43, das 1069 instâncias em que os modelos discordam, 559 favorecem o BioBERTpt e 510 o BERTimbau ($p = 0,142$), contagem levemente favorável ao *encoder* clínico, no mesmo sentido já observado na semente 42 (540 contra 516, $p = 0,479$). A acurácia global acompanha essa direção em ambas (0,894 contra 0,893 na semente 42; 0,902 contra 0,900 na 43), sempre por margens inferiores a 0,003. O que troca de sinal entre as sementes é, portanto, o desempenho na classe *negation_of* especificamente, e não o padrão de acertos dos dois modelos sobre o conjunto de teste.

Esse contraste **não estabelece a superioridade de nenhum dos dois encoders na classe investigada**. O que ele mostra não é a instabilidade do veredito estatístico, que se repete nas duas sementes, mas a instabilidade da própria *direção* da diferença. Sob protocolo, partição e conjunto de teste idênticos, o **signal** dessa diferença se inverte em função apenas da inicialização do treino. No F1 de *negation_of*, a semente 42 aponta para o *encoder* geral e a 43 para o clínico, ambas sobre as mesmas 19210 instâncias, e em nenhuma delas a diferença alcança significância estatística.

O que não atravessa as duas sementes é, portanto, a direção *na métrica-alvo*. O que atravessa é a ausência de diferença mensurável, dado que nem o McNemar nem o *bootstrap* pareado rejeitam a hipótese nula em qualquer delas. A troca de semente não desfaz a comparação entre os dois modelos sobre o conjunto de teste; desfaz a leitura sobre qual dos dois leva vantagem na classe específica em que a hipótese do pré-treinamento clínico seria testada. A isso se soma a **menor previsibilidade** do *encoder* clínico entre reinicializações, com amplitude de 0,043 no F1 de *negation_of* contra 0,007 do geral. Tomada a média das duas sementes, o BioBERTpt fica marginalmente à frente tanto na métrica-alvo (0,717 contra 0,715) quanto em macro-F1 (0,703 contra 0,701), mas por margens de 0,003 e 0,002, inferiores à amplitude entre

sementes de qualquer dos dois modelos, o que torna essa média pouco informativa como estimativa de desempenho esperado. Com duas execuções por modelo, nenhuma leitura estatística de direção deve ser tomada como definitiva; o que os dados sustentam é que a escolha do *checkpoint* de pré-treino tem, nesta tarefa, efeito menor que o da semente de treino.

6.7 O RECLIN-PT NO CONJUNTO DE TESTE

As seções anteriores compararam os dois *baselines* entre si. Esta seção reporta o sistema construído sobre eles, o RECLin-PT, descrito na Seção 5.5, e o terceiro sistema de referência introduzido na Seção 5.5.5. Todos são avaliados sobre o mesmo conjunto de teste de 19210 candidatos, sob a configuração fechada no conjunto de desenvolvimento ($\text{min_freq}=3$, léxico de 11 formas e regra R3 com $\text{gap} \leq 1$), com uma única leitura do teste por sistema.

Convém reiterar que nenhuma das quatro execuções filtradas envolve treino. Elas partem das predições salvas da execução correspondente reportada nas seções anteriores, às quais a regra de rebaixamento é aplicada, de modo que o RECLin-PT compartilha os pesos dos *baselines* e não introduz pesos próprios. A configuração de referência é a que aplica o filtro sobre o BERTimbau, *encoder* indicado pela Seção 6.6 por custo e previsibilidade. O filtro foi aplicado também ao BioBERTpt, nas duas sementes, para verificar que o ganho não depende do *checkpoint* de pré-treino.

6.7.1 Desempenho na classe-alvo

A Tabela 11 consolida os nove sistemas sob as mesmas métricas.

O efeito do filtro é de precisão, como o diagnóstico da Seção 5.5 previa. A precisão de *negation_of* passa da faixa de 0,5547–0,6167 dos *baselines* para 0,7514–0,8059, ao custo de cerca de dois pontos centesimais¹ de *recall*, que cai de 0,9145–0,9342 para 0,8947–0,9145. O F1 da classe sobe, em consequência, de 0,6961–0,7388 para 0,8168–0,8509, e o macro-F1, de 0,6932–0,7128 para 0,7334–0,7506. O ganho de macro-F1

¹ Ponto centesimal é a diferença absoluta de 0,01 em uma métrica expressa entre 0 e 1, análogo ao ponto percentual das métricas expressas em porcentagem.

Tabela 11 – Desempenho na classe *negation_of* e macro-F1 no conjunto de teste ($n = 19.210$) dos quatro *baselines*, das quatro execuções do RECLin-PT e da regra pura R3. Negrito indica o melhor valor por coluna.

Sistema	P _{neg}	R _{neg}	F1 _{neg}	Macro-F1
BioBERTpt (clínico), semente 42	0,5547	0,9342	0,6961	0,6932
BERTimbau (geral), semente 42	0,5816	0,9145	0,7110	0,6977
BioBERTpt (clínico), semente 43	0,6167	0,9211	0,7388	0,7128
BERTimbau (geral), semente 43	0,5915	0,9145	0,7183	0,7035
RECLin-PT sobre BioBERTpt, semente 42	0,7596	0,9145	0,8299	0,7383
RECLin-PT sobre BERTimbau, semente 42	0,7514	0,8947	0,8168	0,7334
RECLin-PT sobre BioBERTpt, semente 43	0,8059	0,9013	0,8509	0,7506
RECLin-PT sobre BERTimbau, semente 43	0,7684	0,8947	0,8267	0,7401
Regra pura R3 ($\text{gap} \leq 1$)	0,6324	0,7697	0,6944	0,5549

Fonte: elaborado pelo autor (`scripts/run_fase2_test.py` → `results/*.preds.json`).

é integralmente atribuível às classes *negation_of* e *no_relation*, dado que o F1 de *associated_with* permanece inalterado em todos os dígitos nas quatro execuções, conforme a regra de rebaixamento faz prever (Seção 5.5).

A regra pura R3 ocupa a última linha da tabela, e o contraste entre as suas duas colunas de F1 merece leitura cuidadosa. Na classe-alvo ela alcança 0,6944, valor da mesma ordem dos quatro *baselines*. Em macro-F1 ela fica em 0,5549, abaixo de todos os demais sistemas, porque nunca prediz *associated_with* e zera o F1 dessa classe. Ela é, portanto, um piso alto para a negação e não um sistema de extração de relações, e é sob essa leitura que entra na comparação seguinte.

6.7.2 Significância das dezesseis comparações

O critério de decisão é o intervalo de confiança de 95% do *bootstrap* pareado sobre o F1 de *negation_of*, o mesmo adotado na Seção 6.5 e definido na Seção 4.7. O teste de McNemar não é informativo entre um sistema e a sua própria versão filtrada. A regra altera predições em uma única direção, de *negation_of* para *no_relation*, mas o rebaixamento pode tanto corrigir um falso positivo quanto desfazer um acerto. O

segundo caso ocorre quando a regra atinge uma predição correta cujo e_1 não pertence ao léxico, e corresponde ao custo de *recall* registrado na subseção anterior. Nas quatro execuções, a tabela de discordâncias é fortemente assimétrica, com dezenas de falsos positivos corrigidos para poucos acertos desfeitos, mas nenhuma das suas duas células é nula. Entretanto, a versão filtrada não é um segundo modelo, e sim uma transformação determinística das predições do primeiro. Toda discordância entre os dois corresponde, portanto, a uma predição rebaixada, e o teste apenas contaria quantos rebaixamentos corrigiram um erro e quantos o introduziram, contagem já refletida na variação de precisão e de *recall* da Tabela 11. Por esse motivo ele é omitido desta seção.

Tabela 12 – As dezesseis comparações pareadas entre cada execução do RECLin-PT e cada *baseline* oficial, no F1 de *negation_of* sobre o conjunto de teste (*bootstrap* pareado, 10.000 reamostragens, IC95% por percentis 2,5/97,5).

Sistema A	Baseline B	F1 A	F1 B	Diferença (A – B) com IC95%
RECLin-PT sobre BioBERTpt, s. 42	BioBERTpt, s. 42	0,8299	0,6961	+0,1338 [+0,0998; +0,1700]
RECLin-PT sobre BioBERTpt, s. 42	BERTimbau, s. 42	0,8299	0,7110	+0,1189 [+0,0789; +0,1613]
RECLin-PT sobre BioBERTpt, s. 42	BioBERTpt, s. 43	0,8299	0,7388	+0,0911 [+0,0473; +0,1356]
RECLin-PT sobre BioBERTpt, s. 42	BERTimbau, s. 43	0,8299	0,7183	+0,1115 [+0,0691; +0,1562]
RECLin-PT sobre BERTimbau, s. 42	BioBERTpt, s. 42	0,8168	0,6961	+0,1207 [+0,0780; +0,1647]
RECLin-PT sobre BERTimbau, s. 42	BERTimbau, s. 42	0,8168	0,7110	+0,1058 [+0,0749; +0,1399]
RECLin-PT sobre BERTimbau, s. 42	BioBERTpt, s. 43	0,8168	0,7388	+0,0780 [+0,0340; +0,1225]
RECLin-PT sobre BERTimbau, s. 42	BERTimbau, s. 43	0,8168	0,7183	+0,0985 [+0,0596; +0,1392]
RECLin-PT sobre BioBERTpt, s. 43	BioBERTpt, s. 42	0,8509	0,6961	+0,1549 [+0,1110; +0,2009]
RECLin-PT sobre BioBERTpt, s. 43	BERTimbau, s. 42	0,8509	0,7110	+0,1399 [+0,0969; +0,1843]
RECLin-PT sobre BioBERTpt, s. 43	BioBERTpt, s. 43	0,8509	0,7388	+0,1121 [+0,0788; +0,1476]
RECLin-PT sobre BioBERTpt, s. 43	BERTimbau, s. 43	0,8509	0,7183	+0,1326 [+0,0874; +0,1781]
RECLin-PT sobre BERTimbau, s. 43	BioBERTpt, s. 42	0,8267	0,6961	+0,1307 [+0,0859; +0,1762]
RECLin-PT sobre BERTimbau, s. 43	BERTimbau, s. 42	0,8267	0,7110	+0,1158 [+0,0767; +0,1556]
RECLin-PT sobre BERTimbau, s. 43	BioBERTpt, s. 43	0,8267	0,7388	+0,0880 [+0,0430; +0,1348]
RECLin-PT sobre BERTimbau, s. 43	BERTimbau, s. 43	0,8267	0,7183	+0,1084 [+0,0760; +0,1425]

Fonte: elaborado pelo autor (results/significance_filtro_*_vs_baseline_*.json).

A Tabela 12 cruza cada uma das quatro execuções do RECLin-PT com cada um dos quatro *baselines* oficiais, incluindo as comparações cruzadas entre *encoders* e entre sementes. **As dezesseis comparações apresentam intervalo de confiança inteiramente acima de zero**, sem exceção, nas duas sementes e nos dois *encoders*.

O caso mais desfavorável possível é a execução filtrada mais fraca medida contra o *baseline* mais forte, isto é, o RECLin-PT sobre o BERTimbau na semente 42 (0,8168) contra o BioBERTpt na semente 43 (0,7388), e mesmo ele produz diferença de +0,0780 com IC95% [+0,0340; +0,1225]. Diferentemente da diferença entre os dois *baselines* examinada na Seção 6.6, o ganho não depende nem do *checkpoint* de pré-treino nem da semente de treino.

6.7.3 O que a restrição lexical alcança sozinha

A regra pura R3 foi submetida ao mesmo teste contra os quatro *baselines*, e o resultado é o oposto. Contra o BioBERTpt na semente 42 a diferença é de $-0,0017$, com IC95% $[-0,0588; +0,0540]$; contra o BERTimbau na mesma semente, de $-0,0166$, com IC95% $[-0,0716; +0,0386]$; contra o BioBERTpt na semente 43, de $-0,0444$, com IC95% $[-0,1022; +0,0145]$; e contra o BERTimbau na semente 43, de $-0,0240$, com IC95% $[-0,0818; +0,0334]$. Os quatro intervalos contêm o zero. **A regra pura não supera nenhum dos *baselines* com significância estatística**, e empata estatisticamente com os quatro sob o critério adotado.

Esse resultado foi produzido precisamente para ser reportado, e não apesar disso. Ele delimita a contribuição do RECLin-PT, que não está na restrição lexical isolada. Uma lista de onze formas, aplicada sem modelo algum, alcança na classe-alvo o mesmo patamar das quatro execuções ajustadas em GPU, e não mais do que isso.

A leitura conjunta dos dois resultados é o argumento central desta etapa. A restrição lexical restringe o espaço de decisão, e o *encoder* decide, dentro desse espaço, qual é o alvo correto da negação. Nenhum dos dois basta sozinho. O *encoder* isolado localiza o contexto de negação e erra o par, razão pela qual a sua precisão na classe não passa de 0,6167. A regra isolada aplica a restrição sem decidir o alvo, razão pela qual empata com os *baselines*. O ganho medido aparece somente na combinação das duas, que é o que o RECLin-PT é.

7 DISCUSSÃO

Este capítulo interpreta os resultados obtidos, discute limitações do trabalho e aponta ameaças à validade dos achados.

7.1 ANÁLISE DOS RESULTADOS

O resultado central é a **ausência de vantagem consistente do pré-treinamento clínico**. Para a extração de relações no SemClinBr, no espaço de três classes, o BioBERTpt não produz ganho estável sobre o BERTimbau, nem mesmo na classe *negation_of*, em que a especialização de domínio seria mais plausível. Convém precisar o que os testes sustentam, porque o quadro é menos confortável que um empate. Na métrica-alvo, o veredito de *empate* vale para as duas sementes, uma vez que o *bootstrap* pareado sobre o F1 de *negation_of* não rejeita a hipótese nula nem na semente 42 nem na 43. O que *não* se mantém entre elas é a *direção nessa classe*, dado que o sinal da diferença se inverte e passa a favorecer o *encoder* clínico. O teste de McNemar, que incide sobre o conjunto dos candidatos, tampouco rejeita a hipótese nula em qualquer das sementes, e a contagem de discordâncias aponta, nas duas, para o *encoder* clínico, por margem compatível com o acaso (540 contra 516 na semente 42; 559 contra 510 na 43), assim como a acurácia. Nenhum dos testes aplicados detecta, portanto, diferença entre os dois *encoders*. O que se mantém, além dessa ausência de diferença, é a *magnitude relativa*. A variação do *encoder* clínico entre sementes (0,043 na métrica-alvo) supera a diferença medida entre os dois *encoders* em qualquer das sementes (0,015 na 42 e 0,020 na 43), ao passo que a variação do *encoder* geral (0,007) fica abaixo dela (Seção 6.6). É nesse sentido, e apenas nesse, que não há ganho atribuível ao domínio de pré-treino. O motivo não é uma derrota do clínico, que chega a ficar à frente na negação sob a semente 43, mas o fato de a diferença entre os dois na classe investigada não sobreviver à troca de uma semente. Esse achado contrasta com a expectativa difundida, bem como com os ganhos relatados para o reconhecimento de entidades nomeadas clínicas em português (SCHNEIDER *et al.*, 2020), de que modelos de domínio sempre se transfiram melhor.

Duas explicações são plausíveis e compatíveis com os dados.

A primeira é **linguística**. A negação clínica em português é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”, além de adjetivos que embutem negação morfológicamente, como “afebril” e “anicterico”, conforme o Apêndice B). Esse sinal é frequente e regular o bastante para que um *encoder* de domínio geral, com vocabulário amplo do português, o capture sem desvantagem consistente em relação a um clínico. A caracterização do corpus reforça essa leitura, pois a mediana da distância entre as entidades de uma relação `negation_of` é de um único caractere (Seção 4.2), ou seja, o gatilho de negação está praticamente colado ao achado negado. Detectá-lo depende pouco de conhecimento clínico especializado.

A segunda é **estrutural**. A tarefa, tal como formulada, depende mais da estrutura local do par, isto é, da direção, da proximidade e da delimitação das entidades, do que de conhecimento lexical especializado de domínio, e essa estrutura é fornecida igualmente aos dois *baselines* pela representação de entrada compartilhada (Seção 5.4). A semelhança entre as matrizes de confusão (Seção 6.4) é a evidência mais direta disso. Os dois modelos não apenas chegam a números próximos, mas concentram o erro no mesmo lugar, a fronteira entre `associated_with` e `no_relation`.

Um corolário prático, e diretamente relevante para o desenvolvimento do RECLin-PT, é a **eficiência**. O BERTimbau acompanha o BioBERTpt em macro-F1 médio, ficando 0,002 atrás (0,701 contra 0,703), com aproximadamente 60% dos parâmetros (108,9 contra 177,9 milhões). Quando o desempenho é equivalente, o modelo menor é preferível por custo de inferência e de memória, consideração concreta para implantação em ambientes clínicos com recursos limitados. A esse argumento soma-se a estabilidade, dado que a amplitude entre sementes do BERTimbau na métrica-alvo (0,007) é cerca de seis vezes menor que a do BioBERTpt (0,043), o que torna seu desempenho mais previsível em uma nova execução. Vale registrar a contrapartida. É justamente essa dispersão que permite ao BioBERTpt superar o geral na semente 43, de modo que a preferência pelo *encoder* menor se justifica por previsibilidade e custo, não por superioridade média na métrica-alvo.

7.2 O GANHO DO FILTRO DE PISTA LEXICAL

A primeira das duas explicações oferecidas na análise anterior para a ausência de vantagem do *encoder* clínico era a lexicalização forte da negação em português. Até a comparação entre *baselines*, ela permanecia justificativa linguística, apoiada na regularidade dos gatilhos e na mediana de distância de um único caractere entre a pista e o achado negado. O filtro de pista a converte em medida. Um léxico de apenas 11 formas, induzido automaticamente do conjunto de treino, cobre 0,9467 dos pares *negation_of* do conjunto de desenvolvimento, e exigir a presença de uma dessas formas no primeiro argumento eleva a precisão da classe no teste de 0,5547–0,6167 para 0,7514–0,8059, ao custo de cerca de dois pontos centesimais de *recall* (Seção 6.7). O que esse resultado mostra é que a maior parte dos falsos positivos do modelo contextual ocorre em pares que nenhum gatilho de negação inicia, ou seja, fora do espaço em que a classe poderia legitimamente existir. Confirma-se, assim, por medida direta e não apenas por argumento, que o sinal de negação no português clínico é regular o bastante para ser delimitado por uma lista curta, e é essa mesma propriedade que torna dispensável o pré-treinamento de domínio para capturá-lo.

O erro que resta depois do filtro foi auditado, e a sua composição qualifica o quanto ainda há a ganhar. A auditoria incide sobre uma execução sorteada entre as quatro, com a semente do sorteio fixada em código antes do primeiro sorteio, e recaiu sobre o RECLin-PT aplicado ao BioBERTpt na semente 43. Essa execução produz 33 falsos positivos, classificados por um critério estrutural fixado antes da leitura dos casos, que decide pela evidência do *gold* e não por leitura clínica caso a caso. Dos 33, 18 (54,5%) são prováveis erros de anotação do *gold*, em que a pista e o alvo são adjacentes e o corpus não registra relação alguma para aquela pista; 6 (18,2%) são ambiguidades genuínas, tipicamente listas coordenadas¹ em que o *gold* anota apenas o primeiro alvo; e 9 (27,3%) são erros do modelo. Se toda a divergência de anotação fosse resolvida a favor do modelo, os 24 casos que não configuram erro de leitura clínica deixariam de contar como falsos positivos, e a precisão dessa execução passaria de 0,8059 para 0,9384, com F1 de 0,9195. **Esse valor não é um resultado do sistema.** Ele é

¹ Lista coordenada é a enumeração de achados ligados por vírgula ou conjunção e precedidos por uma única pista de negação, como em “sem febre, tosse ou dispneia”, em que a pista nega cada um dos itens.

um *teto hipotético*, condicionado a uma resolução favorável de divergências que esta auditoria não estabelece, e presta-se apenas a dimensionar quanta precisão ainda resta disponível antes de se investir GPU nessa direção. O desempenho efetivamente medido dessa execução continua sendo o F1 de 0,8509 da Tabela 11. Cabe registrar também o limite da própria auditoria, cujo critério mecânico acerta o padrão dominante, que é a lista coordenada, e erra em casos que exigiriam interpretar o que a frase quer dizer. Uma revisão humana pode mover casos entre as três classes, e o trecho de contexto de cada caso consta do relatório justamente para permiti-la.

7.3 A CLASSE ASSOCIATED_WITH

A classe `associated_with` permanece a mais difícil para os dois modelos ($F1 \approx 0,44$), com alta cobertura e baixa precisão. Duas causas se somam.

A primeira é **conceitual**. Distinguir associação genuína de mera proximidade textual é intrinsecamente ambíguo em texto clínico telegráfico, em que entidades vizinhas frequentemente não mantêm relação anotada, como ilustra o próprio exemplo de geração de candidatos (Quadro 1), em que cinco dos seis pares ordenados possíveis são `no_relation`.

A segunda é **metodológica**. A janela `max_gap= 25` descarta 9,11% das relações `associated_with` do conjunto de teste (Seção 4.6.1), enquanto não descarta *nenhuma* relação `negation_of`. O F1 dessa classe é, portanto, medido sob um teto de *recall* substancialmente mais baixo que o das demais. Como o teto é idêntico para os dois modelos, ele não afeta a comparação, objeto deste trabalho, mas qualquer leitura do valor absoluto de F1 de `associated_with` precisa levá-lo em conta.

7.4 LIMITAÇÕES

A limitação mais séria recai sobre o alcance da caracterização de empate. O veredito de ausência de diferença vale para as duas sementes, mas resulta de uma **não rejeição** da hipótese nula, e não de uma demonstração de equivalência. Soma-se a isso que a comparação pareada refeita na semente 43 inverte o sinal da diferença observado na semente de referência, passando a apontar para o BioBERTpt clínico. A conclusão

prática, a ausência de ganho *confiável* atribuível ao pré-treinamento clínico, sobrevive a essa inversão, porque se apoia na instabilidade da diferença e não em sua direção; mas qualquer afirmação sobre *qual encoder* é superior depende inteiramente da semente e não está sustentada por estes experimentos. Além disso, **duas sementes por modelo não bastam** para estimar um intervalo de confiança sobre essa variação, e o desvio reportado na Tabela 9 deve ser lido como dispersão observada, não como estimativa de variância. Fechar a questão exige um número maior de repetições com agregação formal.

A tarefa pressupõe **entidades já anotadas** (*gold*). A avaliação não considera o erro propagado de uma etapa de reconhecimento de entidades nomeadas automática, de modo que os resultados refletem a extração de relações isoladamente. Em um cenário fim a fim, os valores absolutos seriam necessariamente menores.

Por fim, o achado é específico desta **formulação de três classes** e desta **escala de modelo** (*base*). Não se pode excluir que o pré-treinamento clínico volte a importar em espaços de relação mais ricos, em modelos maiores ou em cenários com menos dados de ajuste.

7.5 AMEAÇAS À VALIDADE

Quanto à **validade interna**, o congelamento das partições com semente fixa e verificação por *hashes* SHA-256 (Apêndice A), somado ao particionamento em nível de documento, mitiga o vazamento de dados, a principal causa de resultados não reproduzíveis em PLN biomédico. A paridade total de implementação entre os dois *baselines* (Capítulo 5) garante que a diferença medida reflita o *checkpoint*, e não artefatos de código. Restam, contudo, decisões de projeto que influenciam os números absolutos, das quais a mais consequente é a janela `max_gap=25` na geração de pares candidatos. Esse limite foi quantificado por partição e por classe (Seção 4.6.1) e, portanto, é uma limitação *documentada e de magnitude conhecida*, e não uma fonte de incerteza não medida.

Uma segunda ameaça diz respeito à **independência das instâncias**. O *bootstrap* pareado trata os 19210 candidatos como independentes, o que não é estritamente

verdadeiro, pois pares de um mesmo documento compartilham texto e vocabulário, de modo que o intervalo de confiança reportado é provavelmente mais estreito que o real. Essa ameaça atenua-se, mas não desaparece, pelo fato de a comparação ser *pareada*, já que ambos os modelos são avaliados exatamente sobre as mesmas instâncias, e a dependência afeta os dois igualmente. Ainda assim, a conclusão de empate nas duas sementes deve ser lida com essa ressalva.

Quanto à **validade externa**, o SemClinBr, apesar de multi-institucional e multiespecialidade, representa um conjunto específico de instituições e estilos de redação; a generalização para outros contextos clínicos e para outros espaços de relação deve ser feita com cautela. As inconsistências de anotação conhecidas do corpus, ainda que tratadas e registradas pelo *parser*, também impõem um limite superior ao desempenho alcançável, limite que se aplica igualmente aos dois modelos comparados.

7.5.1 Deriva dos *offsets* de entidade

Uma última ameaça à validade interna foi identificada durante a construção do RECLin-PT e merece registro próprio, por não ter sido considerada no protocolo original. Os *offsets* das entidades do corpus não indexam corretamente o texto do documento na representação canônica. No conjunto de teste, apenas 64,4% das entidades satisfazem a identidade entre o trecho recortado pelo *offset* e o texto anotado da própria entidade, contra 58,9% no treino e 65,8% no desenvolvimento. A deriva é cumulativa e negativa ao longo do documento, assinatura compatível com uma normalização de espaço em branco aplicada ao texto *depois* do cálculo dos *offsets*. A etapa exata em que ela ocorre permanece por identificar, e a correção automática de deslocamentos de ± 1 e ± 2 caracteres executada pelo *parser* (Capítulo 4) não alcança uma deriva acumulada dessa magnitude.

Três razões circunscrevem o alcance dessa ameaça. A primeira é que ela afeta os dois *encoders* de forma idêntica, por atuar na construção da janela marcada (Seção 5.4), que é compartilhada, de modo que a comparação do Capítulo 6 permanece válida. A segunda é que o filtro de pista do RECLin-PT não consulta *offset* algum, pois decide pela forma de superfície registrada na própria entidade, e o resultado da

Seção 6.7 não depende, portanto, desse alinhamento. A terceira é que a distância entre entidades empregada na geração de candidatos e na regra pura é calculada entre *offsets* mutuamente consistentes, permanecendo válida como medida relativa.

O que a deriva sugere é um teto de desempenho a recuperar, e não um erro de comparação. Em cerca de 36% das entidades do conjunto de teste, os marcadores [E1] e [E2] são inseridos alguns caracteres deslocados em relação à superfície que deveriam delimitar, e todos os valores absolutos deste trabalho foram medidos sob essa condição. Corrigir o alinhamento é, por isso, uma das continuidades previstas no Capítulo 8.

8 CONCLUSÃO

Este trabalho abordou a extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, no espaço de rótulos *negation_of*, *associated_with* e *no_relation*. Como etapa inicial do desenvolvimento do **RECLin-PT**, conduziu-se um experimento controlado de *baselines* para responder a uma pergunta que fundamenta as decisões de projeto seguintes: o pré-treinamento clínico importa para a extração de relações em textos médicos em português? A ênfase recaiu, simultaneamente, sobre a resposta a essa pergunta e sobre a construção de uma cadeia experimental reproduzível, do texto bruto às métricas finais. Respondida a pergunta, a segunda etapa construiu o RECLin-PT sobre a base por ela indicada, por meio de um filtro de pista lexical induzido do conjunto de treino e calibrado no de desenvolvimento, e mediu-o sob o mesmo protocolo aplicado aos *baselines*.

8.1 CONTRIBUIÇÕES

As principais contribuições são: (i) um *parser* fiel e determinístico do formato XML do SemClinBr, com verificação de sanidade e correção controlada de *offsets*; (ii) uma caracterização do corpus que evidencia o desbalanceamento das relações e a proximidade entre entidades relacionadas, em particular a quase adjacência dos pares de negação; (iii) um protocolo de particionamento em nível de documento, estratificado e congelado, que previne vazamento de dados; (iv) um gerador determinístico de pares candidatos compartilhado por todos os modelos, com o teto de *recall* imposto pela janela quantificado por partição e por classe; (v) uma infraestrutura experimental de paridade total, em que os dois *encoders* comparados diferem apenas no *checkpoint* de pré-treino; e (vi) uma comparação empírica com teste de significância pareado entre um *encoder* clínico e um geral sobre a mesma tarefa; (vii) o **RECLin-PT** propriamente dito, sistema híbrido que combina o *encoder* escolhido a um filtro de pista lexical induzido do conjunto de treino e calibrado no de desenvolvimento, entregue e avaliado sob o mesmo protocolo estatístico aplicado aos *baselines*; e (viii) uma auditoria dos falsos positivos remanescentes da classe-alvo, sob critério fixado antes da leitura dos casos, que dimensiona quanto do erro residual é divergência de anotação do corpus.

Quanto aos resultados, não se observou vantagem *consistente* do pré-treinamento clínico. Na semente de referência (42), a diferença no F1 de *negation_of* entre BioBERTpt e BERTimbau é de 0,015 a favor do geral e não é estatisticamente significativa na métrica-alvo (*bootstrap* pareado IC95% $[-0,051; +0,021]$, $p = 0,420$); na semente 43, o mesmo *bootstrap* sobre essa métrica inverte o sinal e passa a favorecer o BioBERTpt clínico, mas tampouco alcança significância (IC95% $[-0,018; +0,057]$, $p = 0,288$). A *direção* da diferença **na classe-alvo**, portanto, não é estável entre sementes, pois a variação de inicialização de um mesmo modelo (0,043 de amplitude no BioBERTpt) supera com folga a diferença entre os dois modelos. Essa instabilidade de direção é da métrica-alvo e **não se estende ao padrão global de acertos**, que tampouco separa os dois modelos. O teste de McNemar, que incide sobre as três classes, não rejeita a hipótese nula em nenhuma das sementes, e a contagem de discordâncias favorece levemente o *encoder* clínico nas duas (540 contra 516 na semente 42; 559 contra 510 na 43). O que é estável, além dessa ausência de diferença, é a assimetria de dispersão. O *encoder* geral acompanha o clínico em macro-F1 médio (0,701 contra 0,703) com cerca de 60% dos parâmetros e com desempenho cerca de seis vezes mais estável entre reinicializações na métrica-alvo.

Quanto à segunda etapa, o RECLin-PT supera os *baselines* na classe-alvo com significância estatística nas duas sementes e nos dois *encoders*. As dezesseis comparações entre cada execução filtrada e cada *baseline* oficial apresentam intervalo de confiança de 95% do *bootstrap* pareado inteiramente acima de zero, e o caso mais desfavorável possível, a execução filtrada mais fraca contra o *baseline* mais forte, dá +0,0780 com IC95% $[+0,0340; +0,1225]$. O F1 de *negation_of* passa da faixa de 0,6961–0,7388 dos *baselines* para 0,8168–0,8509, e o macro-F1, de 0,6932–0,7128 para 0,7334–0,7506. O ganho não decorre da restrição lexical isolada, uma vez que a regra pura, aplicada sem o *encoder*, empata estatisticamente com os quatro *baselines*. Convém enunciar com precisão o que foi entregue. O RECLin-PT não possui pesos próprios, e nenhum modelo foi retreinado nesta etapa. Ele é um sistema híbrido, em que um filtro determinístico restringe o espaço em que *negation_of* pode ser predita e o *encoder* já ajustado decide o alvo dentro desse espaço.

8.2 TRABALHOS FUTUROS

Conduzir o estudo de *baselines* antes da especialização foi uma decisão de sequenciamento, e não uma lacuna. A escolha do *encoder* é pré-requisito de qualquer aprimoramento posterior, pois, fixada a base por expectativa (e a expectativa de partida, registrada na Seção 1.2, era a de vantagem do pré-treino clínico), todo ganho ou perda medido depois ficaria confundido com o efeito do *checkpoint*, sem meio de separar um do outro. E o resultado dessa primeira etapa é, ele próprio, um achado de consequência prática, e não um resultado nulo vazio. Sob teste pareado e sob duas sementes de treino, o *encoder* clínico não leva vantagem *confiável* nesta tarefa (a diferença medida troca de sinal entre sementes), o que liberou a construção do RECLin-PT sobre um modelo sensivelmente menor. Isso não equivale a custo zero, pois, tomada a média das duas sementes, o *encoder* clínico fica 0,003 à frente na métrica-alvo (0,717 contra 0,715), e é esse o custo esperado da escolha. Ele é, contudo, muito menor que a própria amplitude entre sementes do BioBERT_{pt} (0,043), o que o torna mal estimado por duas execuções. Como registra o Capítulo 3, não localizamos avaliação controlada equivalente para o português, de modo que esse achado não era obtível por consulta à literatura.

As duas etapas anunciadas na Introdução foram concluídas neste trabalho. O RECLin-PT não é um sistema a construir, e sim um sistema construído, medido e comparado aos *baselines* sob o mesmo crivo estatístico a que eles foram submetidos. O que permanece aberto não é a sua existência, e sim o caminho de aprimoramento que ela torna possível.

A extensão natural do que foi entregue é o **ajuste fino propriamente dito**. O RECLin-PT restringe o espaço de candidatos em que `negation_of` pode ser predita e delega ao *encoder* já ajustado a escolha do alvo dentro desse espaço, sem que os pesos desse *encoder* tenham sido revisitados. O passo seguinte consiste em treinar um modelo dedicado *dentro* do espaço restrito, isto é, ajustar um classificador cujos exemplos negativos sejam apenas os candidatos que sobrevivem ao filtro. A hipótese a testar é a de que, removida a massa de pares que o filtro descarta de qualquer modo, a capacidade do modelo passe a ser empregada na fronteira que de fato decide a classe,

que é a escolha do alvo entre os candidatos iniciados por um gatilho. Trata-se de uma extensão do sistema entregue, e não de uma pendência dele, uma vez que o ganho a medir passa a ser o ganho *sobre* o RECLin-PT, tomado agora como *baseline*. A auditoria discutida na Seção 7.2 dimensiona o que há a ganhar nessa direção e recomenda cautela, dado que parte expressiva do erro residual é divergência de anotação do corpus, que nenhum treino adicional corrige.

Cabe explicitar que a prioridade dada à negação não recai sobre a classe de pior desempenho. A Seção 6.3 mostra que *associated_with* é a mais difícil das três ($F1 \approx 0,44$, contra $\approx 0,70$ – $0,71$ de *negation_of* nos *baselines* e $\approx 0,82$ – $0,85$ no RECLin-PT). O critério é de criticidade clínica, e não de facilidade. Uma negação lida como afirmação inverte o sentido de um achado no prontuário, ao passo que um *associated_with* não recuperado empobrece a extração sem alterar o sentido do que foi extraído. O teto de *recall* de *associated_with* permanece, ainda assim, entre as continuidades previstas a seguir.

Como continuidade, prevê-se ainda: corrigir o alinhamento entre os *offsets* de entidade e o texto do documento (Seção 7.5.1), medindo quanto do desempenho absoluto é limitado por marcadores deslocados; estimar o desempenho dos *baselines* e do RECLin-PT sob um número maior de sementes de treino, com agregação formal, para obter um intervalo de confiança da diferença mais estreito; submeter parte dos falsos positivos remanescentes a revisão humana, de modo a substituir por medida o teto hipotético estimado pela auditoria; enriquecer a representação de entrada com o **tipo semântico** das entidades, hoje ausente dos marcadores (Seção 5.4.3), medindo se o ganho difere entre o *encoder* clínico e o geral; reavaliar a janela *max_gap* da geração de pares candidatos, elevando o teto de *recall* de *associated_with* sem inviabilizar o custo de treino; investigar o tratamento explícito do escopo da negação e da direção das relações; estender o espaço de relações para além das três classes atuais; avaliar modelos maiores e *encoders* multilíngues (CONNEAU *et al.*, 2020); e integrar uma etapa de reconhecimento de entidades nomeadas automática, medindo a extração de relações em um cenário fim a fim.

O trabalho entrega, portanto, as duas etapas anunciadas. Os *baselines* respondem à

pergunta de projeto, e o RECLin-PT, construído sobre a base que eles indicam, entrega ganho estatisticamente significativo na classe clinicamente mais crítica. O que se abre a seguir é a continuidade de um resultado, e não o encerramento de uma pendência.

REFERÊNCIAS

- ALMEIDA, V. A. de *et al.* **Clinical named entity recognition in the Portuguese language: a benchmark of modern BERT models and LLMs.** 2026. ArXiv:2603.26510 [cs.CL]. Pré-publicação.
- CHAPMAN, W. W. *et al.* A simple algorithm for identifying negated findings and diseases in discharge summaries. **Journal of Biomedical Informatics**, v. 34, n. 5, p. 301–310, 2001.
- CONNEAU, A. *et al.* Unsupervised cross-lingual representation learning at scale. In: **Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2020. p. 8440–8451.
- DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. In: **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)**. [S.l.]: Association for Computational Linguistics, 2019. p. 4171–4186.
- DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895–1923, 1998.
- FORMAN, G.; SCHOLZ, M. Apples-to-apples in cross-validation studies: Pitfalls in classifier performance measurement. **ACM SIGKDD Explorations Newsletter**, v. 12, n. 1, p. 49–57, 2010.
- FRAILE NAVARRO, D. *et al.* Clinical named entity recognition and relation extraction using natural language processing of medical free text: A systematic review. **International Journal of Medical Informatics**, v. 177, p. 105122, 2023.
- LEE, J. *et al.* BioBERT: A pre-trained biomedical language representation model for biomedical text mining. **Bioinformatics**, v. 36, n. 4, p. 1234–1240, 2020.
- LIN, C. *et al.* Does BERT need domain adaptation for clinical negation detection? **Journal of the American Medical Informatics Association**, v. 27, n. 4, p. 584–591, 2020.
- OLIVEIRA, L. E. S. e. *et al.* SemClinBr – a multi-institutional and multi-specialty semantically annotated corpus for Portuguese clinical NLP tasks. **Journal of Biomedical Semantics**, v. 13, n. 1, p. 13, 2022.
- SCHNEIDER, E. T. R. *et al.* BioBERTpt – a Portuguese neural language model for clinical named entity recognition. In: **Proceedings of the 3rd Clinical Natural Language Processing Workshop**. [S.l.]: Association for Computational Linguistics, 2020. p. 65–72.
- SECHIDIS, K.; TSOUMAKAS, G.; VLAHAVAS, I. On the stratification of multi-label data. In: **Machine Learning and Knowledge Discovery in Databases (ECML PKDD 2011)**. [S.l.]: Springer, 2011. (Lecture Notes in Computer Science, v. 6913), p. 145–158.
- SHIMAOKA, A. M. *et al.* Large language models in Portuguese for healthcare: a systematic review. **Research on Biomedical Engineering**, v. 42, n. 1, p. 13, 2026.

SILVA, D. Pinheiro da *et al.* Exploring named entity recognition and relation extraction for ontology and medical records integration. **Informatics in Medicine Unlocked**, v. 43, p. 101381, 2023.

SOARES, L. B. *et al.* Matching the blanks: Distributional similarity for relation learning. In: **Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2019. p. 2895–2905.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for Brazilian Portuguese. In: **Intelligent Systems (BRACIS 2020)**. [S.l.]: Springer, 2020. (Lecture Notes in Computer Science, v. 12319), p. 403–417.

UZUNER, Ö. *et al.* 2010 i2b2/VA challenge on concepts, assertions, and relations in clinical text. **Journal of the American Medical Informatics Association**, v. 18, n. 5, p. 552–556, 2011.

VASWANI, A. *et al.* Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

Apêndices

APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS

Para garantir a reprodutibilidade dos experimentos, as partições de treino, desenvolvimento e teste foram congeladas após sua geração (semente 42, estratificação multirrótulo em nível de documento). O Quadro 4 apresenta os *hashes* SHA-256 dos arquivos, registrados por `src/make_splits.py` em `data/splits/MANIFEST.json` e versionados junto com os dados. Qualquer alteração nos arquivos altera o *hash*, permitindo a verificação independente da integridade das partições.

A verificação não é apenas documental. Os *scripts* que geram as tabelas e figuras deste trabalho recalculam esses *hashes* antes de ler os dados e interrompem a execução se algum deles divergir do manifesto. Assim, nenhum número publicado aqui pode ter sido produzido a partir de uma partição diferente da registrada abaixo.

Quadro 4 – SHA-256 das partições congeladas do SemClinBr.

Arquivo	SHA-256
<code>train.jsonl</code>	36014b2adc8308bce94aeecf066c38f69e1f53dda4517fa424527554b31a437a
<code>dev.jsonl</code>	a9ea327684165c5053f8f3db5468a27f71c1d9e30d2859e343b6d275839c8aeb
<code>test.jsonl</code>	86304d8d507c6707695e2b86c3533b763a96247f06326e5980b4567385231e62

Fonte: elaborado pelo autor (`data/splits/MANIFEST.json`, gerado por `src/make_splits.py`).

As partições contêm, respectivamente, 800, 100 e 100 documentos. A Tabela 3, no Capítulo 4, registra a distribuição das relações entre elas: 9221 no treino, 987 na validação e 1250 no teste.

APÊNDICE B – MARCADORES DE NEGAÇÃO DO PORTUGUÊS CLÍNICO

A negação clínica em português é fortemente **lexicalizada**, pois um conjunto pequeno e recorrente de gatilhos responde pela maior parte das ocorrências, o que está na origem da eficácia de abordagens como o algoritmo NegEx (CHAPMAN *et al.*, 2001) e é uma das explicações discutidas no Capítulo 7 para a **ausência de vantagem consistente** do *encoder* de domínio clínico sobre o de domínio geral na captura da negação. Entre as duas sementes avaliadas, a diferença entre os dois nessa classe não mantém sequer o sinal.

Este apêndice registra os marcadores mais frequentes observados no SemClinBr, a título de caracterização linguística do fenômeno. Os dois *encoders* comparados no Capítulo 6 **não** recebem lista alguma de gatilhos, e aprendem o sinal de negação diretamente do texto marcado. O léxico empregado pelo filtro de pista do RECLin-PT (Seção 5.5) é objeto distinto deste quadro, por ser induzido automaticamente do conjunto de treino e não redigido a partir de observação linguística.

Quadro 5 – Marcadores de negação recorrentes no português clínico.

Marcador	Observação
não	negação verbal/adverbial geral
sem	preposição de ausência
nega	forma verbal (“paciente nega. . .”)
ausência	substantivo de ausência
ausente	adjetivo de ausência
afebril	adjetivo com negação léxico-morfológica (sem febre)
anictérico	adjetivo com negação léxico-morfológica (sem icterícia)

Fonte: elaborado pelo autor a partir do SemClinBr.

Os termos “afebril” e “anictérico” são adjetivos que embutem negação morfológicamente e que, no SemClinBr, aparecem anotados como entidades da categoria *Negation*, categoria que responde por 2646 menções no corpus (Seção 4.2). Uma abordagem puramente léxica sobre esta lista não trataria negação de escopo amplo (“o paciente não apresenta nenhum dos seguintes: A, B, C”), negação estendida por conjunção, nem a direção da relação, limitações que motivam o uso de modelos contextuais,

capazes de aprender o escopo a partir do contexto em vez de aplicar uma regra rígida de janela. A Seção 6.7 mede essa limitação, ao comparar uma regra puramente léxica com os modelos contextuais sobre o mesmo conjunto de teste.

APÊNDICE C – HIPERPARÂMETROS

Este apêndice consolida os hiperparâmetros efetivamente utilizados nas etapas executadas do *pipeline*. O Quadro 6 reúne os parâmetros comuns à preparação dos dados e à avaliação; o Quadro 7 detalha o ajuste fino dos dois *encoders* comparados.

Todos os valores abaixo foram lidos do campo `config` dos arquivos `results/baseline_*.json`, gravado pelo próprio código de treino no momento da execução, e não transcritos de um plano de experimento. Os dois *encoders* compartilham a configuração integralmente, e essa identidade é verificada automaticamente por `scripts/_artifacts.py`, que recusa gerar qualquer tabela deste trabalho caso as configurações das quatro execuções (dois modelos $\times$ duas sementes) diverjam em algum campo.

Quadro 6 – Parâmetros gerais da preparação dos dados e da avaliação.

Parâmetro	Valor
Semente do particionamento	42 (congelada)
Sementes de treino	42 (referência) e 43 (robustez)
Partição treino/validação/teste	80/10/10 (nível de documento)
Estratificação	multirrótulo por presença de classe no documento
Janela máxima de pares (<code>max_gap</code>)	25 caracteres
Contexto em torno do par (<code>ctx_chars</code>)	128 caracteres
<i>Bootstrap</i> pareado	10.000 reamostragens, percentis 2,5/97,5
Teste pareado	McNemar (binomial exato)
Critério de significância	IC95% da diferença não contém zero

Fonte: elaborado pelo autor (`results/baseline_*.json` e `results/significance_*.json`).

A Tabela 6, no Capítulo 6, registra a evolução época a época de cada uma das quatro execuções: perda de treino, perda de validação, macro-F1 e F1 de `negation_of` na validação, além da duração.

Quadro 7 – Hiperparâmetros do ajuste fino, idênticos para os dois *encoders*.

Parâmetro	Valor
<i>Encoder</i> clínico	pucpr/biobertpt-all (177,9 M de parâmetros)
<i>Encoder</i> geral	neuralmind/ bert-base-portuguese-cased (108,9 M de parâmetros)
Núcleo de implementação	src/relation_extraction.py
Representação de entrada	janela de texto com marcadores de posição ([E1]/[E2]), sem tipo semântico
Cabeçote de classificação	AutoModelForSequenceClassification (projeção linear sobre a representação agregada da sequência)
Perda	<i>cross-entropy</i> com <code>class_weight="balanced"</code>
<code>max_length</code>	128 <i>tokens</i>
Taxa de aprendizado	2×10^{-5} (AdamW)
Escalonador	linear com <i>warmup</i>
<i>Batch</i> (treino e avaliação)	64
Épocas	3
Seleção de modelo	maior macro-F1 no conjunto de validação
Hardware	Google Colab, <i>Tesla</i> T4

Fonte: elaborado pelo autor (campo config de results/baseline_*.json).