



**BACHARELADO EM SISTEMAS DE INFORMAÇÃO**  
**TRABALHO DE GRADUAÇÃO**

**ANGELO ANTONIO LIMA SILVEIRA FILHO**

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS**  
**SOBRE O CORPUS SEMCLINBR**

Cachoeiro de itapemirim

2026

ANGELO ANTONIO LIMA SILVEIRA FILHO

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS  
SOBRE O CORPUS SEMCLINBR**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Cristiano da Silveira Colombo

Coorientadora: Profa. Dra. Beltrana de Tal

Cachoeiro de itapemirim

2026

(Biblioteca do Campus Cachoeiro de Itapemirim)

X999y

RECLin-PT: extração de relações em notas clínicas em português sobre o corpus SemClinBr/ Angelo Antonio Lima Silveira Filho. – 2026.

66 f: il; 30 cm.

Orientador: Cristiano da Silveira Colombo

Trabalho de Graduação – Instituto Federal do Espírito Santo, Bacharelado em Sistemas de Informação, 2026.

1. Processamento de linguagem natural. 2. Extração de relações. 3. Informática em saúde. 4. Aprendizado de máquina. 5. Língua portuguesa. I. Colombo, Cristiano da Silveira. II. Título. III. Instituto Federal do Espírito Santo.

CDD 000.00

**ANGELO ANTONIO LIMA SILVEIRA FILHO**

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS  
SOBRE O CORPUS SEMCLINBR**

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Aprovado em 01 de Agosto de 2026

**COMISSÃO EXAMINADORA**

**Prof. Dr. Cristiano da Silveira Colombo**

Instituto Federal do Espírito Santo  
Orientador

**Profa. Dra. Beltrana de Tal**

Instituto Federal do Espírito Santo  
Coorientadora

**Profa. Dra. Fulana de Tal**

Instituto Federal do Espírito Santo  
Examinadora

**Prof. Dr. Cicrano de Tal**

Instituto Federal do Espírito Santo  
Examinador

À minha mãe, meu alicerce de força e superação, que esteve ao meu lado mesmo nos dias em que eu já não tinha vontade de continuar. Que jamais me desamparou diante das dificuldades e, com amor, coragem e fé, tornou-se o meu maior exemplo de vida. Tudo o que sou carrega um pouco da sua força. Aos meus amigos de jornada, que foram âncora e apoio durante todo o processo.

*“Citação a ser escolhida.”*  
(Autor, ano)

## RESUMO

O registro eletrônico em saúde concentra grande parte da informação clínica em texto livre, no qual a relação entre conceitos, em especial a negação de achados, é determinante para a correta interpretação. Este trabalho investiga a extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, considerando o espaço de rótulos *negation\_of*, *associated\_with* e *no\_relation*. Como etapa inicial do desenvolvimento do RECLin-PT, um modelo aprimorado de extração de relações clínicas em português, conduz-se um experimento controlado para responder a uma questão de projeto: o pré-treinamento clínico importa para essa tarefa? Propõe-se uma cadeia experimental reprodutível que vai do texto bruto às métricas finais, composta por um *parser* determinístico do formato XML do corpus, análise exploratória das relações, particionamento 80/10/10 em nível de documento, estratificado e congelado para evitar vazamento de dados, e geração controlada de pares candidatos. Sobre essa infraestrutura, dois *encoders* para o português são ajustados variando apenas o *checkpoint* de pré-treino: um de domínio clínico (BioBERTpt) e um de domínio geral (BERTimbau). No conjunto de teste congelado, os dois empatam estatisticamente no F1 de *negation\_of* na semente de referência (0,677 contra 0,694; *bootstrap* pareado IC95%  $[-0,053; +0,018]$ ,  $p = 0,345$ ), mas esse veredito não se sustenta nas duas sementes testadas. Na semente 43 a diferença *inverte de sinal* e passa a favorecer o *encoder* clínico de forma significativa (IC95%  $[+0,016; +0,090]$ ). A variação entre sementes de um mesmo modelo supera a diferença entre os modelos, de modo que nem o veredito nem sua direção são estáveis *nessa classe*, ao passo que, no padrão global de acertos, o teste de McNemar aponta para o *encoder* geral nas duas sementes. Esses resultados indicam que o RECLin-PT pode ser construído sobre o *encoder* geral, que acompanha o clínico em macro-F1 médio com cerca de 60% dos parâmetros e é cerca de dez vezes mais estável entre reinicializações.

**Palavras-chave:** Extração de relações. Processamento de linguagem natural clínico. Língua portuguesa. SemClinBr. Aprendizado de máquina.

## ABSTRACT

Electronic health records store much clinical information as free text, in which the relationship between concepts, particularly the negation of findings, is decisive for correct interpretation. This work investigates relation extraction between clinical entities in Portuguese over the SemClinBr corpus, considering the label space `negation_of`, `associated_with` and `no_relation`. As the initial stage of developing RECLin-PT, an improved clinical relation extraction model for Portuguese, we run a controlled experiment to answer a design question: does clinical pre-training matter for this task? We propose a reproducible experimental pipeline that goes from raw text to final metrics, comprising a deterministic parser for the corpus XML format, exploratory analysis of relations, a document-level, stratified and frozen 80/10/10 split to prevent data leakage, and controlled candidate-pair generation. On this infrastructure, two Portuguese encoders are fine-tuned changing only the pre-trained checkpoint: a clinical-domain one (BioBERTpt) and a general-domain one (BERTimbau). On the frozen test set, the two are statistically tied on the `negation_of` F1 under the reference seed (0.677 vs. 0.694; paired bootstrap 95% CI  $[-0.053, +0.018]$ ,  $p = 0.345$ ), but this verdict does not hold across the two seeds we tested. Under seed 43 the difference *flips sign* and significantly favours the clinical encoder (95% CI  $[+0.016, +0.090]$ ). Seed-to-seed variation of a single model exceeds the gap between the models, so neither the verdict nor its direction is stable *on that class*, whereas on the overall pattern of correct predictions McNemar’s test points to the general encoder under both seeds. These results indicate that RECLin-PT can be built on the general encoder, which matches the clinical one in mean macro-F1 with about 60% of the parameters and is roughly ten times more stable across restarts.

**Keywords:** Relation extraction. Clinical natural language processing. Portuguese language. SemClinBr. Machine learning.



## LISTA DE FIGURAS

|                                                                                                                                                                                                          |    |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Figura 1 – Processo de criação e anotação do corpus SemClinBr . . . . .                                                                                                                                  | 26 |
| Figura 2 – Distribuição dos tipos de relação no SemClinBr. . . . .                                                                                                                                       | 28 |
| Figura 3 – Distribuição da distância em caracteres entre entidades relacionadas<br>(recorte em 200), com a janela <code>max_gap</code> assinalada. . . . .                                               | 28 |
| Figura 4 – Distribuição do número de relações por documento. . . . .                                                                                                                                     | 29 |
| Figura 5 – Categorias atômicas de entidade mais frequentes (15 primeiras). . .                                                                                                                           | 29 |
| Figura 6 – Distribuição das relações por partição (escala logarítmica), com o<br>percentual de <code>negation_of</code> anotado. . . . .                                                                 | 31 |
| Figura 7 – Evolução por época dos dois <i>encoders</i> nas sementes 42 e 43: perda<br>(à esquerda) e F1 no conjunto de validação (à direita). Marcador<br>preenchido indica a época selecionada. . . . . | 44 |
| Figura 8 – F1 por classe no conjunto de teste: BioBERTpt (clínico) vs. BERTim-<br>bau (geral), semente 42. . . . .                                                                                       | 46 |
| Figura 9 – Matriz de confusão do BioBERTpt (clínico), normalizada por linha. .                                                                                                                           | 47 |
| Figura 10 – Matriz de confusão do BERTimbau (geral), normalizada por linha. .                                                                                                                            | 47 |

## LISTA DE TABELAS

|                                                                                                                                                                                  |    |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Tabela 1 – Distribuição dos tipos de relação no corpus parseado. . . . .                                                                                                         | 27 |
| Tabela 2 – Distância em caracteres entre as entidades de cada relação, por tipo. . . . .                                                                                         | 28 |
| Tabela 3 – Distribuição real das relações por partição ( <i>splits</i> congelados, semente 42). . . . .                                                                          | 31 |
| Tabela 4 – Pares candidatos gerados por partição ( $\text{max\_gap}=25$ ) e distribuição dos rótulos. . . . .                                                                    | 33 |
| Tabela 5 – Teto de <i>recall</i> imposto pela janela $\text{max\_gap}=25$ por partição. . . . .                                                                                  | 34 |
| Tabela 6 – Evolução por época no conjunto de validação. * marca a época selecionada (maior macro-F1 na validação), cujo <i>checkpoint</i> produziu as métricas de teste. . . . . | 45 |
| Tabela 7 – Resultados dos <i>baselines</i> no conjunto de teste ( $n=19.210$ , semente 42). Negrito indica o melhor valor por coluna. . . . .                                    | 45 |
| Tabela 8 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ( $n=19.210$ , semente 42). . . . .                                                 | 48 |
| Tabela 9 – Robustez à semente de treino: métricas de teste por semente, média e amplitude observada. . . . .                                                                     | 49 |
| Tabela 10 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ( $n=19.210$ , semente 43). . . . .                                                | 50 |

## LISTA DE QUADROS

|                                                                                                            |    |
|------------------------------------------------------------------------------------------------------------|----|
| Quadro 1 – Exemplo de geração de candidatos para um trecho do SemClinBr. . . . .                           | 33 |
| Quadro 2 – Ambiente experimental e hiperparâmetros compartilhados pelos<br>dois <i>baselines</i> . . . . . | 36 |
| Quadro 3 – Entrada efetivamente construída para o par <i>gold</i> do Quadro 1. . . . .                     | 42 |
| Quadro 4 – SHA-256 das partições congeladas do SemClinBr. . . . .                                          | 62 |
| Quadro 5 – Marcadores de negação recorrentes no português clínico. . . . .                                 | 63 |
| Quadro 6 – Parâmetros gerais da preparação dos dados e da avaliação. . . . .                               | 65 |
| Quadro 7 – Hiperparâmetros do ajuste fino, idênticos para os dois <i>encoders</i> . . . . .                | 66 |

## LISTA DE ABREVIATURAS

|           |                                                                                 |
|-----------|---------------------------------------------------------------------------------|
| ABNT      | Associação Brasileira de Normas Técnicas                                        |
| BERT      | <i>Bidirectional Encoder Representations from Transformers</i>                  |
| i2b2      | <i>Informatics for Integrating Biology and the Bedside</i>                      |
| IC        | Intervalo de Confiança                                                          |
| IFES      | Instituto Federal do Espírito Santo                                             |
| MCC       | <i>Matthews Correlation Coefficient</i> (Coeficiente de Correlação de Matthews) |
| n2c2      | <i>National NLP Clinical Challenges</i>                                         |
| NER       | <i>Named Entity Recognition</i> (Reconhecimento de Entidades Nomeadas)          |
| NLP       | <i>Natural Language Processing</i> (Processamento de Linguagem Natural)         |
| PLN       | Processamento de Linguagem Natural                                              |
| RE        | <i>Relation Extraction</i> (Extração de Relações)                               |
| SemClinBr | <i>Semantically Annotated Corpus for Portuguese Clinical NLP</i>                |
| TF-IDF    | <i>Term Frequency–Inverse Document Frequency</i>                                |
| XML       | <i>Extensible Markup Language</i>                                               |

## SUMÁRIO

|              |                                                        |           |
|--------------|--------------------------------------------------------|-----------|
| <b>1</b>     | <b>INTRODUÇÃO</b>                                      | <b>13</b> |
| 1.1          | Problema de pesquisa                                   | 13        |
| 1.2          | Motivação                                              | 14        |
| 1.3          | Objetivos                                              | 15        |
| <b>1.3.1</b> | <b>Objetivo geral</b>                                  | <b>15</b> |
| <b>1.3.2</b> | <b>Objetivos específicos</b>                           | <b>16</b> |
| 1.4          | Organização do trabalho                                | 17        |
| <b>2</b>     | <b>REFERENCIAL TEÓRICO</b>                             | <b>18</b> |
| 2.1          | Processamento de linguagem natural clínico             | 18        |
| 2.2          | Extração de entidades e de relações                    | 18        |
| 2.3          | Abordagens baseadas em regras e a negação clínica      | 19        |
| 2.4          | Abordagens baseadas em aprendizado de máquina          | 19        |
| 2.5          | Modelos baseados em <i>transformers</i>                | 19        |
| <b>3</b>     | <b>TRABALHOS RELACIONADOS</b>                          | <b>21</b> |
| 3.1          | Recursos e desafios em inglês                          | 21        |
| 3.2          | Recursos para o português                              | 21        |
| 3.3          | Posicionamento deste trabalho                          | 23        |
| <b>4</b>     | <b>METODOLOGIA</b>                                     | <b>24</b> |
| 4.1          | Visão geral do pipeline                                | 24        |
| 4.2          | Corpus SemClinBr                                       | 25        |
| 4.3          | Parsing e representação canônica                       | 26        |
| 4.4          | Caracterização do corpus                               | 27        |
| <b>4.4.1</b> | <b>Distribuição dos tipos de relação</b>               | <b>27</b> |
| <b>4.4.2</b> | <b>Distância entre entidades relacionadas</b>          | <b>27</b> |
| <b>4.4.3</b> | <b>Relações por documento e categorias de entidade</b> | <b>29</b> |
| 4.5          | Particionamento dos dados                              | 30        |
| 4.6          | Geração de pares candidatos                            | 31        |
| <b>4.6.1</b> | <b>Teto de recall imposto pela janela</b>              | <b>33</b> |
| 4.7          | Protocolo de avaliação                                 | 34        |
| 4.8          | Ajuste fino, ambiente experimental e rastreabilidade   | 35        |
| <b>5</b>     | <b>PROPOSTA DO PROTÓTIPO</b>                           | <b>38</b> |

|       |                                                                |           |
|-------|----------------------------------------------------------------|-----------|
| 5.1   | Visão geral e papel dos <i>baselines</i> . . . . .             | 38        |
| 5.2   | Os dois <i>encoders</i> comparados . . . . .                   | 39        |
| 5.2.1 | <b>BioBERTpt — <i>encoder</i> de domínio clínico</b> . . . . . | <b>39</b> |
| 5.2.2 | <b>BERTimbau — <i>encoder</i> de domínio geral</b> . . . . .   | <b>39</b> |
| 5.3   | Tratamento do desbalanceamento . . . . .                       | 40        |
| 5.4   | Representação de entrada: marcadores de posição . . . . .      | 40        |
| 5.4.1 | <b>O esquema adotado</b> . . . . .                             | <b>40</b> |
| 5.4.2 | <b>Exemplo</b> . . . . .                                       | <b>41</b> |
| 5.4.3 | <b>O que essa escolha deixa de fora</b> . . . . .              | <b>42</b> |
| 6     | <b>EXPERIMENTOS E RESULTADOS</b> . . . . .                     | <b>43</b> |
| 6.1   | Configuração experimental . . . . .                            | 43        |
| 6.2   | Curvas de treino e seleção de modelo . . . . .                 | 43        |
| 6.3   | Resultados no conjunto de teste . . . . .                      | 45        |
| 6.4   | Matrizes de confusão . . . . .                                 | 46        |
| 6.5   | Significância estatística . . . . .                            | 48        |
| 6.6   | Robustez à semente de treino . . . . .                         | 49        |
| 7     | <b>DISCUSSÃO</b> . . . . .                                     | <b>52</b> |
| 7.1   | Análise dos resultados . . . . .                               | 52        |
| 7.2   | A classe <code>associated_with</code> . . . . .                | 53        |
| 7.3   | Limitações . . . . .                                           | 54        |
| 7.4   | Ameaças à validade . . . . .                                   | 55        |
| 8     | <b>CONCLUSÃO</b> . . . . .                                     | <b>56</b> |
| 8.1   | Contribuições . . . . .                                        | 56        |
| 8.2   | Trabalhos futuros . . . . .                                    | 57        |
|       | <b>REFERÊNCIAS</b> . . . . .                                   | <b>59</b> |
|       | <b>APÊNDICES</b> . . . . .                                     | <b>61</b> |
|       | <b>APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS</b>    | <b>62</b> |
|       | <b>APÊNDICE B – MARCADORES DE NEGAÇÃO DO PORTUGUÊS</b>         |           |
|       | <b>CLÍNICO</b> . . . . .                                       | <b>63</b> |
|       | <b>APÊNDICE C – HIPERPARÂMETROS</b> . . . . .                  | <b>65</b> |

## 1 INTRODUÇÃO

O registro eletrônico em saúde concentra grande parte da informação clínica sob a forma de texto livre. Notas de evolução, sumários de alta e laudos são redigidos em linguagem natural, com abreviações idiossincráticas, ausência frequente de pontuação padronizada e construções negativas características do discurso médico. Essa riqueza textual, embora valiosa para pesquisa e apoio à decisão, permanece majoritariamente inacessível a consultas estruturadas, o que motiva o desenvolvimento de técnicas de Processamento de Linguagem Natural (PLN) capazes de transformar texto clínico em conhecimento estruturado.

No contexto da língua portuguesa, o avanço dessas técnicas foi historicamente limitado pela escassez de recursos anotados. A disponibilização do corpus **SemClinBr** (OLIVEIRA *et al.*, 2022), primeiro corpus clínico anotado semanticamente para o português, com mil documentos provenientes de múltiplas instituições e especialidades, criou condições para investigar tarefas antes restritas ao inglês, entre elas a extração de relações entre entidades clínicas.

### 1.1 PROBLEMA DE PESQUISA

A extração de entidades nomeadas identifica menções a conceitos clínicos (sintomas, doenças, achados, procedimentos), mas isoladamente não captura como esses conceitos se articulam no enunciado. Saber que um documento menciona “febre” não é suficiente. É preciso distinguir se a febre está *associada* ao quadro do paciente ou se está sendo *negada* (“paciente afebril”). Esse vínculo é o objeto da **extração de relações** (Relation Extraction, RE).

Este trabalho desenvolve o **RECLin-PT**, um modelo aprimorado de extração de relações em texto clínico em português sobre o corpus SemClinBr. Essa construção se dá em dois momentos, ambos conduzidos aqui. O primeiro responde a uma questão de projeto: *o pré-treinamento clínico importa para a extração de relações em textos médicos em português?* Responder a ela determina sobre qual *encoder*<sup>1</sup> o RECLin-PT

<sup>1</sup> *Encoder* é a metade codificadora da arquitetura Transformer, que recebe a sequência de entrada e devolve uma representação vetorial contextual de cada *token*, sem gerar texto novo. É o tipo de modelo do BERT e de suas variantes.

deve ser construído, e exige comparar dois modelos na *mesma* tarefa variando *somente* o *checkpoint*<sup>2</sup> de pré-treino. O segundo parte da base assim escolhida e a especializa na relação de negação, produzindo o modelo propriamente dito. O desafio é agravado por dois fatores inerentes ao corpus: o forte desbalanceamento entre as classes de relação e o fato de o SemClinBr anotar apenas relações positivas, exigindo a geração controlada de exemplos negativos.

Convém explicitar desde já o posicionamento assumido. A contribuição deste trabalho não está em propor uma arquitetura inédita, mas em estabelecer a cadeia experimental completa, que vai do texto bruto às métricas com teste de significância pareado. Essa cadeia é usada duplamente, para responder a essa questão e para construir o RECLinPT sobre a base que ela indica, medindo-o sob o mesmo crivo a que os *baselines* foram submetidos. A mesma cadeia permite que trabalhos futuros sobre o corpus sejam comparados em pé de igualdade. Trata-se de uma escolha deliberada de escopo, retomada e desenvolvida na Seção 3.3 e na Seção 5.1.

## 1.2 MOTIVAÇÃO

A negação clínica é um fenômeno linguístico de alto impacto, uma vez que tratar um achado negado como presente pode inverter completamente a interpretação de um prontuário. Em português, a negação é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”), e há a expectativa difundida de que modelos pré-treinados sobre texto do próprio domínio clínico capturem melhor essas construções do que modelos de domínio geral. Esse ganho, contudo, não é automático. Em inglês, Lin *et al.* (2020) reportam, na detecção de negação clínica, desempenho superior do BERT de domínio geral em relação a variantes submetidas a adaptação de domínio. Para o português, não localizamos avaliação controlada que isole o efeito do pré-treinamento de domínio na extração de relações clínicas. A comparação direta entre *encoders* clínicos e de domínio geral sobre o SemClinBr foi conduzida para o reconhecimento de entidades (ALMEIDA *et al.*, 2026), e não para a etapa de relações (Capítulo 3). Construir esse teste de forma reproduzível, desde o texto bruto até as métricas finais, é em si uma contribuição metodológica, dado que o compartilhamento restrito de modelos

<sup>2</sup> *Checkpoint* é o arquivo com os pesos de um modelo já pré-treinado, distribuído publicamente e usado como ponto de partida do ajuste fino.



e o detalhamento insuficiente do ajuste fino<sup>3</sup> são críticas recorrentes à literatura de PLN biomédico (FRAILE NAVARRO *et al.*, 2023; SHIMAOKA *et al.*, 2026). O teste não se esgota, contudo, em si mesmo. Dele sai a base sobre a qual o RECLin-PT é construído, e é o mesmo protocolo que depois mede o modelo especializado. Isolar esse efeito exige, porém, enunciar a tarefa por inteiro, e não apenas como um detector de negação. Como o SemClinBr anota somente relações positivas, o rótulo `no_relation` precisa ser construído para representar os pares sem vínculo, sem o que a avaliação ficaria restrita ao conjunto já anotado; e `associated_with`, a outra relação positiva do corpus, é mantida como classe própria para que `negation_of` seja decidida contra uma alternativa concreta, e não apenas contra a ausência de relação. Daí a formulação em três classes que os objetivos a seguir enunciam, detalhada na Seção 2.2 e na Seção 4.6. É também o impacto clínico da negação que justifica dirigir a ela, e não ao conjunto das três classes, a especialização que dá origem ao RECLin-PT.

## 1.3 OBJETIVOS

### 1.3.1 Objetivo geral

Desenvolver, de forma reprodutível, um *pipeline* determinístico de extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, considerando o espaço de rótulos `negation_of`, `associated_with` e `no_relation`, e, sobre essa infraestrutura, avaliar sob protocolo estatístico rigoroso (macro-F1 e F1 por classe, com teste de significância pareado) se o pré-treinamento de domínio clínico traz ganho para a tarefa, comparando um *encoder* clínico (BioBERTpt) e um de domínio geral (BERTimbau) sob paridade total de implementação; e, a partir da base assim identificada, construir nesta mesma fase o **RECLin-PT**, modelo especializado de extração de relações clínicas em português com foco na classe `negation_of`, avaliado sob o mesmo protocolo e entregue como parte deste trabalho.

<sup>3</sup> Ajuste fino (fine-tuning) é o retreinamento de um modelo pré-treinado sobre os dados de uma tarefa específica, partindo dos pesos já aprendidos em vez de uma inicialização aleatória (DEVLIN *et al.*, 2019).

### 1.3.2 Objetivos específicos

- Construir um *parser* fiel ao formato XML do SemClinBr que produza uma representação canônica determinística do corpus.
- Caracterizar o corpus por meio de análise exploratória, quantificando a distribuição das relações e a distância entre entidades relacionadas.
- Definir uma partição treino/desenvolvimento/teste em nível de documento, estratificada e congelada, de modo a evitar vazamento de dados.
- Implementar um gerador determinístico de pares candidatos compartilhado por todos os modelos, garantindo a comparabilidade dos resultados.
- Ajustar (*fine-tuning*) dois *encoders* para o português na tarefa de extração de relações: um de domínio clínico (BioBERTpt) e um de domínio geral (BERTimbau).
- Garantir paridade total de implementação entre os dois ajustes, mantendo-os sob um único núcleo de código, de modo que difiram apenas no *checkpoint* de pré-treino.
- Comparar os dois *baselines* sob teste de significância pareado (McNemar e *bootstrap* pareado<sup>4</sup> no F1 de `negation_of`), reportando macro-F1, F1 por classe, MCC e acurácia.
- Avaliar a robustez do resultado à semente de treino, treinando ambos os modelos com uma segunda inicialização e repetindo todo o protocolo estatístico.
- Identificar, a partir dessa comparação, a melhor base sobre a qual desenvolver o RECLin-PT.
- Construir o RECLin-PT a partir do *encoder* identificado como base mais adequada, com adaptação direcionada à classe `negation_of`, e avaliá-lo sob o mesmo protocolo estatístico aplicado aos *baselines*.

<sup>4</sup> O *bootstrap* pareado estima a incerteza de uma diferença de desempenho reamostrando com reposição o mesmo conjunto de teste para os dois modelos, sem supor uma distribuição para a métrica. O procedimento adotado está descrito na Seção 4.7.

## 1.4 ORGANIZAÇÃO DO TRABALHO

O Capítulo 2 apresenta os fundamentos de PLN clínico, extração de relações e modelos baseados em transformers. O Capítulo 3 discute trabalhos relacionados, com ênfase em recursos para o português. O Capítulo 4 descreve o corpus, o *pipeline* de processamento, a geração de pares candidatos, o ajuste fino dos *encoders* e o protocolo de avaliação. O Capítulo 5 detalha a proposta de modelo. O Capítulo 6 reporta os experimentos e resultados. O Capítulo 7 analisa limitações e ameaças à validade, e o Capítulo 8 sintetiza as contribuições e aponta trabalhos futuros.

## 2 REFERENCIAL TEÓRICO

Este capítulo reúne os fundamentos necessários à compreensão do trabalho: o processamento de linguagem natural aplicado a textos clínicos, a tarefa de extração de relações, as abordagens baseadas em regras e em aprendizado, e os modelos de linguagem baseados em transformers.

### 2.1 PROCESSAMENTO DE LINGUAGEM NATURAL CLÍNICO

O PLN clínico ocupa-se da análise automática de textos produzidos no cuidado em saúde, como notas de evolução, sumários de alta e laudos. Esses textos apresentam características que os distinguem da linguagem geral: vocabulário técnico, abreviações não padronizadas, telegrafismo (omissão de elementos gramaticais) e prevalência de construções negativas e de incerteza. Tais propriedades tornam a transferência direta de ferramentas treinadas em domínio aberto pouco eficaz, motivando recursos e modelos específicos do domínio.

### 2.2 EXTRAÇÃO DE ENTIDADES E DE RELAÇÕES

A extração de informação em texto clínico costuma ser decomposta em duas tarefas encadeadas. A primeira, **reconhecimento de entidades nomeadas** (Named Entity Recognition, NER), delimita trechos do texto que mencionam conceitos de interesse e lhes atribui um tipo semântico. A segunda, **extração de relações** (RE), determina se um par de entidades mantém uma relação e de que tipo. Formalmente, dado um par ordenado de entidades  $(e_1, e_2)$  em um documento, a RE pode ser modelada como um problema de classificação que associa ao par um rótulo dentro de um conjunto pré-definido.

Neste trabalho o espaço de rótulos é `negation_of`, `associated_with` e `no_relation`. O rótulo `no_relation` é fundamental. Como a anotação de corpora registra apenas relações positivas, todo par de entidades não anotado deve ser tratado como ausência de relação, o que introduz um forte desbalanceamento de classes.

## 2.3 ABORDAGENS BASEADAS EM REGRAS E A NEGAÇÃO CLÍNICA

Abordagens baseadas em regras codificam conhecimento linguístico explícito. Em detecção de negação clínica, o algoritmo **NegEx** (CHAPMAN *et al.*, 2001) tornou-se referência. A partir de um léxico de gatilhos de negação e de janelas de contexto, ele classifica achados como negados ou afirmados. Sua simplicidade e eficácia derivam do fato de a negação clínica ser altamente lexicalizada. Em português, gatilhos como “não”, “sem”, “nega” e “ausência de”, além de adjetivos que embutem negação morfológicamente (“afebril”, “anictérico”), sustentam estratégias análogas (Apêndice B). A alta lexicalização sugere que o sinal de negação possa estar acessível mesmo a modelos não especializados no domínio clínico, hipótese que este trabalho testa diretamente.

## 2.4 ABORDAGENS BASEADAS EM APRENDIZADO DE MÁQUINA

Métodos aprendidos estimam, a partir de exemplos rotulados, a associação entre características do par de entidades e o rótulo da relação. Modelos lineares como a regressão logística, alimentados por características léxicas (por exemplo, representações TF-IDF do texto entre as entidades) e estruturais (tipos das entidades, distância, direção), oferecem um compromisso entre interpretabilidade e desempenho e são frequentemente empregados como *sanity check* antes de modelos mais custosos. Sua principal limitação é a representação de palavras como unidades independentes, incapaz de capturar dependências de longo alcance e contexto, limitação que motivou a transição da área para modelos contextuais.

## 2.5 MODELOS BASEADOS EM TRANSFORMERS

A arquitetura Transformer (VASWANI *et al.*, 2017), baseada em mecanismos de atenção, viabilizou modelos de linguagem pré-treinados que produzem representações contextuais das palavras. O **BERT** (DEVLIN *et al.*, 2019) popularizou o paradigma de pré-treinamento seguido de ajuste fino (fine-tuning) para tarefas específicas. Para o português, os candidatos naturais à extração de relações clínicas dividem-se entre modelos de **domínio geral** e modelos **adaptados ao domínio clínico**. No primeiro grupo está o **BERTimbau** (SOUZA; NOGUEIRA; LOTUFO, 2020), pré-treinado no

corpus brWaC<sup>1</sup> e hoje a referência de domínio geral para a língua; nele também se enquadram modelos multilíngues como o **XLM-R** (CONNEAU *et al.*, 2020), que trocam especialização por cobertura ampla de idiomas. No segundo grupo está o **BioBERTpt** (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e textos biomédicos em português brasileiro. É o contraste entre esses dois grupos que estrutura a proposta deste trabalho, que compara o BioBERTpt ao BERTimbau sob paridade total de implementação; o XLM-R permanece como alternativa de base ampla, relevante ao panorama, mas fora do escopo experimental aqui delimitado.

---

<sup>1</sup> O brWaC (Brazilian Portuguese Web as Corpus) é um corpus de larga escala construído a partir de páginas web em português brasileiro, sem restrição de domínio.

### 3 TRABALHOS RELACIONADOS

Este capítulo situa o trabalho em relação a recursos e estudos de extração de informação clínica, com ênfase na língua portuguesa.

#### 3.1 RECURSOS E DESAFIOS EM INGLÊS

A extração de relações clínicas consolidou-se em língua inglesa em torno de campanhas de avaliação como as séries Informatics for Integrating Biology and the Bedside (i2b2) e National NLP Clinical Challenges (n2c2) (UZUNER *et al.*, 2011), que disponibilizaram corpora anotados e tarefas compartilhadas para problemas como relações entre medicamentos, dosagens e efeitos adversos. Esses esforços estabeleceram protocolos de avaliação e evidenciaram a importância de tratar adequadamente o desbalanceamento de classes e o vazamento de dados entre partições, preocupações transpostas para este trabalho. O vazamento é endereçado pelo particionamento em nível de documento (Seção 4.5), e o desbalanceamento, pela geração controlada de pares candidatos e pelo tratamento explícito da assimetria de classes que dela resulta (Seção 4.6).

Quanto aos modelos, o **BioBERT** (LEE *et al.*, 2020) demonstrou os ganhos da adaptação de domínio biomédico em inglês, estabelecendo o precedente que motiva a questão investigada nesta monografia. Quanto à representação de entrada, a delimitação do par por marcadores de entidade inseridos no próprio texto (SOARES *et al.*, 2019) tornou-se a técnica padrão para extração de relações com modelos baseados em BERT, e é a adotada aqui (Seção 5.4).

#### 3.2 RECURSOS PARA O PORTUGUÊS

O desenvolvimento de PLN clínico em português foi por muito tempo limitado pela ausência de corpora anotados de acesso controlado. O **SemClinBr** (OLIVEIRA *et al.*, 2022) preencheu parte dessa lacuna ao disponibilizar mil documentos clínicos anotados semanticamente, acompanhados de dicionários de abreviações e de pistas de negação. É o corpus central deste trabalho.

No plano dos modelos, o **BioBERTpt** (SCHNEIDER *et al.*, 2020) adaptou o paradigma de modelos de linguagem contextuais ao domínio clínico e biomédico em português brasileiro, demonstrando ganhos em reconhecimento de entidades nomeadas clínicas em relação a modelos de domínio geral. O **BERTimbau** (SOUZA; NOGUEIRA; LOTUFO, 2020), por sua vez, é a referência de domínio geral para o português, pré-treinado no corpus brWaC. Modelos multilíngues como o XLM-R (CONNEAU *et al.*, 2020) oferecem uma alternativa de base ampla, útil como ponto de comparação futuro.

Quanto às tarefas efetivamente atacadas em português, o levantamento aqui conduzido aponta concentração fora da extração de relações. Uma revisão sistemática de 28 estudos de modelos de linguagem em português voltados à saúde, publicados entre janeiro de 2020 e novembro de 2024, inventaria as tarefas tratadas, a saber, classificação (16 modelos), reconhecimento de entidades nomeadas (8), modelagem de tópicos, resposta a perguntas, geração de texto e agentes conversacionais. A extração de relações não figura nesse inventário (SHIMAOKA *et al.*, 2026). O desequilíbrio não é exclusivo do português. Uma revisão de 94 estudos de extração de informação em texto clínico registra 63 dedicados a reconhecimento de entidades contra 13 dedicados a extração de relações (FRAILE NAVARRO *et al.*, 2023). O trabalho de extração de relações em texto clínico em português aqui localizado (SILVA *et al.*, 2023) anota um corpus próprio de oncologia em português brasileiro e menciona três *encoders* candidatos (BERT multilíngue, BioBERTpt e BERTimbau), mas não reporta comparação entre eles e resolve a etapa de relações com uma rede BiLSTM, sem teste de significância; o efeito do pré-treinamento de domínio sobre a extração de relações, portanto, não é isolado ali.

É digno de nota que os ganhos relatados para o BioBERTpt foram medidos em NER, e não em extração de relações. O modelo é avaliado em dois corpora de narrativas clínicas na tarefa de reconhecimento de entidades (SCHNEIDER *et al.*, 2020). O BERTimbau, por sua vez, é avaliado em similaridade textual, inferência textual e reconhecimento de entidades, todas tarefas de domínio geral (SOUZA; NOGUEIRA; LOTUFO, 2020). A comparação direta entre os dois sobre o SemClinBr, sob protocolo de treinamento unificado, foi conduzida para o reconhecimento de entidades (ALMEIDA *et al.*, 2026), e não para a extração de relações. Não localizamos, para o português,



trabalho que verifique se a vantagem do pré-treinamento clínico se transfere para a extração de relações, lacuna que este trabalho endereça.

### 3.3 POSICIONAMENTO DESTE TRABALHO

Enquanto os trabalhos em português localizados na Seção 3.2 concentram-se em classificação e NER, e o de extração de relações não isola o efeito do *checkpoint* de pré-treino, este trabalho aborda a etapa subsequente de extração de relações sobre o SemClinBr e, como ponto de partida do RECLin-PT, *testa* de forma controlada se o ganho do pré-treinamento clínico observado em NER se transfere para a extração de relações, com atenção particular à negação clínica. A contribuição não está em propor uma arquitetura inédita, mas em estabelecer, de maneira reproduzível e estatisticamente fundamentada, uma cadeia completa, do texto bruto às métricas com teste de significância pareado, que sirva de referência comparável para trabalhos futuros sobre o mesmo corpus, e em responder a uma questão de projeto que não localizamos endereçada, para o português, sob comparação controlada.

## 4 METODOLOGIA

Este capítulo descreve o corpus, o *pipeline* de processamento, a estratégia de particionamento, a geração de pares candidatos, o ajuste fino dos *encoders* e o protocolo de avaliação. Todas as etapas foram projetadas sob a premissa de **reprodutibilidade**: ordenação determinística das saídas, serialização fixa, semente aleatória registrada e verificação por hashes SHA-256.

### 4.1 VISÃO GERAL DO PIPELINE

Entende-se por *pipeline* de PLN uma sequência encadeada de etapas em que a saída de cada estágio é a entrada do seguinte, de modo que o dado bruto é progressivamente transformado até a métrica final. Estruturar o trabalho como um *pipeline* explícito tem duas vantagens: isola a responsabilidade de cada etapa (facilitando o teste e a auditoria isolados) e torna o caminho completo **reproduzível**, pois cada estágio é determinístico e seus artefatos podem ser verificados de forma independente. As etapas deste trabalho, na ordem em que são executadas, são:

1. **Parsing (XML bruto → dataset.jsonl).** O *parser* converte cada documento XML do SemClinBr em um registro canônico JSONL (texto, entidades e relações). É necessário porque o formato XML original, fiel à anotação, não é prático para as etapas seguintes; a representação canônica unifica o acesso ao corpus.
2. **Particionamento (dataset.jsonl → *splits*).** O conjunto é dividido em treino, desenvolvimento e teste em nível de documento. É necessário para separar dados de ajuste dos de avaliação sem vazamento (Seção 4.5).
3. **Geração de pares candidatos (*splits* → candidatos rotulados).** Como o corpus só anota relações positivas, esta etapa constrói os exemplos negativos (*no\_relation*), produzindo o espaço de classificação completo (Seção 4.6).
4. **Marcação de entidades (candidatos → texto marcado).** Cada par candidato é transformado na *string* de entrada do *encoder*, que consiste em uma janela de texto em torno do par, com as duas entidades delimitadas por marcadores

(Seção 5.4 do Capítulo 5). É necessária para informar ao modelo *quais* trechos da janela formam o par sob análise e qual deles é o primeiro argumento da relação.

5. **Ajuste fino (texto marcado → modelo treinado).** Cada *encoder* é ajustado sobre os candidatos marcados da partição de treino, com seleção de modelo pelo desempenho na partição de desenvolvimento. É a etapa que produz o classificador empregado no estágio seguinte; o ambiente e os hiperparâmetros estão na Seção 4.8, e a representação de entrada e a paridade entre os dois *encoders*, no Capítulo 5.
6. **Classificação (texto marcado → predições).** Cada *baseline* ou modelo atribui um rótulo do conjunto {negation\_of, associated\_with, no\_relation} a cada candidato (Capítulo 5).
7. **Avaliação (predições → métricas).** As predições são comparadas ao *gold* para produzir macro-F1, F1 por classe, MCC e acurácia, com testes pareados entre os modelos (Seção 4.7).

O **determinismo** é garantido em *todas* as etapas, condição para que os *hashes* SHA-256 dos artefatos sejam estáveis entre execuções: a serialização JSONL é fixada byte a byte (`ensure_ascii=False`, `sort_keys=True`, quebras de linha LF); a ordenação das saídas é explícita (documentos por `doc_id`, candidatos por `(start, end, id)`); a semente do particionamento é fixada em 42, e a semente de treino é registrada em cada artefato de resultado. As seções seguintes detalham cada etapa. A Figura 1 (Seção 4.2) situa a origem do dado de entrada, ilustrando o processo de criação e anotação do SemClinBr que antecede o *pipeline* aqui descrito.

## 4.2 CORPUS SEMCLINBR

O trabalho utiliza o corpus SemClinBr (OLIVEIRA *et al.*, 2022)<sup>1</sup>, composto por mil documentos clínicos em português anotados com entidades e relações. O corpus é distribuído sob licença restrita, mediante solicitação formal, e seus arquivos XML originais são tratados como **imutáveis** ao longo do *pipeline*. As relações anotadas

<sup>1</sup> Repositório do corpus e formulário de requisição de acesso em [github.com/HAILab-PUCPR/SemClinBr](https://github.com/HAILab-PUCPR/SemClinBr).

no corpus público utilizado pertencem a dois tipos, *associated\_with* e *negation\_of*, sobre os quais se constrói o espaço de rótulos da tarefa. A Figura 1 ilustra o processo de criação e anotação do corpus.




Figura 1 – Processo de criação e anotação do corpus SemClinBr

Fonte: Oliveira et al. (2022).

#### 4.3 PARSING E REPRESENTAÇÃO CANÔNICA

Um *parser* converte cada arquivo XML em um registro canônico no formato JSONL<sup>2</sup>, com identificador do documento, texto, lista de entidades (tipo e *offsets*) e lista de relações. O *parser* é *fiel ao XML*, ou seja, não normaliza tipos de entidade ou de relação, e deixa tais decisões para etapas posteriores. A única transformação aplicada ao texto é o colapso de quebras de linha ( $\backslash r \backslash n$ ,  $\backslash r$ ,  $\backslash n$ ) em espaço único, necessário para manter o alinhamento dos *offsets* de anotação.

Por se tratar de um corpus com inconsistências de anotação conhecidas, o *parser* executa verificações de sanidade (correspondência entre o texto extraído por *offset* e o atributo anotado, validade dos intervalos e integridade referencial das relações) e, quando possível, corrige automaticamente pequenos deslocamentos de *offset* ( $\pm 1$  e  $\pm 2$  caracteres). As inconsistências são acumuladas em um log de avisos em vez de interromperem o processamento.

<sup>2</sup> JSONL (JSON Lines) é um formato textual em que cada linha do arquivo é um objeto JSON independente, o que permite ler e gravar grandes conjuntos registro a registro.

#### 4.4 CARACTERIZAÇÃO DO CORPUS

A análise exploratória (Exploratory Data Analysis, EDA) foi conduzida sobre a representação canônica do corpus, totalizando 1 000 documentos, 45 508 entidades (média de 45,5 por documento) e 11 458 relações (média de 11,5 por documento). A mediana é de 10 relações por documento, o percentil 90 é de 24 e o máximo observado é de 65; 46 documentos (4,60%) não possuem nenhuma relação anotada. Essa caracterização quantifica a distribuição das relações, a distância entre entidades relacionadas e as categorias de entidade, fornecendo subsídio empírico para as decisões de projeto das etapas seguintes.

##### 4.4.1 Distribuição dos tipos de relação

A Tabela 1 e a Figura 2 mostram o forte desbalanceamento entre os dois tipos de relação anotados, com predominância de `associated_with` (85,98%) sobre `negation_of` (14,02%). Esse desequilíbrio motiva tanto a escolha do macro-F1 como métrica principal quanto o tratamento explícito de classes nos modelos aprendidos.

Tabela 1 – Distribuição dos tipos de relação no corpus parseado.


| Tipo de relação              | N             | %             |
|------------------------------|---------------|---------------|
| <code>negation_of</code>     | 1.606         | 14,02         |
| <code>associated_with</code> | 9.852         | 85,98         |
| <b>Total</b>                 | <b>11.458</b> | <b>100,00</b> |

Fonte: elaborado pelo autor a partir do SemClinBr (`data/processed/dataset.jsonl`).

##### 4.4.2 Distância entre entidades relacionadas

A Tabela 2 e a Figura 3 indicam que as relações ocorrem entre entidades próximas, com mediana da distância de poucos caracteres e percentil 95 que não ultrapassa algumas dezenas (`associated_with`: média 11,8, mediana 4, p95 43; `negation_of`: média 3,5, mediana 1, p95 15). O contraste entre os dois tipos é o achado relevante. A negação é praticamente adjacente, pois em 75% dos casos a distância é de um único caractere, enquanto a associação se distribui por uma cauda bem mais longa. Essa assimetria fundamenta a escolha da janela máxima (`max_gap=25`) na geração de

Figura 2 – Distribuição dos tipos de relação no SemClinBr.




Fonte: elaborado pelo autor (scripts/make\_tcc\_eda.py).

pares candidatos, discutida na Seção 4.6.1. Uma janela estreita preserva quase toda a classe-alvo e limita a explosão combinatória de negativos, ao custo de um teto de *recall* concentrado em *associated\_with*.

Tabela 2 – Distância em caracteres entre as entidades de cada relação, por tipo.

| Tipo            | N     | média | p25 | p50 | p75 | p90 | p95 |
|-----------------|-------|-------|-----|-----|-----|-----|-----|
| negation_of     | 1.606 | 3,5   | 1   | 1   | 1   | 11  | 15  |
| associated_with | 9.852 | 11,8  | 1   | 4   | 10  | 25  | 43  |

Fonte: elaborado pelo autor a partir do SemClinBr (data/processed/dataset.jsonl).


Figura 3 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200), com a janela *max\_gap* assinalada.

Fonte: elaborado pelo autor (scripts/make\_tcc\_eda.py).

#### 4.4.3 Relações por documento e categorias de entidade


A Figura 4 apresenta a distribuição do número de relações por documento, e a Figura 5, as categorias de entidade mais frequentes (após decomposição das anotações multirótulo separadas por "|"). As categorias predominantes refletem a natureza telegráfica e abreviada do texto clínico: Abbreviation (12592), Finding (6827), Therapeutic or Preventive Procedure (4759) e Sign or Symptom (4616). Vale notar a presença expressiva da categoria Negation (2646), coerente com a importância do fenômeno de negação tratado neste trabalho.

Figura 4 – Distribuição do número de relações por documento.



Fonte: elaborado pelo autor (scripts/make\_tcc\_eda.py).

Figura 5 – Categorias atômicas de entidade mais frequentes (15 primeiras).



Fonte: elaborado pelo autor (scripts/make\_tcc\_eda.py).

## 4.5 PARTICIONAMENTO DOS DADOS

A partição segue a razão 80/10/10 em **nível de documento**, e não de relação. Essa escolha previne o vazamento de dados, pois relações de um mesmo documento compartilham vocabulário e trechos repetidos, e dividi-las entre partições diferentes inflaria artificialmente as métricas de teste. A partição é **estratificada** pela presença das classes `negation_of` e `associated_with` em cada documento, por meio do algoritmo de estratificação multirrótulo de Sechidis, Tsoumakas e Vlahavas (2011), de modo a garantir representação estável da classe minoritária em todas as partições.

A partição é gerada com semente fixa (42) e **congelada**. Os arquivos de treino, desenvolvimento e teste e seus respectivos *hashes* SHA-256 são versionados (Apêndice A), evitando que comparações entre execuções sejam confundidas com variação de amostragem. O resultado são 800 documentos de treino, 100 de desenvolvimento e 100 de teste.

A Tabela 3 apresenta a distribuição real das relações entre as partições. O ponto crítico é que a classe minoritária `negation_of`, que representa 14,02% das relações do corpus, permanece bem representada em todas as partições, com proporções de 14,09% no treino, 15,70% na validação e 12,16% no teste. A estratificação atua sobre a *presença* das classes em cada documento, e não sobre a contagem de relações. Com isso, ela garante que nenhuma partição fique sem exemplos da classe rara, mas não iguala percentuais; daí a variação de cerca de três pontos percentuais observada. Essa garantia é o que importa para o protocolo, uma vez que um particionamento puramente aleatório poderia, por azar de amostragem, sub-representar `negation_of` no conjunto de teste, comprometendo a estabilidade da estimativa de F1 dessa classe. Com 152 relações `negation_of` no teste, a estimativa permanece interpretável, ainda que com incerteza amostral relevante, razão pela qual todas as comparações do Capítulo 6 são acompanhadas de teste pareado e intervalo de confiança, e não apenas do valor pontual.

A Figura 6 apresenta a mesma informação em barras agrupadas (escala logarítmica), com o percentual de `negation_of` de cada partição anotado na legenda. A leitura visual reforça o ponto anterior. A classe rara está presente em volume comparável nas três




Tabela 3 – Distribuição real das relações por partição (*splits* congelados, semente 42).

| Partição     | Documentos   | associated_with | negation_of  | Total relações | % negation_of |
|--------------|--------------|-----------------|--------------|----------------|---------------|
| Treino       | 800          | 7.922           | 1.299        | 9.221          | 14,09         |
| Validação    | 100          | 832             | 155          | 987            | 15,70         |
| Teste        | 100          | 1.098           | 152          | 1.250          | 12,16         |
| <b>Total</b> | <b>1.000</b> | <b>9.852</b>    | <b>1.606</b> | <b>11.458</b>  | <b>14,02</b>  |

Fonte: elaborado pelo autor (data/splits/MANIFEST.json).

partições, mas sua fração não é constante, e a partição de teste é justamente a de menor proporção.

Figura 6 – Distribuição das relações por partição (escala logarítmica), com o percentual de *negation\_of* anotado.



Fonte: elaborado pelo autor (scripts/make\_tcc\_eda.py).

#### 4.6 GERAÇÃO DE PARES CANDIDATOS

O SemClinBr anota apenas relações *positivas*. Cada relação registrada indica que existe vínculo entre duas entidades, mas a ausência de anotação não é, por si, um exemplo negativo explícito. Avaliar um classificador no espaço {*negation\_of*, *associated\_with*, *no\_relation*} exige, portanto, **construir** os exemplos negativos. Treinar ou avaliar apenas com os pares anotados produziria um classificador binário sobre as duas classes positivas, incapaz de operar em um cenário real, em que o sistema recebe *todos* os pares de entidades de um documento e precisa decidir, para cada um, se há

relação e de que tipo. A classe `no_relation` é o que torna a tarefa aplicável fora do conjunto anotado.

A geração é feita pela função `iter_candidate_pairs` (`src/candidates.py`), compartilhada por todos os modelos e *baselines*, condição necessária para que os resultados fiquem na mesma régua estatística. Para cada documento, ela percorre todos os **pares ordenados** de entidades  $(e_1, e_2)$ , com  $e_1 \neq e_2$ . A ordem importa, uma vez que a direção é relevante para a negação. Em seguida, descarta os pares cuja distância em caracteres exceda a janela máxima (`max_gap=25`) e os pares entre documentos distintos, e atribui o rótulo. Se o par ordenado  $(e_1, e_2)$  coincide com uma relação anotada, ele recebe o tipo *gold*; caso contrário, recebe `no_relation`. A emissão segue ordenação determinística por  $(start, end, id)$ , de modo que o conjunto de candidatos e o *hash* das predições sejam estáveis entre execuções.

Em resumo, o gerador respeita cinco propriedades. **(i) Ordenação determinística:** os pares são emitidos sempre na mesma ordem por  $(start, end, id)$  de  $e_1$  e depois de  $e_2$ , requisito do qual depende a estabilidade das predições entre execuções. **(ii) Sem cruzamento entre documentos:** nunca se forma um par com entidades de documentos distintos, pois o documento é a unidade de processamento. **(iii) Janela respeitada:** apenas pares cuja distância em caracteres (entre o fim de  $e_1$  e o início de  $e_2$ ) seja  $\leq \text{max\_gap} = 25$  são gerados. **(iv) Sem autopares:** nunca se forma o par  $(e, e)$  de uma entidade consigo mesma ( $e_1 \neq e_2$ ), nem entre entidades com *span* idêntico. **(v) Conferência com o *gold*:** um par presente nas relações anotadas do documento recebe o tipo real (`associated_with` ou `negation_of`), e um par ausente recebe `no_relation` (amostragem negativa).

A Quadro 1 ilustra o processo em um trecho real do corpus. A relação anotada é  $16 \rightarrow 52 = \text{negation\_of}$  (a entidade “NÃO ESPECIFICADA” nega “OSTEOMIELITE”). Das seis combinações ordenadas possíveis entre as três entidades próximas, apenas o par  $(16, 52)$  casa com o *gold*; os outros cinco tornam-se `no_relation`. A representação de entrada para os modelos contextuais delimita o par com marcadores de posição, por exemplo `[E1] OSTEOMIELITE [/E1] [E2] NÃO ESPECIFICADA [/E2]` (Seção 5.4).

A Tabela 4 reporta o resultado do procedimento nas três partições: 152686 candi-

Quadro 1 – Exemplo de geração de candidatos para um trecho do SemClinBr.

Entidades: 16=“OSTEOMIELEITE” (*Disease or Syndrome*), 52=“NÃO ESPECIFICADA” (*Negation*), 17=“INTUBADO” (*Finding*). Relação *gold*: 16 → 52 = *negation\_of*.

| Par ordenado | Rótulo gerado                                        |
|--------------|------------------------------------------------------|
| 16 → 52      | <i>negation_of</i> (casa com o <i>gold</i> )         |
| 16 → 17      | <i>no_relation</i>                                   |
| 52 → 16      | <i>no_relation</i> (direção inversa do <i>gold</i> ) |
| 52 → 17      | <i>no_relation</i>                                   |
| 17 → 16      | <i>no_relation</i>                                   |
| 17 → 52      | <i>no_relation</i>                                   |

Fonte: elaborado pelo autor (`src/candidates.py`).

dados de treino, 19064 de validação e 19210 de teste. A consequência direta é um conjunto de teste fortemente desbalanceado. Dos 19210 pares candidatos, 18062 (94,02%) pertencem à classe *no\_relation*, enquanto *associated\_with* e *negation\_of* somam, respectivamente, 996 e 152 instâncias. Esse desbalanceamento de  $\approx 16:1$  é intrínseco à tarefa, e não um artefato evitável, pois decorre da combinatória de pares de entidades. Ele é tratado, nos modelos aprendidos, pela reescala de perda `class_weight="balanced"` (Capítulo 5), e, na avaliação, pela escolha do macro-F1 como métrica principal, que dá peso igual às três classes.

Tabela 4 – Pares candidatos gerados por partição (`max_gap= 25`) e distribuição dos rótulos.

| Partição  | Candidatos | <i>negation_of</i> | <i>associated_with</i> | <i>no_relation</i> | % <i>no_relation</i> |
|-----------|------------|--------------------|------------------------|--------------------|----------------------|
| Treino    | 152.686    | 1.255              | 7.096                  | 144.335            | 94,53                |
| Validação | 19.064     | 150                | 763                    | 18.151             | 95,21                |
| Teste     | 19.210     | 152                | 996                    | 18.062             | 94,02                |

Fonte: elaborado pelo autor (`src/candidates.py`); confere com o campo `n_candidates` de `results/baseline_*.json`.

#### 4.6.1 Teto de recall imposto pela janela

A janela `max_gap= 25` impõe um **teto de recall**. Toda relação *gold* cujo par fique a mais de 25 caracteres jamais é gerada como candidato e, portanto, é irrecuperável por qualquer classificador, independentemente da arquitetura. A Tabela 5 quantifica esse

limite por partição, e o ponto essencial é que ele **não se distribui igualmente entre as classes**. Na classe-alvo *negation\_of*, a perda é nula ou marginal, pois **nenhuma** das 152 relações do conjunto de teste é descartada, contra 3 de 155 na validação e 27 de 1299 no treino (2,08%), valor coerente com a mediana de distância de 1 caractere observada na EDA. Em *associated\_with*, ao contrário, a perda é substantiva, com 100 de 1098 no teste (9,11%), o que puxa o teto agregado do conjunto de teste para 92,00%.

Trata-se de uma **decisão de projeto documentada**, um compromisso entre o *recall* de *associated\_with* e a explosão combinatória de candidatos negativos, tomado em favor da classe que este trabalho investiga. A consequência deve ser lida junto com os resultados. O F1 de *associated\_with* reportado no Capítulo 6 é medido *sob* esse teto, e não sobre o conjunto completo de relações anotadas. Como o teto é idêntico para todos os modelos, que recebem exatamente os mesmos candidatos, ele limita o desempenho absoluto, mas não afeta a comparação entre eles.

A tabela também reporta, em coluna separada, as *duplicatas de anotação* colapsadas, isto é, relações *gold* repetidas com o mesmo par ordenado e tipo, que o gerador representa uma única vez. Estas **não** reduzem o teto, pois a relação permanece recuperável, sendo apenas redundância de anotação do corpus.

Tabela 5 – Teto de *recall* imposto pela janela `max_gap= 25` por partição.

| Partição     | Total ouro    | Perdas <i>negation_of</i> | Perdas <i>associated_with</i> | Duplicatas colapsadas | Teto recall (%) |
|--------------|---------------|---------------------------|-------------------------------|-----------------------|-----------------|
| Treino       | 9.221         | 27 (2,08%)                | 806 (10,17%)                  | 37                    | 90,97           |
| Validação    | 987           | 3 (1,94%)                 | 68 (8,17%)                    | 3                     | 92,81           |
| Teste        | 1.250         | 0 (0,00%)                 | 100 (9,11%)                   | 2                     | 92,00           |
| <b>Total</b> | <b>11.458</b> | <b>30 (1,87%)</b>         | <b>974 (9,89%)</b>            | <b>42</b>             | <b>91,24</b>    |

Fonte: elaborado pelo autor (`scripts/make_tcc_eda.py`).

#### 4.7 PROTOCOLO DE AVALIAÇÃO

A métrica principal é o **macro-F1**, que atribui peso igual às três classes e, portanto, penaliza modelos que ignoram as classes minoritárias, comportamento desejável dado o desbalanceamento. Classes ausentes nas predições recebem F1 nulo em vez de serem descartadas, conforme recomendado por Forman e Scholz (2010). Reporta-se também o F1 por classe, o micro-F1 (equivalente à acurácia neste cenário de rótulo

único) e o *coeficiente de correlação de Matthews* (MCC), robusto a desbalanceamento. A métrica que responde diretamente à pergunta “o modelo detecta bem a negação?” é o F1 de `negation_of` no conjunto de teste, tratada aqui como **métrica-alvo**.

A comparação entre modelos emprega dois testes pareados complementares, ambos calculados sobre o *mesmo* conjunto de teste a partir das predições salvas, o que elimina a variância entre amostras da comparação e mede exatamente a diferença entre os modelos.

O **teste de McNemar** (DIETTERICH, 1998) olha apenas as instâncias em que os dois modelos discordam quanto ao acerto. Monta-se a tabela de discordâncias ( $b$  = o primeiro acerta e o segundo erra;  $c$  = o inverso) e, sob a hipótese nula de mesma taxa de acerto, avalia-se  $b \sim \text{Binomial}(b+c, 0,5)$  pelo **teste binomial exato**. Ele mede se os padrões de erro *globais* diferem, mas não é específico de uma classe.

O **bootstrap pareado** responde à pergunta específica da classe-alvo. Reamostram-se, com reposição, as instâncias do conjunto de teste 10000 vezes; a cada reamostragem recalcula-se a diferença  $F1_A - F1_B$  no F1 de `negation_of`, e reportam-se a diferença média, o intervalo de confiança de 95% (percentis 2,5/97,5) e um valor- $p$  bilateral. Adota-se como critério de decisão a **exclusão do zero pelo IC95%**. Se o intervalo contém zero, a diferença não é considerada estatisticamente significativa ao nível  $\alpha = 0,05$ .

Por fim, como **análise de robustez à inicialização**, ambos os modelos são treinados também com uma segunda semente (43), e todo o protocolo acima é repetido sobre esses resultados. Essa análise é parte do protocolo, e não um complemento opcional, pois, como o Capítulo 6 mostra, o veredito do teste pareado depende da semente, e reportar uma única execução por modelo daria uma impressão de definitividade que os dados não sustentam.

#### 4.8 AJUSTE FINO, AMBIENTE EXPERIMENTAL E RASTREABILIDADE

As etapas de *parsing*, particionamento, geração de candidatos, análise exploratória e testes de significância executam em CPU; o ajuste fino dos *encoders* é executado em

ambiente com GPU (Google Colab<sup>3</sup>, Tesla T4), com o mesmo núcleo de código para os dois modelos. O Quadro 2 consolida o ambiente e os hiperparâmetros comuns às duas execuções.

Quadro 2 – Ambiente experimental e hiperparâmetros compartilhados pelos dois *baselines*.

| Item                     | Valor                                                               |
|--------------------------|---------------------------------------------------------------------|
| Ajuste fino (GPU)        | Google Colab, Tesla T4                                              |
| Demais etapas            | CPU                                                                 |
| Núcleo de implementação  | src/relation_extraction.py (idêntico para os dois <i>encoders</i> ) |
| max_gap                  | 25 caracteres                                                       |
| ctx_chars                | 128 caracteres em torno do par                                      |
| max_length               | 128 <i>tokens</i>                                                   |
| <i>Batch</i>             | 64                                                                  |
| Taxa de aprendizado      | $2 \times 10^{-5}$ (AdamW), escalonador linear com <i>warmup</i>    |
| Épocas                   | 3                                                                   |
| Perda                    | <i>cross-entropy</i> com <code>class_weight="balanced"</code>       |
| Seleção de modelo        | maior macro-F1 no conjunto de validação                             |
| Sementes de treino       | 42 (referência) e 43 (robustez)                                     |
| <i>Bootstrap</i> pareado | 10.000 reamostragens, percentis 2,5/97,5                            |
| Comparação pareada       | McNemar (binomial exato) + <i>bootstrap</i> pareado                 |

Fonte: elaborado pelo autor (campo `config` de `results/baseline_*.json`).

A rastreabilidade é reforçada por três mecanismos: a semente de treino é registrada em cada arquivo de resultado, junto com a configuração completa; os *splits* congelados são verificados por *hashes* SHA-256 (Apêndice A); e cada métrica reportada tem um arquivo JSON correspondente em `results/`, do qual as tabelas e figuras deste trabalho são geradas por *script*, nunca transcritas à mão.<sup>4</sup>

<sup>3</sup> Ambiente hospedado pelo Google para execução de *notebooks* Python com acesso a GPU, disponível em [colab.research.google.com](https://colab.research.google.com).

<sup>4</sup> O código, os *scripts* de geração das tabelas e figuras e os arquivos de resultado estão em [github.com/angeloalsf/RECLin-PT](https://github.com/angeloalsf/RECLin-PT). O corpus SemClinBr não é redistribuído ali, por ter licença própria



## 5 PROPOSTA DO PROTÓTIPO

Este capítulo descreve a proposta de solução para a extração de relações clínicas. O trabalho integra o desenvolvimento do **RECLin-PT**, um modelo aprimorado de extração de relações em texto clínico em português. Como etapa inicial dessa construção, conduz-se um **experimento controlado de *baselines*** que responde a uma pergunta de projeto anterior a qualquer aprimoramento: *o pré-treinamento clínico importa para a extração de relações em textos médicos em português?* A resposta determina sobre qual *encoder* o RECLin-PT deve ser construído.

### 5.1 VISÃO GERAL E PAPEL DOS *BASELINES*

Comparam-se dois *encoders* para o português, tratados como *baselines* sob a mesma tarefa: o **BioBERTpt** (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e biomédicas em português, e o **BERTimbau** (SOUZA; NOGUEIRA; LOTUFO, 2020), pré-treinado em texto de domínio geral (brWaC). Os dois compartilham a mesma arquitetura base (BERT) e diferem essencialmente no corpus de pré-treinamento, o que os torna candidatos naturais a um experimento controlado sobre a importância do domínio de pré-treino.

A premissa metodológica central é a **paridade**. A infraestrutura descrita aqui não constitui um modelo com nome próprio, e sim a cadeia que viabiliza a comparação de forma justa. Os dois *baselines* compartilham um único núcleo de implementação (`src/relation_extraction.py`) e são, por construção, idênticos em tudo exceto no *checkpoint* carregado:

- a mesma partição congelada e os mesmos pares candidatos (Capítulo 4), o que coloca os dois sob o mesmo teto de *recall* e na mesma régua estatística;
- a mesma representação de entrada por marcadores de entidade (Seção 5.4);
- a mesma função de perda, *cross-entropy* com `class_weight="balanced"`;
- o mesmo escalonador linear com *warmup* e os mesmos hiperparâmetros de otimização (Quadro 2);



- a mesma semente de treino e o mesmo critério de seleção de modelo, o maior macro-F1 no conjunto de validação.

Trocar um *baseline* pelo outro consiste, literalmente, em mudar a *string* do *checkpoint*. Qualquer diferença observada pode, portanto, ser atribuída ao pré-treinamento, e não a artefatos de implementação. Essa é exatamente a condição para que a pergunta de pesquisa tenha resposta.

## 5.2 OS DOIS *ENCODERS* COMPARADOS

### 5.2.1 BioBERTpt — *encoder* de domínio clínico

O **BioBERTpt** (`pucpr/biobertpt-all`)<sup>1</sup> (SCHNEIDER *et al.*, 2020) é um modelo contextual adaptado ao domínio clínico e biomédico em português brasileiro, com 177,9 milhões de parâmetros. Sua adoção corresponde à expectativa, difundida na literatura e sustentada pelos ganhos relatados em reconhecimento de entidades nomeadas clínicas, de que o pré-treinamento sobre texto do próprio domínio produza representações mais adequadas a tarefas clínicas. É essa expectativa que o experimento coloca à prova.

### 5.2.2 BERTimbau — *encoder* de domínio geral

O **BERTimbau** (`neuralmind/bert-base-portuguese-cased`)<sup>2</sup> (SOUZA; NOGUEIRA; LOTUFO, 2020) é a referência de domínio geral para o português, pré-treinado no corpus brWaC, com 108,9 milhões de parâmetros, cerca de 60% do tamanho do BioBERTpt. Ele entra no experimento como o controle que isola o efeito do domínio de pré-treino, e não como modelo secundário. Se o desempenho for equivalente, o modelo menor é preferível por custo de inferência e de memória, consideração concreta para implantação em ambientes clínicos com recursos limitados.

<sup>1</sup> *Checkpoint* público em [huggingface.co/pucpr/biobertpt-all](https://huggingface.co/pucpr/biobertpt-all).

<sup>2</sup> *Checkpoint* público em [huggingface.co/neuralmind/bert-base-portuguese-cased](https://huggingface.co/neuralmind/bert-base-portuguese-cased).

### 5.3 TRATAMENTO DO DESBALANCEAMENTO

Uma decisão central, comum aos dois *baselines*, é o uso de `class_weight="balanced"` na função de perda, que reescala o erro de forma inversamente proporcional à frequência de cada classe. Sem esse ajuste, o otimizador minimizaria o erro simplesmente prevendo `no_relation` para quase tudo, dado que essa classe concentra 94,02% dos candidatos de teste. A reescala força o modelo a “pagar” caro por erros nas classes raras, sem descartar dados nem introduzir o não-determinismo de uma subamostragem. Como a mesma estratégia é aplicada aos dois *encoders*, seu efeito é compartilhado e não confunde a comparação.

A seleção de modelo usa o conjunto de validação (macro-F1), com o conjunto de teste reservado a uma única avaliação final. Os hiperparâmetros efetivamente utilizados constam do Apêndice C.

### 5.4 REPRESENTAÇÃO DE ENTRADA: MARCADORES DE POSIÇÃO

O modelo contextual não recebe o par de entidades de forma abstrata, e sim um recorte do *texto* do documento com o par delimitado por **marcadores de entidade**. A técnica é padrão em extração de relações com modelos baseados em BERT (SOARES *et al.*, 2019). Inserir no próprio texto marcadores que delimitam  $e_1$  e  $e_2$  é mais eficaz do que concatenar representações de *span* isoladas, pois permite que o mecanismo de atenção condicione a codificação de toda a janela ao par sob análise.

#### 5.4.1 O esquema adotado

A função `build_marked_window` (`src/relation_extraction.py`) recorta uma janela de  $\pm 128$  caracteres em torno do par (`ctx_chars`) e insere quatro delimitadores, no esquema

[E1] superfície <sub>$e_1$</sub>  [/E1] ... [E2] superfície <sub>$e_2$</sub>  [/E2]

Os quatro marcadores são registrados como *tokens*<sup>3</sup> especiais no *tokenizer* (`add_`

<sup>3</sup> *Tokens* são as unidades em que o *tokenizer* divide o texto antes de entregá-lo ao modelo, e podem ser palavras inteiras ou fragmentos de palavra. Os especiais não vêm do texto e recebem um vetor

`special_tokens`), e a matriz de *embeddings* do modelo é redimensionada (`resize_token_embeddings`) para lhes dar um vetor dedicado, aprendido durante o ajuste fino.

Três propriedades desse esquema merecem registro explícito, por delimitarem exatamente *que informação* o modelo recebe:

1. **Os marcadores são posicionais, não semânticos.** Eles indicam quais trechos da janela formam o par e qual deles é o primeiro argumento, e nada mais. O **tipo semântico** anotado pelo SemClinBr (`Disease or Syndrome`, `Negation`, `Finding...`) **não é passado ao modelo**, e cabe a ele inferir a natureza de cada entidade a partir da superfície textual e do contexto.
2. **A direção vem da etiqueta, não da ordem.** A inserção é feita por deslocamento de caractere; quando  $e_2$  precede  $e_1$  no texto, a *string* resultante começa por `[E2]`. A direção da relação, que importa para `negation_of`, é preservada por *qual* marcador envolve *qual* entidade, e não pela ordem em que os marcadores aparecem.
3. **A classificação usa a representação agregada da sequência.** O cabeçote é o de `AutoModelForSequenceClassification`, que projeta a representação agregada da sequência (o *token* `[CLS]`) nas três classes. Não há extração explícita dos estados ocultos dos marcadores. Eles influenciam a predição por meio da atenção, ao condicionar a codificação da janela inteira ao par delimitado.

Como a mesma representação é aplicada aos dois *encoders*, qualquer efeito dessas escolhas é compartilhado e não confunde a comparação (Capítulo 6).

#### 5.4.2 Exemplo

Aplicado ao trecho do Quadro 1, o par *gold* 16 → 52 produz a entrada reproduzida no Quadro 3. Note que nem `Disease or Syndrome` (tipo de “OSTEOMIELOITE”) nem `Negation` (tipo de “NÃO ESPECIFICADA”) aparecem na entrada, pois o modelo vê apenas o texto e os delimitadores.

---

próprio.

Quadro 3 – Entrada efetivamente construída para o par *gold* do Quadro 1.

---

... CURATIVO COM ASPECTO LIMPO E SECO. SEGUE EM OBSERVAÇÃO. [E1]  
 OSTEOMIELOITE [/E1] [E2] NÃO ESPECIFICADA [/E2]. INTUBADO, SOB  
 VENTILAÇÃO MECÂNICA, MONITORIZAÇÃO CARDÍACA ...

---

Fonte: elaborado pelo autor (saída de `build_marked_window` para o documento 8906 do SemClinBr, `ctx_chars=128`).

#### 5.4.3 O que essa escolha deixa de fora

Registrar o que *não* entra na representação é tão importante quanto descrever o que entra. O SemClinBr anota cada entidade com tipos semânticos da UMLS, frequentemente em **rótulos múltiplos** separados por “|” (por exemplo, `Medical Device|Finding|Abbreviation`). Essa anotação **não chega ao modelo**. Os resultados do Capítulo 6 foram obtidos com marcadores puramente posicionais, e a natureza de cada entidade tem de ser inferida da superfície textual e do contexto.

A anotação de tipo, aliás, não é diretamente aproveitável na forma em que vem. No conjunto de treino ocorrem apenas 89 tipos *atômicos* distintos, mas a combinação multirrótulo faz o número de *strings* de tipo distintas subir para 828, das quais 752 contêm “|”. Injetar essa *string* diretamente no marcador seria contraproducente, pois cada uma das 828 combinações viraria um símbolo praticamente único e mal povoado no treino, prejudicando a generalização. Aproveitá-la exigiria, antes, um esquema de normalização que colapsasse as combinações em um vocabulário pequeno e estável.

Para a pergunta desta etapa, porém, a ausência do tipo é inclusive conveniente. Como nenhum dos dois *encoders* recebe a informação semântica pronta, a comparação mede a capacidade de cada um de *inferi-la* do texto, e é exatamente aí que o pré-treinamento de domínio deveria fazer diferença.

## 6 EXPERIMENTOS E RESULTADOS

Este capítulo reporta os experimentos conduzidos e seus resultados. Os dois *encoders* descritos no Capítulo 5 foram ajustados sobre a mesma partição congelada e avaliados sobre o mesmo conjunto de teste, composto por 19210 pares candidatos (18062 *no\_relation*, 996 *associated\_with* e 152 *negation\_of*), gerados conforme o Capítulo 4. As métricas seguem o protocolo ali descrito.

### 6.1 CONFIGURAÇÃO EXPERIMENTAL

Cada *encoder* foi ajustado por 3 épocas, com *batch* de 64, taxa de aprendizado  $2 \times 10^{-5}$  (AdamW) e *max\_length* de 128 *tokens*, sob *cross-entropy* ponderada por *class\_weight="balanced"*. A época reportada é a de maior macro-F1 no conjunto de validação; o conjunto de teste foi avaliado uma única vez, ao final. Os dois modelos foram treinados com a semente de referência 42 e, como análise de robustez, novamente com a semente 43, mantendo, em ambos os casos, todos os demais elementos idênticos (Quadro 2).

O conjunto de teste é fortemente desbalanceado, e a classe *no\_relation* concentra 94,02% dos pares. Esse cenário torna o macro-F1 a métrica mais informativa, por penalizar modelos que negligenciam as classes minoritárias, e faz da acurácia uma métrica enganosa isoladamente, dado que um classificador que respondesse sempre *no\_relation* acertaria mais de 94% dos candidatos sem qualquer utilidade clínica.

### 6.2 CURVAS DE TREINO E SELEÇÃO DE MODELO


A Figura 7 apresenta a evolução por época dos dois *encoders* nas duas sementes, e a Tabela 6 traz os mesmos valores em número. Três observações são relevantes.

Primeiro, a **perda de treino cai monotonicamente** nas quatro execuções, enquanto a perda de validação estabiliza ou volta a subir a partir da segunda época, comportamento típico de ajuste fino de *encoders* sobre conjuntos pequenos. Segundo, e mais importante para o protocolo, o **macro-F1 de validação continua subindo** mesmo quando a perda de validação piora. É o caso do BERTimbau na semente 43, cuja

perda de validação sobe de 0,426 (época 2) para 0,474 (época 3) enquanto o macro-F1 avança de 0,654 para 0,680. Sob forte desbalanceamento, perda e macro-F1 não são intercambiáveis como critério de parada, e selecionar pela perda teria descartado a melhor época em termos da métrica de interesse, razão pela qual a seleção de modelo usa explicitamente o macro-F1 de validação.

Terceiro, as curvas tornam visível a **diferença de estabilidade** entre os *encoders*. O BERTimbau percorre trajetórias quase sobrepostas nas duas sementes na perda de treino, e o BioBERTpt, não. Na semente 42 ele parte de um F1 de *negation\_of* de 0,436 na primeira época, contra 0,588 na semente 43, e só recupera terreno ao longo do treino. Essa distância de 0,152 entre as duas sementes do mesmo *encoder* contrasta com os 0,056 observados no BERTimbau na mesma época. Essa dispersão, visível desde a primeira época, é a mesma que reaparece nas métricas finais (Seção 6.6).

Figura 7 – Evolução por época dos dois *encoders* nas sementes 42 e 43: perda (à esquerda) e F1 no conjunto de validação (à direita). Marcador preenchido indica a época selecionada.



Fonte: elaborado pelo autor (scripts/make\_tcc\_curves.py).

Tabela 6 – Evolução por época no conjunto de validação. \* marca a época selecionada (maior macro-F1 na validação), cujo *checkpoint* produziu as métricas de teste.

| Modelo              | Semente | Época | Perda (treino) | Perda (val.) | Macro-F1 (val.) | F1 negation_of (val.) | Duração (min) |
|---------------------|---------|-------|----------------|--------------|-----------------|-----------------------|---------------|
| BioBERTpt (clínico) | 42      | 1     | 0,7588         | 0,4582       | 0,544           | 0,436                 | 58,8          |
|                     |         | 2     | 0,4401         | 0,4005       | 0,622           | 0,628                 | 58,9          |
|                     |         | 3*    | 0,3173         | 0,4404       | 0,653           | 0,673                 | 58,9          |
|                     | 43      | 1     | 0,6558         | 0,4290       | 0,586           | 0,588                 | 59,7          |
|                     |         | 2*    | 0,3937         | 0,4212       | 0,685           | 0,736                 | 59,7          |
|                     |         | 3     | 0,2856         | 0,4505       | 0,683           | 0,722                 | 59,5          |
| BERTimbau (geral)   | 42      | 1     | 0,6995         | 0,4784       | 0,633           | 0,630                 | 56,7          |
|                     |         | 2     | 0,4031         | 0,4217       | 0,650           | 0,660                 | 56,7          |
|                     |         | 3*    | 0,3055         | 0,4492       | 0,663           | 0,695                 | 56,7          |
|                     | 43      | 1     | 0,7280         | 0,4459       | 0,586           | 0,573                 | 53,1          |
|                     |         | 2     | 0,4109         | 0,4261       | 0,654           | 0,677                 | 53,3          |
|                     |         | 3*    | 0,3048         | 0,4739       | 0,680           | 0,707                 | 53,3          |

Fonte: elaborado pelo autor (campo `dev_history` de `results/baseline_*.json`).

### 6.3 RESULTADOS NO CONJUNTO DE TESTE

A Tabela 7 consolida os resultados dos dois *baselines* na semente de referência. Os melhores valores por coluna estão em negrito.

Tabela 7 – Resultados dos *baselines* no conjunto de teste ( $n = 19.210$ , semente 42). Negrito indica o melhor valor por coluna.


| Modelo              | Macro-F1     | F1 <sub>neg</sub> | F1 <sub>assoc</sub> | F1 <sub>no_rel</sub> | MCC          | Acurácia     |
|---------------------|--------------|-------------------|---------------------|----------------------|--------------|--------------|
| BioBERTpt (clínico) | 0,675        | 0,677             | 0,415               | 0,933                | 0,453        | 0,880        |
| BERTimbau (geral)   | <b>0,686</b> | <b>0,694</b>      | <b>0,426</b>        | <b>0,938</b>         | <b>0,460</b> | <b>0,888</b> |

Fonte: elaborado pelo autor (`results/baseline_*_seed42.json`).

Os dois *baselines* apresentam desempenho praticamente indistinguível. O BERTimbau geral atinge macro-F1 de 0,686 e o BioBERTpt clínico, 0,675, uma diferença de 0,011 em favor do *encoder* geral. Na métrica-alvo, o F1 de *negation\_of*, a ordenação se mantém, e o BERTimbau geral (0,694) supera marginalmente o BioBERTpt clínico (0,677). As demais métricas seguem o mesmo padrão de quase empate. Ambos alcançam *recall* alto na negação e, neste caso, *idêntico* (0,901 nos dois *encoders*), com precisão moderada ( $\approx 0,54\text{--}0,56$ ), e ambos têm na classe *associated\_with* a maior dificuldade ( $F1 \approx 0,42\text{--}0,43$ ), com alta cobertura mas baixa precisão. A Figura 8 resume

o F1 por classe dos dois *baselines*, cujas barras são praticamente coincidentes em todas as classes.

Figura 8 – F1 por classe no conjunto de teste: BioBERTpt (clínico) vs. BERTimbau (geral), semente 42.



Fonte: elaborado pelo autor (`scripts/make_tcc_artifacts.py`).


## 6.4 MATRIZES DE CONFUSÃO

As Figuras 9 e 10 apresentam as matrizes de confusão dos dois *baselines*, **normalizadas por linha**, de modo que cada célula indica a fração das instâncias de uma classe verdadeira atribuída a cada classe predita. Os valores da diagonal correspondem, assim, ao *recall* por classe. Essa visão complementa o F1 por classe ao revelar *para onde* vão os erros de cada modelo.

Os dois padrões de erro são notavelmente semelhantes, com diagonal forte na negação e na classe majoritária, e o erro dominante remanescente na confusão entre *associated\_with* e *no\_relation*, coerente com a baixa precisão daquela classe nos dois modelos. A semelhança qualitativa entre as matrizes reforça a leitura de que os dois *encoders* aprendem essencialmente a mesma função para esta tarefa, pois não apenas chegam a números próximos, mas erram nos mesmos lugares.




Figura 9 – Matriz de confusão do BioBERTpt (clínico), normalizada por linha.



Fonte: elaborado pelo autor (scripts/make\_tcc\_artifacts.py).

Figura 10 – Matriz de confusão do BERTimbau (geral), normalizada por linha.



Fonte: elaborado pelo autor (scripts/make\_tcc\_artifacts.py).

## 6.5 SIGNIFICÂNCIA ESTATÍSTICA

A proximidade dos valores pontuais sugere empate, mas a conclusão exige um teste pareado. A Tabela 8 reporta a comparação direta entre os dois *baselines* no conjunto de teste, na semente de referência.

Tabela 8 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ( $n = 19.210$ , semente 42).

| Medida                                                       | Valor            |
|--------------------------------------------------------------|------------------|
| F1 <i>negation_of</i> — BioBERTpt (A)                        | 0,677            |
| F1 <i>negation_of</i> — BERTimbau (B)                        | 0,694            |
| Diferença observada (A – B)                                  | –0,017           |
| McNemar: $b$ (só A acerta) / $c$ (só B acerta)               | 540 / 695        |
| McNemar: valor- $p$ (binomial exato)                         | < 0,001          |
| <i>Bootstrap</i> pareado: IC95% da diferença                 | [–0,053; +0,018] |
| <i>Bootstrap</i> pareado: valor- $p$                         | 0,3450           |
| <b>Diferença significativa (<math>\alpha = 0,05</math>)?</b> | <b>Não</b>       |

Fonte: elaborado pelo autor (results/significance\_biobertpt\_vs\_bertimbau\_seed42.json).

No F1 de *negation\_of*, a diferença observada é de apenas –0,017 (a favor do BERTimbau geral). Os dois testes, contudo, **não respondem à mesma pergunta**, e nesta semente eles divergem, o que exige lê-los separadamente.

O teste de McNemar incide sobre o *padrão global de acertos*, em todas as três classes. Ele rejeita a hipótese nula de igualdade ( $p \approx 1,1 \times 10^{-5}$ ). Das 1235 instâncias em que os modelos discordam, 540 favorecem o BioBERTpt e 695 o BERTimbau, assimetria grande demais para o acaso. Há, portanto, diferença mensurável entre os dois *encoders no conjunto dos candidatos*, e ela aponta para o *encoder* geral, o que é coerente com a vantagem em macro-F1 e em *associated\_with* vista na Seção 6.3.

O *bootstrap* pareado, por sua vez, incide diretamente sobre a métrica-alvo, o F1 de *negation\_of*, e aí o resultado é outro. O intervalo de confiança de 95% para a diferença é [–0,053; +0,018], que **inclui o zero**, com valor- $p$  de 0,345. **Na classe que este trabalho investiga não há diferença estatisticamente significativa** entre o

*encoder* clínico e o geral *nesta semente*. A leitura conjunta é, então, precisa. A vantagem do *encoder* geral é real no agregado, mas não se sustenta na negação, que é onde a hipótese do pré-treinamento clínico seria testada. A ressalva de semente permanece relevante, pois a análise a seguir mostra que nem este veredito nem a direção da diferença *nessa classe* se repetem na semente 43, ao contrário do que aponta o McNemar, que se repete.

## 6.6 ROBUSTEZ À SEMENTE DE TREINO

Para situar a magnitude da diferença entre os *baselines*, ambos foram treinados com uma segunda semente (43), mantendo todo o restante idêntico. A Tabela 9 consolida as métricas por semente e a amplitude observada.

Tabela 9 – Robustez à semente de treino: métricas de teste por semente, média e amplitude observada.

| Modelo              | Métrica            | Semente 42 | Semente 43 | Média | Amplitude |
|---------------------|--------------------|------------|------------|-------|-----------|
| BioBERTpt (clínico) | Macro-F1           | 0,675      | 0,712      | 0,694 | 0,038     |
|                     | F1 negation_of     | 0,677      | 0,754      | 0,715 | 0,078     |
|                     | F1 associated_with | 0,415      | 0,439      | 0,427 | 0,024     |
|                     | F1 no_relation     | 0,933      | 0,944      | 0,938 | 0,011     |
| BERTimbau (geral)   | Macro-F1           | 0,686      | 0,704      | 0,695 | 0,018     |
|                     | F1 negation_of     | 0,694      | 0,702      | 0,698 | 0,008     |
|                     | F1 associated_with | 0,426      | 0,460      | 0,443 | 0,035     |
|                     | F1 no_relation     | 0,938      | 0,950      | 0,944 | 0,012     |

Fonte: elaborado pelo autor (scripts/aggregate\_seeds.py → results/summary\_by\_seed.json).

O contraste entre os dois *encoders* é acentuado. No BioBERTpt, o macro-F1 sobe de 0,675 (semente 42) para 0,712 (semente 43), e o F1 de *negation\_of*, de 0,677 para 0,754, uma amplitude de 0,078 atribuível *apenas* à inicialização aleatória do treino. Essa variação entre sementes de um *mesmo* modelo é quase **cinco vezes maior** que a diferença de 0,017 observada entre o BioBERTpt e o BERTimbau na semente 42. Em outras palavras, o ruído de treino do *encoder* clínico, isoladamente, supera qualquer vantagem que se pudesse atribuir ao domínio de pré-treino.

O BERTimbau, sob a mesma troca de semente, mostra-se sensivelmente mais estável.

O macro-F1 passa de 0,686 para 0,704 e o F1 de *negation\_of*, de 0,694 para 0,702, uma amplitude de 0,008, cerca de dez vezes menor que a do BioBERTpt na mesma métrica.

O ponto metodologicamente mais delicado é que o *veredito estatístico* também muda. A Tabela 10 aplica à semente 43 exatamente o mesmo protocolo da Seção 6.5.

Tabela 10 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ( $n = 19.210$ , semente 43).

| Medida                                                       | Valor           |
|--------------------------------------------------------------|-----------------|
| F1 <i>negation_of</i> — BioBERTpt (A)                        | 0,754           |
| F1 <i>negation_of</i> — BERTimbau (B)                        | 0,702           |
| Diferença observada (A – B)                                  | 0,053           |
| McNemar: $b$ (só A acerta) / $c$ (só B acerta)               | 442 / 624       |
| McNemar: valor- $p$ (binomial exato)                         | $< 0,001$       |
| <i>Bootstrap</i> pareado: IC95% da diferença                 | [0,016; +0,090] |
| <i>Bootstrap</i> pareado: valor- $p$                         | 0,0054          |
| <b>Diferença significativa (<math>\alpha = 0,05</math>)?</b> | <b>Sim</b>      |

Fonte: elaborado pelo autor (results/significance\_biobertpt\_vs\_bertimbau\_seed43.json).

Na semente 43, a ordenação entre os dois *baselines* no F1 de negação **se inverte**. O BioBERTpt clínico passa à frente, com margem de 0,053, e o *bootstrap* pareado sobre essa métrica, que na semente 42 não rejeitava a hipótese nula, passa a acusar a diferença como **significativa**, agora em favor do *encoder* clínico (IC95% [+0,016; +0,090],  $p = 0,0054$ ).

Essa inversão é da **métrica-alvo**, e não do padrão global de erro; a distinção entre os dois testes, estabelecida na Seção 6.5, é o que permite enunciá-la sem ambiguidade. O teste de McNemar incide sobre o conjunto dos candidatos, e não sobre a classe investigada. Ele rejeita a hipótese nula nas duas sementes e, nas duas, **aponta para o mesmo lado**. Na semente 43, das 1066 instâncias em que os modelos discordam, 442 favorecem o BioBERTpt e 624 o BERTimbau ( $p \approx 2,7 \times 10^{-8}$ ), a mesma assimetria em favor do *encoder* geral já observada na semente 42 (540 contra 695,  $p \approx 1,1 \times 10^{-5}$ ). A acurácia global acompanha essa direção em ambas (0,880 contra 0,888 na semente

42; 0,898 contra 0,908 na 43). O que troca de sinal entre as sementes é, portanto, o desempenho na classe `negation_of` especificamente, e não o padrão de acertos dos dois modelos sobre o conjunto de teste.

Esse contraste **não estabelece a superioridade de nenhum dos dois *encoders* na classe investigada**. O que ele mostra é mais forte do que a instabilidade de um veredito. Sob protocolo, partição e conjunto de teste idênticos, não apenas a conclusão do teste pareado *sobre a métrica-alvo* alterna entre “sem diferença” e “diferença significativa”, como o próprio **sinal** dessa diferença se inverte em função apenas da inicialização do treino. No F1 de `negation_of`, a semente 42 aponta para o *encoder* geral e a 43 para o clínico, ambas sobre as mesmas 19210 instâncias.

O que não atravessa as duas sementes é, portanto, a direção *na métrica-alvo*. No agregado ela atravessa, pois tanto o McNemar quanto a acurácia apontam para o *encoder* geral nas duas. A troca de semente não desfaz a comparação entre os dois modelos sobre o conjunto de teste; desfaz a leitura sobre a classe específica em que a hipótese do pré-treinamento clínico seria testada. A isso se soma a **menor previsibilidade** do *encoder* clínico entre reinicializações, com amplitude de 0,078 no F1 de `negation_of` contra 0,008 do geral. Tomada a média das duas sementes, o BioBERTpt fica marginalmente à frente na métrica-alvo (0,715 contra 0,698) e empatado em macro-F1 (0,694 contra 0,695), mas com dispersão uma ordem de grandeza maior, o que torna essa média pouco informativa como estimativa de desempenho esperado. Com duas execuções por modelo, nenhuma leitura estatística de direção deve ser tomada como definitiva; o que os dados sustentam é que a escolha do *checkpoint* de pré-treino tem, nesta tarefa, efeito menor que o da semente de treino.

## 7 DISCUSSÃO

Este capítulo interpreta os resultados obtidos, discute limitações do trabalho e aponta ameaças à validade dos achados.

### 7.1 ANÁLISE DOS RESULTADOS

O resultado central é a **ausência de vantagem consistente do pré-treinamento clínico**. Para a extração de relações no SemClinBr, no espaço de três classes, o BioBERTpt não produz ganho estável sobre o BERTimbau, nem mesmo na classe *negation\_of*, em que a especialização de domínio seria mais plausível. Convém precisar o que os testes sustentam, porque o quadro é menos confortável que um empate. Na métrica-alvo, o veredito de *empate* vale para a semente 42 e não se repete na semente 43, em que o *bootstrap* pareado sobre o F1 de *negation\_of* acusa diferença significativa, e em favor do *encoder* clínico. O que *não* se mantém entre as duas sementes é a *direção nessa classe*, uma vez que o sinal da diferença se inverte. A instabilidade é da métrica-alvo, e não do padrão global de erro. O teste de McNemar, que incide sobre o conjunto dos candidatos, rejeita a hipótese nula nas duas sementes e aponta nas duas para o *encoder* geral (540 contra 695 discordâncias na semente 42; 442 contra 624 na 43), assim como a acurácia. O que se mantém, além dessa direção agregada, é a *magnitude relativa*. Em ambas as sementes, a variação de um mesmo *encoder* entre sementes supera a diferença medida entre *encoders* distintos (Seção 6.6). É nesse sentido, e apenas nesse, que não há ganho atribuível ao domínio de pré-treino. O motivo não é uma derrota do clínico, que chega a ficar à frente na negação sob a semente 43, mas o fato de a diferença entre os dois na classe investigada não sobreviver à troca de uma semente. Esse achado contrasta com a expectativa difundida, bem como com os ganhos relatados para o reconhecimento de entidades nomeadas clínicas em português (SCHNEIDER *et al.*, 2020), de que modelos de domínio sempre se transfiram melhor.

Duas explicações são plausíveis e compatíveis com os dados.

A primeira é **linguística**. A negação clínica em português é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”, além de adjetivos que embutem negação morfolo-

gicamente, como “afebril” e “anictérico”, conforme o Apêndice B). Esse sinal é frequente e regular o bastante para que um *encoder* de domínio geral, com vocabulário amplo do português, o capture sem desvantagem consistente em relação a um clínico. A caracterização do corpus reforça essa leitura, pois a mediana da distância entre as entidades de uma relação `negation_of` é de um único caractere (Seção 4.2), ou seja, o gatilho de negação está praticamente colado ao achado negado. Detectá-lo depende pouco de conhecimento clínico especializado.

A segunda é **estrutural**. A tarefa, tal como formulada, depende mais da estrutura local do par, isto é, da direção, da proximidade e da delimitação das entidades, do que de conhecimento lexical especializado de domínio, e essa estrutura é fornecida igualmente aos dois *baselines* pela representação de entrada compartilhada (Seção 5.4). A semelhança entre as matrizes de confusão (Seção 6.4) é a evidência mais direta disso. Os dois modelos não apenas chegam a números próximos, mas concentram o erro no mesmo lugar, a fronteira entre `associated_with` e `no_relation`.

Um corolário prático, e diretamente relevante para o desenvolvimento do RECLin-PT, é a **eficiência**. O BERTimbau iguala o BioBERTpt em macro-F1 médio (0,695 contra 0,694) com aproximadamente 60% dos parâmetros (108,9 contra 177,9 milhões). Quando o desempenho é equivalente, o modelo menor é preferível por custo de inferência e de memória, consideração concreta para implantação em ambientes clínicos com recursos limitados. A esse argumento soma-se a estabilidade, dado que a amplitude entre sementes do BERTimbau na métrica-alvo (0,008) é cerca de dez vezes menor que a do BioBERTpt (0,078), o que torna seu desempenho mais previsível em uma nova execução. Vale registrar a contrapartida. É justamente essa dispersão que permite ao BioBERTpt superar o geral na semente 43, de modo que a preferência pelo *encoder* menor se justifica por previsibilidade e custo, não por superioridade média na métrica-alvo.

## 7.2 A CLASSE ASSOCIATED\_WITH

A classe `associated_with` permanece a mais difícil para os dois modelos ( $F1 \approx 0,43$ ), com alta cobertura e baixa precisão. Duas causas se somam.

A primeira é **conceitual**. Distinguir associação genuína de mera proximidade textual é intrinsecamente ambíguo em texto clínico telegráfico, em que entidades vizinhas frequentemente não mantêm relação anotada, como ilustra o próprio exemplo de geração de candidatos (Quadro 1), em que cinco dos seis pares ordenados possíveis são `no_relation`.

A segunda é **metodológica**. A janela `max_gap=25` descarta 9,11% das relações `associated_with` do conjunto de teste (Seção 4.6.1), enquanto não descarta *nenhuma* relação `negation_of`. O F1 dessa classe é, portanto, medido sob um teto de *recall* substancialmente mais baixo que o das demais. Como o teto é idêntico para os dois modelos, ele não afeta a comparação, objeto deste trabalho, mas qualquer leitura do valor absoluto de F1 de `associated_with` precisa levá-lo em conta.

### 7.3 LIMITAÇÕES

A limitação mais séria recai sobre a própria caracterização de empate. Ela vale para a semente 42; a comparação pareada refeita na semente 43 acusa diferença significativa, e em favor do BioBERTpt clínico, invertendo o sinal observado na semente de referência. A conclusão prática, a ausência de ganho *confiável* atribuível ao pré-treinamento clínico, sobrevive a essa inversão, porque se apoia na instabilidade da diferença e não em sua direção; mas qualquer afirmação sobre *qual encoder* é superior depende inteiramente da semente e não está sustentada por estes experimentos. Além disso, **duas sementes por modelo não bastam** para estimar um intervalo de confiança sobre essa variação, e o desvio reportado na Tabela 9 deve ser lido como dispersão observada, não como estimativa de variância. Fechar a questão exige um número maior de repetições com agregação formal.

A tarefa pressupõe **entidades já anotadas** (*gold*). A avaliação não considera o erro propagado de uma etapa de reconhecimento de entidades nomeadas automática, de modo que os resultados refletem a extração de relações isoladamente. Em um cenário fim a fim, os valores absolutos seriam necessariamente menores.

Por fim, o achado é específico desta **formulação de três classes** e desta **escala de modelo** (*base*). Não se pode excluir que o pré-treinamento clínico volte a importar em



espaços de relação mais ricos, em modelos maiores ou em cenários com menos dados de ajuste.

#### 7.4 AMEAÇAS À VALIDADE

Quanto à **validade interna**, o congelamento das partições com semente fixa e verificação por *hashes* SHA-256 (Apêndice A), somado ao particionamento em nível de documento, mitiga o vazamento de dados, a principal causa de resultados não reproduzíveis em PLN biomédico. A paridade total de implementação entre os dois *baselines* (Capítulo 5) garante que a diferença medida reflita o *checkpoint*, e não artefatos de código. Restam, contudo, decisões de projeto que influenciam os números absolutos, das quais a mais consequente é a janela `max_gap=25` na geração de pares candidatos. Esse limite foi quantificado por partição e por classe (Seção 4.6.1) e, portanto, é uma limitação *documentada e de magnitude conhecida*, e não uma fonte de incerteza não medida.

Uma segunda ameaça diz respeito à **independência das instâncias**. O *bootstrap* pareado trata os 19210 candidatos como independentes, o que não é estritamente verdadeiro, pois pares de um mesmo documento compartilham texto e vocabulário, de modo que o intervalo de confiança reportado é provavelmente mais estreito que o real. Essa ameaça atenua-se, mas não desaparece, pelo fato de a comparação ser *pareada*, já que ambos os modelos são avaliados exatamente sobre as mesmas instâncias, e a dependência afeta os dois igualmente. Ainda assim, a conclusão de empate na semente 42 (e a de diferença significativa na semente 43) deve ser lida com essa ressalva.

Quanto à **validade externa**, o SemClinBr, apesar de multi-institucional e multiespecialidade, representa um conjunto específico de instituições e estilos de redação; a generalização para outros contextos clínicos e para outros espaços de relação deve ser feita com cautela. As inconsistências de anotação conhecidas do corpus, ainda que tratadas e registradas pelo *parser*, também impõem um limite superior ao desempenho alcançável, limite que se aplica igualmente aos dois modelos comparados.

## 8 CONCLUSÃO

Este trabalho abordou a extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, no espaço de rótulos `negation_of`, `associated_with` e `no_relation`. Como etapa inicial do desenvolvimento do **RECLin-PT**, conduziu-se um experimento controlado de *baselines* para responder a uma pergunta que fundamenta as decisões de projeto seguintes: o pré-treinamento clínico importa para a extração de relações em textos médicos em português? A ênfase recaiu, simultaneamente, sobre a resposta a essa pergunta e sobre a construção de uma cadeia experimental reproduzível, do texto bruto às métricas finais.

### 8.1 CONTRIBUIÇÕES

As principais contribuições são: (i) um *parser* fiel e determinístico do formato XML do SemClinBr, com verificação de sanidade e correção controlada de *offsets*; (ii) uma caracterização do corpus que evidencia o desbalanceamento das relações e a proximidade entre entidades relacionadas, em particular a quase adjacência dos pares de negação; (iii) um protocolo de particionamento em nível de documento, estratificado e congelado, que previne vazamento de dados; (iv) um gerador determinístico de pares candidatos compartilhado por todos os modelos, com o teto de *recall* imposto pela janela quantificado por partição e por classe; (v) uma infraestrutura experimental de paridade total, em que os dois *encoders* comparados diferem apenas no *checkpoint* de pré-treino; e (vi) uma comparação empírica com teste de significância pareado entre um *encoder* clínico e um geral sobre a mesma tarefa.

Quanto aos resultados, não se observou vantagem *consistente* do pré-treinamento clínico. Na semente de referência (42), a diferença no F1 de `negation_of` entre BioBERTpt e BERTimbau é de 0,017 a favor do geral e não é estatisticamente significativa na métrica-alvo (*bootstrap* pareado IC95%  $[-0,053; +0,018]$ ,  $p = 0,345$ ); na semente 43, o mesmo *bootstrap* sobre essa métrica inverte o sinal e passa a favorecer o BioBERTpt clínico, agora de forma significativa (IC95%  $[+0,016; +0,090]$ ,  $p = 0,0054$ ). Nem o veredito estatístico nem a *direção* da diferença **na classe-alvo**, portanto, são estáveis entre sementes, pois a variação de inicialização de um mesmo modelo (0,078 de amplitude no

BioBERTpt) supera com folga a diferença entre os dois modelos. Essa instabilidade é da métrica-alvo e **não se estende ao padrão global de acertos**. O teste de McNemar, que incide sobre as três classes, rejeita a hipótese nula nas duas sementes e aponta nas duas para o *encoder* geral (540 contra 695 discordâncias na semente 42; 442 contra 624 na 43). O que é estável, além dessa direção agregada, é a assimetria de dispersão. O *encoder* geral acompanha o clínico em macro-F1 médio (0,695 contra 0,694) com cerca de 60% dos parâmetros e com desempenho cerca de dez vezes mais estável entre reinicializações na métrica-alvo.

## 8.2 TRABALHOS FUTUROS

Entregar um estudo de *baselines* e deixar a especialização do modelo para a fase seguinte é uma decisão de sequenciamento, e não uma lacuna. A escolha do *encoder* é pré-requisito de qualquer aprimoramento posterior. Fixada a base por expectativa (e a expectativa de partida, registrada na Seção 1.2, era a de vantagem do pré-treino clínico), todo ganho ou perda medido depois ficaria confundido com o efeito do *checkpoint*, sem meio de separar um do outro. E o resultado obtido é, ele próprio, um achado de consequência prática, e não um resultado nulo vazio. Sob teste pareado e sob duas sementes de treino, o *encoder* clínico não leva vantagem *confiável* nesta tarefa (a diferença medida troca de sinal entre sementes), o que libera a construção do RECLin-PT sobre um modelo sensivelmente menor. Isso não equivale a custo zero, pois, tomada a média das duas sementes, o *encoder* clínico fica 0,017 à frente na métrica-alvo (0,715 contra 0,698), e é esse o custo esperado da escolha. Ele é, contudo, menor que a própria amplitude entre sementes do BioBERTpt (0,078), o que o torna mal estimado por duas execuções. Como registra o Capítulo 3, não localizamos avaliação controlada equivalente para o português, de modo que esse achado não era obtível por consulta à literatura.

Esses resultados orientam diretamente a fase seguinte. O RECLin-PT não é um trabalho a iniciar. Os *baselines* aqui reportados são a sua primeira fase, e o que constitui trabalho futuro imediato é a especialização do modelo sobre a base escolhida. Como o BERTimbau geral acompanha o clínico em macro-F1 médio, exige cerca de 60% dos parâmetros e varia cerca de dez vezes menos entre sementes na métrica-alvo,

ele se apresenta como a base mais atraente por eficiência e previsibilidade, ressalvado que a semente 43 mostra o clínico à frente na negação, de modo que a escolha se apoia em custo e estabilidade, e não em superioridade média demonstrada. Esse refinamento terá como foco o aprimoramento da classe `negation_of`, a mais crítica para a correta interpretação clínica.

Cabe explicitar que essa prioridade não recai sobre a classe de pior desempenho. A Seção 6.3 mostra que `associated_with` é a mais difícil das três ( $F1 \approx 0,42\text{--}0,43$ , contra  $\approx 0,68\text{--}0,69$  de `negation_of`). O critério é de criticidade clínica, e não de facilidade. Uma negação lida como afirmação inverte o sentido de um achado no prontuário, ao passo que um `associated_with` não recuperado empobrece a extração sem alterar o sentido do que foi extraído. O teto de *recall* de `associated_with` permanece, ainda assim, entre as continuidades previstas a seguir.

Como continuidade, prevê-se ainda: estimar o desempenho dos *baselines* sob um número maior de sementes de treino, com agregação formal, para obter um intervalo de confiança da diferença mais estreito; enriquecer a representação de entrada com o **tipo semântico** das entidades, hoje ausente dos marcadores (Seção 5.4.3), medindo se o ganho difere entre o *encoder* clínico e o geral; reavaliar a janela `max_gap` da geração de pares candidatos, elevando o teto de *recall* de `associated_with` sem inviabilizar o custo de treino; investigar o tratamento explícito do escopo da negação e da direção das relações; estender o espaço de relações para além das três classes atuais; avaliar modelos maiores e *encoders* multilíngues (CONNEAU *et al.*, 2020); e integrar uma etapa de reconhecimento de entidades nomeadas automática, medindo a extração de relações em um cenário fim a fim.

O trabalho encontra-se, portanto, em andamento. Os *baselines* aqui reportados estabelecem o ponto de partida do RECLin-PT, e não um encerramento.

## REFERÊNCIAS

- ALMEIDA, V. A. de *et al.* **Clinical named entity recognition in the Portuguese language: a benchmark of modern BERT models and LLMs.** 2026. ArXiv:2603.26510 [cs.CL]. Pré-publicação.
- CHAPMAN, W. W. *et al.* A simple algorithm for identifying negated findings and diseases in discharge summaries. **Journal of Biomedical Informatics**, v. 34, n. 5, p. 301–310, 2001.
- CONNEAU, A. *et al.* Unsupervised cross-lingual representation learning at scale. In: **Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2020. p. 8440–8451.
- DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. In: **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)**. [S.l.]: Association for Computational Linguistics, 2019. p. 4171–4186.
- DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895–1923, 1998.
- FORMAN, G.; SCHOLZ, M. Apples-to-apples in cross-validation studies: Pitfalls in classifier performance measurement. **ACM SIGKDD Explorations Newsletter**, v. 12, n. 1, p. 49–57, 2010.
- FRAILE NAVARRO, D. *et al.* Clinical named entity recognition and relation extraction using natural language processing of medical free text: A systematic review. **International Journal of Medical Informatics**, v. 177, p. 105122, 2023.
- LEE, J. *et al.* BioBERT: A pre-trained biomedical language representation model for biomedical text mining. **Bioinformatics**, v. 36, n. 4, p. 1234–1240, 2020.
- LIN, C. *et al.* Does BERT need domain adaptation for clinical negation detection? **Journal of the American Medical Informatics Association**, v. 27, n. 4, p. 584–591, 2020.
- OLIVEIRA, L. E. S. e. *et al.* SemClinBr – a multi-institutional and multi-specialty semantically annotated corpus for Portuguese clinical NLP tasks. **Journal of Biomedical Semantics**, v. 13, n. 1, p. 13, 2022.
- SCHNEIDER, E. T. R. *et al.* BioBERTpt – a Portuguese neural language model for clinical named entity recognition. In: **Proceedings of the 3rd Clinical Natural Language Processing Workshop**. [S.l.]: Association for Computational Linguistics, 2020. p. 65–72.
- SECHIDIS, K.; TSOUMAKAS, G.; VLAHAVAS, I. On the stratification of multi-label data. In: **Machine Learning and Knowledge Discovery in Databases (ECML PKDD 2011)**. [S.l.]: Springer, 2011. (Lecture Notes in Computer Science, v. 6913), p. 145–158.
- SHIMAOKA, A. M. *et al.* Large language models in Portuguese for healthcare: a systematic review. **Research on Biomedical Engineering**, v. 42, n. 1, p. 13, 2026.

SILVA, D. Pinheiro da *et al.* Exploring named entity recognition and relation extraction for ontology and medical records integration. **Informatics in Medicine Unlocked**, v. 43, p. 101381, 2023.

SOARES, L. B. *et al.* Matching the blanks: Distributional similarity for relation learning. In: **Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2019. p. 2895–2905.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for Brazilian Portuguese. In: **Intelligent Systems (BRACIS 2020)**. [S.l.]: Springer, 2020. (Lecture Notes in Computer Science, v. 12319), p. 403–417.

UZUNER, Ö. *et al.* 2010 i2b2/VA challenge on concepts, assertions, and relations in clinical text. **Journal of the American Medical Informatics Association**, v. 18, n. 5, p. 552–556, 2011.

VASWANI, A. *et al.* Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

## **Apêndices**

## APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS

Para garantir a reprodutibilidade dos experimentos, as partições de treino, desenvolvimento e teste foram congeladas após sua geração (semente 42, estratificação multirrótulo em nível de documento). O Quadro 4 apresenta os *hashes* SHA-256 dos arquivos, registrados por `src/make_splits.py` em `data/splits/MANIFEST.json` e versionados junto com os dados. Qualquer alteração nos arquivos altera o *hash*, permitindo a verificação independente da integridade das partições.

A verificação não é apenas documental. Os *scripts* que geram as tabelas e figuras deste trabalho recalculam esses *hashes* antes de ler os dados e interrompem a execução se algum deles divergir do manifesto. Assim, nenhum número publicado aqui pode ter sido produzido a partir de uma partição diferente da registrada abaixo.

Quadro 4 – SHA-256 das partições congeladas do SemClinBr.

| Arquivo                  | SHA-256                                                          |
|--------------------------|------------------------------------------------------------------|
| <code>train.jsonl</code> | 36014b2adc8308bce94aeecf066c38f69e1f53dda4517fa424527554b31a437a |
| <code>dev.jsonl</code>   | a9ea327684165c5053f8f3db5468a27f71c1d9e30d2859e343b6d275839c8aeb |
| <code>test.jsonl</code>  | 86304d8d507c6707695e2b86c3533b763a96247f06326e5980b4567385231e62 |

Fonte: elaborado pelo autor (`data/splits/MANIFEST.json`, gerado por `src/make_splits.py`).

As partições contêm, respectivamente, 800, 100 e 100 documentos. A Tabela 3, no Capítulo 4, registra a distribuição das relações entre elas: 9221 no treino, 987 na validação e 1250 no teste.



## APÊNDICE B – MARCADORES DE NEGAÇÃO DO PORTUGUÊS CLÍNICO

A negação clínica em português é fortemente **lexicalizada**, pois um conjunto pequeno e recorrente de gatilhos responde pela maior parte das ocorrências, o que está na origem da eficácia de abordagens como o algoritmo NegEx (CHAPMAN *et al.*, 2001) e é uma das explicações discutidas no Capítulo 7 para a **ausência de vantagem consistente** do *encoder* de domínio clínico sobre o de domínio geral na captura da negação. Entre as duas sementes avaliadas, a diferença entre os dois nessa classe não mantém sequer o sinal.

Este apêndice registra os marcadores mais frequentes observados no SemClinBr, a título de caracterização linguística do fenômeno. Eles **não** constituem parâmetro de nenhum dos modelos avaliados, uma vez que os dois *encoders* comparados no Capítulo 6 não recebem lista alguma de gatilhos, e aprendem o sinal de negação diretamente do texto marcado.

Quadro 5 – Marcadores de negação recorrentes no português clínico.

| Marcador   | Observação                                              |
|------------|---------------------------------------------------------|
| não        | negação verbal/adverbial geral                          |
| sem        | preposição de ausência                                  |
| nega       | forma verbal (“paciente nega. . .”)                     |
| ausência   | substantivo de ausência                                 |
| ausente    | adjetivo de ausência                                    |
| afebril    | adjetivo com negação léxico-morfológica (sem febre)     |
| anictérico | adjetivo com negação léxico-morfológica (sem icterícia) |

Fonte: elaborado pelo autor a partir do SemClinBr.

Os termos “afebril” e “anictérico” são adjetivos que embutem negação morfológicamente e que, no SemClinBr, aparecem anotados como entidades da categoria *Negation*, categoria que responde por 2646 menções no corpus (Seção 4.2). Uma abordagem puramente léxica sobre esta lista não trataria negação de escopo amplo (“o paciente não apresenta nenhum dos seguintes: A, B, C”), negação estendida por conjunção, nem a direção da relação, limitações que motivam o uso de modelos contextuais,

capazes de aprender o escopo a partir do contexto em vez de aplicar uma regra rígida de janela.

## APÊNDICE C – HIPERPARÂMETROS

Este apêndice consolida os hiperparâmetros efetivamente utilizados nas etapas executadas do *pipeline*. O Quadro 6 reúne os parâmetros comuns à preparação dos dados e à avaliação; o Quadro 7 detalha o ajuste fino dos dois *encoders* comparados.

Todos os valores abaixo foram lidos do campo `config` dos arquivos `results/baseline_*.json`, gravado pelo próprio código de treino no momento da execução, e não transcritos de um plano de experimento. Os dois *encoders* compartilham a configuração integralmente, e essa identidade é verificada automaticamente por `scripts/_artifacts.py`, que recusa gerar qualquer tabela deste trabalho caso as configurações das quatro execuções (dois modelos  $\times$  duas sementes) diverjam em algum campo.

Quadro 6 – Parâmetros gerais da preparação dos dados e da avaliação.

| Parâmetro                                           | Valor                                            |
|-----------------------------------------------------|--------------------------------------------------|
| Semente do particionamento                          | 42 (congelada)                                   |
| Sementes de treino                                  | 42 (referência) e 43 (robustez)                  |
| Partição treino/validação/teste                     | 80/10/10 (nível de documento)                    |
| Estratificação                                      | multirrótulo por presença de classe no documento |
| Janela máxima de pares ( <code>max_gap</code> )     | 25 caracteres                                    |
| Contexto em torno do par ( <code>ctx_chars</code> ) | 128 caracteres                                   |
| <i>Bootstrap</i> pareado                            | 10.000 reamostragens, percentis 2,5/97,5         |
| Teste pareado                                       | McNemar (binomial exato)                         |
| Critério de significância                           | IC95% da diferença não contém zero               |

Fonte: elaborado pelo autor (`results/baseline_*.json` e `results/significance_*.json`).

A Tabela 6, no Capítulo 6, registra a evolução época a época de cada uma das quatro execuções: perda de treino, perda de validação, macro-F1 e F1 de `negation_of` na validação, além da duração.

Quadro 7 – Hiperparâmetros do ajuste fino, idênticos para os dois *encoders*.

| Parâmetro                         | Valor                                                                                            |
|-----------------------------------|--------------------------------------------------------------------------------------------------|
| <i>Encoder</i> clínico            | pucpr/biobertpt-all (177,9 M de parâmetros)                                                      |
| <i>Encoder</i> geral              | neuralmind/<br>bert-base-portuguese-cased (108,9 M de parâmetros)                                |
| Núcleo de implementação           | src/relation_extraction.py                                                                       |
| Representação de entrada          | janela de texto com marcadores de posição ([E1]/[E2]), sem tipo semântico                        |
| Cabeçote de classificação         | AutoModelForSequenceClassification (projeção linear sobre a representação agregada da sequência) |
| Perda                             | <i>cross-entropy</i> com <code>class_weight="balanced"</code>                                    |
| <code>max_length</code>           | 128 <i>tokens</i>                                                                                |
| Taxa de aprendizado               | $2 \times 10^{-5}$ (AdamW)                                                                       |
| Escalonador                       | linear com <i>warmup</i>                                                                         |
| <i>Batch</i> (treino e avaliação) | 64                                                                                               |
| Épocas                            | 3                                                                                                |
| Seleção de modelo                 | maior macro-F1 no conjunto de validação                                                          |
| Hardware                          | Google Colab, <i>Tesla</i> T4                                                                    |

Fonte: elaborado pelo autor (campo config de results/baseline\_\*.json).