



INSTITUTO FEDERAL

Espírito Santo

Campus Cachoeiro de Itapemirim

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

TRABALHO DE GRADUAÇÃO

ANGELO ANTONIO LIMA SILVEIRA FILHO

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS
SOBRE O CORPUS SEMCLINBR**

Cachoeiro de itapemirim

2026

ANGELO ANTONIO LIMA SILVEIRA FILHO

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS
SOBRE O CORPUS SEMCLINBR**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Cristiano da Silveira Colombo

Coorientadora: Profa. Dra. Beltrana de Tal

Cachoeiro de itapemirim

2026

(Biblioteca do Campus Cachoeiro de Itapemirim)

X999y

RECLin-PT: extração de relações em notas clínicas em português sobre o corpus SemClinBr/ Angelo Antonio Lima Silveira Filho. – 2026.

57 f: il; 30 cm.

Orientador: Cristiano da Silveira Colombo

Trabalho de Graduação – Instituto Federal do Espírito Santo, Bacharelado em Sistemas de Informação, 2026.

1. Processamento de linguagem natural. 2. Extração de relações. 3. Informática em saúde. 4. Aprendizado de máquina. 5. Língua portuguesa. I. Colombo, Cristiano da Silveira. II. Título. III. Instituto Federal do Espírito Santo.

CDD 000.00

ANGELO ANTONIO LIMA SILVEIRA FILHO

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS
SOBRE O CORPUS SEMCLINBR**

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Aprovado em 01 de Agosto de 2026

COMISSÃO EXAMINADORA

Prof. Dr. Cristiano da Silveira Colombo

Instituto Federal do Espírito Santo
Orientador

Profa. Dra. Beltrana de Tal

Instituto Federal do Espírito Santo
Coorientadora

Profa. Dra. Fulana de Tal

Instituto Federal do Espírito Santo
Examinadora

Prof. Dr. Cicrano de Tal

Instituto Federal do Espírito Santo
Examinador

À minha mãe, meu alicerce de força e superação, que esteve ao meu lado mesmo nos dias em que eu já não tinha vontade de continuar. Que jamais me desamparou diante das dificuldades e, com amor, coragem e fé, tornou-se o meu maior exemplo de vida. Tudo o que sou carrega um pouco da sua força. Aos meus amigos de jornada, que foram âncora e apoio durante todo o processo.

RESUMO

O registro eletrônico em saúde concentra grande parte da informação clínica em texto livre, no qual a relação entre conceitos, em especial a negação de achados, é determinante para a correta interpretação. Este trabalho investiga a extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, considerando o espaço de rótulos *negation_of*, *associated_with* e *no_relation*. Como etapa inicial do desenvolvimento do RECLin-PT, um modelo aprimorado de extração de relações clínicas em português, conduz-se um experimento controlado para responder a uma questão de projeto: o pré-treinamento clínico importa para essa tarefa? Propõe-se uma cadeia experimental reprodutível que vai do texto bruto às métricas finais, composta por um *parser* determinístico do formato XML do corpus, análise exploratória das relações, particionamento 80/10/10 em nível de documento, estratificado e congelado para evitar vazamento de dados, e geração controlada de pares candidatos. Sobre essa infraestrutura, dois *encoders* para o português são ajustados variando apenas o *checkpoint* de pré-treino: um de domínio clínico (BioBERTpt) e um de domínio geral (BERTimbau). No conjunto de teste congelado, os dois empatam estatisticamente no F1 de *negation_of* na semente de referência (0,724 contra 0,734; McNemar $p = 0,18$; *bootstrap* pareado IC95% $[-0,047; +0,026]$), mas esse veredito não se sustenta nas duas sementes testadas: a variação entre sementes de um mesmo modelo supera a diferença entre os modelos, e o *encoder* clínico não lidera em nenhuma delas. Esses resultados indicam que o RECLin-PT pode ser construído sobre o *encoder* geral, mais eficiente e mais estável entre reinicializações, sem penalidade de desempenho.

Palavras-chave: Extração de relações. Processamento de linguagem natural clínico. Língua portuguesa. SemClinBr. Aprendizado de máquina.

ABSTRACT

Electronic health records store much clinical information as free text, in which the relationship between concepts, particularly the negation of findings, is decisive for correct interpretation. This work investigates relation extraction between clinical entities in Portuguese over the SemClinBr corpus, considering the label space `negation_of`, `associated_with` and `no_relation`. As the initial stage of developing RECLin-PT, an improved clinical relation extraction model for Portuguese, we run a controlled experiment to answer a design question: does clinical pre-training matter for this task? We propose a reproducible experimental pipeline that goes from raw text to final metrics, comprising a deterministic parser for the corpus XML format, exploratory analysis of relations, a document-level, stratified and frozen 80/10/10 split to prevent data leakage, and controlled candidate-pair generation. On this infrastructure, two Portuguese encoders are fine-tuned changing only the pre-trained checkpoint: a clinical-domain one (BioBERTpt) and a general-domain one (BERTimbau). On the frozen test set, the two are statistically tied on the `negation_of` F1 under the reference seed (0.724 vs. 0.734; McNemar $p = 0.18$; paired bootstrap 95% CI $[-0.047, +0.026]$), but this verdict does not hold across the two seeds we tested: seed-to-seed variation of a single model exceeds the gap between the models, and the clinical encoder leads under neither seed. These results indicate that RECLin-PT can be built on the general encoder, which is more efficient and more stable across restarts, with no performance penalty.

Keywords: Relation extraction. Clinical natural language processing. Portuguese language. SemClinBr. Machine learning.

LISTA DE ILUSTRAÇÕES

Figura 1 – Processo de criação e anotação do corpus SemClinBr	22
Figura 2 – Distribuição dos tipos de relação no SemClinBr.	23
Figura 3 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200), com a janela <code>max_gap</code> assinalada.	24
Figura 4 – Distribuição do número de relações por documento.	25
Figura 5 – Categorias atômicas de entidade mais frequentes (15 primeiras). . .	25
Figura 6 – Distribuição das relações por partição (escala logarítmica), com o percentual de <code>negation_of</code> anotado.	27
Figura 7 – Evolução por época dos dois <i>encoders</i> nas sementes 42 e 43: perda (à esquerda) e F1 no conjunto de validação (à direita). Marcador preenchido indica a época selecionada.	39
Figura 8 – F1 por classe no conjunto de teste: BioBERTpt (clínico) vs. BERTim- bau (geral), semente 42.	41
Figura 9 – Matriz de confusão do BioBERTpt (clínico), normalizada por linha. .	42
Figura 10 – Matriz de confusão do BERTimbau (geral), normalizada por linha. .	42

LISTA DE TABELAS

Tabela 1 – Distribuição dos tipos de relação no corpus parseado.	23
Tabela 2 – Distância em caracteres entre as entidades de cada relação, por tipo.	24
Tabela 3 – Distribuição real das relações por partição (<i>splits</i> congelados, semente 42).	26
Tabela 4 – Pares candidatos gerados por partição ($\text{max_gap}=20$) e distribuição dos rótulos.	29
Tabela 5 – Teto de <i>recall</i> imposto pela janela $\text{max_gap}=20$ por partição.	30
Tabela 6 – Evolução por época no conjunto de validação. * marca a época selecionada (maior macro-F1 na validação), cujo <i>checkpoint</i> produziu as métricas de teste.	40
Tabela 7 – Resultados dos <i>baselines</i> no conjunto de teste ($n=16.074$, semente 42). Negrito indica o melhor valor por coluna.	40
Tabela 8 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ($n=16.074$, semente 42).	43
Tabela 9 – Robustez à semente de treino: métricas de teste por semente, média e amplitude observada.	44
Tabela 10 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ($n=16.074$, semente 43).	45

LISTA DE QUADROS

Quadro 1 – Exemplo de geração de candidatos para um trecho do SemClinBr.	29
Quadro 2 – Ambiente experimental e hiperparâmetros compartilhados pelos dois <i>baselines</i>	32
Quadro 3 – Entrada efetivamente construída para o par <i>gold</i> do Quadro 1.	36
Quadro 4 – SHA-256 das partições congeladas do SemClinBr.	54
Quadro 5 – Marcadores de negação recorrentes no português clínico.	55
Quadro 6 – Parâmetros gerais da preparação dos dados e da avaliação.	56
Quadro 7 – Hiperparâmetros do ajuste fino, idênticos para os dois <i>encoders</i>	57

LISTA DE SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
IC	Intervalo de Confiança
IFES	Instituto Federal do Espírito Santo
MCC	<i>Matthews Correlation Coefficient</i> (Coeficiente de Correlação de Matthews)
NER	<i>Named Entity Recognition</i> (Reconhecimento de Entidades Nomeadas)
NLP	<i>Natural Language Processing</i> (Processamento de Linguagem Natural)
PLN	Processamento de Linguagem Natural
RE	<i>Relation Extraction</i> (Extração de Relações)
SemClinBr	<i>Semantically Annotated Corpus for Portuguese Clinical NLP</i>
TF-IDF	<i>Term Frequency–Inverse Document Frequency</i>
XML	<i>Extensible Markup Language</i>

SUMÁRIO

1	INTRODUÇÃO	12
1.1	PROBLEMA DE PESQUISA	12
1.2	MOTIVAÇÃO	13
1.3	OBJETIVOS	13
1.3.1	Objetivo geral	13
1.3.2	Objetivos específicos	13
1.4	ORGANIZAÇÃO DO TRABALHO	14
2	REFERENCIAL TEÓRICO	15
2.1	PROCESSAMENTO DE LINGUAGEM NATURAL CLÍNICO	15
2.2	EXTRAÇÃO DE ENTIDADES E DE RELAÇÕES	15
2.3	ABORDAGENS BASEADAS EM REGRAS E A NEGAÇÃO CLÍNICA	16
2.4	ABORDAGENS BASEADAS EM APRENDIZADO DE MÁQUINA	16
2.5	MODELOS BASEADOS EM <i>TRANSFORMERS</i>	16
3	TRABALHOS RELACIONADOS	18
3.1	RECURSOS E DESAFIOS EM INGLÊS	18
3.2	RECURSOS PARA O PORTUGUÊS	18
3.3	POSICIONAMENTO DESTE TRABALHO	19
4	METODOLOGIA	20
4.1	VISÃO GERAL DO PIPELINE	20
4.2	CORPUS SEMCLINBR	21
4.3	PARSING E REPRESENTAÇÃO CANÔNICA	22
4.4	CARACTERIZAÇÃO DO CORPUS	22
4.4.1	Distribuição dos tipos de relação	23
4.4.2	Distância entre entidades relacionadas	23
4.4.3	Relações por documento e categorias de entidade	24
4.5	PARTICIONAMENTO DOS DADOS	25
4.6	GERAÇÃO DE PARES CANDIDATOS	27
4.6.1	Teto de recall imposto pela janela	29
4.7	PROTOCOLO DE AVALIAÇÃO	30
4.8	AMBIENTE EXPERIMENTAL E RASTREABILIDADE	31
5	PROPOSTA DO PROTÓTIPO	33

5.1	VISÃO GERAL E PAPEL DOS <i>BASELINES</i>	33
5.2	OS DOIS <i>ENCODERS</i> COMPARADOS	34
5.2.1	BioBERTpt — <i>encoder</i> de domínio clínico	34
5.2.2	BERTimbau — <i>encoder</i> de domínio geral	34
5.3	TRATAMENTO DO DESBALANCEAMENTO	34
5.4	REPRESENTAÇÃO DE ENTRADA: MARCADORES DE POSIÇÃO .	35
5.4.1	O esquema adotado	35
5.4.2	Exemplo	36
5.4.3	O que essa escolha deixa de fora	37
6	EXPERIMENTOS E RESULTADOS	38
6.1	CONFIGURAÇÃO EXPERIMENTAL	38
6.2	CURVAS DE TREINO E SELEÇÃO DE MODELO	38
6.3	RESULTADOS NO CONJUNTO DE TESTE	40
6.4	MATRIZES DE CONFUSÃO	41
6.5	SIGNIFICÂNCIA ESTATÍSTICA	43
6.6	ROBUSTEZ À SEMENTE DE TREINO	44
7	DISCUSSÃO	46
7.1	ANÁLISE DOS RESULTADOS	46
7.2	A CLASSE ASSOCIATED_WITH	47
7.3	LIMITAÇÕES	48
7.4	AMEAÇAS À VALIDADE	48
8	CONCLUSÃO	50
8.1	CONTRIBUIÇÕES	50
8.2	TRABALHOS FUTUROS	51
	REFERÊNCIAS	52
	APÊNDICES	53
	APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS	54
	APÊNDICE B – MARCADORES DE NEGAÇÃO DO PORTUGUÊS	
	CLÍNICO	55
	APÊNDICE C – HIPERPARÂMETROS	56

1 INTRODUÇÃO

O registro eletrônico em saúde concentra grande parte da informação clínica sob a forma de texto livre. Notas de evolução, sumários de alta e laudos são redigidos em linguagem natural, com abreviações idiossincráticas, ausência frequente de pontuação padronizada e construções negativas características do discurso médico. Essa riqueza textual, embora valiosa para pesquisa e apoio à decisão, permanece majoritariamente inacessível a consultas estruturadas, o que motiva o desenvolvimento de técnicas de Processamento de Linguagem Natural (PLN) capazes de transformar texto clínico em conhecimento estruturado.

No contexto da língua portuguesa, o avanço dessas técnicas foi historicamente limitado pela escassez de recursos anotados. A disponibilização do corpus **SemClinBr** (OLIVEIRA *et al.*, 2022), primeiro corpus clínico anotado semanticamente para o português, com mil documentos provenientes de múltiplas instituições e especialidades, criou condições para investigar tarefas antes restritas ao inglês, entre elas a extração de relações entre entidades clínicas.

1.1 PROBLEMA DE PESQUISA

A extração de entidades nomeadas identifica menções a conceitos clínicos (sintomas, doenças, achados, procedimentos), mas isoladamente não captura como esses conceitos se articulam no enunciado. Saber que um documento menciona “febre” não é suficiente: é preciso distinguir se a febre está *associada* ao quadro do paciente ou se está sendo *negada* (“paciente afebril”). Esse vínculo é o objeto da **extração de relações** (Relation Extraction, RE).

Este trabalho integra o desenvolvimento do **RECLin-PT**, um modelo aprimorado de extração de relações em texto clínico em português sobre o corpus SemClinBr. Como etapa inicial dessa construção, investiga-se a seguinte questão de projeto: *o pré-treinamento clínico importa para a extração de relações em textos médicos em português?* Responder a ela determina sobre qual *encoder* o RECLin-PT deve ser construído, e exige comparar dois modelos na *mesma* tarefa variando *somente* o *checkpoint* de pré-treino. O desafio é agravado por dois fatores inerentes ao corpus: o

forte desbalanceamento entre as classes de relação e o fato de o SemClinBr anotar apenas relações positivas, exigindo a geração controlada de exemplos negativos.

1.2 MOTIVAÇÃO

A negação clínica é um fenômeno linguístico de alto impacto: tratar um achado negado como presente pode inverter completamente a interpretação de um prontuário. Em português, a negação é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”), e há a expectativa difundida de que modelos pré-treinados sobre texto do próprio domínio clínico capturem melhor essas construções do que modelos de domínio geral. Essa expectativa, contudo, é raramente testada de forma controlada para o português: trabalhos costumam adotar um modelo clínico por hipótese, sem isolar o efeito do pré-treinamento de domínio sob protocolo estatístico rigoroso. Construir esse teste de forma reproduzível, desde o texto bruto até as métricas finais, é em si uma contribuição metodológica, dado que a falta de reprodutibilidade é uma das principais críticas dirigidas à literatura de PLN biomédico.

1.3 OBJETIVOS

1.3.1 Objetivo geral

Desenvolver, de forma reproduzível, um *pipeline* determinístico de extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, considerando o espaço de rótulos *negation_of*, *associated_with* e *no_relation*, e, sobre essa infraestrutura, avaliar sob protocolo estatístico rigoroso (macro-F1 e F1 por classe, com teste de significância pareado) se o pré-treinamento de domínio clínico traz ganho para a tarefa, comparando um *encoder* clínico (BioBERTpt) e um de domínio geral (BERTimbau) sob paridade total de implementação, de modo a identificar a melhor base sobre a qual construir o RECLin-PT.

1.3.2 Objetivos específicos

- Construir um *parser* fiel ao formato XML do SemClinBr que produza uma representação canônica determinística do corpus.

- Caracterizar o corpus por meio de análise exploratória, quantificando a distribuição das relações e a distância entre entidades relacionadas.
- Definir uma partição treino/desenvolvimento/teste em nível de documento, estratificada e congelada, de modo a evitar vazamento de dados.
- Implementar um gerador determinístico de pares candidatos compartilhado por todos os modelos, garantindo a comparabilidade dos resultados.
- Ajustar dois *encoders* para o português, um de domínio clínico (BioBERTpt) e um de domínio geral (BERTimbau), sob um único núcleo de implementação, de modo que difiram apenas no *checkpoint* de pré-treino.
- Comparar os dois *baselines* sob teste de significância pareado (McNemar e *bootstrap* pareado no F1 de `negation_of`), reportando macro-F1, F1 por classe, MCC e acurácia.
- Avaliar a robustez do resultado à semente de treino, treinando ambos os modelos com uma segunda inicialização e repetindo todo o protocolo estatístico.
- Identificar, a partir dessa comparação, a melhor base sobre a qual desenvolver o RECLin-PT.

1.4 ORGANIZAÇÃO DO TRABALHO

O Capítulo 2 apresenta os fundamentos de PLN clínico, extração de relações e modelos baseados em transformers. O Capítulo 3 discute trabalhos relacionados, com ênfase em recursos para o português. O Capítulo 4 descreve o corpus, o *pipeline* de processamento, a geração de pares candidatos e o protocolo de avaliação. O Capítulo 5 detalha a proposta de modelo. O Capítulo 6 reporta os experimentos e resultados. O Capítulo 7 analisa limitações e ameaças à validade, e o Capítulo 8 sintetiza as contribuições e aponta trabalhos futuros.

2 REFERENCIAL TEÓRICO

Este capítulo reúne os fundamentos necessários à compreensão do trabalho: o processamento de linguagem natural aplicado a textos clínicos, a tarefa de extração de relações, as abordagens baseadas em regras e em aprendizado, e os modelos de linguagem baseados em transformers.

2.1 PROCESSAMENTO DE LINGUAGEM NATURAL CLÍNICO

O PLN clínico ocupa-se da análise automática de textos produzidos no cuidado em saúde, como notas de evolução, sumários de alta e laudos. Esses textos apresentam características que os distinguem da linguagem geral: vocabulário técnico, abreviações não padronizadas, telegrafismo (omissão de elementos gramaticais) e prevalência de construções negativas e de incerteza. Tais propriedades tornam a transferência direta de ferramentas treinadas em domínio aberto pouco eficaz, motivando recursos e modelos específicos do domínio.

2.2 EXTRAÇÃO DE ENTIDADES E DE RELAÇÕES

A extração de informação em texto clínico costuma ser decomposta em duas tarefas encadeadas. A primeira, **reconhecimento de entidades nomeadas** (Named Entity Recognition, NER), delimita trechos do texto que mencionam conceitos de interesse e lhes atribui um tipo semântico. A segunda, **extração de relações** (RE), determina se um par de entidades mantém uma relação e de que tipo. Formalmente, dado um par ordenado de entidades (e_1, e_2) em um documento, a RE pode ser modelada como um problema de classificação que associa ao par um rótulo dentro de um conjunto pré-definido.

Neste trabalho o espaço de rótulos é `negation_of`, `associated_with` e `no_relation`. O rótulo `no_relation` é fundamental: como a anotação de corpora registra apenas relações positivas, todo par de entidades não anotado deve ser tratado como ausência de relação, o que introduz um forte desbalanceamento de classes.

2.3 ABORDAGENS BASEADAS EM REGRAS E A NEGAÇÃO CLÍNICA

Abordagens baseadas em regras codificam conhecimento linguístico explícito. Em detecção de negação clínica, o algoritmo **NegEx** (CHAPMAN *et al.*, 2001) tornou-se referência: a partir de um léxico de gatilhos de negação e de janelas de contexto, classifica achados como negados ou afirmados. Sua simplicidade e eficácia derivam do fato de a negação clínica ser altamente lexicalizada. Em português, gatilhos como “não”, “sem”, “nega” e “ausência de”, além de adjetivos que embutem negação morfológicamente (“afebril”, “anictérico”), sustentam estratégias análogas (Apêndice B). A alta lexicalização sugere que o sinal de negação possa estar acessível mesmo a modelos não especializados no domínio clínico, hipótese que este trabalho testa diretamente.

2.4 ABORDAGENS BASEADAS EM APRENDIZADO DE MÁQUINA

Métodos aprendidos estimam, a partir de exemplos rotulados, a associação entre características do par de entidades e o rótulo da relação. Modelos lineares como a regressão logística, alimentados por características léxicas (por exemplo, representações TF-IDF do texto entre as entidades) e estruturais (tipos das entidades, distância, direção), oferecem um compromisso entre interpretabilidade e desempenho e são frequentemente empregados como *sanity check* antes de modelos mais custosos. Sua principal limitação é a representação de palavras como unidades independentes, incapaz de capturar dependências de longo alcance e contexto, limitação que motivou a transição da área para modelos contextuais.

2.5 MODELOS BASEADOS EM TRANSFORMERS

A arquitetura Transformer (VASWANI *et al.*, 2017), baseada em mecanismos de atenção, viabilizou modelos de linguagem pré-treinados que produzem representações contextuais das palavras. O **BERT** (DEVLIN *et al.*, 2019) popularizou o paradigma de pré-treinamento seguido de ajuste fino (fine-tuning) para tarefas específicas. Para o português, modelos multilíngues como o **XLM-R** (CONNEAU *et al.*, 2020) e, sobretudo, modelos especializados no domínio clínico como o **BioBERTpt** (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e textos biomédicos em português brasileiro,

constituem candidatos naturais para a extração de relações clínicas, e é sobre eles que se apoia a proposta deste trabalho.

3 TRABALHOS RELACIONADOS

Este capítulo situa o trabalho em relação a recursos e estudos de extração de informação clínica, com ênfase na língua portuguesa.

3.1 RECURSOS E DESAFIOS EM INGLÊS

A extração de relações clínicas consolidou-se em língua inglesa em torno de campanhas de avaliação como as séries i2b2 e n2c2, que disponibilizaram corpora anotados e tarefas compartilhadas para problemas como relações entre medicamentos, dosagens e efeitos adversos. Esses esforços estabeleceram protocolos de avaliação e evidenciaram a importância de tratar adequadamente o desbalanceamento de classes e o vazamento de dados entre partições, preocupações transpostas para este trabalho.

3.2 RECURSOS PARA O PORTUGUÊS

O desenvolvimento de PLN clínico em português foi por muito tempo limitado pela ausência de corpora anotados de acesso controlado. O **SemClinBr** (OLIVEIRA *et al.*, 2022) preencheu parte dessa lacuna ao disponibilizar mil documentos clínicos anotados semanticamente, acompanhados de dicionários de abreviações e de pistas de negação. É o corpus central deste trabalho.

No plano dos modelos, o **BioBERTpt** (SCHNEIDER *et al.*, 2020) adaptou o paradigma de modelos de linguagem contextuais ao domínio clínico e biomédico em português brasileiro, demonstrando ganhos em reconhecimento de entidades nomeadas clínicas em relação a modelos de domínio geral. O **BERTimbau** (SOUZA; NOGUEIRA; LOTUFO, 2020), por sua vez, é a referência de domínio geral para o português, pré-treinado no corpus brWaC. Modelos multilíngues como o XLM-R (CONNEAU *et al.*, 2020) oferecem uma alternativa de base ampla, útil como ponto de comparação futuro.

É digno de nota que os ganhos relatados para o BioBERTpt foram medidos em NER, e não em extração de relações. A transferência dessa vantagem para a etapa subsequente costuma ser *assumida* pela literatura em português, e não verificada, lacuna que este trabalho endereça.

3.3 POSICIONAMENTO DESTE TRABALHO

Enquanto boa parte da literatura em português concentra-se em NER e adota um modelo clínico por hipótese, este trabalho aborda a etapa subsequente de extração de relações sobre o SemClinBr e, como ponto de partida do RECLin-PT, *testa* de forma controlada se o ganho do pré-treinamento clínico observado em NER se transfere para a extração de relações, com atenção particular à negação clínica. A contribuição não está em propor uma arquitetura inédita, mas em estabelecer, de maneira reprodutível e estatisticamente fundamentada, uma cadeia completa, do texto bruto às métricas com teste de significância pareado, que sirva de referência comparável para trabalhos futuros sobre o mesmo corpus, e em responder a uma questão de projeto que a literatura em português normalmente deixa implícita.

4 METODOLOGIA

Este capítulo descreve o corpus, o *pipeline* de processamento, a estratégia de particionamento, a geração de pares candidatos e o protocolo de avaliação. Todas as etapas foram projetadas sob a premissa de **reprodutibilidade**: ordenação determinística das saídas, serialização fixa, semente aleatória registrada e verificação por hashes SHA-256.

4.1 VISÃO GERAL DO PIPELINE

Entende-se por *pipeline* de PLN uma sequência encadeada de etapas em que a saída de cada estágio é a entrada do seguinte, de modo que o dado bruto é progressivamente transformado até a métrica final. Estruturar o trabalho como um *pipeline* explícito tem duas vantagens: isola a responsabilidade de cada etapa (facilitando o teste e a auditoria isolados) e torna o caminho completo **reproduzível**, pois cada estágio é determinístico e seus artefatos podem ser verificados de forma independente. As etapas deste trabalho, na ordem em que são executadas, são:

1. **Parsing (XML bruto → dataset.jsonl)**. O *parser* converte cada documento XML do SemClinBr em um registro canônico JSONL (texto, entidades e relações). É necessário porque o formato XML original, fiel à anotação, não é prático para as etapas seguintes; a representação canônica unifica o acesso ao corpus.
2. **Particionamento (dataset.jsonl → *splits*)**. O conjunto é dividido em treino, desenvolvimento e teste em nível de documento. É necessário para separar dados de ajuste dos de avaliação sem vazamento (Seção 4.5).
3. **Geração de pares candidatos (*splits* → candidatos rotulados)**. Como o corpus só anota relações positivas, esta etapa constrói os exemplos negativos (*no_relation*), produzindo o espaço de classificação completo (Seção 4.6).
4. **Marcação de entidades (candidatos → texto marcado)**. Cada par candidato é transformado na *string* de entrada do *encoder*: uma janela de texto em torno do par, com as duas entidades delimitadas por marcadores (Seção 5.4 do Capítulo 5).

É necessária para informar ao modelo *quais* trechos da janela formam o par sob análise e qual deles é o primeiro argumento da relação.

5. **Classificação (texto marcado → predições).** Cada *baseline* ou modelo atribui um rótulo do conjunto {negation_of, associated_with, no_relation} a cada candidato (Capítulo 5).
6. **Avaliação (predições → métricas).** As predições são comparadas ao *gold* para produzir macro-F1, F1 por classe, MCC e acurácia, com testes pareados entre os modelos (Seção 4.7).

O **determinismo** é garantido em *todas* as etapas, condição para que os *hashes* SHA-256 dos artefatos sejam estáveis entre execuções: a serialização JSONL é fixada byte a byte (`ensure_ascii=False`, `sort_keys=True`, quebras de linha LF); a ordenação das saídas é explícita (documentos por `doc_id`, candidatos por `(start, end, id)`); a semente do particionamento é fixada em 42, e a semente de treino é registrada em cada artefato de resultado. As seções seguintes detalham cada etapa. A Figura 1 (Seção 4.2) situa a origem do dado de entrada, ilustrando o processo de criação e anotação do SemClinBr que antecede o *pipeline* aqui descrito.

4.2 CORPUS SEMCLINBR

O trabalho utiliza o corpus SemClinBr (OLIVEIRA *et al.*, 2022), composto por mil documentos clínicos em português anotados com entidades e relações. O corpus é distribuído sob licença restrita, mediante solicitação formal, e seus arquivos XML originais são tratados como **imutáveis** ao longo do *pipeline*. As relações anotadas no corpus público utilizado pertencem a dois tipos, `associated_with` e `negation_of`, sobre os quais se constrói o espaço de rótulos da tarefa. A Figura 1 ilustra o processo de criação e anotação do corpus.




Figura 1 – Processo de criação e anotação do corpus SemClinBr

Fonte: Oliveira et al. (2022).

4.3 PARSING E REPRESENTAÇÃO CANÔNICA

Um *parser* converte cada arquivo XML em um registro canônico no formato JSONL, com identificador do documento, texto, lista de entidades (tipo e *offsets*) e lista de relações. O *parser* é *fiel ao XML*: não normaliza tipos de entidade ou de relação, deixando tais decisões para etapas posteriores. A única transformação aplicada ao texto é o colapso de quebras de linha ($\backslash r \backslash n$, $\backslash r$, $\backslash n$) em espaço único, necessário para manter o alinhamento dos *offsets* de anotação.

Por se tratar de um corpus com inconsistências de anotação conhecidas, o *parser* executa verificações de sanidade (correspondência entre o texto extraído por *offset* e o atributo anotado, validade dos intervalos e integridade referencial das relações) e, quando possível, corrige automaticamente pequenos deslocamentos de *offset* (± 1 e ± 2 caracteres). As inconsistências são acumuladas em um log de avisos em vez de interromperem o processamento.

4.4 CARACTERIZAÇÃO DO CORPUS

A análise exploratória (Exploratory Data Analysis, EDA) foi conduzida sobre a representação canônica do corpus, totalizando 1 000 documentos, 45 508 entidades (média de 45,5 por documento) e 11 458 relações (média de 11,5 por documento). A mediana é de 10 relações por documento, o percentil 90 é de 24 e o máximo observado é de 65;

46 documentos (4,60%) não possuem nenhuma relação anotada. Essa caracterização quantifica a distribuição das relações, a distância entre entidades relacionadas e as categorias de entidade, fornecendo subsídio empírico para as decisões de projeto das etapas seguintes.

4.4.1 Distribuição dos tipos de relação


A Tabela 1 e a Figura 2 mostram o forte desbalanceamento entre os dois tipos de relação anotados, com predominância de `associated_with` (85,98%) sobre `negation_of` (14,02%). Esse desequilíbrio motiva tanto a escolha do macro-F1 como métrica principal quanto o tratamento explícito de classes nos modelos aprendidos.

Tabela 1 – Distribuição dos tipos de relação no corpus parseado.

Tipo de relação	N	%
<code>negation_of</code>	1.606	14,02
<code>associated_with</code>	9.852	85,98
Total	11.458	100,00

Fonte: elaborado pelo autor a partir do SemClinBr (`data/processed/dataset.jsonl`).

Figura 2 – Distribuição dos tipos de relação no SemClinBr.



Fonte: elaborado pelo autor (`scripts/make_tcc_eda.py`).

4.4.2 Distância entre entidades relacionadas

A Tabela 2 e a Figura 3 indicam que as relações ocorrem entre entidades próximas: a mediana da distância é de poucos caracteres e o percentil 95 não ultrapassa algumas dezenas (`associated_with`: média 11,8, mediana 4, p95 43; `negation_of`: média 3,5,


mediana 1, p95 15). O contraste entre os dois tipos é o achado relevante: a negação é praticamente adjacente, pois em 75% dos casos a distância é de um único caractere, enquanto a associação se distribui por uma cauda bem mais longa. Essa assimetria fundamenta a escolha da janela máxima ($\text{max_gap}=20$) na geração de pares candidatos, discutida na Seção 4.6.1: uma janela estreita preserva quase toda a classe-alvo e limita a explosão combinatória de negativos, ao custo de um teto de *recall* concentrado em *associated_with*.

Tabela 2 – Distância em caracteres entre as entidades de cada relação, por tipo.

Tipo	N	média	p25	p50	p75	p90	p95
<i>negation_of</i>	1.606	3,5	1	1	1	11	15
<i>associated_with</i>	9.852	11,8	1	4	10	25	43

Fonte: elaborado pelo autor a partir do SemClinBr (`data/processed/dataset.jsonl`).

Figura 3 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200), com a janela *max_gap* assinalada.




Fonte: elaborado pelo autor (`scripts/make_tcc_eda.py`).

4.4.3 Relações por documento e categorias de entidade

A Figura 4 apresenta a distribuição do número de relações por documento, e a Figura 5, as categorias de entidade mais frequentes (após decomposição das anotações multirótulo separadas por “|”). As categorias predominantes refletem a natureza telegráfica e abreviada do texto clínico: *Abbreviation* (12592), *Finding* (6827), *Therapeutic or*


Preventive Procedure (4759) e Sign or Symptom (4616). Vale notar a presença expressiva da categoria Negation (2646), coerente com a importância do fenômeno de negação tratado neste trabalho.

Figura 4 – Distribuição do número de relações por documento.



Fonte: elaborado pelo autor (scripts/make_tcc_eda.py).

Figura 5 – Categorias atômicas de entidade mais frequentes (15 primeiras).



Fonte: elaborado pelo autor (scripts/make_tcc_eda.py).

4.5 PARTICIONAMENTO DOS DADOS

A partição segue a razão 80/10/10 em **nível de documento**, e não de relação. Essa escolha previne o vazamento de dados: relações de um mesmo documento compartilham vocabulário e trechos repetidos, e dividi-las entre partições diferentes inflaria artificialmente as métricas de teste. A partição é **estratificada** pela presença das

classes `negation_of` e `associated_with` em cada documento, por meio do algoritmo de estratificação multirrótulo de Sechidis, Tsoumakas e Vlahavas (2011), de modo a garantir representação estável da classe minoritária em todas as partições.

A partição é gerada com semente fixa (42) e **congelada**: os arquivos de treino, desenvolvimento e teste e seus respectivos *hashes* SHA-256 são versionados (Apêndice A), evitando que comparações entre execuções sejam confundidas com variação de amostragem. O resultado são 800 documentos de treino, 100 de desenvolvimento e 100 de teste.

A Tabela 3 apresenta a distribuição real das relações entre as partições. O ponto crítico é que a classe minoritária `negation_of`, que representa 14,02% das relações do corpus, permanece bem representada em todas as partições, com proporções de 14,09% no treino, 15,70% na validação e 12,16% no teste. A estratificação atua sobre a *presença* das classes em cada documento, e não sobre a contagem de relações: ela garante que nenhuma partição fique sem exemplos da classe rara, mas não iguala percentuais: daí a variação de cerca de três pontos percentuais observada. Essa garantia é o que importa para o protocolo: um particionamento puramente aleatório poderia, por azar de amostragem, sub-representar `negation_of` no conjunto de teste, comprometendo a estabilidade da estimativa de F1 dessa classe. Com 152 relações `negation_of` no teste, a estimativa permanece interpretável, ainda que com incerteza amostral relevante, razão pela qual todas as comparações do Capítulo 6 são acompanhadas de teste pareado e intervalo de confiança, e não apenas do valor pontual.

Tabela 3 – Distribuição real das relações por partição (*splits* congelados, semente 42).


Partição	Documentos	<code>associated_with</code>	<code>negation_of</code>	Total relações	% <code>negation_of</code>
Treino	800	7.922	1.299	9.221	14,09
Validação	100	832	155	987	15,70
Teste	100	1.098	152	1.250	12,16
Total	1.000	9.852	1.606	11.458	14,02

Fonte: elaborado pelo autor (`data/splits/MANIFEST.json`).

A Figura 6 apresenta a mesma informação em barras agrupadas (escala logarítmica), com o percentual de `negation_of` de cada partição anotado na legenda. A leitura visual

reforça o ponto anterior: a classe rara está presente em volume comparável nas três partições, mas sua fração não é constante, e a partição de teste é justamente a de menor proporção.

Figura 6 – Distribuição das relações por partição (escala logarítmica), com o percentual de `negation_of` anotado.



Fonte: elaborado pelo autor (`scripts/make_tcc_eda.py`).

4.6 GERAÇÃO DE PARES CANDIDATOS

O SemClinBr anota apenas relações *positivas*: cada relação registrada indica que existe vínculo entre duas entidades, mas a ausência de anotação não é, por si, um exemplo negativo explícito. Avaliar um classificador no espaço `{negation_of, associated_with, no_relation}` exige, portanto, **construir** os exemplos negativos. Treinar ou avaliar apenas com os pares anotados produziria um classificador binário sobre as duas classes positivas, incapaz de operar em um cenário real, em que o sistema recebe *todos* os pares de entidades de um documento e precisa decidir, para cada um, se há relação e de que tipo. A classe `no_relation` é o que torna a tarefa aplicável fora do conjunto anotado.

A geração é feita pela função `iter_candidate_pairs` (`src/candidates.py`), compartilhada por todos os modelos e *baselines*, condição necessária para que os resultados fiquem na mesma régua estatística. Para cada documento, ela percorre todos os **pares ordenados** de entidades (e_1, e_2) , com $e_1 \neq e_2$, uma vez que a ordem importa: a direção é relevante para a negação. Em seguida, descarta os pares cuja distância

em caracteres exceda a janela máxima ($\text{max_gap} = 20$) e os pares entre documentos distintos, e atribui o rótulo: se o par ordenado (e_1, e_2) coincide com uma relação anotada, recebe o tipo *gold*; caso contrário, recebe *no_relation*. A emissão segue ordenação determinística por $(\text{start}, \text{end}, \text{id})$, de modo que o conjunto de candidatos e o *hash* das predições sejam estáveis entre execuções.

Em resumo, o gerador respeita cinco propriedades. **(i) Ordenação determinística:** os pares são emitidos sempre na mesma ordem por $(\text{start}, \text{end}, \text{id})$ de e_1 e depois de e_2 , requisito do qual depende a estabilidade das predições entre execuções. **(ii) Sem cruzamento entre documentos:** nunca se forma um par com entidades de documentos distintos, pois o documento é a unidade de processamento. **(iii) Janela respeitada:** apenas pares cuja distância em caracteres (entre o fim de e_1 e o início de e_2) seja $\leq \text{max_gap} = 20$ são gerados. **(iv) Sem autopares:** nunca se forma o par (e, e) de uma entidade consigo mesma ($e_1 \neq e_2$), nem entre entidades com *span* idêntico. **(v) Conferência com o *gold*:** um par presente nas relações anotadas do documento recebe o tipo real (*associated_with* ou *negation_of*), e um par ausente recebe *no_relation* (amostragem negativa).

A Quadro 1 ilustra o processo em um trecho real do corpus. A relação anotada é $16 \rightarrow 52 = \text{negation_of}$ (a entidade “NÃO ESPECIFICADA” nega “OSTEOMIELETTE”). Das seis combinações ordenadas possíveis entre as três entidades próximas, apenas o par $(16, 52)$ casa com o *gold*; os outros cinco tornam-se *no_relation*. A representação de entrada para os modelos contextuais delimita o par com marcadores de posição, por exemplo `[E1] OSTEOMIELETTE [/E1] [E2] NÃO ESPECIFICADA [/E2]` (Seção 5.4).

A Tabela 4 reporta o resultado do procedimento nas três partições: 128380 candidatos de treino, 15994 de validação e 16074 de teste. A consequência direta é um conjunto de teste fortemente desbalanceado: dos 16074 pares candidatos, 14959 (93,06%) pertencem à classe *no_relation*, enquanto *associated_with* e *negation_of* somam, respectivamente, 964 e 151 instâncias. Esse desbalanceamento de $\approx 14:1$ é intrínseco à tarefa, e não um artefato evitável: decorre da combinatória de pares de entidades. Ele é tratado, nos modelos aprendidos, pela reescala de perda `class_weight="balanced"` (Capítulo 5), e, na avaliação, pela escolha do macro-F1 como métrica principal, que dá

Quadro 1 – Exemplo de geração de candidatos para um trecho do SemClinBr.

Entidades: 16=“OSTEOMIELEITE” (*Disease or Syndrome*), 52=“NÃO ESPECIFICADA” (*Negation*), 17=“INTUBADO” (*Finding*). Relação *gold*: 16 → 52 = *negation_of*.

Par ordenado	Rótulo gerado
16 → 52	<i>negation_of</i> (casa com o <i>gold</i>)
16 → 17	<i>no_relation</i>
52 → 16	<i>no_relation</i> (direção inversa do <i>gold</i>)
52 → 17	<i>no_relation</i>
17 → 16	<i>no_relation</i>
17 → 52	<i>no_relation</i>

Fonte: elaborado pelo autor (`src/candidates.py`).

peso igual às três classes.

Tabela 4 – Pares candidatos gerados por partição (`max_gap= 20`) e distribuição dos rótulos.

Partição	Candidatos	<i>negation_of</i>	<i>associated_with</i>	<i>no_relation</i>	% <i>no_relation</i>
Treino	128.380	1.239	6.855	120.286	93,70
Validação	15.994	146	738	15.110	94,47
Teste	16.074	151	964	14.959	93,06

Fonte: elaborado pelo autor (`src/candidates.py`); confere com o campo `n_candidates` de `results/baseline_*.json`.

4.6.1 Teto de recall imposto pela janela

A janela `max_gap= 20` impõe um **teto de recall**: toda relação *gold* cujo par fique a mais de 20 caracteres jamais é gerada como candidato e, portanto, é irrecuperável por qualquer classificador, independentemente da arquitetura. A Tabela 5 quantifica esse limite por partição, e o ponto essencial é que ele **não se distribui igualmente entre as classes**. Na classe-alvo *negation_of*, a perda é marginal: 1 de 152 relações no teste (0,66%), 7 de 155 na validação e 43 de 1299 no treino (3,31%), valor coerente com a mediana de distância de 1 caractere observada na EDA. Em *associated_with*, ao contrário, a perda é substantiva: 132 de 1098 no teste (12,02%), o que puxa o teto agregado do conjunto de teste para 89,36%.

Trata-se de uma **decisão de projeto documentada**: um compromisso entre o *recall*

de `associated_with` e a explosão combinatória de candidatos negativos, tomado em favor da classe que este trabalho investiga. A consequência deve ser lida junto com os resultados: o F1 de `associated_with` reportado no Capítulo 6 é medido *sob* esse teto, e não sobre o conjunto completo de relações anotadas. Como o teto é idêntico para todos os modelos, que recebem exatamente os mesmos candidatos, ele limita o desempenho absoluto, mas não afeta a comparação entre eles.

A tabela também reporta, em coluna separada, as *duplicatas de anotação* colapsadas, isto é, relações *gold* repetidas com o mesmo par ordenado e tipo, que o gerador representa uma única vez. Estas **não** reduzem o teto, pois a relação permanece recuperável, sendo apenas redundância de anotação do corpus.

Tabela 5 – Teto de *recall* imposto pela janela `max_gap= 20` por partição.

Partição	Total ouro	Perdas <code>negation_of</code>	Perdas <code>associated_with</code>	Duplicatas colapsadas	Teto recall (%)
Treino	9.221	43 (3,31%)	1.047 (13,22%)	37	88,18
Validação	987	7 (4,52%)	93 (11,18%)	3	89,87
Teste	1.250	1 (0,66%)	132 (12,02%)	2	89,36
Total	11.458	51 (3,18%)	1.272 (12,91%)	42	88,45

Fonte: elaborado pelo autor (`scripts/make_tcc_eda.py`).

4.7 PROTOCOLO DE AVALIAÇÃO

A métrica principal é o **macro-F1**, que atribui peso igual às três classes e, portanto, penaliza modelos que ignoram as classes minoritárias, comportamento desejável dado o desbalanceamento. Classes ausentes nas predições recebem F1 nulo em vez de serem descartadas, conforme recomendado por Forman e Scholz (2010). Reporta-se também o F1 por classe, o micro-F1 (equivalente à acurácia neste cenário de rótulo único) e o *coeficiente de correlação de Matthews* (MCC), robusto a desbalanceamento. A métrica que responde diretamente à pergunta “o modelo detecta bem a negação?” é o F1 de `negation_of` no conjunto de teste, tratada aqui como **métrica-alvo**.

A comparação entre modelos emprega dois testes pareados complementares, ambos calculados sobre o *mesmo* conjunto de teste a partir das predições salvas, o que elimina a variância entre amostras da comparação e mede exatamente a diferença entre os modelos.

O **teste de McNemar** (DIETTERICH, 1998) olha apenas as instâncias em que os dois modelos discordam quanto ao acerto: monta-se a tabela de discordâncias (b = o primeiro acerta e o segundo erra; c = o inverso) e, sob a hipótese nula de mesma taxa de acerto, avalia-se $b \sim \text{Binomial}(b+c, 0,5)$ pelo **teste binomial exato**. Ele mede se os padrões de erro *globais* diferem, mas não é específico de uma classe.

O **bootstrap pareado** responde à pergunta específica da classe-alvo: reamostram-se, com reposição, as instâncias do conjunto de teste 10000 vezes; a cada reamostragem recalcula-se a diferença $F1_A - F1_B$ no F1 de `negation_of`, e reportam-se a diferença média, o intervalo de confiança de 95% (percentis 2,5/97,5) e um valor- p bilateral. Adota-se como critério de decisão a **exclusão do zero pelo IC95%**: se o intervalo contém zero, a diferença não é considerada estatisticamente significativa ao nível $\alpha = 0,05$.

Por fim, como **análise de robustez à inicialização**, ambos os modelos são treinados também com uma segunda semente (43), e todo o protocolo acima é repetido sobre esses resultados. Essa análise é parte do protocolo, e não um complemento opcional: como o Capítulo 6 mostra, o veredito do teste pareado depende da semente, e reportar uma única execução por modelo daria uma impressão de definitividade que os dados não sustentam.

4.8 AMBIENTE EXPERIMENTAL E RASTREABILIDADE

As etapas de *parsing*, particionamento, geração de candidatos, análise exploratória e testes de significância executam em CPU; o ajuste fino dos *encoders* é executado em ambiente com GPU (Google Colab, Tesla T4), com o mesmo núcleo de código para os dois modelos. O Quadro 2 consolida o ambiente e os hiperparâmetros comuns às duas execuções.

A rastreabilidade é reforçada por três mecanismos: a semente de treino é registrada em cada arquivo de resultado, junto com a configuração completa; os *splits* congelados são verificados por *hashes* SHA-256 (Apêndice A); e cada métrica reportada tem um arquivo JSON correspondente em `results/`, do qual as tabelas e figuras deste trabalho são geradas por *script*, nunca transcritas à mão.

Quadro 2 – Ambiente experimental e hiperparâmetros compartilhados pelos dois *baselines*.

Item	Valor
Ajuste fino (GPU)	Google Colab, Tesla T4
Demais etapas	CPU
Núcleo de implementação	src/relation_extraction.py (idêntico para os dois <i>encoders</i>)
max_gap	20 caracteres
ctx_chars	128 caracteres em torno do par
max_length	128 <i>tokens</i>
<i>Batch</i>	64
Taxa de aprendizado	2×10^{-5} (AdamW), escalonador linear com <i>warmup</i>
Épocas	3
Perda	<i>cross-entropy</i> com <code>class_weight="balanced"</code>
Seleção de modelo	maior macro-F1 no conjunto de validação
Sementes de treino	42 (referência) e 43 (robustez)
<i>Bootstrap</i> pareado	10.000 reamostragens, percentis 2,5/97,5
Comparação pareada	McNemar (binomial exato) + <i>bootstrap</i> pareado

Fonte: elaborado pelo autor (campo config de results/baseline_*.json).

5 PROPOSTA DO PROTÓTIPO

Este capítulo descreve a proposta de solução para a extração de relações clínicas. O trabalho integra o desenvolvimento do **RECLin-PT**, um modelo aprimorado de extração de relações em texto clínico em português. Como etapa inicial dessa construção, conduz-se um **experimento controlado de *baselines*** que responde a uma pergunta de projeto anterior a qualquer aprimoramento: *o pré-treinamento clínico importa para a extração de relações em textos médicos em português?* A resposta determina sobre qual *encoder* o RECLin-PT deve ser construído.

5.1 VISÃO GERAL E PAPEL DOS *BASELINES*

Comparam-se dois *encoders* para o português, tratados como *baselines* sob a mesma tarefa: o **BioBERTpt** (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e biomédicas em português, e o **BERTimbau** (SOUZA; NOGUEIRA; LOTUFO, 2020), pré-treinado em texto de domínio geral (brWaC). Os dois compartilham a mesma arquitetura base (BERT) e diferem essencialmente no corpus de pré-treinamento, o que os torna candidatos naturais a um experimento controlado sobre a importância do domínio de pré-treino.

A premissa metodológica central é a **paridade**: a infraestrutura descrita aqui não constitui um modelo com nome próprio, é apenas a cadeia que viabiliza a comparação de forma justa. Os dois *baselines* compartilham um único núcleo de implementação (`src/relation_extraction.py`) e são, por construção, idênticos em tudo exceto no *checkpoint* carregado:

- a mesma partição congelada e os mesmos pares candidatos (Capítulo 4), o que coloca os dois sob o mesmo teto de *recall* e na mesma régua estatística;
- a mesma representação de entrada por marcadores de entidade (Seção 5.4);
- a mesma função de perda, *cross-entropy* com `class_weight="balanced"`;
- o mesmo escalonador linear com *warmup* e os mesmos hiperparâmetros de otimização (Quadro 2);

- a mesma semente de treino e o mesmo critério de seleção de modelo: maior macro-F1 no conjunto de validação.

Trocar um *baseline* pelo outro consiste, literalmente, em mudar a *string* do *checkpoint*. Qualquer diferença observada pode, portanto, ser atribuída ao pré-treinamento, e não a artefatos de implementação. Essa é exatamente a condição para que a pergunta de pesquisa tenha resposta.

5.2 OS DOIS *ENCODERS* COMPARADOS

5.2.1 BioBERTpt — *encoder* de domínio clínico

O **BioBERTpt** (`pucpr/biobertpt-all`) (SCHNEIDER *et al.*, 2020) é um modelo contextual adaptado ao domínio clínico e biomédico em português brasileiro, com 177,9 milhões de parâmetros. Sua adoção corresponde à expectativa, difundida na literatura e sustentada pelos ganhos relatados em reconhecimento de entidades nomeadas clínicas, de que o pré-treinamento sobre texto do próprio domínio produza representações mais adequadas a tarefas clínicas. É essa expectativa que o experimento coloca à prova.

5.2.2 BERTimbau — *encoder* de domínio geral

O **BERTimbau** (`neuralmind/bert-base-portuguese-cased`) (SOUZA; NOGUEIRA; LOTUFO, 2020) é a referência de domínio geral para o português, pré-treinado no corpus brWaC, com 108,9 milhões de parâmetros, cerca de 60% do tamanho do BioBERTpt. Ele entra no experimento como o controle que isola o efeito do domínio de pré-treino, e não como modelo secundário: se o desempenho for equivalente, o modelo menor é preferível por custo de inferência e de memória, consideração concreta para implantação em ambientes clínicos com recursos limitados.

5.3 TRATAMENTO DO DESBALANCEAMENTO

Uma decisão central, comum aos dois *baselines*, é o uso de `class_weight="balanced"` na função de perda: o erro é reescalado de forma inversamente proporcional à frequên-

cia de cada classe. Sem esse ajuste, o otimizador minimizaria o erro simplesmente prevendo `no_relation` para quase tudo, dado que essa classe concentra 93,06% dos candidatos de teste. A reescala força o modelo a “pagar” caro por erros nas classes raras, sem descartar dados nem introduzir o não-determinismo de uma subamostragem. Como a mesma estratégia é aplicada aos dois *encoders*, seu efeito é compartilhado e não confunde a comparação.

A seleção de modelo usa o conjunto de validação (macro-F1), com o conjunto de teste reservado a uma única avaliação final. Os hiperparâmetros efetivamente utilizados constam do Apêndice C.

5.4 REPRESENTAÇÃO DE ENTRADA: MARCADORES DE POSIÇÃO

O modelo contextual não recebe o par de entidades de forma abstrata: recebe um recorte do *texto* do documento com o par delimitado por **marcadores de entidade**. A técnica é padrão em extração de relações com modelos baseados em BERT: inserir no próprio texto marcadores que delimitam e_1 e e_2 é mais eficaz do que concatenar representações de *span* isoladas, pois permite que o mecanismo de atenção condicione a codificação de toda a janela ao par sob análise.

5.4.1 O esquema adotado

A função `build_marked_window` (`src/relation_extraction.py`) recorta uma janela de ± 128 caracteres em torno do par (`ctx_chars`) e insere quatro delimitadores, no esquema

$$[E1] \text{ superfície}_{e_1} [/E1] \quad \dots \quad [E2] \text{ superfície}_{e_2} [/E2]$$

Os quatro marcadores são registrados como *tokens* especiais no *tokenizer* (`add_special_tokens`), e a matriz de *embeddings* do modelo é redimensionada (`resize_token_embeddings`) para lhes dar um vetor dedicado, aprendido durante o ajuste fino.

Três propriedades desse esquema merecem registro explícito, por delimitarem exatamente *que informação* o modelo recebe:

1. **Os marcadores são posicionais, não semânticos.** Eles indicam quais trechos da janela formam o par e qual deles é o primeiro argumento, e nada mais. O **tipo semântico** anotado pelo SemClinBr (Disease or Syndrome, Negation, Finding...) **não é passado ao modelo**: cabe a ele inferir a natureza de cada entidade a partir da superfície textual e do contexto.
2. **A direção vem da etiqueta, não da ordem.** A inserção é feita por deslocamento de caractere; quando e_2 precede e_1 no texto, a *string* resultante começa por [E2]. A direção da relação, que importa para *negation_of*, é preservada por *qual* marcador envolve *qual* entidade, e não pela ordem em que os marcadores aparecem.
3. **A classificação usa a representação agregada da sequência.** O cabeçote é o de `AutoModelForSequenceClassification`, que projeta a representação agregada da sequência (o *token* [CLS]) nas três classes. Não há extração explícita dos estados ocultos dos marcadores: eles influenciam a predição por meio da atenção, ao condicionar a codificação da janela inteira ao par delimitado.

Como a mesma representação é aplicada aos dois *encoders*, qualquer efeito dessas escolhas é compartilhado e não confunde a comparação (Capítulo 6).

5.4.2 Exemplo

Aplicado ao trecho do Quadro 1, o par *gold* 16 → 52 produz a entrada reproduzida no Quadro 3. Note que nem Disease or Syndrome (tipo de “OSTEOMIELITE”) nem Negation (tipo de “NÃO ESPECIFICADA”) aparecem na entrada: o modelo vê apenas o texto e os delimitadores.

Quadro 3 – Entrada efetivamente construída para o par *gold* do Quadro 1.

```
... CURATIVO COM ASPECTO LIMPO E SECO. SEGUE EM OBSERVAÇÃO. [E1]
OSTEOMIELITE [/E1] [E2] NÃO ESPECIFICADA [/E2]. INTUBADO, SOB
VENTILAÇÃO MECÂNICA, MONITORIZAÇÃO CARDÍACA ...
```

Fonte: elaborado pelo autor (saída de `build_marked_window` para o documento 8906 do SemClinBr, `ctx_chars=128`).

5.4.3 O que essa escolha deixa de fora

Registrar o que *não* entra na representação é tão importante quanto descrever o que entra. O SemClinBr anota cada entidade com tipos semânticos da UMLS, frequentemente em **rótulos múltiplos** separados por “|” (por exemplo, Medical Device|Finding|Abbreviation). Essa anotação **não chega ao modelo**: os resultados do Capítulo 6 foram obtidos com marcadores puramente posicionais, e a natureza de cada entidade tem de ser inferida da superfície textual e do contexto.

A anotação de tipo, aliás, não é diretamente aproveitável na forma em que vem. No conjunto de treino ocorrem apenas 89 tipos *atômicos* distintos, mas a combinação multirrótulo faz o número de *strings* de tipo distintas subir para 828, das quais 752 contêm “|”. Injetar essa *string* diretamente no marcador seria contraproducente: cada uma das 828 combinações viraria um símbolo praticamente único e mal povoado no treino, prejudicando a generalização. Aproveitá-la exigiria, antes, um esquema de normalização que colapsasse as combinações em um vocabulário pequeno e estável.

Para a pergunta desta etapa, porém, a ausência do tipo é inclusive conveniente: como nenhum dos dois *encoders* recebe a informação semântica pronta, a comparação mede a capacidade de cada um de *inferi-la* do texto, e é exatamente aí que o pré-treinamento de domínio deveria fazer diferença.

6 EXPERIMENTOS E RESULTADOS

Este capítulo reporta os experimentos conduzidos e seus resultados. Os dois *encoders* descritos no Capítulo 5 foram ajustados sobre a mesma partição congelada e avaliados sobre o mesmo conjunto de teste, composto por 16074 pares candidatos (14959 *no_relation*, 964 *associated_with* e 151 *negation_of*), gerados conforme o Capítulo 4. As métricas seguem o protocolo ali descrito.

6.1 CONFIGURAÇÃO EXPERIMENTAL

Cada *encoder* foi ajustado por 3 épocas, com *batch* de 64, taxa de aprendizado 2×10^{-5} (AdamW) e *max_length* de 128 *tokens*, sob *cross-entropy* ponderada por *class_weight="balanced"*. A época reportada é a de maior macro-F1 no conjunto de validação; o conjunto de teste foi avaliado uma única vez, ao final. Os dois modelos foram treinados com a semente de referência 42 e, como análise de robustez, novamente com a semente 43, mantendo, em ambos os casos, todos os demais elementos idênticos (Quadro 2).

O conjunto de teste é fortemente desbalanceado: a classe *no_relation* concentra 93,06% dos pares. Esse cenário torna o macro-F1 a métrica mais informativa, por penalizar modelos que negligenciam as classes minoritárias, e faz da acurácia uma métrica enganosa isoladamente: um classificador que respondesse sempre *no_relation* acertaria mais de 93% dos candidatos sem qualquer utilidade clínica.

6.2 CURVAS DE TREINO E SELEÇÃO DE MODELO


A Figura 7 apresenta a evolução por época dos dois *encoders* nas duas sementes, e a Tabela 6 traz os mesmos valores em número. Três observações são relevantes.

Primeiro, a **perda de treino cai monotonicamente** nas quatro execuções, enquanto a perda de validação estabiliza ou volta a subir a partir da segunda época, comportamento típico de ajuste fino de *encoders* sobre conjuntos pequenos. Segundo, e mais importante para o protocolo, o **macro-F1 de validação continua subindo** mesmo quando a perda de validação piora: é o caso do BERTimbau na semente 43, cuja

perda de validação sobe de 0,437 (época 2) para 0,489 (época 3) enquanto o macro-F1 avança de 0,624 para 0,674. Sob forte desbalanceamento, perda e macro-F1 não são intercambiáveis como critério de parada, e selecionar pela perda teria descartado a melhor época em termos da métrica de interesse, razão pela qual a seleção de modelo usa explicitamente o macro-F1 de validação.

Terceiro, as curvas tornam visível a **diferença de estabilidade** entre os *encoders*. O BERTimbau percorre trajetórias quase sobrepostas nas duas sementes na perda de treino; o BioBERTpt, não: na semente 43 ele parte de um F1 de *negation_of* de 0,374 na primeira época, contra 0,679 na semente 42, e só recupera terreno ao longo do treino. Essa dispersão, visível desde a primeira época, é a mesma que reaparece nas métricas finais (Seção 6.6).

Figura 7 – Evolução por época dos dois *encoders* nas sementes 42 e 43: perda (à esquerda) e F1 no conjunto de validação (à direita). Marcador preenchido indica a época selecionada.



Fonte: elaborado pelo autor (scripts/make_tcc_curves.py).

Tabela 6 – Evolução por época no conjunto de validação. * marca a época selecionada (maior macro-F1 na validação), cujo *checkpoint* produziu as métricas de teste.

Modelo	Semente	Época	Perda (treino)	Perda (val.)	Macro-F1 (val.)	F1 negation_of (val.)	Duração (min)
BioBERTpt (clínico)	42	1	0,6703	0,4115	0,638	0,679	48,4
		2	0,4020	0,4005	0,663	0,690	48,5
		3*	0,2900	0,4422	0,680	0,725	48,5
	43	1	0,7329	0,4251	0,513	0,374	53,4
		2	0,4426	0,4373	0,594	0,611	53,5
		3*	0,3542	0,4316	0,661	0,698	53,6
BERTimbau (geral)	42	1	0,7152	0,4729	0,587	0,533	47,4
		2*	0,4208	0,5239	0,657	0,665	47,8
		3	0,3183	0,4967	0,656	0,660	47,9
	43	1	0,7212	0,4612	0,583	0,548	54,2
		2	0,4188	0,4371	0,624	0,643	54,4
		3*	0,3158	0,4895	0,674	0,699	54,4

Fonte: elaborado pelo autor (campo `dev_history` de `results/baseline_*.json`).

6.3 RESULTADOS NO CONJUNTO DE TESTE

A Tabela 7 consolida os resultados dos dois *baselines* na semente de referência. Os melhores valores por coluna estão em negrito.

Tabela 7 – Resultados dos *baselines* no conjunto de teste ($n = 16.074$, semente 42). Negrito indica o melhor valor por coluna.


Modelo	Macro-F1	F1 _{neg}	F1 _{assoc}	F1 _{no_rel}	MCC	Acurácia
BioBERTpt (clínico)	0,707	0,724	0,460	0,935	0,487	0,885
BERTimbau (geral)	0,704	0,734	0,445	0,934	0,471	0,882

Fonte: elaborado pelo autor (`results/baseline_*_seed42.json`).

Os dois *baselines* apresentam desempenho praticamente indistinguível. O BioBERTpt clínico atinge macro-F1 de 0,707 e o BERTimbau geral, 0,704, uma diferença de 0,003. Na métrica-alvo, o F1 de `negation_of`, a ordem inclusive se inverte: o BERTimbau geral (0,734) supera marginalmente o BioBERTpt clínico (0,724). As demais métricas seguem o mesmo padrão de quase empate: ambos alcançam *recall* alto na negação (BioBERTpt 0,894; BERTimbau 0,887) com precisão moderada ($\approx 0,61$ – $0,63$), e ambos têm na classe `associated_with` a maior dificuldade ($F1 \approx 0,45$ – $0,46$), com alta cobertura mas baixa precisão. A Figura 8 resume o F1 por classe dos dois *baselines*: as barras são

praticamente coincidentes em todas as classes.

Figura 8 – F1 por classe no conjunto de teste: BioBERTpt (clínico) vs. BERTimbau (geral), semente 42.




Fonte: elaborado pelo autor (`scripts/make_tcc_artifacts.py`).

6.4 MATRIZES DE CONFUSÃO

As Figuras 9 e 10 apresentam as matrizes de confusão dos dois *baselines*, **normalizadas por linha**, de modo que cada célula indica a fração das instâncias de uma classe verdadeira atribuída a cada classe predita. Os valores da diagonal correspondem, assim, ao *recall* por classe. Essa visão complementa o F1 por classe ao revelar *para onde* vão os erros de cada modelo.


Os dois padrões de erro são notavelmente semelhantes: diagonal forte na negação e na classe majoritária, e o erro dominante remanescente na confusão entre `associated_with` e `no_relation`, coerente com a baixa precisão daquela classe nos dois modelos. A semelhança qualitativa entre as matrizes reforça a leitura de que os dois *encoders* aprendem essencialmente a mesma função para esta tarefa: não apenas chegam a números próximos, mas erram nos mesmos lugares.

Figura 9 – Matriz de confusão do BioBERTpt (clínico), normalizada por linha.



Fonte: elaborado pelo autor (scripts/make_tcc_artifacts.py).

Figura 10 – Matriz de confusão do BERTimbau (geral), normalizada por linha.



Fonte: elaborado pelo autor (scripts/make_tcc_artifacts.py).

6.5 SIGNIFICÂNCIA ESTATÍSTICA

A proximidade dos valores pontuais sugere empate, mas a conclusão exige um teste pareado. A Tabela 8 reporta a comparação direta entre os dois *baselines* no conjunto de teste, na semente de referência.

Tabela 8 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ($n = 16.074$, semente 42).

Medida	Valor
F1 <code>negation_of</code> — BioBERTpt (A)	0,724
F1 <code>negation_of</code> — BERTimbau (B)	0,734
Diferença observada (A – B)	–0,010
McNemar: b (só A acerta) / c (só B acerta)	494 / 452
McNemar: valor- p (binomial exato)	0,18
<i>Bootstrap</i> pareado: IC95% da diferença	$[-0,047; +0,026]$
<i>Bootstrap</i> pareado: valor- p	0,5704
Diferença significativa ($\alpha = 0,05$)?	Não

Fonte: elaborado pelo autor (`results/significance_biobertpt_vs_bertimbau_seed42.json`).

No F1 de `negation_of`, a diferença observada é de apenas $-0,010$ (a favor do BERTimbau geral). O teste de McNemar não rejeita a hipótese nula de igualdade ($p = 0,18$): das 946 instâncias em que os modelos discordam, 494 favorecem o BioBERTpt e 452 o BERTimbau, uma assimetria compatível com o acaso. O *bootstrap* pareado confirma o resultado: o intervalo de confiança de 95% para a diferença é $[-0,047; +0,026]$, que **inclui o zero**, com valor- p de 0,57. Em ambos os testes, portanto, **não há diferença estatisticamente significativa** entre o *encoder* clínico e o geral *nesta semente*, ressalva relevante, pois a análise a seguir mostra que esse veredito não se repete na semente 43.

6.6 ROBUSTEZ À SEMENTE DE TREINO

Para situar a magnitude da diferença entre os *baselines*, ambos foram treinados com uma segunda semente (43), mantendo todo o restante idêntico. A Tabela 9 consolida as métricas por semente e a amplitude observada.

Tabela 9 – Robustez à semente de treino: métricas de teste por semente, média e amplitude observada.

Modelo	Métrica	Semente 42	Semente 43	Média	Amplitude
BioBERTpt (clínico)	Macro-F1	0,707	0,665	0,686	0,042
	F1 negation_of	0,724	0,653	0,689	0,070
	F1 associated_with	0,460	0,417	0,439	0,043
	F1 no_relation	0,935	0,923	0,929	0,012
BERTimbau (geral)	Macro-F1	0,704	0,706	0,705	0,002
	F1 negation_of	0,734	0,726	0,730	0,008
	F1 associated_with	0,445	0,453	0,449	0,009
	F1 no_relation	0,934	0,939	0,936	0,005

Fonte: elaborado pelo autor (`scripts/aggregate_seeds.py` → `results/summary_by_seed.json`).

O contraste entre os dois *encoders* é acentuado. No BioBERTpt, o macro-F1 cai de 0,707 (semente 42) para 0,665 (semente 43), e o F1 de `negation_of`, de 0,724 para 0,653, uma amplitude de 0,070 atribuível *apenas* à inicialização aleatória do treino. Essa variação entre sementes de um *mesmo* modelo é cerca de **sete vezes maior** que a diferença de 0,010 observada entre o BioBERTpt e o BERTimbau na semente 42. Em outras palavras, o ruído de treino do *encoder* clínico, isoladamente, supera a vantagem que se poderia atribuir ao domínio de pré-treino.

O BERTimbau, sob a mesma troca de semente, mostra-se sensivelmente mais estável: o macro-F1 passa de 0,704 para 0,706 e o F1 de `negation_of`, de 0,734 para 0,726, uma amplitude de 0,008, cerca de nove vezes menor que a do BioBERTpt na mesma métrica.

O ponto metodologicamente mais delicado é que o *veredito estatístico* também muda. A Tabela 10 aplica à semente 43 exatamente o mesmo protocolo da Seção 6.5.

Tabela 10 – Comparação pareada BioBERTpt (clínico) vs. BERTimbau (geral) no conjunto de teste ($n = 16.074$, semente 43).

Medida	Valor
F1 negation_of — BioBERTpt (A)	0,653
F1 negation_of — BERTimbau (B)	0,726
Diferença observada (A – B)	–0,073
McNemar: b (só A acerta) / c (só B acerta)	394 / 818
McNemar: valor- p (binomial exato)	$< 0,001$
<i>Bootstrap</i> pareado: IC95% da diferença	$[-0,115; -0,031]$
<i>Bootstrap</i> pareado: valor- p	$< 0,001$
Diferença significativa ($\alpha = 0,05$)?	Sim

Fonte: elaborado pelo autor (results/significance_biobertpt_vs_bertimbau_seed43.json).

Na semente 43, a ordenação entre os dois *baselines* no F1 de negação se mantém, agora com margem de 0,073, e o mesmo protocolo acusa uma diferença **significativa** em favor do BERTimbau (McNemar $p < 10^{-30}$; *bootstrap* pareado IC95% $[-0,115; -0,031]$, $p = 0,0002$), ao contrário do que se observa na semente 42, em que o mesmo teste não rejeita a hipótese nula.

Esse contraste **não estabelece a superioridade do *encoder* geral**. O que ele mostra é que o próprio veredito do teste pareado, sob protocolo e conjunto de teste idênticos, alterna entre “sem diferença” e “diferença significativa” em função apenas da inicialização do treino. O que atravessa as duas sementes são dois fatos. O primeiro é o **signal**: em nenhuma das sementes o pré-treinamento clínico aparece à frente. O segundo é a **menor previsibilidade** do *encoder* clínico entre reinicializações, que, em um cenário de implantação, pesa a favor do geral. A leitura estatística, essa sim, depende da semente e não deve ser tomada como definitiva a partir de uma única execução por modelo.

7 DISCUSSÃO

Este capítulo interpreta os resultados obtidos, discute limitações do trabalho e aponta ameaças à validade dos achados.

7.1 ANÁLISE DOS RESULTADOS

O resultado central é a **ausência de vantagem do pré-treinamento clínico**: para a extração de relações no SemClinBr, no espaço de três classes, o BioBERTpt não produz ganho mensurável sobre o BERTimbau, nem mesmo na classe `negation_of`, em que a especialização de domínio seria mais plausível. Convém precisar o que os testes sustentam. O veredito de *empate* vale para a semente 42 e não se repete na semente 43, em que a comparação pareada favorece o BERTimbau. O que se mantém entre as duas sementes não é o empate, e sim a *direção*: em nenhuma delas o *encoder* clínico fica à frente. Esse achado contrasta com a expectativa difundida, bem como com os ganhos relatados para o reconhecimento de entidades nomeadas clínicas em português (SCHNEIDER *et al.*, 2020), de que modelos de domínio sempre se transfiram melhor.

Duas explicações são plausíveis e compatíveis com os dados.

A primeira é **linguística**. A negação clínica em português é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”, além de adjetivos que embutem negação morfológicamente, como “afebril” e “anictérico”, conforme o Apêndice B). Esse sinal é frequente e regular o bastante para que um *encoder* de domínio geral, com vocabulário amplo do português, o capture tão bem quanto um clínico. A caracterização do corpus reforça essa leitura: a mediana da distância entre as entidades de uma relação `negation_of` é de um único caractere (Seção 4.2), ou seja, o gatilho de negação está praticamente colado ao achado negado. Detectá-lo depende pouco de conhecimento clínico especializado.

A segunda é **estrutural**. A tarefa, tal como formulada, depende mais da estrutura local do par, isto é, da direção, da proximidade e da delimitação das entidades, do que de conhecimento lexical especializado de domínio, e essa estrutura é fornecida igualmente

aos dois *baselines* pela representação de entrada compartilhada (Seção 5.4). A semelhança entre as matrizes de confusão (Seção 6.4) é a evidência mais direta disso: os dois modelos não apenas chegam a números próximos, mas concentram o erro no mesmo lugar: a fronteira entre `associated_with` e `no_relation`.

Um corolário prático, e diretamente relevante para o desenvolvimento do RECLin-PT, é a **eficiência**: o BERTimbau iguala o BioBERTpt com aproximadamente 60% dos parâmetros (108,9 contra 177,9 milhões). Quando o desempenho é equivalente, o modelo menor é preferível por custo de inferência e de memória, consideração concreta para implantação em ambientes clínicos com recursos limitados. A esse argumento soma-se a estabilidade: a amplitude entre sementes do BERTimbau na métrica-alvo (0,008) é cerca de nove vezes menor que a do BioBERTpt (0,070), o que torna seu desempenho mais previsível em uma nova execução.

7.2 A CLASSE ASSOCIATED_WITH

A classe `associated_with` permanece a mais difícil para os dois modelos ($F1 \approx 0,45$), com alta cobertura e baixa precisão. Duas causas se somam.

A primeira é **conceitual**: distinguir associação genuína de mera proximidade textual é intrinsecamente ambíguo em texto clínico telegráfico, em que entidades vizinhas frequentemente não mantêm relação anotada, como ilustra o próprio exemplo de geração de candidatos (Quadro 1), em que cinco dos seis pares ordenados possíveis são `no_relation`.

A segunda é **metodológica**: a janela `max_gap=20` descarta 12,02% das relações `associated_with` do conjunto de teste (Seção 4.6.1), enquanto descarta apenas uma relação `negation_of`. O F1 dessa classe é, portanto, medido sob um teto de *recall* substancialmente mais baixo que o das demais. Como o teto é idêntico para os dois modelos, ele não afeta a comparação, objeto deste trabalho, mas qualquer leitura do valor absoluto de F1 de `associated_with` precisa levá-lo em conta.

7.3 LIMITAÇÕES

A limitação mais séria recai sobre a própria caracterização de empate. Ela vale para a semente 42; a comparação pareada refeita na semente 43 acusa diferença significativa em favor do BERTimbau. Nenhuma das duas sementes coloca o *encoder* clínico à frente, de modo que a conclusão prática, a ausência de ganho atribuível ao pré-treinamento clínico, não depende da semente. A leitura estatística, porém, depende. Além disso, **duas sementes por modelo não bastam** para estimar um intervalo de confiança sobre essa variação: o desvio reportado na Tabela 9 deve ser lido como dispersão observada, não como estimativa de variância. Fechar a questão exige um número maior de repetições com agregação formal.

A tarefa pressupõe **entidades já anotadas** (*gold*): a avaliação não considera o erro propagado de uma etapa de reconhecimento de entidades nomeadas automática, de modo que os resultados refletem a extração de relações isoladamente. Em um cenário fim a fim, os valores absolutos seriam necessariamente menores.

Por fim, o achado é específico desta **formulação de três classes** e desta **escala de modelo** (*base*). Não se pode excluir que o pré-treinamento clínico volte a importar em espaços de relação mais ricos, em modelos maiores ou em cenários com menos dados de ajuste.

7.4 AMEAÇAS À VALIDADE

Quanto à **validade interna**, o congelamento das partições com semente fixa e verificação por *hashes* SHA-256 (Apêndice A), somado ao particionamento em nível de documento, mitiga o vazamento de dados, a principal causa de resultados não reproduzíveis em PLN biomédico. A paridade total de implementação entre os dois *baselines* (Capítulo 5) garante que a diferença medida reflita o *checkpoint*, e não artefatos de código. Restam, contudo, decisões de projeto que influenciam os números absolutos, das quais a mais consequente é a janela `max_gap=20` na geração de pares candidatos. Esse limite foi quantificado por partição e por classe (Seção 4.6.1) e, portanto, é uma limitação *documentada e de magnitude conhecida*, e não uma fonte de incerteza não medida.

Uma segunda ameaça diz respeito à **independência das instâncias**. O *bootstrap* pareado trata os 16074 candidatos como independentes, o que não é estritamente verdadeiro: pares de um mesmo documento compartilham texto e vocabulário, de modo que o intervalo de confiança reportado é provavelmente mais estreito que o real. Essa ameaça atenua-se, mas não desaparece, pelo fato de a comparação ser *pareada*: ambos os modelos são avaliados exatamente sobre as mesmas instâncias, e a dependência afeta os dois igualmente. Ainda assim, a conclusão de empate na semente 42 deve ser lida com essa ressalva.

Quanto à **validade externa**, o SemClinBr, apesar de multi-institucional e multiespecialidade, representa um conjunto específico de instituições e estilos de redação; a generalização para outros contextos clínicos e para outros espaços de relação deve ser feita com cautela. As inconsistências de anotação conhecidas do corpus, ainda que tratadas e registradas pelo *parser*, também impõem um limite superior ao desempenho alcançável, limite que se aplica igualmente aos dois modelos comparados.

8 CONCLUSÃO

Este trabalho abordou a extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, no espaço de rótulos `negation_of`, `associated_with` e `no_relation`. Como etapa inicial do desenvolvimento do **RECLin-PT**, conduziu-se um experimento controlado de *baselines* para responder a uma pergunta que fundamenta as decisões de projeto seguintes: o pré-treinamento clínico importa para a extração de relações em textos médicos em português? A ênfase recaiu, simultaneamente, sobre a resposta a essa pergunta e sobre a construção de uma cadeia experimental reprodutível, do texto bruto às métricas finais.

8.1 CONTRIBUIÇÕES

As principais contribuições são: (i) um *parser* fiel e determinístico do formato XML do SemClinBr, com verificação de sanidade e correção controlada de *offsets*; (ii) uma caracterização do corpus que evidencia o desbalanceamento das relações e a proximidade entre entidades relacionadas, em particular a quase adjacência dos pares de negação; (iii) um protocolo de particionamento em nível de documento, estratificado e congelado, que previne vazamento de dados; (iv) um gerador determinístico de pares candidatos compartilhado por todos os modelos, com o teto de *recall* imposto pela janela quantificado por partição e por classe; (v) uma infraestrutura experimental de paridade total, em que os dois *encoders* comparados diferem apenas no *checkpoint* de pré-treino; e (vi) uma comparação empírica com teste de significância pareado entre um *encoder* clínico e um geral sobre a mesma tarefa.

Quanto aos resultados, não se observou vantagem do pré-treinamento clínico. Na semente de referência (42), a diferença no F1 de `negation_of` entre BioBERTpt e BERTimbau é de 0,010 e não é estatisticamente significativa (McNemar $p = 0,18$; *bootstrap* pareado IC95% $[-0,047; +0,026]$); na semente 43, a mesma comparação pareada passa a favorecer o BERTimbau (IC95% $[-0,115; -0,031]$, $p = 0,0002$). O veredito estatístico, portanto, **não é estável entre sementes**, pois a variação de inicialização de um mesmo modelo (0,070 de amplitude no BioBERTpt) supera com folga a diferença entre os dois modelos. A direção, contudo, é estável: em nenhuma

das sementes testadas o *encoder* clínico fica à frente. O *encoder* geral alcança o clínico com cerca de 60% dos parâmetros e com desempenho sensivelmente mais estável entre reinicializações.

8.2 TRABALHOS FUTUROS

Esses resultados orientam diretamente a próxima etapa: o RECLin-PT será desenvolvido a partir do *encoder* identificado como melhor base nos *baselines*. Como o BERTimbau geral não fica atrás em nenhuma das sementes testadas na métrica-alvo e exige cerca de 60% dos parâmetros, ele se apresenta como a base mais atraente por eficiência e previsibilidade. O desenvolvimento terá como foco o aprimoramento da classe `negation_of`, a mais crítica para a correta interpretação clínica.

Como continuidade, prevê-se ainda: estimar o desempenho dos *baselines* sob um número maior de sementes de treino, com agregação formal, para obter um intervalo de confiança da diferença mais estreito; enriquecer a representação de entrada com o **tipo semântico** das entidades, hoje ausente dos marcadores (Seção 5.4.3), medindo se o ganho difere entre o *encoder* clínico e o geral; reavaliar a janela `max_gap` da geração de pares candidatos, elevando o teto de *recall* de `associated_with` sem inviabilizar o custo de treino; investigar o tratamento explícito do escopo da negação e da direção das relações; estender o espaço de relações para além das três classes atuais; avaliar modelos maiores e *encoders* multilíngues (CONNEAU *et al.*, 2020); e integrar uma etapa de reconhecimento de entidades nomeadas automática, medindo a extração de relações em um cenário fim a fim.

O trabalho encontra-se, portanto, em andamento: os *baselines* aqui reportados estabelecem o ponto de partida do RECLin-PT, e não um encerramento.

REFERÊNCIAS

- CHAPMAN, W. W. *et al.* A simple algorithm for identifying negated findings and diseases in discharge summaries. **Journal of Biomedical Informatics**, v. 34, n. 5, p. 301–310, 2001.
- CONNEAU, A. *et al.* Unsupervised cross-lingual representation learning at scale. In: **Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2020. p. 8440–8451.
- DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. In: **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)**. [S.l.]: Association for Computational Linguistics, 2019. p. 4171–4186.
- DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895–1923, 1998.
- FORMAN, G.; SCHOLZ, M. Apples-to-apples in cross-validation studies: Pitfalls in classifier performance measurement. **ACM SIGKDD Explorations Newsletter**, v. 12, n. 1, p. 49–57, 2010.
- OLIVEIRA, L. E. S. e. *et al.* SemClinBr – a multi-institutional and multi-specialty semantically annotated corpus for Portuguese clinical NLP tasks. **Journal of Biomedical Semantics**, v. 13, n. 1, p. 13, 2022.
- SCHNEIDER, E. T. R. *et al.* BioBERTpt – a Portuguese neural language model for clinical named entity recognition. In: **Proceedings of the 3rd Clinical Natural Language Processing Workshop**. [S.l.]: Association for Computational Linguistics, 2020. p. 65–72.
- SECHIDIS, K.; TSOUMAKAS, G.; VLAHAVAS, I. On the stratification of multi-label data. In: **Machine Learning and Knowledge Discovery in Databases (ECML PKDD 2011)**. [S.l.]: Springer, 2011. (Lecture Notes in Computer Science, v. 6913), p. 145–158.
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for Brazilian Portuguese. In: **Intelligent Systems (BRACIS 2020)**. [S.l.]: Springer, 2020. (Lecture Notes in Computer Science, v. 12319), p. 403–417.
- VASWANI, A. *et al.* Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

Apêndices

APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS

Para garantir a reprodutibilidade dos experimentos, as partições de treino, desenvolvimento e teste foram congeladas após sua geração (semente 42, estratificação multirrótulo em nível de documento). O Quadro 4 apresenta os *hashes* SHA-256 dos arquivos, registrados por `src/make_splits.py` em `data/splits/MANIFEST.json` e versionados junto com os dados. Qualquer alteração nos arquivos altera o *hash*, permitindo a verificação independente da integridade das partições.

A verificação não é apenas documental: os *scripts* que geram as tabelas e figuras deste trabalho recalculam esses *hashes* antes de ler os dados e interrompem a execução se algum deles divergir do manifesto. Assim, nenhum número publicado aqui pode ter sido produzido a partir de uma partição diferente da registrada abaixo.

Quadro 4 – SHA-256 das partições congeladas do SemClinBr.

Arquivo	SHA-256
<code>train.jsonl</code>	36014b2adc8308bce94aeecf066c38f69e1f53dda4517fa424527554b31a437a
<code>dev.jsonl</code>	a9ea327684165c5053f8f3db5468a27f71c1d9e30d2859e343b6d275839c8aeb
<code>test.jsonl</code>	86304d8d507c6707695e2b86c3533b763a96247f06326e5980b4567385231e62

Fonte: elaborado pelo autor (`data/splits/MANIFEST.json`, gerado por `src/make_splits.py`).

As partições contêm, respectivamente, 800, 100 e 100 documentos. A Tabela 3, no Capítulo 4, registra a distribuição das relações entre elas: 9221 no treino, 987 na validação e 1250 no teste.

APÊNDICE B – MARCADORES DE NEGAÇÃO DO PORTUGUÊS CLÍNICO

A negação clínica em português é fortemente **lexicalizada**: um conjunto pequeno e recorrente de gatilhos responde pela maior parte das ocorrências, o que está na origem da eficácia de abordagens como o algoritmo NegEx (CHAPMAN *et al.*, 2001) e é uma das explicações discutidas no Capítulo 7 para o fato de um *encoder* de domínio geral capturar a negação tão bem quanto um clínico.

Este apêndice registra os marcadores mais frequentes observados no SemClinBr, a título de caracterização linguística do fenômeno. Eles **não** constituem parâmetro de nenhum dos modelos avaliados: os dois *encoders* comparados no Capítulo 6 não recebem lista alguma de gatilhos, e aprendem o sinal de negação diretamente do texto marcado.

Quadro 5 – Marcadores de negação recorrentes no português clínico.

Marcador	Observação
não	negação verbal/adverbial geral
sem	preposição de ausência
nega	forma verbal (“paciente nega. . .”)
ausência	substantivo de ausência
ausente	adjetivo de ausência
afebril	adjetivo com negação léxico-morfológica (sem febre)
anictérico	adjetivo com negação léxico-morfológica (sem icterícia)

Fonte: elaborado pelo autor a partir do SemClinBr.

Os termos “afebril” e “anictérico” são adjetivos que embutem negação morfológicamente e que, no SemClinBr, aparecem anotados como entidades da categoria *Negation*, categoria que responde por 2646 menções no corpus (Seção 4.2). Uma abordagem puramente léxica sobre esta lista não trataria negação de escopo amplo (“o paciente não apresenta nenhum dos seguintes: A, B, C”), negação estendida por conjunção, nem a direção da relação, limitações que motivam o uso de modelos contextuais, capazes de aprender o escopo a partir do contexto em vez de aplicar uma regra rígida de janela.

APÊNDICE C – HIPERPARÂMETROS

Este apêndice consolida os hiperparâmetros efetivamente utilizados nas etapas executadas do *pipeline*. O Quadro 6 reúne os parâmetros comuns à preparação dos dados e à avaliação; o Quadro 7 detalha o ajuste fino dos dois *encoders* comparados.

Todos os valores abaixo foram lidos do campo `config` dos arquivos `results/baseline_*.json`, gravado pelo próprio código de treino no momento da execução, e não transcritos de um plano de experimento. Os dois *encoders* compartilham a configuração integralmente: essa identidade é verificada automaticamente por `scripts/_artifacts.py`, que recusa gerar qualquer tabela deste trabalho caso as configurações das quatro execuções (dois modelos $\times$ duas sementes) diverjam em algum campo.

Quadro 6 – Parâmetros gerais da preparação dos dados e da avaliação.

Parâmetro	Valor
Semente do particionamento	42 (congelada)
Sementes de treino	42 (referência) e 43 (robustez)
Partição treino/validação/teste	80/10/10 (nível de documento)
Estratificação	multirrótulo por presença de classe no documento
Janela máxima de pares (<code>max_gap</code>)	20 caracteres
Contexto em torno do par (<code>ctx_chars</code>)	128 caracteres
<i>Bootstrap</i> pareado	10.000 reamostragens, percentis 2,5/97,5
Teste pareado	McNemar (binomial exato)
Critério de significância	IC95% da diferença não contém zero

Fonte: elaborado pelo autor (`results/baseline_*.json` e `results/significance_*.json`).

A Tabela 6, no Capítulo 6, registra a evolução época a época de cada uma das quatro execuções: perda de treino, perda de validação, macro-F1 e F1 de `negation_of` na validação, além da duração.

Quadro 7 – Hiperparâmetros do ajuste fino, idênticos para os dois *encoders*.

Parâmetro	Valor
<i>Encoder</i> clínico	pucpr/biobertpt-all (177,9 M de parâmetros)
<i>Encoder</i> geral	neuralmind/ bert-base-portuguese-cased (108,9 M de parâmetros)
Núcleo de implementação	src/relation_extraction.py
Representação de entrada	janela de texto com marcadores de posição ([E1]/[E2]), sem tipo semântico
Cabeçote de classificação	AutoModelForSequenceClassification (projeção linear sobre a representação agregada da sequência)
Perda	<i>cross-entropy</i> com <code>class_weight="balanced"</code>
<code>max_length</code>	128 <i>tokens</i>
Taxa de aprendizado	2×10^{-5} (AdamW)
Escalonador	linear com <i>warmup</i>
<i>Batch</i> (treino e avaliação)	64
Épocas	3
Seleção de modelo	maior macro-F1 no conjunto de validação
Hardware	Google Colab, <i>Tesla</i> T4

Fonte: elaborado pelo autor (campo config de results/baseline_*.json).