



BACHARELADO EM SISTEMAS DE INFORMAÇÃO
TRABALHO DE GRADUAÇÃO

ANGELO ANTONIO LIMA SILVEIRA FILHO

RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS
SOBRE O CORPUS SEMCLINBR

Cachoeiro de itapemirim

2026

ANGELO ANTONIO LIMA SILVEIRA FILHO

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS
SOBRE O CORPUS SEMCLINBR**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Cristiano da Silveira Colombo

Coorientadora: Profa. Dra. Beltrana de Tal

Cachoeiro de itapemirim

2026

(Biblioteca do Campus Cachoeiro de Itapemirim)

X999y

RECLin-PT: extração de relações em notas clínicas em português sobre o corpus SemClinBr/ Angelo Antonio Lima Silveira Filho. – 2026.

54 f: il; 30 cm.

Orientador: Cristiano da Silveira Colombo

Trabalho de Graduação – Instituto Federal do Espírito Santo, Bacharelado em Sistemas de Informação, 2026.

1. Processamento de linguagem natural. 2. Extração de relações. 3. Informática em saúde. 4. Aprendizado de máquina. 5. Língua portuguesa. I. Colombo, Cristiano da Silveira. II. Título. III. Instituto Federal do Espírito Santo.

CDD 000.00

ANGELO ANTONIO LIMA SILVEIRA FILHO

**RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS
SOBRE O CORPUS SEMCLINBR**

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Aprovado em 01 de Agosto de 2026

COMISSÃO EXAMINADORA

Prof. Dr. Cristiano da Silveira Colombo

Instituto Federal do Espírito Santo
Orientador

Profa. Dra. Beltrana de Tal

Instituto Federal do Espírito Santo
Coorientadora

Profa. Dra. Fulana de Tal

Instituto Federal do Espírito Santo
Examinadora

Prof. Dr. Cicrano de Tal

Instituto Federal do Espírito Santo
Examinador

À minha mãe, meu alicerce de força e superação, que esteve ao meu lado mesmo nos dias em que eu já não tinha vontade de continuar. Que jamais me desamparou diante das dificuldades e, com amor, coragem e fé, tornou-se o meu maior exemplo de vida. Tudo o que sou carrega um pouco da sua força. Aos meus amigos de jornada, que foram âncora e apoio durante todo o processo.

RESUMO

O registro eletrônico em saúde concentra grande parte da informação clínica em texto livre, no qual a relação entre conceitos — em especial a negação de achados — é determinante para a correta interpretação. Este trabalho investiga a extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, considerando o espaço de rótulos *negation_of*, *associated_with* e *no_relation*. Propõe-se uma cadeia experimental reprodutível que vai do texto bruto às métricas finais, composta por: um parser determinístico do formato XML do corpus; análise exploratória das relações; particionamento 80/10/10 em nível de documento, estratificado e congelado para evitar vazamento de dados; e geração controlada de pares candidatos. Foram estabelecidos *baselines* de referência — classe majoritária e regras léxicas inspiradas no algoritmo NegEx —, avaliados por macro-F1 e F1 por classe com intervalos de confiança de 95% obtidos por *bootstrap*. O *baseline* de regras alcançou macro-F1 de 0,236, superando a classe majoritária (0,006), mas com baixa precisão nas classes positivas. Um *baseline* de regressão logística com características léxicas e estruturais elevou o macro-F1 para 0,637, superando os anteriores em todas as métricas e confirmando o ganho de modelos aprendidos. Esses resultados estabelecem patamares de comparação para a etapa seguinte, o ajuste fino do modelo contextual de domínio clínico BioBERTpt.

Palavras-chave: Extração de relações. Processamento de linguagem natural clínico. Língua portuguesa. SemClinBr. Aprendizado de máquina.

ABSTRACT

Electronic health records store much clinical information as free text, in which the relationship between concepts — particularly the negation of findings — is decisive for correct interpretation. This work investigates relation extraction between clinical entities in Portuguese over the SemClinBr corpus, considering the label space `negation_of`, `associated_with` and `no_relation`. We propose a reproducible experimental pipeline that goes from raw text to final metrics, comprising: a deterministic parser for the corpus XML format; exploratory analysis of relations; a document-level, stratified and frozen 80/10/10 split to prevent data leakage; and controlled candidate-pair generation. Reference baselines — majority class and NegEx-inspired lexical rules — were established and evaluated with macro-F1 and per-class F1 with 95% bootstrap confidence intervals. The rule-based baseline reached a macro-F1 of 0.236, surpassing the majority class (0.006) but with low precision on the positive classes. A logistic-regression baseline with lexical and structural features raised the macro-F1 to 0.637, outperforming the previous baselines on every metric and confirming the gain of learned models. These results establish comparison baselines for the next step, the fine-tuning of the clinical-domain contextual model BioBERTpt.

Keywords: Relation extraction. Clinical natural language processing. Portuguese language. SemClinBr. Machine learning.

LISTA DE ILUSTRAÇÕES

Figura 1 – Processo de criação e anotação do corpus SemClinBr	21
Figura 2 – Distribuição dos tipos de relação no SemClinBr.	22
Figura 3 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200).	23
Figura 4 – Distribuição do número de relações por documento.	24
Figura 5 – Categorias atômicas de entidade mais frequentes (top 25).	25
Figura 6 – Distribuição das relações por partição (escala logarítmica), com o percentual de <i>negation_of</i> anotado.	26
Figura 7 – Matriz de confusão do <i>baseline</i> de classe majoritária (B0), normali- zada por linha.	40
Figura 8 – Matriz de confusão do <i>baseline</i> de regras léxicas (B1), normalizada por linha.	41
Figura 9 – Matriz de confusão do <i>baseline</i> de regressão logística (B2), normali- zada por linha.	41

LISTA DE TABELAS

Tabela 1 – Distribuição dos tipos de relação no corpus parseado.	22
Tabela 2 – Estatísticas da distância (em caracteres) entre entidades relacionadas, por tipo.	23
Tabela 3 – Distribuição real das relações por partição (<i>splits</i> congelados, somente 42).	26
Tabela 4 – Teto de recall imposto pela janela <code>max_gap=200</code> por partição.	29
Tabela 5 – Resultados dos modelos no conjunto de teste (macro-F1 e F1 por classe, com IC95%).	38
Tabela 6 – Teste de McNemar pareado entre os <i>baselines</i> ($\alpha = 0,05$, correção de Holm-Bonferroni).	42
Tabela 7 – Macro-F1 e IC95% por <i>bootstrap</i> por instância vs. por documento ($n_{\text{doc}} = 99$).	42

LISTA DE QUADROS

Quadro 1 – Exemplo de geração de candidatos para um trecho do SemClinBr.	28
Quadro 2 – Ambiente experimental e versões pinadas (<i>baselines</i>).	31
Quadro 3 – Exemplos de normalização de tipos pela função <code>normalize_type</code>	37
Quadro 4 – SHA-256 das partições congeladas do SemClinBr.	50
Quadro 5 – Marcadores de negação utilizados no <i>baseline</i> B1.	51
Quadro 6 – Parâmetros gerais do pipeline.	52
Quadro 7 – Hiperparâmetros do <i>baseline</i> de regras (B1).	52
Quadro 8 – Hiperparâmetros do <i>baseline</i> de regressão logística (B2).	53
Quadro 9 – Hiperparâmetros planejados do modelo proposto (BioBERTpt).	54

LISTA DE SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
IC	Intervalo de Confiança
IFES	Instituto Federal do Espírito Santo
NER	<i>Named Entity Recognition</i> (Reconhecimento de Entidades Nomeadas)
NLP	<i>Natural Language Processing</i> (Processamento de Linguagem Natural)
PLN	Processamento de Linguagem Natural
RE	<i>Relation Extraction</i> (Extração de Relações)
SemClinBr	<i>Semantically Annotated Corpus for Portuguese Clinical NLP</i>
TF-IDF	<i>Term Frequency–Inverse Document Frequency</i>
XML	<i>Extensible Markup Language</i>

SUMÁRIO

1	INTRODUÇÃO	12
1.1	PROBLEMA DE PESQUISA	12
1.2	MOTIVAÇÃO	13
1.3	OBJETIVOS	13
1.3.1	Objetivo geral	13
1.3.2	Objetivos específicos	13
1.4	ORGANIZAÇÃO DO TRABALHO	14
2	REFERENCIAL TEÓRICO	15
2.1	PROCESSAMENTO DE LINGUAGEM NATURAL CLÍNICO	15
2.2	EXTRAÇÃO DE ENTIDADES E DE RELAÇÕES	15
2.3	ABORDAGENS BASEADAS EM REGRAS E A NEGAÇÃO CLÍNICA	16
2.4	ABORDAGENS BASEADAS EM APRENDIZADO DE MÁQUINA	16
2.5	MODELOS BASEADOS EM <i>TRANSFORMERS</i>	16
3	TRABALHOS RELACIONADOS	17
3.1	RECURSOS E DESAFIOS EM INGLÊS	17
3.2	RECURSOS PARA O PORTUGUÊS	17
3.3	POSICIONAMENTO DESTE TRABALHO	17
4	METODOLOGIA	19
4.1	VISÃO GERAL DO PIPELINE	19
4.2	CORPUS SEMCLINBR	20
4.3	PARSING E REPRESENTAÇÃO CANÔNICA	21
4.4	CARACTERIZAÇÃO DO CORPUS	21
4.4.1	Distribuição dos tipos de relação	22
4.4.2	Distância entre entidades relacionadas	22
4.4.3	Relações por documento e categorias de entidade	23
4.5	PARTICIONAMENTO DOS DADOS	24
4.6	GERAÇÃO DE PARES CANDIDATOS	26
4.6.1	Teto de recall imposto pela janela	28
4.7	PROTOCOLO DE AVALIAÇÃO	29
4.8	AMBIENTE EXPERIMENTAL E RASTREABILIDADE	30
5	PROPOSTA DO PROTÓTIPO	32

5.1	VISÃO GERAL E PAPEL DOS <i>BASELINES</i>	32
5.2	B0 — CLASSE MAJORITÁRIA	32
5.3	B1 — REGRAS LÉXICAS (NEGEX-PT)	33
5.4	B2 — REGRESSÃO LOGÍSTICA COM CARACTERÍSTICAS	33
5.5	MODELO PROPOSTO — BIOBERTPT	34
5.6	REPRESENTAÇÃO DE ENTRADA: MARCADORES TIPADOS E GRUPOS SEMÂNTICOS UMLS	35
5.6.1	O problema dos tipos crus	35
5.6.2	Agregação nos 15 grupos semânticos UMLS	36
5.6.3	Por que isso ajuda o modelo	36
5.6.4	Exemplos	36
6	EXPERIMENTOS E RESULTADOS	38
6.1	CONFIGURAÇÃO EXPERIMENTAL	38
6.2	RESULTADOS	38
6.3	ANÁLISE DOS <i>BASELINES</i>	38
6.4	MATRIZES DE CONFUSÃO	39
6.5	SIGNIFICÂNCIA ESTATÍSTICA (TESTE DE MCNEMAR)	40
6.6	ROBUSTEZ DO INTERVALO DE CONFIANÇA (<i>BOOTSTRAP</i> POR DOCUMENTO)	42
6.7	MODELO PROPOSTO BASEADO EM <i>TRANSFORMER</i>	43
7	DISCUSSÃO	44
7.1	ANÁLISE DOS RESULTADOS	44
7.2	LIMITAÇÕES	44
7.3	AMEAÇAS À VALIDADE	45
8	CONCLUSÃO	46
8.1	CONTRIBUIÇÕES	46
8.2	TRABALHOS FUTUROS	46
	REFERÊNCIAS	48
	APÊNDICES	49
	APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS	50
	APÊNDICE B – LÉXICO DE NEGAÇÃO DO <i>BASELINE</i> DE REGRAS	51
	APÊNDICE C – HIPERPARÂMETROS	52

1 INTRODUÇÃO

O registro eletrônico em saúde concentra grande parte da informação clínica sob a forma de texto livre. Notas de evolução, sumários de alta e laudos são redigidos em linguagem natural, com abreviações idiossincráticas, ausência frequente de pontuação padronizada e construções negativas características do discurso médico. Essa riqueza textual, embora valiosa para pesquisa e apoio à decisão, permanece majoritariamente inacessível a consultas estruturadas, o que motiva o desenvolvimento de técnicas de Processamento de Linguagem Natural (PLN) capazes de transformar texto clínico em conhecimento estruturado.

No contexto da língua portuguesa, o avanço dessas técnicas foi historicamente limitado pela escassez de recursos anotados. A disponibilização do corpus **SemClinBr** (OLIVEIRA *et al.*, 2022), primeiro corpus clínico anotado semanticamente para o português, com mil documentos provenientes de múltiplas instituições e especialidades, criou condições para investigar tarefas antes restritas ao inglês, entre elas a extração de relações entre entidades clínicas.

1.1 PROBLEMA DE PESQUISA

A extração de entidades nomeadas identifica menções a conceitos clínicos (sintomas, doenças, achados, procedimentos), mas isoladamente não captura como esses conceitos se articulam no enunciado. Saber que um documento menciona “febre” não é suficiente: é preciso distinguir se a febre está *associada* ao quadro do paciente ou se está sendo *negada* (“paciente afebril”). Esse vínculo é o objeto da **extração de relações** (Relation Extraction, RE).

Este trabalho investiga a seguinte questão: *em que medida é possível classificar automaticamente as relações entre entidades clínicas anotadas no SemClinBr, dentro do espaço de rótulos `negation_of`, `associated_with` e `no_relation`, e qual o ganho de modelos aprendidos sobre abordagens léxicas?* O desafio é agravado por dois fatores inerentes ao corpus: o forte desbalanceamento entre as classes de relação e o fato de o SemClinBr anotar apenas relações positivas, exigindo a geração controlada de exemplos negativos.

1.2 MOTIVAÇÃO

A negação clínica é um fenômeno linguístico de alto impacto: tratar um achado negado como presente pode inverter completamente a interpretação de um prontuário. Em português, a negação é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”), o que sugere que mesmo abordagens simples podem estabelecer um patamar de desempenho relevante e, ao mesmo tempo, evidenciar as lacunas que justificam modelos contextuais. Construir esse percurso de forma reproduzível — desde o texto bruto até as métricas finais — é, em si, uma contribuição metodológica, dado que a falta de reprodutibilidade é uma das principais críticas dirigidas à literatura de PLN biomédico.

1.3 OBJETIVOS

1.3.1 Objetivo geral

Desenvolver, de forma reproduzível, um *pipeline* determinístico de extração de relações entre entidades clínicas em português sobre o corpus SemClinBr — considerando o espaço de rótulos `negation_of`, `associated_with` e `no_relation` — e avaliar, sob protocolo estatístico rigoroso (macro-F1 e F1 por classe com intervalos de confiança por bootstrap e teste de significância pareado), uma cadeia de três *baselines* de complexidade crescente: classe majoritária (B0), regras léxicas (B1) e regressão logística com características (B2). O ajuste fino de um modelo contextual de domínio clínico (BioBERTpt) é posicionado como trabalho futuro imediato, para o qual a cadeia estabelecida fornece patamares de comparação.

1.3.2 Objetivos específicos

- Construir um parser fiel ao formato XML do SemClinBr que produza uma representação canônica determinística do corpus.
- Caracterizar o corpus por meio de análise exploratória, quantificando a distribuição das relações e a distância entre entidades relacionadas.

- Definir uma partição treino/desenvolvimento/teste em nível de documento, estratificada e congelada, de modo a evitar vazamento de dados.
- Implementar um gerador determinístico de pares candidatos compartilhado por todos os modelos, garantindo a comparabilidade dos resultados.
- Estabelecer e avaliar três *baselines* — classe majoritária (B0), regras léxicas inspiradas no algoritmo NegEx (CHAPMAN *et al.*, 2001) (B1) e regressão logística com características léxicas e estruturais (B2) —, reportando macro-F1 e F1 por classe com intervalos de confiança por bootstrap e comparação por teste de McNemar.
- Preparar a infraestrutura para o ajuste fino do BioBERTpt como modelo proposto, a ser executado como continuidade imediata do trabalho.

1.4 ORGANIZAÇÃO DO TRABALHO

O Capítulo 2 apresenta os fundamentos de PLN clínico, extração de relações e modelos baseados em transformers. O Capítulo 3 discute trabalhos relacionados, com ênfase em recursos para o português. O Capítulo 4 descreve o corpus, o pipeline de processamento, a geração de pares candidatos e o protocolo de avaliação. O Capítulo 5 detalha a proposta de modelo. O Capítulo 6 reporta os experimentos e resultados. O Capítulo 7 analisa limitações e ameaças à validade, e o Capítulo 8 sintetiza as contribuições e aponta trabalhos futuros.

2 REFERENCIAL TEÓRICO

Este capítulo reúne os fundamentos necessários à compreensão do trabalho: o processamento de linguagem natural aplicado a textos clínicos, a tarefa de extração de relações, as abordagens baseadas em regras e em aprendizado, e os modelos de linguagem baseados em transformers.

2.1 PROCESSAMENTO DE LINGUAGEM NATURAL CLÍNICO

O PLN clínico ocupa-se da análise automática de textos produzidos no cuidado em saúde, como notas de evolução, sumários de alta e laudos. Esses textos apresentam características que os distinguem da linguagem geral: vocabulário técnico, abreviações não padronizadas, telegrafismo (omissão de elementos gramaticais) e prevalência de construções negativas e de incerteza. Tais propriedades tornam a transferência direta de ferramentas treinadas em domínio aberto pouco eficaz, motivando recursos e modelos específicos do domínio.

2.2 EXTRAÇÃO DE ENTIDADES E DE RELAÇÕES

A extração de informação em texto clínico costuma ser decomposta em duas tarefas encadeadas. A primeira, **reconhecimento de entidades nomeadas** (Named Entity Recognition, NER), delimita trechos do texto que mencionam conceitos de interesse e lhes atribui um tipo semântico. A segunda, **extração de relações** (RE), determina se um par de entidades mantém uma relação e de que tipo. Formalmente, dado um par ordenado de entidades (e_1, e_2) em um documento, a RE pode ser modelada como um problema de classificação que associa ao par um rótulo dentro de um conjunto pré-definido.

Neste trabalho o espaço de rótulos é `negation_of`, `associated_with` e `no_relation`. O rótulo `no_relation` é fundamental: como a anotação de corpora registra apenas relações positivas, todo par de entidades não anotado deve ser tratado como ausência de relação, o que introduz um forte desbalanceamento de classes.

2.3 ABORDAGENS BASEADAS EM REGRAS E A NEGAÇÃO CLÍNICA

Abordagens baseadas em regras codificam conhecimento linguístico explícito. Em detecção de negação clínica, o algoritmo **NegEx** (CHAPMAN *et al.*, 2001) tornou-se referência: a partir de um léxico de gatilhos de negação e de janelas de contexto, classifica achados como negados ou afirmados. Sua simplicidade e eficácia derivam do fato de a negação clínica ser altamente lexicalizada. Em português, gatilhos como “não”, “sem”, “nega” e “ausência de”, além de adjetivos que embutem negação morfológicamente (“afebril”, “anictérico”), sustentam estratégias análogas, adotadas neste trabalho como *baseline*.

2.4 ABORDAGENS BASEADAS EM APRENDIZADO DE MÁQUINA

Métodos aprendidos estimam, a partir de exemplos rotulados, a associação entre características do par de entidades e o rótulo da relação. Modelos lineares como a regressão logística, alimentados por características léxicas (por exemplo, representações TF-IDF do texto entre as entidades) e estruturais (tipos das entidades, distância, direção), oferecem um compromisso entre interpretabilidade e desempenho, servindo de *sanity check* antes de modelos mais custosos. Sua principal limitação é a representação de palavras como unidades independentes, incapaz de capturar dependências de longo alcance e contexto.

2.5 MODELOS BASEADOS EM *TRANSFORMERS*

A arquitetura Transformer (VASWANI *et al.*, 2017), baseada em mecanismos de atenção, viabilizou modelos de linguagem pré-treinados que produzem representações contextuais das palavras. O **BERT** (DEVLIN *et al.*, 2019) popularizou o paradigma de pré-treinamento seguido de ajuste fino (fine-tuning) para tarefas específicas. Para o português, modelos multilíngues como o **XLM-R** (CONNEAU *et al.*, 2020) e, sobretudo, modelos especializados no domínio clínico como o **BioBERTpt** (SCHNEIDER *et al.*, 2020) — adaptado a narrativas clínicas e textos biomédicos em português brasileiro — constituem candidatos naturais para a extração de relações clínicas, e é sobre eles que se apoia a proposta deste trabalho.

3 TRABALHOS RELACIONADOS

Este capítulo situa o trabalho em relação a recursos e estudos de extração de informação clínica, com ênfase na língua portuguesa.

3.1 RECURSOS E DESAFIOS EM INGLÊS

A extração de relações clínicas consolidou-se em língua inglesa em torno de campanhas de avaliação como as séries i2b2 e n2c2, que disponibilizaram corpora anotados e tarefas compartilhadas para problemas como relações entre medicamentos, dosagens e efeitos adversos. Esses esforços estabeleceram protocolos de avaliação e evidenciaram a importância de tratar adequadamente o desbalanceamento de classes e o vazamento de dados entre partições — preocupações transpostas para este trabalho.

3.2 RECURSOS PARA O PORTUGUÊS

O desenvolvimento de PLN clínico em português foi por muito tempo limitado pela ausência de corpora anotados de acesso controlado. O **SemClinBr** (OLIVEIRA *et al.*, 2022) preencheu parte dessa lacuna ao disponibilizar mil documentos clínicos anotados semanticamente, acompanhados de dicionários de abreviações e de pistas de negação. É o corpus central deste trabalho.

No plano dos modelos, o **BioBERTpt** (SCHNEIDER *et al.*, 2020) adaptou o paradigma de modelos de linguagem contextuais ao domínio clínico e biomédico em português brasileiro, demonstrando ganhos em reconhecimento de entidades nomeadas clínicas em relação a modelos de domínio geral. Modelos multilíngues como o XLM-R (CONNEAU *et al.*, 2020) oferecem uma alternativa de base ampla, útil como ponto de comparação.

3.3 POSICIONAMENTO DESTES TRABALHOS

Enquanto boa parte da literatura em português concentra-se em NER, este trabalho aborda a etapa subsequente de extração de relações sobre o SemClinBr, com atenção particular à negação clínica. A contribuição não está em propor uma arquitetura inédita,

mas em estabelecer, de maneira reprodutível e estatisticamente fundamentada, uma cadeia completa — do texto bruto às métricas com intervalos de confiança — que sirva de referência comparável para trabalhos futuros sobre o mesmo corpus.

4 METODOLOGIA

Este capítulo descreve o corpus, o pipeline de processamento, a estratégia de particionamento, a geração de pares candidatos e o protocolo de avaliação. Todas as etapas foram projetadas sob a premissa de **reprodutibilidade**: ordenação determinística das saídas, serialização fixa, semente aleatória registrada e verificação por hashes SHA-256.

4.1 VISÃO GERAL DO PIPELINE

Entende-se por *pipeline* de PLN uma sequência encadeada de etapas em que a saída de cada estágio é a entrada do seguinte, de modo que o dado bruto é progressivamente transformado até a métrica final. Estruturar o trabalho como um *pipeline* explícito tem duas vantagens: isola a responsabilidade de cada etapa (facilitando o teste e a auditoria isolados) e torna o caminho completo **reproduzível**, pois cada estágio é determinístico e seus artefatos podem ser verificados de forma independente. As etapas deste trabalho, na ordem em que são executadas, são:

1. **Parsing (XML bruto → dataset.jsonl)**. O *parser* converte cada documento XML do SemClinBr em um registro canônico JSONL (texto, entidades e relações). É necessário porque o formato XML original, fiel à anotação, não é prático para as etapas seguintes; a representação canônica unifica o acesso ao corpus.
2. **Particionamento (dataset.jsonl → *splits*)**. O conjunto é dividido em treino, desenvolvimento e teste em nível de documento. É necessário para separar dados de ajuste dos de avaliação sem vazamento (Seção 4.5).
3. **Geração de pares candidatos (*splits* → candidatos rotulados)**. Como o corpus só anota relações positivas, esta etapa constrói os exemplos negativos (*no_relation*), produzindo o espaço de classificação completo (Seção 4.6).
4. **Marcação de entidades (candidatos → texto marcado)**. Para os modelos contextuais, cada par candidato é transformado na string de entrada do *encoder*, com marcadores de entidade tipados (Seção 5.6 do Capítulo 5). É necessária para informar ao modelo *quais* entidades formam o par e *de que tipo* elas são.

5. **Classificação (texto marcado → predições).** Cada *baseline* ou modelo atribui um rótulo do conjunto {negation_of, associated_with, no_relation} a cada candidato (Capítulo 5).
6. **Avaliação (predições → métricas).** As predições são comparadas ao *gold* para produzir macro-F1, F1 por classe e intervalos de confiança, com testes pareados entre modelos (Seção 4.7).

O **determinismo** é garantido em *todas* as etapas, condição para que os *hashes* SHA-256 dos artefatos sejam estáveis entre execuções: a serialização JSONL é fixada byte a byte (`ensure_ascii=False`, `sort_keys=True`, quebras de linha LF); a ordenação das saídas é explícita (documentos por `doc_id`, candidatos por `(start, end, id)`); a semente aleatória é fixada em 42 e registrada em cada artefato de resultado; e o ambiente de execução tem versões de bibliotecas pinadas. As seções seguintes detalham cada etapa. A Figura 1 (Seção 4.2) situa a origem do dado de entrada, ilustrando o processo de criação e anotação do SemClinBr que antecede o *pipeline* aqui descrito.

4.2 CORPUS SEMCLINBR

O trabalho utiliza o corpus SemClinBr (OLIVEIRA *et al.*, 2022), composto por mil documentos clínicos em português anotados com entidades e relações. O corpus é distribuído sob licença restrita, mediante solicitação formal, e seus arquivos XML originais são tratados como **imutáveis** ao longo do pipeline. As relações anotadas no corpus público utilizado pertencem a dois tipos, `associated_with` e `negation_of`, sobre os quais se constrói o espaço de rótulos da tarefa. A Figura 1 ilustra o processo de criação e anotação do corpus.




Figura 1 – Processo de criação e anotação do corpus SemClinBr

Fonte: Oliveira et al. (2022).

4.3 PARSING E REPRESENTAÇÃO CANÔNICA

Um parser converte cada arquivo XML em um registro canônico no formato JSONL, com identificador do documento, texto, lista de entidades (tipo e *offsets*) e lista de relações. O parser é *fiel ao XML*: não normaliza tipos de entidade ou de relação, deixando tais decisões para etapas posteriores. A única transformação aplicada ao texto é o colapso de quebras de linha ($\backslash r \backslash n$, $\backslash r$, $\backslash n$) em espaço único, necessário para manter o alinhamento dos *offsets* de anotação.

Por se tratar de um corpus com inconsistências de anotação conhecidas, o parser executa verificações de sanidade (correspondência entre o texto extraído por *offset* e o atributo anotado, validade dos intervalos e integridade referencial das relações) e, quando possível, corrige automaticamente pequenos deslocamentos de *offset* (± 1 e ± 2 caracteres). As inconsistências são acumuladas em um log de avisos em vez de interromperem o processamento.

4.4 CARACTERIZAÇÃO DO CORPUS

A análise exploratória (Exploratory Data Analysis, EDA) foi conduzida sobre a representação canônica do corpus, totalizando 1 000 documentos, 45 132 entidades (média de 45,1 por documento) e 11 353 relações (média de 11,4 por documento). A mediana é de 10 relações por documento, o percentil 90 é de 24 e o máximo observado é de 63;

46 documentos (4,60%) não possuem nenhuma relação anotada. Essa caracterização quantifica a distribuição das relações, a distância entre entidades relacionadas e as categorias de entidade, fornecendo subsídio empírico para as decisões de projeto das etapas seguintes.

4.4.1 Distribuição dos tipos de relação


A Tabela 1 e a Figura 2 mostram o forte desbalanceamento entre os dois tipos de relação anotados, com predominância de `associated_with` (86,07%) sobre `negation_of` (13,93%). Esse desequilíbrio motiva tanto a escolha do macro-F1 como métrica principal quanto o tratamento explícito de classes nos modelos aprendidos.

Tabela 1 – Distribuição dos tipos de relação no corpus parseado.

Tipo de relação	N	%
<code>associated_with</code>	9772	86.07
<code>negation_of</code>	1581	13.93
Total	11353	100.00

Fonte: elaborado pelo autor a partir do SemClinBr.

Figura 2 – Distribuição dos tipos de relação no SemClinBr.



Fonte: elaborado pelo autor (`scripts/eda/eda_relations.py`).

4.4.2 Distância entre entidades relacionadas

A Tabela 2 e a Figura 3 indicam que as relações ocorrem entre entidades próximas: a mediana da distância é de poucos caracteres e o percentil 95 não ultrapassa algumas


dezenas (`associated_with`: média 11,9, p95 43; `negation_of`: média 3,5, p95 15). Essa observação fundamenta diretamente a escolha da janela máxima (`max_gap`= 200) na geração de pares candidatos.

Tabela 2 – Estatísticas da distância (em caracteres) entre entidades relacionadas, por tipo.

Tipo	N	média	p25	p50	p75	p90	p95
<code>associated_with</code>	9772	11.9	1	4	10	25	43
<code>negation_of</code>	1581	3.5	1	1	1	11	15

Fonte: elaborado pelo autor a partir do SemClinBr.

Figura 3 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200).




Fonte: elaborado pelo autor (`scripts/eda/eda_relations.py`).

4.4.3 Relações por documento e categorias de entidade

A Figura 4 apresenta a distribuição do número de relações por documento, e a Figura 5, as categorias de entidade mais frequentes (após decomposição das anotações multirrotulo separadas por “[”). As categorias predominantes — Abbreviation (12502), Finding (6806), Therapeutic or Preventive Procedure (4737) e Sign or Symptom (4579) — refletem a natureza telegráfica e abreviada do texto clínico. Vale notar a presença expressiva da categoria Negation (2616), coerente com a importância do fenômeno de negação tratado neste trabalho.

Figura 4 – Distribuição do número de relações por documento.



Fonte: elaborado pelo autor (scripts/eda/eda_relations.py).


4.5 PARTICIONAMENTO DOS DADOS

A partição segue a razão 80/10/10 em **nível de documento**, e não de relação. Essa escolha previne o vazamento de dados: relações de um mesmo documento compartilham vocabulário e trechos repetidos, e dividi-las entre partições diferentes inflaria artificialmente as métricas de teste. A partição é **estratificada** pela presença das classes `negation_of` e `associated_with` em cada documento, por meio do algoritmo de estratificação multirrótulo de Sechidis, Tsoumakas e Vlahavas (2011), de modo a garantir representação estável da classe minoritária em todas as partições.

A partição é gerada com semente fixa (42) e **congelada**: os arquivos de treino, desenvolvimento e teste e seus respectivos *hashes* SHA-256 são versionados (Apêndice A), evitando que comparações entre execuções sejam confundidas com variação de amostragem. O resultado são 800 documentos de treino, 100 de desenvolvimento e 100 de teste.

A Tabela 3 apresenta a distribuição real das relações entre as partições. O ponto crítico é que a classe minoritária `negation_of`, que representa apenas 13,93% das relações do corpus, mantém proporção estável em todas as partições (entre 13,74% e 14,96%). Essa preservação confirma o funcionamento do algoritmo de estratificação multirrótulo

Figura 5 – Categorias atômicas de entidade mais frequentes (top 25).



Fonte: elaborado pelo autor (scripts/eda/eda_relations.py).

de Sechidis, Tsoumakas e Vlahavas (2011): um particionamento puramente aleatório poderia, por azar de amostragem, sub-representar `negation_of` no conjunto de teste, comprometendo a estabilidade da estimativa de F1 dessa classe. A estratificação por presença simultânea das duas classes evita esse risco e torna as métricas por classe comparáveis entre as partições.

A Figura 6 apresenta a mesma informação em barras agrupadas (escala logarítmica), evidenciando visualmente que a proporção da classe minoritária `negation_of` permanece estável (13,7%, 15,0% e 14,4% em treino, desenvolvimento e teste). A constância dessa proporção, apesar de a partição ser feita por documento e não por relação, é exatamente o efeito da estratificação multirrótulo: a classe rara não é sub-representada em nenhuma partição, condição necessária para que a estimativa de F1 de `negation_of`


Tabela 3 – Distribuição real das relações por partição (*splits* congelados, semente 42).

Partição	Documentos	associated_with	negation_of	Total relações	% negation_of
Treino	800	7854	1251	9105	13,74
Dev	100	955	168	1123	14,96
Teste	100	963	162	1125	14,40
Total	1000	9772	1581	11353	13,93

Fonte: elaborado pelo autor (data/splits/split_stats.json).

of no teste seja confiável.

Figura 6 – Distribuição das relações por partição (escala logarítmica), com o percentual de *negation_of* anotado.



Fonte: elaborado pelo autor (scripts/eda/plot_split_distribution.py).

4.6 GERAÇÃO DE PARES CANDIDATOS

O SemClinBr anota apenas relações *positivas*: cada relação registrada indica que existe vínculo entre duas entidades, mas a ausência de anotação não é, por si, um exemplo negativo explícito. Avaliar um classificador no espaço {*negation_of*, *associated_with*, *no_relation*} exige, portanto, **construir** os exemplos negativos. Treinar ou avaliar apenas com os pares anotados produziria um classificador binário sobre as duas classes positivas, incapaz de operar em um cenário real, em que o sistema recebe *todos* os pares de entidades de um documento e precisa decidir, para cada um, se há relação e de que tipo. A classe *no_relation* é o que torna a tarefa aplicável fora do

conjunto anotado.

A geração é feita pela função `iter_candidate_pairs` (`scripts/utils/candidates.py`), compartilhada por todos os modelos e *baselines* — condição necessária para que os resultados fiquem na mesma régua estatística. Para cada documento, ela percorre todos os **pares ordenados** de entidades (e_1, e_2) , $e_1 \neq e_2$ — a ordem importa porque a direção é relevante para a negação —, descarta os pares cuja distância em caracteres exceda a janela máxima (`max_gap=200`) e os pares entre documentos distintos, e atribui o rótulo: se o par ordenado (e_1, e_2) coincide com uma relação anotada, recebe o tipo *gold*; caso contrário, recebe `no_relation`. A emissão segue ordenação determinística por `(start, end, id)`, de modo que o conjunto de candidatos — e o *hash* das predições — seja estável entre execuções.

Em resumo, o gerador respeita cinco propriedades, todas verificadas por testes automatizados (`tests/test_determinism.py`): **(i) ordenação determinística** — os pares são emitidos sempre na mesma ordem por `(start, end, id)` de e_1 e depois de e_2 , requisito do qual depende o *hash* SHA-256 das predições; **(ii) sem cruzamento entre documentos** — nunca se forma um par com entidades de documentos distintos, pois o documento é a unidade de processamento; **(iii) janela respeitada** — apenas pares cuja distância em caracteres (entre o fim de e_1 e o início de e_2) seja $\leq \text{max_gap} = 200$ são gerados; **(iv) sem autopares** — nunca se forma o par (e, e) de uma entidade consigo mesma ($e_1 \neq e_2$); e **(v) conferência com o *gold*** — um par presente nas relações anotadas do documento recebe o tipo real (`associated_with` ou `negation_of`), e um par ausente recebe `no_relation` (amostragem negativa).

A Quadro 1 ilustra o processo em um trecho real do corpus. A relação anotada é $16 \rightarrow 52 = \text{negation_of}$ (a entidade “NÃO ESPECIFICADA” nega “OSTEOMIELOITE”). Das seis combinações ordenadas possíveis entre as três entidades próximas, apenas o par $(16, 52)$ casa com o *gold*; os outros cinco tornam-se `no_relation`. A representação de entrada para os modelos contextuais marca o par com delimitadores tipados, por exemplo `[E1] DISO : OSTEOMIELOITE [/E1] [E2] Negation : NÃO ESPECIFICADA [/E2]`.

A consequência direta é um conjunto de teste fortemente desbalanceado: dos

Quadro 1 – Exemplo de geração de candidatos para um trecho do SemClinBr.

Entidades: 16=“OSTEOMIELITE” (*Disease or Syndrome*), 52=“NÃO ESPECIFICADA” (*Negation*), 17=“INTUBADO” (*Finding*). Relação *gold*: 16 → 52 = *negation_of*.

Par ordenado	Rótulo gerado
16 → 52	<i>negation_of</i> (casa com o <i>gold</i>)
16 → 17	<i>no_relation</i>
52 → 16	<i>no_relation</i> (direção inversa do <i>gold</i>)
52 → 17	<i>no_relation</i>
17 → 16	<i>no_relation</i>
17 → 52	<i>no_relation</i>

Fonte: elaborado pelo autor (`scripts/utils/candidates.py`).

107 568 pares candidatos, 106 451 (98,92%) pertencem à classe *no_relation*, enquanto *associated_with* e *negation_of* somam, respectivamente, 957 e 160 instâncias. Esse desbalanceamento de $\approx 99:1$ é intrínseco à tarefa — decorre da combinatória de pares de entidades — e não um artefato evitável. Ele é tratado, nos modelos aprendidos, pela reescala de perda `class_weight="balanced"` (Seção 5), e, na avaliação, pela escolha do macro-F1 como métrica principal, que dá peso igual às três classes.

4.6.1 Teto de recall imposto pela janela

A janela `max_gap= 200` é justificada pela EDA (o p95 da distância das relações verdadeiras fica abaixo de 200 caracteres em ambos os tipos), mas impõe um **teto de recall**: toda relação *gold* cujo par fique a mais de 200 caracteres jamais é gerada como candidato e, portanto, é irrecuperável por qualquer classificador, independentemente da arquitetura. A Tabela 4 quantifica esse limite por partição: as perdas por janela são pequenas — 48 de 9 105 relações no treino (0,53%), 13 de 1 123 na validação (1,16%) e 4 de 1 125 no teste (0,36%), todas da classe *associated_with* —, o que fixa o teto de recall em 99,47%, 98,84% e 99,64%, respectivamente. Trata-se de uma **decisão de projeto documentada** (um compromisso entre recall e explosão de candidatos negativos), e não de um defeito. A tabela também reporta, em coluna separada, as *duplicatas de anotação* colapsadas — relações *gold* repetidas com o mesmo par ordenado e tipo, que o gerador representa uma única vez —; estas **não** reduzem o teto, pois a relação permanece recuperável, sendo apenas redundância de anotação do corpus.

Tabela 4 – Teto de recall imposto pela janela `max_gap= 200` por partição.

Partição	Total ouro	Perdidas (gap > 200)	Duplicatas colapsadas	Teto recall (%)
Treino	9105	48 (0.53%)	34	99.47
Validação	1123	13 (1.16%)	4	98.84
Teste	1125	4 (0.36%)	4	99.64
Total	11353	65 (0.57%)	42	99.43

Fonte: elaborado pelo autor (`scripts/eda/recall_ceiling.py`).

4.7 PROTOCOLO DE AVALIAÇÃO

A métrica principal é o **macro-F1**, que atribui peso igual às três classes e, portanto, penaliza modelos que ignoram as classes minoritárias — comportamento desejável dado o desbalanceamento. Classes ausentes nas predições recebem F1 nulo em vez de serem descartadas, conforme recomendado por Forman e Scholz (2010). Reporta-se também o F1 por classe.

A incerteza das estimativas é quantificada por **intervalos de confiança de 95%** obtidos por bootstrap (1000 reamostragens, método percentil 2,5/97,5, semente 42 registrada para reprodutibilidade exata). Adota-se o *bootstrap por instância* como procedimento principal, por ser a convenção em PLN biomédico, o que mantém os resultados comparáveis aos da literatura. Como, porém, os pares candidatos de um mesmo documento não são independentes (compartilham texto e vocabulário), reporta-se também, como **análise de robustez**, um *bootstrap por documento (cluster bootstrap)*: a cada reamostragem sorteiam-se documentos com reposição e tomam-se todos os candidatos dos documentos sorteados, produzindo um intervalo de confiança mais conservador (mais largo). A comparação entre as duas variantes é apresentada no Capítulo 6.

Comparações pareadas entre modelos empregam o **teste de McNemar** (DIETTERICH, 1998), calculado sobre os acertos por instância no mesmo conjunto de teste. Para cada par de modelos, monta-se a tabela de discordâncias (b = o primeiro acerta e o segundo erra; c = o inverso) e aplica-se o **teste binomial exato** quando $b + c < 25$ ou o χ^2 **com correção de continuidade** caso contrário. Como três pares são testados simultaneamente ($B0 \times B1$, $B0 \times B2$ e $B1 \times B2$), os valores- p são ajustados pela correção

de **Holm-Bonferroni**, controlando a taxa de erro familiar.

4.8 AMBIENTE EXPERIMENTAL E RASTREABILIDADE

Todo o pipeline é executado em contêineres Docker, com **versões de bibliotecas fixadas**, de modo que o ambiente faça parte do registro experimental. A pinagem é uma exigência de reprodutibilidade: a mudança de uma versão menor de `scikit-learn` ou `scipy` pode deslocar os intervalos de confiança reportados. As etapas de *parsing*, análise exploratória, particionamento e *baselines* executam em CPU (sem GPU), dentro do contêiner; o ajuste fino do modelo baseado em transformer é executado em ambiente com GPU (Google Colab, Tesla T4). O Quadro 2 consolida o ambiente.

A rastreabilidade é reforçada por três mecanismos: a semente padrão 42 é registrada em cada arquivo de resultado; os *splits* congelados são verificados por *hashes* SHA-256 (Apêndice A); e cada métrica reportada tem um arquivo JSON correspondente em `experiments/results/`. A análise de variância prevista para o modelo principal emprega múltiplas sementes de treino.

Quadro 2 – Ambiente experimental e versões pinadas (*baselines*).

Item	Valor
Sistema host	Windows 11 + Docker
Imagem base	nvidia/cuda:12.1.1-cudnn8-devel-ubuntu22.04
Python	3.10
scikit-learn	1.5.0
scipy	1.13.1
numpy	1.26.4
pandas	2.2.2
matplotlib	3.9.0
lxml	5.2.2
iterative-stratification	0.1.7
statsmodels	0.14.2
PyTorch	2.3.1 (CUDA 12.1)
transformers	4.41.2
Hardware (<i>baselines</i>)	CPU (sem GPU)
Semente aleatória	42 (fixada em todos os experimentos)
<i>Bootstrap</i>	1000 reamostragens, percentil 2,5/97,5, semente 42 (por instância e por documento)
Comparação pareada	McNemar (exato/ χ^2) + Holm-Bonferroni
Datas de execução	B0/B1: 27/05/2026; B2: 02/06/2026; McNemar/matrizes/ <i>bootstrap</i> doc.: 07/06/2026

Fonte: elaborado pelo autor (docker/Dockerfile e *timestamps* de experiments/results/).

5 PROPOSTA DO PROTÓTIPO

Este capítulo descreve a proposta de solução para a extração de relações clínicas, organizada em uma cadeia de modelos de complexidade crescente. A estratégia permite isolar o ganho atribuível a cada incremento e fornecer pontos de comparação estatisticamente justos, todos avaliados sobre os mesmos pares candidatos e a mesma partição congelada.

5.1 VISÃO GERAL E PAPEL DOS *BASELINES*

Antes de investir no ajuste fino de um modelo contextual — que demanda GPU e tempo de treino consideráveis — estabelecem-se *baselines*: modelos simples que definem **patamares mínimos de desempenho**. Sua função é tripla. Primeiro, calibram a expectativa: um modelo proposto só é interessante se superar, com folga, soluções triviais. Segundo, validam o *pipeline*: se um modelo linear com características rasas já produz resultados coerentes, o gerador de pares candidatos, o espaço de rótulos e o protocolo de avaliação estão corretos (*sanity check*). Terceiro, evidenciam o **teto das abordagens léxicas**: ao mostrar onde regras e modelos lineares falham, justificam empiricamente a adoção de modelos contextuais. A cadeia proposta contempla três *baselines* (B0, B1 e B2) e o modelo principal (BioBERTpt). A progressão de complexidade — piso trivial, heurística léxica e modelo linear aprendido — não é apenas conceitual: ela se traduz em ganhos de macro-F1 monotônicos ($0,006 < 0,236 < 0,637$) e estatisticamente significativos sob o teste pareado de McNemar (Capítulo 6), o que valida a escolha de cada degrau como referência para o modelo proposto.

5.2 B0 — CLASSE MAJORITÁRIA

O *baseline* B0 prediz sempre a classe mais frequente entre as relações positivas anotadas, `associated_with`. É deliberadamente trivial e não aprende nada do texto, mas é **necessário**: estabelece o piso absoluto contra o qual qualquer outro modelo deve ser comparado. Seu resultado é, em si, informativo — sob o forte desbalanceamento da tarefa, um modelo que ignora as classes minoritárias obtém macro-F1 próximo de zero, o que revela imediatamente a dificuldade do problema e demonstra por que a acurácia simples seria uma métrica enganosa (um classificador que respondesse sempre `no_`

`relation` acertaria $\approx 99\%$ dos candidatos sem ter qualquer utilidade prática).

5.3 B1 — REGRAS LÉXICAS (NEGEX-PT)

O *baseline* B1 codifica conhecimento linguístico explícito, inspirado no algoritmo **NegEx** (CHAPMAN *et al.*, 2001), referência em detecção de negação clínica. A adaptação ao português clínico baseia-se no fato de a negação ser fortemente lexicalizada no domínio. As regras são aplicadas em cascata:

1. **R1 (negação)**: se houver um marcador de negação na janela entre as duas entidades ou no contexto de 30 caracteres à esquerda da segunda entidade, classifica o par como `negation_of`. A busca é *case-insensitive* e usa fronteira de palavra, evitando falsos positivos como “sem” dentro de “semelhante”.
2. **R2 (associação)**: caso contrário, se a distância entre as entidades for inferior a 50 caracteres, classifica como `associated_with`.
3. **R3 (padrão)**: do contrário, `no_relation`.

A lista real de marcadores utilizada (extraída de `scripts/baselines/baseline_rules.py`) é: “não”, “sem”, “nega”, “ausência”, “ausente”, “afebril” e “anictérico”. Os dois últimos são adjetivos que embutem negação léxico-morfologicamente (“afebril” = sem febre; “anictérico” = sem icterícia) e que aparecem anotados no SemClinBr como entidades de negação. O léxico completo e os limiares constam do Apêndice B e do Apêndice C.

5.4 B2 — REGRESSÃO LOGÍSTICA COM CARACTERÍSTICAS

O *baseline* B2 é o primeiro modelo **aprendido** da cadeia: uma regressão logística (FORMAN; SCHOLZ, 2010) que estima pesos a partir do conjunto de treino e prediz no de teste. Combina três famílias de características:

- **TF-IDF do texto entre as entidades** (n-gramas de 1 a 2 palavras, *lowercase*, `min_df=2`, vocabulário de até 50000 termos): captura conectivos e marcadores

de negação sem fixá-los como regra.

- **TF-IDF de uma janela de contexto à esquerda** da segunda entidade (30 caracteres): cobre a negação que precede o alvo, como na regra R1, porém de forma aprendida.
- **características estruturais** (via *one-hot*): tipos das duas entidades e sua combinação ordenada, direção textual, distância em caracteres (bruta em escala logarítmica e discretizada em faixas) e presença de marcador de negação como atributo — não como regra rígida.

Uma decisão central é o uso de `class_weight="balanced"`: a perda é reescalada de forma inversamente proporcional à frequência de cada classe. Sem esse ajuste, o otimizador minimizaria o erro simplesmente prevendo `no_relation` para quase tudo, dado que essa classe domina $\approx 99\%$ dos candidatos. A reescala força o modelo a “pagar” caro por erros nas classes raras, sem descartar dados nem introduzir não-determinismo de subamostragem. A mesma estratégia é prescrita ao modelo principal, para que a comparação seja justa.

5.5 MODELO PROPOSTO — BIOBERTPT

O modelo principal é o ajuste fino do **BioBERTpt** (SCHNEIDER *et al.*, 2020), modelo de linguagem contextual de domínio clínico para o português. A formulação prevista insere *marcadores de entidade tipados* que delimitam e_1 e e_2 no texto, e usa a concatenação dos estados ocultos dos marcadores de início como representação do par, preservando a direção da relação. O desbalanceamento é tratado pela mesma *cross-entropy* ponderada do B2, e a seleção de modelo usa o conjunto de desenvolvimento (macro-F1), com o teste reservado apenas à avaliação final. Espera-se que a modelagem contextual capture dependências de longo alcance e construções de negação que escapam às abordagens léxicas e lineares. Os hiperparâmetros planejados constam do Apêndice C. Os detalhes finais de arquitetura e hiperparâmetros serão confirmados após a execução do treino.

5.6 REPRESENTAÇÃO DE ENTRADA: MARCADORES TIPADOS E GRUPOS SEMÂNTICOS UMLS

O modelo contextual não recebe o par de entidades de forma abstrata: recebe o *texto* do documento com o par delimitado por **marcadores de entidade tipados**. A literatura de extração de relações com modelos baseados em BERT mostra que inserir marcadores que delimitam e_1 e e_2 no texto — e anotar o *tipo* de cada entidade junto ao marcador — é mais eficaz do que concatenar representações de *span* isoladas. Adota-se o esquema

[E1] <grupo> : superfície e_1 [/E1] ... [E2] <grupo> : superfície e_2 [/E2]

em que os quatro marcadores [E1] [/E1] [E2] [/E2] são registrados como *tokens* especiais no *tokenizer* (cada um vira um único *token*, com *embedding* dedicado), a ordem (e_1, e_2) vem do gerador de candidatos e preserva a direção da relação, e <grupo> é o **grupo semântico** da entidade — não o seu tipo bruto. A decisão de usar o grupo, e não o tipo bruto, é descrita a seguir.

5.6.1 O problema dos tipos crus

O SemClinBr anota cada entidade com tipos semânticos da UMLS, frequentemente em **rótulos múltiplos** separados por “|” (por exemplo, Medical Device|Finding|Abbreviation). As estatísticas a seguir são medidas **apenas no conjunto de treino**, pois é a partição sobre a qual o modelo é ajustado e decisões de projeto não devem ser informadas por dev/test (mesma higiene aplicada ao *fit* do TF-IDF do B2). No treino ocorrem apenas 86 tipos *atômicos* distintos; a combinação multirrótulo desses tipos, porém, faz o número de *strings* de tipo distintas explodir para 838 (das quais 764 contêm “|”). O corpus completo mantém o mesmo padrão (89 atômicos para 922 combinações), de modo que o fenômeno não é particular do treino. Usar a *string* de tipo diretamente como atributo seria contraproducente: cada uma das 838 combinações viraria um símbolo praticamente único e mal povoado, e o modelo teria pouquíssimos exemplos de cada um, prejudicando a generalização.

5.6.2 Agregação nos 15 grupos semânticos UMLS

A solução é **agregar** os tipos atômicos nos 15 *Grupos Semânticos* da UMLS propostos por McCray, Burgun e Bodenreider (2001) — por exemplo, ANAT (anatomia), CHEM (químicos e fármacos), DISO (transtornos), PROC (procedimentos) —, acrescidos de duas camadas próprias do SemClinBr que não são tipos UMLS mas carregam sinal relevante para a tarefa: Abbreviation e Negation (esta última diretamente associada à classe negation_of). A agregação é implementada pela função `normalize_type` (`scripts/training/markers.py`) por uma tabela estática que mapeia cada tipo atômico ao seu grupo. Um rótulo múltiplo é tratado separando-o por “|”, mapeando cada segmento ao seu grupo e reunindo os grupos *únicos* em ordem alfabética; tipos fora do mapa caem em `Other` (cobertura total no treino: nenhum tipo cai em `Other`). Como resultado, os 86 tipos atômicos do treino reduzem-se a apenas 17 códigos de grupo (15 grupos UMLS + 2 camadas), e as 838 *strings* de tipo, a 100 *tags* normalizadas — ainda combinações multirrótulo, mas agora construídas a partir de um vocabulário pequeno e estável de códigos. A função é **idempotente** — `normalize_type(normalize_type(x)) = normalize_type(x)` —, propriedade verificada nos testes automatizados.

5.6.3 Por que isso ajuda o modelo

A diferença é direta na representação. Com tipos crus, uma entidade `[E1: Abbreviation|Therapeutic or Preventive Procedure|Medical Device]` produz um símbolo de tipo praticamente único; com a agregação, a mesma entidade vira `[E1: Abbreviation,DEVI,PROC]`, um rótulo composto por um vocabulário **pequeno e controlado** de grupos. Como o estado oculto do marcador de início (h_{E_1} , e analogamente h_{E_2}) é a representação que alimenta o cabeçote de classificação, fazê-lo carregar o *grupo semântico* — estável e bem povoado — em vez do tipo bruto esparsos torna a representação do par mais generalizável e menos suscetível a *overfitting* em combinações raras.

5.6.4 Exemplos

O Quadro 3 ilustra a normalização em casos reais e construídos. O caso `Disease or Syndrome` → `DISO` corresponde à entidade “OSTEOMIELO” usada no exemplo de

geração de candidatos (Quadro 1); o caso multirrótulo `Abbreviation|Laboratory or Test Result` → `Abbreviation,PHEN` mostra o colapso de uma combinação em dois grupos únicos ordenados.

Quadro 3 – Exemplos de normalização de tipos pela função `normalize_type`.

Tipo bruto (SemClinBr)	Grupo(s) normalizado(s)
Disease or Syndrome	DISO
Organic Chemical Pharmacologic Substance	CHEM
Abbreviation Laboratory or Test Result	Abbreviation,PHEN
Negation Sign or Symptom	DISO,Negation
Tipo inexistente	Other

Fonte: elaborado pelo autor (`scripts/training/markers.py`).

Aplicado ao trecho do Quadro 1, o par *gold* 16 → 52 resulta na entrada marcada [E1] DISO : OSTEOMIELEITE [/E1] [E2] Negation : NÃO ESPECIFICADA [/E2], em que os grupos DISO e Negation substituem os tipos brutos correspondentes.

6 EXPERIMENTOS E RESULTADOS

Este capítulo reporta os experimentos conduzidos até o momento e seus resultados. Todos os modelos foram avaliados sobre o mesmo conjunto de teste, composto por 107 568 pares candidatos gerados conforme o Capítulo 4, e as métricas seguem o protocolo ali descrito (macro-F1 e F1 por classe, com intervalos de confiança de 95% por bootstrap).

6.1 CONFIGURAÇÃO EXPERIMENTAL

A semente aleatória foi fixada em 42 em todas as etapas, e os intervalos de confiança foram estimados com 1 000 reamostragens pelo método percentil (Quadro 2). O conjunto de teste apresenta forte desbalanceamento: a classe `no_relation` concentra a quase totalidade dos pares (106 451 instâncias), enquanto `associated_with` e `negation_of` somam, respectivamente, 957 e 160 instâncias. Esse cenário torna o macro-F1 a métrica mais informativa, por penalizar modelos que negligenciam as classes minoritárias.

6.2 RESULTADOS

A Tabela 5 consolida os resultados dos três *baselines* executados (B0, B1 e B2), com a linha do modelo principal (BioBERTpt) reservada para a etapa seguinte. Os melhores valores por coluna (entre os modelos já executados) estão em negrito.

Tabela 5 – Resultados dos modelos no conjunto de teste (macro-F1 e F1 por classe, com IC95%).

Modelo	n_{test}	Macro-F1 [IC95%]	F1 _{negation_of}	F1 _{associated_with}	F1 _{no_relation}
Classe majoritária (B0)	107568	0,006 [0,006; 0,006]	0,000 [0,000; 0,000]	0,018 [0,017; 0,019]	0,000 [0,000; 0,000]
Regras léxicas (B1)	107568	0,236 [0,234; 0,238]	0,010 [0,008; 0,011]	0,058 [0,054; 0,061]	0,641 [0,638; 0,644]
Regressão logística (B2)	107568	0,637 [0,620; 0,653]	0,658 [0,608; 0,704]	0,272 [0,255; 0,288]	0,982 [0,981; 0,982]
BioBERTpt (principal)	—	— (a executar no Colab, Semana 5–6)			

Fonte: elaborado pelo autor a partir de `experiments/results/*.json`.

6.3 ANÁLISE DOS BASELINES

O modelo de classe majoritária (B0) obtém macro-F1 de apenas 0,006: por prever sempre `associated_with`, zera o F1 das demais classes e confirma que a métrica expõe corretamente a inutilidade de soluções triviais sob desbalanceamento extremo.

O *baseline* de regras léxicas (B1) eleva o macro-F1 para 0,236 [IC95%: 0,234; 0,238]. A decomposição por classe revela que esse desempenho é sustentado sobretudo pela classe `no_relation` ($F1 = 0,641$), enquanto as classes positivas permanecem baixas (`associated_with` = 0,058 e `negation_of` = 0,010). As regras alcançam alta cobertura das classes positivas, mas com precisão muito baixa: o léxico de negação dispara em excesso e o limiar de distância classifica muitos pares como `associated_with`, gerando grande número de falsos positivos.

A regressão logística (B2) supera os dois *baselines* anteriores em todas as métricas, atingindo macro-F1 de 0,637 [IC95%: 0,620; 0,653] — quase o triplo do B1, com intervalos de confiança que não se sobrepõem, o que indica que o ganho é estatisticamente robusto. O salto mais expressivo ocorre na classe `negation_of`, que vai de 0,010 (B1) para 0,658 (B2): o modelo aprende a combinar o sinal lexical de negação com o contexto e os tipos das entidades, em vez de aplicar a regra rígida do B1. A classe `associated_with` permanece a mais difícil ($F1 = 0,272$), com alta cobertura (*recall* 0,73) mas baixa precisão (0,17), refletindo a dificuldade de distinguir associação genuína de mera proximidade textual. Esse desempenho do B2 — obtido com características rasas — valida o *pipeline* de pares e estabelece um patamar exigente para o modelo contextual.


6.4 MATRIZES DE CONFUSÃO

As Figuras 7, 8 e 9 apresentam as matrizes de confusão dos três *baselines*, **normalizadas por linha**, de modo que cada célula indica a fração das instâncias de uma classe verdadeira atribuída a cada classe predita — os valores da diagonal correspondem, assim, ao *recall* por classe. Essa visão complementa o F1 por classe ao revelar *para onde* vão os erros de cada modelo.

A matriz do B0 (Figura 7) é degenerada: por predizer sempre `associated_with`, concentra toda a massa na coluna correspondente, e as linhas de `negation_of` e `no_relation` têm *recall* nulo. O B1 (Figura 8) alcança alto *recall* nas classes positivas (0,856 em `negation_of` e 0,903 em `associated_with`), mas dispersa a classe majoritária `no_relation`, da qual 26,4% é erroneamente enviada para `negation_of` e outros

26,4% para `associated_with` — a super-predição de negação que explica sua baixa precisão. O B2 (Figura 9) tem diagonal forte (0,956, 0,725 e 0,966); o erro dominante remanescente é a confusão entre `associated_with` e `no_relation` (27,3% das instâncias de `associated_with` vão para `no_relation`), coerente com a baixa precisão dessa classe e com a dificuldade de distinguir associação genuína de mera proximidade textual.

Figura 7 – Matriz de confusão do *baseline* de classe majoritária (B0), normalizada por linha.




Fonte: elaborado pelo autor (`scripts/evaluation/confusion_matrices.py`).

6.5 SIGNIFICÂNCIA ESTATÍSTICA (TESTE DE MCNEMAR)

A não-sobreposição dos intervalos de confiança sugere que as diferenças entre os *baselines* são reais, mas é uma evidência indireta. A Tabela 6 traz o teste pareado de McNemar para os três pares, calculado sobre os acertos por instância no mesmo conjunto de teste, com os valores- p ajustados por Holm-Bonferroni (Capítulo 4).


Os três pares **rejeitam** a hipótese nula de igualdade ($p_{\text{Holm}} < 0,001$), confirmando que a progressão $B0 < B1 < B2$ é estatisticamente significativa também sob teste pareado, e não apenas pela leitura dos intervalos de confiança. As contagens discordantes são fortemente assimétricas em favor do modelo mais complexo: no par $B1 \times B2$, por exemplo, há $c = 52771$ instâncias em que apenas o B2 acerta contra $b = 262$ em que

Figura 8 – Matriz de confusão do *baseline* de regras léxicas (B1), normalizada por linha.



Fonte: elaborado pelo autor (`scripts/evaluation/confusion_matrices.py`).

Figura 9 – Matriz de confusão do *baseline* de regressão logística (B2), normalizada por linha.



Fonte: elaborado pelo autor (`scripts/evaluation/confusion_matrices.py`).

Tabela 6 – Teste de McNemar pareado entre os *baselines* ($\alpha = 0,05$, correção de Holm-Bonferroni).

Par	b	c	Estat.	p	p_{Holm}	Decisão
B0×B1	93	50326	50045.69	<0.001	<0.001	rejeita H_0 ($\alpha = 0.05$)
B0×B2	263	103005	102216.69	<0.001	<0.001	rejeita H_0 ($\alpha = 0.05$)
B1×B2	262	52771	51988.20	<0.001	<0.001	rejeita H_0 ($\alpha = 0.05$)

b/c : instâncias em que apenas o primeiro/segundo modelo do par acerta. Fonte: elaborado pelo autor (`scripts/evaluation/mcnemar_baselines.py`).

apenas o B1 acerta. Em todos os casos $b + c \geq 25$, de modo que se aplicou a estatística χ^2 com correção de continuidade, em vez do teste binomial exato.

6.6 ROBUSTEZ DO INTERVALO DE CONFIANÇA (*BOOTSTRAP* POR DOCUMENTO)

Por fim, a Tabela 7 compara o IC95% do macro-F1 estimado por *bootstrap* por instância (procedimento principal) com o estimado por *bootstrap* por documento (análise de robustez, que respeita a não-independência dos pares de um mesmo documento). Como esperado, o intervalo por documento é ligeiramente mais largo — para o B2, [0,617; 0,659] contra [0,620; 0,653] por instância —, mas a conclusão central se mantém: o intervalo do B2 continua **muito acima** do intervalo do B1 ([0,225; 0,246] por documento), de modo que a separação $B1 < B2$ sobrevive ao critério mais conservador. A estimativa pontual é idêntica nas duas variantes (o *bootstrap* afeta apenas a largura do intervalo, não o ponto).

Tabela 7 – Macro-F1 e IC95% por *bootstrap* por instância vs. por documento ($n_{\text{doc}} = 99$).

Modelo	Macro-F1	IC95% (instância)	IC95% (documento)
Classe majoritária (B0)	0,006	[0,006; 0,006]	[0,005; 0,007]
Regras léxicas (B1)	0,236	[0,234; 0,238]	[0,225; 0,246]
Regressão logística (B2)	0,637	[0,620; 0,653]	[0,617; 0,659]

Fonte: elaborado pelo autor (`experiments/results/bootstrap_by_document.json`).

6.7 MODELO PROPOSTO BASEADO EM *TRANSFORMER*

O ajuste fino do BioBERTpt (pucpr/biobertpt-all), com marcadores de entidade tipados, *cross-entropy* ponderada e seleção de modelo por macro-F1 no conjunto de desenvolvimento, constitui a etapa imediatamente seguinte do trabalho, a ser executada em ambiente com GPU (Google Colab, *Tesla* T4) nas seeds de treino 42, 123 e 1337, conforme o planejamento em docs/plano_notebook_biobertpt.md. Sua avaliação seguirá exatamente o mesmo protocolo dos *baselines* — macro-F1 e F1 por classe com IC95%, média $\pm$ desvio entre as seeds e comparação com o B2 pelo teste de McNemar (DIETTERICH, 1998) —, de modo que os resultados se incorporem diretamente à Tabela 5. A análise comparativa correspondente será apresentada após a conclusão dessa etapa.

7 DISCUSSÃO

Este capítulo interpreta os resultados obtidos até o momento, discute limitações do trabalho e aponta ameaças à validade dos achados.

7.1 ANÁLISE DOS RESULTADOS

Os resultados dos *baselines* confirmam as hipóteses iniciais. Primeiro, o problema é de fato dominado pelo desbalanceamento: a classe majoritária obtém macro-F1 próximo de zero, e o ganho do *baseline* de regras concentra-se na classe *no_relation*. Segundo, a negação clínica em português é lexicalizada o bastante para que regras simples tenham alta cobertura, mas a baixa precisão observada mostra que a mera presença de um marcador de negação na janela não basta: o escopo da negação e a direção da relação precisam ser modelados.

A regressão logística (B2) corrobora essa interpretação. Ao aprender a ponderar o sinal lexical de negação com o contexto e os tipos das entidades, eleva o macro-F1 de 0,236 (B1) para 0,637, com ganho expressivo justamente na classe *negation_of* (de 0,010 para 0,658) e intervalos de confiança que não se sobrepõem aos do B1. Isso mostra que um modelo aprendido, ainda que linear e com características rasas, supera substancialmente as regras — evidência empírica que justifica a transição para modelos contextuais, dos quais se espera ganho adicional sobretudo na classe *associated_with*, que permanece a mais difícil ($F1 = 0,272$ no B2, limitada pela baixa precisão).

7.2 LIMITAÇÕES

As regras léxicas do *baseline* B1 não tratam negação de escopo amplo (“o paciente não apresenta nenhum dos seguintes: A, B, C”), negação estendida por conjunção, nem a direção da relação, atribuindo o mesmo rótulo aos pares (a, b) e (b, a) . Além disso, a tarefa pressupõe entidades já anotadas (*gold*): a avaliação não considera o erro propagado de uma etapa de NER automática, de modo que os resultados refletem a extração de relações isoladamente. Por fim, o modelo principal baseado em transformer (BioBERTpt) ainda não foi executado, de modo que a comparação final entre o *baseline* aprendido (B2) e o modelo contextual depende dessa etapa.

7.3 AMEAÇAS À VALIDADE

Quanto à validade interna, o congelamento das partições com semente fixa e verificação por *hashes* SHA-256, somado ao particionamento em nível de documento, mitiga o vazamento de dados — a principal causa de resultados não reproduzíveis em PLN biomédico. Restam, contudo, decisões de projeto que podem influenciar os números, como a janela máxima de 200 caracteres na geração de pares candidatos, que descarta relações verdadeiras mais distantes e impõe um **teto de recall** ao sistema. Esse limite, porém, foi quantificado (Seção 4.6.1, Tabela 4) e é pequeno: no conjunto de teste, apenas 4 de 1 125 relações *gold* (0,36%, todas *associated_with*) caem fora da janela, fixando o teto de recall em 99,64%. Trata-se, assim, de uma limitação documentada e de magnitude conhecida, e não de uma fonte de incerteza não medida — o que reforça a defensabilidade do protocolo.

Uma segunda decisão de avaliação diz respeito à largura dos intervalos de confiança. O *bootstrap* por instância, adotado como procedimento principal, trata os 107 568 candidatos como independentes, o que não é estritamente verdadeiro, pois pares de um mesmo documento compartilham texto e vocabulário. Para endereçar essa ameaça, reportou-se também o *bootstrap* por documento (Seção 6.6), mais conservador; a separação entre B1 e B2 sobrevive ao intervalo mais largo, de modo que a conclusão não depende da hipótese de independência.

Quanto à validade externa, o SemClinBr, apesar de multi-institucional e multiespecialidade, representa um conjunto específico de instituições e estilos de redação; a generalização para outros contextos clínicos deve ser feita com cautela. As inconsistências de anotação conhecidas do corpus, ainda que tratadas e registradas pelo parser, também impõem um limite superior ao desempenho alcançável.

8 CONCLUSÃO

Este trabalho abordou a extração de relações entre entidades clínicas em português sobre o corpus SemClinBr, no espaço de rótulos *negation_of*, *associated_with* e *no_relation*. A ênfase recaiu sobre a construção de uma cadeia experimental reprodutível, do texto bruto às métricas com intervalos de confiança.

8.1 CONTRIBUIÇÕES

As principais contribuições até o momento são: (i) um parser fiel e determinístico do formato XML do SemClinBr, com verificação de sanidade e correção controlada de *offsets*; (ii) uma caracterização do corpus que evidencia o desbalanceamento das relações e a proximidade entre entidades relacionadas; (iii) um protocolo de particionamento em nível de documento, estratificado e congelado, que previne vazamento de dados; (iv) um gerador determinístico de pares candidatos compartilhado por todos os modelos; e (v) *baselines* de referência avaliados sob um protocolo estatístico uniforme (macro-F1 com IC95% por bootstrap), estabelecendo patamares comparáveis para o mesmo corpus.

Os resultados dos *baselines* mostraram que soluções triviais são inviáveis sob o desbalanceamento da tarefa (B0 com macro-F1 0,006) e que abordagens léxicas, embora alcancem alta cobertura da negação, têm precisão limitada (B1 com macro-F1 0,236). A regressão logística (B2) superou ambos com folga (macro-F1 0,637), confirmando o ganho de modelos aprendidos e motivando o uso de modelos contextuais para reduzir a lacuna remanescente, sobretudo na classe *associated_with*.

8.2 TRABALHOS FUTUROS

Como continuidade, prevê-se: executar o ajuste fino do BioBERTpt (SCHNEIDER *et al.*, 2020) como modelo proposto, nas seeds de treino 42, 123 e 1337; realizar a análise de variância entre seeds e a comparação estatística com o *baseline* B2 pelo teste de McNemar (DIETTERICH, 1998); investigar o tratamento do escopo da negação e da direção das relações; e avaliar o impacto da janela máxima na geração de pares candidatos. A médio prazo, a integração com uma etapa de NER automática permitiria

medir o desempenho da extração de relações em um cenário fim a fim.

REFERÊNCIAS

- CHAPMAN, W. W. *et al.* A simple algorithm for identifying negated findings and diseases in discharge summaries. **Journal of Biomedical Informatics**, v. 34, n. 5, p. 301–310, 2001.
- CONNEAU, A. *et al.* Unsupervised cross-lingual representation learning at scale. In: **Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2020. p. 8440–8451.
- DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. In: **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)**. [S.l.]: Association for Computational Linguistics, 2019. p. 4171–4186.
- DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895–1923, 1998.
- FORMAN, G.; SCHOLZ, M. Apples-to-apples in cross-validation studies: Pitfalls in classifier performance measurement. **ACM SIGKDD Explorations Newsletter**, v. 12, n. 1, p. 49–57, 2010.
- MCCRAY, A. T.; BURGUN, A.; BODENREIDER, O. Aggregating UMLS semantic types for reducing conceptual complexity. **Studies in Health Technology and Informatics**, v. 84, p. 216–220, 2001. Disponível em: <<https://pmc.ncbi.nlm.nih.gov/articles/PMC4300099/>>.
- OLIVEIRA, L. E. S. e. *et al.* SemClinBr – a multi-institutional and multi-specialty semantically annotated corpus for Portuguese clinical NLP tasks. **Journal of Biomedical Semantics**, v. 13, n. 1, p. 13, 2022.
- SCHNEIDER, E. T. R. *et al.* BioBERTpt – a Portuguese neural language model for clinical named entity recognition. In: **Proceedings of the 3rd Clinical Natural Language Processing Workshop**. [S.l.]: Association for Computational Linguistics, 2020. p. 65–72.
- SECHIDIS, K.; TSOUMAKAS, G.; VLAHAVAS, I. On the stratification of multi-label data. In: **Machine Learning and Knowledge Discovery in Databases (ECML PKDD 2011)**. [S.l.]: Springer, 2011. (Lecture Notes in Computer Science, v. 6913), p. 145–158.
- VASWANI, A. *et al.* Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

Apêndices

APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS

Para garantir a reprodutibilidade dos experimentos, as partições de treino, desenvolvimento e teste foram congeladas após sua geração (semente 42, estratificação multirrótulo em nível de documento). O Quadro 4 apresenta os *hashes* SHA-256 dos arquivos, gerados por `scripts/splitting/make_splits.py` e versionados em `data/splits/SHA256SUMS.txt`. Qualquer alteração nos arquivos altera o *hash*, permitindo a verificação independente da integridade das partições.

Quadro 4 – SHA-256 das partições congeladas do SemClinBr.

Arquivo	SHA-256
<code>train.jsonl</code>	<code>3d7a2a0730f8931a405449a4062f529700a632815767e25336c422e101933775</code>
<code>dev.jsonl</code>	<code>20ce38a9807d7488002fc7de865096ca6357c64021e44f6dd78f92c3346d7837</code>
<code>test.jsonl</code>	<code>597af7fb88c2bedeec304ea7c92afbe3f6851e913a10d643f2ce34511e77daed</code>

Fonte: elaborado pelo autor (`data/splits/SHA256SUMS.txt`).

As partições contêm, respectivamente, 800, 100 e 100 documentos. A distribuição das relações por partição — 9 105 no treino, 1 123 no desenvolvimento e 1 125 no teste — preserva a proporção entre as classes `associated_with` e `negation_of` observada no corpus completo.

APÊNDICE B – LÉXICO DE NEGAÇÃO DO *BASELINE* DE REGRAS

O *baseline* de regras léxicas (B1), descrito na Seção 5, identifica a relação *negation_of* a partir de um conjunto de marcadores de negação adaptados ao português clínico, na linha do algoritmo NegEx (CHAPMAN *et al.*, 2001). A detecção é *case-insensitive* e emprega fronteira de palavra, de modo a evitar correspondências espúrias (por exemplo, “sem” dentro de “semelhante”). Os marcadores são buscados na janela entre as duas entidades e em uma janela de contexto de 30 caracteres à esquerda da segunda entidade.

Quadro 5 – Marcadores de negação utilizados no *baseline* B1.

Marcador	Observação
não	negação verbal/adverbial geral
sem	preposição de ausência
nega	forma verbal (“paciente nega. . .”)
ausência	substantivo de ausência
ausente	adjetivo de ausência
afebril	adjetivo com negação léxico-morfológica (sem febre)
anictérico	adjetivo com negação léxico-morfológica (sem icterícia)

Fonte: elaborado pelo autor (`scripts/baselines/baseline_rules.py`).

O Quadro 5 lista os marcadores. Os termos “afebril” e “anictérico” são adjetivos que embutem negação morfollogicamente e que, no SemClinBr, aparecem anotados como entidades de negação, o que justifica seu uso como gatilho. As limitações dessa lista — ausência de tratamento de negação de escopo amplo e de negação estendida por conjunção — são discutidas no Capítulo 7.

APÊNDICE C – HIPERPARÂMETROS

Este apêndice consolida os hiperparâmetros das etapas já executadas do pipeline. O Quadro 6 reúne os parâmetros comuns à geração de pares candidatos e à avaliação; o Quadro 7 detalha o *baseline* de regras (B1) e o Quadro 8 o *baseline* de regressão logística (B2).

Quadro 6 – Parâmetros gerais do pipeline.

Parâmetro	Valor
Semente aleatória (padrão)	42
Sementes p/ análise de variância	42, 123, 7, 2024, 31337
Janela máxima de pares (<code>max_gap</code>)	200 caracteres
Partição treino/dev/teste	80/10/10 (nível de documento)
<i>Bootstrap</i> (reamostragens)	1000 (método percentil, IC95%)

Fonte: elaborado pelo autor.

Quadro 7 – Hiperparâmetros do *baseline* de regras (B1).

Parâmetro	Valor
Contexto à esquerda (R1)	30 caracteres
Limiar de distância (R2)	50 caracteres
Rótulo padrão (R3)	<code>no_relation</code>

Fonte: elaborado pelo autor (`scripts/baselines/baseline_rules.py`).

O Quadro 9 reúne os hiperparâmetros *planejados* para o modelo principal (BioBERTpt), conforme `docs/plano_notebook_biobertpt.md`. Os valores definitivos serão confirmados após a execução do treino.

Os valores efetivamente utilizados substituirão os planejados após a execução do treino do modelo.

Quadro 8 – Hiperparâmetros do *baseline* de regressão logística (B2).

Parâmetro	Valor
<i>TF-IDF</i> (entre/esquerda)	n-gramas 1–2, <i>lowercase</i> , <code>min_df=2</code>
Vocabulário máximo (entre)	50000
Faixas de distância (<i>buckets</i>)	0, 10, 25, 50, 100, 200
Reescala de classes	<code>class_weight="balanced"</code>
Regularização (C)	1.0
<i>Solver</i>	<code>lbfgs</code> (padrão do <i>scikit-learn</i>)
Máximo de iterações	1000
Características totais	94257
Candidatos (treino)	831902

Fonte: elaborado pelo autor (`scripts/baselines/baseline_lr.py` e `experiments/results/baseline_lr.json`).

Quadro 9 – Hiperparâmetros planejados do modelo proposto (BioBERTpt).

Parâmetro	Valor planejado
<i>Encoder</i>	pucpr/biobertpt-all
Representação de entrada	marcadores de entidade tipados ($[E1]/[E2]$)
<i>Pooling</i>	concatenação dos estados de início (h_{E1}, h_{E2})
Cabeçote	1 camada linear ($1536 \rightarrow 3$), <i>dropout</i> 0,1
Perda	<i>cross-entropy</i> ponderada (<i>class_weight</i> ="balanced")
<i>max_length</i>	256 <i>tokens</i>
Taxa de aprendizado	2e-5 (AdamW)
<i>Batch</i> (treino)	16 + acúmulo 2 (efetivo 32)
<i>Batch</i> (avaliação)	64
Épocas (máx.)	5 (com <i>early stopping</i> , paciência 2)
<i>warmup_ratio</i>	0,1
<i>weight_decay</i>	0,01
<i>fp16</i>	sim
Seleção de modelo	macro-F1 no <i>dev</i>
Sementes de treino	42, 123, 1337
<i>Bootstrap</i>	1000, semente 42 (fixa)
Hardware	Google Colab, <i>Tesla</i> T4

Fonte: elaborado pelo autor (docs/plano_notebook_biobertpt.md).