

INSTITUTO FEDERAL
Espírito Santo
Campus Cachoeiro de Itapemirim

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

TRABALHO DE GRADUAÇÃO

ANGELO ANTONIO LIMA SILVEIRA FILHO

RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS SOBRE O CORPUS SEMCLINBR

Cachoeiro de itapemirim

2026

ANGELO ANTONIO LIMA SILVEIRA FILHO

RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS SOBRE O CORPUS SEMCLINBR

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Cristiano da Silveira Colombo

Coorientadora: Profa. Dra. Beltrana de Tal

Cachoeiro de itapemirim

2026

(Biblioteca do Campus Cachoeiro de Itapemirim)

X999y

RECLin-PT: extração de relações em notas clínicas em português sobre o corpus SemClinBr/ Angelo Antonio Lima Silveira Filho. – 2026.

67 f: il; 30 cm.

Orientador: Cristiano da Silveira Colombo

Trabalho de Graduação – Instituto Federal do Espírito Santo, Bacharelado em Sistemas de Informação, 2026.

1. Processamento de linguagem natural. 2. Extração de relações. 3. Informática em saúde. 4. Aprendizado de máquina. 5. Língua portuguesa. I. Colombo, Cristiano da Silveira. II. Título. III. Instituto Federal do Espírito Santo.

CDD 000.00

Elaborada por XXXXXXXXXXXXXXXXXXXXX – CRB-X/ES - XXX

ANGELO ANTONIO LIMA SILVEIRA FILHO

RECLIN-PT: EXTRAÇÃO DE RELAÇÕES EM NOTAS CLÍNICAS EM PORTUGUÊS SOBRE O CORPUS SEMCLINBR

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Aprovado em 01 de Agosto de 2026

COMISSÃO EXAMINADORA

Prof. Dr. Cristiano da Silveira Colombo
Instituto Federal do Espírito Santo
Orientador

Profa. Dra. Beltrana de Tal
Instituto Federal do Espírito Santo
Coorientadora

Profa. Dra. Fulana de Tal
Instituto Federal do Espírito Santo
Examinadora

Prof. Dr. Cicrano de Tal
Instituto Federal do Espírito Santo
Examinador

À minha mãe, meu alicerce de força e superação, que esteve ao meu lado mesmo nos dias em que eu já não tinha vontade de continuar. Que jamais me desamparou diante das dificuldades e, com amor, coragem e fé, tornou-se o meu maior exemplo de vida. Tudo o que sou carrega um pouco da sua força. Aos meus amigos de jornada, que foram âncora e apoio durante todo o processo.

“Citação a ser escolhida.”

(Autor, ano)

RESUMO

O registro eletrônico em saúde concentra grande parte da informação clínica em texto livre, no qual a relação entre conceitos, em especial a negação de achados, é determinante para a correta interpretação. Este trabalho desenvolve o RECLin-PT, um modelo de extração de relações em notas clínicas em português sobre o corpus SemClinBr, com ênfase na relação `negation_of`, no espaço de rótulos `negation_of`, `associated_with` e `no_relation`. A definição de sua configuração é orientada por experimentos controlados, que investigam como a escolha do *encoder* pré-treinado e da estratégia de modelagem influencia o desempenho, com todas as alternativas avaliadas sobre os mesmos dados e pares candidatos e sob um protocolo pré-registrado que fixa os critérios de seleção no conjunto de desenvolvimento (DEV) e reserva o conjunto de teste para uma avaliação única, posterior ao congelamento da configuração. Os resultados apresentados são preliminares, todos no DEV, com semente 42. Na estratégia baseline, o BERTimbau-base, de domínio geral, e o BioBERTpt-all, clínico, alcançam F1 de `negation_of` de 0,800 e 0,802, sem diferença detectável pelo *bootstrap* pareado, com o BERTimbau-base usando cerca de 61% dos parâmetros. Com o BioBERTpt-all, o Two-Stage, que detecta a existência de relação antes de decidir o tipo, obtém o maior F1 de `negation_of` (0,831), com precisão de 0,798, e é usado como referência preliminar. Sua vantagem, porém, não se distingue da Pair-Aware (0,829), que tem o maior macro-F1 (0,741) e é a única estratégia cuja diferença para o baseline (0,802) tem intervalo de confiança acima de zero. A configuração final do RECLin-PT ainda não foi selecionada: dependem dela a comparação entre *encoders* nas demais estratégias e a avaliação no teste, e a resposta sobre a influência do *encoder* é provisória e limitada à estratégia baseline.

Palavras-chave: Extração de relações. Processamento de linguagem natural clínico. Língua portuguesa. SemClinBr. Aprendizado de máquina.

ABSTRACT

Electronic health records store much clinical information as free text, in which the relationship between concepts, particularly the negation of findings, is decisive for correct interpretation. This work develops RECLin-PT, a relation extraction model for Portuguese clinical notes on the SemClinBr corpus, with emphasis on the `negation_of` relation, in the label space `negation_of`, `associated_with` and `no_relation`. The definition of its configuration is informed by controlled experiments that investigate how the choice of pre-trained encoder and of modelling strategy influences performance, with all alternatives evaluated on the same data and candidate pairs and under a pre-registered protocol that fixes selection criteria on the development set (DEV) and reserves the test set for a single evaluation after the configuration is frozen. The results reported here are preliminary, all on DEV, with seed 42. In the baseline strategy, the general-domain BERTimbau-base and the clinical BioBERTpt-all reach `negation_of` F1 of 0.800 and 0.802, with no difference detected by the paired bootstrap, the former using about 61% of the parameters. With BioBERTpt-all, the Two-Stage architecture, which detects whether a relation exists before deciding its type, obtains the highest `negation_of` F1 (0.831), with precision of 0.798, and is used as the preliminary reference. Its advantage, however, cannot be distinguished from Pair-Aware (0.829), which has the highest macro-F1 (0.741) and is the only strategy whose difference from the baseline (0.802) has a confidence interval above zero. The final RECLin-PT configuration has not yet been selected: it depends on the encoder comparison in the other strategies and on the test-set evaluation, and the answer regarding the influence of the encoder is provisional and limited to the baseline strategy.

Keywords: Relation extraction. Clinical natural language processing. Portuguese language. SemClinBr. Machine learning.

LISTA DE FIGURAS

Figura 1 – Exemplo real de anotação de um documento do SemClinBr (documento 9091, trecho): entidades anotadas, com seus identificadores, e relações entre elas. 27
Figura 2 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200), com a janela `max_gap` assinalada. 32
Figura 3 – Ciclo de desenvolvimento do RECLin-PT e estado atual de cada etapa. 44
Figura 4 – Matrizes de confusão no DEV (normalizadas por linha, contagens entre parênteses): baseline, Pair-Aware e Two-Stage, BioBERTpt-all, seed 42. 48
Figura 5 – Two-Stage no DEV: F1 de `negation_of` e macro-F1 do *pipeline* completo em função do limiar τ. 49

LISTA DE TABELAS

Tabela 1 – Distância em caracteres entre as entidades de cada relação anotada (corpus completo). 32

Tabela 2 – Partições congeladas: documentos, entidades, relações anotadas e pares candidatos ($\texttt{max_gap}=25$). 33

Tabela 3 – Relações anotadas que se tornam pares candidatos com $\texttt{max_gap}=25$ (teto de *recall*), por partição. 35

Tabela 4 – Sensibilidade ao `max_gap` (treino e desenvolvimento): pares candidatos, cobertura das relações e pares `no_relation` por relação coberta. * valor adotado. 35

Tabela 5 – Comparação de *encoders* na estratégia baseline, no DEV (seed 42, mesma configuração; só o *checkpoint* muda): F1 por classe, P e R de `negation_of`, macro-F1 e MCC. 46

Tabela 6 – Resultados no conjunto de desenvolvimento (DEV) dos sistemas do protocolo, BioBERTpt-all, seed 42: precisão (P), *recall* (R) e F1 de `negation_of`, macro-F1 e MCC. Melhor valor por coluna em negrito. 47

Tabela 7 – Precisão, *recall* e F1 de `associated_with` e `no_relation` no DEV, sistemas do protocolo (BioBERTpt-all, seed 42). 47

Tabela 8 – Comparações pareadas **descritivas** no DEV: diferença no F1 de `negation_of`, IC95% e valor-p do *bootstrap* pareado (10.000 reamostras, semente 42) e McNemar exato sobre os acertos globais (b/c: só A acerta / só B acerta). 50

Tabela 9 – Busca de τ do Two-Stage no DEV (pipeline completo, fluxo real). * valor congelado. 64

Tabela 10 – Evolução por época no DEV das execuções de três rótulos. $*$ marca a época selecionada (maior macro-F1 no DEV). 65

Tabela 11 – Two-Stage, estágio 1 (relação $\times$ `no_relation`) no DEV completo: perdas, AP, precisão e *recall* de `relacao`, *recall* nos pares `negation_of` e duração. $*$ época selecionada (maior AP). 66

Tabela 12 – Two-Stage, estágio 2 (negation_of × associated_with) nos 913 pares do DEV com relação anotada: perdas, precisão, *recall* e F1 de negation_of e duração. ∗ época selecionada (maior F1 de negation_of). 66
Tabela 13 – Resultado exploratório no DEV (fora do protocolo pré-registrado): Pair-Aware MLP ao lado da Pair-Aware do protocolo, BioBERTpt-all, seed 42. 67

LISTA DE QUADROS

Quadro 1 – Hiperparâmetros e configuração do *fine-tuning*, comuns às estratégias treinadas. 26
Quadro 2 – Ambientes de execução e versões das principais bibliotecas. . . . 28
Quadro 3 – Exemplo de geração de candidatos para um trecho do SemClinBr. 34
Quadro 4 – Entrada efetivamente construída para o par *gold* do Quadro 3. . . 40
Quadro 5 – SHA-256 das partições congeladas e do manifesto. 62
Quadro 6 – Léxico de pistas congelado (D4): `min_freq`$= 10$, 8 formas, `lexico_sha1` `8af0716633e9`. 63

LISTA DE ABREVIATURAS

ABNT	Associação Brasileira de Normas Técnicas
AP	*Average Precision* (Precisão Média)
BERT	*Bidirectional Encoder Representations from Transformers*
CRLF	*Carriage Return + Line Feed*
DEV	Conjunto de desenvolvimento (*development set*)
EDA	*Exploratory Data Analysis* (Análise Exploratória de Dados)
i2b2	*Informatics for Integrating Biology and the Bedside*
IC	Intervalo de Confiança
IFES	Instituto Federal do Espírito Santo
MCC	*Matthews Correlation Coefficient* (Coeficiente de Correlação de Matthews)
n2c2	*National NLP Clinical Challenges*
NER	*Named Entity Recognition* (Reconhecimento de Entidades Nomeadas)
NLP	*Natural Language Processing* (Processamento de Linguagem Natural)
PLN	Processamento de Linguagem Natural
RE	*Relation Extraction* (Extração de Relações)
SemClinBr	*Semantically Annotated Corpus for Portuguese Clinical NLP*
XML	*Extensible Markup Language*

SUMÁRIO

1 INTRODUÇÃO 14
1.1 Problema de pesquisa 14
1.2 Motivação 15
1.3 Objetivos 16
1.3.1 Objetivo geral 16
1.3.2 Objetivos específicos 17
2 REFERENCIAL TEÓRICO 18
2.1 Processamento de linguagem natural clínico 18
2.2 Extração de entidades e de relações 18
2.3 Abordagens baseadas em regras e a negação clínica 19
2.4 Modelos baseados em *transformers* 19
2.5 Representação do par e decomposição da decisão 20
3 TRABALHOS RELACIONADOS 21
3.1 Recursos e desafios em inglês 21
3.2 Recursos para o português e posicionamento deste trabalho 21
4 METODOLOGIA 24
4.1 *Fine-tuning* de *encoders* pré-treinados 24
4.2 O *dataset* SemClinBr 26
4.3 Preparação do ambiente 28
4.4 Métricas utilizadas para avaliar os modelos 29
4.5 Preparação dos dados 31
4.5.1 Reconstrução dos dados e alinhamento dos offsets 31
4.5.2 Caracterização do corpus 31
4.5.3 Particionamento dos dados 32
4.5.4 Geração de pares candidatos 33
4.5.5 Teto de recall imposto pela janela 34
4.6 Protocolo pré-registrado e comparações estatísticas 35
5 PROPOSTA DO RECLIN-PT 38
5.1 Paridade entre os sistemas comparados 38
5.2 Os *encoders* 38
5.3 Representação de entrada: marcadores de posição 39

5.4 Estratégias de modelagem 41
5.4.1 Baseline 41
5.4.2 Baseline calibrado 41
5.4.3 Filtro léxico 41
5.4.4 Pair-Aware 42
5.4.5 Two-Stage 42
6 EXPERIMENTOS E RESULTADOS 44
6.1 Treino e seleção de época 45
6.2 Comparação entre *encoders* 45
6.3 Estratégias do protocolo com o BioBERTpt-all 46
6.4 O Two-Stage em detalhe 48
6.5 Comparações pareadas descritivas 49
6.6 Resultado exploratório 50
7 DISCUSSÃO 51
7.1 A escolha do *encoder* 51
7.2 As estratégias de modelagem 52
7.3 A classe `associated_with` 53
7.4 Limitações 54
7.5 Ameaças à validade 54
8 CONCLUSÃO 56
8.1 Principais resultados 56
8.2 Limitações 57
8.3 Contribuições 57
8.4 Trabalhos futuros 57
REFERÊNCIAS 59
APÊNDICES 61
APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS 62
APÊNDICE B – LÉXICO DE PISTAS DE NEGAÇÃO 63
APÊNDICE C – BUSCA DO LIMIAR DO TWO-STAGE 64
APÊNDICE D – HISTÓRICO DE TREINO POR ÉPOCA 65
APÊNDICE E – RESULTADO EXPLORATÓRIO DA PAIR-AWARE MLP 67

1 INTRODUÇÃO

O registro eletrônico em saúde concentra grande parte da informação clínica sob a forma de texto livre. Notas de evolução, sumários de alta e laudos são redigidos em linguagem natural, com abreviações idiossincráticas, ausência frequente de pontuação padronizada e construções negativas características do discurso médico. Essa riqueza textual, embora valiosa para pesquisa e apoio à decisão, permanece majoritariamente inacessível a consultas estruturadas, o que motiva o desenvolvimento de técnicas de Processamento de Linguagem Natural (PLN) capazes de transformar texto clínico em conhecimento estruturado.

No contexto da língua portuguesa, o avanço dessas técnicas foi historicamente limitado pela escassez de recursos anotados. A disponibilização do corpus **SemClinBr** (OLIVEIRA *et al.*, 2022), primeiro corpus clínico anotado semanticamente para o português, com mil documentos provenientes de múltiplas instituições e especialidades, criou condições para investigar tarefas antes restritas ao inglês, entre elas a extração de relações entre entidades clínicas.

1.1 PROBLEMA DE PESQUISA

A extração de entidades nomeadas identifica menções a conceitos clínicos (sintomas, doenças, achados, procedimentos), mas isoladamente não captura como esses conceitos se articulam no enunciado. Saber que um documento menciona “febre” não é suficiente. É preciso distinguir se a febre está *associada* ao quadro do paciente ou se está sendo *negada* (“paciente afebril”). Esse vínculo é o objeto da extração de relações (Relation Extraction, RE).

Os sistemas atuais de extração de relações partem de um *encoder*[1] pré-treinado, ajustado à tarefa a partir de um *checkpoint*[2] público. Para o português, contudo, a extração de relações clínicas é pouco representada na literatura, que se concentra na classificação de textos e no reconhecimento de entidades (SHIMAOKA *et al.*, 2026).

[1] *Encoder* é a metade codificadora da arquitetura Transformer, que recebe a sequência de entrada e devolve uma representação vetorial contextual de cada *token*, sem gerar texto novo. É o tipo de modelo do BERT e de suas variantes.

[2] *Checkpoint* é o arquivo com os pesos de um modelo já pré-treinado, distribuído publicamente e usado como ponto de partida do ajuste fino.

O problema abordado neste trabalho é, assim, o desenvolvimento de um modelo de extração de relações em notas clínicas em português, com ênfase na identificação de relações de negação: o RECLin-PT, desenvolvido sobre o SemClinBr. Esse desenvolvimento envolve decisões para as quais a literatura não oferece resposta pronta: qual *encoder* usar, entre os de domínio geral e os adaptados ao domínio clínico, escolha com consequências de custo e de desempenho, e qual estratégia de modelagem define como as saídas desse *encoder* produzem os rótulos de relação. Daí a pergunta de pesquisa:

> *Como desenvolver o RECLin-PT para a extração de relações clínicas em português no corpus SemClinBr, com ênfase na identificação de relações de negação, e de que modo a escolha do encoder pré-treinado e da estratégia de modelagem influencia seu desempenho?*

A primeira parte da pergunta corresponde à finalidade do trabalho, o desenvolvimento do modelo; a segunda, às decisões que esse desenvolvimento exige, investigadas experimentalmente para subsidiar a definição de sua configuração. Para isso, os componentes do modelo são avaliados em duas dimensões, sob um protocolo pré-registrado e sobre os mesmos dados e pares candidatos: os *encoders*, comparados sob configuração idêntica, e as estratégias de modelagem, comparadas com o mesmo *encoder*. O desafio é agravado por dois fatores inerentes ao corpus: o forte desbalanceamento entre as classes de relação e o fato de o SemClinBr anotar apenas relações positivas, o que exige a geração controlada de exemplos negativos.

1.2 MOTIVAÇÃO

A negação clínica é um fenômeno linguístico de alto impacto, uma vez que tratar um achado negado como presente pode inverter completamente a interpretação de um prontuário, o que justifica um modelo dedicado a essa relação. No desenvolvimento do RECLin-PT, a primeira decisão é o *encoder*. Em português, a negação é fortemente lexicalizada (“não”, “sem”, “nega”, “ausência de”), e há a expectativa difundida de que modelos pré-treinados sobre texto do próprio domínio clínico capturem melhor essas construções do que modelos de domínio geral. Esse ganho, contudo, não é automático.

Em inglês, Lin *et al.* (2020) reportam que, na detecção de negação clínica, o BERT sem as extensões de adaptação de domínio avaliadas obteve, em média, o melhor desempenho. Para o português, não localizamos avaliação controlada que isole o efeito do pré-treinamento de domínio na extração de relações clínicas. A comparação direta entre *encoders* clínicos e de domínio geral sobre o SemClinBr foi conduzida para o reconhecimento de entidades (ALMEIDA *et al.*, 2026), e não para a etapa de relações (Capítulo 3).

A escolha do *encoder* também não é independente da estratégia de modelagem. Um classificador direto de três classes, uma cabeça que lê explicitamente o par de entidades e uma arquitetura em dois estágios, que primeiro detecta a existência de relação e depois decide seu tipo, distribuem o problema de formas diferentes, e o efeito do pré-treinamento pode variar com essa distribuição. Comparar estratégias e *encoders* de forma justa exige que todos passem pelos mesmos dados, pelos mesmos pares candidatos e pelo mesmo protocolo de seleção e de avaliação. Por isso, o desenvolvimento do RECLin-PT apoia-se em uma cadeia experimental reprodutível, que também responde a críticas recorrentes à literatura de PLN biomédico, como o compartilhamento restrito de modelos e o detalhamento insuficiente do ajuste fino[3] (FRAILE NAVARRO *et al.*, 2023; SHIMAOKA *et al.*, 2026).

1.3 OBJETIVOS

1.3.1 Objetivo geral

Desenvolver o RECLin-PT, um modelo de extração de relações clínicas em português aplicado ao corpus SemClinBr, com ênfase na identificação de relações de negação (`negation_of`), investigando alternativas de *encoder* pré-treinado e de estratégia de modelagem para subsidiar a definição de sua configuração.

[3] Ajuste fino (fine-tuning) é o retreinamento de um modelo pré-treinado sobre os dados de uma tarefa específica, partindo dos pesos já aprendidos em vez de uma inicialização aleatória (DEVLIN *et al.*, 2019).

1.3.2 Objetivos específicos

- Reconstruir os dados do SemClinBr a partir dos XML originais, com o texto alinhado aos offsets de anotação, e congelar partições em nível de documento, estratificadas e verificáveis por *hashes*.
- Caracterizar o corpus, quantificando a distribuição das relações e a distância entre entidades relacionadas, e justificar a janela de geração de pares candidatos.
- Implementar um gerador determinístico de pares candidatos compartilhado por todas as estratégias, garantindo a comparabilidade dos resultados.
- Implementar as estratégias de modelagem candidatas do RECLin-PT: baseline, baseline calibrado, filtro léxico, Pair-Aware e Two-Stage, além de uma variante exploratória da Pair-Aware.
- Comparar, para orientar a escolha do *encoder*, *encoders* para o português sob configuração idêntica, mudando apenas o *checkpoint* de pré-treino: BioBERTpt-all e BERTimbau-base, com o BioBERTpt-clin previsto.
- Comparar, para orientar a escolha da estratégia, as estratégias implementadas com o mesmo *encoder* e sob o mesmo protocolo.
- Avaliar as configurações do RECLin-PT por precisão, *recall* e F1 por classe, macro-F1 e MCC, com comparações pareadas por *bootstrap*[4] e McNemar.
- Indicar a estratégia de referência preliminar do RECLin-PT e registrar o que falta para congelar sua configuração e avaliá-la no conjunto de teste.

[4] O *bootstrap* pareado estima a incerteza de uma diferença de desempenho reamostrando com reposição o mesmo conjunto para os dois modelos, sem supor uma distribuição para a métrica (Seção 4.6).

2 REFERENCIAL TEÓRICO

Este capítulo reúne os fundamentos em que se apoia o desenvolvimento do RECLin-PT: o processamento de linguagem natural aplicado a textos clínicos, a tarefa de extração de relações, a abordagem baseada em regras para a negação clínica, os modelos de linguagem baseados em transformers e as formas de representar o par de entidades e de decompor a decisão.

2.1 PROCESSAMENTO DE LINGUAGEM NATURAL CLÍNICO

O PLN clínico ocupa-se da análise automática de textos produzidos no cuidado em saúde, como notas de evolução, sumários de alta e laudos. Esses textos apresentam características que os distinguem da linguagem geral: vocabulário técnico, abreviações não padronizadas, telegrafismo (omissão de elementos gramaticais) e prevalência de construções negativas e de incerteza. Tais propriedades tornam a transferência direta de ferramentas treinadas em domínio aberto pouco eficaz, motivando recursos e modelos específicos do domínio.

2.2 EXTRAÇÃO DE ENTIDADES E DE RELAÇÕES

A extração de informação em texto clínico costuma ser decomposta em duas tarefas encadeadas. A primeira, reconhecimento de entidades nomeadas (Named Entity Recognition, NER), delimita trechos do texto que mencionam conceitos de interesse e lhes atribui um tipo semântico. A segunda, extração de relações (RE), determina se um par de entidades mantém uma relação e de que tipo. Formalmente, dado um par ordenado de entidades (e_1, e_2) em um documento, a RE pode ser modelada como um problema de classificação que associa ao par um rótulo dentro de um conjunto pré-definido.

Neste trabalho o espaço de rótulos é `negation_of`, `associated_with` e `no_relation`. O rótulo `no_relation` é fundamental. Como a anotação de corpora registra apenas relações positivas, todo par de entidades não anotado deve ser tratado como ausência de relação, o que introduz um forte desbalanceamento de classes.

2.3 ABORDAGENS BASEADAS EM REGRAS E A NEGAÇÃO CLÍNICA

Abordagens baseadas em regras codificam conhecimento linguístico explícito. Em detecção de negação clínica, o algoritmo NegEx (CHAPMAN *et al.*, 2001) tornou-se referência. A partir de um léxico de gatilhos de negação e de janelas de contexto, ele classifica achados como negados ou afirmados. Sua simplicidade e eficácia derivam do fato de a negação clínica ser altamente lexicalizada. Em português, gatilhos como "não", "sem", "nega" e "ausência de", além de adjetivos que embutem negação morfologicamente ("afebril", "anictérico"), sustentam estratégias análogas. A alta lexicalização sugere que o sinal de negação possa estar acessível mesmo a modelos não especializados no domínio clínico, hipótese relevante para a escolha do *encoder* do RECLin-PT e que a comparação entre *encoders* examina.

2.4 MODELOS BASEADOS EM *TRANSFORMERS*

Métodos aprendidos clássicos, que representam as palavras como unidades independentes, não capturam dependências de longo alcance nem contexto, limitação que motivou a transição da área para modelos contextuais. A arquitetura Transformer (VASWANI *et al.*, 2017), baseada em mecanismos de atenção, viabilizou modelos de linguagem pré-treinados que produzem representações contextuais das palavras. O BERT (DEVLIN *et al.*, 2019) popularizou o paradigma de pré-treinamento seguido de ajuste fino (fine-tuning) para tarefas específicas. Para o português, os candidatos naturais à extração de relações clínicas dividem-se entre modelos de domínio geral e modelos adaptados ao domínio clínico. No primeiro grupo está o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020), pré-treinado no corpus brWaC[1] e hoje a referência de domínio geral para a língua; nele também se enquadram modelos multilíngues como o XLM-R (CONNEAU *et al.*, 2020), que trocam especialização por cobertura ampla de idiomas. No segundo grupo está o BioBERTpt (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e textos biomédicos em português brasileiro e distribuído em variantes conforme o corpus de adaptação, entre elas a *clin* (narrativas clínicas) e a *all* (clínico e biomédico). É o contraste entre esses dois grupos que estrutura a escolha

[1] O brWaC (Brazilian Portuguese Web as Corpus) é um corpus de larga escala construído a partir de páginas web em português brasileiro, sem restrição de domínio.

do *encoder* do RECLin-PT e, com ela, a pergunta de pesquisa; o XLM-R permanece como alternativa de base ampla, fora do escopo experimental aqui delimitado.

2.5 REPRESENTAÇÃO DO PAR E DECOMPOSIÇÃO DA DECISÃO

Em extração de relações com modelos do tipo BERT, o par de entidades costuma ser indicado por marcadores inseridos no próprio texto, como `[E1]...[/E1]` e `[E2]...[/E2]`, de modo que a atenção condicione a codificação de toda a sequência ao par sob análise (SOARES *et al.*, 2019). A partir da sequência marcada, a classificação pode usar apenas a representação agregada da sequência (o *token* `[CLS]`) ou ler explicitamente os estados ocultos nas posições dos marcadores de início das entidades, variante que Soares *et al.* (2019) denominam *entity start* e que concentra a decisão no par em vez de no contexto inteiro.

Quando a grande maioria dos pares não mantém relação, como ocorre ao considerar todos os pares próximos de um documento, um único classificador precisa resolver ao mesmo tempo duas perguntas de natureza diferente: *se* há relação e *qual* relação. Uma alternativa é decompor a decisão em estágios encadeados, em que um primeiro classificador binário filtra os pares com relação e um segundo decide o tipo apenas entre eles. Em decomposições desse tipo, a passagem de um estágio ao outro depende de um limiar sobre a probabilidade estimada pelo primeiro: limiares altos favorecem a precisão e sacrificam o *recall* das relações que não chegam ao segundo estágio. Do mesmo modo, num classificador direto, um limiar sobre a probabilidade de uma classe permite deslocar o compromisso entre precisão e *recall* dessa classe sem novo treino. Essas alternativas fundamentam as estratégias de modelagem do RECLin-PT (Seção 5.4). A forma de escolher esses limiares e suas consequências para a avaliação são tratadas no protocolo experimental (Seção 4.6).

3 TRABALHOS RELACIONADOS

Este capítulo situa o desenvolvimento do RECLin-PT em relação a recursos e estudos de extração de informação clínica, com ênfase na língua portuguesa, e identifica o que esses trabalhos oferecem ao modelo e o que deixam em aberto.

3.1 RECURSOS E DESAFIOS EM INGLÊS

A extração de relações clínicas consolidou-se em língua inglesa em torno de campanhas de avaliação como as séries Informatics for Integrating Biology and the Bedside (i2b2) e National NLP Clinical Challenges (n2c2) (UZUNER *et al.*, 2011), que disponibilizaram corpora anotados e tarefas compartilhadas para problemas como relações entre medicamentos, dosagens e efeitos adversos. Esses esforços estabeleceram protocolos de avaliação e evidenciaram a importância de tratar adequadamente o desbalanceamento de classes e o vazamento de dados entre partições, preocupações transpostas para este trabalho, respectivamente, pela geração controlada de pares candidatos (Seção 4.5.4) e pelo particionamento em nível de documento (Seção 4.5.3).

Quanto aos modelos, o BioBERT (LEE *et al.*, 2020) demonstrou os ganhos da adaptação de domínio biomédico em inglês, estabelecendo o precedente que torna a escolha entre *encoders* de domínio e gerais uma decisão a examinar no desenvolvimento do RECLin-PT. Quanto à representação de entrada, a delimitação do par por marcadores de entidade inseridos no próprio texto (SOARES *et al.*, 2019) tornou-se a técnica padrão para extração de relações com modelos baseados em BERT, e é a adotada aqui (Seção 5.3).

3.2 RECURSOS PARA O PORTUGUÊS E POSICIONAMENTO DESTE TRABALHO

O desenvolvimento de PLN clínico em português foi por muito tempo limitado pela ausência de corpora anotados de acesso controlado. O **SemClinBr** (OLIVEIRA *et al.*, 2022) preencheu parte dessa lacuna ao disponibilizar mil documentos clínicos de múltiplas instituições e especialidades, anotados semanticamente e acompanhados de dicionários de abreviações e de pistas de negação. Para este trabalho, sua contribuição central é a anotação de relações, inclusive de negação, entre entidades; como o

corpus anota apenas relações positivas, usá-lo para classificar todos os pares de um documento exige construir os exemplos negativos (Seção 4.5.4). É o corpus sobre o qual o RECLin-PT é desenvolvido.

Os *encoders* disponíveis para o português foram avaliados, até aqui, sobretudo em reconhecimento de entidades. O BioBERTpt (SCHNEIDER *et al.*, 2020) adaptou modelos BERT a narrativas clínicas e textos biomédicos em português brasileiro e relatou ganhos em NER em dois corpora de narrativas clínicas; o BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020), referência de domínio geral, foi avaliado em similaridade textual, inferência textual e reconhecimento de entidades, todas tarefas de domínio geral. Nenhum dos dois trabalhos mede o efeito do pré-treinamento sobre a extração de relações. O estudo mais próximo, de Almeida *et al.* (2026), compara sobre o SemClinBr, com hiperparâmetros comuns sempre que possível, variantes do BioBERTpt, o BERTimbau, modelos BERT recentes e modelos de linguagem de grande porte, também em reconhecimento de entidades; nesse estudo, o melhor desempenho coube a um modelo multilíngue de domínio geral (mmBERT-base), à frente das variantes do BioBERTpt, o que indica que o domínio do pré-treino não é o único fator relevante mesmo em NER. Esses resultados motivam comparar *encoders* antes de fixar o do RECLin-PT, mas não substituem essa comparação: se a vantagem observada em entidades se transfere para relações é a questão que permanece aberta.

A extração de relações clínicas em português é pouco representada na literatura revisada. Uma revisão sistemática de 28 estudos de modelos de linguagem em português voltados à saúde, publicados entre janeiro de 2020 e novembro de 2024, inventaria classificação (16 modelos), reconhecimento de entidades nomeadas (8), modelagem de tópicos, resposta a perguntas, geração de texto e agentes conversacionais, sem registrar extração de relações (SHIMAOKA *et al.*, 2026). O desequilíbrio não é exclusivo do português: uma revisão de 94 estudos de extração de informação em texto clínico registra 63 dedicados a reconhecimento de entidades contra 13 dedicados a extração de relações (FRAILE NAVARRO *et al.*, 2023). O trabalho de extração de relações em texto clínico em português aqui localizado (SILVA *et al.*, 2023) contribui com um corpus próprio de oncologia em português brasileiro e menciona três *encoders* candidatos (BERT multilíngue, BioBERTpt e BERTimbau), mas não reporta comparação entre eles

e resolve a etapa de relações com uma rede BiLSTM, sem teste de significância. O efeito do pré-treinamento de domínio sobre a extração de relações, portanto, não é isolado ali.

Em síntese, os trabalhos revisados oferecem o corpus, os *encoders* e as técnicas de representação do par em que o RECLin-PT se apoia, mas não localizamos estudo que verifique, para o português, se a vantagem do pré-treinamento clínico relatada em NER se transfere para a extração de relações, nem que compare, sobre um mesmo corpus clínico em português, estratégias de modelagem distintas sob protocolo único. O RECLin-PT se posiciona nessa lacuna: é desenvolvido sobre o SemClinBr com foco na negação clínica, e suas estratégias, que vão do classificador direto a uma arquitetura em dois estágios, combinam técnicas já descritas na literatura, como os marcadores de entidade e a decomposição da decisão. Sua contribuição central é o próprio modelo; as comparações de *encoders* e de estratégias, conduzidas sob as mesmas condições e com uma cadeia reprodutível, servem para orientar sua configuração e, ao mesmo tempo, produzem evidência sobre a lacuna descrita, que pode servir de referência para trabalhos futuros sobre o mesmo corpus.

4 METODOLOGIA

Neste capítulo são descritos os métodos empregados no desenvolvimento do RECLin-PT: o ajuste fino de *encoders* pré-treinados para a extração de relações, o *dataset* utilizado, a preparação do ambiente experimental, as métricas de avaliação, a preparação dos dados e o protocolo que rege a seleção e a comparação dos modelos. Os experimentos descritos são o instrumento pelo qual as decisões de modelagem do RECLin-PT, isto é, a escolha do *encoder* e da estratégia, passam a se apoiar em evidência medida, e não em preferência prévia. Todas as etapas foram projetadas sob a premissa de reprodutibilidade: cada artefato é identificado por *hash*, e cada decisão tomada sobre os dados fica registrada antes de ser usada.

4.1 *FINE-TUNING* DE *ENCODERS* PRÉ-TREINADOS

Os modelos deste trabalho partem de *encoders* pré-treinados: redes da família BERT (DEVLIN *et al.*, 2019) que já aprenderam, sobre grandes volumes de texto não anotado, a produzir uma representação vetorial contextual para cada *token*. Esse conhecimento prévio é a razão de usá-los. Em vez de aprender a língua a partir dos poucos exemplos anotados da tarefa, o modelo parte de pesos que já codificam vocabulário, morfologia e relações sintáticas, e o treino só precisa especializá-los. O *encoder* é escolhido pelo seu *checkpoint* de pré-treino; neste trabalho, o BioBERTpt-all, de domínio clínico, e o BERTimbau-base, de domínio geral, com o BioBERTpt-clin previsto (Seção 5.2).

O *fine-tuning* (ajuste fino) adapta esses pesos à extração de relações. Cada exemplo é um par de entidades, apresentado ao modelo como uma janela de texto em torno do par, com as duas entidades delimitadas por marcadores (Seção 5.3). O *encoder* transforma a janela em representações contextuais, e uma cabeça de classificação, uma camada nova acrescentada sobre ele, converte essas representações em uma pontuação para cada rótulo. Durante o treino, as predições são comparadas aos rótulos anotados por uma função de perda de entropia cruzada; o gradiente dessa perda é propagado de volta por toda a rede (retropropagação), e um otimizador atualiza tanto a cabeça quanto os pesos do *encoder*. Como as classes são muito desbalanceadas, a perda de cada exemplo é ponderada pelo inverso da frequência de sua classe no

treino, com peso $n/(K \cdot n_c)$, em que n é o número de exemplos, K o número de classes e n_c o número de exemplos da classe c; sem essa ponderação, o modelo minimizaria o erro prevendo `no_relation` para quase tudo.

O procedimento de treino é o mesmo para todas as estratégias treinadas e segue a configuração do Quadro 1. Os exemplos de treino são apresentados em lotes de 64, embaralhados por um gerador com semente fixa. O otimizador é o AdamW, com taxa de aprendizado de 2×10^{-5} e *weight decay* de $0{,}01$; a taxa cresce linearmente durante os primeiros 10% dos passos (aquecimento) e decresce linearmente até zero, e a norma do gradiente é limitada a 1. O treino percorre um número fixo de épocas, sem parada antecipada. Ao fim de cada época, o modelo é avaliado no conjunto de desenvolvimento (DEV) pelo critério da estratégia, e os pesos da melhor época são restaurados ao final. Essa é a única escolha feita durante o treino, e ela usa apenas o DEV (Seção 4.6). Para que a mesma configuração produza os mesmos números no mesmo ambiente, as sementes de Python, NumPy e PyTorch são fixadas, as operações determinísticas da GPU são exigidas sempre que disponíveis, e o estado completo dos geradores aleatórios é salvo nos *checkpoints*, o que permite retomar um treino interrompido exatamente do ponto em que parou.

O *fine-tuning* é a base comum de todas as estratégias treinadas, que diferem na forma de ler a representação do *encoder* e de organizar a decisão; duas estratégias apenas pós-processam as predições do baseline, sem treino próprio (Capítulo 5).

Três conceitos são distinguidos ao longo do texto. O *encoder* é o modelo de linguagem pré-treinado, fixado pelo seu *checkpoint*. A estratégia é a forma como esse *encoder* é ajustado e como suas saídas são combinadas para produzir os três rótulos. O RECLin-PT é o modelo em desenvolvimento, formado por um *encoder* e uma estratégia e apoiado pela cadeia de dados e pelo protocolo descritos neste capítulo. Sua configuração final será a combinação de *encoder* e estratégia selecionada pelos critérios do protocolo, depois do congelamento das escolhas e da avaliação no conjunto de teste, e ainda não foi definida; o Capítulo 6 indica qual estratégia serve de referência nas análises preliminares.

Quadro 1 – Hiperparâmetros e configuração do *fine-tuning*, comuns às estratégias treinadas.

Item	Valor
Entrada	janela de ± 128 caracteres em torno do par (`ctx_chars`), com marcadores `[E1]`/`[E2]`, sem tipo semântico; até 128 *tokens* (`max_length`)
Pares candidatos	distância máxima de 25 caracteres entre as entidades (`max_gap`)
Lote (*batch*)	64
Otimizador	AdamW; taxa de aprendizado 2×10^{-5}; *weight decay* $0{,}01$
Escalonador	linear, com aquecimento nos primeiros 10% dos passos
Norma máxima do gradiente	1,0
Perda	entropia cruzada ponderada (`class_weight="balanced"`), com pesos calculados no treino de cada estratégia ou estágio
Épocas	3 (estratégias de três rótulos e estágio 1 do Two-Stage); 10 (estágio 2)
Seleção da época	maior macro-F1 no DEV (estratégias de três rótulos); critérios próprios nos estágios do Two-Stage
Semente	42

Fonte: elaborado pelo autor.

4.2 O *DATASET* SEMCLINBR

Os documentos clínicos utilizados neste trabalho foram retirados do **SemClinBr** (OLIVEIRA *et al.*, 2022)[1], primeiro corpus clínico em português do Brasil anotado semanticamente. Ele reúne mil documentos provenientes de múltiplas instituições e especialidades, redigidos por profissionais de saúde no registro do cuidado, e é distribuído mediante solicitação formal, para uso não comercial. Neste trabalho, o SemClinBr é a única fonte de dados: dele saem os exemplos de treino, a escolha de modelos no DEV e o conjunto de teste reservado para a avaliação final.

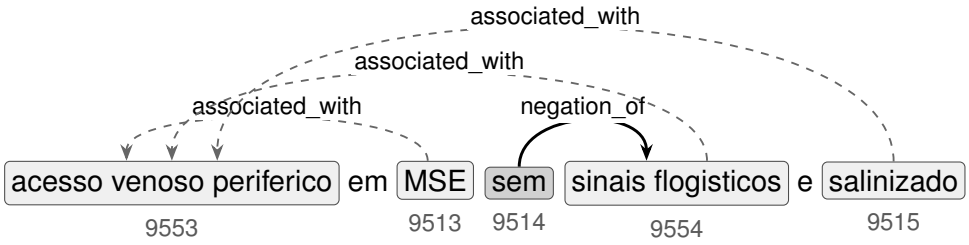
O texto do corpus é típico do prontuário. As frases são curtas e telegráficas, com omissão de verbos e artigos, abreviações frequentes e não padronizadas (como MSE,

[1] Repositório do corpus e formulário de requisição de acesso em github.com/HAILab-PUCPR/SemClinBr.

para membro superior esquerdo), mistura de letras maiúsculas e minúsculas e ausência ocasional de acentos, e construções negativas recorrentes, como “sem sinais flogísticos” ou “nega queixas”. Essas características afastam o texto da linguagem dos corpora usados no pré-treino de domínio geral e motivam a comparação entre *encoders*.

Cada documento traz anotações de entidades, trechos do texto delimitados por posições de caractere (*offsets*) e associados a tipos semânticos da UMLS, além de categorias próprias como `Abbreviation` e `Negation`; uma mesma entidade pode receber vários tipos, separados por “|”. Entre as entidades, são anotadas relações dirigidas, de um primeiro argumento (e_1) para um segundo (e_2), de dois tipos: `associated_with`, que liga conceitos relacionados, como um dispositivo e a região do corpo em que está, e `negation_of`, que liga uma expressão de negação ao conceito negado. A Figura 1 mostra um trecho real de um documento do corpus, com as entidades e as relações anotadas.

Figura 1 – Exemplo real de anotação de um documento do SemClinBr (documento 9091, trecho): entidades anotadas, com seus identificadores, e relações entre elas.



Id	Entidade	Tipo anotado
9553	acesso venoso periferico	*Therapeutic or Preventive Procedure*|*Medical Device*
9513	MSE	*Body Location or Region*|*Abbreviation*
9514	sem	*Negation*
9554	sinais flogisticos	*Sign or Symptom*
9515	salinizado	*Therapeutic or Preventive Procedure*|*Finding*

Fonte: elaborado pelo autor a partir de dados do SemClinBr (OLIVEIRA *et al.*, 2022).

No trecho, a entidade “sem” (tipo `Negation`) é o primeiro argumento de uma relação `negation_of` cujo segundo argumento é “sinais flogisticos”: o registro afirma a *ausência* de sinais inflamatórios no acesso venoso, e um sistema que perdesse essa relação leria o achado como presente. As outras três relações, do tipo `associated_with`, ligam a

localização (“MSE”), o achado negado e o estado (“salinizado”) ao dispositivo descrito.

Três características da anotação afetam diretamente o treino e a avaliação. A primeira é o desbalanceamento: das $11\,458$ relações anotadas no corpus, $9\,852$ são `associated_with` e apenas $1\,606$ ($14{,}02\%$) são `negation_of`. A segunda é que o corpus anota apenas relações positivas. Um par de entidades sem anotação não é, por si, um exemplo explícito de ausência de relação, e por isso os exemplos negativos (`no_relation`) precisam ser construídos a partir dos pares não anotados (Seção 4.5.4), o que agrava ainda mais o desbalanceamento. A terceira é que as relações são dirigidas: o par (e_1, e_2) e o par inverso são exemplos diferentes, e só um deles pode carregar a relação anotada.

4.3 PREPARAÇÃO DO AMBIENTE

Os experimentos foram organizados em um pacote Python próprio, versionado em um repositório Git[2], que reúne a leitura do corpus, as partições, a geração de candidatos, as estratégias, o treino, a avaliação e os relatórios. O Quadro 2 resume os ambientes utilizados e as versões registradas pelo próprio código em cada execução.

Quadro 2 – Ambientes de execução e versões das principais bibliotecas.

Item	Valor
Treino e avaliação no DEV	Google Colab, GPU NVIDIA Tesla T4 (15 GB), CUDA 13.0
Python	3.13 (treino); 3.10 (reconstrução dos dados, no computador do autor)
Bibliotecas	PyTorch 2.11.0, Transformers 5.16.1, Tokenizers 0.23.2, Hugging Face Hub 1.29.0, Safetensors 0.8.0, NumPy 2.1.3, SciPy 1.16.3
Pesos pré-treinados	`pucpr/biobertpt-all` (revisão `36b11cf`) e `neuralmind/bert-base-portuguese-cased` (revisão `94d69c9`), baixados por revisão exata e conferidos por *hash*
Determinismo	`PYTHONHASHSEED=0`, `CUBLAS_WORKSPACE_CONFIG=:4096:8`, sementes fixas e algoritmos determinísticos do PyTorch

Fonte: elaborado pelo autor.

[2] Código e resultados em github.com/angeloalsf/RECLin-PT (branch `resultados-colab`); o corpus SemClinBr não é redistribuído, por ter acesso restrito.

A reconstrução dos dados a partir dos XML do corpus foi executada no computador do autor, porque os arquivos originais não podem ser redistribuídos; o resultado são partições derivadas, identificadas por *hashes* (Seção 4.5). O treino foi executado no Google Colab, com um *notebook* por estratégia, que obtém o código do repositório, confere o ambiente e a GPU e chama os *scripts* de treino. Os pesos pré-treinados são baixados uma única vez, na revisão exata registrada no protocolo, e carregados sem acesso à rede, com os *hashes* de todos os arquivos conferidos antes de cada carga. As versões das bibliotecas são fixadas por um arquivo de restrições, com o qual o pacote é instalado.

Cada execução grava uma pasta própria com a configuração completa (`config.json`), o histórico de treino por época e as sessões (`treino.json`), as métricas (`metricas.json`), as predições do DEV (`predicoes_dev.json`) e o registro do ambiente e da proveniência (`experimento.json`). Os *checkpoints*, que permitem retomar um treino interrompido, são espelhados no Google Drive durante o treino. Para reproduzir os experimentos, basta instalar o pacote com as versões fixadas, conferir as partições contra o manifesto e executar os *scripts* de treino com a mesma configuração e semente; as tabelas e figuras deste trabalho são regeneradas a partir das pastas das execuções por *scripts*, sem transcrição manual de números.

4.4 MÉTRICAS UTILIZADAS PARA AVALIAR OS MODELOS

Nesta seção são apresentadas as métricas utilizadas para avaliar o desempenho dos modelos de extração de relações. As métricas centrais são a precisão (*precision*), o *recall* e o F1-*Score*, calculadas para cada uma das três classes da tarefa, `negation_of`, `associated_with` e `no_relation`. Para uma classe, um par conta como verdadeiro positivo (TP) quando é dessa classe e o modelo o atribui a ela; como falso positivo (FP) quando o modelo o atribui à classe sem que ele pertença a ela; e como falso negativo (FN) quando pertence à classe e o modelo o atribui a outra.

A precisão (*precision*) é calculada pela razão entre o número de verdadeiros positivos e o total de previsões positivas realizadas pelo modelo. Essa métrica indica a proporção de previsões positivas que foram classificadas corretamente, conforme apresentado na

Fórmula 1.

Fórmula 1 – Precisão

$$\text{Precisão} = \frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{Falsos positivos}}$$

O *recall*, também conhecido como sensibilidade ou taxa de detecção, corresponde à proporção de exemplos positivos reais que foram identificados corretamente pelo modelo. Dessa forma, a métrica permite avaliar a capacidade do modelo de recuperar os exemplos pertencentes à classe analisada, conforme apresentado na Fórmula 2.

Fórmula 2 – *Recall*

$$\textit{Recall} = \frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{Falsos negativos}}$$

Por fim, o F1-*Score* combina as medidas de precisão e *recall* por meio da média harmônica entre elas. Essa métrica permite avaliar conjuntamente a capacidade do modelo de realizar previsões positivas corretas e identificar os exemplos positivos reais. Seu cálculo é apresentado na Fórmula 3.

Fórmula 3 – F1-*Score*

$$\text{F1-}\textit{Score} = 2 \cdot \frac{\text{Precisão} \cdot \textit{Recall}}{\text{Precisão} + \textit{Recall}}$$

No código do projeto, as três métricas são calculadas a partir da matriz de confusão, com o F1 na forma equivalente $2TP/(2TP+FP+FN)$, e valem zero quando o denominador é nulo, por exemplo quando o modelo nunca prediz a classe. O F1 de `negation_of` é a métrica primária do trabalho. Para resumir o desempenho nas três classes, usa-se o macro-F1, média simples dos três F1, que dá o mesmo peso a cada classe e, por isso, penaliza modelos que negligenciam as minoritárias (FORMAN; SCHOLZ, 2010); ele é também o critério de seleção de época das estratégias de três rótulos. São reportados ainda a acurácia, pouco informativa isoladamente porque `no_relation`

domina os pares, e o coeficiente de correlação de Matthews (MCC) multiclasse, que considera a matriz de confusão inteira e é robusto ao desbalanceamento.

4.5 PREPARAÇÃO DOS DADOS

4.5.1 Reconstrução dos dados e alinhamento dos offsets

Os dados empregados foram reconstruídos diretamente dos XML do SemClinBr. Um *parser* lê cada arquivo e produz um registro com identificador do documento, texto, entidades (tipo e offsets) e relações, sem normalizar tipos e sem alterar ou descartar nenhuma anotação. O ponto crítico da reconstrução é o alinhamento entre o texto e os offsets. Em parte dos documentos, os offsets foram calculados sobre o texto com quebras de linha de dois caracteres, e substituir cada quebra por um único espaço desloca todas as entidades seguintes. A regra adotada identifica, por documento e com todas as anotações, qual convenção os offsets seguem e, quando é a de dois caracteres, substitui cada quebra por dois espaços, de modo que o texto passe a ter o comprimento pressuposto pelos offsets. A regra transformou 421 dos 1.000 documentos; nos demais, o texto foi mantido sem alteração.

O resultado foi verificado por auditoria: nenhuma entidade das três partições apresenta divergência entre o trecho recortado pelo offset e o texto anotado, e a reconstrução preserva os documentos de cada partição, as entidades, as relações, os pares candidatos e os rótulos de referência. As 26 anomalias de anotação encontradas (por exemplo, um offset inválido) foram mantidas como estão e registradas em arquivo próprio. Um manifesto (`MANIFEST.json`) registra o SHA-256 de cada partição, as contagens e a proveniência da fonte (Apêndice A).

4.5.2 Caracterização do corpus

A análise exploratória (Exploratory Data Analysis, EDA) foi conduzida com as próprias funções do código do projeto, totalizando $1\,000$ documentos, $45\,508$ entidades e $11\,458$ relações. A mediana é de 10 relações por documento, o percentil 90 é de 24 e o máximo é de 65; 46 documentos não possuem relação anotada. Entre as categorias de entidade (após decompor as anotações multirrótulo), predominam `Abbreviation`

(12 592), `Finding` (6 827) e `Therapeutic or Preventive Procedure` (4 759), e a categoria `Negation` soma 2 646 menções.

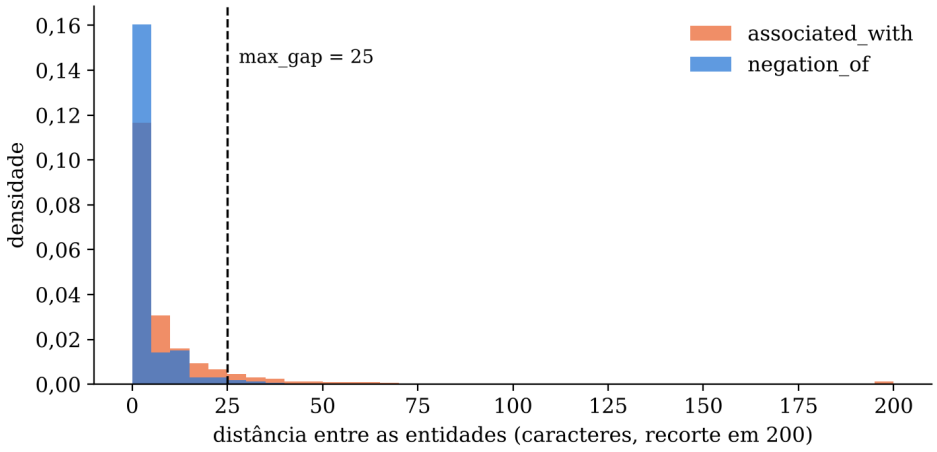
A Tabela 1 e a Figura 2 mostram que as relações ocorrem entre entidades próximas, com um contraste nítido entre os tipos. A negação é praticamente adjacente, com mediana e percentil 75 de um único caractere, enquanto a associação se distribui por uma cauda bem mais longa. Essa assimetria fundamenta a janela máxima (`max_gap` $= 25$) da geração de pares candidatos (Seção 4.5.5).

Tabela 1 – Distância em caracteres entre as entidades de cada relação anotada (corpus completo).

Tipo	n	Média	Mediana	p75	p95	Máx.	> 25
`negation_of`	1 606	3,5	1	1	15	54	1,87%
`associated_with`	9 852	11,8	4	10	43	541	9,89%

Fonte: elaborado pelo autor.

Figura 2 – Distribuição da distância em caracteres entre entidades relacionadas (recorte em 200), com a janela `max_gap` assinalada.



Fonte: elaborado pelo autor.

4.5.3 Particionamento dos dados

A partição segue a razão 80/10/10 em nível de documento, e não de relação. Essa escolha previne o vazamento de dados, pois relações de um mesmo documento compartilham vocabulário e trechos repetidos, e dividi-las entre partições inflaria artificialmente as métricas. A partição é estratificada pela presença de `negation_of`: os

documentos com ao menos uma relação de negação e os demais são embaralhados separadamente, com semente 42, e divididos 80/10/10 dentro de cada grupo, o que garante exemplos da classe rara nas três partições. O resultado são 800 documentos de treino, 100 de DEV e 100 de teste, congelados e verificados por SHA-256 (Apêndice A). A Tabela 2 apresenta as contagens por partição.

Tabela 2 – Partições congeladas: documentos, entidades, relações anotadas e pares candidatos ($\texttt{max_gap} = 25$).

Partição	Documentos	Entidades	`negation_of`	`associated_with`	Candidatos	`no_relation`
Treino	800	36 455	1 299	7 922	152 686	144 335
Desenvolvimento	100	4 513	155	832	19 064	18 151
Teste	100	4 540	152	1 098	19 210	18 062
Total	1 000	45 508	1 606	9 852	190 960	180 548

Fonte: elaborado pelo autor.

4.5.4 Geração de pares candidatos

Como o corpus anota apenas relações positivas, avaliar um classificador no espaço {`negation_of`, `associated_with`, `no_relation`} exige construir os exemplos negativos. Treinar ou avaliar apenas com os pares anotados produziria um classificador incapaz de operar em um cenário real, em que o sistema recebe *todos* os pares de entidades de um documento.

A geração é feita por uma única função do código, compartilhada por todas as estratégias, condição necessária para que os resultados fiquem na mesma régua. Para cada documento, ela percorre os pares ordenados de entidades (e_1, e_2), já que a direção é relevante para a negação, e respeita cinco propriedades: (i) os pares são emitidos sempre na mesma ordem, pela posição de e_1 e de e_2; (ii) não há pares entre documentos diferentes; (iii) apenas pares cuja distância em caracteres (entre o fim de e_1 e o início de e_2) seja $\leq \texttt{max_gap} = 25$ são gerados; (iv) nunca se forma o par de uma entidade consigo mesma, nem entre entidades com *span* idêntico; e (v) um par presente nas relações anotadas (*gold*) recebe o tipo anotado, e um par ausente recebe `no_relation`.

O Quadro 3 ilustra o processo em outro trecho real do corpus. A relação anotada é $16 \rightarrow 52 = \texttt{negation_of}$ (a entidade “NÃO ESPECIFICADA” nega “OSTEOMIELITE”).

Das seis combinações ordenadas possíveis entre as três entidades próximas, apenas o par $(16, 52)$ casa com o *gold*; os outros cinco tornam-se `no_relation`.

Quadro 3 – Exemplo de geração de candidatos para um trecho do SemClinBr.

Entidades: 16="OSTEOMIELITE" (*Disease or Syndrome*), 52="NÃO ESPECIFICADA" (*Negation*), 17="INTUBADO" (*Finding*). Relação *gold*: $16 \rightarrow 52 =$ `negation_of`.

Par ordenado	Rótulo gerado	
$16 \rightarrow 52$	`negation_of`	(casa com o *gold*)
$16 \rightarrow 17$	`no_relation`	
$52 \rightarrow 16$	`no_relation`	(direção inversa do *gold*)
$52 \rightarrow 17$	`no_relation`	
$17 \rightarrow 16$	`no_relation`	
$17 \rightarrow 52$	`no_relation`	

Fonte: elaborado pelo autor a partir de dados do SemClinBr (OLIVEIRA *et al.*, 2022).

O procedimento produz $152\,686$ candidatos de treino, $19\,064$ de DEV e $19\,210$ de teste (Tabela 2). No DEV, sobre o qual os resultados deste trabalho são medidos, $18\,151$ pares ($95{,}21\%$) pertencem a `no_relation`, contra 763 `associated_with` e 150 `negation_of`. Esse desbalanceamento é intrínseco à tarefa, pois decorre da combinatória de pares de entidades, e é tratado pela ponderação da perda (Seção 4.1) e pelo uso do macro-F1 na seleção de modelos (Seção 4.4).

4.5.5 Teto de recall imposto pela janela

A janela `max_gap`$= 25$ impõe um teto de recall: toda relação *gold* cujo par fique a mais de 25 caracteres jamais é gerada como candidato e é irrecuperável por qualquer classificador. A Tabela 3 quantifica a cobertura das relações anotadas por partição (além da janela, pares com *span* idêntico e relações repetidas sobre o mesmo par contam como não cobertos). O limite não se distribui igualmente entre as classes: a cobertura é maior na classe-alvo `negation_of` do que em `associated_with`, coerente com a distância menor entre os argumentos da negação. A Tabela 4 mostra o custo de ampliar a janela, que é de outra natureza: a partir de 25, os ganhos de cobertura de `negation_of` são pequenos, enquanto o número de pares candidatos e de exemplos `no_relation` por relação coberta continua a crescer quase linearmente (com 50, cerca de 76% mais candidatos). Como o teto é idêntico para todas as estratégias, que

recebem exatamente os mesmos candidatos, ele limita o desempenho absoluto, mas não afeta a comparação entre elas.

Tabela 3 – Relações anotadas que se tornam pares candidatos com `max_gap`$= 25$ (teto de *recall*), por partição.

Partição	`negation_of`	`associated_with`
Treino	1 255/1 299 (0,9661)	7 096/7 922 (0,8957)
Desenvolvimento	150/155 (0,9677)	763/832 (0,9171)
Teste	152/152 (1,0000)	996/1 098 (0,9071)

Fonte: elaborado pelo autor.

Tabela 4 – Sensibilidade ao `max_gap` (treino e desenvolvimento): pares candidatos, cobertura das relações e pares `no_relation` por relação coberta. * valor adotado.

`max_gap`	Candidatos	Cob. `negation_of`	Cob. `associated_with`	`no_relation`/relação
5	61 982	0,7999	0,6525	8,015563636363636
10	87 418	0,8700	0,7506	10,155946911689638
15	116 772	0,9402	0,8239	12,611376617321366
20	144 374	0,9525	0,8674	15,080864335041213
25*	171 750	0,9663	0,8978	17,539507772020727
30	198 956	0,9746	0,9184	20,037961298509043
50	302 844	0,9862	0,9550	29,921380437002245
100	541 912	0,9869	0,9801	53,11003494757863
200	954 044	0,9869	0,9909	93,37570481748936

Fonte: elaborado pelo autor.

4.6 PROTOCOLO PRÉ-REGISTRADO E COMPARAÇÕES ESTATÍSTICAS

As decisões experimentais desta fase foram fixadas em um protocolo registrado antes de qualquer treino, rotulado “validação inicial, seed 42”. Ele define o escopo (*encoder* BioBERTpt-all, semente 42 e as partições congeladas), a revisão exata dos pesos pré-treinados, os critérios de seleção e de parada de cada estratégia, os limiares escolhidos no DEV, a sequência de execução e a forma de interpretar os resultados. Alterações posteriores ao registro dependem de aprovação explícita do autor e ficam documentadas; a mais relevante para este texto é a decisão que fixou a configuração

atual da Pair-Aware (Seção 5.4.4), aprovada antes de seu treino. Duas execuções apresentadas aqui estão fora do escopo pré-registrado e são assim identificadas: o baseline com o BERTimbau-base, que estende a comparação de *encoders*, e a variante Pair-Aware MLP, exploratória. O protocolo prevê ainda uma estratégia de *fine-tuning* restrito, treinada apenas sobre os pares cujo primeiro argumento é pista do léxico de negação, que não foi executada até o momento e, por isso, não é descrita no Capítulo 5 (Seção 7.4).

Todas as escolhas usam somente o DEV:

- Época: cada estratégia de três rótulos treina um número fixo de épocas, sem parada antecipada, e mantém a de maior macro-F1 no DEV (empate: a primeira). Os estágios do Two-Stage usam métricas próprias (Seção 5.4.5).
- Limiares: o limiar τ do Two-Stage e o limiar t do baseline calibrado são escolhidos numa grade de $0{,}05$ a $0{,}95$, com passo de $0{,}05$, pelo maior F1 de `negation_of` da saída final no DEV (desempates: maior macro-F1, menor distância de $0{,}5$, maior limiar) e congelados em arquivo vinculado aos *hashes* dos modelos e do DEV.
- Léxico de pistas: o léxico usado pelo filtro foi congelado antes da fase, por validação cruzada só no treino (Seção 5.4.3).

O teste de cada sistema deve ser avaliado uma única vez, depois que todas as escolhas do DEV estiverem congeladas, e nenhum resultado de teste influencia qualquer escolha. Até o momento deste texto, nenhum sistema foi avaliado no teste, porque a configuração definitiva, inclusive a escolha do *encoder*, ainda não foi congelada. Por isso, todos os resultados do Capítulo 6 são de DEV. Os do Two-Stage e do baseline calibrado são, além disso, otimistas por construção, porque seus limiares foram escolhidos no mesmo DEV em que são medidos.

Para as comparações estatísticas entre sistemas, empregam-se dois testes pareados, calculados sobre o *mesmo* conjunto a partir das predições salvas. O teste de McNemar (DIETTERICH, 1998) considera as instâncias em que os dois sistemas discordam quanto ao acerto (b: só o primeiro acerta; c: só o segundo) e avalia, sob a hipótese nula

de mesma taxa de acerto, $b \sim \mathrm{Binomial}(b+c, 0{,}5)$ pelo teste binomial exato. Por incidir sobre o acerto global, ele é dominado pela classe `no_relation` e não é específico da classe-alvo. O *bootstrap* pareado responde à pergunta da classe-alvo: reamostram-se as instâncias com reposição $10\,000$ vezes (semente 42), recalcula-se a diferença no F1 de `negation_of` e reportam-se a diferença, o intervalo de confiança de 95% (percentis $2{,}5/97{,}5$) e um valor-p bilateral. Uma diferença é tratada como detectada quando o IC95% exclui o zero.

O protocolo prevê esses testes no conjunto de teste. Neste trabalho eles são aplicados ao DEV apenas de forma descritiva, para dimensionar a incerteza das diferenças observadas; não substituem a comparação pré-registrada no teste e não corrigem o otimismo dos sistemas com limiar escolhido no DEV. Com uma única semente, eles medem a incerteza sobre os exemplos, dados os modelos treinados, e não a variação do treino.

5 PROPOSTA DO RECLIN-PT

Este capítulo apresenta a proposta do RECLin-PT, modelo de extração de relações clínicas em português com ênfase em `negation_of`. Um modelo RECLin-PT é formado por um *encoder* pré-treinado, ajustado sobre os pares candidatos do Capítulo 4, e por uma estratégia de modelagem, que define como as saídas desse *encoder* produzem os três rótulos. O desenvolvimento consiste em escolher esses dois componentes, e por isso eles são examinados em duas dimensões: os *encoders*, comparados sob configuração idêntica, e as estratégias, comparadas com o mesmo *encoder*. As alternativas são descritas aqui sem antecipar resultados; a estratégia que serve de referência nas análises preliminares é indicada no Capítulo 6, e a configuração final só será selecionada depois do congelamento das escolhas e da avaliação no teste (Seção 4.6).

5.1 PARIDADE ENTRE OS SISTEMAS COMPARADOS

A premissa metodológica central é a paridade. Todas as estratégias usam a mesma partição congelada, os mesmos pares candidatos (e, portanto, o mesmo teto de *recall*), a mesma representação de entrada (Seção 5.3), a mesma configuração base de otimização (Quadro 1), a mesma semente e critérios de seleção fixados no protocolo. Todas gravam predições no conjunto completo de candidatos, na mesma ordem e com os mesmos rótulos de referência, o que permite compará-las por todas as métricas e pelos mesmos testes pareados. Entre *encoders*, a paridade é ainda mais estrita: na estratégia baseline, os dois modelos passam exatamente pelo mesmo código, e trocar um pelo outro consiste em mudar o *checkpoint* carregado.

5.2 OS *ENCODERS*

O *encoder* de domínio clínico é o BioBERTpt-all (`pucpr/biobertpt-all`)[1] (SCHNEIDER *et al.*, 2020), adaptado a narrativas clínicas e textos biomédicos em português brasileiro, com $177{,}9$ milhões de parâmetros com a cabeça de classificação do baseline. É o *encoder* fixado pelo protocolo desta fase e o único com o qual todas as estratégias foram treinadas.

[1] *Checkpoint* público em huggingface.co/pucpr/biobertpt-all.

O *encoder* de domínio geral é o BERTimbau-base [2] (SOUZA; NOGUEIRA; LOTUFO, 2020), referência de domínio geral para o português, com $108{,}9$ milhões de parâmetros (cerca de 61% do BioBERTpt-all). Ele entra como o controle que isola o efeito do domínio de pré-treino. Se o desempenho for equivalente, o modelo menor é preferível por custo de inferência e de memória, consideração concreta para ambientes clínicos com recursos limitados. Sua execução, por ora restrita à estratégia baseline, está fora do escopo pré-registrado desta fase.

A variante BioBERTpt-clin (`pucpr/biobertpt-clin`), adaptada só a narrativas clínicas, está prevista na comparação de *encoders*, mas ainda não tem resultado.

A delimitação a esses *encoders* é deliberada. Para orientar a configuração do RECLin-PT, a influência do domínio de pré-treinamento e da estratégia de extração de relações é avaliada sob condições experimentais controladas, e por isso cada comparação muda um único fator: o *checkpoint*, com a estratégia fixa, ou a estratégia, com o *encoder* fixo. Os dois *encoders* treinados têm a mesma arquitetura de porte *base*, e a diferença no número de parâmetros decorre inteiramente do tamanho do vocabulário, cerca de quatro vezes maior no BioBERTpt-all ($119\,551$ contra $29\,798$ *tokens*, incluídos os marcadores), que amplia a matriz de *embeddings*. Variantes de maior porte, como os modelos *large*, ficaram fora do escopo experimental: cada uma acrescentaria custos de treinamento e de avaliação a todas as estratégias e introduziria a escala como um fator adicional, o que tornaria a comparação menos viável e menos controlada nas condições deste trabalho. Modelos maiores podem apresentar vantagens, mas o porte, por si só, não garante ganhos na tarefa investigada, e a questão permanece aberta para trabalhos futuros. A delimitação, portanto, não implica que os *encoders* escolhidos sejam superiores a outros.

5.3 REPRESENTAÇÃO DE ENTRADA: MARCADORES DE POSIÇÃO

Os modelos não recebem o par de entidades de forma abstrata, e sim um recorte do *texto* do documento com o par delimitado por marcadores de entidade (SOARES *et al.*, 2019). A função `janela_marcada` (`reclin/entrada.py`) recorta uma janela de ± 128

[2] *Checkpoint* público `neuralmind/bert-base-portuguese-cased`, em huggingface.co/neuralmind/bert-base-portuguese-cased.

caracteres em torno do par (`ctx_chars`) e insere quatro delimitadores, no esquema

$$\texttt{[E1]}\ \text{superfície}_{e_1}\ \texttt{[/E1]}\quad \ldots\quad \texttt{[E2]}\ \text{superfície}_{e_2}\ \texttt{[/E2]}$$

Os quatro marcadores são registrados como *tokens*[3] especiais, e a matriz de *embeddings* é redimensionada para lhes dar um vetor dedicado, aprendido durante o ajuste fino. Duas propriedades delimitam *que informação* o modelo recebe:

1. Os marcadores são posicionais, não semânticos. Eles indicam quais trechos da janela formam o par e qual deles é o primeiro argumento. O tipo semântico anotado pelo SemClinBr (`Disease or Syndrome`, `Negation`, `Finding...`) não é passado ao modelo, que precisa inferir a natureza de cada entidade a partir da superfície textual e do contexto.
2. A direção vem da etiqueta, não da ordem. Quando e_2 precede e_1 no texto, a *string* resultante começa por `[E2]`; a direção da relação, que importa para `negation_of`, é preservada por *qual* marcador envolve *qual* entidade.

Aplicado ao trecho do Quadro 3, o par *gold* $16 \rightarrow 52$ produz a entrada reproduzida no Quadro 4, na qual nenhum tipo semântico aparece.

Quadro 4 – Entrada efetivamente construída para o par *gold* do Quadro 3.

```
... CURATIVO COM ASPECTO LIMPO E SECO. SEGUE EM OBSERVAÇÃO. [E1]
OSTEOMIELITE [/E1] [E2] NÃO ESPECIFICADA [/E2]. INTUBADO, SOB
VENTILAÇÃO MECÂNICA, MONITORIZAÇÃO CARDÍACA ...
```

Fonte: elaborado pelo autor a partir de dados do SemClinBr (OLIVEIRA *et al.*, 2022).

A anotação de tipo, além de não chegar ao modelo, não seria aproveitável na forma em que vem. No treino ocorrem apenas 89 tipos *atômicos* distintos, mas a combinação multirrótulo faz o número de *strings* de tipo distintas subir para 828, das quais 752 contêm "`|`"; cada combinação viraria um símbolo praticamente único e mal povoado. Para a comparação de *encoders*, a ausência do tipo é inclusive conveniente, pois mede

[3] *Tokens* são as unidades em que o *tokenizer* divide o texto antes de entregá-lo ao modelo, e podem ser palavras inteiras ou fragmentos de palavra. Os especiais não vêm do texto e recebem um vetor próprio.

a capacidade de cada um de *inferi-lo* do texto, exatamente onde o pré-treinamento de domínio deveria fazer diferença.

5.4 ESTRATÉGIAS DE MODELAGEM

5.4.1 Baseline

O baseline é o classificador direto da tarefa: todos os pares candidatos, a janela marcada e o *encoder* com a cabeça de classificação de sequência, que projeta a representação agregada (`[CLS]`) nas três classes. Usa a configuração comum de treino e de seleção de época (Seção 4.1 e Quadro 1) e nenhum conhecimento específico de negação. É a referência contra a qual as demais estratégias são descritas, pelas suas diferenças, e a estratégia em que os dois *encoders* foram comparados.

5.4.2 Baseline calibrado

O baseline calibrado não treina nada: aplica às probabilidades já produzidas pelo baseline um limiar t sobre a probabilidade de `negation_of`. Se $P(\texttt{negation_of}) \geq t$, o par recebe `negation_of`; caso contrário, recebe a mais provável entre `associated_with` e `no_relation`. O limiar é escolhido no DEV pela busca do protocolo (Seção 4.6). Seu papel é de controle: como o Two-Stage também depende de um limiar escolhido no DEV, só a comparação com o baseline calibrado permite separar o efeito da arquitetura do efeito de simplesmente recalibrar a decisão.

5.4.3 Filtro léxico

O filtro pós-processa as predições do baseline com um léxico de pistas de negação: toda predição `negation_of` cujo primeiro argumento (e_1) não seja uma pista do léxico é rebaixada a `no_relation`. Nenhuma predição é promovida, nenhuma outra classe é tocada e, por isso, o filtro só pode elevar a precisão da classe-alvo, nunca o seu *recall*. As formas são comparadas após remoção de acentos, colapso de espaços e conversão para caixa baixa.

O léxico é induzido exclusivamente do treino: são contadas as formas de e_1 nos pares candidatos `negation_of`, e retêm-se as que atingem uma frequência mínima (`min_`

`freq`). O valor foi escolhido antes da fase, por validação cruzada em 5 partes só no treino, sem modelos, predições, DEV ou teste, pelo maior F1 do léxico como detector; a escolha recaiu sobre `min_freq`$= 10$, que retém 8 formas (Apêndice B). Duas limitações registradas acompanham essa escolha: o valor escolhido é o maior da grade avaliada, e o critério favorece a precisão, porque os falsos positivos dominam o F1 de um léxico usado como detector.

5.4.4 Pair-Aware

A Pair-Aware substitui a cabeça do baseline por uma que lê explicitamente o par: os estados ocultos da última camada nas posições do `[CLS]`, de `[E1]` e de `[E2]` são concatenados e projetados nas três classes,

$$[\,h_{\texttt{[CLS]}}; h_{\texttt{[E1]}}; h_{\texttt{[E2]}}\,] \rightarrow \text{Dropout} \rightarrow \text{Linear}(3d, 3),$$

a variante *entity start* de Soares *et al.* (2019), com o `[CLS]` mantido. A configuração em vigor foi fixada antes de seu treino, por decisão registrada no protocolo: todos os pares candidatos, sem filtro e sem uso do léxico, cabeça linear (sem camada oculta), 3 épocas e seleção pelo macro-F1 do DEV, como o baseline. Assim, todas as suas métricas são comparáveis às do baseline, e a única diferença entre os dois é a forma de ler a representação.

A variante exploratória Pair-Aware MLP é idêntica, exceto pela cabeça, que tem uma camada oculta, $\text{Linear}(3d, d) \rightarrow \text{GELU} \rightarrow \text{Dropout} \rightarrow \text{Linear}(d, 3)$. Ela foi criada depois do protocolo, está fora dele e é apresentada apenas como resultado exploratório.

5.4.5 Two-Stage

O Two-Stage decompõe a decisão em dois classificadores binários independentes, cada um com seu próprio ajuste fino a partir dos pesos originais do *encoder*; nenhum estágio parte de um modelo já ajustado.

- Estágio 1, existe relação? Classifica `relacao` contra `no_relation` e é treinado com todos os pares candidatos do treino ($8\,351$ com relação e $144\,335$ sem relação).

Treina por 3 épocas, e a época escolhida é a de maior precisão média (AP) da classe `relacao` no DEV completo.

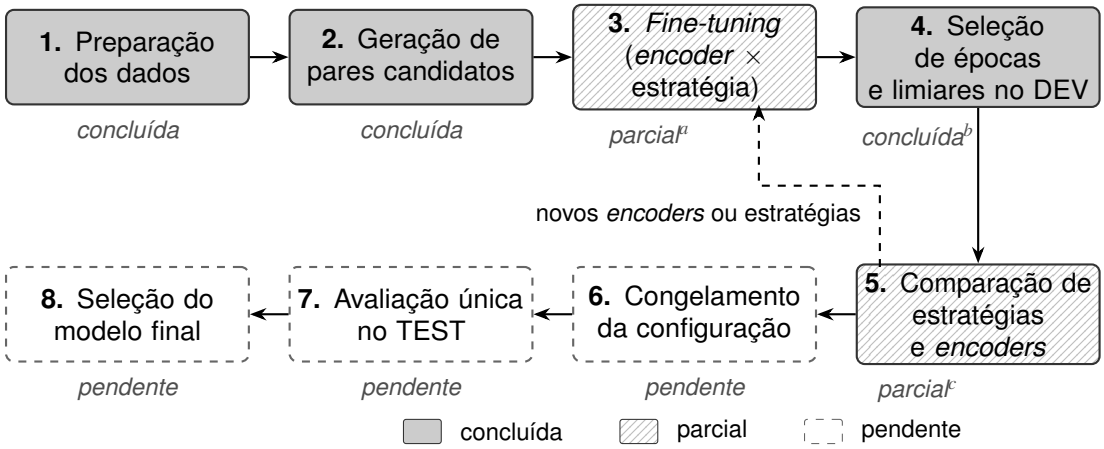
- Estágio 2, qual o tipo? Classifica `negation_of` contra `associated_with` e é treinado só com os pares do treino que têm relação anotada ($1\,255$ e $7\,096$). Treina por 10 épocas, e a escolhida é a de maior F1 de `negation_of` nos 913 pares do DEV com relação anotada.
- Composição (inferência). Um par segue para o estágio 2 quando a probabilidade de relação estimada pelo estágio 1, arredondada a quatro casas, é $\geq \tau$; os demais ficam `no_relation`, e o estágio 2 decide o tipo dos pares roteados pelo argmax. A saída tem os três rótulos da tarefa sobre o conjunto completo.

O limiar τ é o único parâmetro do *pipeline* escolhido no DEV, pela busca do protocolo, executando para cada valor da grade o fluxo real (o estágio 2 só sobre os pares roteados). Como cada estágio é escolhido pela sua própria métrica, nada garante que a combinação de épocas seja a melhor para o *pipeline* completo, e não há otimização conjunta. O estágio 2 é treinado com os rótulos anotados, nunca com predições do estágio 1: os dois só se encontram na composição. A motivação da decomposição é a do Capítulo 2: separar a pergunta “há relação?”, dominada pelo desbalanceamento, da pergunta “qual relação?”, em que `negation_of` deixa de competir com a massa de pares `no_relation`.

6 EXPERIMENTOS E RESULTADOS

Neste capítulo são descritos os experimentos conduzidos no desenvolvimento do RECLin-PT, com foco na classe `negation_of`, bem como os resultados obtidos até o momento, todos no conjunto de desenvolvimento. Cada experimento responde a uma decisão de configuração do modelo: a comparação entre *encoders*, à escolha do *encoder*, e a comparação entre estratégias, à escolha da estratégia. Este capítulo reporta o que foi observado; o que esses resultados implicam para o RECLin-PT é discutido no Capítulo 7. A Figura 3 apresenta o ciclo de desenvolvimento e o estado atual de cada etapa. A preparação dos dados e a geração de pares candidatos estão concluídas. O *fine-tuning* foi realizado apenas para parte das combinações de *encoder* e estratégia, e a seleção de épocas e de limiares no DEV foi feita para todas as execuções existentes. A comparação é parcial: as estratégias foram comparadas com o BioBERTpt-all, e os *encoders*, apenas na estratégia baseline, de forma descritiva e no DEV. O congelamento da configuração, a avaliação única no conjunto de teste e a seleção da configuração final do RECLin-PT permanecem pendentes. A seta de retorno indica que novos *encoders* ou estratégias voltam à etapa de *fine-tuning* antes de entrar na comparação.

Figura 3 – Ciclo de desenvolvimento do RECLin-PT e estado atual de cada etapa.



[a] O BioBERTpt-all foi ajustado em todas as estratégias treinadas; o BERTimbau-base, apenas no baseline; o BioBERTpt-clin e o *fine-tuning* restrito não têm execução. [b] Para as execuções existentes e verificadas. [c] Estratégias comparadas com o BioBERTpt-all; *encoders*, apenas na estratégia baseline; comparações descritivas no DEV.

Fonte: elaborado pelo autor.

Todos os números são do conjunto de desenvolvimento (DEV), com semente 42, sobre

os $19\,064$ pares candidatos das partições congeladas (Seção 4.5.4). O DEV é o mesmo conjunto usado nas escolhas de época e de limiar, e nenhum sistema foi avaliado no teste. Os resultados são, portanto, evidências preliminares, e não estimativas finais de desempenho; os do Two-Stage e do baseline calibrado, cujo limiar foi escolhido neste mesmo DEV, são otimistas por construção (Seção 4.6).

6.1 TREINO E SELEÇÃO DE ÉPOCA

Nas execuções de três rótulos, a época selecionada foi sempre a terceira, a última permitida pelo protocolo, e o macro-F1 do DEV ainda subia entre a segunda e a terceira época (no baseline BioBERTpt-all, de $0{,}712$ para $0{,}719$); a evolução completa por época, com perdas e duração, está no Apêndice D. Nessas execuções, a perda do DEV deixou de cair a partir da segunda época, de modo que perda e macro-F1 não apontaram a mesma época. A coincidência entre a melhor época e o teto é compatível com a possibilidade de que um orçamento maior de treino altere os números absolutos; essa possibilidade é comum a todas as estratégias e não foi explorada. As épocas executadas em uma única sessão levaram cerca de uma hora na GPU T4; as interrompidas e retomadas registram apenas a parte final, o que impede usar as durações para comparar o custo das estratégias.

O Two-Stage não segue esse padrão porque seus dois estágios são classificadores binários treinados separadamente, com critérios de seleção próprios, e o macro-F1 do *pipeline* completo só é definido após a escolha do limiar τ (Seção 6.4).

6.2 COMPARAÇÃO ENTRE *ENCODERS*

A Tabela 5 compara o BioBERTpt-all e o BERTimbau-base na estratégia baseline, sob configuração idêntica. Os dois *encoders* chegam a desempenhos muito próximos. Na classe-alvo, o BioBERTpt-all alcança F1 de $0{,}802$ e o BERTimbau-base, de $0{,}800$, com perfis ligeiramente diferentes: o clínico tem *recall* maior ($0{,}947$ contra $0{,}920$), e o geral, precisão maior ($0{,}708$ contra $0{,}696$). Nas demais classes e no macro-F1, a pequena vantagem é do BERTimbau-base ($0{,}723$ contra $0{,}719$), e o MCC é praticamente igual. A diferença no F1 de `negation_of` ($-0{,}0023$ para o BERTimbau-base) tem IC95% de $[-0{,}0295; +0{,}0253]$ pelo *bootstrap* pareado descritivo (Seção 6.5), isto é, não é

distinguível de zero. O BERTimbau-base obtém esse resultado com cerca de 61% dos parâmetros do BioBERTpt-all.

Tabela 5 – Comparação de *encoders* na estratégia baseline, no DEV (seed 42, mesma configuração; só o *checkpoint* muda): F1 por classe, P e R de `negation_of`, macro-F1 e MCC.

Encoder	Parâm.	F1 neg	F1 assoc	F1 no_rel	P neg	R neg	Macro-F1	MCC
BioBERTpt-all	177,9 M	0,802	0,408	0,946	0,696	0,947	0,719	0,480
BERTimbau-base	108,9 M	0,800	0,417	0,951	0,708	0,920	0,723	0,480

A execução BERTimbau-base está fora do escopo pré-registrado (que fixa o BioBERTpt-all) e não tem nome oficial. BioBERTpt-clin: sem resultado.

Fonte: elaborado pelo autor.

Esse é, até aqui, o único resultado que compara *encoders* diretamente, com uma estratégia, uma semente e no DEV. As estratégias seguintes foram treinadas apenas com o BioBERTpt-all, de modo que a comparação nas demais estratégias é uma etapa pendente, e não se sabe ainda se o efeito do *encoder* muda com a estratégia.

6.3 ESTRATÉGIAS DO PROTOCOLO COM O BIOBERTPT-ALL

A Tabela 6 reúne os cinco sistemas do protocolo com resultado disponível, todos com o BioBERTpt-all. Na classe-alvo, todos superam o F1 do baseline, principalmente pela precisão. O Two-Stage tem o maior F1 e a maior precisão, com o menor número de falsos positivos, mas também o menor *recall*. A Pair-Aware fica logo atrás no F1 de `negation_of`, com *recall* próximo ao do baseline, e tem, entre os sistemas do protocolo, o maior macro-F1 e o maior MCC. O filtro léxico e o baseline calibrado melhoram a precisão do baseline ao custo de parte do *recall*: o filtro rebaixou 24 das 204 predições `negation_of` do baseline, e o limiar escolhido para o calibrado foi $t = 0{,}90$.

As outras duas classes completam o quadro (Tabela 7). O Two-Stage tem o maior F1 de `no_relation`, mas o menor de `associated_with`: sua precisão nessa classe é a maior, e seu *recall* é o menor, cerca de um terço do baseline. É essa perda que mantém o seu macro-F1 abaixo do da Pair-Aware, apesar do melhor resultado na classe-alvo. O filtro e o calibrado praticamente não alteram `associated_with`, como esperado de regras que atuam sobre `negation_of`; entre os sistemas do protocolo, a Pair-Aware tem o maior F1 de `associated_with` $(0{,}436)$, ainda baixo para todas as estratégias.

Tabela 6 – Resultados no conjunto de desenvolvimento (DEV) dos sistemas do protocolo, BioBERTpt-all, seed 42: precisão (P), *recall* (R) e F1 de `negation_of`, macro-F1 e MCC. Melhor valor por coluna em negrito.

Sistema	P	R	F1	VP/FP/FN	Macro-F1	MCC
Baseline	0,696	**0,947**	0,802	142/62/8	0,719	0,480
Baseline calibrado ($t = 0{,}90$)	0,723	0,920	0,809	138/53/12	0,721	0,479
Filtro léxico	0,750	0,900	0,818	135/45/15	0,724	0,477
Pair-Aware	0,742	0,940	0,829	141/49/9	**0,741**	**0,497**
Two-Stage ($\tau = 0{,}95$)	**0,798**	0,867	**0,831**	130/33/20	0,725	0,462

DEV, $n = 19\,064$ pares (150 `negation_of`). Não são resultados de teste. τ e t foram escolhidos neste mesmo DEV.

Fonte: elaborado pelo autor.

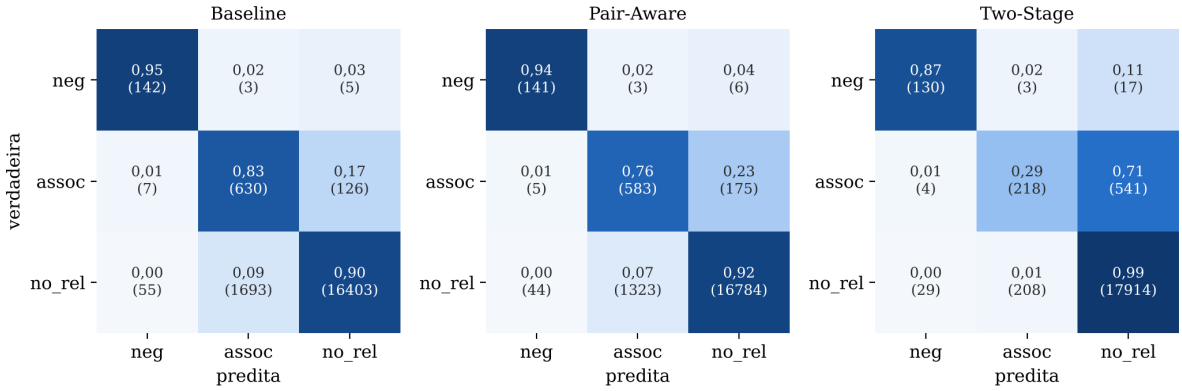
Tabela 7 – Precisão, *recall* e F1 de `associated_with` e `no_relation` no DEV, sistemas do protocolo (BioBERTpt-all, seed 42).

	`associated_with`			`no_relation`		
Sistema	P	R	F1	P	R	F1
Baseline	0,271	**0,826**	0,408	**0,992**	0,904	0,946
Baseline calibrado ($t = 0{,}90$)	0,270	**0,826**	0,407	**0,992**	0,904	0,946
Filtro léxico	0,271	**0,826**	0,408	**0,992**	0,905	0,946
Pair-Aware	0,305	0,764	**0,436**	0,989	0,925	0,956
Two-Stage ($\tau = 0{,}95$)	**0,508**	0,286	0,366	0,970	**0,987**	**0,978**

Fonte: elaborado pelo autor.

A Figura 4 mostra para onde vão os erros. No baseline e na Pair-Aware, a classe `negation_of` é quase toda recuperada, e o erro dominante é a confusão de `no_relation` com `associated_with` ($1\,693$ e $1\,323$ pares). No Two-Stage, essa confusão quase desaparece (208 pares), mas o erro se desloca para o sentido inverso: 541 das 763 relações `associated_with` são classificadas como `no_relation`, e 17 das 150 `negation_of` também.

Figura 4 – Matrizes de confusão no DEV (normalizadas por linha, contagens entre parênteses): baseline, Pair-Aware e Two-Stage, BioBERTpt-all, seed 42.



Fonte: elaborado pelo autor.

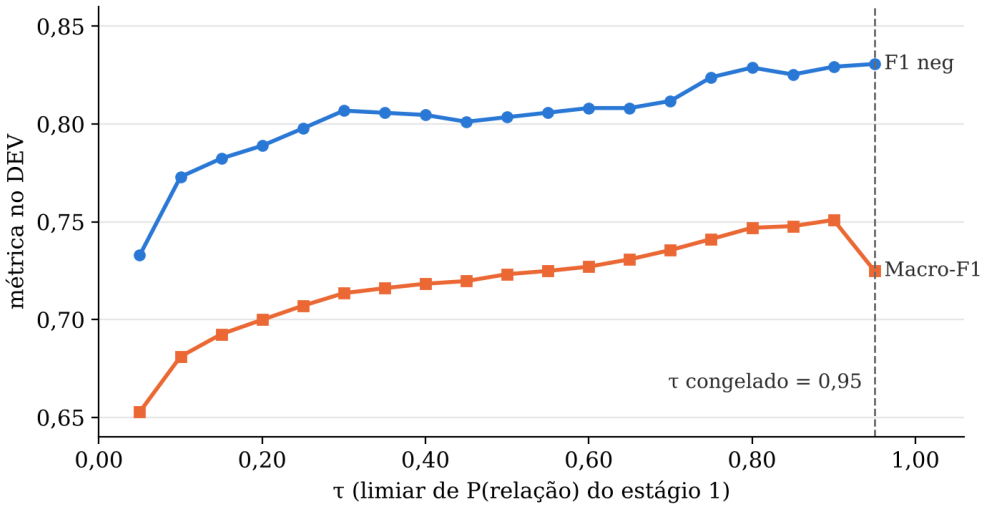
6.4 O TWO-STAGE EM DETALHE

No estágio 1, a época selecionada pela AP de `relacao` foi a segunda das três ($0{,}544$), e as épocas executadas em sessão única levaram cerca de uma hora. No estágio 2, medido só sobre os 913 pares do DEV com relação anotada, o F1 de `negation_of` ficou entre $0{,}943$ e $0{,}970$ ao longo das dez épocas, a selecionada foi a oitava ($0{,}970$), e cada época levou cerca de três minutos, por ser treinado só sobre os pares com relação anotada. A evolução completa por época dos dois estágios está no Apêndice D. Esses números descrevem cada estágio isoladamente e não são resultados da arquitetura, porque o estágio 2 nunca vê, na inferência, os pares que o estágio 1 não roteia.

A Figura 5 mostra o efeito de τ sobre o *pipeline* completo (a tabela completa está no Apêndice C). O F1 de `negation_of` cresce com τ, de $0{,}733$ em $\tau = 0{,}05$ até $0{,}8307$ em $\tau = 0{,}95$, enquanto o macro-F1 cresce até $0{,}751$ em $\tau = 0{,}90$ e cai para $0{,}725$ em $\tau = 0{,}95$. O valor congelado, $0{,}95$, é o extremo superior da grade e venceu $\tau = 0{,}90$ por pouco no critério do protocolo ($0{,}8307$ contra $0{,}8293$), mas reduziu os pares roteados ao estágio 2 de $1\,303$ para 592; como os pares não roteados recebem `no_relation`, essa redução se reflete diretamente na queda do *recall* de `associated_with`.

Com $\tau = 0{,}95$, o estágio 1 encaminha ao estágio 2 592 pares, dos quais 237 não têm relação anotada. Ele recupera $88{,}7\%$ dos pares `negation_of`, mas só $38{,}9\%$ do conjunto de pares com relação, e, entre os pares roteados que têm relação, o estágio 2

Figura 5 – Two-Stage no DEV: F1 de `negation_of` e macro-F1 do *pipeline* completo em função do limiar τ.



Fonte: elaborado pelo autor.

acerta o tipo em $98{,}0\%$ dos casos. Nesta execução, portanto, as perdas do Two-Stage concentram-se no estágio 1 e no limiar, e não na distinção entre os tipos.

6.5 COMPARAÇÕES PAREADAS DESCRITIVAS

A Tabela 8 aplica ao DEV, apenas de forma descritiva, os testes que o protocolo prevê para o teste. No F1 de `negation_of`, o Two-Stage fica à frente de todos os sistemas, mas nenhuma dessas diferenças é distinguível de zero, nem mesmo contra o baseline calibrado, controle exigido pelo protocolo para atribuir o efeito à arquitetura; contra a Pair-Aware, a vantagem é de apenas $+0{,}0013$. A única diferença com IC95% inteiramente acima de zero é a da Pair-Aware sobre o baseline ($+0{,}0272$, $[+0{,}0052; +0{,}0506]$). Entre *encoders*, o intervalo é centrado em zero.

O McNemar rejeita a igualdade em quase todas as comparações, mas responde a outra pergunta: ele incide sobre o acerto global, dominado pela classe `no_relation`. O Two-Stage, por exemplo, acerta muito mais pares no total (acurácia de $0{,}958$, contra $0{,}901$ do baseline), em grande parte porque prevê `no_relation` com mais frequência, o que não se traduz em vantagem na classe-alvo nem no macro-F1. A única comparação sem diferença no McNemar é a do baseline calibrado com o baseline, cujas predições diferem em apenas 12 pares.

Tabela 8 – Comparações pareadas **descritivas** no DEV: diferença no F1 de `negation_of`, IC95% e valor-p do *bootstrap* pareado (10.000 reamostras, semente 42) e McNemar exato sobre os acertos globais (b/c: só A acerta / só B acerta).

Comparação (A − B)	ΔF1 neg	IC95%	p	b/c	p McNemar
Two-Stage − Baseline	$+0{,}0284$	$[-0{,}0079; +0{,}0650]$	0,127	1517/430	$< 0{,}001$
Two-Stage − Baseline calibrado	$+0{,}0213$	$[-0{,}0113; +0{,}0543]$	0,208	1512/429	$< 0{,}001$
Baseline calibrado − Baseline	$+0{,}0071$	$[-0{,}0121; +0{,}0260]$	0,469	8/4	0,388
Two-Stage − Filtro léxico	$+0{,}0125$	$[-0{,}0187; +0{,}0439]$	0,433	1509/430	$< 0{,}001$
Two-Stage − Pair-Aware	$+0{,}0013$	$[-0{,}0327; +0{,}0347]$	0,963	1137/383	$< 0{,}001$
Pair-Aware − Baseline	$+0{,}0272$	$[+0{,}0052; +0{,}0506]$	0,012	588/255	$< 0{,}001$
Two-Stage − Pair-Aware MLP	$+0{,}0135$	$[-0{,}0223; +0{,}0486]$	0,468	1122/380	$< 0{,}001$
BERTimbau-base (baseline) − BioBERTpt-all (baseline)	$-0{,}0023$	$[-0{,}0295; +0{,}0253]$	0,877	499/337	$< 0{,}001$

Descritivas: τ (Two-Stage) e t (calibrado) foram escolhidos neste DEV, e a época de cada modelo também; não substituem as comparações pré-registradas no TEST.

Fonte: elaborado pelo autor.

6.6 RESULTADO EXPLORATÓRIO

A variante Pair-Aware MLP, fora do protocolo, foi treinada com a mesma entrada, os mesmos dados e a mesma seleção da Pair-Aware do protocolo, mudando apenas a cabeça. Ela teve *recall* de `negation_of` um pouco maior ($0{,}953$) e precisão menor ($0{,}715$), e terminou com F1 de $0{,}817$ e macro-F1 de $0{,}737$, ambos abaixo da Pair-Aware linear; a diferença para o Two-Stage no F1 de `negation_of` também não é distinguível de zero (Tabela 8). Os valores completos estão no Apêndice E. Por ser exploratório, esse resultado não é evidência confirmatória e não entra na escolha da estratégia de referência.

7 DISCUSSÃO

Este capítulo interpreta os resultados de desenvolvimento do RECLin-PT à luz da pergunta de pesquisa e do que implicam para as decisões de configuração do modelo, discute as estratégias e registra as limitações e ameaças à validade. Todas as leituras abaixo são preliminares, porque se apoiam no DEV, com uma única semente, e aguardam a avaliação no teste; quando uma explicação é plausível, mas não foi testada, ela é apresentada como hipótese.

7.1 A ESCOLHA DO *ENCODER*

Na única comparação direta disponível, a estratégia baseline, o pré-treinamento clínico não produziu vantagem detectável. O BioBERTpt-all e o BERTimbau-base chegam a F1 de `negation_of` praticamente iguais, com intervalo de confiança da diferença centrado em zero, e o *encoder* geral fica ligeiramente à frente nas outras classes e no macro-F1. Os dois se distinguem mais no perfil do que no nível: o clínico recupera um pouco mais das negações, e o geral erra um pouco menos ao predizê-las. Esse quadro contrasta com a expectativa difundida, bem como com os ganhos relatados para o reconhecimento de entidades clínicas em português (SCHNEIDER *et al.*, 2020), de que modelos de domínio se transfiram melhor.

Duas hipóteses são compatíveis com esse resultado, sem que os experimentos atuais permitam distingui-las ou demonstrá-las. A primeira é linguística: a negação clínica em português é fortemente lexicalizada, e o gatilho está quase sempre colado ao achado negado, com distância mediana de um único caractere (Seção 4.5.2); um sinal tão local e regular pode depender pouco de vocabulário clínico especializado. A segunda é estrutural: a tarefa, tal como formulada, depende da delimitação e da direção do par, fornecidas igualmente aos dois *encoders* pela mesma representação de entrada. Testar essas hipóteses exigiria, por exemplo, analisar os erros por tipo de gatilho e por distância entre os argumentos, o que não foi feito. Há, além disso, um argumento de eficiência: com desempenho equivalente, o BERTimbau-base usa cerca de 61% dos parâmetros, o que tende a reduzir o custo de memória e de inferência, embora esse custo não tenha sido medido neste trabalho.

Essas leituras respondem apenas parcialmente à parte da pergunta de pesquisa que trata do *encoder*. A comparação cobre uma estratégia, uma semente e o DEV, e o BERTimbau-base foi treinado fora do escopo pré-registrado. Não se sabe ainda se o efeito do *encoder* muda quando a decisão é decomposta, como no Two-Stage, ou quando a cabeça lê o par, como na Pair-Aware, nem como se comporta a variante BioBERTpt-clin. Para o RECLin-PT, a evidência disponível permite manter o BERTimbau-base como candidato viável, mas não basta para fixar o *encoder*, cuja escolha permanece em aberto.

7.2 AS ESTRATÉGIAS DE MODELAGEM

Com o BioBERTpt-all, todas as estratégias superam o baseline no F1 de `negation_of`, e o fazem principalmente pela precisão. O baseline já recupera quase todas as negações, e o seu gargalo são os falsos positivos. As estratégias diferem na forma de reduzi-los e no que pagam por isso.

O filtro léxico e o baseline calibrado atuam só sobre as predições de `negation_of`: o primeiro exige que o primeiro argumento seja uma pista de negação, e o segundo exige uma probabilidade alta. Ambos trocam alguns acertos por menos falsos positivos e deixam as outras classes intactas. A Pair-Aware reduz os falsos positivos sem sacrificar o *recall* e melhora também `associated_with` e `no_relation`. Como a única diferença em relação ao baseline é a forma de ler a representação, o resultado é compatível com um benefício da leitura explícita do par, mas, com uma única semente, ele não pode ser separado da variação do treino. É a única estratégia cuja diferença para o baseline tem intervalo de confiança inteiramente acima de zero no DEV, e a de maior macro-F1 entre as do protocolo. O Two-Stage vai mais longe na precisão e no F1 da classe-alvo; o diagnóstico do fluxo (Seção 6.4) é coerente com a explicação de que só os pares que o estágio 1 considera muito prováveis chegam a ser classificados, e entre eles o estágio 2 quase não erra o tipo. O preço é o *recall*: o que o estágio 1 não encaminha vira `no_relation`, o que custa algumas negações e, sobretudo, a maior parte das relações `associated_with`.

Esse compromisso é amplificado pelo limiar. O τ foi escolhido, como manda o protocolo,

apenas pelo F1 de `negation_of`, e o valor vencedor ficou no extremo da grade, à frente de $\tau = 0{,}90$ por uma margem mínima, mas com perda expressiva de macro-F1. Um critério baseado no macro-F1 teria escolhido $\tau = 0{,}90$ (Apêndice C). Como esse critério foi fixado antes de qualquer resultado, ele não foi alterado, e a consequência é registrada aqui.

Os resultados sustentam o uso do Two-Stage como estratégia de referência preliminar do RECLin-PT, pelo maior F1 e pela maior precisão observados na classe clinicamente mais crítica, em que um falso positivo apaga um achado do prontuário. Não sustentam, porém, afirmar que ele é superior, nem tomá-lo como a configuração final: sua vantagem sobre a Pair-Aware é de uma fração de ponto, e nenhuma de suas diferenças é distinguível de zero, nem mesmo com o viés favorável de um limiar escolhido no DEV. Em particular, o protocolo condiciona qualquer atribuição do efeito à arquitetura a uma diferença positiva contra o baseline calibrado, que controla o efeito de apenas recalibrar a decisão, e essa diferença não foi detectada no DEV. A Pair-Aware é, assim, a alternativa mais forte até a avaliação no teste, e a variante exploratória com MLP não acrescentou ganho observado sobre a cabeça linear.

7.3 A CLASSE `ASSOCIATED_WITH`

A classe `associated_with` é a mais difícil para todas as estratégias. Dois fatores podem contribuir para isso. O primeiro, uma hipótese conceitual, é que distinguir associação genuína de mera proximidade textual seja ambíguo em texto clínico telegráfico, em que entidades vizinhas frequentemente não mantêm relação anotada, como no exemplo do Quadro 3. O segundo é metodológico e foi medido: o F1 da classe é calculado sob o teto de *recall* imposto pela janela, que deixa de fora cerca de 8% das relações `associated_with` do DEV, contra cerca de 3% das de `negation_of` (Seção 4.5.5). No Two-Stage, a dificuldade aparece na forma de *recall* baixo, pelo roteamento restritivo; nas demais estratégias, na forma de precisão baixa. Como o foco deste trabalho é a negação, nenhuma decisão foi otimizada para essa classe.

7.4 LIMITAÇÕES

A limitação mais séria é a ausência de avaliação no teste. Todos os números são de DEV, o mesmo conjunto usado para escolher épocas e limiares; os do Two-Stage e do baseline calibrado são otimistas por construção, e mesmo as escolhas de época introduzem algum otimismo nas demais estratégias. A avaliação definitiva será feita no teste, uma única vez, depois de congelada a configuração.

Além disso: (i) há uma única semente, de modo que não é possível separar o efeito de uma estratégia ou de um *encoder* da variação do treino; os intervalos de confiança medem só a incerteza sobre os exemplos; (ii) as estratégias foram comparadas com um único *encoder*, e a comparação de *encoders*, com uma única estratégia; (iii) o baseline com o BERTimbau-base e a Pair-Aware MLP estão fora do escopo pré-registrado; (iv) em todas as execuções de três rótulos, a época escolhida foi a última permitida, o que sugere que mais treino poderia mudar os valores absolutos; (v) o limiar τ e o `min_freq` do léxico ficaram no extremo das respectivas grades; (vi) o *fine-tuning* restrito, previsto no protocolo, não foi executado; (vii) a tarefa pressupõe entidades já anotadas, e o erro de uma etapa automática de reconhecimento de entidades não é considerado; e (viii) o achado se limita a esta formulação de três classes e à escala *base* dos modelos (Seção 5.2).

7.5 AMEAÇAS À VALIDADE

Quanto à validade interna, as partições congeladas e verificadas por *hash*, a reconstrução dos dados com offsets alinhados ao texto e o particionamento em nível de documento mitigam o vazamento de dados e os erros de alinhamento. Persistem, contudo, pontos de procedência que precisam ser resolvidos antes da avaliação no teste. As execuções foram produzidas com quatro versões distintas do código, enquanto o protocolo prevê uma identidade única na conferência final. A comparação dos manifestos mostrou que, entre o baseline BioBERTpt-all e o baseline BERTimbau-base, o código da estratégia baseline é idêntico, e as diferenças estão em outras estratégias e em infraestrutura; para as demais execuções, as diferenças correspondem às mudanças documentadas da Pair-Aware e à criação da variante MLP. Três execuções

foram retomadas a partir de um *checkpoint* (o baseline com o BERTimbau-base, a Pair-Aware MLP e o estágio 1 do Two-Stage) e registram apenas a sessão final de treino (Apêndice D), e todas as sessões registradas trazem um aviso de não determinismo de uma rotina de atenção da GPU, emitido apesar de os algoritmos determinísticos terem sido solicitados. Nenhum desses pontos altera as métricas recalculadas a partir das predições, mas todos limitam a reprodutibilidade estrita.

Uma segunda ameaça diz respeito à independência das instâncias: o *bootstrap* pareado trata os pares candidatos como independentes, embora pares de um mesmo documento compartilhem texto, de modo que os intervalos reportados são provavelmente mais estreitos que os reais. A comparação pareada atenua, mas não elimina, esse efeito. Quanto à validade externa, o SemClinBr representa um conjunto específico de instituições e de estilos de redação, e as 26 anomalias de anotação mantidas no corpus impõem um limite ao desempenho alcançável, igual para todos os sistemas.

8 CONCLUSÃO

Este trabalho teve como objetivo desenvolver o RECLin-PT, modelo de extração de relações em notas clínicas em português sobre o corpus SemClinBr, com ênfase na relação `negation_of`. Quanto à primeira parte da pergunta de pesquisa, como desenvolver o modelo, o trabalho construiu sua cadeia de dados, com a reconstrução do corpus a partir dos XML, as partições congeladas e o gerador de pares candidatos, e, sobre ela, a representação do par por marcadores e o ajuste fino de *encoders*, com cinco estratégias de modelagem implementadas, todas avaliadas no DEV com o BioBERTpt-all, além do baseline com o BERTimbau-base. Os experimentos realizados sobre essa base indicaram uma estratégia de referência preliminar, mas a configuração final do modelo ainda não foi selecionada nem validada no teste, de modo que essa parte da resposta permanece incompleta. Quanto à segunda parte, a influência do *encoder* e da estratégia sobre o desempenho, a resposta disponível é provisória e delimitada: na única comparação direta realizada, a estratégia baseline, o pré-treinamento clínico não trouxe vantagem detectável no DEV; com o mesmo *encoder*, as diferenças observadas entre estratégias na classe-alvo foram maiores do que a diferença entre *encoders*, embora apenas uma delas tenha sido detectada pelo *bootstrap* pareado.

8.1 PRINCIPAIS RESULTADOS

Na estratégia baseline, o BioBERTpt-all e o BERTimbau-base alcançam F1 de `negation_of` de $0{,}802$ e $0{,}800$, com intervalo de confiança da diferença centrado em zero, e o *encoder* geral, com cerca de 61% dos parâmetros, fica ligeiramente à frente no macro-F1. Com o BioBERTpt-all, todas as estratégias melhoram o F1 de `negation_of` do baseline, sobretudo pela precisão. O Two-Stage obtém o maior F1 ($0{,}831$) e a maior precisão ($0{,}798$) na classe-alvo, ao custo de *recall* e, principalmente, da classe `associated_with`, e é usado como estratégia de referência preliminar. Sua vantagem, contudo, não se distingue da Pair-Aware ($0{,}829$) nem dos demais sistemas, e seu limiar foi escolhido no próprio DEV, no extremo da grade. A Pair-Aware tem o maior macro-F1 ($0{,}741$) e é a única estratégia com diferença detectada sobre o baseline. Para o desenvolvimento do RECLin-PT, esses resultados indicam que a escolha entre

Two-Stage e Pair-Aware continua em aberto e que o *encoder* de domínio geral é um candidato viável, a confirmar nas demais estratégias.

8.2 LIMITAÇÕES

Essas conclusões não podem ser tomadas como definitivas. Todos os números são de DEV, o mesmo conjunto usado nas escolhas de época e de limiar; há uma única semente; os *encoders* foram comparados em uma só estratégia, e o BioBERTpt-clin ainda não foi avaliado; e a configuração final do RECLin-PT não foi congelada nem avaliada no teste. As limitações e as ameaças à validade são detalhadas no Capítulo 7 (Seção 7.4 em diante).

8.3 CONTRIBUIÇÕES

As principais contribuições são: (i) o desenvolvimento do RECLin-PT, com a implementação e a comparação, sob o mesmo protocolo, de cinco estratégias de modelagem para a extração de relações clínicas em português, do classificador direto a uma arquitetura em dois estágios, usada como referência preliminar da versão atual; (ii) a comparação, sob configuração idêntica, entre um *encoder* clínico e um geral na extração de relações sobre o SemClinBr, que subsidia a escolha do *encoder* do modelo e oferece evidência inicial sobre a lacuna descrita no Capítulo 3; (iii) a cadeia de dados que sustenta essas comparações, com os dados reconstruídos dos XML e o texto alinhado aos offsets de anotação, partições em nível de documento congeladas por *hashes* e um gerador determinístico de pares candidatos compartilhado por todas as estratégias, com o teto de *recall* quantificado; (iv) uma caracterização do corpus que evidencia o desbalanceamento das relações e a quase adjacência dos pares de negação; e (v) um protocolo pré-registrado e uma matriz de rastreabilidade que ligam cada escolha e cada número do texto ao artefato de origem.

8.4 TRABALHOS FUTUROS

Os próximos passos decorrem diretamente das limitações registradas e são necessários para completar a avaliação do RECLin-PT:

- completar a comparação de *encoders*, treinando o BERTimbau-base e o BioBERTpt-clin nas mesmas estratégias, em especial no Two-Stage e na Pair-Aware;
- congelar a configuração definitiva, unificar a identidade do código das execuções e conferir a proveniência de todas elas, como prevê o protocolo;
- avaliar no teste, uma única vez, cada sistema congelado, e aplicar as comparações pré-registradas, em particular a do Two-Stage contra o baseline e contra o baseline calibrado;
- repetir os experimentos com mais sementes, para separar o efeito das estratégias e dos *encoders* da variação do treino;
- executar o *fine-tuning* restrito previsto no protocolo;
- investigar, em novo protocolo, critérios de limiar que considerem as três classes, grades que não terminem no valor escolhido e orçamentos de treino maiores, já que a melhor época coincidiu com o teto;
- enriquecer a entrada com o tipo semântico das entidades e integrar uma etapa automática de reconhecimento de entidades, medindo a extração de relações em um cenário fim a fim.

REFERÊNCIAS

ALMEIDA, V. A. de *et al.* **Clinical named entity recognition in the Portuguese language: a benchmark of modern BERT models and LLMs**. 2026. ArXiv:2603.26510 [cs.CL]. Pré-publicação.

CHAPMAN, W. W. *et al.* A simple algorithm for identifying negated findings and diseases in discharge summaries. **Journal of Biomedical Informatics**, v. 34, n. 5, p. 301–310, 2001.

CONNEAU, A. *et al.* Unsupervised cross-lingual representation learning at scale. In: **Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2020. p. 8440–8451.

DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. In: **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)**. [S.l.]: Association for Computational Linguistics, 2019. p. 4171–4186.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895–1923, 1998.

FORMAN, G.; SCHOLZ, M. Apples-to-apples in cross-validation studies: Pitfalls in classifier performance measurement. **ACM SIGKDD Explorations Newsletter**, v. 12, n. 1, p. 49–57, 2010.

FRAILE NAVARRO, D. *et al.* Clinical named entity recognition and relation extraction using natural language processing of medical free text: A systematic review. **International Journal of Medical Informatics**, v. 177, p. 105122, 2023.

LEE, J. *et al.* BioBERT: A pre-trained biomedical language representation model for biomedical text mining. **Bioinformatics**, v. 36, n. 4, p. 1234–1240, 2020.

LIN, C. *et al.* Does BERT need domain adaptation for clinical negation detection? **Journal of the American Medical Informatics Association**, v. 27, n. 4, p. 584–591, 2020.

OLIVEIRA, L. E. S. e. *et al.* SemClinBr – a multi-institutional and multi-specialty semantically annotated corpus for Portuguese clinical NLP tasks. **Journal of Biomedical Semantics**, v. 13, n. 1, p. 13, 2022.

SCHNEIDER, E. T. R. *et al.* BioBERTpt – a Portuguese neural language model for clinical named entity recognition. In: **Proceedings of the 3rd Clinical Natural Language Processing Workshop**. [S.l.]: Association for Computational Linguistics, 2020. p. 65–72.

SHIMAOKA, A. M. *et al.* Large language models in Portuguese for healthcare: a systematic review. **Research on Biomedical Engineering**, v. 42, n. 1, p. 13, 2026.

SILVA, D. Pinheiro da *et al.* Exploring named entity recognition and relation extraction for ontology and medical records integration. **Informatics in Medicine Unlocked**, v. 43, p. 101381, 2023.

SOARES, L. B. *et al.* Matching the blanks: Distributional similarity for relation learning. In: **Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)**. [S.l.]: Association for Computational Linguistics, 2019. p. 2895–2905.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for Brazilian Portuguese. In: **Intelligent Systems (BRACIS 2020)**. [S.l.]: Springer, 2020. (Lecture Notes in Computer Science, v. 12319), p. 403–417.

UZUNER, Ö. *et al.* 2010 i2b2/VA challenge on concepts, assertions, and relations in clinical text. **Journal of the American Medical Informatics Association**, v. 18, n. 5, p. 552–556, 2011.

VASWANI, A. *et al.* Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

Apêndices

APÊNDICE A – HASHES SHA-256 DAS PARTIÇÕES CONGELADAS

As partições de treino, desenvolvimento e teste reconstruídas dos XML do SemClinBr foram congeladas após sua geração (semente 42, estratificação pela presença de `negation_of`, nível de documento). O Quadro 5 apresenta os *hashes* SHA-256 dos arquivos de partição versionados no repositório do projeto e do manifesto que os registra, junto com as contagens, a proveniência dos XML e as anomalias mantidas. Qualquer alteração nos arquivos altera o *hash*, o que permite a verificação independente da integridade das partições. O código recusa combinar versões de dados numa mesma execução ou tabela, e cada execução registra os *hashes* das partições que usou.

Quadro 5 – SHA-256 das partições congeladas e do manifesto.

Partição	Arquivo	SHA-256
Treino	`train.jsonl`	`b8aaafce423afb9cda49fa5d116c14b1 4d6b9c2d09a0521bff4ef8733305d034`
Desenvolvimento	`dev.jsonl`	`19feb024ca9d60f0016491b2e9bc35ab 7de9b5cc384e0d22ba34b21a85a9f99c`
Teste	`test.jsonl`	`47d40d0b06f23714a8f332e3f8455bff 0471bb68fad7b4a835b2aa72812e9666`
Manifesto	`MANIFEST.json`	`18264860a3d8fff7bcc335b8f5703a55 d60e08893a09be2afa20b1ea446d3b70`

Fonte: elaborado pelo autor.

As partições contêm, respectivamente, 800, 100 e 100 documentos, com as contagens de relações e de pares candidatos da Tabela 2.

APÊNDICE B – LÉXICO DE PISTAS DE NEGAÇÃO

O Quadro 6 registra o léxico de pistas congelado usado pelo filtro léxico (Seção 5.4.3). As formas foram induzidas exclusivamente do treino, a partir do primeiro argumento (e_1) dos pares candidatos `negation_of`, e são comparadas após remoção de acentos, colapso de espaços e conversão para caixa baixa. O limiar `min_freq`$= 10$ foi escolhido antes da fase experimental, por validação cruzada em 5 partes só no treino, na grade $\{1,2,3,5,10\}$, pelo maior F1 do léxico como detector de `negation_of`. Nenhuma estratégia de três rótulos, nem o Two-Stage, recebe esse léxico: ele é usado apenas pelo filtro.

Quadro 6 – Léxico de pistas congelado (D4): `min_freq`$= 10$, 8 formas, `lexico_sha1` `8af0716633e9`.

Forma normalizada	Ocorrências como e_1 (treino)
`sem`	662
`nega`	353
`nao`	128
`ausente`	12
`ausencia`	11
`s`	11
`evacuacao`	10
`s/`	10

Fonte: elaborado pelo autor.

APÊNDICE C – BUSCA DO LIMIAR DO TWO-STAGE

A Tabela 9 reproduz a busca completa do limiar τ do Two-Stage no DEV, registrada no arquivo de congelamento do limiar. Para cada valor da grade, o *pipeline* completo foi executado pelo fluxo real, com o estágio 2 aplicado só aos pares roteados. O critério do protocolo é o maior F1 de `negation_of`, com desempate pelo macro-F1. Esses valores foram usados para a escolha de τ e são, por isso, otimistas como estimativa de desempenho.

Tabela 9 – Busca de τ do Two-Stage no DEV (pipeline completo, fluxo real). * valor congelado.

τ	Pares roteados	VP/FP/FN neg	F1 neg	Macro-F1
0,05	3 901	144/99/6	0,7328	0,6527
0,10	3 407	143/77/7	0,7730	0,6811
0,15	3 131	142/71/8	0,7824	0,6926
0,20	2 968	142/68/8	0,7889	0,6999
0,25	2 825	142/64/8	0,7978	0,7071
0,30	2 686	142/60/8	0,8068	0,7135
0,35	2 605	141/59/9	0,8057	0,7160
0,40	2 518	140/58/10	0,8046	0,7183
0,45	2 432	139/58/11	0,8012	0,7197
0,50	2 331	139/57/11	0,8035	0,7232
0,55	2 246	139/56/11	0,8058	0,7249
0,60	2 179	139/55/11	0,8081	0,7270
0,65	2 089	139/55/11	0,8081	0,7308
0,70	1 985	138/52/12	0,8118	0,7355
0,75	1 857	138/47/12	0,8239	0,7411
0,80	1 711	138/45/12	0,8288	0,7469
0,85	1 560	137/45/13	0,8253	0,7478
0,90	1 303	136/42/14	0,8293	0,7509
0,95*	592	130/33/20	0,8307	0,7249

Fonte: elaborado pelo autor.

APÊNDICE D – HISTÓRICO DE TREINO POR ÉPOCA

Este apêndice reúne a evolução por época das execuções no DEV, resumida na Seção 6.1 e na Seção 6.4. A Tabela 10 apresenta as execuções de três rótulos, com a época selecionada pelo maior macro-F1 no DEV. As Tabelas 11 e 12 apresentam os dois estágios do Two-Stage, cada um com o seu critério de seleção. Os valores vêm dos arquivos `treino.json` de cada execução.

As durações registram o tempo de cada época na sessão em que ela foi concluída. Três execuções foram interrompidas e retomadas a partir de um *checkpoint*: o baseline com o BERTimbau-base, a Pair-Aware MLP e o estágio 1 do Two-Stage. Em cada uma delas, o registro preserva apenas a sessão final; a época retomada mostra a duração da parte executada nessa sessão, e as épocas anteriores, concluídas em sessões sem registro, não podem ser conferidas. Por isso, as durações não servem para comparar o custo de treino entre estratégias.

Tabela 10 – Evolução por época no DEV das execuções de três rótulos. $*$ marca a época selecionada (maior macro-F1 no DEV).

Execução	Época	Perda (treino)	Perda (DEV)	Macro-F1	F1 neg	Duração (min)
Baseline (BioBERTpt-all)	1	0,5642	0,3622	0,580	0,507	62,2
	2	0,3226	0,3544	0,712	0,798	61,4
	3$*$	0,2550	0,3609	0,719	0,802	60,6
Baseline (BERTimbau-base)	1	0,5411	0,4312	0,688	0,778	66,4‡
	2	0,2882	0,3774	0,713	0,799	67,3‡
	3$*$	0,2265	0,3930	0,723	0,800	20,3†
Pair-Aware	1	0,4165	0,3964	0,702	0,788	58,4
	2	0,2543	0,3330	0,727	0,802	59,3
	3$*$	0,1896	0,3803	0,741	0,829	59,7
Pair-Aware MLP	1	0,4219	0,3623	0,709	0,795	24,1‡
	2	0,2558	0,3322	0,718	0,795	10,3†
	3$*$	0,1915	0,3683	0,737	0,817	68,1

† Época interrompida e retomada a partir de um *checkpoint*; a duração cobre apenas a sessão final (BERTimbau-base, época 3: 658 dos 2 386 passos; Pair-Aware MLP, época 2: 272 dos 2 386 passos). ‡ Época concluída em sessão anterior, sem registro de sessão preservado; a duração consta do histórico de treino, mas não pode ser conferida com o registro da sessão. As durações não são comparáveis entre execuções como medida de custo.

Fonte: elaborado pelo autor.

Tabela 11 – Two-Stage, estágio 1 (relação × `no_relation`) no DEV completo: perdas, AP, precisão e *recall* de `relacao`, *recall* nos pares `negation_of` e duração. ∗ época selecionada (maior AP).

Época	Perda (treino)	Perda (DEV)	AP	P	R	R nos pares neg	Duração (min)
1	0,4349	0,3506	0,506	0,315	0,778	0,973	59,9‡
2∗	0,2830	0,3392	0,544	0,321	0,820	0,947	60,8‡
3	0,2252	0,3597	0,533	0,339	0,798	0,960	37,1†

† Época interrompida e retomada a partir de um *checkpoint*; a duração cobre apenas a sessão final (estágio 1, época 3: 1 158 dos 2 386 passos). ‡ Época concluída em sessão anterior, sem registro de sessão preservado; a duração consta do histórico de treino, mas não pode ser conferida com o registro da sessão. As durações não são comparáveis entre execuções como medida de custo.

Fonte: elaborado pelo autor.

Tabela 12 – Two-Stage, estágio 2 (`negation_of` × `associated_with`) nos 913 pares do DEV com relação anotada: perdas, precisão, *recall* e F1 de `negation_of` e duração. ∗ época selecionada (maior F1 de `negation_of`).

Época	Perda (treino)	Perda (DEV)	P neg	R neg	F1 neg	Duração (min)
1	0,3949	0,1898	0,952	0,933	0,943	2,9
2	0,0536	0,1291	0,953	0,940	0,946	3,0
3	0,0237	0,0835	0,942	0,973	0,957	3,1
4	0,0172	0,1255	0,961	0,973	0,967	3,4
5	0,0107	0,1330	0,960	0,967	0,963	3,1
6	0,0040	0,1562	0,967	0,967	0,967	3,1
7	0,0039	0,1427	0,960	0,967	0,963	3,1
8∗	0,0014	0,1537	0,967	0,973	0,970	3,4
9	0,0009	0,1722	0,973	0,953	0,963	3,1
10	0,0004	0,1660	0,967	0,967	0,967	3,1

Fonte: elaborado pelo autor.

APÊNDICE E – RESULTADO EXPLORATÓRIO DA PAIR-AWARE MLP

A Tabela 13 apresenta a variante Pair-Aware MLP, criada depois do protocolo e mantida fora dele (Seção 5.4.4), ao lado da Pair-Aware do protocolo. O resultado é exploratório: não integra a comparação pré-registrada, não é evidência confirmatória e não entra na escolha da estratégia de referência.

Tabela 13 – Resultado exploratório no DEV (fora do protocolo pré-registrado): Pair-Aware MLP ao lado da Pair-Aware do protocolo, BioBERTpt-all, seed 42.

Sistema	P	R	F1	VP/FP/FN	Macro-F1	MCC
Pair-Aware (protocolo, D10)	0,742	0,940	0,829	141/49/9	0,741	0,497
Pair-Aware MLP (exploratória)	0,715	0,953	0,817	143/57/7	0,737	0,498

Fonte: elaborado pelo autor.